

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science and Technology

Master Thesis

基於人流資料、土地使用分區圖以及 Google 趨勢資料

進行捷運進出站人數預測-以台北捷運為例

Forecast the Crowd Flow of Mass Rapid Transit Based on
the People Flow Data, the Land Use Districts and the Data
from Google Trends - A Case Study on Taipei Mass Rapid
Transit

盧政傑

Zheng-Jie Lu

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D

中華民國 110 年 6 月

June 2021

摘要

近年來，台灣台北地區隨著捷運系統的逐漸完備，人們的活動開始大量仰賴捷運系統，而捷運系統每個站點的運量也深深影響了台北地區的人流變化。也因此若要掌握台北地區的人流變化，許多學者們會從預測捷運站點的運量變化開始。在過往，已經有許多學者嘗試使用各種統計方法、機器學習方法，以及深度學習方法來進行預測。然而我們發現這些方法都有其缺陷，包含(1)學者們都必須先獲取該站點大量的歷史運量後，才能進行預測，而這樣的模式會讓新的捷運站點或是因各種開發案而造成捷運站周圍有大幅度變化的站點運量無法預測。(2)現行捷運運量預測模型的開發，大多是一個站點搭配一個模型，所以其運算成本都十分昂貴，讓其難以被應用至真實環境中。也因此，本論文提出了兩大概念來克服上述缺陷，包含(1)使用捷運站周圍的大量時空欄位來先幫捷運系統的站點進行分群，而分在同一群的站點僅會使用同一模型建模與預測。以及(2)嘗試透過建立集成式學習模型針對新站點進行流量預測。而藉由上述的第一個概念，我們除了預期可用新站點的周圍時空資料來辨析新站點屬於哪個群組，並因此估算其流量外，我們也可確保整個捷運系統要建的模型數量大幅降低。而藉由第二個概念，在新站點設立時，透過數個相似站點模型進行新站點流量評估，讓流量評估不再有數個結果去做取捨。最終本論文則會透過真實的台北捷運運量資料，與各式捷運站周圍的時空資料來進行模型的建置，實驗結果則驗證了我們所提出方法的有效性。

關鍵字： 捷運乘客流量、訓練時間成本、Hammerstein Recurrent Neural Network(HRNN)、Gated Recurrent Unit(GRU)、支持向量回歸(SVR)

ABSTRACT

People in Taipei are increasingly relying on the city's mass rapid transit (MRT) system for their commute to work or school, especially with the construction of more and more stations. As a result, the flow of people in the Taipei area has been affected. In order to understand how the flow of people will change in the future, an area forecasting model of the flow of people must first be established. Experts and scholars have attempted to establish such forecasting models by statistics, machine learning, or deep learning; however, a number of defects must be solved. First, an enormous amount of historical data is needed to train these models, and difficulties in training manifest in cases of new stations or substantial changes in the surrounding areas or environment of stations. Second, the cost of training is very high due to each individual station having its own forecasting model. In this research, we propose two opinions to overcome these defects. The first is clustering MRT stations by spatiotemporal data before training the models, which only requires that these group models be established to forecast the flow of people in the future. The second is to establish an ensemble model for forecasting a new station, where the use of spatiotemporal data of a new station should be able to predict which groups are the most similar. Not only can this estimate the flow of people in the future, but it can also reduce training costs. Following our simulation using real metro data and spatiotemporal data of MRT stations in Taipei, the results confirm the efficacy and feasibility of the options proposed.

Keywords: People Flow, Training Cost, Hammerstein Recurrent Neural Network (HRNN), Gated Recurrent Unit (GRU), Support Vector Regression (SVR)

誌謝

這兩年中要感謝的人太多了細數不完，不論是陳奕中教授的指導、家人的支持、學長姊的幫助與同儕的相互扶持，都是協助我完成碩士論文的一個部分，在此致上最真摯的感謝，謝謝你們。

在眾多人物之中，最為感謝的莫過於陳奕中老師 aka.指導教授，從大三開始就和陳老師學習如何做資料分析、資料分析的思維與深度學習的領域，在實驗室的幾年中，雖然我資質比較駑鈍一點，沒辦法成就一番大事業，但非常感謝教授不辭辛勞地提拔我，不僅專業知識上的培養、解決問題的思維建置與心靈上的交流，更推薦我去參與一些計劃案，讓我有計劃案能夠與外界的人合作完成一些事情，在此，政傑向您致上最高的謝意，謝謝您這幾年的提拔與指導，謝謝。

再來，我要感謝我的家人，願意讓我成為家裡的米蟲，又被多養了兩年，這兩年來辛苦了，再來換我養你們了。最後，感謝一路上陪我成長的每個人，不論是豪哥、東錡、映均、詠緹、力誠、姿靜等，讓我順利拿到碩士學位。願在往後的日子，大家能夠順利成長。

目錄

摘要.....	ii
ABSTRACT.....	iii
誌謝.....	iv
目錄.....	v
表目錄.....	viii
圖目錄.....	x
第一章 緒論.....	1
1.1 研究背景及動機.....	1
1.2 研究目的.....	3
1.3 研究範圍.....	4
1.4 研究流程.....	5
第二章 文獻探討.....	7
2.1 空間聚類相關研究.....	7
2.1.1 基於時間序列進行空間聚類.....	7
2.1.2 基於周圍環境特性進行空間聚類.....	7
2.2 時間序列相似度計算方法介紹.....	8
2.2.1 Pearson Correlation.....	8
2.2.2 Cosine Similarity.....	8
2.2.3 False Nearest Neighbors.....	9
2.2.4 Dynamic Time Warping.....	9
2.3 捷運流量預測的相關研究介紹.....	10
2.4 各預測模型的相關研究介紹.....	10
2.4.1 Support Vector Regression.....	10
2.4.2 Recurrent Neural Network.....	11
2.4.3 Long Short-Term Memory.....	12
2.4.4 Gated Recurrent Unit.....	12

2.4.5 上述各種建模方法之討論.....	13
2.5 小結.....	14
第三章 資料集	15
3.1 本研究選取時空資料的邏輯.....	15
3.2 台北捷運資料.....	16
3.3 行動數據資料.....	18
3.4 輔助訓練與分類的資料.....	18
第四章 研究方法	21
4.1 基於地理特徵將捷運站分類.....	22
4.2 捷運站點流量動態相似度計算與分群.....	26
4.2.1 資料前處理.....	26
4.2.2 Cosine Similarity 計算相似度.....	28
4.2.3 DTW 計算相似度.....	29
4.2.4 捷運站相似分群.....	31
4.3 建立各群預測模型.....	32
4.3.1 SVR 流量預測模型.....	32
4.3.2 HRNN 流量預測模型.....	33
4.3.3 GRU 流量預測模型	35
4.3.4 集成式學習模型.....	37
4.3.5 模型績效評估.....	38
4.4Online 說明.....	38
第五章 實驗模擬	39
5.1 資料集與實驗參數介紹.....	39
5.1.1 台北捷運資料.....	39
5.1.2 行動數據.....	40
5.1.2 分類資料與輔助訓練資料.....	40
5.2 地理空間特徵分類結果.....	41

5.3 動態相似度分群結果.....	42
5.4 預測模型參數選擇與最佳結果.....	43
5.4.1 三重國小站.....	45
5.4.2 小碧潭站.....	56
5.4.3 頂埔站.....	66
5.5 小結.....	75
第六章 結論.....	77
參考文獻.....	78
附件一 所有捷運站區域比例表.....	84
附件二 模型預測結果折線圖.....	88



表目錄

表 1、台北捷運車站出入口座標資料表	17
表 2、台北捷運站點間進出站人數表	17
表 3、台北捷運各站出站人數表	17
表 4、台北捷運各站進站人數表	17
表 5、整理後行動人流資料表	18
表 6、Google Trends 資料表	20
表 7、三和國中站土地使用分區比例表	24
表 8、區域分類閾值表	24
表 9、三民高中站土地使用分區比例表	25
表 10、部分站點分區未達標比例表	26
表 11、台北捷運各站每日平均出站人數表	27
表 12、台北捷運各站每日平均進站人數表	27
表 13、捷運站流量相似度表	31
表 14、MAPE 能力分級表	38
表 15、地理空間特徵分類結果表	41
表 16、動態相似度分群結果表	42
表 17、三和國中站群組一日模型訓練集 RMSE 績效表	46
表 18、三和國中站群組一日模型訓練集 MAPE 績效表	46
表 19、三和國中站群組一日模型測試集 RMSE 績效表	48
表 20、三和國中站群組一日模型測試集 MAPE 績效表	48
表 21、三和國中站群組之一日集成式學習模型預測三重國小站績效表	50
表 22、三和國中站群組三日模型訓練集 RMSE 績效表	50
表 23、三和國中站群組三日模型訓練集 MAPE 績效表	51
表 24、三和國中站群組三日模型測試集 RMSE 績效表	52
表 25、三和國中站群組三日模型測試集 MAPE 績效表	52
表 26、三和國中站群組之三日集成式學習模型預測三重國小站績效表	55
表 27、三和國中站 群組一日模型訓練時間表	55
表 28、三和國中站 群組三日模型訓練時間表	55
表 29、木柵站群組一日模型訓練集 RMSE 績效表	58
表 30、木柵站群組一日模型訓練集 MAPE 績效表	58
表 31、木柵站群組一日模型測試集 RMSE 績效表	59
表 32、木柵站群組一日模型測試集 MAPE 績效表	59
表 33、木柵站群組之一日集成式學習模型預測小碧潭站績效表	60
表 34、木柵站群組三日模型訓練集 RMSE 績效表	61
表 35、木柵站群組三日模型訓練集 MAPE 績效表	61

表 36、木柵站群組三日模型測試集 RMSE 績效表	62
表 37、木柵站群組三日模型測試集 MAPE 績效表	63
表 38、木柵站群組之三日集成式學習模型預測小碧潭站績效表	64
表 39、小碧潭站	65
表 40、小碧潭站	65
表 41、丹鳳站群組一日模型訓練集 RMSE 績效表	67
表 42、丹鳳站群組一日模型訓練集 MAPE 績效表	68
表 43、丹鳳站群組一日模型測試集 RMSE 績效表	69
表 44、丹鳳站群組一日模型測試集 MAPE 績效表	69
表 45、丹鳳站群組一日集成式學習模型績效表	70
表 46、丹鳳站群組三日模型測試集 RMSE 績效表	71
表 47、丹鳳站群組三日模型測試集 MAPE 績效表	71
表 48、丹鳳站群組三日模型測試集 RMSE 績效表	72
表 49、丹鳳站群組三日模型測試集 MAPE 績效表	72
表 50、丹鳳站群組三日集成式學習模型績效表	73
表 51、丹鳳站群組 一日模型訓練時間表	74
表 52、丹鳳站群組 三日模型訓練時間表	74

圖目錄

圖 1、台北捷運建立模型示意圖	2
圖 2、研究流程圖	6
圖 3、SVM 分類示意圖	11
圖 4、中正紀念公園附近都市計畫使用分區圖	19
圖 5、板橋捷運站於 Google Trends 趨勢搜尋示意圖	20
圖 6、研究流程圖。(a)預測一日流量流程圖，(b)訓練三日流量流程圖	22
圖 7、國土規劃地理資訊圖台上三和國中站地理資訊圖	23
圖 8、國土規劃地理資訊圖台之三和國中站都市計畫使用分區圖	23
圖 9、國土規劃地理資訊圖台三和國中站都市計畫使用分區 500 公尺範圍圖	24
圖 10、國土規劃地理資訊圖台上 三民高中站都市計畫使用分區 500 公尺範圍圖	25
圖 11、忠孝新生站捷運站中心與各出口圖	27
圖 12、DTW 示意圖	29
圖 13、三重國小站三和國中站動態規劃結果圖	30
圖 14、三和國中站與三重國小站相似度矩陣空間投射圖	32
圖 15、HRNN 與 RNN 系統相異之處示意圖	34
圖 16、HRNN 架構圖	34
圖 17、GRU 架構圖	36
圖 18、GRU Layer 架構圖	37
圖 19、集成式學習模型示意圖	37
圖 20、台北捷運站各站於 2018 年至 2019 年平均單日流量圖	40
圖 21、三重國小周圍 500 公尺 土地使用分區圖	45
圖 22、三和國中站周圍 500 公尺 土地使用分區圖	45
圖 23、五種模型訓練萬隆站 2018 年至 2019 年進站人數折線圖	47
圖 24、萬隆站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖	49
圖 25、一日集成式學習模型測試三重國小站於 2018 年 1 月 8 日 至 2019 年 12 月 9 日進站人數折線圖	49
圖 26、GRU 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖	51
圖 27、DRNN 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖	52
圖 28、三和國中站 HRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖	53
圖 29、三和國中站 GRU 模型預測三重國小站 2018 年至 2019 年進站人數折線圖	54
圖 30、三日集成式學習模型預測三重國小站	54
圖 31、小碧潭站 周圍 500 公尺土地使用分區圖	56

圖 32、木柵站 周圍 500 公尺土地使用分區圖	56
圖 33、辛亥站周圍 500 公尺土地使用分區圖	57
圖 34、五種模型訓練木柵站 2018 年至 2019 年進站人數折線圖	58
圖 35、木柵站五種模型預測小碧潭站 2018 年至 2019 年進站人數折線圖	59
圖 36、一日集成式學習模型訓練小碧潭站	60
圖 37、GRU 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖	61
圖 38、SimRNN 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖	62
圖 39、辛亥站 HRNN 模型預測小碧潭站 2018 年至 2019 年進站人數折線圖	63
圖 40、木柵站 GRU 模型預測小碧潭站 2018 年至 2019 年進站人數折線圖	63
圖 41、三日集成式學習模型測試小碧潭站 於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖	64
圖 42、頂埔站周圍 500 公尺土地使用分區圖	66
圖 43、丹鳳站周圍 500 公尺土地使用分區圖	66
圖 44、頭前庄站周圍 500 公尺土地使用分區圖	67
圖 45、五種模型訓練丹鳳站 2018 至 2019 年進站人數折線圖	68
圖 46、五種模型訓練頭前庄站 2018 年至 2019 年進站人數折線圖	69
圖 47、頭前庄站五種模型預測頂埔站 2018 年至 2019 年進站人數折線圖	70
圖 48、集成式學習模型測試頂埔站	70
圖 49、HRNN 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖	71
圖 50、GRU 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖	72
圖 51、丹鳳站 SimRNN 模型預測頂埔站 2018 年至 2019 年進站人數折線圖	73
圖 52、頭前庄站 HRNN 模型預測頂埔站 2018 年至 2019 年進站人數折線圖	73
圖 53、丹鳳站群組三日集成式學習模型預測頂埔站	74

第一章 緒論

1.1 研究背景及動機

近年來民眾對於減少碳排放的環保意識以日俱增，越來越多民眾從搭乘私人交通工具逐漸轉變成搭乘大眾運輸工具。根據 109 年台北市交通局統計，每日約有 200 萬人次的民眾會透過捷運來進行通勤，不論是上下班或是上下課捷運都是民眾首選的大眾交通工具，而現今雙北市已開通的捷運站共有 108 個站點，未來將會開放三環六線共 208 個捷運站點服務著北北桃三個地區民眾。隨著不斷開通新的站點，北北桃三個地區的商业模式或是民眾移動時交通工具的選擇都會與以往有所不同，這種變化對商家、政府或是捷運公司都會帶來影響。首先，對於地方商家而言，便需要去掌握人群流動的變化，進而擬定相關的行銷策略；對於大型連鎖服務商店，則可以依此考量該站點是否具有競爭力、是否需要駐點等相關商業策略；對於政府而言，過往民眾皆是透過不同的交通方式來往於該地，隨著捷運站點的開通民眾將會在上下班時段聚集在這些捷運站，此時若發生災害將會影響非常多人，若能夠提早知道捷運站點聚集人數，將可以提早規劃災害發生時的緊急應變措施；對於捷運公司來說，能夠預測尖峰與離峰的搭乘人數，達到疏緩人潮或縮減班次，進而達到縮減成本與提升服務滿意度兩大目標。

在過往研究中掌握未來捷運站人群進出站人數最主要的作法皆是透過預測的方法來得知，預測人群流動的研究大多是以統計分析或人工智慧技術進行預測，如 Liu *et al.*[22]將自整合移動平均自回歸模型 (Autoregressive Integrated Moving Average model, ARIMA)、模糊類神經網路(Fuzzy Neural Network, Fuzzy-NN)、長短期記憶類神經網路(Long Short-Term Memory, LSTM)應用於地鐵人群流量預測，三種模型於兩種不同資料驗證集的績效評估中以 LSTM 最佳。Liu *et al.*[23]則是純粹應用遞迴類神經網路(Recurrent Neural Networks, RNN)、LSTM 與 GRU(Gated Recurrent Unit)於廣州地鐵客流量預測，此研究的三個模型的績效皆非常優異，又




圖 1、台北捷運建立模型示意圖

以深度學習的績效優於淺層類神經網路。上述方法雖然都宣稱了他們的有效性，但我們發現這些方法仍然沒有辦法克服兩大問題，包含了新站點的流量預測問題與預測流量的時間成本問題。

首先是新站點的流量無法預測問題。一般來說，不論是深度學習、淺層類神經網路或是機器學習模型，對於新站點模型的訓練皆需要歷史流量來對模型進行調整，但有一個很大的盲點就是新站點並沒有歷史流量，因為該站點尚未開通，對於該站的流量只能透過各種方法進行評估，評估方法可以是透過地緣相近站點的流量、具有相似地區結構站點的流量或是透過其它地區性資訊來進行流量借鏡，或是直接使用這些站點的流量作為新站流量的評估，但相似站與新站點終究不是同一站點，評估的流量必然會有誤差，該如何以最合理的方式去評估新站點的流量且誤差並不會太大使成了新站流量預測的一大問題點。

接著是預測流量的時間成本問題，深度學習模型能有其他模型擁有更好的預測結果，主要歸功於錯綜複雜的隱藏層能夠學習到一般模型無法學習到的地方，使得人群流動數量的預測變得更加精準，雖深度學習模型能夠精準預測人群流動的

數量，但卻也因其為數眾多的隱藏層，使得模型訓練的時間成本十分地高，而在現今開發預測模型的論文中，大多是以少數幾個地區作為研究探討的對象，因此時間成本並不在研究的考量範圍，但應用於多數地區時模型訓練的時間成本將變成致命的問題之一，以台北捷運為例，若以淺層遞迴類神經網路 Simple RNN 模型做訓練，訓練時間約為 20 分鐘，如圖 1 所示，訓練一次全台北捷運站進出站人數的預測模型將訓練 108 個捷運站預測模型，將耗用近 36 小時約為一天半的訓練時間，若將模型改為其他學者所研發以深度學習為基礎的精準模型，將會使得時間成本更加可觀，若要掌握台北捷運各站點進出站人數，如何降低訓練的時間成本將變得十分重要。

1.2 研究目的

為了克服過往研究所遇到的新站點無法預測與預測成本過高問題，本論文提出了兩大概念來進行改善，包含(1)在模型建置前，先行使用捷運站的外部時空資料，如周圍區域的相似，或是不同時間下的運量等，將運量變化相似的幾個站點整合成一個群組，而所有被包含在同一個群組的站點將用同一個模型進行訓練。而這樣的模式將帶來兩大好處。第一個好處是，當政府或捷運公司要討論設置新站點時，他們可以先調查新站點周圍的時空資料，接著依據這些時空資料辨識出新站點與哪個群組的捷運站較相近，並因此可用該群組的模型估算新站點的可能運量。第二個好處則是，因為被分在同一個群組的 n 個站點會用同一個模型來進行建模，故模型量一下子可以減少 n 倍，並因此大幅降低模型的建置成本。(2)在進行新站點流量建模時，嘗試使用集成式學習模型來進行預測。會想使用集成式學習模型，主要是因為與站點外部時空資料相似的站點必然不只有一個，若每一個都用來預測新站點流量將會有不同的流量狀況，反而會讓使用者無法從中進行選擇，過往也有學者透過集成式學習模型來解決流量問題，如 Liu 學者[20]透過不同模型預測相同地點進行地區人流，依此作為資料集再使用簡單的回歸模型去進行異常流量建模，

透過集成式學習模型的輸出去判斷該地點流量是否異常。透過集成式學習模型預測的流量將會是相似站點與不同模型對於同一地點的綜合性評估，該種評估方法是相較於僅用任一相似站點進行新站點評估合理。

依據上述兩大概念，本論文所提出的演算法步驟則可歸類如下面三大步驟，包含(1)透過地理空間特徵進行分類、(2)基於分類結果透過歷史流量進行動態相似度分群、(3)替每組分群結果，建立不同的淺層類神經與深度學習預測模型，現介紹這些步驟如下。步驟一，由於不同捷運站的進出站人數會因為其地理位置或是附近的國土規劃狀況而有所不同，若透過地理空間特徵進行捷運站的分類，不僅能先將狀況相似的站點整併在一起，更能夠減少後續步驟所需的時間成本。步驟二，將分類完的捷運站依照其歷史流量進行分群，雖然步驟一已將捷運站透過不同空間特徵進行分類，但預測模型仍需要依照其歷史流量進行建置，本研究預計透過動態時間校正(Dynamic Time Warping, DTW)與餘弦相似度(Cosine Similarity)進行捷運站歷史流量相似度計算，找尋分類後流量狀況相似的捷運站進行分群。步驟三，當建立完基於地理空間組合特徵工程的捷運站分群後，群內捷運站的歷史流量狀況應為相似的，此時使用任何一個站點的資料訓練預測模型都能夠預測其他捷運站點的進出站人數，進而達到減少訓練的模型數量。特別的，我們則會嘗試不同的預測模型，如淺層類神經網路與深度學習模型，並驗證是否能因我們幫目標模型選取較適合預測的輸入欄位，所以可以使用淺層類神經網路取代深度學習模型，並進一步降低預測成本。

1.3 研究範圍

本研究針對台北捷運站之進出站流量進行探討，使用臺北市資料大平臺公開之台北捷運每日進出站人數資料進行研究，資料起訖時間為 2018 年 01 月 01 日 00:00:00 至 2019 年 12 月 31 日 23:00:00 每小時之各站進出站人數資料，共 108 個

站點。為了探討各捷運站的國土規劃狀況，亦整理了由內政部營建署國土規劃地理資訊圖台所開放之都市計畫使用分區資料，資料為台北市與新北市土地規劃使用狀況。為了使預測結果更加準確，本研究亦整理了由某電信業者所提供的行動數據資料，資料內容為 2018 年 01 月 01 日 00:00:00 至 2019 年 12 月 31 日 23:00:00 每小時之行動資料；與各捷運站點於 Google Trend 上的搜尋趨勢資料作為模型訓練時的特徵資料。

1.4 研究流程

本研究之研究流程如圖 2 所示，分別為問題定義、收集與整理相關資料、相關文獻回顧、資料觀察、建立地理空間組合特徵工程與類神經網路預測模型、實驗模擬與結果、結論與建議，各階段說明如下：

1. 問題定義

建立台北捷運人流預測模型將耗用大量訓練時間，而過往未有學者針對大量的目標進行時間成本探討，而是針對模型預測準確度進行研究，本研究著重於藉由特徵工程將多數相同流量變化狀況相似的捷運站進行分群，並依分群結果建立單群模型，不僅能避免掉個別建模的情況達到減少訓練時間的目的，更能預測新設立的捷運站點流量狀況。

2. 相關文獻回顧

對於過往進行空間聚類與流量預測的研究進行探討，並從文獻中選取適用於本研究的模型如 DTW、Cosine Similarity、ARIMA、SVR、LSTM 等。

3. 收集與整理相關資料

本研究收集由台北市開放平台所開放之捷運各站點進出站人數、各站點於 Google 的搜尋趨勢、某電信業者所提供之行動數據統計資料，時間範圍為 2018 年 01 月 01 日 00:00:00 至 2019 年 12 月 31 日 23:00:00 每小時的各項資料；由台北市開放平台所開放之台北捷運車站出入口座標與內政部營建署國土規劃地理

資訊圖台之都市計畫使用分區資料。

4. 資料觀察

對於資料進行視覺化，了解各捷運站於地理空間具有何種特徵、捷運站的流量變化具有哪些特性與哪些捷運站具有相似的流量變化。以本研究而言，視覺化資料後能夠了解差不多的地理空間資訊的捷運站是否具有相似的流量變化。

5. 建立地理空間組合特徵工程與類神經網路預測模型

此部分將基於資料觀察的結果進行地理空間分類，並計算類別內各站歷史流量相似度進行分群，依此建立不同的流量預測模型。

6. 實驗模擬與結果

對於建置好的預測模型將與其他同類別同分群的捷運站進行流量預測，比較使用地理空間特徵分類後結果探討與比較各模型之訓練時間成本與績效狀況。

7. 結論與建議

根據實驗模擬之結果驗證本研究提出的方法是否不僅能降低訓練時間成本也有良好的預測績效，並依研究結果提出結論與未來從事相關研究的建議。




圖 2、研究流程圖

第二章 文獻探討

本章節將介紹(1)空間聚類相關研究、(2) 歷史流量相似度計算方法介紹、(3)捷運流量預測的相關研究介紹以及(4)各預測模型的相關研究介紹。

2.1 空間聚類相關研究

過往研究中對大致上可以分成基於時間序列與基於周圍環境特性，兩種不同的方法進行空間聚類，以下小節將分別介紹過往學者的研究。

2.1.1 基於時間序列進行空間聚類

捷運站的流量多數為是指過去時間點下該地點的人口聚集量的時間序列資料，過往於這方面的研究較少，但過往學者於這方面的研究皆在分析前先透過不同的標準將資料進行前處理再進行分群或分類的演算法，如 Chen *et al.*[6] 將上海地鐵站的流量透過不同時段與日期，將上海地鐵站人群數量分成 36 個不同資料集，並透過 K-means 與主成分分析進行資料分群。而在多數文獻中，過往基於時間序列聚類的研究多數是為了應用於增進模型預測的精準度，也就是透過增加其他相似的資料輔助模型進行訓練，進而達到更好績效的結果，如 Li *et al.*[19] 透過多尺度徑向基函數(Radial Basis Function, RBF)找尋資料中北京地鐵人群流量區分出異常與非異常時段地鐵站並應用於預測人群流量。

2.1.2 基於周圍環境特性進行空間聚類

周圍環境特性有很多例如地理標籤資訊、地區國家土地使用狀況、地區人口組成等，該種方法對於結果具有極度強大的解釋能力，因為該類研究會考量許多與目標相關的各種周圍環境特性，從中探討其關係並進行空間聚類，如 Wei *et al.* [41] 透過站點乘客流量、站點所在位置、站點附近交通和站點擁有的相關服務，建立地鐵分級模型去計算各站點的評比分數，並依照分數結果進行上海地鐵站分級研究。Tsai & Wang [36]、Kao & Wang[10]則是過地理分群演算法 DBSCAN 與 K-Means 對

於公車站牌進行地理聚類研究。Liu *et al.*[21]則是將上海的共享單車租借透過 DBSCAN 去進行租借站於空間上的密度分佈研究，並提出新的虛擬站點去探討新站點的建設可能性。Zola *et al.*[47]提出基於 DBSCAN 而變化的新聚類方法 Google Trends noun (GTN)進行 Twitter 用戶於各城市的聚集分布狀況。Hu *et al.*[12]透過 Flickr 上具有地理標籤資訊的資料，透過 DBSCAN 去找尋用戶於六個不同國家的六個城市去進行聚類分析，找尋出人們於城市中最關注的區域。

2.2 時間序列相似度計算方法介紹

本研究探討之交通站相似主要是建立在時間序列變化的動態相似程度，找尋時間序列變化相似的捷運站有助於後續相關研究，不論是建立預測模型或是挑選重要特徵，相似度比較都是非常重要的一個環節，相似度計算的方法有很多，例如皮爾森積差相關係數(Pearson Correlation)、Cosine Similarity、假最鄰近點(False Nearest Neighbors, FNN)或 DTW 等。時間序列的相似性需要考慮的東西又與一般資料不同，因為時間序列資料可能會發生時間推移或延遲發作等與時間相關的問題，因此時間序列資料的相似度需要考量時間維度，不能只考慮點與點之間的關係性，也需要考量到時間變化，因此並非每種相似度計算皆適用於時間序列上。

2.2.1 Pearson Correlation

Pearson Correlation 是最常用來探討兩資料之間是否有相同變化狀況的指標，若資料間的變化狀況為同向且變化量相近時其值會越接近 1 也就是正相關，反之則為-1 負相關，若其值為 0 則代表兩變項並沒有任何相關性，然而交通流量為一種時間序列資料，也就是未來的時間序列資料受到過往時間點的影響，即 $t+1$ 受 t 至 $t-k$ 影響，時間性的影響將可能會使資料呈現非線性變化，因此若使用 Pearson Correlation 將可能造成某時間段落高度相關，但另一個時間段又不相關的情況。

2.2.2 Cosine Similarity

Cosine Similarity 則是以向量的方式進行兩組資料間相似情形的計算，當兩組

資料的變化方向越是相近兩組資料應被視為相似的群組。Yu *et al.* [42] 透過 Cosine Similarity 去分辨朝聖聖地人群變化與馬拉松人群變化。Beşiktaş and Mantar[3]將路網流量資訊轉成向量並透過 DBSCAN 結合 Cosine Similarity 進行路網的聚類研究。Peng *et al.*[28]透過 Cosine Similarity 去計算單詞間的相似程度，並用於對抗式生成網路生成情感相似的文本。

2.2.3 False Nearest Neighbors

FNN 的核心理論是建立在時間序列資料具有時間延遲(Time delay)的特性，因此將透過不同的時間延遲去重建資料集，並從中比較資料集點與點之間的變化狀況是否與未來的狀況相似，資料點的變化不相似將被稱為假鄰居點，FNN 便是在計算這些假鄰居點的數量，這些鄰居的數量便是兩個資料集的不相似度。FNN 也被廣泛應用在多數研究中，Vignesh *et al.*[38]透過 FNN 探討美國 639 個地表水流監測站的流量狀況並進行分類。Altındış *et al.*[2]透過 FNN 與拓撲數據分析(Topological Data Analysis ,TDA)去處理腦波訊號(EEG)，並證明了 TDA 的參數決定對於提取 EEG 是非常重要的。Adewole *et al.*[1]則是透過 FNN 去重建與計算與 Nigeria 地區 PM_{2.5} 相關的氣象特徵。

2.2.4 Dynamic Time Warping

DTW 主要應用於語音辨識的波形校正，在聲音中會因為每次的講話速度不一致而使得相同變化形狀的波被拉長，若使用歐式距離將會使得應對應的波形點不會對齊而使得辨識錯誤，DTW 則能夠透過動態規劃來進行波形重構並計算兩波形的相似度，DTW 已被 Li 學者[18]於各種時間序列資料集證實是聚類研究中是非常重要的。Han *et al.*[10]透過 DTW 進行股市的股價變化分析，找尋出變化相似的股票進行聚類與建模。Masnad *et al.*[25]透過三軸加速度器去收集不同年齡、身高、性別之人類活動行為，並透過 DTW 去分析不同狀態下的三軸加速度軌跡狀況。Ramezanpanah *et al.*[30]透過 DTW 去分析不同狀態下機器人模擬人類行為的動作識別，並證實了該方法有著極好的性能。

2.3 捷運流量預測的相關研究介紹

過往於預測交通流量的方法不外乎是透過統計分析、機器學習或是類神經網路，不同的方法皆有其不同的優劣勢部分，Hong *et al.*[11] 比較了季節時間序列模型(Seasonal ARIMA model, SARIMA)、SVR、倒傳遞類神經網路(Back Propagation Neural Network, BPNN)三種不同的模型於板橋市交通流量預測，三個模型中以 SVR 績效表現最佳；Liu *et al.*[22]則比較了比較 ARIMA、模糊類神經網路(Fuzzy Neural Network)、LSTM 於地鐵人群流量預測，其中 LSTM 測試與預測時的績效皆大勝另外兩種方法；Tang *et al.*[35]比較了 SVR 與 ARIMA 於深圳地鐵客流量預測，結果是由 SVR 之績效比 ARIMA 來得更好。Nagy & Simon[26]學者於交通預測研究中比較了 18 種不同的方法，包含了統計、機器學習與類神經網路模型，從研究中發現 GRU 的收斂速度比 LSTM 來得佳，LSTM 與 GRU 的模型性能優於 ARIMA、RNN 等多數模型。從過往的研究中能發現，LSTM 應用於交通流量預測所的績效最佳，其次為 SVR 模型，若要預測交通流量應先考慮使用這兩種模型。

2.4 各預測模型的相關研究介紹

於過往的交通流量預測相關文獻能得知 SVR 與 LSTM 在該領域具有良好的表現，本節將探討 SVR 與 LSTM 的相關研究。LSTM 為 RNN 的變化模型，該類模型常被應用於時間序列資料的預測，RNN 能透過記憶前一個時間點的神經元狀況，給予下次訓練時更多參考的資訊；LSTM 則有三個不同的閥門控制記憶時間點的量，進而達到比 RNN 更加的預測準度，但也因為記憶了比 RNN 更多時間點，使得其運算成本比 RNN 來得高。而為了解決運算成本的問題，學者開發了以更新閥(Update Gate)與重置閥(Reset Gate)取代三個控制閥的 GRU，使得 GRU 的整體架構與 RNN 相似但於記憶的部分則具有 LSTM 的特點。

2.4.1 Support Vector Regression

SVR 為 SVM 的延伸應用，SVM 主要著重在找出一條能夠完美分類資料的線，

如圖 3 中紅色的分類線，該線能夠完美分類兩種不同的資料集分布狀況。而 SVR 則是延伸了 SVM 找出分類線的概念並加上損失函數，將找出來的分類線透過損失函數去貼近資料集的狀況，讓方程式能夠擬合非線性變化的資料集。過往學者因模型的績效非常亮眼，因此將其用來與過往的統計方法進行比較，如 Zhu *et al.*[46]為了預測上海的道路交通流量，透過自迴歸模型(Autoregressive model, AR)、多元自適應回歸模型(Multivariate Adaptive Regression Splines, MARS)等多種統計模型與機器學習 SVR 進行比較，最後結果表明了機器學習的方法優於統計模型方法。也因為其強大的能力，因此有許多學者在不同領域皆應用 SVR 進行研究，如 Nourali & Osanloo[27]則透過 SVR 去估算礦山開採時所需耗費的成本，該方法也被應用於不同領域，如 Chen *et al.*[5]將 SVR 應用於預測辦公室電力負荷。




圖 3、SVM 分類示意圖

2.4.2 Recurrent Neural Network

RNN 是具有記憶前一時間點的時間記憶類神經網路模型，常被用來預測時間序列的相關研究。RNN 的變化模型有許多，例如 RSONFIN[14]、MNN [32]與 HRNN[8]，三種模型皆繼承了 RNN 模型的動態記憶特點並透過不同的理論方法改良 RNN 的學習狀況，其中又以 HRNN 的模型績效勝過另外兩種模型[39]，HRNN 也在高速公路交通流量的預測上擁有良好的成績[15]。

RNN 的變化模型雖有許多種，但上述的模型皆與 RNN 一樣為淺層類神經網路，隨著硬體設備的能力日漸強大，出現了以大量隱藏層學習非線性變化聞名的深層類神經網路，LSTM 與 GRU 則為 RNN 於深層類神經網路的變化模型。

2.4.3 Long Short-Term Memory

LSTM 為深層類神經網路的一種，LSTM 不僅擁有著深層類神經網路數龐大神經元與隱藏層的特點，也就是能夠以不同的角度去學習資料的狀況，讓每層隱藏層之間的權重狀況可以逼近導向資料狀況，更具有三個閥門進行歷史時間點記憶的能力，LSTM 於過往的研究中也有亮眼的成績，Zhang *et al.*[45]結合了卷積類神經網路(Convolutional Neural Networks, CNN)與 LSTM 進行高速公路旅行時間預測。

雖然 LSTM 精準預測未來間點的結果，但因那複雜的運算過程使得模型的訓練時間非常地久，訓練時間過長是每個深層類神經網路的痛點，因此有許多專家學者針對模型的訓練時間進行各種學習改善，其中 GRU 便是以 RNN 基礎，與 LSTM 極為相似的改善模型。

2.4.4 Gated Recurrent Unit

GRU 為 RNN 的改良模型之一，由 Chung *et al.* [8]所提出，其概念主要與 LSTM 一樣能夠記憶長期的歷史的狀況，但透過更新閥與重置閥來取代 LSTM 的輸入閥、輸出閥與遺忘閥，降低了模型訓練時所耗費的運算成本。Sun *et al.*[3]結合了機器學習的概念於 GRU 模型創建了堆疊式 GRU 模型(Selected Stacked GRU, SSGRU)並比較 LSTM、GRU 與 SSGRU 的績效，其中以 SSGRU 績效最佳，其次為 GRU。Wang *et al.*[40]提出 Sequence to Sequence 的模式結合不同模型預測交通流量，並從中比較各模型績效狀況，其中以結合 GRU 的模型預測效能最佳。Zhang *et al.*[44]透過侵入後時間與碰撞時間透過 GRU 來進行預測交叉路口的行車軌跡。

2.4.5 上述各種建模方法之討論

從上述學者於研究中使用的方法中能發現有許多學者使用不同模型預測流量，雖然深度學習模型在這些方法中有亮眼的預測績效，但若在訓練模型時選用錯誤的模型訓練則無法達到最具效益的結果，例如淺層類神經網路就能達到 95%預測準確率，卻使用深層類神經網路做為預測模型去追求那 2%的精準度，而 2%的精準度在研究中並沒有太大的差異，將造成訓練成本的浪費，Han *et al.*[9]透過修剪不必要的神經元去比較有修剪的淺層類神經網路與未修剪的深層類神經網路比較，最終發現透過修剪過神經元的淺層類神經網路績效與深層類神經網路差不多，但是淺層類神經網路的處理速度卻高於深層類神經網路約 3 至 7 倍。Caruana[4]學者則是提出了一種學習策略用於簡單模型的模型能力亦能與複雜的模型相當。淺層遞迴類神經網路 Simple RNN 的變化模型有許多，例如將每次的記憶內容以透過模糊理論作為下一次學習依據的遞迴式自我模糊推理類神經網路(A Recurrent Self-Organizing Neural Fuzzy Inference Network, RSONFIN)[14]、內嵌記憶單元的記憶神經元網路(Memory neuron networks, MNN) [32]或是應用動態識別系統的 Hammerstein Recurrent Neural Network(HRNN) [8]，三種模型皆繼承了 RNN 模型的動態記憶特點並透過不同的理論方法改良 RNN 的學習狀況，並與深層類神經網路比較後而有不差的績效狀況，三個模型中又以 HRNN 的模型績效與運算時間勝過另外兩種模型[30]。從上述學者研究中能發現通常在建模時會選用不同領域的模型除了比較績效以外，時間成本也須納入考量，而對於不同資料集則會使用多種方法進行建模，因此本研究將透過比較深層類神經網路的 GRU、淺層類神經網路的 HRNN 與機器學習的支持向量回歸(Support Vector Regression, SVR)模型訓練的時間成本與績效狀況，找尋出保有最佳時間成本與績效的模型。

2.5 小結

綜合上述之文獻回顧，可歸納出以下結論：

1. 空間聚類的方法各有其優劣勢，而過往研究皆只針對其中一方進行相關研究，尚未有研究進行兩種方法的綜合探討。
2. Pearson Correlation 計算線性相關而捷運資料為時間序列資料，其時間序列變化為非線性的，因此 Pearson Correlation 不適用於本研究；，FNN 考量的重點為時間延遲性，捷運站間的旅行時間在正常情況下並不會超過 1 小時，因此在正常捷運站間通行將不會產生時間延遲性的發生。
3. RNN 為遞迴類神經網路的初始版本，學者為了增進該模型的能力而研發了許多不同的變化模型，在同樣為淺層類神經網路的 RNN 變體模型中以 HRNN 預測能力最佳。
4. 於過往預測交通流量的研究，SVR 與 LSTM 兩種模型皆得到到不錯的結果。

由上述四點總述，當今研究尚未有人組合基於時間序列與基於地理特性資訊進行交通站點聚類，使得分析模式未達到最佳的成效；而在時間序列相似度計算受限於資料與方法的緣故，將透過 Cosine Similarity 與 DTW 進行捷運站點間流量資料的相似度計算；最後考量到研究的初衷並非為精準預測，而是降低模型的訓練時間成本，因此將使用輕量 LSTM 為變化的 GRU 做為深層類神經網路的代表模型，而淺層遞迴類神經網路將以 HRNN 作為代表，並與 SVR 一同比較模型績效與訓練時間多寡。

第三章 資料集

本章節介紹本研究選取時空資料的邏輯、所使用資料集的介紹，以及如何進行資料的前整理。

3.1 本研究選取時空資料的邏輯

本節介紹若要將整個捷運系統上的站點分成幾個群組時可以考慮的觀點。

(1) 以捷運站的空間特性的縮減模型數量

若能夠將捷運站依照找尋具有地區代表性的捷運站並整合與其相似的其他站點，將僅需建立代表性捷運站的流量預測模型。例如以淡水站作為地區代表站點，建立淡水站的流量預測模型並用於預測淡水站、紅樹林站、竹圍站等。過往研究中尚未有學者針對捷運站進行相似的研究，但於不同領域中皆有學者進行相關研究，如 Martin [24] 定義了影響地區 Persistence 與 Redundancy 因子並從中探討西班牙鄉村地區與都市地區大氣監測站的空間代表性。Righini *et al.* [31] 以 4 乘 4 的網格進行空間分辨網格去處理義大利北部和中部的空間資訊，並計算大氣監測站於該網格的空間代表性。Stolz [33] 透過建構 Concentration Similarity Function 去量化義大利空氣品質監測站於空間區域代表性的數值。Piersanti *et al.* [29] 則是透過強化集成式聚類方法於計算網格資訊的方式去決定具有空間代表性的站點。

(2) 以捷運站周圍環境特性來減模型數量

捷運站的周圍環境特性很多例如地理標籤資訊、地區國家土地使用狀況、地區人口組成等，這些不同的地理特性資訊亦能代表著地區的區域特性，像是以家庭為主的住宅區、以景點為主的景點區或是以工作為主的工作區等，每個區域特性將會影響著捷運站的流量狀況。例如住宅區的捷運站會有民眾會早上進站上班上課與傍晚出站回家的特性，若依照地區分類後將能夠針對特性建立地區特性模型，用該模型來預測所有特性相同的捷運站流量狀況。過往學者多數是以地理標籤資訊來進行相關研究，如 Tsai & Wang [36] 於 2017 年藉由公車站點地理經緯度座標透過

DBSCAN 進行公車站分群。Kao & Chen[10]於 2018 年將公車站點地理經緯度座標依照階段式 k-means 演算法進行分群。

(3) 以時間序列的角度縮減模型數量

捷運站的流量會受到時間變化的影響，像是有些捷運站平日早上與傍晚會因為上下班的人潮而達到高峰值，中午則是呈現低谷狀況，或是過年期間因為民眾不用上班上課，而讓某些站點的流量持續呈現低谷狀況，因此若依照捷運站歷史流量作為分群依據，將能夠針對群組建立預測模型，進而減少預測的模型數量。如 Chen et al.[6]曾將上海地鐵乘客歷史流量依照平、假日與多個時段進行資料切割，並透過 K-means 與主成分分析(Principal Component Analysis, PCA)進行時段流量相似地鐵站分群。

綜合上述的幾個邏輯，我們認為若要進行本研究，必須收集幾種與捷運站人流的相關資料，包含(1)台北捷運流量資料、(2)行動數據流量資料、(3)各站點的 Google Trends 網路聲量搜尋趨勢與(4)捷運站周圍土地使用分區資料，現介紹這些資料集如下面幾節。

3.2 台北捷運資料

本研究使用之台北捷運資料皆來自臺北市資料大平臺，主要分為(1)台北捷運車站出入口座標與(2)台北捷運站點間進出站人數的兩個資料集，以下將詳細介紹資料內容：

(1) 台北捷運車站出入口座標

此資料收錄了 2020 年 10 月 31 日以前台北捷運已開通捷運站之所有出入口經緯度座標，共有 384 個捷運站出入口資訊，資料欄位包含了項次(資料的次序)、出入口名稱、出入口編號、經度與緯度，如表 1 台北捷運車站出入口座標資料表所示。該資料主要用於觀察捷運站於國土規劃地理圖台所在的地理位置投點，該平台能夠得知捷運站附近的國土規劃分區資訊。

表 1、台北捷運車站出入口座標資料表

項次	出入口名稱	出入口編號	經度	緯度
1	頂埔站出口 1	1	121.418218	24.959306
2	頂埔站出口 2	2	121.419000	24.959310

(2) 台北捷運站點間進出站人數資料

此資料收錄了 2018 年 01 月 01 日 00 時至 2019 年 12 月 31 日 23 時台北捷運站各站點間進出站人數，以小時作為資料單位，每小時共有 11664 筆資料記錄從各站點進站到各站點出站的人數資料，資料欄位包含了日期、時段、進站、出站以及人次，如表 2 台北捷運站點間進出站人數表所示。而為了使所有資料集之時間單位相同，因此將台北捷運站點間進出站人數資料做每日平均化，並將資料集轉換成各站點每日平均進出站人數，如表 3 台北捷運各站進站人數表與表 4 台北捷運各站出站人數表所示。

表 2、台北捷運站點間進出站人數表

日期	時段	進站	出站	人次
2018-02-03	12	台北車站	南京復興	103
2018-02-03	12	台北車站	忠孝復興	306

表 3、台北捷運各站出站人數表

日期	三和國中站	三重國小站	中山國中站
2018-01-11 06:00	139	70	150
2018-01-11 07:00	394	231	863

表 4、台北捷運各站進站人數表

日期	三和國中站	三重國小站	中山國中站
2018-01-11 06:00	416	416	134
2018-01-11 07:00	1,907	1,890	988

3.3 行動數據資料

本研究整理了由某電信商所提供的行動裝置人流數據資料，此資料收錄了 2018 年 01 月 01 日至 2019 年 12 月 31 日北北基桃宜使用該電信之行動數據，為了保護使用者的個人資訊，資料的收集是以每 500 平方公尺作為統計使用者數量，基於保密協定內容不多贅述，為了後續研究需求將資料整理成如表 6 所示，其中本研究僅使用每 500 平方公尺作為統計使用者數量的總人數。

表 5、整理後行動人流資料表

統計人數	經度	緯度	時間
615	121.295	24.880	2018010312
941	121.150	24.965	2018010312

3.4 輔助訓練與分類的資料

此節將介紹用於分類的(1)內政部營建署提供之國土規劃地理資訊圖台之都市計畫使用分區資料與用於輔助模型訓練的(2) Google Trend 上各捷運站的搜尋趨勢資料集，以下將詳細介紹資料內容：

(1) 地理資訊圖台之都市計畫使用分區資料

此資料為內政部營建署所建立之國土規劃地理資訊圖台，主要收錄都市計畫、國家公園或國土規劃圖資等全國土地使用現況資訊，都市計畫使用分區資料如圖 8 所示，圖 4 為中正紀念公園附近都市計畫使用分區圖，由各種顏色代表不同區域類別，紅色代表商業區、黃色代表住宅區、綠色代表空地或公園等等。



圖 4、中正紀念公園附近都市計畫使用分區圖

(2) Google Trend 上各捷運站的搜尋趨勢資料集

Google Trends 為 Google 公司所開發的一款服務，其服務內容為透過關鍵字與時間範圍搜尋時間內關鍵字的搜尋熱度，其數值介於 0 至 100，搜尋熱度是依照時間範圍內搜尋次數最高的日期為 100 最低則為 0 計算，其搜尋介面如圖 5 所示，於圖 9 中為輸入關鍵字「板橋捷運站」與時間範圍設定在「過去七天」的結果示意圖，圖中折線部分為搜尋熱度狀況，關鍵字之趨勢狀況將能為訓練模型預測未來流量給予幫助。

本研究共收集了台北捷運各站點作為關鍵字於 2017 年 12 月 25 日至 2019 年 12 月 31 日每七日為單位儲存之 Google Trends 搜尋熱度，資料收錄型態如表 7 所示，表 7 為 2017 年 12 月 25 日至 2017 年 12 月 31 日三重國小站與三和國中站之搜尋聲量。





圖 5、板橋捷運站於 Google Trends 趨勢搜尋示意圖

表 6、Google Trends 資料表

日期	三重國小站	三和國中站
2017/12/25	33	0
2017/12/26	100	98
2017/12/27	66	0
2017/12/28	0	0
2017/12/29	34	0
2017/12/30	0	100
2017/12/31	0	0

第四章 研究方法

本研究提出基於地理空間組合特徵工程的捷運站整合模式，應用於減少訓練台北捷運進出站人數預測模型的時間成本，研究的流程架構如圖 6 所示，分成(a)預測一日模型流程圖與(b)預測三日模型流程圖各四個階段進行，階段包含(1)觀察捷運站周圍 500 公尺內的國土規劃狀況，並依此作為捷運站的地理空間進行捷運站分類。(2)對各類別的站點以 Cosine Similarity 結合 DTW 計算各站點的流量相似度以進行分群，各群組內的捷運站將呈現地理空間資訊相似且動態變化相近的結果。(3)將分群後的捷運站點透過 SVR、HRNN、GRU 與集成式學習模型訓練各群未來一日與三日的流量狀況，並透過平均絕對百分比誤差(Mean Absolute



(a)




圖 6、研究流程圖。(a)預測一日流量流程圖，(b)訓練三日流量流程圖

Percentage Error,MAPE)與均方根誤差(Root Mean Square Error ,RMSE)計算模型績效狀況與模型的訓練時間來決定各群適合的預測模型。(4)最後的真實上線階段，將透過訓練好的模型進行各群的捷運站流量預測。以下將介紹上述四階段的詳細流程。

4.1 基於地理特徵將捷運站分類

透過地理特徵分類共分成 3 個步驟，(1)以內政部營建署國土規劃地理資訊圖台中得捷運站點為中心，500 公尺為半徑畫圓，(2)統計區域內的各區使用比例，(3)依據閾值將捷運站點分類，而部分站點則有例外狀況，本節將依序介紹如何將捷運站透過地理特徵進行分類與例外站點將如何處理。



圖 7、國土規劃地理資訊圖台上三和國中站地理資訊圖

本研究參考捷運站附近的國土規劃狀況將捷運站進行不同類別的分類，而參考的依據則來自台北市開放平台所開放之台北捷運車站出入口座標與內政部營建署國土規劃地理資訊圖台之都市計畫使用分區資料，分別代表了捷運站所在位置與捷運站附近的規劃狀況。此處將以三和國中捷運站為例，首先本研究會找尋國土規劃地理資訊圖台上捷運站的經緯度位置如圖 7 所示，三和國中站附近的國土規劃狀況是由多種不同色塊進行標籤，如圖 8 所示，例如黃色代表住宅區、咖啡色代表工作區、紫色代表學區、藍色代表捷運用地等等，而後會由該點向外劃 500 公尺，並觀察範圍內的國土使用狀況如圖 9 所示，之所以會選擇以 500 公尺作為探



圖 8、國土規劃地理資訊圖台之三和國中站都市計畫使用分區圖



圖 9、國土規劃地理資訊圖台三和國中站都市計畫使用分區 500 公尺範圍圖

討範圍，因為 Zacharias [43]學者於 2001 年的研究中指出日常生活中大多數人能接受的步行距離約為 500 公尺左右，因此本研究之範圍設定在 500 公尺，此地區的使用分區比例如表 7 所示，從表中能看到該地區的使用分區比例最高為住宅區其次為工作區，再來會依據閾值來將站點進行分類，閾值的設定如表 8 所示，而三和國中站的住宅區為最高比例且超過 40%，因此會將此站歸類為住宅區。

分類的閾值主要是都市計畫使用分區狀況中若有其中一種類別達到上表的即將該區域分屬為該類別，在閾值中以學區與混合區之閾值與其它區不同，主要是因

表 7、三和國中站土地使用分區比例表

	工作區	住宅區	商業區	機關用地	學區	遊憩空地
三和國中站	20	56	7	4	10	3

表 8、區域分類閾值表

	工作區	住宅區	商業區	學區
工作區	$\geq 40\%$			
住宅區	$\geq 50\%$			
商業區	$\geq 40\%$			
學區	$\geq 25\%$			
混合區	任兩區總和超過 80%			




圖 10、國土規劃地理資訊圖台上

三民高中站都市計畫使用分區 500 公尺範圍圖

為學校大小皆不相同，有些學校大到 60 多公頃，有些學校則不足 1 公頃，而此部分之分區依據又是依照土地使用面積，若將學區依樣設定為 40% 會產生沒有分區的狀況，即學區被劃分在不同的區別內，如圖 10 三民高中站國土規劃狀況圖所示，白色的範圍為 500 公尺的範圍，表 9 為三民高中站使用分區比例表，從該表能發現該捷運站點國土規劃的使用大小依序為住宅區、學區、商業區、捷運用地與遊憩空地，雖住宅區的使用分區為最高比例，但從表 9 能看到住宅區使用比例為該站最高，學區比例則只有 25%，若將學區的使用分區比例一樣調至 40% 則將無法將其歸類在學區，而從該站點的使用分區狀況亦能看出雖該地點的使用分區為學區，但流量狀況卻不一定是因為是學區所以具有一定是怎樣的流量特性，站點的流量亦可能受工作區流量變化或是文教區流量變化影響；混合區則是因為有某兩種區域其比例皆未超過設定閥值但部分區域獨大，如工商混合區便是因為工作區與

表 9、三民高中站土地使用分區比例表

捷運站	工作區	住宅區	商業區	機關用地	學區	遊憩空地
三民高中站	9	32	25	5	25	4

商業區的使用狀況皆超過 30%但未超過 40%，但兩者相加則有超過 80%，此類別捷運站多數皆位於台北市如中正紀念堂站、民權西路站、中山站等。除了以分類的站點外，亦有部分站點其比例皆無法達到上述得條件，此部分站點之所以無法達到條件主要是因為其使用分區中有比例為遊憩空地或是機關用地，如表 10 部分站點分區未達標比例表所示，表 10 中的台大醫院站有 35%比例為機關用地，20%為空地，兩個占比即超過了 50%，其他分區皆難以突破上述條件，而對於這類的站點僅能夠逐一進行人工得分類，以台大醫院站為例，此區域的機關用地為醫院，而醫院的排班狀況比較貼近工作區，因此會將機關用地比例歸為工作區比例，而空地部分則是會依照現有的使用分區比例劃分過去，最終該站將被歸類為工作區。

表 10、部分站點分區未達標比例表

捷運站	工作區	住宅區	商業區	機關用地	學區	遊憩空地
淡水站	8	37	17	18	0	20
劍潭站	10	30	8	12	15	25
臺大醫院站	9	32	25	5	25	4

4.2 捷運站點流量動態相似度計算與分群

在前一步將各捷運站依照不同地理空間資訊分類後，雖多數的流量變化的捷運站點已被歸在同一類別內，但僅以地理資訊進行站點分類仍會有例外的狀況出現，本小節將介紹如何透過 Cosine Similarity 與 DTW 去計算類別內所有站點間的相似度，並依照相似度進行站點的分群。

4.2.1 資料前處理

由於收集到之 Google Trends 以日為單位進行儲存，而捷運統計資料與行動人流數據則以小時為單位進行儲存，對於資料時間單位不同的部分，本研究將捷運統

表 11、台北捷運各站每日平均出站人數表

日期	三和國中站	三重國小站	中山國中站
2018-01-12 00:00	551.292	821.125	555.208
2018-01-13 00:00	411.792	593.792	461.583

表 12、台北捷運各站每日平均進站人數表

日期	三和國中站	三重國小站	中山國中站
2018-01-12 00:00	572.167	810.542	549.167
2018-01-13 00:00	436.500	587.000	465.792

計資料與行動人流數據進行每日平均化，將其從每小時流量變成每日流量，其結果如表 11 與表 12 所示。考量到行動人流數據為 500 平方公尺內的用戶統計資料，部分捷運站其出口會橫跨不同區域範圍如圖 11 所示，圖 11 上紅圈為捷運站出口點，黃色星星為捷運站本體的經緯度，若以捷運站點本體作為行動人流數據資料整理依據將會產生資料偏差，為此本研究依照捷運站點 500 公尺內涵蓋的網格區域之中心距離與站點距離進行人數修正。




圖 11、忠孝新生站捷運站中心與各出口圖

在進行往後的每一步驟前，為了使每個站點的流量基礎點都為一樣的標準，會先將數值先依照最小值與最大值進行正規化，使其數值縮到介於 -1 至 1 的範圍，會使用最小值與最大值進行正規化是因為各站點之流量會因為其所在位置不同而使得上下限皆不同，如台北車站平均日流量約為 6000，而中山國中站平均日流量則為 650，就算兩者為相似站點，在進行相似度計算或是類神經網路模型的訓練時皆為因為流量大小差異過大而無法正常運作。最小值最大值正規化公式如下：

$$X_{nor} = \frac{X - X_{min}}{X_{max} - X_{min}} \in [-1, 1] \quad (1)$$

其中 X_{max} 與 X_{min} 分別為資料集中的最大值與最小值。會將每一個數值依照原始資料集的最大最小值進行正規化。

4.2.2 Cosine Similarity 計算相似度

Cosine Similarity 是利用捷運站各時間點下流量間的向量的夾角去計算餘弦值。當兩組流量資料的夾角為 90 度時其餘弦值將為 0 時，表示兩組資料並沒有相似之處；當其夾角為 0 度時餘弦值為將為 1，表示兩資料的變化有著高度的同向相似性；若兩資料間的夾角為 180 度時餘弦值為將為 -1，代表著兩組資料有著高度的同向相似，而捷運站的流量皆為正數，並不會出負數的情況出現，因此於此部分計算時會產生資料點間的相似性極高的情況，為此本研究將採用整餘弦相似性 (Adjusted-Cosine Similarity) 進行捷運站間流量相似性的計算，其公式如下：

$$sim(i, j) = \frac{\sum_{u \in U} (R_{u,i} - \bar{R}_u)(R_{u,j} - \bar{R}_u)}{\sqrt{\sum_{u \in U} (R_{u,i} - \bar{R}_u)^2} \sqrt{\sum_{u \in U} (R_{u,j} - \bar{R}_u)^2}} \quad (2)$$

其中 u 表示捷運站資料各向量點的分量， $\bar{R}_u$ 則是資料的平均值，Adjusted-Cosine Similarity 會先將資料中心化，也就是會將資料減去自身得平均值，用以觀察資料變化的波動性，並去計算兩組資料的相似程度。以三重國小站、三和國中站與中山

國中站做說明，三重國小站與三和國中站出站的人數高峰皆在傍晚 5、6 點，若減去平均值早上部分將會呈現負值，而傍晚部分會呈現正值，中山國中站則為早上與傍晚的雙高峰因此早上與傍晚皆會呈現正值，此時便能看出三重國小站與三和國中站的出站人數變化是相似的，而中山國中則是與前面兩者不同的。

4.2.3 DTW 計算相似度

DTW 主要是透過動態規劃(Dynamic Programming)去計算兩組捷運站流量變化距離，若其中兩捷運站流量資料分別為長度 n 的時間序列 $Q = q_1, q_2, \dots, q_n$ 與長度 m 的時間序列 $C = c_1, c_2, \dots, c_m$ ，DTW 會先建立一個 $n \times m$ 的矩陣 A ，如圖 12 所示。矩陣 A 中的第 i 行 j 列元素為 $(q_i - c_j)^2$ ，代表花費對其 q_i 和 c_j 所需的成本，當成本越小代表著兩時間序列越相似，越大則反之。DTW 的主要目的在於找到一個最佳的路徑來對齊 Q 和 C ，此時將會從 A 的左下角開始找尋一條路徑 $R = r_1, r_2, \dots, r_k$ ，而路徑 R 的找尋過程有三個限制條件，分別為邊界條件、連續性與單調性。邊界條件則是指路徑的起始點為最左下角與最右上角，不能任意從中間點開始路徑規




圖 12、DTW 示意圖

劃。連續性是指路徑的移動只能移動到相鄰的元素，即上方、右方與右上方三個元素。單調性則是指路徑的移動不能走回頭路，也就是不能往左方或下方移動。DTW 所計算的為路徑 R 上的成本總和，DTW 的公式如下：

$$DTW(Q,C) = \arg \min_{R=r_1, r_2, r_3, \dots, r_k} \sqrt{\sum_{k=1, w_k=(i,j)}^k (q_i, c_j)^2} \quad (3)$$

除了動態規劃外，DTW 還有一個 time wrapping 要設定，DTW 在進行尋找下一個值做動態規劃時會依據 time wrapping 來決定要找哪一個數值進行成本計算。當兩個時間序列只是時間延遲或位移，在其他不同的相似度計算方法中將會產生不相似的結果，但實際上兩個時間序列是非常相似的，DTW 則可以透過動態規劃與 time wrapping 值的設定來對齊兩個時間序列，進而避免時間延遲或位移的影響。

以三和國中站與三重國小站為例，假設三和國中站為 Q 而三重國小站為 C ， $Q = 0.42624, 0.79145, 0.80887, \dots, 1$ 而 $C = 0.34562, 0.77698, 0.80088, \dots, 0.99821$ 根據第 1 行 1 列元素為 $(q_1 - c_1)^2$ 則數值為 $(0.42624 - 0.34562)^2$ 計算後數值為 0.081，而往後數值皆照公式進行計算，其結果如圖 13 所示，圖 13 中最右上角 25.228 即為三重國小站與三和國中站之 DTW 動態規劃成本。

三 重 國 小 站	730	295.267	92.427	88.954	88.861	...	25.573	25.878	26.175	25.228
	729	294.316	91.907	88.458	88.366	...	25.365	25.306	25.402	24.920
	728	293.712	91.735	88.310	88.218	...	25.499	25.080	24.881	25.393
	727	293.582	91.434	87.985	87.893	...	25.025	24.832	25.180	25.393
	726	293.152	91.433	87.959	87.866	...	24.781	25.066	25.648	25.586
	...	...	...	...	...	...	...	...	...	...
	3	0.989	0.1265	0.103	0.110	...	105.285	105.373	105.751	105.931
	2	0.526	0.095	0.104	0.114	...	108.091	108.158	108.522	108.719
	1	0.081	0.431	0.805	1.181	...	242.190	242.488	242.489	243.052
		1	2	3	4	...	727	728	729	730
三和國中站										

圖 13、三重國小站三和國中站動態規劃結果圖

4.2.4 捷運站相似分群

在計算完兩種不同於計算捷運站流量的相似度後，將整理成如表 13 捷運站流量相似度表，而後會將兩種不同的相似度情形投射到新的空間中如圖 18 三和國中站與三重國小站相似度矩陣空間投射圖所示，在此空間中越接近左上表示兩站點越相似，越接近右下則反之。依據表 13 中的三和國中站與三重國小站的動態規劃成本為 24.986 而 Cosine Similarity 為 0.999，於空間中以點 $P2$ 作為表示；三和國中站與中山國中站於 DTW 的規劃成本為 46.189 而 Cosine Similarity 為 0.995，於空間中以點 $P3$ 作為表示；三重國小站與中山國中站於 DTW 的規劃成本為 51.321 而 Cosine Similarity 為 0.991，於空間中以點 $P4$ 作為表示；空間中的 $P1$ 則為各站點各自對自己的相似度，因其必然相似因此點皆重疊在空間中的最左上角。從圖 14 的空間中能觀察出點 $P1$ 與點 $P2$ 為獨立點 $P3$ 與點 $P4$ 為相近點，其中點 $P2$ 為三和國中站與三重國小站相似度投點，因此三和國中站與三重國小站能分為同一群，而點 $P3$ 與點 $P4$ 則為中山國中站與另外兩站之站點流量，這兩點皆表示中山國中站與三和國中站及三重國小站為不相似站點，因此會將三者同為住宅區之捷運站分成兩個群體，其一為三和國中站及三重國小站，另一個則為中山國中站。

表 13、捷運站流量相似度表

(DTW , Cosine Similarity)	三和國中站	中山國中站	三重國小站
三和國中站	(0 ,1)	(46.189 ,0.995)	(24.986 ,0.999)
中山國中站	(46.189 ,0.995)	(0 ,1)	(51.321 ,0.991)
三重國小站	(24.986 ,0.999)	(51.321 ,0.991)	(0 ,1)




圖 14、三和國中站與三重國小站相似度矩陣空間投射圖

4.3 建立各群預測模型

在 4.2 節將捷運站點依照歷史流量相似程度分成諸多群組之後，接著將會從同群體的資料中挑選一組資料作為預測模型的主要資料，在模型訓練時會再搭配行動數據資料與 Google Trend 搜尋趨勢資料進行訓練，本研究挑選了 SVR、HRNN 與 GRU 作為預測流量的模型，輸入資料為過去 t 個時間點下資料矩陣，輸出則為未來時間點的人數狀況，於此本研究將過去 t 個時間點設定為 7，對應資料集則為過去一週的流量變化會影響未來的流量狀況，設定為 7 天主要是因為流量變化以 7 天呈現一個週期變化，而資料於不同模型訓練前皆會先進行正規化，依照各資料集狀況將資料縮放至到 -1 到 1 之間，正規化方法如公式 1 於此將不再贅述。

4.3.1 SVR 流量預測模型

SVR 為 SVM 的變體模型，SVM 的主要目標在於尋找能夠一分为二的平面，而 SVR 主要在於尋求空間中能夠擬和資料的最佳平面。SVR 透過結構風險最小化 (Structural Risk Minimization, SRM) 的原理，讓 SVR 有限的資料下仍能保有不錯的預測能力，這種方法有別於以往的經驗風險最小化 (Empirical Risk Minimization, ERM)，透過提升維度的方法，建構決策函數來實現回歸，並從中找尋資料最佳的回歸超平面，使得更多的訓練資料能落在平面的誤差範圍內。其主要公式如下：

$$f(x) = \omega T x + b \quad (4)$$

SVR 是一種回歸模型，但與其他模型不同的地方是，SVR 會計算出一個誤差值 ϵ 代表著對於誤差的容忍度，當真實值 y_i 落在 $f(x_i) \pm \epsilon$ 間時，皆當作預測正確而不去計算函數的損失狀況，而 SVR 的問題則可以表示為

$$\min_{w,b} \frac{1}{2} \|w\|^2 + G \sum_{i=1}^m u_{\epsilon}(f(x_i) - y_i) \quad (5)$$

對於擬合資料的平面仍希望能夠減少誤差，因此引入了懲罰係數 G ，當 G 越大時，代表著模型對錯誤的容忍度越低， u_{ϵ} 則為 ϵ -不敏感損失函數(ϵ -Insensitive Loss Function)

$$u_{\epsilon}(z) = \begin{cases} 0, & \text{if } |z| \leq \epsilon \\ |z| - \epsilon, & \text{otherwise} \end{cases} \quad (6)$$

而其推導公式將不贅述，本研究主要參考 Vapnik[3] 並採用一般 SVR 的回歸函數的形式定義為

$$f(x) = \sum_{i=1}^m (a_i - a_i^*) K(x, x_i) + b \quad (7)$$

其中 a_i 與 a_i^* 為拉格朗日乘數，用於滿足等式 $a_i^* a_i = 0$ ， a_i^* and $a_i \geq 0$ 。 $K(x, x_i)$ 則為內核函數，而本研究所使用之內核函數為 RBF，主要是因為其能力強大且被多數研究中應用[13]。

$$K(x, x_i) = \exp(-\theta \|x_i - x_j\|^2) \quad (8)$$

其中的 θ 則為 RBF 參數。

4.3.2 HRNN 流量預測模型

HRNN 是用於預測時間序列最有效的淺層類神經網路之一。時間序列預測一直都被視為是難以處理的問題，因時間序列資料具有動態非線性的特性，該模型的特色便是將動態非線性之模型拆解成靜態非線性系統與動態線性系統，如圖 15 所示，分成不同狀態個別建模，讓模型於靜態非線性系統學習非線性相關的資訊，於動態線性系統學習與線性相關的動態資訊，使得淺層類神經網路也有不錯績效。




圖 15、HRNN 與 RNN 系統相異之處示意圖




圖 16、HRNN 架構圖

HRNN 的架構如圖 16 所示，主要分成輸入層、靜態層、動態層與輸出層，以下詳細介紹本模型的數學架構。而在第 j 層的神經元中，此處將會使用 $I_i^{(j)}(k), f_i^{(j)}(k)$ and $o_i^{(j)}(k)$ 代表第 i 個神經元於第 k 個時間下的輸入、函數的輸入，以及輸出。

首先為輸入層。輸入層並沒有做任何的資料加值，此處的輸出為前面的輸入

$$O_i(k) = f_i(k) = I_i(k). \quad (9)$$

再來為隱藏層的靜態層部分，輸入會經過 Tangent sigmoid 函數的進行非連續轉連續數值運算。而其公式如下：

$$f_i(k) = \sum_{j=1}^p b_{ij} o_j(k), \quad (10)$$

$$O_j(k) = \frac{\exp(f_i(k) - \exp(f_j(k)))}{\exp(f_i(k) + \exp(f_j(k)))}, \quad (11)$$

其中 b 為輸入層與靜態層之間的權重數值， $\exp(\bullet)$ 則為 exponential function。

在靜態層的動態層部分，各神經元會參照同一層神經元前一次與該次的輸出，計算本次動態層的輸出，其公式如下：

$$f_j(k+1) = \sum_{j=1}^q a_{ij} x_j(k) + \sum_{m=1}^p b_{im} o_m(k), \quad (12)$$

$$o_i(k) = x_i(k) = f_i(k), \quad (13)$$

最後是輸出層的部分，此層將整合來自動態層的數值並傳送最終運算結果，其公式如下：

$$o_i(k) = f_i(k) = \sum_{j=1}^r c_{ij} x_j(k). \quad (14)$$

4.3.3 GRU 流量預測模型

GRU 為 RNN 參照 LSTM 而延伸變化的模型之一，主要用於解決長期記憶和反向推導訓練時所產生的梯度等問題所研發，GRU 將 LSTM 所用的三個閥門做了簡化，新的控制閥門分別為 Update Gate(Z_t)與 Reset Gate(r_t)， Z_t 會控制過去到現在要保留多少個記憶資訊，而 r_t 則用於決定如何將新資訊與舊資訊做整合。

整體模型架構如圖 17 所示，主要分成輸入層、靜態層、隱藏層、GRU 層與輸出層，以下將介紹本模型的數學架構。輸入層、隱藏層與輸出層皆與 HRNN 模型




圖 17、GRU 架構圖

架構公式相同，不同的地方在於動態層與靜態層之間再加入了一層隱藏層去學習靜態轉換後的狀態再進入動態層，動態層更改為 GRU 層，並於最後再加入兩層隱藏層去學習動態層轉換後的狀態。

本研究所使用之 GRU 將參照學者 Sun[34]學者所建立之基礎 GRU 模型建立 GRU 層，GRU 層的神經元架構如圖 18 所示，其中 Update Gate 與 Reset Gate 的主要公式如下：

$$Z_t = \sigma(x_t U^z + h_{t-1} W^z) \quad (15)$$

$$r_t = \sigma(x_t U^r + h_{t-1} W^r) \quad (16)$$

神經元中 $\tilde{h}_t$ 為經由激活函數所計算之最新資訊， h_t 為 GRU 計算後的資訊，透過 r_t 控制要保留多少 h_{t-1} 之前記憶的資訊量， Z_t 用來決定時間點 t 的 $\tilde{h}_t$ 需要多少記憶的資訊進行輔助計算。




圖 18、GRU Layer 架構圖

4.3.4 集成式學習模型

當新站點被分類至任一群組後，雖透過任一站點之預測模型理應能達到流量預測相似的結果，然而若新站點於分類後群組中擁有 n 個相似站，此時將會有 n 個未來流量，而每個模型所給予之流量狀況不盡然會相同，因此對於新站點之預測本研究設計集成式學習模型用以解決多個輸出的情況，其概念圖如圖 19 所示，集成式學習模型的輸入為過去 t 個時間點下 HRNN 與 GRU 預測結果，輸出則為未來時間點的捷運進出站流量，其模型架構與數學式皆與 HRNN 相同，使用 HRNN 進行模型集成式學習是因為其擁有不亞於深度學習之預測能力，也擁有淺層類神經網路之運算成本低的優勢[30]，三個模型間的權重皆互不影響，三個模型皆為獨立訓練。




圖 19、集成式學習模型示意圖

4.3.5 模型績效評估

訓練完模型之後，將會進行模型的訓練與預測績效評估，本研究預計使用的績效指標為用與訓練集的 RMSE 與測試集的 MAPE，兩種績效評估的公式如下：

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (predict_i - actual_i)^2}{N}} \quad (17)$$

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{actual_i - predict_i}{actual_i} \right| \times \frac{N}{100} \quad (18)$$

RMSE 主要用於檢視模型訓練時的平均誤差值狀況，當誤差值越小表示模型訓練得越好，MAPE 則用來檢視模型於測試集中平均絕對誤差範圍，若於未知的資料中平均絕對誤差落在 20% 以內則表示模型的可用性非常高，MAPE 主要參照 Lewis[16] 學者的研究，其能力分級如表 14 所示。除了比較模型績效外亦會記錄各模型的訓練時間，用以後續分析比較績效與訓練時間成本的選擇。

表 14、MAPE 能力分級表

預測能力	MAPE 值
不正確	>50%
合理	20%~50%
良好	10%~20%
高精準度	<10%

4.4 Online 說明

此小節將介紹研究 Online 的部分，在 Online 前所有模型將於 Offline 時先行訓練好，包含了各捷運站分類、分群與各群流量模型，而在 Online 時，使用者只需輸入捷運站點名稱，系統將會自動去搜尋與站點相關的 Google Trends、流量資料、行動數據與預測模型，並即時提供使用者目標地點的未來流量狀況。

第五章 實驗模擬

本章使用台北市政府所開放之捷運站進出站統計人數資料集來驗證本研究提出方法的有效性，並記錄各模型之運算時間成本以做比較。本章的內容共分成 5 個部分，包含了資料集與實驗參數介紹、地理空間特徵分類結果、動態相似度分群結果、預測模型參數選擇與最佳結果與小結。所有實驗皆於 Python 環境完成，所使用設備規格為 Intel Core I7-9700K at 3.60GHz 的 CPU、Nvidia GeForce RTX2080 Ti 的 GPU 與 DDR4 64GB 記憶體來完成。

5.1 資料集與實驗參數介紹

本研究為驗證提出方法之有效性，分別收集台北捷運資料、行動數據資料以及輔助訓練的資料與分類的資料，並透過三種不同模型於預測捷運站點進出站流量狀況於各模型訓練時記錄其運算時間成本與模型預測績效，模型的輸入將會依據各分群結果產生不同狀況，假設一群組 G 內共有 m 筆相似站點，且各站點有 n 個特徵資料，除了集成式學習以外的模型輸入將為過往 7 天的 n 個特徵，而集成式學習的輸入則為 m 個站點於過往 7 天中 n 個特徵資料，模型的輸出則為未來一天與未來三天兩種不同的模型，績效狀況採用兩種常見的能力評估方式分別為 MAPE 與 RMSE。以下將個別介紹收集到之資料集。

5.1.1 台北捷運資料

本研究收集自臺北市資料大平臺所開放的台北捷運資料，主要有台北捷運車站出入口座標資料集與台北捷運站點間進出站統計人數資料集。台北捷運站出入口座標資料集收錄台北捷運站點各出口之經緯度座標，台北捷運 108 個捷運站點共有 384 個出入口。

台北捷運站點間進出站統計人數資料集收錄 2018 年 1 月 1 日至 2019 年 12 月 31 日台北捷運站點每小時之進出站人數統計資料，為了使所有資料集之時間單位相同將所有捷運站點做每日平均化，平均化後總資料筆數為 157,680 筆，最大單日

流量站點為 2018 年 12 月 31 日的台北車站，其平均單日流量為 9,808 人，兩年平均流量為 6,650 人；最小單日流量站點為 2019 年 9 月 3 日的辛亥站，平均單日流量為 36 人，兩年平均流量為 129 人。

兩年平均流量如圖 20 台北捷運站各站於 2018 年至 2019 年平均單日流量圖所示，兩年平均流量大於 1,000 人共有 30 個站點，這些站點大多位於台北市中心，如行天宮站、西門站、市政府站等，介於 1,000 人至 500 人共有 36 個站點，小於 500 人則有 42 個站點，透過該圖能看出捷運站點流量差距非常大，多則數千人少則數百人，對於流量差距大的資料要直接進行研究會存在一些困難，如流量小的站點人數變化平均不超過 500 人，若與流量大的站點如台北車站或是西門站進行 DTW 計算，就算兩者的流量變化相似，但也因為其動態規劃成本過高而無法判斷兩者的流量變化是相似的。




圖 20、台北捷運站各站於 2018 年至 2019 年平均單日流量圖

5.1.2 行動數據

行動裝置人流數據資料由某電信商所提供，基於保密協定資料內容於此將不多贅述。

5.1.2 分類資料與輔助訓練資料

此份資料共有兩種，分別為將捷運站點分類用之土地規劃使用比例表與輔助

模型訓練用的 Google Trend，土地規劃使用比例表來自內政部營建署提供之國土規劃地理資訊圖台之都市計畫使用分區資料，本研究於圖資上利用該圖資之比例尺由捷運站點向外劃 500 公尺並從中劃分各捷運站點土地規劃使用比例，將其整理成捷運站土地規劃使用比例表，所有站點土地規劃使用比例表如附件一所示。輔助訓練用之 Google Trends 則收錄 2017 年 12 月 25 日至 2019 年 12 月 31 日各捷運站點 Google Trends 搜尋熱度。

5.2 地理空間特徵分類結果

在整理完所有資料後將透過地理特徵將捷運站分類，最終將 108 個捷運站劃分成 5 種區域，分別為住宅區、工作區、商業區、學區、住商混合區以及工商混合區，結果如表 15 所示，從表中能看到類別中捷運站點被歸類的類別以住宅區為最多。

表 15、地理空間特徵分類結果表

類別	捷運站站點
住宅區	辛亥、木柵、小碧潭、葫洲、明德、紅樹林、大直、六張犁、新埔、頂溪、關渡、芝山、石牌、三重、信義安和、七張、後山埤、台電大樓、淡水、景安、東門、海山、永春、江子翠、永安市場、南勢角、台北小巨蛋、南京三民、奇岩、忠義、蘆洲、迴龍、復興崗、菜寮、三和國中、三重國小、新店區公所、萬隆、土城、內湖、唭哩岸、大安森林公園、萬芳社區、大湖公園、大坪林
住商混合區	忠孝復興、市政府、忠孝新生、板橋、雙連、行天宮、中正紀念堂、民權西路、古亭、松江南京、中山、忠孝敦化、南京復興、臺北橋、大橋頭、景美、中山國中、新北投、北投、南港展覽館
學區	新店、輔大、三民高中、徐匯中學、新莊、萬芳醫院、科技大樓、文德、小南門、大安、圓山、公館、劍潭、劍南路、東湖
工作區	先嗇宮、港墘、頭前庄、丹鳳、頂埔、西湖、永寧、昆陽、亞東醫院、台大醫院、松山機場、竹圍、麟光、動物園
商業區	西門、台北車站、府中、龍山寺、台北 101、南港軟體園區、松山、國父紀念館、中山國小、象山、士林、北門
工商混合區	南京復興、善導寺、南港

5.3 動態相似度分群結果

將捷運站點分成五大類型之後，針對各類別內的流量狀況進行動態相似度分群，其中 DTW 的 time wrapping 值設定為 1，分群後結果如表 16 動態相似度分群結果表所示，依序有住宅區、工作區、商業區、學區、住商混合區以及工商混合區共分成 36 群，其中以住宅區所占比例最大，最少為工商混合區，而在分群後發現分類別內站點是具有地緣相近的因素，例如商業區的西門站與台北車站、工商混合區的忠孝新生與忠孝復興站或是學區的三民高中站與徐匯中學站等，上述站點皆為一站之遠且流量變化相似；亦有距離差非常遠但流量變化相似的站點，例如住宅區的淡水站與後山埤站、住商混合區的板橋站與中山站或是新埔站與三重站等。

表 16、動態相似度分群結果表

類別	第一群	第二群	第三群	第四群	第五群	第六群	第七群	第八群
住宅區	景安、東門、海山、永春、江子翠、永安市場、南勢角、台北小巨蛋、南京三民	菜寮、三和國中、三重國小、新店區公所、萬隆、土城、內湖、唭哩岸	信義安和、七張、後山埤、台電大樓、淡水	葫洲、明德、大直、六張犁、紅樹林	奇岩、忠義、蘆洲、迴龍、復興崗	新埔、頂溪、關渡、芝山、石牌、三重	大安森林公園、萬芳社區、大湖公園、大坪林	辛亥、木柵、小碧潭
工作區	亞東醫院、台大醫院	松山機場、竹圍、麟光	頭前庄、丹鳳、頂埔	西湖	永寧、昆陽	先嗇宮	港墘	動物園
學區	萬芳醫院、科技大樓、文德	三民高中、徐匯中學、新莊	圓山、公館、劍潭、劍南路	小南門、大安	新店、輔大	東湖		

類別	第一群	第二群	第三群	第四群	第五群	第六群	第七群	第八群
住 商 混 合 區	忠孝復興、 市政府、忠 孝新生、板 橋	雙連、行 天宮、中 正紀念 堂、民權 西路、	古亭、 松江南 京、中 山、忠 孝敦 化、南 京復興	臺北 橋、大 橋頭、 景美、 中山國 中	新北 投、北 投	南港展 覽館		
商 業 區	中山國小、 象山、士 林、北門、	府中、龍 山寺	台北 101、南 港軟體 園區	松山、 國父紀 念館	西門、 台北車 站			
工 商 混 合 區	南京復興、 善導寺	南港						

5.4 預測模型參數選擇與最佳結果

本章模擬捷運站點分別有三重國小站、小碧潭站與頂埔站。三重國小站在於主觀分類下會將其分類為學區，而在本研究之地理特徵分類後將其歸類為住宅區，透過相似度分群後發現在該群組內並非只有學校也還有其他住宅區站點，如菜寮站、萬隆站等等，可見部分捷運站點雖主觀為不同類別，但不同類別的站點間是有相似的流量變化，透過模擬該站點驗證各群組是具有相互預測之能力，也就是具有相似的流量變化能夠相互預測；多數知名商家於 2019 年 5 月 16 日開幕於小碧潭站，使該站點於當日的流量產生劇烈變化，並提高往後於該站點之流量，透過模擬該站點驗證本研究之模型對未來流量產生變化後的適應能力；頂埔站出口多為工業區屬於工作區站點，流量變化穩定沒有突發事件產生使其流量產生劇烈變化，透過模擬該站點去證實模型於基本狀況擁有良好的預測能力，透過模擬這三個不同站點去驗證本研究提出方法的有效性與可行性。

三個站點的模型預測的時長分別為未來一日與未來三日，除了三種本研究選定模型，本研究亦加入淺層遞迴類神經網路(Simple Recurrent Neural Networks, SimRNN)與深層遞迴類神經網路(Deep Recurrent Neural Networks, DRNN)進行比較，模擬未來一日使用的模型為 SVR、HRNN、GRU、SimRNN、DRNN 與集成式學習模型，模擬未來三日使用的模型為 HRNN、GRU、SimRNN、DRNN 與集成式學習模型。

模型所使用的訓練資料皆為各站點之資料集，其中將資料以八成做為訓練兩成作為驗證，測試集則為實驗模擬的三個站點，分別有三重國小站、小碧潭站與頂埔站，SVR 模型的內核函數為 RBF，HRNN 與 GRU 的網路迭代次數(Epochs)在一日模型中皆設定為 100 次，在三日模型中皆設定為 150 次，模型 Epochs 設定為 100 與 150 主要是有先行訓練過數次不同類神經，而在觀察過這些類神經網路的於訓練與驗證時損失函數的變化，一日模型平均在 30 個 Epochs 時模型皆會穩定收斂，而三日模型則要 70 至 80，為確保不同站點皆能穩定收斂因此將 Epochs 設定為 100 與 150，而損失函數使用回歸模型最常使用的均方誤差(Mean square error, MSE)，其公式如下：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (19)$$

訓練 40 個不同初始狀態模型取最佳者作為最終預測模型，訓練 40 個不同初始狀態的模型則是用於避免模型落入區域最佳解，而與 Epochs 一樣有先行試跑過部分站點，發現模型約 40 個便能找到最佳解的模型，而 40 個模型以後雖仍然有更好的但差異不大，故訓練 40 個不同初始狀態模型。

5.4.1 三重國小站

三重國小站附近有三重國小、光榮國中與光榮國小，圖 21 為三重國小周圍 500 公尺土地使用分區圖，圖上黃色代表住宅使用地、綠色代表空地、紫色代表工作區、粉色代表主幹道、藍色為機關用地與橘色代表批發使用地，透過該圖能看出學區所佔比例不及所設定之閾值而住宅區比例佔了近了七成因此將其歸類在住宅區。在同為住宅區且土地規劃比例與其最為相似之站點為三和國中站，該站與三重國小站距離僅有一站之遠，圖 22 為三和國中站周圍 500 公尺土地使用分區圖，透過該圖能看出雖然三和國中一樣位於捷運站出但比例仍不足閾值，而三和國中站出口附近雖然有塑膠工廠或是五金行等工作區之規劃，但比例上仍以住宅區為大宗，因此也將其歸類為住宅區。而後將使用與三和國中站的動態相似分群結果之站點進行建模，其結果有菜寮站、新店區公所站、萬隆站、土城站、內湖站與唭哩岸站，模型部分將分成預測未來一日的模型與預測未來三日模型兩個部分進行解說。



圖 21、三重國小周圍 500 公尺
土地使用分區圖




圖 22、三和國中站周圍 500 公尺
土地使用分區圖

(1)預測未來一日模型

預測未來一日模型的訓練績效如表 17 與表 18 所示，表 17 與 18 分別為三和國中站群組模型的訓練 RMSE 與 MAPE 績效表，此份績效表有各站模型預測自身兩年的捷運站流量的 MAPE 與 RMSE，表格為灰色者為最佳的績效結果，從此表能看到在所有訓練模型中皆以 GRU 模型的績效最佳，其次為 DRNN 模型，最差為 SVR 模型，附件二圖 1 至圖 8 為模型於訓練集的預測折線圖，從圖中能看到 SVR 模型在三者之中皆為預測最集中的模型，而類神經網路模型皆比 SVR 模型敏感，數值較容易貼近真實值，從圖 23 五種模型訓練萬隆站 2018 年至 2019 年進站人數

表 17、三和國中站群組一日模型訓練集 RMSE 績效表

捷運站	GRU	DRNN	HRNN	SimRNN	SVR
菜寮	35.358	43.4756	45.4742	45.176	55.61
三和國中	38.4289	44.883	55.5036	47.9226	60.4661
新店區公所	32.0412	38.0687	45.9095	39.7576	50.0701
萬隆	24.5497	29.2626	31.7243	30.534	40.2802
土城	19.8939	24.6956	28.3786	25.536	29.9581
唹哩岸	21.1656	25.6914	30.1512	26.7913	33.568
內湖	22.3063	29.2482	31.9763	30.3626	38.5892
三重國小	29.3295	36.3717	41.5656	38.7377	47.0932

表 18、三和國中站群組一日模型訓練集 MAPE 績效表

捷運站	GRU	DRNN	HRNN	SimRNN	SVR
菜寮	5.40749	6.77411	7.73926	7.42743	8.85539
三和國中	5.00011	5.42113	7.98326	5.96328	7.26957
新店區公所	5.06846	5.14086	7.71915	5.6414	6.9033

捷運站	GRU	DRNN	HRNN	SimRNN	SVR
萬隆	4.06859	4.42369	5.27966	4.73797	5.79766
土城	4.58497	5.33092	6.67025	5.33784	5.96779
唎哩岸	4.66869	5.37291	6.8847	5.2317	6.61853
內湖	4.4302	4.9	6.02885	5.22392	6.45254
三重國小	3.96003	4.55585	5.71992	4.77383	5.80283

折線圖中能看到在 2018 年與 2019 年 2 月初過年期間，捷運站點的人流量都會大幅降低，僅有 DRNN 與 GRU 給予最即時性的變化預測，HRNN 與 RNN 則是會延遲一兩天才會發作，SVR 模型則是對於該變化毫無反應，在模型的預測結果中皆以 GRU 與 DRNN 模型最為接近真實值，主要原因可能為這兩個模型為深度學習模型，能用以學習資料變化的變數較淺層類神經網路多，因此在於各變數具有細微變化時，模型的預測較能接近結果。




圖 23、五種模型訓練萬隆站 2018 年至 2019 年進站人數折線圖

預測未來一日的模型的測試績效如表 19 與表 20 所示，表 19 與 20 分別為三和國中站群組預測三重國小站的 RMSE 與 MAPE 測試績效表，表格為灰色者為最佳的績效結果，從測試績效表中原本於訓練集表現最差的 HRNN 此時卻有良好的結果，可能是因為 HRNN 為淺層類神經網路，其所存放的變數因為不像 GRU 一樣

表 19、三和國中站群組一日模型測試集 RMSE 績效表

捷運站	GRU	DRNN	HRNN	SimRNN	SVR
菜寮	104.29	59.0465	67.4352	56.0319	75.8117
三和國中	61.6813	43.7335	47.8723	42.7976	50.4429
新店區公所	71.309	52.1562	65.2708	56.2584	52.0357
萬隆	71.6921	79.6608	61.2944	68.536	72.2614
土城	147.48	214.02	122.901	143.907	188.074
唎哩岸	189.705	146.539	126.371	203.572	182.418
內湖	106.16	102.624	83.6022	86.9186	110.523
三重國小	29.3295	36.3717	41.5656	38.7377	47.0932

表 20、三和國中站群組一日模型測試集 MAPE 績效表

捷運站	GRU	DRNN	HRNN	SimRNN	SVR
菜寮	24.3295	10.1849	13.6684	10.2633	15.6362
三和國中	9.11331	6.68772	6.44131	5.53044	6.32016
新店區公所	12.6626	8.67126	12.9804	10.2408	8.98405
萬隆	15.2282	16.4887	11.9277	13.6236	14.5216
土城	38.8948	73.9657	30.0868	38.9149	58.3546
唎哩岸	60.3587	39.2726	33.241	68.9106	55.5467
內湖	25.316	22.9539	18.1521	19.6878	25.7664
三重國小	3.96003	4.55585	5.71992	4.77383	5.80283

多，因此對於部分細微變化而變得不夠敏感，反而使得其預測結果較為貼近預測站點的真實值。附件二圖 9 至圖 16 為模型於測試集的預測折線圖，從圖 24 萬隆站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖中能看到雖然預測數值皆低估，但其趨勢狀態卻是相近的。




圖 24、萬隆站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖

從訓練績效表與測試績效表中能看出三和國中站捷運站點，若不用來預測新站點，其績效皆落在 10% 以內，根據 Lewis[16] 學者的研究所有模型的預測能力皆為精準，但若用來預測新站點則與訓練時有不同的結果，在五個模型中以 HRNN 的績效狀況最佳，其次為 GRU 模型，若使用這兩個模型的輸出作為集成式學習模型的輸入，理應新站點的流量預測結果也會更貼近真實值。集成式學習模型的績效如表 19 所示 三和國中站群組之一日集成式學習模型預測三重國小站績效表所示，透過該表能看到測試集的 MAPE 績效落在 38%，在 MAPE，預測折線圖則如圖 25 集成式學習模型預測三重國小站於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖所示，從此圖來看模型對於預測結果皆呈現低估狀態，從圖 25 中能看到，雖然平均流量皆為低估，但模型預測的趨勢還是準確的，並不會驟降時




圖 25、一日集成式學習模型測試三重國小站於 2018 年 1 月 8 日
至 2019 年 12 月 9 日進站人數折線圖

數值預測上升，或是上升時數值預測為驟降的狀況，會產生流量低估的狀況主要是因為新站點尚未開通，因此還不會知道它的平均流量狀況，僅能透過相似站點去做評估，在三和國中站群組中各站點平均流量從 200 至 500 都有，而實際上三重國小站則是在於平均流量 500 人左右，各個子模型對於該站點的流量預測皆會呈現低估狀態，因此集成式學習模型預測出來數值也會呈現低估的狀況。

表 21、三和國中站群組之一日集成式學習模型預測三重國小站績效表

資料集	RMSE	MAPE
訓練集	121.562	24.1592
測試集	121.729	23.9511

(2)預測未來三日模型

預測未來三日模型於訓練集的預測折線圖如附件二圖 19 至圖 50 所示，圖中會有三條預測線分別代表模型輸出的 $t+1$ 、 $t+2$ 與 $t+3$ 各輸出點所構成的預測折線圖，訓練績效如表 22 與表 23 訓練三和國中站群組三日模型 RMSE 與 MAPE 績效表所示，表格為灰色者為最佳的績效結果，此表紀錄 $t+1$ 、 $t+2$ 與 $t+3$ 中最佳的績

表 22、三和國中站群組三日模型訓練集 RMSE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
菜寮	44.089	36.1444	89.19	96.4298
三和國中	48.987	38.5614	45.2591	48.2867
新店區公所	40.5133	32.4921	53.2867	51.7844
萬隆	30.0374	24.387	83.3024	83.1546
土城	26.4161	21.5217	191.17	189.141
唎哩岸	27.3358	21.6902	183.468	180.974
內湖	29.897	23.5126	122.634	119.928
三重國小	38.889	30.4939	35.6444	38.9154

表 23、三和國中站群組三日模型訓練集 MAPE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
菜寮	7.157809	6.11103	21.62474	23.64975
三和國中	6.107879	4.591606	6.006885	6.298966
新店 區公所	5.834651	4.978688	10.44052	9.64407
萬隆	4.605393	3.847808	19.0255	18.55132
土城	6.082554	4.878219	61.33212	61.35174
唎哩岸	5.983895	4.955527	59.02778	57.93336
內湖	5.39665	4.281272	31.74569	30.89935
三重國小	5.23825	3.837005	4.533821	4.997455

效表現，在所有訓練模型中以 GRU 的績效最佳，圖 26 與圖 27 分別為內湖站 DRNN 與 GRU 訓練集的預測折線圖，從圖 26 與圖 27 能看出 GRU 對於極端值的變化較 DRNN 來的有適應力，DRNN 的預測主要皆集中在某個範圍內，極端值皆無法預測得準。




圖 26、GRU 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖




圖 27、DRNN 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖

預測未來三日模型於測試集的預測折線圖如附件二圖 51 至圖 82 所示，圖中會有三條預測線分別代表模型輸出的 $t+1$ 、 $t+2$ 與 $t+3$ 各輸出點所構成的預測折線圖，訓練績效如表 24 與表 25 三和國中站群組訓練三重國小站三日模型測試集

表 24、三和國中站群組三日模型測試集 RMSE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
菜寮	66.2591	88.9558	63.5657	60.4122
三和國中	52.3744	61.8662	43.6942	42.1286
新店區公所	52.2429	60.339	46.8591	46.7005
萬隆	53.021	91.4739	69.4278	46.5419
土城	174.792	196.811	177.268	142.851
唎哩岸	132.011	163.433	164.488	203.596
內湖	76.5433	128.789	99.2997	86.7656
三重國小	38.889	30.4939	35.6444	38.9154

表 25、三和國中站群組三日模型測試集 MAPE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
菜寮	12.63262	15.89322	11.64068	11.28747

捷運站	HRNN	GRU	DRNN	SimRNN
三和國中	7.411487	10.01445	5.363357	5.439105
新店區公所	8.193211	9.053063	7.666963	7.76849
萬隆	9.70662	21.19316	13.22543	7.44158
土城	55.5082	64.34563	53.7217	38.60485
唎哩岸	35.20233	46.92894	46.48635	67.69391
內湖	16.23043	34.69901	22.53893	18.58603
三重國小	5.23825	3.837005	4.533821	4.952155

RMSE 與 MAPE 績效表所示，此表紀錄 $t+1$ 、 $t+2$ 與 $t+3$ 中最佳的績效表現，表格為灰色者為最佳的績效結果，在所有模型中以 SimRNN 模型績效最佳，圖 28 與圖 29 分別為三和國中站 SimRNN 與 GRU 測試集的預測折線圖，從圖 28 能看出 SimRNN 對於極端的數值預測能力是差的，即 2 月份的春節連假預測的流量與以往一樣變成流量的高估，而圖 29 的 GRU 模型則是對於數值的變化非常敏感，可能是因為在三和國中站的流量變化皆是以多個變數的數值互相補正，而在預測三重國小站時，互相補正的數值此時失去平衡，使得預測的數值變得忽小忽大，




圖 28、三和國中站 HRNN 模型預測三重國小站

2018 年至 2019 年進站人數折線圖




圖 29、三和國中站 GRU 模型預測三重國小站
2018 年至 2019 年進站人數折線圖

從兩張圖能看出 SimRNN 模型對於 2019 年 8 月 9 日與 9 月 30 日兩個驟降的流量預測不準確，GRU 模型則有預測到其中一個極端值，這兩個極端數值為颱風天，地方政府有放颱風假，颱風假使站點的流量急速下降，雖然 2018 年並沒有放颱風假，模型沒辦法去學習與颱風假相關的特徵變化，SimRNN 對於此部分無法準確預測視為合理狀況，反而 GRU 模型能夠預測到其中一天颱風天的流量狀況，這是非常不可思議的事情，主要是因為模型輸入並沒有與颱風天放假相關的資料，僅有地區的行動人流數據可以推敲，由此可見 GRU 模型對於預測極端值變化的數值是較 SimRNN 有能力的。

集成式學習模型的績效結果如表績效如表 26 所示，表 26 為三和國中站群組之三日集成式學習模型預測三重國小站績效，透過該表我們能看出訓練與測試績




圖 30、三日集成式學習模型預測三重國小站

於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

效差異不大，集成式學習模型的預測折線圖如附件二圖 83 與附件圖 84 所示，圖 30 為集成式學習模型測試集的預測折線圖，從此圖來看模型對於預測結果皆呈現低估狀態，主要是因為大多數的站點流量偏低，在一日集成式學習模型的結果上已發現三和國中群組子模型預測的流量皆為低估，對於站點的流量預測議會呈現低估狀態。

表 26、三和國中站群組之三日集成式學習模型預測三重國小站績效表

資料集	RMSE	MAPE
訓練集	118.818	23.511
測試集	145.164	26.5332

(3)模型時間成本

表 23 與表 24 為兩種模型的運算時間成本，時間單位為秒，其中並無 SVR、DRNN 與 SimRNN 的時間成本，主要是因為 SVR 於訓練的時間超級快平均約為 0.01 秒，但其用於預測結果的狀況皆不盡理想故不討論之，而 SimRNN 與 DRNN 皆為績效比較用模型，故不討論兩者的訓練時間成本，在這個群組中訓練最佳一日 HRNN 模型平均要花 5 分鐘，GRU 模型則需 12 分鐘；而三日 HRNN 模型平均要花 10 分鐘，GRU 模型平均要花 30 分鐘，主要隨著輸出層層數與預測時長不同而有所不同。

表 27、三和國中站

表 28、三和國中站

群組一日模型訓練時間表

群組三日模型訓練時間表

捷運站	HRNN	GRU	捷運站	HRNN	GRU
菜寮	324.418	917.175	菜寮	684.338	1817.175
三和國中	310.228	891.121	三和國中	773.152	1813.131
新店區公所	337.428	968.521	新店區公所	712.443	1938.521
萬隆	294.439	932.460	萬隆	716.846	1893.112

捷運站	HRNN	GRU	捷運站	HRNN	GRU
土城	276.820	906.745	土城	723.812	1896.551
嘿哩岸	405.298	823.069	嘿哩岸	694.148	1871.716
內湖	374.488	955.195	內湖	670.188	1865.151
三重國小	345.332	855.221	三重國小	685.312	1915.821

5.4.2 小碧潭站

小碧潭站鄰近新店溪，捷運站點附近有著許多的公寓大樓，在 2019 年 5 月中起知名家具商家進駐捷運站大樓形成共構商場，而小碧潭站點的流量也從該月開始隨之飆升，而商圈主要建構在小碧潭捷運站，因此其周遭的土地使用規劃將不會產生變化，圖 31 為小碧潭站周圍 500 公尺土地使用分區圖，透過該圖能看到新店溪幾乎佔了一半的土地，因此會將土地使用比率放大兩倍，而此站點土地規劃多為住宅用，因此將小碧潭站劃分為住宅區，在與其狀態相似的有木柵站。圖 32 為木柵站周圍 500 公尺土地使用分區圖，從此圖能看出木柵站緊臨著景美溪且土地規



圖 31、小碧潭站

周圍 500 公尺土地使用分區圖




圖 32、木柵站

周圍 500 公尺土地使用分區圖



圖 33、辛亥站周圍 500 公尺土地使用分區圖

劃比率約有四成為景美溪，因此其土地使用比率一樣放大兩倍，土地規劃也多為住宅用，因此將木柵站劃分為住宅區，與木柵站動態相似分群結果之站點僅有辛亥站，辛亥站的狀況確實也與這兩個站點狀況相似，圖 33 為辛亥站周圍 500 公尺土地使用分區圖，該圖右方有一部分藍色區域，此區域為機關使用地，透過調查後發現該地區為台北市政府公務人員訓練處，雖為機關用地但仍屬於工作地區，因此將此區域規劃轉為工作區比例，而辛亥站附近為中埔山，其佔比也約有四成左右，因此將其同木柵站做處理，土地規劃也多為住宅用，因此將辛亥站劃分為住宅區。

(1) 預測未來一日模型

預測未來一日的模型的訓練績效如表 25 所示，表 25 為木柵站群組一日模型訓練績效表，表格為灰色者為最佳的績效結果，從該表中能看出不論是在哪種模型其績效皆非常良好 MAPE 平均落在 10% 左右，訓練集的預測折線圖如附件二圖 85 至圖 87 所示，圖 34 為五種模型訓練木柵站 2018 年至 2019 年進站人數折線圖，

表 29、木柵站群組一日模型訓練集 RMSE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
辛亥	10.8142	16.8666	15.6407	12.7235	13.0763
木柵	16.4945	23.8193	21.9666	20.5	21.1132
小碧潭	12.7733	22.9774	15.4027	14.1904	14.8121

表 30、木柵站群組一日模型訓練集 MAPE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
辛亥	5.62402	7.51353	8.95138	6.27089	6.56391
木柵	6.95525	9.70563	9.69008	8.59073	9.205
小碧潭	7.44175	11.0603	8.31764	8.53804	8.04632




圖 34、五種模型訓練木柵站 2018 年至 2019 年進站人數折線圖

木柵站的流量變化為屬於穩定型，也就是並沒有太多突發事件使得人流產生急遽性變化，因此所有模型在這種站點的流量的訓練都有不錯的績效狀況。

預測未來一日模型的測試績效如表 31 與表 32 所示，表 31 與表 32 為木柵站群組預測小碧潭站一日模型測試集 RMSE 與 MAPE 績效表，表格為灰色者為最佳的績效結果，從此表中能看出所有模型的績效狀況明顯變差了，MAPE 原本平均

表 31、木柵站群組一日模型測試集 RMSE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
辛亥	30.4584	28.2504	22.1562	26.7572	20.3074
木柵	46.0704	39.6264	27.6821	23.0852	32.1024
小碧潭	12.7733	22.9774	15.4027	14.1904	14.8121

表 32、木柵站群組一日模型測試集 MAPE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
辛亥	18.9868	16.5812	12.4421	16.4633	11.1725
木柵	27.5331	24.2605	17.1635	14.1325	20.2692
小碧潭	7.44175	11.0603	8.31764	8.53804	8.04632




圖 35、木柵站五種模型預測小碧潭站 2018 年至 2019 年進站人數折線圖

在 10% 左右，許多模型提高至 20% 至 30%，訓練集的預測折線圖如附件二圖 88 至圖 90 所示，圖 35 為木柵站五種模型預測小碧潭站 2018 年至 2019 年進站人數折線圖，從該圖能看到 SVR、DRNN 與 SimRNN 對於小碧潭站的流量預測並沒有與真實流量趨勢相近，只有預測出來的流量相近而已，反觀 GRU 與 HRNN 對於該站點流量趨勢的是有相似的狀況，也就是預測值變動的狀況與真實值相似，但於數值的預測上一樣與前面三個模型一樣沒有非常精準，但卻是最貼近真實值的兩個模型。在 2019 年 5 月中旬人流劇烈變動後，對其有反應的模型僅有 HRNN 與 GRU

三個模型，SVR、SimRNN 與 DRNN 則是預測出與以往相似的流量變化，若流量產生急劇性的變化，這三個模型是不適合做為長久的流量預測模型。

集成式學習模型的測試績效如表 33 所示，表 33 為木柵站群組之一日集成式學習模型預測小碧潭站績效表，集成式學習模型的績效狀況皆在 30% 以內，作為預測模型是不錯的，集成式學習模型的預測狀況如附件二的圖 91 與圖 92 所示，圖 36 為集成式學習模型訓練小碧潭站於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖，從圖 36 能發現到集成式學習模型會遇到與 SVR、SimRNN 和 DRNN 一樣的問題，也就是流量急遽變化時預測不準確的問題，但集成式學習預測出來的數值是較這三者更接近真實值的。

表 33、木柵站群組之一日集成式學習模型預測小碧潭站績效表

資料集	MAPE	RMSE
訓練集	17.0713	37.0933
測試集	20.6724	41.8264



圖 36、一日集成式學習模型訓練小碧潭站

於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

(2)預測未來三日模型

預測未來三日的模型於訓練集的預測折線圖如附件二圖 93 至圖 104 所示，圖中會有三條預測線分別代表模型輸出的 $t+1$ 、 $t+2$ 與 $t+3$ 各輸出點所構成的預測折

線圖，模型的訓練績效如表 34 與表 35 所示，表 34 與表 35 分別為木柵站群組三日模型訓練集 RMSE 與 MAPE 績效表，此表紀錄 $t+1$ 、 $t+2$ 與 $t+3$ 中最佳的績效表現，表格為灰色者表示其績效最佳，在所有訓練模型中以 GRU 與 HRNN 模型績效最佳，DRNN 與 SimRNN 則沒有與一日模型一樣優秀的預測狀況，圖 37 與圖 38

表 34、木柵站群組三日模型訓練集 RMSE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
辛亥	13.9028	11.3091	38.0134	37.342
木柵	21.0464	16.9404	64.4824	67.5344
小碧潭	14.525	12.8536	14.7475	14.8272

表 35、木柵站群組三日模型訓練集 MAPE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
辛亥	7.3414	5.7098	24.7378	24.8036
木柵	8.7756	6.7543	35.3326	36.1831
小碧潭	8.0567	7.7895	8.4936	8.1131

GRU模型訓練木柵站於2018年至2019年進站人數預測折線圖




圖 37、GRU 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖




圖 38、SimRNN 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖

分別為木柵站 GRU 與 SimRNN 模型預測訓練集的折線圖，從兩張圖中能看到模型對於數值的預測趨勢都是非常準確的，但 SimRNN 預測的狀況較 GRU 來得保守，許多應該要下降的數值都沒有下降。

預測未來三日的模型於測試集的預測折線圖如附件二圖 105 至圖 116 所示，圖中會有三條預測線分別代表模型輸出的 $t+1$ 、 $t+2$ 與 $t+3$ 各輸出點所構成的預測折線圖，模型的訓練績效表 36 與表 37 所示，表 36 與表 37 為木柵站群組預測小碧潭站三日模型測試集 RMSE 與 MAPE 績效表，此表紀錄 $t+1$ 、 $t+2$ 與 $t+3$ 中最佳的績效表現，表格為灰色者表示其績效最佳，相較於在訓練集的績效狀況，在測試集

表 36、木柵站群組三日模型測試集 RMSE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
辛亥	22.4644	33.2809	21.787	22.6387
木柵	29.009	42.6709	36.0433	21.3473
小碧潭	14.525	12.8536	14.7475	14.8272

表 37、木柵站群組三日模型測試集 MAPE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
辛亥	11.27902	27.92316	12.54563	12.77431
木柵	18.26791	26.07548	22.11361	12.23289
小碧潭	8.056751	7.789511	8.493613	8.113102

時反而 GRU 的預測績效變成最差，圖 39 與圖 40 分別為木柵站 GRU 與 SimRNN 模型預測小碧潭站的折線圖，從圖 39 中能 GRU 模型對於急遽變化前的流量皆是呈現高估預測，而流量急遽變化後的預測非常準確，圖 40 的 SimRNN 則為流量皆非常接近真實值，但於預測時則有產生延遲預測的狀況。




圖 39、辛亥站 HRNN 模型預測小碧潭站 2018 年至 2019 年進站人數折線圖



圖 40、木柵站 GRU 模型預測小碧潭站 2018 年至 2019 年進站人數折線圖

集成式學習模型於預測小碧潭站未來三日的訓練績效如表 38 所示，表 38 為木柵站群組之三日集成式學習模型預測小碧潭站績效表，集成式學習模型三日訓練集訓練結果非常差，但在測試集時績效變好，附件二圖 117 與圖 118 為集成式學習模型於訓練與測試集的預測結果圖，圖 41 為集成式學習模型測試小碧潭站於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖，從圖中的預測狀況可以看到模型對於數值的預測在流量產生變化前皆為高估狀態，變化後則又正常，或許是因為模型是從歷史資料學習到新資料，而在 2019 年 5 月以前的平均流量皆在 100 左右，而新資料流量平均在 200 左右，模型於後面資料集學習到的流量狀況是在 200，因此模型的權重皆被調整為平均 200 人的狀況，對於更舊的資料皆會呈現高估預測，亦可能是因為集成式學習模型的主架構為淺層類神經網路，儲存的變數過少沒辦法去適應資料集的所有變化，所以對於流量變化前的狀況皆被變化後的給取代了。

表 38、木柵站群組之三日集成式學習模型預測小碧潭站績效表

資料集	RMSE	MAPE
訓練集	60.433	60.433
測試集	36.010	31.794

三日集成式模型測試小碧潭站於2018年1月8日至2019年12月9日進站人數折線圖




圖 41、三日集成式學習模型測試小碧潭站

於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

(3)模型時間成本

表 31 與表 31 為兩種模型的運算時間成本，時間單位為秒，在這個群組中訓練最佳一日 HRNN 模型平均要花 6 分鐘，GRU 模型則需 15 分鐘；而三日 HRNN 模型平均要花 7 分鐘，GRU 模型平均要花 32 分鐘，淺層類神經網路與深度學習的訓練時間差異非常大。

表 39、小碧潭站

群組一日模型訓練時間表

捷運站	HRNN	GRU
辛亥	347.291	510.332
木柵	381.181	532.136
小碧潭	313.947	513.075

表 40、小碧潭站

群組三日模型訓練時間表

捷運站	HRNN	GRU
辛亥	997.332	1995.832
木柵	967.451	2045.311
小碧潭	934.223	1989.916

5.4.3 頂埔站

捷運頂埔站主要為在土城工業區，捷運站附近緊鄰著科技園區與精密工業工廠，捷運站對面有許多的公寓大樓，圖 42 為頂埔站周圍 500 公尺土地使用分區，從圖中能看到雖然捷運站 500 公尺內的土地規劃似乎工作區與住宅區為最大宗，但考量到若將範圍再往外擴大，將會看到兩區域的分佈差距，再者捷運站主要土城工業區附近，故將此站點歸類在工作區，與捷運頂埔站土地規劃相似的站點為捷運丹鳳站，圖 43 為丹鳳站周圍 500 公尺土地使用分區，捷運丹鳳站主要位於新莊與泰山的交匯處，捷運站附近有代工廠與原料工廠以及部分的公寓大樓，比較圖 42 與圖 43 能發現兩者都以工作區為主其次為住宅區，在 500 公尺範圍內有一個商業區，在動態規劃相似上捷運丹鳳站與捷運頭前庄站兩者站點為相似站，圖 44 為頭前庄站周圍 500 公尺土地使用分區，頭前庄站近鄰大漢溪，頭前庄站與新埔站分別為大漢橋前與後的第一個捷運站，又分屬不同的捷運線，頭前庄站為黃線而新埔站為藍線，兩者雖差距一座橋但土地利用狀況卻相去甚遠，頭前庄站附近有自來水



圖 42、頂埔站周圍
500 公尺土地使用分區圖



圖 43、丹鳳站周圍
500 公尺土地使用分區圖



圖 44、頭前庄站周圍 500 公尺土地使用分區圖

公司、宅配通公司、麵粉工廠等等，從圖 44 上能看到上方有一塊藍色機關用地，該機關為衛生福利部台北醫院，醫院的工作性質於商業區與工業區相比而言更接近工業區一點，因此將其比例更改為工業區，圖 44 的左方過去皆為住宅區，右方過去皆為工作區，捷運站也可以說是位在工作區與住宅區的交會處。

(1)預測未來一日模型

預測未來一日的模型的訓練績效如表 41 與表 42 所示，表 41 與表 42 為丹鳳站群組一日模型訓練集 RMSE 與 MAPE 績效表，表格顏色為灰色者為績效最佳者，從該表中能看出不論是在哪種模型其績效皆非常良好 MAPE 皆落在 10%左右，訓練集的預測折線圖如附件二圖 119 至圖 121 所示，圖 45 為五種模型訓練丹鳳站

表 41、丹鳳站群組一日模型訓練集 RMSE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
頭前庄	18.5024	27.2552	23.8134	21.598	22.6968
丹鳳	29.2308	46.1772	41.4495	35.9264	36.9861
頂埔	27.0988	38.9376	38.8314	33.1544	33.3185

表 42、丹鳳站群組一日模型訓練集 MAPE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
頭前庄	5.95068	7.81188	8.1226	7.12817	7.4013
丹鳳	4.99207	7.24333	7.4957	6.11808	6.0436
頂埔	5.16619	6.81804	8.40046	5.82249	5.89003

五種模型訓練丹鳳站2018年至2019年進站人數折線圖




圖 45、五種模型訓練丹鳳站 2018 至 2019 年進站人數折線圖

2018 年至 2019 年進站人數折線圖，丹鳳站的流量變化為屬於穩定型，也就是並沒有太多突發事件使得人流產生急遽性變化，圖中有四個點使得流量下降至 100 多人，其中每年的 2 月為春假期間，正常工廠皆停班故流量下降為正常狀況，而 2019 年則有兩個下降點分別為 2019 年的 8 月 9 日與 9 月 30 日，這兩個時間點為強颱入境政府宣佈停班停課，在所有工廠都停班的狀況下流量下降為正常狀況，從五個模型的預設狀況皆能看到因為放颱風假而使得流量預測不準的狀況，主要是 2018 年雖然有颱風入境但危險程度還不到放假標準，使得模型沒有任何與颱風假相關的流量變化資訊，因此無法預測的到 2019 年兩次颱風的流量狀況。

預測未來一日模型的測試績效如表 43 與表 44 所示，表 43 與表 44 為丹鳳站群組一日模型測試集 RMSE 與 MAPE 績效表，表格顏色為灰色者表示其績效於五個模型中最佳者，從表中能看出績效狀況明顯差異大，又以頭前庄站的差異最

表 43、丹鳳站群組一日模型測試集 RMSE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
頭前庄	141.604	139.86	75.8631	87.8432	98.0916
丹鳳	59.8367	62.5311	61.9288	42.0859	47.5009
頂埔	27.0988	38.9376	38.8314	33.1544	33.3185

表 44、丹鳳站群組一日模型測試集 MAPE 績效表

捷運站	GRU	SVR	HRNN	DRNN	SimRNN
頭前庄	62.5364	60.358	24.4308	27.9789	34.279
丹鳳	15.0252	11.22	15.1562	8.81031	9.59627
頂埔	5.16619	6.81804	8.40046	5.82249	5.89003

大，訓練集的預測折線圖附件二圖 122 至圖 124 所示，圖 46 為五種模型訓練頭前庄站 2018 年至 2019 年進站人數折線圖，從該圖能明顯看出頭前庄站的平均流量約為 200 人左右，而訓練模型的準確度非常之高，圖 47 為頭前庄站五種模型預測頂埔站 2018 年至 2019 年進站人數折線圖，從該圖能看到頂埔站的平均流量約在 350 人左右，兩站平均流量相差約 150 人，縱然流量變化狀況相似但流量的預測上卻無法相近，在這 5 個模型中以 HRNN 模型預測流量最接近真實狀況。




圖 46、五種模型訓練頭前庄站 2018 年至 2019 年進站人數折線圖

頭前庄站五種模型預測頂埔站2018年至2019年進站人數折線圖




圖 47、頭前庄站五種模型預測頂埔站 2018 年至 2019 年進站人數折線圖

組合模型測試頂埔站於2018年1月8日至2019年12月9日進站人數折線圖




圖 48、集成式學習模型測試頂埔站

於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

集成式學習模型的測試績效如表 45 所示，表 45 為丹鳳站群組一日集成式學習模型績效表，透過該表能看到模型的訓練與測試績效皆非常優異，附件二圖 125 與圖 126 為丹鳳站群組集成式學習模型預測折線圖，圖 48 為集成式學習模型測試頂埔站於 2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖，從此圖中能看到集成式學習模型預測的流量普遍呈現低估的狀況，其原因可能是因為多數模型對於真實值的預測皆為低估，因此於集成式於預測時，輸入的數值本身就有低估的狀況，模型的輸出也就會低估。

表 45、丹鳳站群組一日集成式學習模型績效表

資料集	RMSE	MAPE
訓練集	46.5346	12.48372
測試集	76.8145	19.06551

(2)預測未來三日模型

預測未來三日的模型於訓練集的預測折線圖附件二圖 127 至圖 138 所示，圖中會有三條預測線分別代表模型輸出的 $t+1$ 、 $t+2$ 與 $t+3$ 各輸出點所構成的預測折線圖，模型的訓練績效如表 46 與表 47 所示，表 46 與表 47 為丹鳳站群組三日模型訓練集 RMSE 與 MAPE 績效表，此表紀錄 $t+1$ 、 $t+2$ 與 $t+3$ 中最佳的績效表現，表格顏色為灰色者為模型中績效最佳者，在所有訓練模型中以 GRU 與 HRNN 模型績效最佳，圖 49 與圖 50 分別為頭前庄站 HRNN 與 GRU 訓練集的預測折線圖，在這兩個模型的預測圖中能看到兩個模型對於頭前庄站皆能預測準確。

表 46、丹鳳站群組三日模型測試集 RMSE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
頭前庄	22.5479	19.0684	21.775	25.046
丹鳳	37.5455	31.5713	53.3223	53.595
頂埔	33.9383	27.8044	33.3961	34.0287

表 47、丹鳳站群組三日模型測試集 MAPE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
頭前庄	7.29777	6.371378	7.12399	7.57119
丹鳳	6.480219	5.153795	10.98406	10.86174
頂埔	6.751872	5.269626	6.226816	6.505655




圖 49、HRNN 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖




圖 50、GRU 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖

預測未來三日的模型於測試集的預測折線圖如附件二圖 139 至圖 150 所示，圖中會有三條預測線分別代表模型輸出的 $t+1$ 、 $t+2$ 與 $t+3$ 各輸出點所構成的預測折線圖，表 48 與表 49 為丹鳳站群組三日模型測試集 RMSE 與 MAPE 績效表所示，此表紀錄 $t+1$ 、 $t+2$ 與 $t+3$ 中最佳的績效表現，表格顏色為灰色者為模型中績效最佳者，績效表上能看到與一日模型測試集的狀況一樣，因為流量差異的關係，使得各模型對於頭前庄站的預測能力非常差，僅有淺層類神經網路預測的績效優

表 48、丹鳳站群組三日模型測試集 RMSE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
頭前庄	85.3434	143.289	102.693	89.4093
丹鳳	49.3135	50.5634	49.3775	52.8699
頂埔	33.9383	27.8044	33.3961	34.0287

表 49、丹鳳站群組三日模型測試集 MAPE 績效表

捷運站	HRNN	GRU	DRNN	SimRNN
頭前庄	29.94861	67.70231	35.84091	28.87099
丹鳳	10.22347	10.85905	10.65505	9.512992
頂埔	6.751872	5.269626	6.226816	6.505655

頭前庄站Simple RNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 51、丹鳳站 SimRNN 模型預測頂埔站 2018 年至 2019 年進站人數折線圖

頭前庄站HRNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 52、頭前庄站 HRNN 模型預測頂埔站 2018 年至 2019 年進站人數折線圖

於深度學習，圖 51 與圖 52 分別為丹鳳站 SimRNN 與 HRNN 模型預測頭前庄站的折線圖，從兩張圖中能看到 HRNN 模型預測數值的震動是較 SimRNN 大的。

集成式學習模型的測試績效如表 50 所示，表 50 為丹鳳站群組三日集成式學習模型績效表，透過該表能看到模型的訓練與測試績效皆非常優異，附件二圖 151 與圖 152 為丹鳳站群組三日集成式學習模型預測折線圖，圖 53 為丹鳳站群組三日

表 50、丹鳳站群組三日集成式學習模型績效表

資料集	RMSE	MAPE
訓練集	50.406	11.843
測試集	46.659	11.847

三日集成式模型測試頂埔於2018年1月8日至2019年12月9日進站人數折線圖




圖 53、丹鳳站群組三日集成式學習模型預測頂埔站

於2018年1月8日至2019年12月9日進站人數折線圖

集成式學習模型預測頂埔站於2018年1月8日至2019年12月9日進站人數折線圖，從圖53能看到雖然頭前庄站的流量變化偏低，但木柵站的模型預測的流量較貼近頂埔站的流量，因此在集成式學習模型的訓練時，不會產生所有輸入的預測值皆處於低估狀態，使得集成式學習模型的輸出值為低估狀態。

(3)模型時間成本

表39與表40為兩種模型於一日與三日預測模型的訓練時間，時間單位為秒，這個群組中訓練最佳一日HRNN模型平均要花7分鐘，GRU模型則需10分鐘；而三日HRNN模型平均要花10分鐘，GRU模型平均要花25分鐘。

表 51、丹鳳站群組

一日模型訓練時間表

捷運站	HRNN	GRU
頭前庄	418.318	622.332
丹鳳	391.992	631.136
頂埔	400.103	597.075

表 52、丹鳳站群組

三日模型訓練時間表

捷運站	HRNN	GRU
頭前庄	612.182	1728.992
丹鳳	633.113	1672.102
頂埔	638.715	1537.132

5.5 小結

本研究分別模擬了三個不同捷運站點於一日與三日的流量預測，並整理了以下幾點結論：

1. 若捷運站地理空間相似度高其流量變化會有相近的狀況，但平均流量狀況卻不一定是相近的，在同一相似的群組內可能會有不同流量大小的站點。
2. SVR 模型雖然在各群組的原始站點訓練中皆有不錯績效，但用來預測新站點時將會預測不準確。
3. 淺層類神經網路模型雖然是最適合預測新站點的模型，但在兩個淺層類神經網路中又以 HRNN 的預測狀況更優於 SimRNN，主要是因為在極端值的預測 HRNN 擁有比 SimRNN 更優秀的預測績效。
4. 若不考慮時間成本的問題深度學習模型是適合用來預測原始站點的模型，模型不論是在極端值的預測或是整體的預測上皆有步錯的表現，但 GRU 模型因為有記憶單元，使得整體得預測狀況又優於 DRNN。
5. 對於新站點的預測上集成式學習模型是最合理的選擇，雖然其時間成本是所有模型裡面最高的，但該模型學習了不同模型的預測狀況，並從中評估新站點的流量狀況，克服了流量大小差異使得預測不準確的問題，雖模型本身亦會受到前置模型預測高估或低估影響使得流量預測高估或低估，但狀況並不嚴重。

綜上所述，若要進行群組流量預測將以 HRNN 為最優先考量，新站點流量預測則可以考慮使用本研究提出之集成式學習模型，若僅對舊有站點進行流量預測且極端性變化並不影響則可以使用 SimRNN 模型或是 SVR 模型，

本研究中一日流量的預測中 GRU 模型平均訓練時間為 12 分鐘，HRNN 模型平均為 7 分鐘，若建構 36 個分群模型則分別需花費 7.2 小時與 4.2 小時；三日流量的預測中 GRU 模型平均訓練時間為 30 分鐘，HRNN 模型平均為 12 分鐘，若建

構 36 個分群模型則分別需花費 7.2 小時與 45 小時，相較於訓練 108 個站點所花費的時間成本，透過地理空間組合特徵工程方式能將時間成本減少至原本的三分之一，訓練模型減少的时间成本非常地可觀。

模型能快速建立起來對許多層面皆有助益，以連鎖便利超商舉例，在訂定進貨時通常是由總公司設定各店鋪基本配量，此時於捷運站點附近的店便可以依照流量狀況調整基本配量，再由各店鋪依據經驗法則進行配貨量調整，但新開站點的店鋪並沒有歷史經驗可言，只能由於它店的配貨經驗進行調整或是根據前幾日的報廢狀況進行配貨調整直到流量與報廢品數量穩定下來，然而這段期間內的損失理應是能減少或是避免的，因此若有個方法能夠找到相似流量下的相似店鋪配量狀況進行調整應能減少報廢成本。再者，當有新捷運站點開立，捷運站點的流量預測會隨著開通的時間變長使得模型的預測精準度越發提高，因為所使用的流量不再是其他方法評估而來，而是使用站點自身的流量狀況進行預測，但於流量預測模型卻需要依據新資料重新建模，雖然單站點的建模時間不高，但捷運通常一次開通將是一整條捷運線並非一個或兩個站點，屆時時間成本亦然會拉高，若使用本研究的方法將可以快速找到相似站點對新站點流量進行評估預測且不需要再進行新站點的建模。

第六章 結論

捷運為民眾帶來莫大的便利性，地方政府也意識到捷運的重要性，越來越多捷運站點正在興建與開通，例如台中捷運站於 2021 年 4 月 5 日開通，對於商家、政府或是捷運公司來說，掌握新站點流量是一件重要的事情，過往研究中對於站點的流量普遍採用預測模型去評估未來的流量狀況，預測方法又以深度學習為準確度最高的模型，雖然深度學習能夠以最高的準確度進行流量預測，卻因其錯縱複雜的隱藏層與神經元的訓練使得時間成本極高，過往研究中雖有討論時間成本問題，但多數皆為模型方法的調整，模型方法調整又會因為案例不同而不一定適用於本研究，故本研究提出一種基於地理空間資訊與特徵工程的方法縮減訓練的模型數量，地理空間資訊為土地利用分區狀況，而特徵工程則使用 DTW 與 Cosine Similarity 進行站點流量變化的相似度計算，除了透過聚類方法將訓練量減少，本研究亦比較於人流預測上擁有良好績效的三種模型的預測績效與時間成本問題，而為了全新站點的流量預測，亦設計集成式學習模型進行流量評估，最終於實驗模擬發現在考量時間成本下 HRNN 為預測捷運站流量最佳的模型，若不考慮時間成本則以 GRU 模型為預測捷運站流量最佳的模型，而對於未知的新站點則以集成式學習模型為最合理的預測模型。

針對未來研究可以往以下幾點繼續延伸討論：1.地理空間資訊本研究以土地利用狀況作為分類依據，還有許多空間資訊可以做為聚類依據，例如，地理標籤資訊、地區人群或是交通結構狀況等，皆能作為未來延就可以延伸討論的地方。2.使用分區閾值的設定為主觀下最佳數值的設定，此部分可以依照需求進行調整，亦可考慮直接使用非監督式聚類方法進行分區，如 K-means 等。3.集成式學習模型的設計為雛型概念，能夠透過其他方法進行集成式學習模型設計，如更改預測的主模型或是透過更多的模型進行預測，然後再進行模型的集成式學習。未來也可以將類似的結構概念套用至其他題目，例如連鎖商家開店來客預測。

參考文獻

- [1] Adewole, A. T., Falayi, E. O., Roy-Layinde, T. O., & Adelaja, A. D. (2020). Chaotic Time Series analysis of meteorological parameters in some selected stations in Nigeria. *Scientific African*, e00617.
- [2] Altındış, F., Yılmaz, B., Borisenok, S., & İçöz, K. Parameter investigation of topological data analysis for EEG signals. *Biomedical Signal Processing and Control*, 63, 102196.
- [3] Beşiktaş, C., & Mantar, H. A. (2012, March). Real-time traffic classification based on cosine similarity using sub-application vectors. In *International Workshop on Traffic Monitoring and Analysis* (pp. 89-92). Springer, Berlin, Heidelberg.
- [4] Caruana, R. (1997). Multitask Learning. *Machine Learning*, 28(1), 41–75.
- [5] Chen, Y., Xu, P., Chu, Y., Li, W., Wu, Y., Ni, L., ... & Wang, K. (2017). Short-term electrical load forecasting using the Support Vector Regression (SVR) model to calculate the demand response baseline for office buildings. *Applied Energy*, 195, 659-670
- [6] Chen, Y., Yao, M., & Cai, Z. (2018, July). Research on the Classification of Urban Rail Transit Stations-Taking Shanghai Metro as an Example. In *2018 15th International Conference on Service Systems and Service Management (ICSSSM)* (pp. 1-6). IEEE.
- [7] Chow, T. W., & Fang, Y. (1998). A recurrent neural-network-based real-time learning control strategy applying to nonlinear systems with unknown dynamics. *IEEE transactions on industrial electronics*, 45(1), 151-161.
- [8] Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*.

- [9] Han, S., Mao, H., & Dally, W. J. (2015). Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding. *arXiv preprint arXiv:1510.00149*.
- [10] Han, T., Peng, Q., Zhu, Z., Shen, Y., Huang, H., & Abid, N. N. (2020). A pattern representation of stock time series based on DTW. *Physica A: Statistical Mechanics and its Applications*, 124161.
- [11] Hong, W. C., Dong, Y., Zheng, F., & Wei, S. Y. (2011). Hybrid evolutionary algorithms in a SVR traffic flow forecasting model. *Applied Mathematics and Computation*, 217(15), 6733-6747.
- [12] Hu, Y., Gao, S., Janowicz, K., Yu, B., Li, W., & Prasad, S. (2015). Extracting and understanding urban areas of interest using geotagged photos. *Computers, Environment and Urban Systems*, 54, 240-254.
- [13] Huang, S. C., Chuang, P. J., Wu, C. F., & Lai, H. J. (2010). Chaos-based support vector regressions for exchange rate forecasting. *Expert Systems with Applications*, 37(12), 8590-8598.
- [14] Juang, C. F., & Lin, C. T. (1999). A recurrent self-organizing neural fuzzy inference network. *IEEE Transactions on Neural Networks*, 10(4), 828-845.
- [15] Lee, R. K., Yang, Y. C., Chen, J. H., & Chen, Y. C. (2017, November). Freeway travel time prediction by using the GA-based Hammerstein recurrent neural network. In *International Conference on Genetic and Evolutionary Computing* (pp. 12-19). Springer, Singapore.
- [16] Lewis, C. D. (1982). *Industrial and business forecasting methods: A practical guide to exponential smoothing and curve fitting*. Butterworth-Heinemann.
- [17] Li, D. C. (2019), Regional PM2.5 Prediction Based on Neural Network, *National Yunlin University of Science and Technology*, Yunlin City.

- [18] Li, H. Time works well: Dynamic time warping based on time weighting for time series data mining. *Information Sciences*, 547, 592-608.
- [19] Li, Y., Wang, X., Sun, S., Ma, X., & Lu, G. (2017). Forecasting short-term subway passenger flow under special events scenarios using multiscale radial basis function networks. *Transportation Research Part C: Emerging Technologies*, 77, 306-328.
- [20] Liu, S. C. (2020), Analysis and Prediction of Abnormal Stream of People in Taipei Mass Rapid Transit, *National Yunlin University of Science and Technology*, Yunlin City.
- [21] Liu, Y., & Tian, L., (2020). A graded cluster system to mine virtual stations in free-floating bike-sharing system on multi-scale geographic view, *Journal of Cleaner Production*, 124692.
- [22] Liu, Y., Liu, Z., & Jia, R. (2019). DeepPF: A deep learning based architecture for metro passenger flow prediction. *Transportation Research Part C: Emerging Technologies*, 101, 18-34.
- [23] Liu, Y., Qin, Y., Guo, J., Cai, C., Wang, Y., & Jia, L. (2018, December). Short-term forecasting of rail transit passenger flow based on long short-term memory neural network. In *2018 International Conference on Intelligent Rail Transportation (ICIRT)* (pp. 1-5). IEEE.
- [24] Martin, F., Fileni, L., Palomino, I., Vivanco, M. G., & Garrido, J. L. (2014). Analysis of the spatial representativeness of rural background monitoring stations in Spain. *Atmospheric Pollution Research*, 5(4), 779-788.
- [25] Masnad, M., MukitHasan, G. M., Iftekhar, K. M., & Rahman, M. S. (2019, June). Human Activity Recognition using DTW Algorithm. In *2019 IEEE Region 10 Symposium (TENSYP)* (pp. 39-43). IEEE.

- [26] Nagy, A. M., & Simon, V. (2018). Survey on traffic prediction in smart cities. *Pervasive and Mobile Computing*, 50, 148-163.
- [27] Nourali, H., & Osanloo, M. (2019). Mining capital cost estimation using Support Vector Regression (SVR). *Resources Policy*, 62, 527-540.
- [28] Peng, B., Wang, J., & Zhang, X. (2020). Adversarial learning of sentiment word representations for sentiment analysis. *Information Sciences*, 541, 426-441.
- [29] Piersanti, A., Vitali, L., Righini, G., Cremona, G., & Ciancarella, L. (2015). Spatial representativeness of air quality monitoring stations: a grid model based approach. *Atmospheric Pollution Research*, 6(6), 953-960.
- [30] Ramezanpanah, Z., Mallem, M., & Davesne, F. (2020). Human Action Recognition Using Laban Movement Analysis and Dynamic Time Warping. *Procedia Computer Science*, 176, 390-399.
- [31] Righini, G., Cappelletti, A., Ciucci, A., Cremona, G., Piersanti, A., Vitali, L., & Ciancarella, L. (2014). GIS based assessment of the spatial representativeness of air quality monitoring stations using pollutant emissions data. *Atmospheric Environment*, 97, 121-129.
- [32] Sastry, P. S., Santharam, G., & Unnikrishnan, K. P. (1994). Memory neuron networks for identification and control of dynamical systems. *IEEE transactions on neural networks*, 5(2), 306-319.
- [33] Stolz, T., Huertas, M. E., & Mendoza, A. (2020). Assessment of air quality monitoring networks using an ensemble clustering method in the three major metropolitan areas of Mexico. *Atmospheric Pollution Research*.
- [34] Sun, P., Boukerche, A., & Tao, Y. (2020). SSGRU: a novel hybrid stacked GRU-based traffic volume prediction approach in a road network. *Computer Communications*, 160, 502-511.

- [35] Tang, L., Zhao, Y., Cabrera, J., Ma, J., & Tsui, K. L. (2018). Forecasting short-term passenger flow: An empirical study on shenzhen metro. *IEEE Transactions on Intelligent Transportation Systems*, 20(10), 3613-3622..
- [36] Tsai, C. H., & Wang, J. Y. (2017). The study of bus arrival schedule based on DBSCAN algorithm, *National Chiao Tung University*, Hsinchu City.
- [37] Vapnik, V. (2013). *The nature of statistical learning theory*. Springer science & business media.
- [38] Vignesh, R., Jothiprakash, V., & Sivakumar, B. (2015). Streamflow variability and classification using false nearest neighbor method. *Journal of Hydrology*, 531, 706-715.
- [39] Wang, J. S., & Hsu, Y. L. (2010). An MDL-based Hammerstein recurrent neural network for control applications. *Neurocomputing*, 74(1-3), 315-327.
- [40] Wang, X., Guan, X., Cao, J., Zhang, N., & Wu, H. (2020). Forecast Network-Wide Traffic States for Multiple Steps Ahead: A Deep Learning Approach Considering Dynamic Non-Local Spatial Correlation and Non-Stationary Temporal Dependency. *arXiv preprint arXiv:2004.02391*.
- [41] Wei, Y., Lin, S., Chu, R., Tian, Q., & Fei, W. (2016). A method of grading subway stations. *Journal of Transportation Research Procedia*, 137, 806-810.
- [42] Yu, H., Pan, G., Zhang, L., Li, Z., & Pan, M. (2019). Translation domain segmentation model based on improved cosine similarity for crowd motion segmentation. *Journal of Electronic Imaging*, 28(2), 023011
- [43] Zacharias, J. (2001). Pedestrian behavior pedestrian behavior and perception in urban walking environments. *Journal of Planning Literature*, 16(1), 3-18.

- [44] Zhang, S., Abdel-Aty, M., Wu, Y., & Zheng, O. (2020). Modeling pedestrians' near-accident events at signalized intersections using gated recurrent unit (GRU). *Accident Analysis & Prevention*, 148, 105844.
- [45] Zhang, Z., Chen, P., Wang, Y., & Yu, G. (2017, October). A hybrid deep learning approach for urban expressway travel time prediction considering spatial-temporal features. In *2017 IEEE 20th International Conference on Intelligent Transportation Systems (ITSC)* (pp. 795-800). IEEE.
- [46] Zhu, S., Lian, X., Wei, L., Che, J., Shen, X., Yang, L., ... & Li, J. (2018). PM2. 5 forecasting using SVR with PSOGSA algorithm based on CEEMD, GRNN and GCA considering meteorological factors. *Atmospheric Environment*, 183, 20-32.
- [47] Zola, P., Ragno, C., & Cortez, P. (2020). A Google Trends spatial clustering approach for a worldwide Twitter user geolocation. *Information Processing & Management*, 57(6), 102312.

附件一 所有捷運站區域比例表

表 1、商業區比例表

捷運站	工作區	住宅區	商業區	機關用地	學區	空地
南京復興	0	35	40	0	16	9
南港軟體園區	10	20	45	12	0	13
象山	0	25	40	8	12	15
台北 101	0	27	40	13	15	5
台北車站	12	0	68	12	5	3
中山	0	30	40	15	10	5
士林	0	15	40	13	17	15
西門	20	0	65	7	8	0
北門	12	5	48	15	12	8
中山	0	30	40	15	10	5
南京復興	0	35	40	0	16	9
松山	10	22	41	15	8	4
中山國小	0	21	59	3	12	5
府中	0	14	57	12	14	3
龍山寺	4	7	69	7	11	2
西門	20	0	65	7	8	0
台北車站	12	0	68	12	5	3
國父紀念館	14	25	43	4	11	3

表 2、工作區比例表

捷運站	工作區	住宅區	商業區	機關用地	學區	空地
西湖	45	25	3	5	15	7
先嗇宮	89	6	2	2	1	0
頭前庄	76	18	0	4	0	2
丹鳳	43	12	9	5	12	19
頂埔	44	24	16	4	0	12
永寧	69	15	0	8	0	8
昆陽	43	17	13	11	12	4

表 3、學區比例表

捷運站	工作區	住宅區	商業區	機關用地	學區	空地
萬芳醫院	0	15	25	10	45	5
科技大樓	0	45	20	3	30	2
大安	0	35	15	5	40	5
文德	0	37	10	5	28	20
大安	0	35	15	5	40	5
新店	0	15	10	10	30	35
公館	0	14	17	23	38	8
新莊	8	23	23	12	32	2
輔大	25	12	25	4	33	1
徐匯中學	12	42	4	6	32	4
三民高中	7	34	22	8	25	4

表 4、住宅區比例表

捷運站	工作區	住宅區	商業區	機關用地	學區	空地
六張犁	0	60	20	5	10	5
大直	0	50	15	15	15	5
信義安和	0	50	35	5	5	5
東門	0	60	15	10	10	5
明德	0	55	15	10	8	12
石牌	0	55	20	12	13	0
新店區公所	0	55	3	20	10	12
七張	10	65	8	6	7	4
小碧潭	0	57	0	24	12	7
大坪林	30	60	0	5	0	5
台電大樓	0	53	18	8	12	9
南勢角	10	53	14	12	8	3
景安	0	82	4	11	0	3
永安市場	0	63	21	0	0	16
頂溪	0	58	21	6	12	3
東門	0	60	15	10	10	5
三重	0	62	21	12	4	1
三重國小	0	62	21	4	12	1
三和國中	14	52	7	9	13	5
土城	8	54	12	9	12	5

捷運站	工作區	住宅區	商業區	機關用地	學區	空地
海山	1	67	21	4	5	2
新埔	0	74	3	8	12	3
永春	0	58	23	4	12	3
後山埤	4	63	17	4	8	4

表 5、其他區

捷運站	工作區	住宅區	商業區	機關用地	學區	空地
大安森林公園	0	40	10	0	15	35
大湖公園	0	35	15	10	10	30
大橋頭站	0	37	36	4	21	2
小南門	25	25	7	8	20	15
中山國中	0	45	30	0	20	5
中正紀念堂	3	30	30	12	10	15
內湖	0	45	25	5	12	13
木柵	0	45	10	10	15	20
北投	0	37	28	10	10	15
古亭	0	42	35	5	15	4
台大醫院	0	0	30	35	15	20
台北小巨蛋	4	48	21	0	12	15
台北橋	0	47	36	5	9	3
市政府	12	36	37	4	8	3
民權西路	13	35	35	12	0	5
江子翠	5	47	18	12	14	4
竹園	20	35	12	13	0	20
行天宮	0	45	30	4	17	4
辛亥	0	40	15	10	15	20
亞東醫院	27	33	12	12	12	4
奇岩	30	41	4	13	2	10
忠孝復興	4	38	33	6	18	1
忠孝敦化	0	46	38	12	4	0
忠孝新生	14	42	16	6	21	1
忠義	8	35	0	15	12	30
東湖	10	25	20	5	15	25
松山機場	0	39	3	45	5	8
松江南京	0	42	39	0	14	5
板橋	9	33	32	11	12	3

捷運站	工作區	住宅區	商業區	機關用地	學區	空地
芝山	15	45	5	18	5	12
南京三民	9	49	21	0	17	4
南港	31	9	22	17	14	7
南港展覽館	5	10	35	10	15	25
紅樹林	10	35	5	5	0	45
迴龍	14	39	2	28	8	9
動物園	25	25	5	20	0	25
唎哩岸	3	45	12	12	13	15
淡水	8	37	17	18	0	20
善導寺	31	7	23	12	24	3
復興崗	0	35	8	25	12	20
景美	0	32	33	8	15	12
港墘	25	40	10	5	15	5
菜寮	8	41	24	12	12	3
圓山	20	25	28	12	0	15
新北投	0	32	36	7	15	10
萬芳社區	0	30	10	10	20	30
萬隆	10	45	23	7	10	5
葫洲	0	45	15	15	10	15
劍南路	5	20	35	5	0	35
劍潭	10	30	8	12	15	25
雙連	0	35	35	12	13	5
關渡	30	25	8	12	10	15
蘆洲	0	42	10	13	24	11
麟光	0	35	5	10	5	45

附件二 模型預測結果折線圖

五種模型訓練菜寮站2018年至2019年進站人數折線圖




圖 1、五種模型訓練菜寮站 2018 年至 2019 年進站人數折線圖

五種模型訓練三和國中站2018年至2019年進站人數折線圖




圖 2、五種模型訓練三和國中站 2018 年至 2019 年進站人數折線圖

五種模型訓練三重國小站2018年至2019年進站人數折線圖




圖 3、五種模型訓練三重國小站 2018 年至 2019 年進站人數折線圖

五種模型訓練新店區公所站2018年至2019年進站人數折線圖




圖 4、五種模型訓練新店區公所站 2018 年至 2019 年進站人數折線圖

五種模型訓練萬隆站2018年至2019年進站人數折線圖




圖 5、五種模型訓練萬隆站 2018 年至 2019 年進站人數折線圖

五種模型訓練土城站2018年至2019年進站人數折線圖




圖 6、五種模型訓練土城站 2018 年至 2019 年進站人數折線圖




圖 7、五種模型訓練唹哩岸站 2018 年至 2019 年進站人數折線圖




圖 8、五種模型訓練內湖站 2018 年至 2019 年進站人數折線圖




圖 9、菜寮站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 10、三和國中站五種模型預測三重國小站
2018 年至 2019 年進站人數折線圖




圖 11、三重國小站五種模型預測三重國小站
2018 年至 2019 年進站人數折線圖




圖 12、新店區公所站站五種模型預測三重國小站
2018 年至 2019 年進站人數折線圖




圖 13、萬隆站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 14、土城站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 15、呷哩岸站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖

內湖站五種模型預測三重國小站2018年至2019年進站人數折線圖




圖 16、內湖站五種模型預測三重國小站 2018 年至 2019 年進站人數折線圖

一日集成式模型訓練三重國小站於2018年1月8日至2019年12月9日進站人數折線圖




圖 17、一日集成式學習模型訓練三重國小站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

一日集成式模型測試三重國小站於2018年1月8日至2019年12月9日進站人數折線圖




圖 18、一日集成式學習模型預測三重國小站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖




圖 19、HRNN 模型訓練菜寮站於 2018 年至 2019 年進站人數預測折線圖




圖 20、HRNN 模型訓練三和國中站於 2018 年至 2019 年進站人數預測折線圖




圖 21、HRNN 模型訓練三重國小站於 2018 年至 2019 年進站人數預測折線圖




圖 22、HRNN 模型訓練新店區公所站
於 2018 年至 2019 年進站人數預測折線圖




圖 23、HRNN 模型訓練萬隆站於 2018 年至 2019 年進站人數預測折線圖




圖 24、HRNN 模型訓練土城站於 2018 年至 2019 年進站人數預測折線圖




圖 25、HRNN 模型訓練嘿哩岸站於 2018 年至 2019 年進站人數預測折線圖




圖 26、HRNN 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖




圖 27、GRU 模型訓練菜寮站於 2018 年至 2019 年進站人數預測折線圖




圖 28、GRU 模型訓練三和國中站於 2018 年至 2019 年進站人數預測折線圖




圖 29、GRU 模型訓練三重國小站於 2018 年至 2019 年進站人數預測折線圖




圖 30、GRU 模型訓練新店區公所站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練萬隆站於2018年至2019年進站人數預測折線圖




圖 31、GRU 模型訓練萬隆站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練土城站於2018年至2019年進站人數預測折線圖




圖 32、GRU 模型訓練土城站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練唹哩岸站於2018年至2019年進站人數預測折線圖




圖 33、GRU 模型訓練唹哩岸站於 2018 年至 2019 年進站人數預測折線圖




圖 34、GRU 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖




圖 35、DRNN 模型訓練菜寮站於 2018 年至 2019 年進站人數預測折線圖




圖 36、DRNN 模型訓練三和國中站於 2018 年至 2019 年進站人數預測折線圖




圖 37、DRNN 模型訓練三重國小站於 2018 年至 2019 年進站人數預測折線圖




圖 38、DRNN 模型訓練新店區公所站於 2018 年至 2019 年進站人數預測折線圖




圖 39、DRNN 模型訓練萬隆站於 2018 年至 2019 年進站人數預測折線圖




圖 40、DRNN 模型訓練土城站於 2018 年至 2019 年進站人數預測折線圖




圖 41、DRNN 模型訓練唭哩岸站於 2018 年至 2019 年進站人數預測折線圖




圖 42、DRNN 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖

Simple RNN模型訓練菜寮站於2018年至2019年進站人數預測折線圖




圖 43、SimRNN 模型訓練菜寮站於 2018 年至 2019 年進站人數預測折線圖

Simple RNN模型訓練三和國中站於2018年至2019年進站人數預測折線圖




圖 44、SimRNN 模型訓練三和國中站於 2018 年至 2019 年進站人數預測折線圖

Simple RNN模型訓練三重國小站於2018年至2019年進站人數預測折線圖




圖 45、SimRNN 模型訓練三重國小站於 2018 年至 2019 年進站人數預測折線圖




圖 46、SimRNN 模型訓練新店區公所站於 2018 年至 2019 年進站人數預測折線圖




圖 47、SimRNN 模型訓練萬隆站於 2018 年至 2019 年進站人數預測折線圖




圖 48、SimRNN 模型訓練土城站於 2018 年至 2019 年進站人數預測折線圖




圖 49、SimRNN 模型訓練噶哩岸站於 2018 年至 2019 年進站人數預測折線圖




圖 50、SimRNN 模型訓練內湖站於 2018 年至 2019 年進站人數預測折線圖




圖 51、菜寮站 HRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 52、菜寮站 HRNN 模型預測三和國中站 2018 年至 2019 年進站人數折線圖




圖 53、三重國小站 HRNN 模型預測三重國小站
2018 年至 2019 年進站人數折線圖




圖 54、新店區公所站 HRNN 模型預測三重國小站
2018 年至 2019 年進站人數折線圖




圖 55、萬隆站 HRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 56、土城站 HRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 57、噶哩岸站 HRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 58、內湖站 HRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 59、菜寮站 GRU 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 60、三和國中站 GRU 模型預測三重國小站

2018 年至 2019 年進站人數折線圖

三重國小站GRU模型預測三重國小站2018年至2019年進站人數折線圖




圖 61、三重國小站 GRU 模型預測三重國小站
2018 年至 2019 年進站人數折線圖

新店區公所站GRU模型預測三重國小站2018年至2019年進站人數折線圖




圖 62、新店區公所站 GRU 模型預測三重國小站
2018 年至 2019 年進站人數折線圖

萬隆站GRU模型預測三重國小站2018年至2019年進站人數折線圖




圖 63、萬隆站 GRU 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

土城站GRU模型預測三重國小站2018年至2019年進站人數折線圖




圖 64、土城站 GRU 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

唎哩岸站GRU模型預測三重國小站2018年至2019年進站人數折線圖




圖 65、唎哩岸站 GRU 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

內湖站GRU模型預測三重國小站2018年至2019年進站人數折線圖




圖 66、內湖站 GRU 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

菜寮站DRNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 67、菜寮站 DRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

三和國中站DRNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 68、三和國中站 DRNN 模型預測三重國小站

2018 年至 2019 年進站人數折線圖

三重國小站DRNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 69、三重國小站 DRNN 模型預測三重國小站

2018 年至 2019 年進站人數折線圖

新店區公所站DRNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 70、新店區公所站 DRNN 模型預測三重國小站
2018 年至 2019 年進站人數折線圖

萬隆站DRNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 71、萬隆站 DRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

土城站DRNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 72、土城站 DRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 73、嘿哩岸站 DRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 74、內湖站 DRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 75、菜寮站 SimRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖




圖 76、三和國中站 SimRNN 模型預測三重國小站
2018 年至 2019 年進站人數折線圖




圖 77、三重國小站 SimRNN 模型預測三重國小站
2018 年至 2019 年進站人數折線圖




圖 78、新店區公所站 SimRNN 模型預測三重國小站
2018 年至 2019 年進站人數折線圖

萬隆站Simple RNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 79、萬隆站 SimRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

土城站Simple RNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 80、土城站 SimRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

噶哩岸站Simple RNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 81、噶哩岸站 SimRNN 模型

預測三重國小站 2018 年至 2019 年進站人數折線圖

內湖站Simple RNN模型預測三重國小站2018年至2019年進站人數折線圖




圖 82、內湖站 SimRNN 模型預測三重國小站 2018 年至 2019 年進站人數折線圖

三日集成式模型訓練三重國小站於2018年1月8日至2019年12月9日進站人數折線圖




圖 83、三日集成式學習模型訓練三重國小站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖




圖 84、三日集成式學習模型預測三重國小站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

五種模型訓練辛亥站2018年至2019年進站人數折線圖




圖 85、五種模型訓練辛亥站 2018 年至 2019 年進站人數折線圖

五種模型訓練木柵站2018年至2019年進站人數折線圖




圖 86、五種模型訓練木柵站 2018 年至 2019 年進站人數折線圖

五種模型訓練小碧潭站2018年至2019年進站人數折線圖




圖 87、五種模型訓練小碧潭站 2018 年至 2019 年進站人數折線圖

辛亥站五種模型預測小碧潭站2018年至2019年進站人數折線圖




圖 88、辛亥站五種模型預測小碧潭站 2018 年至 2019 年進站人數折線圖

木柵站五種模型預測小碧潭站2018年至2019年進站人數折線圖




圖 89、木柵站五種模型預測小碧潭站 2018 年至 2019 年進站人數折線圖

小碧潭站五種模型預測小碧潭站2018年至2019年進站人數折線圖




圖 90、小碧潭站五種模型預測小碧潭站 2018 年至 2019 年進站人數折線圖

一日集成式模型訓練小碧潭站於2018年1月8日至2019年12月9日進站人數折線圖




圖 91、一日集成式學習模型訓練小碧潭站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

一日集成式模型測試小碧潭站於2018年1月8日至2019年12月9日進站人數折線圖




圖 92、一日集成式學習模型訓練小碧潭站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

HRNN模型訓練辛亥站於2018年至2019年進站人數預測折線圖




圖 93、HRNN 模型訓練辛亥站於 2018 年至 2019 年進站人數預測折線圖




圖 94、HRNN 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖




圖 95、HRNN 模型訓練小碧潭站於 2018 年至 2019 年進站人數預測折線圖




圖 96、GRU 模型訓練辛亥站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練木柵站於2018年至2019年進站人數預測折線圖




圖 97、GRU 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練小碧潭站於2018年至2019年進站人數預測折線圖




圖 98、GRU 模型訓練小碧潭站於 2018 年至 2019 年進站人數預測折線圖

Simple RNN模型訓練辛亥站於2018年至2019年進站人數預測折線圖




圖 99、SimRNN 模型訓練辛亥站於 2018 年至 2019 年進站人數預測折線圖




圖 100、SimRNN 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖




圖 101、SimRNN 模型訓練小碧潭站於 2018 年至 2019 年進站人數預測折線圖




圖 102、DRNN 模型訓練辛亥站於 2018 年至 2019 年進站人數預測折線圖




圖 103、DRNN 模型訓練木柵站於 2018 年至 2019 年進站人數預測折線圖




圖 104、DRNN 模型訓練小碧潭站於 2018 年至 2019 年進站人數預測折線圖




圖 105、辛亥站 HRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖




圖 106、木柵站 HRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖



圖 107、小碧潭站 HRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖




圖 108、辛亥站 GRU 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖




圖 109、木柵站 GRU 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖



圖 110、小碧潭站 GRU 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖




圖 111、辛亥站 DRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖

木柵站DRNN模型預測小碧潭站2018年至2019年進站人數折線圖




圖 112、木柵站 DRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖

小碧潭站DRNN模型預測小碧潭站2018年至2019年進站人數折線圖




圖 113、小碧潭站 DRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖

辛亥站Simple RNN模型預測小碧潭站2018年至2019年進站人數折線圖




圖 114、辛亥站 SimRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖

木柵站Simple RNN模型預測小碧潭站2018年至2019年進站人數折線圖




圖 115、木柵站 SimRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖

小碧潭站Simple RNN模型預測小碧潭站2018年至2019年進站人數折線圖




圖 116、小碧潭站 SimRNN 模型預測小碧潭站
於 2018 年至 2019 年進站人數預測折線圖

三日集成式模型訓練小碧潭站於2018年1月8日至2019年12月9日進站人數折線圖




圖 117、三日集成式學習模型訓練小碧潭站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

三日集成式模型測試小碧潭站於2018年1月8日至2019年12月9日進站人數折線圖




圖 118、三日集成式學習模型測試小碧潭站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

五種模型訓練頭前庄站2018年至2019年進站人數折線圖




圖 119、五種模型訓練頭前庄站 2018 年至 2019 年進站人數折線圖

五種模型訓練丹鳳站2018年至2019年進站人數折線圖




圖 120、五種模型訓練丹鳳站 2018 年至 2019 年進站人數折線圖

五種模型訓練頂埔站2018年至2019年進站人數折線圖




圖 121、五種模型訓練頂埔站 2018 年至 2019 年進站人數折線圖

頭前庄站五種模型預測頂埔站2018年至2019年進站人數折線圖




圖 122、頭前庄站五種模型預測頂埔站 2018 年至 2019 年進站人數折線圖

丹鳳站五種模型預測頂埔站2018年至2019年進站人數折線圖




圖 123、丹鳳站五種模型預測頂埔站 2018 年至 2019 年進站人數折線圖

頂埔站五種模型預測頂埔站2018年至2019年進站人數折線圖




圖 124、頂埔站五種模型預測頂埔站 2018 年至 2019 年進站人數折線圖

一日集成式模型訓練頂埔於2018年1月8日至2019年12月9日進站人數折線圖




圖 125、一日集成式學習模型訓練頂埔站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

一日集成式模型測試頂埔於2018年1月8日至2019年12月9日進站人數折線圖




圖 126、一日集成式學習模型測試頂埔站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖




圖 127、HRNN 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖




圖 128、HRNN 模型訓練丹鳳站於 2018 年至 2019 年進站人數預測折線圖




圖 129、HRNN 模型訓練頂埔站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練頭前庄站於2018年至2019年進站人數預測折線圖




圖 130、GRU 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練丹鳳站於2018年至2019年進站人數預測折線圖




圖 131、GRU 模型訓練 GRU 站於 2018 年至 2019 年進站人數預測折線圖

GRU模型訓練頂埔站於2018年至2019年進站人數預測折線圖




圖 132、GRU 模型訓練頂埔站於 2018 年至 2019 年進站人數預測折線圖

DRNN模型訓練頭前庄站於2018年至2019年進站人數預測折線圖




圖 133、DRNN 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖

DRNN模型訓練丹鳳站於2018年至2019年進站人數預測折線圖




圖 134、DRNN 模型訓練 GRU 站於 2018 年至 2019 年進站人數預測折線圖

DRNN模型訓練頂埔站於2018年至2019年進站人數預測折線圖




圖 135、DRNN 模型訓練頂埔站於 2018 年至 2019 年進站人數預測折線圖

Simple RNN模型訓練頭前庄站於2018年至2019年進站人數預測折線圖




圖 136、SimRNN 模型訓練頭前庄站於 2018 年至 2019 年進站人數預測折線圖

Simple RNN模型訓練丹鳳站於2018年至2019年進站人數預測折線圖




圖 137、SimRNN 模型訓練 GRU 站於 2018 年至 2019 年進站人數預測折線圖

Simple RNN模型訓練頂埔站於2018年至2019年進站人數預測折線圖




圖 138、SimRNN 模型訓練頂埔站於 2018 年至 2019 年進站人數預測折線圖




圖 139、頭前庄站 HRNN 模型預測頂埔站
於 2018 年至 2019 年進站人數預測折線圖




圖 140、丹鳳站 HRNN 模型預測頂埔站於 2018 年至 2019 年進站人數預測折線圖




圖 141、頂埔站 HRNN 模型預測頂埔站於 2018 年至 2019 年進站人數預測折線圖




圖 142、頭前庄站 GRU 模型預測頂埔站於 2018 年至 2019 年進站人數預測折線圖




圖 143、丹鳳站 GRU 模型預測頂埔站於 2018 年至 2019 年進站人數預測折線圖




圖 144、頂埔站 GRU 模型預測頂埔站於 2018 年至 2019 年進站人數預測折線圖

頭前庄站DRNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 145、頭前庄站 DRNN 模型預測頂埔站

於 2018 年至 2019 年進站人數預測折線圖

丹鳳站DRNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 146、丹鳳站 DRNN 模型預測頂埔站於 2018 年至 2019 年進站人數預測折線圖

頂埔站DRNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 147、頂埔站 DRNN 模型預測頂埔站於 2018 年至 2019 年進站人數預測折線圖

頭前庄站Simple RNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 148、頭前庄站 SimRNN 模型預測頂埔站

於 2018 年至 2019 年進站人數預測折線圖

丹鳳站Simple RNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 149、丹鳳站 SimRNN 模型預測頂埔站

於 2018 年至 2019 年進站人數預測折線圖

頂埔站Simple RNN模型預測頂埔站2018年至2019年進站人數折線圖




圖 150、頂埔站 SimRNN 模型預測頂埔站

於 2018 年至 2019 年進站人數預測折線圖

三日集成式模型訓練頂埔於2018年1月8日至2019年12月9日進站人數折線圖




圖 151、三日集成式學習模型訓練頂埔站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖

三日集成式模型測試頂埔於2018年1月8日至2019年12月9日進站人數折線圖




圖 152、三日集成式學習模型測試頂埔站

2018 年 1 月 8 日至 2019 年 12 月 9 日進站人數折線圖