

2020/02/25

國立雲林科技大學研究生學位論文電子檔上傳同意書

National Yunlin University of Science and Technology Agreement on Uploading E-file of the Thesis

工業工程與管理系 研究所 _____ 組研究生 賴紫平 (請簽章)

論文已完成口試委員修改建議，並經系所辦查對以下事項無誤，請同意論

文上傳學校圖書館。

■ 查對事項：

☒ 中文論文名稱(研究生自填)：

使用深度學習模型結合二維高斯函數探討交通站點之用量與成因

☒ 英文論文名稱(研究生自填)：

Using Deep Learning Models with 2D-RBF Functions to Predict and Explore the Factors of Usage of Public Transportations

☒ 中文論文名稱與學位論文考試委員會審定書之名稱一致。

☒ 中、英文論文名稱與教務資訊系統/歷年成績之名稱一致。

☒ 中、英文論文名稱與學位論文 PDF 檔封面之名稱一致。

查對人(系所辦助理)： 組員陳應心 (請簽章)

謹陳

論文指導教授： 陳垂中 (請簽章)

備註：

論文上傳前，請掃描成電子檔併於學位論文 PDF 檔第一頁(封面的前一頁)。

請勿裝訂於紙本學位論文內。

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

使用深度學習模型結合二維高斯函數

探討交通站點之用量與成因

Using Deep Learning Models

with 2D-RBF Functions to Predict and Explore
the Factors of Usage of Public Transportations

賴紫平

Tzu-Ping Lai

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D.

中華民國 109 年 6 月

June 2020

國立雲林科技大學
碩士班學位論文考試委員會審定書

本論文係賴紫平君在本校 工業工程與管理系所提論文「使用深度學習模型結合二維高斯函數探討交通站點之用量與成因」合於碩士資格水準，業經本委員會評審認可，特此證明。

口試委員：

陳奕中

陳奕中

侯東旭

侯東旭

許煜亮

許煜亮

指導教授：

陳奕中

陳奕中

所 長：

許煜亮

中 華 民 國 109 年 7 月 17 日

摘要


時空大數據分析為目前最熱門的研究議題之一，因時空資料同時具有空間與時間的特性，可以讓使用者了解隨著時間的推進，資料集中各空間數值的變化。然而過往研究大多以單一面向進行研究，並未考慮時空整合的問題以及模型運行成本，也無法解釋各因子的影響性以及合理解釋，因此本研究提出一個新的組合式類神經網路—2D-RBF-CNN-LSTM (2DRCL)可有效的擷取時空資料的特徵，並利用模型所學習到的因子進行成因探討，模型包含了(1)透過二維 RBF 函數對於圖片中的各個網格空間特徵進行升維，(2)利用 CNN 模型對於升維後的圖片萃取有用空間的特徵，學習圖片中對於時間序列重要的特徵因子，(3)使用 LSTM 對於 CNN 所萃取到的空間特徵資訊進行時間序列預測，(4)將模型訓練後，取出二維 RBF 層中的權重值，探討哪些空間因子為時間序列的重要特徵，並將這些特徵應用在低成本的機器學模型進行預測。最終，本論文以行動數據人流資料作為時空特徵因子，預測 YouBike 各站租借量以驗證我們所提出之方法的有效性。

關鍵字：交通流量預測、特徵工程、深度學習、時空資料庫分析

Abstract

Despite explosive growth in the field of big-data research, most previous studies on temporal variations in patterns related to geographic features (spatio-temporal data) have been unable to account for the influence of multiple factors. This study proposes a complex neural-network architecture capable of retrieving features from spatio-temporal data for use in elucidating the causes of observed phenomena. The proposed model includes 1) a two-dimensional RBF function to enhance the dimensionality of grid features in pictures; 2) a CNN model to extract important spatial features from those pictures; and 3) LSTM to identify temporal variations in the observed patterns. After training the model, the weight values are removed from the two-dimensional RBF layer in order to identify the spatial factors that are important elements in the time-series in order to facilitate the formulation of predictions. The effectiveness of the proposed method was verified by linking data from mobile devices with temporal variations in the rental of bicycles in specific geographic locations (e.g., rental stations and schools).

Keywords: Traffic flow Prediction, Feature Extraction, Deep Learning, Spatio-Temporal Database Analysis



誌謝

論文寫作期間，承蒙「107 年度中央研究院人文社會科學研究中心地理資訊科學研究專題中心碩士培育生計畫」獎助，特此致謝。



目錄

摘要	i
Abstract.....	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	4
1.3 研究範圍	5
第二章 文獻探討	6
2.1 公共自行車租借量預測方法	6
2.1.1 統計分析方法	6
2.1.2 機器學習方法	6
2.1.3 深度學習方法	7
2.1.4 過往自行車預測方法的比較	8
2.2 特徵工程	8
2.3 二維高斯函數(2D Radial Basis Function, 2D RBF).....	9
2.4 卷積類神經網路(Convolutional Neural Network, CNN)	9
2.5 長短期類神經網路(Long Short-Term Memory, LSTM).....	10
第三章 研究方法	12
3.1 資料清洗與網格化	12
3.2 2DRCL 運作流程.....	15
3.3 利用 2DRCL 取出 YouBike 預測關鍵特徵值	19
第四章 實驗模擬	21
4.1 資料集與實驗參數介紹	21
4.2 2DRCL 之 Threshold σ 選擇	22

4.3	演算法取出關鍵特徵值的量化與質化合理性說明	23
第五章	結論與未來研究	30
參考文獻		31



表目錄

表 1-1 各區較代表性站點	2
表 2-1 過往自行車預測常用方法比較	5
表 4-1 人流資料格式	18
表 4-2 各測站在不同 σ 的特徵值數量	19
表 4-3 本論文方法與其他方法所選取出來特徵值之數量比較	20
表 4-4 預測東湖站平日下午 5 點之 RMSE	20
表 4-5 預測東湖站平日早上 7 點之 RMSE	20
表 4-6 預測港墘站平日下午 6 點之 RMSE	20
表 4-7 預測港墘站平日早上 9 點之 RMSE	21
表 4-8 預測松山站平日下午 4 點之 RMSE	21
表 4-9 預測忠孝新生站平日下午 4 點之 RMSE	21
表 4-10 預測松山站假日下午 4 點之 RMSE	21
表 4-11 預測忠孝新生站假日下午 4 點之 RMSE	21
表 4-12 本論文方法在東湖站平日下午 5 點所挑選到的特徵值	22
表 4-13 本論文方法在東湖站平日早上 7 點所挑選到的特徵值	23
表 4-14 本論文方法在港墘站平日下午 6 點所挑選到的特徵值	23
表 4-15 本論文方法在港墘站平日早上 9 點所挑選到的特徵值	24
表 4-16 本論文方法在松山站平日下午 4 點所挑選到的特徵值	24
表 4-17 本論文方法在忠孝新生站平日下午 4 點所挑選到的特徵值	25
表 4-18 本論文方法在松山站假日下午 4 點所挑選到的特徵值	25
表 4-19 本論文方法在忠孝新生站假日下午 4 點所挑選到的特徵值	26

圖目錄

圖 1-1 市立中崙高中周圍地區	2
圖 1-2 2017 年 11 月中崙高站站的星期六自行車租借量統計	2
圖 1-3 2017 年 11 月中崙高站站的星期一自行車租借量統計	2
圖 2-1 卷積類神經網路架構圖[22]	9
圖 2-2 長短期類神經網路架構圖[28]	10
圖 3-1 研究流程圖	11
圖 3-2 東湖租借站涵蓋步行距離的人流網格	13
圖 3-3 依據範圍產生的相對位置網格圖片	13
圖 3-4 本論文所提出之 2DRCL 模型	14
圖 3-5 初始中心點位	14
圖 3-6 正中心點落在正中央 a	15
圖 3-7 正中心點落在正右邊 a	15
圖 3-8 卷積運算圖[36]	16
圖 3-9 池化運算圖[37]	16
圖 3-10 feature map 平坦過程[38]	16
圖 3-11 因子 1 之二維 RBF 訓練後的特徵圖	19
圖 3-12 因子 2 之二維 RBF 訓練後的特徵圖	19
圖 4-1 YouBike 站點位置	20
圖 4-2 特徵值網格對應實際地圖的相對位置代碼	25

第一章 緒論

1.1 研究背景與動機

交通資訊的預測為近年來廣泛研究的議題，許多研究利用電腦可不斷訓練及學習的特性對於車流量、人流量以及交通 OD 進行預測，並利用這些預測結果延伸至大眾運輸工具的車輛排班以及人員配置、路線規劃及租車站點設置等議題，而交通預測的準確性以及模型的運行成本，成為能否在實務應用的關鍵因素。例如，預測公共自行車的租借量，若模型準確度低，將會影響各站點的自行車的數量配置、人員無法對於自行車分配不均的站點進行調度以及調度人員配置的安排；當模型有高準確度，但運行成本過高，則會使模型無法反映即時的租借空間訊息或僅能對於特定地區的租借預測，因此，不論是哪個因素發生皆無法實務應用。

根據過往對交通預測的研究，學者大多僅使用其專業知識預設哪些因子或行為會影響目標資料的預測，再以時間序列模型建模或使用統計分析。這樣的方法會造成三個問題：(1)在做交通資訊議題時，交通數據資料皆會牽涉到時間與空間資料，而不僅僅是考慮時間或空間因素而已，然而許多研究僅針對與「時間」或「空間」相關的因子作為探討，並未考慮時空的整合性[1][2][3] (2)針對建模預測僅提出使用之方法以及預測結果，只單純把資料的所有因子輸入至模型或使用過往認為有用的交通因子輸入至模型進行預測，這樣的方法即使能得到一個高準確度的預測結果，卻無法從模型得知哪些因素才是提升模型準確度的重要因素或是過往研究尚未發現重要因子特徵。(3)將未經過篩選的因子直接輸入至模型中，使模型在訓練過程中消耗大量的運算成本，造成運算時間過長不符實務上的應用。以 YouBike 作為舉例說明，我們可以到圖 1-1 是市立中崙高中附近的地圖，以空間的角度進行觀察可發現中崙高中附近僅有一個 YouBike 租借站和公車站，因此可推斷這些交通工具的使用者大多來自周圍的上班族和學生，或來京華城的旅客，從時間的角度如圖 1-2 跟圖 1-3 得知周圍的學生騎乘 YouBike 比率及其空間分布，而圖 1-2 為 2017 年 11 月中崙高中站的騎乘自行車統計資料，該圖被框選的時

近年來深度學習模型為科學界中最受矚目的方法之一，大量的應用在各個領域，也包含了本論文所探討的交通預測。深度學習一般可以建立高精準度的模型並能從大量原始資料中找學習到較適合建模的特徵值。舉例來說，Wang *et al.*[4]預測中國蘇州的公共自行車租借量，並使用了三種模型分別是長短期記憶模型(Long Short Time Memory Network, LSTM)、門控遞歸單元(Gated recurrent unit, GRU)和隨機森林(Random Forest)，結果顯示 LSTM 模型之成果較其餘兩者好。Pan *et al.*[5]利用歷史自行車借用數據，並使用 LSTM 預測紐約市的共享自行車租借量，相較於其他統計預測模型的結果，LSTM 模型的均方根誤差(RMSE)較好。上述研究結果皆證實深度學習模型應用於交通資訊的預測確比傳統統計分析方法來的合適。

雖然深度學習模型應用在各大領域中皆被證實建模效果相較傳統統計分析方法預測準確度佳，但因其模型的缺點為高運行與建置成本，所以無法在許多實務問題上使用。因此自 2018 年開始，許多學者專注於如何在不降低太多分析準確度的狀況下降低深度學習模型的運行成本，目前方法大致上分為兩個方向，包含(1)刪減深度學習模型中無用的架構以降低運行成本。(2)從深度學習模型中擷取對分析有用的特徵值，利用新的特徵值去訓練低成本的機器學習模型並降低後續的運行成本。第一個方向，Han *et al.*[6]提出刪減深度學習模型中數值較小的神經權重來提升深度學習模型運行速度的方法。Li *et al.*[7]提出藉由刪去深度學習模型中總和權重較小的 Complete filters layer 來減少深度學習模型的層數，並因此加快深度學習模型運行速度的方法。第二個方向，若能將合適的特徵值放入傳統的機器學習模型中，則傳統機器學習模型應能獲得跟深度學習模型一樣好的效能。例如 Sani *et al.*[8]直接取出深度學習最後一個池化層與全連階層間的數值作為深度學習挑選出來對模型最有幫助的特徵值，再將這些特徵值輸入低成本的 K-近鄰演算法(k-Nearest Neighbor, KNN)方法來進行動作辨識，並驗證了這樣方法確實能以較低成本達到與深度學習模型相近的動作辨識率。Mohammad *et al.*[9]則是設計了新的公式來計算每個特徵值在深度學習模型中的重要程度，選取其中最重要者，再把這些重要的特徵值重新輸入深度模型中訓練，最終獲得了低成本，但與深度學習模型效能差不多且優於傳統分析方式的辨識率。換言之，若我們想探討地理資訊的成因，能透過訓練額外的深度學習模型來達成目的。

1.2 研究目的

欲解決上述提及的問題，本研究提出一個新的組合式類神經網路—2D-RBF-CNN-LSTM (2DRCL) 可有效的擷取交通資料中的時空特徵，並輸入至簡易的預測模型達到低成本的運算並維持一定的準確度。此方法以三個階段進行，(1)對外部空間時序資料遺漏值進行補值和將空間資訊進行網格化圖形切片、(2)在預測模型部分，本論文提出使用二維 Radial Basis Function (2D-RBF)結合 CNN-LSTM 進行預測、(3) 根據二維 RBF 層的權重結果篩選重要特徵並輸入簡易模型進行預測。步驟一，由於外部空間時序資料有遺漏值的問題，為避免後續建模的準確度以及成因分析的合理性，此外部空間資料是不能直接用於分析與建模，所以本研究以線性插值法將有遺漏的資料進行補值。網格化圖形切片的部分，以使用者設定的空間研究範圍進行網格空間的探討，將空間資料切成多張網格空間圖片，提供模型以圖片的方式對於外部空間時序資料進行學習。步驟二，使用二維 Radial Basis Function (2D-RBF)結合 CNN-LSTM 進行預測，該方法是在 CNN-LSTM 前串接一層以二維 RBF 為主體的神經元網路架構，而二維 RBF 在此類神經的主要功能為將第一步驟的網格空間圖片進行維度上升的動作，讓模型可以學到更多的空間特徵資訊，輸入至本研究設計的 CNN-LSTM 模型中，以 CNN 模型進行學習二維 RBF 升維後的多張空間資訊圖片，並將其結果輸入至 LSTM 模型中進行交通預測。步驟三，將訓練過後的模型，將模型進行拆解取出二維 RBF 層裡的權重值，該權重為二維 RBF 各圖片中的空間特徵資訊調整後的結果，並以使用者設定的二維 RBF 權重閾值找出模型訓練後各資料點的重要空間特徵，最後將篩選出來的重要特徵以低成本的機器學習模型來驗證我們提出方法的有效性。

藉由我們提出二維 RBF 函數結合 CNN-LSTM 模型，我們預期能達到三個目標。(1)此方法能夠將時間序列以空間型態方式呈現，已考慮整體狀態空間之時空因素，便能解決過往只考慮單一項目以及時空整合之問題。(2)透過閾值設定對二維 RBF 函數之權重能進行特徵篩選，因此我們能夠過濾掉對模型來說不重要之特徵，便能減少模型過多的計算成本。(3)我們會將篩選出來各個時間點的重要空間因子進行成因探討，並解釋各時空因子對交通預測的影響。

1.3 研究範圍

為了驗證我們提出方法的有效性，本論文使用了微笑單車股份有限公司所提供 2018 年 1 月至 6 月的 YouBike 各站租借量統計資料，資料集內容包括：日期、借車地點、借車時間、還車地點、還車時間、總租賃時間。臺北市 YouBike 之站點數總計共有 400 站，若以區域性質實行歸類，可將站點坐落處大致劃分為三種如表 1-1，分別為：學區、工作區以及商業購物區，其中各區較具代表性的站點依序為學區的東湖站；工作區的港墘站；商業購物區的忠孝新生、松山文創，本論文將會以這四個站點進行人流數據分析及預測。

表 1-1 各區較代表性站點

區域	站點
學區	東湖站
工作區	港墘站
商業購物區	忠孝新生、松山文創

第二章 文獻探討

本章節將列舉出與本研究相關的幾個重要研究，著重關注於過往借用量預測的幾個常見方向，包含了公共自行車租借量預測方法比較、特徵工程方式。

2.1 公共自行車租借量預測方法

2.1.1 統計分析方法

有別於傳統的專家模式，本方法應用在許多專業領域上具有更高的彈性，近年來成為學者們最常用來進行租借量預測的工具之一。一般來說，這類方法大多使用非線性模型完成，因為交通租借數值的變化已被多位學者證實為非線性變化，故線性模型並不適用於本議題上。舉例來說，Chen *et al.*[10]認為運輸網絡效率不足通常是由不確定性引起的，例如不確定資源的可用性(例如自行車共享系統中的停車場或自行車)或影響其需求的外在因素(例如天氣或一天中的時間)並使用了廣義加成模型(Generalized Additive Model, GAM)在預測準確性方面獲得可觀的收益。Zhou *et al.*[11]挑選了多種租借因子特徵值及歷史資料，並將這些特徵值輸入基於馬可夫鏈的混合模型中，並成功完成了中國中山市公共自行車租借量的預測。Froehlich *et al.*[12]使用貝葉斯網絡來預測巴塞隆納 Bicing 系統中自行車的短期和長期(提前 5 分鐘和 2 小時)。他們的預測模型結合了一天中的時間，當前可用的自行車和預測窗口，與最後的觀點和歷史趨勢算法相比，實驗結果顯示出顯著的改進。Yoon *et al.*[13]等人基於可用自行車數量的不穩定性，使用自迴歸綜合移動平均(Autoregressive Integrated Moving Average, ARIMA)時間序列模型來提高預測準確性。上述的統計分析方法都宣稱他們能成功的對租借量問題進行預測，然而我們必須了解到這類方法最大的問題是必須先挑選到合適預測的特徵值，其預測效果才會不錯。若同樣的模型輸入不合適預測的特徵值，其預測效果通常也不佳。

2.1.2 機器學習方法

機器學習方法自被開發出來以後，一直都是受學者們重用的模型之一。機器學習需以定義特徵的方式標記資料。該數據足以提供機器學習可理解的標籤進行

訓練，最後根據所學習到的特徵對這資料進行分類。例如：Patil *et al.*[14]將印度市區的公共自行車資料利用隨機森林(Random Forests)的方法進行預測，其結果均方根誤差(Root-Mean-Square Error, RMSE)比其他機器學習方法還來的好。Finseth *et al.*[15]使用隨機森林、梯度提升樹和具有較長短期記憶或門控循環單位的循環神經網絡以上四種機器學習方法評估奧斯陸自行車系統的租借需求，發現門控循環單位是最適合拿來預測的方法，從上述的研究我們可以看出機器學習方法確實能帶給自行車預測問題更佳的預測準確率，機器學習算法旨在通過了解標記的數據來進行學習，在資料面上需要透過人工對資料進行特徵工程將其轉換成可理解之數據標籤，調整資料結構使算法輸出成期望的實際輸出，在方法面上要找尋合適的分群演算法以解決特定問題，以上種種限制使得機器學習需要花費大量的時間成本處理原始資料，缺乏彈性及廣泛性無法用於解決一般問題。

2.1.3 深度學習方法

深度學習是機器學習的分支，是一種以人工智慧神經網路為架構，對資料進行特徵學習的演算法，深度學習網絡的主要優勢在於，不一定需要資料結構化/標籤化數據即可進行預測。神經網絡中的隱藏層通過不同概念的層次結構放置數據，利用損失函數計算與實際標籤的誤差，通過倒傳遞的方式學習誤差以優化網路，模擬人類大腦通過將查詢傳遞給相關問題的各層次結構進行學習。且自從該模型出現後，就受到各界學者們的青睞，並廣泛被應用於多個領域中。交通相關領域中，陸續有許多研究開始應用深度學習模型，並有良好的成效。例如 Xu *et al.*[16]考慮天氣因子、空氣品質、地區分布等因素，使用 LSTM 類神經網路預測中國南京城的 TAZ 共享自行車借用量，結果顯示與其他預測模型來的好。Pan *et al.*[5]根據歷史自行車借用數據、天氣數據和時間數據，使用 LSTM 類神經網路訓練與預測紐約市與澤西市的共享自行車借用量，預測模型的 RMSE 顯示結果較其他預測模型更好。Wang *et al.*[4]使用 LSTM、GRU、Random Forest 三種方法對中國蘇州的共享自行車借用量進行預測，其結果顯示，LSTM 類神經網路的績效較其他兩者演算法來的好。許多實驗證實了深度學習在自行車租借量的問題上確實比傳統方式更為準確。然而，模型的準確度依然仰賴於輸入資料的品質，在解決

租借預測的準確度上雖有不錯的成效，但其中所需要訓練的因子數量相當龐大，不僅耗費大量的時間與硬體成本，在特徵解釋上也更加困難。

2.1.4 過往自行車預測方法的比較

以下我們使用表 2-1 比較過往自行車預測常用的三大方向。這三種方法，都是屬於資料科學的一部分，故在使用這些方法進行分析時都需要大量的歷史數據為基礎才能進行。然而，也就是因為有這些歷史數據為依據，故這三個方法的預測精準率較高，尤以深度學習最高，因為其具有三者之中最複雜的模型。但相對的，因為深度學習模型最為複雜，所以對該模型內重要因子的解釋也最為困難。

表 2-1 過往自行車預測常用方法比較

模型需求	統計分析	機器學習	深度學習
歷史數據	V	V	V
預測精準度	低	中	高
重要因子解釋能力	高	中	低

2.2 特徵工程

在機器學習中，特徵工程是指為了建構模型而選擇相關之特徵子集的過程。有一句話在業界廣泛流傳，數據和特徵決定了機器學習的上限，而模型和算法只是接近這個上限而已。特徵工程的目的是在於最大限度地從原始數據中提取特徵以供算法和模型使用。許多學者證明有做特徵工程在模型預測上都有明顯的提升，舉例來說，Li *et al.*[17]提出了一種基於 S 變換非負矩陣分解和多目標進化算法的齒輪箱混合故障診斷的特徵提取與選擇方案，實驗結果表明，所提出的特徵提取和選擇方案被證明是一種用於變速箱混合故障診斷的有效工具。Pradeep *et al.*[18]引入了一種稱為對角線特徵提取的新方法，用於提取手寫字母的特徵，與採用傳統的水平 and 垂直特徵提取方法的系統相比，所提出的識別系統可以很好地產生較高的識別精度。Yu *et al.*[19]介紹了一種通過自動提取和選擇信息特徵來開發表型算法的方法。識別類風濕關節炎患者和類風濕關節炎患者，自動提取特徵模型與使用專家策劃的特徵訓練的模型相比，可以達到相當或略高的準確性。Xing *et al.*[20]利用 SDAE LR 方法進行特徵分析提取高光譜數據，相對於幾種流行的特徵提取，此模型提取的特徵提供了更好的分類精度方法。Bahadure *et al.*[21]使用了

伯克利小波(Berkeley Wavelet Transform, BWT)變換分割圖像和支持向量機(Support Vector Machine, SVM)通過分析特徵對腫瘤分期進行分類，比起放射科醫生或臨床醫生進行的手動檢測，所提出的方法可以幫助準確及時地發現腦腫瘤以及確定其確切位置。由上述文獻可以得出若找出合適的特徵工程方法，對模型的預測準確度確實都能提升。若同樣的對租借量進行合適的特徵提取方法，其預測效果理應不錯。

2.3 二維高斯函數(2D Radial Basis Function, 2D RBF)

所謂二維高斯函數又名 2D RBF，在圖片辨識上擁有將圖片平滑化(濾除雜訊)的功能，減少圖像雜訊以及降低細節層次。目前關於二維高斯函數的應用大多還是在影像方面，常用於濾除雜訊、低通等等，例如，Su *et al.*[22]利用 2D RBF 來增強圖像特徵的強度，結果顯示該方法可以取得較好的效果。Mirzapour *et al.*[23]設計一種基於二維高斯導數(GD)函數的濾波器，實驗結果證實了 GD 特徵在圖像分類中的出色表現。Hwang *et al.*[24]提出了一種新的特徵向量，該特徵向量是從兩種殘差特徵類型獲得的，這些殘差特徵是從空間中的高斯濾波中提取的圖像的頻域中的頻域和頻率變換殘差，結果表明高斯濾波取出的特徵表現較出色。Ye *et al.*[25]通過高斯函數小波變換提取表達子區域的表達特徵向量，實驗結果表明，基於高斯函數小波變換可以有效地提取表情特徵，對光照變化和個體差異不敏感。Zhang *et al.*[26]提出了一種改進的模糊邊緣檢測算法，並通過一種新的基於高斯函數的模糊算法，實驗結果表明，採用這種新算法不僅邊緣明顯，而且噪聲小。Fang *et al.*[27]提出了一種基於多特徵和模糊推理的方法，所提出的方法在保持性能方面表現良好。綜合上述可以得知，現今二維高斯函數已經被運用在各種圖片特徵擷取且都有得到很好的績效，不僅可以處理去除雜訊甚至可以處理特徵強化功能，因此也有許多人運用在特徵處理上。

2.4 卷積類神經網路(Convolutional Neural Network, CNN)

所謂卷積類神經網路又名 CNN，在圖片辨識上擁有相似於人類的辨識能力甚至更好，相較於一般的類神經網路辨識圖像，因其只能輸入一維資料的特





圖 2-1 卷積類神經網路架構圖[28]

性，而喪失原本空間形狀的重要資訊，由於卷積類神經多了卷積層和池化層兩層，讓卷積類神經不只是簡單的將資料進行運算還能保留空間上的資訊。

目前關於卷積類神經網路的應用大多還是在影像辨識方面，常用於影像辨識、特徵選取、音訊分類、文本分類等等，少部分會用在時間序列的分析，例如，Bardou *et al.*[29]應用卷積類神經網路對惡性乳腺組織進行分割並判斷其是否為乳腺癌，Lawrence *et al.*[30]提出一種基於卷積類神經網路的混合模型來人臉識別，其中識別的項目包含表情，姿勢和面部細節的高度可變性，Shen *et al.*[31]提出了一系列基於卷積神經網路的新潛在語義模型，以學習用於搜索查詢和 Web 文檔的低維語義向量。Yao *et al.*[32]提出了一種基於卷積類神經網路的智能軸承故障診斷方法，大幅提升的故障嚴重性識別的準確度，Chen *et al.*[33]運用卷積類神經網路自動識別植物病害，透過識別植物葉片的疾病並取得其相關特徵以利後續辨識，Liu *et al.*[34]運用 CNN 模型推斷具有潛在特徵的租借輛變化。綜合上述可以得知，現今卷積類神經網路已經被運用在各種領域且都有得到很好的績效，不僅可以處理圖像資料甚至到文本內容都可以處理且由於其模型本身特徵提取功能，因此也有許多人運用在特徵處理上。

2.5 長短期類神經網路(Long Short-Term Memory, LSTM)

所謂長短期類神經網路又名 LSTM，是經過循環神經網路(Recurrent neural network, RNN)改良而來，主要是解決在 RNN 中，發生梯度消失的問題，導致長期記憶被短期記憶所隱蔽。



The repeating module in an LSTM contains four interacting layers.

圖 2-2 長短期類神經網路架構圖[35]

LSTM 是目前常見的其中一種時間序列預測模型，此種模型被廣泛使用在各種領域，如數理統計、經濟、天氣預報、控制系統等等。例如，Lipton *et al.*[36] 利用 LSTM 模型識別臨床測量的多元時間序列模式的能力。Sagheer *et al.*[37]運用 LSTM 模型對石油工業領域預測石油生產量，結果顯示 LSTM 相較於其他時序模型還來的好。Cao *et al.*[38]提出一種基於 LSTM 的混合模型來提高股市價格預測的準確性。Graves *et al.*[39] 研究雙向 LSTM 模型用於語音識別，準確度明顯提高。Gensler *et al.*[40]應用 LSTM 模型於可再生能源發電廠的預測，顯示出優異的預測性能。綜合上述可以得知，現今長短期類神經網路已經被運用在各種領域且都有得到很好的績效，不僅是時序資料甚至到文本內容都可以處理。

第三章 研究方法

本論文提出二維 RBF 函數結合 CNN-LSTM 模型，簡稱 2DRCL，應用於 YouBike 租借量預測與影響其租借量之成因探討，將模型訓練分為兩個部分，分別為 Offline 與 Online，如圖 3-1 所示。Offline 分為三階段，包含(1)人流資料進行清洗與網格化，以線性插值法將資料中的遺漏值進行補值並將資料以網格的方式進行切片，整理成多張圖片輸出。(2)建立與訓練 2DRCL 模型，以輸出圖片中的網格各別建立二維 RBF 函數，用於提取圖片中網格之特徵並以圖片方式輸出，達到升維的效果，接著，將升維的圖片輸入至 CNN-LSTM 模型中，以 CNN 模型學習人流分佈的空間資訊結果，並將其結果輸入至 LSTM 模型中預測 YouBike 租借量。(3) 取出模型訓練過後的二維 RBF 層之權重並以標準差作為閾值設定，探討影響 YouBike 租借量重要的時空特徵。在 Online 部分，將二維 RBF 函數提取的時空重要特徵，應用於各種機器學習的時間序列預測模型中，如隨機森林、決策樹等進行租借量預測。以下會介紹四個部分的詳細流程。

3.1 資料清洗與網格化

在人流資料觀察的過程中，我們發現資料有遺漏值的問題，其原因為各基地台於資料收集時會遇到偶發以及例行維修等事件，如維護停機、電源故障、




圖 3-1 研究流程圖

網路設備不穩以及基地台本身故障的問題，故造成收集到的資料出現遺漏值 Null 以及數值為 0 的紀錄。使資料集不能直接用於分析與建模，所以本研究以線性插值法將遺漏的資料進行補值，以便提升後續建模的準確度以及成因分析的合理性。依據遺漏值之時間範圍，線性插值法可分為兩種，(1)遺漏值範圍小於 24 小時以及(2)遺漏值範圍大於 24 小時。首先，遺漏值時間範圍小於 24 小時，我們會以遺漏範圍前後數值的數值來進行插值(Eq. (1))(Eq. (2))，此方式較能反映發生遺漏值之前後時間範圍的人流分佈情形。

$$x_n = x_{n-1} + n\Delta \quad (1)$$

$$\Delta = \frac{x_{g+1} - x_0}{g + 1} \quad (2)$$

其中 g 代表需要補值的範圍大小，而 n 代表要補值的第 n 筆資料。接著，若需要補值的時間範圍大於 24 小時，則我們則以遺漏值的前、後 24 小時的人數取平均進行補值。(Eq. (3))

$$x(t) = \frac{x_{t+24} + x_{t-24}}{2} \quad (3)$$

採用此作法的原因為需補值的時間範圍太大，造成資料很難反應當天人流分佈的情況，因此使用前一天與後一天的相同時段來模擬當天相同時段可能的人流狀況。將資料補值完後，接著將資料進行網格化切片，由於本研究所使用的人流資料集為某電信提供的行動裝置人流數據資料，為了保護使用者的個資，將以網格方式呈現人流分佈情形，每個網格為 500×500 公尺的範圍所涵蓋各年齡層之人數。而具本研究所知台北市人行平均意願步行距離為 700 公尺[41][42]，因此本研究以 YouBike 站點的半徑 700 公尺作為人流空間特徵之探討，若使用者與 YouBike 站點的步行距離過長，使用者則會選擇其他交通方式到達目的地。而本研究使用之資料集為每格 500×500 公尺之網格資料，故以 3×3 pixels 之圖片探




圖 3-2 東湖租借站涵蓋步行距離的人流網格




圖 3-3 依據範圍產生的相對位置網格圖片

討各網格對於該 YouBike 站點之影響，因此須將人流網格資料以 3×3 pixels 的網格大小進行切片作為圖片輸出，其圖片網格之中心點為 YouBike 的站點位置所在的網格，如圖 3-2 所示，東湖租借站半徑 700 公尺內的人流網格，我們可以利用此空間圖片探討哪個人流網格對於東湖租借站點會影響 YouBike 的租借量，並以圖 3-3 之方式呈現，其中網格顏色會依人流的數量而有深淺的變化。




圖 3-4 本論文所提出之 2DRCL 模型

3.2 2DRCL 運作流程

本論文所使用的 2DRCL 模型如圖 3-4 所示，包含了輸入層、二維 RBF 層、卷積層、池化層，Recurrent 層，以及多層全連接層，其中 Recurrent 層與全連接層為一個完整的 LSTM 模型。

首先，輸入層並不做任何運算，僅是把我們切片之圖片矩陣傳入模型中。假設針對目標自行車預測區域，我們總共使用了此區域的 n 種因子資料，則我們的模型預計會有 n 個輸入。

接著，二維 RBF 層的功能是把模型的每個邊長大小為 m 輸入轉換成 m^2 個新特徵值，則本層會有 $n \cdot m^2$ 個神經元，每個神經元內包含一個二維 RBF 函數，並可被寫為(Eq. (4))

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2} \quad (4)$$

$$\begin{bmatrix} (-1, -1) & (0, -1) & (1, -1) \\ (-1, 0) & (0, 0) & (1, 0) \\ (-1, 1) & (0, 1) & (1, 1) \end{bmatrix}$$

圖 3-5 初始中心點位




圖 3-6 正中心點落在正中央 a




圖 3-7 正中心點落在正右邊 a

其中 x 與 y 代表二維 RBF 產生初始中心點位的絕對位置，如圖 3-5 所示，中心點會走訪每一個網格，而 σ 則是這個神經元中二維 RBF 的標準差。產生出來的二維 RBF 會對應每個輸入的矩陣做相乘。二維 RBF 的 σ 在與 CNN-LSTM 一起訓練後，將能標記每個特徵對 YouBike 租借量預測來說重要資料點的分佈位置。舉例來說，一個 YouBike 租借量預測問題共收集了 1 種空間人流資料 a ，且已知租借量變化會隨著不同網格地點之 a 資料數值成指數成長。假設使用圖 3-4 的模型來對這個問題進行訓練與建模，其中 a 資料使用九個二維 RBF 來描述其對預測有幫助的空間數值範圍，則訓練後的其中兩個二維 RBF 範圍如圖 3-6、圖 3-7 所示，其中圖 3-6 為中心點在正中央之二維 RBF， σ 會隨著 a 資料變小而讓二維 RBF 的寬度也隨之變窄，因此，便能代表 YouBike 租借量在正中央網格之 a 資料增加時，會有數值越大變化量越大的狀況。至於圖 3-7 中心點落在正右邊之二維 RBF，由於 σ 數值較大，會讓二維 RBF 的形狀變得非常扁平，變化量越小。在這個情況下，本論文會設定 Threshold σ ， a 資料一被輸入二維 RBF 後，僅有 a 資料數值小於設定 Threshold σ 的狀況下，會影響 CNN-LSTM 的輸出。

卷積層會接受來自二維 RBF 層的數值並與特定的 Feature Detector (Filter) 做卷積運算，如下圖 3-8 為例，框起來的 input image 跟 Feature Detector 相乘，每一個對應位置相乘後再相加就會得到一個數值，即是輸出 feature map 的值。中間的 Feature Detector (Filter) 會隨機產生好幾種組，Feature Detector 的目的就是幫助我們萃取出圖片當中的一些特徵(ex:形狀、邊緣)，就像人的大腦在判斷這個圖片是什麼東西也是根據形狀來推測，最後使用 Relu 函數去掉負值，使卷積層更能淬煉出物體的形狀。




圖 3-8 卷積運算圖[43]



圖 3-9 池化運算圖[44]




圖 3-10 feature map 平坦過程[45]

池化層會接收來自卷積層萃取出來的 feature map，並採用 Average Pooling 這個方法，Average Pooling 的概念是全局平均池化，如圖 3-9。它的好處是當圖片整個平移幾個 Pixel 的話對判斷上完全不會造成影響，以及有很好的抗雜訊功能。

CNN 跟 LSTM 模型連接的橋樑的平坦層，其中層數是依據前一層 feature map 平坦化後的數量而定的。如下圖 3-10，假設前一層輸出的 feature map 為 3×3 矩陣，則平坦化過後會變成 1×9 ，那全連接層的神經元顆數就為 9。

遞迴層會接受來自平坦層的數值，並探討前一個時間點遞迴層的輸出對現在時間點遞迴層輸出的影響。此層的神經元個數則以前一層神經元數目 α 為基準，且每個神經元彼此間為全連接的狀況，公式為：

$$U_t = I^t \times w_i^t + bias_i \quad (5)$$

$$S^t = h_i^t \times kw_i^t \quad (6)$$

$$h_i^t = O_i^{t-1} \quad (7)$$

$$O_i^t = act(U^t + S^t) \quad (8)$$

其中 U^t 代表的是第 t 時間點的輸入項方程式，為當前輸入 I^t 乘上對應的權重值 w^t 並加上對應偏壓值 $bias_i$ ，而 S^t 則為前一個時間點的輸出 h_i^t (即 $h_i^t = O_i^{t-1}$) 乘上其對應的遞迴權重值 kw_i^t ，最終將這兩項加總並輸入激活函數(Relu)中則可獲得當前時間點的輸出 O_i^t 。

接著為遞迴層，此處跟一般的時間序列預測模型(RNN)不同之處在於 LSTM 的遞迴層額外考慮了輸入閘、遺忘閘、記憶細胞向量、輸出閘、隱藏狀態向量等五個元素。

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \quad (9)$$

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \quad (10)$$

$$c_t = f_t \circ c_{t-1} + i_t \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (11)$$

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o) \quad (12)$$

$$h_t = o_t \circ c_t \tanh(c_t) \quad (13)$$

其中上述式子中的 W_{xi} 、 W_{hi} 、 W_{ci} 、 W_{xf} 、 W_{hf} 、 W_{cf} 、 W_{xc} 、 W_{hc} 、 W_{xo} 、 W_{ho} 、 W_{co} 、 b_i 、 b_f 、 b_c 、 b_o 皆為權重值，會由類神經網路訓練後求得最佳解。

LSTM 的最後為全連接層。在這層中，每個神經元都會整合來自前一層所有神經元的輸出，並將整合結果經過激活函數計算後輸出，而每一層第 i 個神經元的公式則可寫為(Eq. (14))

$$o_j = act(i_j \times w_{ij}) + b_j \quad (14)$$

其中 i_j 代表前一層神經元的輸出， act 為 $tanh$ 的激活函數， w_{ij} 為前一層輸出對應的權重值， b_j 則是對應第 j 個神經元的偏壓值。

3.3 利用 2DRCL 取出 YouBike 預測關鍵特徵值

這個小節描述我們如何從訓練好的 2DRCL 中判定哪些因子是 YouBike 預測的關鍵特徵值，共包含兩個步驟。(1)辨識每個二維 RBF 是否認定他們描述的因子 X 中擁有對預測有用的資料，以及(2)重複執行前一步驟數次，以確保能獲得最重要的特徵值，現介紹兩步驟細節如下。

在第一步中，如同我們前一節所提到的，2DRCL 在訓練時能藉由調整二維 RBF 的 σ ，來標記輸入維度的關鍵資料分佈位置。假設一個具有 n 個時間點的空間因子 $X = [x_1, x_2, \dots, x_n]$ 在依序輸入二維 RBF 後，會產生轉換後的圖片矩陣 $X' = [RBF(x_1), RBF(x_2), \dots, RBF(x_n)]$ 。其中若某時間點 i 的網格數值 $RBF(x_i)$ 接近於 0，代表二維 RBF 認為 x_i 對 CNN-LSTM 預測來說是有幫助的。反之若 $RBF(x_i)$ 接近於 1，則代表 x_i 對預測來說是有沒有幫助的。接著我們會計算 X' 的標準差 $\sigma(X')$ ，並定一個 Threshold σ 來判斷這個二維 RBF 是否認定 X 中具有對預測有用的資料。以圖 3-11、圖 3-12 為例，我們將一個 3×3 網格圖片因子輸入至二維 RBF 層中，每個網格會對應一個二維 RBF 函數，經過訓練後，我們可得到 9 張二維 RBF 的權重特徵圖。在訓練完模型後，將各權重特徵圖給予 Threshold σ 判斷，篩選出重要空間特徵。我們可以看到因子 1 與因子 2 在 t 時間點經過訓練後，取出的二維 RBF 權重特徵圖，其權重為標準差數值，而標準差會落在 0 至 1 之間，標準差越大表示空間因子的常態分佈較為發散，該網格對於租借量影響較小，在權重特徵圖中網格會以藍色呈現；標準差的數值越小表示常態分佈越集中，該網格對租借量的影響越大，在權重特徵網格會以紅色呈現。




圖 3-11 因子 1 之二維 RBF 訓練後的特徵圖




圖 3-12 因子 2 之二維 RBF 訓練後的特徵圖

我們可以看到因子 1 的第五張跟第六張地區網格圖片較接近紅色，表示該網格為重要空間資訊，其餘的地區網格顏色為藍色，對模型而言為過多雜訊且為不重要之空間特徵。以因子 1 的九個轉換後權重特徵圖輸入至後續 CNN-LSTM 中，較為紅色的網格，有助於模型學習空間特徵，反之，較為藍色的網格，則不會提升模型準確度，因此我們會將此網格視為雜訊，且不輸入至模型中。接著我們觀察第二個因子輸入以及其轉換後的權重特徵圖，九個轉換後的權重特徵圖，每一張圖片的顏色都沒有標準差數值較接近 0 的網格。在這個狀況下，可以得知此因子的 t 時間的所有地點均對模型的輸出沒有影響，所以模型的第二個因子對我們來說也是對建模沒有幫助的。

而根據上述的概念，我們發現一個輸入經過二維 RBF 函數轉換後的特徵值是否達到閾值會是一個判斷指標。因此我會以標準差為依據進行特徵值的選取。

一旦我們完成了上述挑選特徵值的步驟，我們即完成了圖 3-1 中第二階段到第三階段的動作，亦即從第二階段所用的特徵值中找到其中對建模最有用的數個特徵值。然而，我們必須了解到這樣一輪動作所選取出來的特徵值不一定會是最佳解，所以我們會重複第二階段多輪，接著在第三階段將取出的結果取平均去篩選其中對建模較無作用的特徵值，希望僅留下其中對建模來說最有用者。

第四章 實驗模擬

本章使用了真實的自行車資料集來驗證我們所提出方法的有效性。內容分成四個部分，包含資料集與實驗參數介紹、Threshold σ 之選擇，以及關鍵特徵值的質化與量化合理性說明。所有實驗則是以 Python 完成，並操作在 Intel Core I7-8700K at 3.70GHz 的 CPU、Nvidia GTX 1080ti 的 GPU、搭配 64GB 記憶體以及 Windows 10 的作業軟體來完成。

4.1 資料集與實驗參數介紹

本研究使用微笑單車股份有限公司所提供 2018 年 1 月 1 日 00 時 00 分 00 秒至 6 月 30 日 23 時 00 分 00 秒台灣台北四百個 YouBike 租借站點之每小時數值，與 2018 年每日每小時人流資料。其中 YouBike 站點位置如圖 4-1 所示。而對於每個站點，我們有每小時的人流資料來做為租借量預測的歷史資料集，而本研究所使用的人流資料集為某電信提供的行動裝置人流數據資料，為了保護使用者的個資，將以網格方式呈現人流分佈情形，每個網格為 500×500 公尺的範圍所涵蓋各項變數，每筆資料共 9 個欄位，如表 4-1 所示。




圖 4-1 YouBike 站點位置

表 4-1 人流資料格式

因子 1	因子 2	因子 3	因子 4	因子 5	因子 6	因子 7	Gird500	TIME
7	44	127	125	202	295	615	121.295_24.880	20180103120000.0
6	238	422	382	321	132	1501	121.210_24.885	20180103120000.0
11	96	286	232	171	145	941	121.150_24.965	20180103120000.0

本論文所採用的人流因子為各年齡層、總人數，總共 7 個因子(因簽署保密協定，所以我們無法說明因子的詳細意義)。而本論文要分析的預測問題是將過去 3 小時的 7 種人流資料，來預測未來 1 小時各站點的租借量數值。在本研究中，我們目標的租借量預測對象則是以區域做劃分，分別位於學區、工作區以及商業購物區，其中各區較具代表性的站點依序為學區的東湖站；工作區的港墘站；商業購物區的忠孝新生、松山文創站。本論文的演算法則是希望從 7 種人流資料中取出這個預測問題的關鍵特徵值，並驗證這些特徵值不管放入哪些模型都能協助這些模型提昇預測準確率與降低成本。

本論文演算法之各項參數設定如下。第一，在 2DRCL 模型參數方面，他會被輸入 21 個因子資料(每小時 7 個因子資料×過去 3 小時)，而每個因子資料會用 9 個二維 RBF 神經元來描述，因此 2DRCL 的二維 RBF 層會有 $21 \times 9 = 189$ 個神經元。而後的兩層 CNN 卷積層神經元個數為 126, 252，最後 LSTM 中遞迴層與全連接層神經元個數則為 128, 32, 8, 1。第二，Threshold σ ，我們會分別測試他在 0.3、0.35、0.4、0.45、0.5 時的結果。並對不同測站分別挑選表現最佳者來當做後續實驗的設定。要有小於標準差門檻的二維 RBF 函數認為這個輸入是對建模有幫助的，這個輸入才會被我們取出。最後為了驗證本論文方法的有效性，每個實驗皆會模擬 15 次，並使用了 Root Mean Squared Error (RMSE) 來檢視模型於資料集最後 15% 的預測結果。

4.2 2DRCL 之 Threshold σ 選擇

本小節透過實驗選擇合適的 Threshold σ ，我們共測試了五組數值 0.3、0.35、0.4、0.45、0.5，其結果列於表 4-2 中，每個測站在不同 σ 的特徵值數量。並將每

一個閾值挑選出來的特徵值分別進行實驗模擬，依據每個實驗的績效評估最終選出 0.35 這個閾值所挑選出來的特徵值。

表 4-2 各測站在不同 σ 的特徵值數量

σ	東湖站	東湖站	港墘站	港墘站
	平日下午 5 點	平日早上 7 點	平日下午 6 點	平日早上 9 點
	# of Features	# of Features	# of Features	# of Features
0.3	7	3	2	1
0.35	19	14	14	10
0.4	36	33	49	44
0.45	84	63	91	95
0.5	131	113	124	134

σ	松山站	忠孝新生站	松山站	忠孝新生站
	平日下午 4 點	平日下午 4 點	假日下午 4 點	假日下午 4 點
	# of Features	# of Features	# of Features	# of Features
0.3	3	4	1	6
0.35	16	18	11	16
0.4	57	47	17	21
0.45	105	102	66	59
0.5	146	142	126	122

4.3 演算法取出關鍵特徵值的量化與質化合理性說明

本小節使用量化與質化的觀點來討論我們所取出之特徵值是否為目標租借站預測用的關鍵特徵值。

量化部分的驗證：本論文特徵值選取方法比較的對象包含三種，(1)直接使用原始的人流資料時間序列來當做特徵值(ALL)，以及(2)所有特徵值去除掉本論文所選取到的特徵值(ALL-KEY)。至於這些特徵值搭配的模型則包含了決策樹、隨機森林以及 LSTM 模型。實驗結果則如表 4-3 到表 4-11 所示，其中表 4-3 是不同方法取出之特徵值數目的結果，表 4-4 到表 4-11 則為每種方法選取出的特徵值套用在不同模型中的結果。首先觀察表 4-3 中的特徵值數量，我們可看到本論文方法所取出的特徵值數量是所有方法中最少的，而這點也證實本論文方法的確有從大量的特徵值中選取出少數特徵值的能力。接著在表 4-4 到表 4-11 中，我們首先比較本論文方法與 ALL、ALL-KEY 這幾個方法所選取出來特徵值套用在不同模型上的結果。明顯這三個方法相對應的建模 RMSE 都比我們的方法差。這是因為

這三個方法除了預測用的關鍵特徵值外還包含了不少對預測沒有幫助的特徵值，會影響模型建模的準確度，並造成 RMSE 升高。而這點可在 ALL-KEY 的實驗中進一步獲得證實。該方法所有的特徵值都是我們演算法認定對預測沒有幫助者，所以其預測準確度甚至會比 ALL 方法還差。

表 4-3 本論文方法與其他方法所選取出來特徵值之數量比較

地點	ALL	ALL-KEY	Proposed Method
東湖站平日下午 5 點	189	170	19
東湖站平日早上 7 點	189	175	14
港墘站平日下午 6 點	189	175	14
港墘站平日早上 9 點	189	179	10
松山站平日下午 4 點	189	173	16
忠孝新生站平日下午 4 點	189	171	18
松山站假日下午 4 點	189	178	11
忠孝新生站假日下午 4 點	189	173	16

表 4-4 預測東湖站平日下午 5 點之 RMSE

方法	ALL	ALL-KEY	Proposed Method
Random Forest	8.21	8.33	8.14
Decision Tree	9.79	10.05	9.70
LSTM	9.89	10.48	8.82

表 4-5 預測東湖站平日早上 7 點之 RMSE

方法	ALL	ALL-KEY	Proposed Method
Random Forest	3.50	3.51	3.43
Decision Tree	4.32	4.53	3.82
LSTM	4.29	4.35	3.81

表 4-6 預測港墘站平日下午 6 點之 RMSE

方法	ALL	ALL-KEY	Proposed Method
Random Forest	8.42	8.92	8.05
Decision Tree	9.05	13.04	7.77
LSTM	10.98	11.02	10.46

表 4-7 預測港墘站平日早上 9 點之 RMSE

方法	ALL	ALL-KEY	Proposed
----	-----	---------	----------

			Method
Random Forest	9.17	9.40	9.01
Decision Tree	12.64	12.78	11.02
LSTM	12.31	14.81	11.04

表 4-8 預測松山站平日下午 4 點之 RMSE

方法	ALL	ALL-KEY	Proposed Method
Random Forest	7.94	8.26	7.84
Decision Tree	10.71	10.73	9.38
LSTM	8.84	9.60	8.16

表 4-9 預測忠孝新生站平日下午 4 點之 RMSE

方法	ALL	ALL-KEY	Proposed Method
Random Forest	3.35	3.63	3.33
Decision Tree	4.44	5.53	3.78
LSTM	4.68	5.61	4.01

表 4-10 預測松山站假日下午 4 點之 RMSE

方法	ALL	ALL-KEY	Proposed Method
Random Forest	7.39	7.35	7.03
Decision Tree	12.03	16.47	11.47
LSTM	6.82	9.38	5.73

表 4-11 預測忠孝新生站假日下午 4 點之 RMSE

方法	ALL	ALL-KEY	Proposed Method
Random Forest	3.70	4.16	3.36
Decision Tree	9.00	11.10	8.64
LSTM	11.04	11.79	5.10



質化部分的驗證：本論文在每個站點所挑出的特徵值如表 4-12 到表 4-19 所示，以下分別討論十個測站在不同時間下所取出特徵值的合理性。表中 t_1 代表此因子在第一個時間點的數值， t_2 代表此因子在第二個時間點的數值，以此類推。特徵值所對應的代碼之相對位置為下圖 4-2 所示。

p1	p2	p3
p4	p5	p6
p7	p8	p9

圖 4-2 特徵值網格對應實際地圖的相對位置代碼

依據不同時間點，我們方法在東湖站平日下午 5 點之前第一、第二和第三個時間點取出 20 個不同年齡層因子在不同地點的特徵值，如表 4-12 所示。這點十分合理，下午 5 點為高中和大學的放學時間，其中可以看到 p7 的位置為南湖高中、p2 的位置為康寧大學和 p8 為本身 YouBike 所在位置都有明顯的影響量，而 p9 的位置為高速公路所以在此都沒有顯著的特徵。



表 4-12 本論文方法在東湖站平日下午 5 點所挑選到的特徵值

時間點	因子
t_1	因子 1_p5、因子 1_p7、因子 2_p6、因子 4_p6、因子 5_p8、因子 5_p7、因子 7_p2 
t_2	因子 1_p8、因子 1_p2、因子 3_p3、因子 5_p2、因子 5_p3、因子 6_p6 
t_3	因子 2_p2、因子 3_p2、因子 5_p8、因子 6_p8、因子 6_p6、因子 7_p2 

東湖站平日早上 7 點之前第一、第二和第三個時間點取出 14 個不同年齡層在不同地點的特徵值，如表 4-13 所示。其中可以看到 p2、p3、p5 的位置為較多的住宅區、p8 為本身 YouBike 所在位置都有明顯的影響量，一樣 p9 的位置為高速公路所以在此都沒有顯著的特徵。




表 4-13 本論文方法在東湖站平日早上 7 點所挑選到的特徵值

時間點	因子
t_1	因子 5_p8、因子 5_p2、因子 6_p7 
t_2	因子 2_p9、因子 2_p7、因子 3_p5、因子 3_p8、因子 4_p8、因子 6_p2

	
t_3	因子 1_p8、因子 2_p8、因子 4_p2、因子 6_p3、因子 7_p2 




港墘站平日下午 6 點之前第一、第二和第三個時間點取出 14 個不同年齡層在不同地點的特徵值，如表 4-14 所示。其中可以看到 p2、p3、p5 的位置都有學校、p4、p5、p7、p8 為內湖科技園區，在下班放學時間都有明顯的影響量。

表 4-14 本論文方法在港墘站平日下午 6 點所挑選到的特徵值

時間點	因子
t_1	因子 1_p5、因子 1_p7、因子 2_p2、因子 5_p6、因子 6_p2 
t_2	因子 5_p6、因子 7_p1、因子 7_p3 
t_3	因子 1_p2、因子 3_p9、因子 5_p6、因子 6_p4、因子 7_p6、因子 7_p3 

港墘站平日早上 9 點之前第一、第二和第三個時間點取出 10 個不同年齡層在不同地點的特徵值，如表 4-15 所示。其中可以看到 p3、p1 的位置為住宅區，大部分的人要去上班上課，因此有明顯的影響量。



表 4-15 本論文方法在港墘站平日早上 9 點所挑選到的特徵值

時間點	因子
t_1	因子 1_p3、因子 5_p8、因子 6_p1 
t_2	因子 4_p3、因子 5_p8、因子 6_p6 
t_3	因子 1_p4、因子 3_p2、因子 4_p1、因子 6_p3 

松山站平日下午 4 點之前第一、第二和第三個時間點取出 16 個不同年齡層在



不同地點的特徵值，如表 4-16 所示。其中可以看到有明顯的影響量基本上落在 p1、p2、p3，原因是這些地區都為商業地點，有京華城等等。

表 4-16 本論文方法在松山站平日下午 4 點所挑選到的特徵值

時間點	因子
t_1	因子 1_p2、因子 4_p1、因子 5_p7 
t_2	因子 2_p1、因子 2_p3、因子 3_p5、因子 3_p7、因子 4_p1、因子 5_p2、因子 7_p1 
t_3	因子 1_p8、因子 3_p7、因子 5_p6、因子 6_p3、因子 7_p1、因子 7_p6 




忠孝新生站平日下午 4 點之前第一、第二和第三個時間點取出 18 個不同年齡層在不同地點的特徵值，如表 4-17 所示。其中可以看到 p2、p3、p8 的區域有明顯的影響量，原因是因為此處有大量的商業辦公大樓，則 p7 有大型廟宇、臺大醫院。

表 4-17 本論文方法在忠孝新生站平日下午 4 點所挑選到的特徵值

時間點	因子
t_1	因子 1_p2、因子 3_p1、因子 3_p2、因子 6_p6、因子 7_p8、因子 7_p3 
t_2	因子 1_p7、因子 1_p2、因子 3_p2、因子 4_p5、因子 5_p7、因子 7_p8、因子 7_p3 
t_3	因子 1_p1、因子 1_p8、因子 3_p2、因子 4_p8、因子 7_p8 




松山站假日下午 4 點之前第一、第二和第三個時間點取出 17 個不同年齡層在不同地點的特徵值，如表 4-18 所示。其中可以看到 p2、p4、p7、p9、p8 的位置有明顯的影響量，因為假日民眾會出來逛街，而這些地點都有商城。

表 4-18 本論文方法在松山站假日下午 4 點所挑選到的特徵值

時間點	因子
t_1	因子 3_p9、因子 4_p4、因子 5_p1、因子 5_p7、因子 5_p3、因子 7_p9 
t_2	因子 2_p6、因子 6_p9、因子 7_p2 
t_3	因子 1_p5、因子 1_p7、因子 3_p9、因子 4_p1、因子 4_p8、因子 5_p3、因子 7_p9、因子 7_p3 

忠孝新生站假日下午 4 點之前第一、第二和第三個時間點取出 21 個不同年齡層在不同地點的特徵值，如表 4-19 所示。由於忠孝新生假日的時候時常辦一些展覽跟活動，所以可以看到年輕族群在各個地點都有顯著的影響。

表 4-19 本論文方法在忠孝新生站假日下午 4 點所挑選到的特徵值

時間點	因子
t_1	因子 1_p5、因子 1_p9、因子 2_p9、因子 2_p3、因子 3_p9、因子 3_p8、因子 3_p7、因子 4_p7、因子 5_p5、因子 6_p8、因子 6_p6、因子 6_p3 
t_2	因子 1_p5、因子 1_p1、因子 3_p5、因子 3_p9 
t_3	因子 1_p9、因子 1_p1、因子 2_p9、因子 2_p7、因子 4_p6 

第五章 結論與未來研究

時空大數據分析為目前最熱門的研究議題之一。然而過往研究大多以單一面向進行研究，並未考慮時空整合的問題以及模型運行成本，也無法解釋各因子的影響性以及合理解釋，因此本研究提出的組合式類神經網路—2D-RBF-CNN-LSTM (2DRCL)可有效的擷取時空資料的特徵，並利用模型所學習到的因子進行成因探討，模型包含了(1)透過二維 RBF 函數對於圖片中的各個網格空間特徵進行升維，(2)利用 CNN 模型對於升維後的圖片萃取有用空間的特徵，學習圖片中對於時間序列重要的特徵因子，(3)使用 LSTM 對於 CNN 所萃取到的空間特徵資訊進行時間序列預測，(4)將模型訓練後，取出二維 RBF 層中的權重值，探討哪些空間因子為時間序列的重要特徵，並將這些特徵應用在低成本的機器學模型進行預測。

在實驗結果中，我們證明此方法能有效對於空間資訊取特徵值，並能應用於時空整合之預測且方法效能的確優於其他方法，能在不失去誤差為前提下，減少模型訓練所需特徵數量，而所設計的模型挑選出的特徵值也符合 YouBike 上的常理。

而在未來研究中，我們可以再針對其他縣市的 YouBike 站點進行相同實驗，找出 YouBike 站點彼此之間的影響，進一步推論影響各地區 YouBike 站點的因素，不僅是準確預測租借量，更是為了找出問題。最後此技術除了運用於 YouBike 領域，也能嘗試應用於其他交通人流資料的特徵擷取，像是捷運進出資料、火車上下車資料，相信都可以有相當不錯的表現。

參考文獻

- [1] 鄭雨桐. (2016). 建成環境對公共自行車使用之影響.
- [2] 呂千慈, 鍾易詩, & 馮正民. (2018). 環境空間與站點數對公共自行車租借量之影響分析. *運輸學刊*, 30(2), 113-137.
- [3] 余書玫, & 黃承傳. (2008). 公共自行車租借系統選擇行為之研究 (Doctoral dissertation).
- [4] Wang, B., & Kim, I. (2018). Short-term prediction for bike-sharing service using machine learning. *Transportation research procedia*, 34, 171-178.
- [5] Pan, Y., Zheng, R. C., Zhang, J., & Yao, X. (2019). Predicting bike sharing demand using recurrent neural networks. *Procedia computer science*, 147, 562-566.
- [6] Han, S., Mao, H., & Dally, W. J. (2015). Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding. *arXiv preprint arXiv:1510.00149*.
- [7] Li, H., Kadav, A., Durdanovic, I., Samet, H., & Graf, H. P. (2016). Pruning filters for efficient convnets. *arXiv preprint arXiv:1608.08710*.
- [8] Sani, S., Wiratunga, N., & Massie, S. (2017). Learning deep features for kNN-based human activity recognition.
- [9] Mohammad, Y., Matsumoto, K., & Hoashi, K. (2018, April). Deep feature learning and selection for activity recognition. In *Proceedings of the 33rd Annual ACM Symposium on Applied Computing* (pp. 930-939). ACM.
- [10] Chen, B., Pinelli, F., Sinn, M., Botea, A., & Calabrese, F. (2013, October). Uncertainty in urban mobility: Predicting waiting times for shared bicycles and parking lots. In *16th International IEEE Conference on Intelligent Transportation Systems (ITSC 2013)* (pp. 53-58). IEEE.
- [11] Zhou, Y., Wang, L., Zhong, R., & Tan, Y. (2018). A Markov Chain Based Demand Prediction Model for Stations in Bike Sharing Systems. *Mathematical Problems in Engineering*, 2018.
- [12] Froehlich, J., Neumann, J., & Oliver, N. (2008). Measuring the pulse of the city through shared bicycle programs. *Proc. of UrbanSense08*, 16-20.

- [13] Yoon, J. W., Pinelli, F., & Calabrese, F. (2012, July). Cityride: a predictive bike sharing journey advisor. In *2012 IEEE 13th International Conference on Mobile Data Management* (pp. 306-311). IEEE.
- [14] Patil, A., Musale, K., & Rao, B. P. (2015). Bike share demand prediction using RandomForests. *IJISSET Int. J. Innov. Sci. Eng. Technol*, 2.
- [15] Finseth, P., & Drevland, L. (2018). *Evaluating Machine Learning Methods for City Bike Demand Prediction in Oslo* (Master's thesis, NTNU).
- [16] Xu, C., Ji, J., & Liu, P. (2018). The station-free sharing bike demand forecasting with a deep learning approach and large-scale datasets. *Transportation research part C: emerging technologies*, 95, 47-60.
- [17] Li, B., Zhang, P. L., Tian, H., Mi, S. S., Liu, D. S., & Ren, G. Q. (2011). A new feature extraction and selection scheme for hybrid fault diagnosis of gearbox. *Expert Systems with Applications*, 38(8), 10000-10009.
- [18] Pradeep, J., Srinivasan, E., & Himavathi, S. (2014). An investigation on the performance of hybrid features for feed forward neural network based English handwritten character recognition system. *WSEAS Transactions on Signal Processing*, 10(1), 21-29.
- [19] Yu, S., Liao, K. P., Shaw, S. Y., Gainer, V. S., Churchill, S. E., Szolovits, P., ... & Cai, T. (2015). Toward high-throughput phenotyping: unbiased automated feature extraction and selection from knowledge sources. *Journal of the American Medical Informatics Association*, 22(5), 993-1000.
- [20] Xing, C., Ma, L., & Yang, X. (2016). Stacked denoise autoencoder based feature extraction and classification for hyperspectral images. *Journal of Sensors*, 2016.
- [21] Bahadure, N. B., Ray, A. K., & Thethi, H. P. (2017). Image analysis for MRI based brain tumor detection and feature extraction using biologically inspired BWT and SVM. *International journal of biomedical imaging*, 2017.
- [22] Su, R., Sun, C., Zhang, C., & Pham, T. D. (2014). A new method for linear feature and junction enhancement in 2D images based on morphological operation, oriented anisotropic Gaussian function and Hessian information. *Pattern Recognition*, 47(10), 3193-3208.

- [23] Mirzapour, F., & Ghassemian, H. (2016). Multiscale Gaussian derivative functions for hyperspectral image feature extraction. *IEEE Geoscience and Remote Sensing Letters*, 13(4), 525-529.
- [24] Hwang, J. J., & Rhee, K. H. (2016, November). Gaussian filtering detection based on features of residuals in image forensics. In *2016 IEEE RIVF International Conference on Computing & Communication Technologies, Research, Innovation, and Vision for the Future (RIVF)* (pp. 153-157). IEEE.
- [25] Ye, J., Zhan, Y., & Song, S. (2004, October). Facial expression features extraction based on gabor wavelet transformation. In *2004 IEEE International Conference on Systems, Man and Cybernetics (IEEE Cat. No. 04CH37583)* (Vol. 3, pp. 2215-2219). IEEE.
- [26] Zhang, J., Lian, Y., Dong, L., Zhao, X., & Liu, J. (2010, February). A new method of fuzzy edge detection based on Gauss function. In *2010 The 2nd International Conference on Computer and Automation Engineering (ICCAE)* (Vol. 4, pp. 559-562). IEEE.
- [27] Fang, L., Shi, W., & Chen, S. (2012). Fuzzy reasoningbased edge detection method using multiple features. *WSEAS TRANSACTIONS on COMPUTERS* E-ISSN, 2224-2872.
- [28] CH.Tseng.(<https://chtseng.wordpress.com/2017/09/12/%E5%88%9D%E6%8E%A2%E5%8D%B7%E7%A9%8D%E7%A5%9E%E7%B6%93%E7%B6%B2%E8%B7%AF/>)
- [29] Bardou, D., Zhang, K., & Ahmad, S. M. (2018). Classification of breast cancer based on histology images using convolutional neural networks. *IEEE Access*, 6, 24680-24693.
- [30] Lawrence, S., Giles, C. L., Tsoi, A. C., & Back, A. D. (1997). Face recognition: A convolutional neural-network approach. *IEEE transactions on neural networks*, 8(1), 98-113.
- [31] Shen, Y., He, X., Gao, J., Deng, L., & Mesnil, G. (2014, April). Learning semantic representations using convolutional neural networks for web search. In *Proceedings of the 23rd international conference on world wide web* (pp. 373-374).
- [32] Yao, D., Liu, H., Yang, J., & Li, X. (2020). A Lightweight Neural Network with Strong Robustness for Bearing Fault Diagnosis. *Measurement*, 107756.

- [33] Chen, J., Chen, J., Zhang, D., Sun, Y., & Nanekaran, Y. A. (2020). Using deep transfer learning for image-based plant disease identification. *Computers and Electronics in Agriculture*, 173, 105393.
- [34] Liu, C., Xu, Y., & Zhu, Y. (2019). ALCNN: Attention-based Model for Fine-grained Demand Inference of Dock-less Shared Bike in New Cities. *arXiv preprint arXiv:1909.11760*.
- [35] 從 零 開 始 : 如 何 使 用 LSTM 模 型 (<https://bigdatafinance.tw/index.php/tech/methodology/1421-lstm-2>)
- [36] Lipton, Z. C., Kale, D. C., Elkan, C., & Wetzel, R. (2015). Learning to diagnose with LSTM recurrent neural networks. *arXiv preprint arXiv:1511.03677*.
- [37] Sagheer, A., & Kotb, M. (2019). Time series forecasting of petroleum production using deep LSTM recurrent networks. *Neurocomputing*, 323, 203-213.
- [38] Cao, J., Li, Z., & Li, J. (2019). Financial time series forecasting model based on CEEMDAN and LSTM. *Physica A: Statistical Mechanics and its Applications*, 519, 127-139.
- [39] Graves, A., Jaitly, N., & Mohamed, A. R. (2013, December). Hybrid speech recognition with deep bidirectional LSTM. In 2013 IEEE workshop on automatic speech recognition and understanding (pp. 273-278). IEEE.
- [40] Gensler, A., Henze, J., Sick, B., & Raabe, N. (2016, October). Deep Learning for solar power forecasting—An approach using AutoEncoder and LSTM Neural Networks. In 2016 IEEE international conference on systems, man, and cybernetics (SMC) (pp. 002858-002865). IEEE.
- [41] 周依潔, 徐淵靜, & 邱裕鈞. (2007). 高齡者日常活動步道系統規劃 (Doctoral dissertation).
- [42] Yang, Y., & Diez-Roux, A. V. (2012). Walking distance by trip purpose and population subgroups. *American journal of preventive medicine*, 43(1), 11-19.
- [43] [資料分析&機器學習] 第 5.1 講: 卷積神經網絡介紹(Convolutional Neural Network)(<https://medium.com/jameslearningnote/%E8%B3%87%E6%96%99%E5%88%86%E6%9E%90-%E6%A9%9F%E5%99%A8%E5%AD%B8%E7%BF%92-%E7%AC%AC5-1%E8%AC%9B->

- %E5%8D%B7%E7%A9%8D%E7%A5%9E%E7%B6%93%E7%B6%B2%E7%B5%A1%E4%BB%8B%E7%B4%B9-convolutional-neural-network-4f8249d65d4f)
- [44] [資料分析&機器學習] 第 5.1 講: 卷積神經網絡介紹(Convolutional Neural Network)(<https://medium.com/jameslearningnote/%E8%B3%87%E6%96%99%E5%88%86%E6%9E%90-%E6%A9%9F%E5%99%A8%E5%AD%B8%E7%BF%92-%E7%AC%AC5-1%E8%AC%9B-%E5%8D%B7%E7%A9%8D%E7%A5%9E%E7%B6%93%E7%B6%B2%E7%B5%A1%E4%BB%8B%E7%B4%B9-convolutional-neural-network-4f8249d65d4f>)
- [45] [資料分析&機器學習] 第 5.1 講: 卷積神經網絡介紹(Convolutional Neural Network)(<https://medium.com/jameslearningnote/%E8%B3%87%E6%96%99%E5%88%86%E6%9E%90-%E6%A9%9F%E5%99%A8%E5%AD%B8%E7%BF%92-%E7%AC%AC5-1%E8%AC%9B-%E5%8D%B7%E7%A9%8D%E7%A5%9E%E7%B6%93%E7%B6%B2%E7%B5%A1%E4%BB%8B%E7%B4%B9-convolutional-neural-network-4f8249d65d4f>)

