

國立成功大學
資訊工程學系
碩士論文

以 CFRBF-UNet 進行全市人流預測的
知識轉移學習

Knowledge Transfer Learning for City-wide Crowd Flow
Prediction using CFRBF-UNet

研究生：劉祐炘

指導教授：李強博士

中華民國一百一十一年七月

Acknowledgements

Abstract

隨著深度學習的持續發展，研究人員會利用都市中的感測器系統將人類的移動資訊數據化並建立預測模型來幫助如都市規劃、旅遊規劃、大眾運輸調配、商場活動等的相關應用。然而近年因為 COVID-19 疫情爆發，都市中人群的移動模式產生劇烈變動，導致先前訓練好的模型無法準確預測發生變化的全市人流量。因此為了準確預測全市的人流並且能夠根據發生變化的人流更新預測模型，本研究旨在使用全市人流圖像預測網路 CFRBF-UNet 進行知識遷移來準確預測全市的人流。我們的模型透過知識轉移的能力能夠僅使用少量的訓練資料更新模型，同時我們的模型能夠有效萃取人流的時空依賴性以及考量外部因素對人流的影響，使其快速恢復原來的預測性能繼續使用。

本研究的實驗使用台灣真實資料來驗證所提出方法的有效性。與現有的方法相比，我們的模型擁有最好的預測性能，並且我們也為 CFRBF-UNet 的內部元件進行廣泛的實驗來評估各元件對於預測性能的貢獻。最後我們也評估了所提出的方法在遷移學習時的轉移速度以及精準度的有效性，實驗表明我們的模型能夠僅使用 2% 的參數進行 Fine-tuning，其節省了 62% 的訓練時間來快速使模型快速恢復原來的預測性能。

Keywords : Deep learning; convolution neural networks; RBF networks; transfer learning; crowd flow prediction; spatio-temporal data;

Table of contents

Acknowledgements	2
Abstract.....	3
Table of contents.....	4
List of Figures.....	6
List of Tables	9
1. Introduction	10
2. Related Work	17
2.1 Deep Urban Crowd Flow Prediction	17
2.2 Deep Transfer Learning	19
2.3 RBF Neural Network.....	21
2.4 U-Net	23
3. Definition and Dataset	25
3.1 Definition.....	25
3.2 Dataset	27
4. Methodology.....	29
4.1 Data Preprocessing	29
4.2 Model Construction	34
4.2.1 CF-UNet: UNet with Spatial Temporal Learner.....	34
4.2.2 CFRBF-UNet: CF-UNet with RBF Transfer Learner	39
4.3 Algorithms of CFRBF-UNet	43
4.3.1 Optimization Algorithm.....	43
4.3.2 Training Algorithm	47
4.3.3 Fine-tuning Algorithm	49
5. Experiment	50
5.1 Experimental Settings.....	50
5.1.1 Suiting Dataset for Transfer Learning	50
5.1.2 Hyperparameters.....	53
5.1.3 Baselines.....	53
5.1.4 Evaluation Metrics.....	54
5.2 Experimental Results.....	55
5.2.1 Source Data Only Performance	55
5.2.2 Target Data Performance	61

5.2.3	Optimization results of RBF Transfer Learner	69
6.	Conclusion and Future Work	73
	References	75

List of Figures

Figure 1.1 Google COVID-19 Community Mobility Reports	10
Figure 1.2 Example of Urban Flow Image	11
Figure 1.3 Taipei railway map	13
Figure 1.4 Crowd flow patterns and relationships.....	13
Figure 1.5 Regular flow vs. Irregular flow	14
Figure 1.6 Possible difficulties when fine-tuning.....	15
Figure 2.1 Filters	18
Figure 2.2 Residual Unit.....	18
Figure 2.3 Architecture of the deep transfer network.....	19
Figure 2.4 Overview of RegionTrans	20
Figure 2.5 Fitting Gaussian distribution	21
Figure 2.6 ANN-RBF Neural Network.....	21
Figure 2.7 U-net structure.....	23
Figure 3.1 (a) Region-base map segmentation; (b) Crowd flow images.....	25
Figure 3.2 (a) Map of dataset range; (b) An example of a crowd flow image in Taipei	27
Figure 4.1 System framework	29
Figure 4.2 Filling of missing data.....	30
Figure 4.3 After data normalization (0-1).....	31
Figure 4.4 Hourly 、daily 、weekly	31
Figure 4.5 Temporal dependent sequences	32
Figure 4.6 CF-UNet architecture	34
Figure 4.7 External Learner.....	35
Figure 4.8 U-net architecture.....	37

Figure 4.9 Convolutions	38
Figure 4.10 CFRBF-UNet architecture	39
Figure 4.11 RBF transfer learner	40
Figure 4.12 RBF kernel mapping example.....	41
Figure 4.13 Source→Target distribution transfer.....	41
Figure 4.14 A Squeeze-and-Excitation block	42
Figure 4.15 Set up RBF initial to accelerate model convergence	44
Figure 4.16 Example of RandomMean from input data.....	45
Figure 4.17 GaussianMixture fitting example.....	46
Figure 4.18 GMM Architecture	47
Figure 5.1 Crowd flow difference in Scenario 2	51
Figure 5.2 Locations of $r_1, r_2, r_3, k_1, k_2, k_3$	52
Figure 5.3 Kernel k_1	52
Figure 5.4 Kernel k_2	52
Figure 5.5 Kernel k_3	52
Figure 5.6 Small flow vs. Big flow: (a) Zhongyi Station; (b) Zhongxiao Fuxing Station ..	56
Figure 5.7 Similar pattern vs. Different flow: (a) Huzhou Station; (b) Jingmei Station	57
Figure 5.8 Numbers of $rbfSize(rs)$ vs. MAE	60
Figure 5.9 Numbers of SE blocks(se) vs. MAE	60
Figure 5.10 Error distributions of Before and After in proposed three regions.....	65
Figure 5.11 Predictions of Before and After in proposed three regions	65
Figure 5.12 Error distributions of kernel 1	66
Figure 5.13 Error distributions of kernel 2	67
Figure 5.14 Error distributions of kernel 3	68
Figure 5.15 Examples of poor convergence of initial parameter settings	69

Figure 5.16 Learning curves of training CFRBF-UNet.....	70
Figure 5.17 Parameters Usage	71
Figure 5.18 Learning curves of Fine-tuning RBF Transfer Learner	72

List of Tables

Table 3.1 Examples from the dataset.....	27
Table 3.2 External Features	28
Table 5.1 Scenario Data.....	51
Table 5.2 Model comparison on Source data	56
Table 5.3 Results of different layers of UNet.....	58
Table 5.4 Comparison of the different input structure of CFRBF-UNet.....	59
Table 5.5 External factors evaluation	60
Table 5.6 Model comparison on S1:Summer→Winter(12).....	61
Table 5.7 Model comparison on S2:Winter→Summer(7).....	62
Table 5.8 Model comparison on S3:Winter(2,3) Only	62
Table 5.9 Model comparison on S3:Summer→Winter(2,3).....	63
Table 5.10 Comparison of Before and After transfer in proposed three retions.....	64
Table 5.11 Best Epoch of Three Initializers	71
Table 5.12 Results of Fine-tuning with Different parameters	71

1. Introduction

近年來利用都市中的感測器系統將人類的移動資訊數據化並分析已逐漸成為趨勢，許多學者研究如何從這些全市的人流資料挖掘出有用的潛在資訊，以幫助如都市規劃、旅遊規劃、大眾運輸調配、商場活動安排 etc., 的相關應用。在這些研究中，大多數都是直接使用豐富的歷史人流資料進行模型的訓練以預測未來的人流。因此這些模型可以很好地捕捉到長期穩定的流量變化使得他們能夠在日常的預測取得良好的預測精準度。然而在真實應用場景中，全市的人流有時可能因為某些原因使得其人流發生劇變，導致原先使用的模型無法在該場景下取得良好的預測性能，原因是由於此時隨著時間變化的流量會與模型先前學習的歷史流量差異過大。舉例來說，最近因為 COVID-19 疫情爆發，全世界的國家包括台灣都受到疫情的影響，導致全球經濟受到嚴重衝擊。而因應 COVID-19 本土疫情持續嚴峻，台灣疫情指揮中心在 2021 年 5 月 19 號發布了全國疫情三級警戒[47]。對此我們比較在該時間點前後 Google 所公開的 COVID-19 Community Mobility Reports[13]如 Figure 1.1 所示。




Figure 1.1 Google COVID-19 Community Mobility Reports

我們可從圖表中觀察到在疫情影響下大眾運輸區域以及住宅區的人流趨勢都在短時間內發生了明顯的變化，其中 Figure 1.1 (a)大眾運輸下降五至七成，而相對應的是 Figure 1.1 (b)住宅區的人流趨勢則上升約二成左右，而 Figure 1.1 (c)工作場所的人流趨勢下降二至三成，Figure 1.1 (d)商場和娛樂場所的人流趨勢下降四到六成。根據這些統計報告我們可以了解在全市中的不同區域或不同性質的地點中其流量將因為某些不可避免之特殊狀況而產生變化，這時若我們直接利用原先訓練好的模型來針對發生變化的人流量進行預測那麼勢必是不可行的，因為各區域或地點的時空間流量模式已被改變。因此，如何使得這些原先透過大量歷史資料訓練的預測模型，能夠準確預測與訓練資料截然不同的人流，是本研究所要解決之重要問題。其中比較簡易的作法是收集這些與訓練資料截然不同的資料與原本的訓練資料一併輸入到模型重新訓練。但這種作法將導致使用單位需要等待原始資料收集和清洗的時間，以及模型重新訓練的時間，這明顯是很沒有效率的做法。因此，若要能夠真正準確地預測真實情況下的全市人流量，我們除了要考慮過去正常情況下的人流資料之外，還要考慮目前真實世界可能發生變異的人流資料。為了使預測模型可以愈快恢復使用，我們希望我們的模型僅需要使用極少數最近的人流資料來快速調整和更新以達到此目標。




Figure 1.2 Example of Urban Flow Image

由於人流資料屬於都市中時空間流量的一種，其中可包括車輛的 GPS 軌跡資料[29][44][58]、道路交通流量[10][30][32]，以及手機移動訊號[5][14][41]等等，因此我們在這些相關的過往研究進行調查，我們發現在全市中的時空間流量預測研究中大多

數會將資料轉換為時空間流量圖的方式做為資料格式以其進行預測[5][28][29][44]，如 Figure 1.2 所示。圖中我們可以看到對於都市中特定範圍的時空流量圖的轉換過程示意圖，對於一張用於預測的人流量圖，是透過固定大小的範圍內的人群活動數量進行統計而來。最終這些轉換後的網格所構成的圖像資料即為預測所用之資料。而後學者們通常考量到資料中時空間流量之間的關係來建立模型。如 Zhang 等人[59]則提出深度 DeepST 模型來預測都市人流的流入量以及流出量，其模型的輸入格式即為時空流量圖，並按照資料時間切分成 closeness, period, trend 來為模型提供三種不同時間依賴性的資料。相同的概念也被應用在 Liang 等人[29]用來預測全市的人流量，而最近幾年，有些學者開始研究如何運用深度遷移學習方法將來源的時空知識遷移到目標的時空預測。這類型研究通常是利用一個數據豐富的城市所擁有的時空間知識遷移到數據匱乏的城市中，如 Wang 等人[51]提出模型 RegionTrans 作為城市的深度時空預測框架，他們利用具豐富數據的源城市的資料訓練模型並將模型的參數保留並且匹配源城市與目標城市相似程度進行知識遷移。Yao 等人[54]則提出 MetaST(A meta-learning approach for spatial-temporal prediction)模型利用多城市的記憶矩陣，透過該矩陣使得用多城市的流量資訊來為目標城市做知識轉移。以及 Wang 等人[52]提出 ST-DAAN(Deep Attentive Adaptation Network for spatial-temporal prediction)模型，該模型透過添加嵌入層使得不同輸入特徵轉換到共同維度，並搭配注意力機制來讓模型提升都市間的知識遷移功能。

在本研究中我們旨在運用知識轉移的技術來提升模型在真實場景中全市流量預測的可行性與有效性，然而目前的研究都尚未全面考慮到全市內部人流知識遷移的可能性。透過知識遷移的模型將能夠有效地為全市人流預測取得實用的預測性能，針對這項重要的題目我們歸納出在實施時會面臨的挑戰：

- **全市人流量性質不同且彼此間複雜的相互影響關係**

在進行全市人預測時，模型除了需要考慮全市大範圍的人流量之外，還需要考慮全市中不同區域之間的潛在關係。因此當預測範圍從都市中一個區域擴大到全市時，

解決多區域流量性質不同且彼此間複雜的相互影響關係是我們首先需要克服的第一個困難點。對此我們比對相同的時間序列下的不同台北捷運站附近的人流量，我們挑選了台北市四個捷運站，他們的位置顯示在 Figure 1.3。圖中台北市的四個捷運站中有距離台北市中心較近的捷運忠孝復興站與距離台北市中心較遠的捷運北投站、捷運景美站以及捷運葫洲站。他們的比較結果顯示在 Figure 1.4 中。首先從 Figure 1.4 (a) 中可明顯看到位於市中心較近的忠孝復興站他的人流量平均落在 4000~10000，最高可達 10776 人；而較偏遠區域的北投站其人流量約落在 100~300，最小為 109 人，兩站人數差異將近一百倍。



Figure 1.3 Taipei railway map




Figure 1.4 Crowd flow patterns and relationships

我們接著觀察 Figure 1.4 (b) 捷運景美站以及捷運葫洲站的比較結果，首先這兩站的距離將近半個台北市，並且他們的流量數值範圍差異超過一百倍，有趣的是儘管這兩站流量數值範圍不同且沒有地理位置的關聯，但他們卻擁有非常相似的流量趨勢。最後

我們也在 Figure 1.4 (c)比對了相同時間下捷運景美站和降雨量的折線圖，因為我們知道天氣會影響人群的移動。對此我們可從圖中紅色的方框觀察到雨量的流量趨勢能夠幫助我們更了解捷運景美站不規律的人流趨勢。從上述範例我們即可得知，對於全市這類型大範圍的時空間流量預測時，預測模型需要具有能克服不同區域間的數值範圍差異，以及有效利用區域間的相互影響的關係並且將外部因素納入考慮，才可達到更佳的預測精準度。

- **學習人流分布的知識且具轉移的能力**

當我們建構一個能夠預測全市人流量的模型之後，接下來我們應該考慮如何針對真實場景中隨時可能發生變化的人流量為模型做調整，我們希望能透過遷移學習使得模型僅需使用少量的新資料進行 Fine-tuning，使得該模型能夠儘快恢復使用。因此我們具體要克服的問題為發生變化的人流是否適合我們直接對模型 Fine-tuning 來進行遷移而避免 Negative Transfer。對此我們舉 Figure 1.5 的例子進行說明。




Figure 1.5 Regular flow vs. Irregular flow

Figure 1.5 (a)是同一種流量在不同時間的走勢。其中黑色線是一般常見具規律的流量趨勢，而灰色線就像是發生變化的人流一樣產生了完全不同模式的不規律流量。此處我們將這些流量變化前後的流量分布圖進行比對，如 Figure 1.5 (b)所示。圖中我們可以看出因整體的流量模式發生變化，導致其分布從原先的一個分布變為兩個分布。注意到這邊我們僅舉單一地點的情形，然而在實際情況中全市人流量發生變化時，所改變的不可能只會有單一地區或地點的流量發生變化，勢必全市中各區域以及它們的相

互關係也將產生劇烈變化。在過去雖然 Fine-tuning 有可能幫助我們將原先已訓練好的模型逐步修改到可使用的狀態，但這通常僅限在兩者的 Domain 是相似或匹配的。但在此案例中我們即可知道，對於全市中這種時空間知識複雜且變動劇烈的遷移情形中，我們若直接用已訓練好的模型對目標流量(即發生變化的人流量)做 Fine-tuning 有可能會產生 Negative Transfer 的情形發生。而在這種情形下進行模型的遷移，最終並不是在幫助模型的學習到目標的人流知識。因此如何使全市人流量預測模型可以有效地將其學到的知識進行轉移，以幫助目標流量的預測，在最終完整地使模型擁有對發生變化的人流量做遷移學習的能力是本研究所要面臨的困難點以及挑戰。

- 針對模型的轉移速度和精準度進行優化

當模型在通過遷移學習進行 Fine-tuning 時，我們應該針對模型在真實場景的可用性考慮以下兩點:(1)如何避免模型在做遷移學習時所花費的時間過久，以及(2)調整模型時如何避免陷入局部最佳解，來進行遷移學習的優化。對此我們以 Figure 1.6 進行說明。首先在 Figure 1.6 (a)中假設黑色的分布為發生變化前的人流分布，而發生變化的灰色人流分布為我們要遷移學習的目標。




Figure 1.6 Possible difficulties when fine-tuning

從圖中可明顯看出兩者的分布因為流量模式發生變化而有很大的差距。當模型在這種情況下進行 Fine-tuning 時，勢必需要跨過很大的範圍才能達成目標。另外有時我們並不能保證模型是否能真的微調適當的分布位置，對此我們以 Figure 1.6 (b)為例。圖中我們可以觀察到當黑色和灰色分布有部分重疊的情況時，模型有可能因為缺乏對所

有分布的全局視野而僅 Fine-tuning 到重疊的位置陷入局部最佳解，最終將導致模型微調結果並不適用全市變化後的人流預測。對此我們必須提出新的方法來克服此困難。

在本論文中我們旨在完成通過深度人流預測網絡 CFRBF-UNet 進行知識轉移的全市人群流量圖像預測，且我們提出以下幾點來克服上述問題：

- 為了解決全市人流預測的難點，我們會使用基於 UNet 改良的 Crow Flow Prediction UNet(CF-UNet)，其會透過 UNet 架構中的收縮路徑將人流資料的空間特徵進行壓縮，使得內部卷積層能夠以更全局的方式捕捉到人流的空間依賴性，此外所提出模型中的 Spatial Temporal Learner 能夠加強萃取人流的時空依賴性的能力，因為此 Learner 考慮了 hourly、weekly、daily 三種時間關係的人流資料，並且他會同時使用不同大小的卷積核以萃取不同時間和空間視野的時空特徵。另外所提出模型會透過 External Learner 來對額外輸入的外部因素進行特徵提取，並將該特徵併入到 UNet 當中。
- 為了使模型能夠掌握輸入資料分布的知識且具轉移知識的能力。我們提出 RBF Transfer Learner 來為上述的 CF-UNet 模型加強其遷移學習的能力，其可被命名為 CFRBF-UNet。透過該 Learner 內部的搭載 RBF 核函數的神經元能夠學習輸入特徵的分布，並且會根據注意力機制來調整不同特徵的權重。而這些經訓練的神經元裡的參數即可代表學習到的知識，我們能夠針對這些對應的參數進行轉移或更新來幫助提升最終的預測性能，以達到知識遷移的目的。
- 為了避免模型在知識轉移時 Fine-tuning 模型可能花費大量時間或陷入局部最佳解影響模型性能，我們會額外開發初始值設置的演算法來為 RBF Transfer Learner 找到合適的參數設置，我們提出兩種初始化器 RandomMean 和 GaussianMixture 來根據不同大小的資料量進行參數初始值的估算，來為模型提供一個能更快且更好收斂的參數初始值。如此便能透過轉移有用的知識使得優化後的 CFRBF-UNet 不需要花費大量時間來訓練模型的參數以及轉移時空間的知識，並且能夠避免微調過程中陷入區域最佳解影響準度的問題發生。

最後本論文會使用真實的人流資料集和天氣資料集來驗證所提出方法的有效性。本論文的其餘部分安排如下。第 2 章為 Related Work。第 3 章為 Definition and Dataset。第 4 章為 Methodology。第 5 章為 Experiment 以及第六章為 Conclusion and Future Work。

2. Related Work

在此節我們會針對與本論文相關的重要過往研究的進行回顧。其內容安排如下：

2.1 Deep Urban Crowd Flow Prediction、2.2 Deep Transfer Learning、2.3 RBF Neural Network，以及 2.4 U-Net。

2.1 Deep Urban Crowd Flow Prediction

都市的人流量與都市中產生的其他時空間流量如車輛軌跡 GPS 訊號[29][44][58]、車站進出口資料[8][20][27]、道路交通流量[10][30][32]，以及手機移動訊號[5][14][41]等等都有直接和間接的關係。因為他們都是人類在都市中活動所造成的。針對這些都市中時空間流量的預測問題，過往學者的做法都是使他們的模型學習歷史資料後，進行未來數值的預測。他們的模型都著重在如何更有效的萃取資料中的特徵來學習以及預測。在此我們回顧近年主流的深度學習預測方法。首先考量到道路交通流量的時間依賴性，Fu 等人[10]使用 Long Short-Term Memory (LSTM)和 Gated Recurrent Unit (GRU)的神經網路進行交通流量預測。也有學者同時考慮了時間與空間的依賴性的問題，如 Lv 等人[32]利用 Stacked Autoencoder (SAE)模型以 Greedy 的分層方式進行訓練，該模型同時輸入多條高速公路的流量數據到神經網路模型裡以交通網路的角度建構模型，並且輸入每條公路過去多個單位時間的資料。使得 SAE 輸入不同空間和時間的歷史道路交通流量來預測道路未來的交通流量。Zhang 等人[59]則提出 A Deep-learning-based prediction model for Spatio-Temporal data (DeepST)來預測都市人流的流入量以及流出量，其模型的輸入按照資料時間切分成 closeness, period, trend 來為模型提供三種不同時間依賴性的資料，用以加強模型對時空特徵的學習能力。然而當上述

模型的輸入維度增加，例如輸入整個都市的交通流量時，可能導致模型的輸入層和隱藏層參數大幅增加。因此有學者在神經網路中引入連續多層的卷積層來解決該問題。他們利用卷積層中不同大小的卷積核來提取人流圖像的空間特徵，如 Figure 2.1 中的三種卷積核。透過不同大小的濾波器可以使模型同時考慮在空間上遠近不同的地區。像是有 Liu 等人[30]利用 Conv-LSTM 模型和 Bi-LSTM 來提取交通流量的時空特徵來預測道路交通流量。Zhang 等人[58]提出 Deep spatio-temporal residual networks (ST-ResNet)模型來對三種時間段分別做特徵提取，他們的模型使用大量由卷積層組成的殘差單元，其單元的結構顯示在 Figure 2.2 當中。殘差單元內部透過兩層卷積層與激活函數後的輸出 $X^{(L+1)}$ 會和輸入特徵 $X^{(L)}$ 融合。透過這個方法，當搭建連續卷積層的時候，可以避免因層數過多而發生 gradient vanishing 的問題，並且能夠幫助提取特徵。




Figure 2.1 Filters




Figure 2.2 Residual Unit

最近也有學者引入新穎的深度學習技術來預測時空間流量的問題，如 Bai 等人[2]提出 Adaptive Graph Convolutional Recurrent Network (AGCRN)來預測公路流量。Li 等人[28]提出 Neural Architecture Search for spatio-temporal prediction (AutoST)來預測都市中的人流量。而也有學者考量到建模成本的問題，如 Liang 等人[29]提出 Spatio-Temporal Relation Network (STRN)來預測全市的人流量，該模型也是使用三種時間段的資料分別進行特徵提取，他們也考量到建模成本的問題，在模型內部生成一個 assignment matrix 透過非監督式的分群將特徵從高維度 N 透過分群降至低維度 M ，達到減低模型訓練參數的效果。然而，以上的方法雖然用深度學習的技術使得模型的效

能提高的新的水平，但是他們沒有就真實情況的預測問題做探討，他們的模型都是在理想情況下建立的，缺乏對新資料遷移學習的能力。

2.2 Deep Transfer Learning

深度學習的模型可以透過遷移學習來降低訓練的門檻，提升模型的泛化能力，而無須從大量資料中學習，其核心概念在於如何從一個或多個 Source Tasks 中提取模型所含有的知識與經驗，然後將其運用在新的 Target Domain 上。例如 Hu 等人[17]利用透過遷移學習的深度神經網路進行短期風速預測，由於有些農場較舊的風力設備老舊，沒有足夠的數據進行預測，因此他們利用深度神經網路來學習預測一個數據豐富的農場後，將經過訓練的網路遷移學習到數據稀少的農場，有效使模型在數據稀少農場的預測結果表現良好。Sun 等人[39]在 Stacked Sparse Autoencoder (SAE)引入遷移學習，用來預測製造刀具機台的壽命。他們模型架構圖如 Figure 2.3 所示，他們首先使用 SAE 網路在 off-line 離線時以豐富 Source data 的故障資訊訓練好模型，之後將訓練好的網路複製到新的 SAE，並在 online 中透過兩個網路間的權重轉移與以及特徵遷移學習，他們將兩個模型之間的特徵機率分布用 Kullback–Leibler 做為新 SAE 模型中特徵轉移學習的約束。如此，這樣的框架可以學習歷史故障數據和新數據之間的相似和聯合特徵。




Figure 2.3 Architecture of the deep transfer network

最近幾年，在都市人流量預測的問題上，有學者開始研究如何運用深度遷移學習方法將來源的時空預測和區域範圍的相關知識遷移到目標的預測任務上。如 Wang 等人[51]將模型對一個數據豐富的城市人流量所擁有的知識遷移到數據匱乏的城市當中，提出模型 RegionTrans 作為城市的深度時空預測框架，如 Figure 2.4 所示。




Figure 2.4 Overview of RegionTrans

透過該框架將模型的知識從一個數據豐富的都市轉移到數據匱乏的都市。他們利用具豐富數據的源城市 Source 的資料訓練模型之後，將模型的參數保留並且匹配源城市與目標城市 Target 相似程度，將前幾個相似的區域提取其對應的模型參數來遷移到目標城市進行訓練，如此便能達到運用模型對源城市知識來預測目標城市流量的遷移學習。而 Yao 等人[54]提出 A meta-learning approach for spatial-temporal prediction (MetaST)，他們利用一個多城市的記憶矩陣來儲存模型對各城市的訓練完後所得到的知識，利用多城市的流量資訊來為目標城市做知識轉移。他們將記憶矩陣與 Target 城市一起訓練，達到多城市遷移學習的效果。Wang 等人[52]則提出 Deep Attentive Adaptation Network for spatial-temporal prediction (ST-DAAN)，他們在 ST-DAAN 模型中加入嵌入層將不同 Domain 的輸入特徵轉換到共同維度的空間，這使模型可以更有效的處理不同 Domain 之間的遷移學習。此外，他們還在模型引入注意力機制來讓模型提升都市間的知識遷移之下模型預測的性能。

上述我們回顧了遷移學習在各領域之間的實際運用，了解到他們如何將模型訓練完成後利用遷移學習的技術在即時的真實場景中進行預測以及更新模型，以驗證在真實情況下之下模型的可行性。而對於都市間人流量遷移學習的相關研究，我們發現此部分研究文獻的數量相較於其他領域顯得稀少。並且，雖然有小部分的學者正透過深度學習試著解決都市流量遷移學習的問題。但由於他們的模型主要是根據城市中小範圍的流量進行處理，且他們考慮的是多城市之間的知識轉移。另外他們的方法並不適用於全市這類型大範圍的預測，因為當輸入維度增加，會使得他們的模型參數量過多而難以訓練。

2.3 RBF Neural Network

Radial Basis Function (RBF) 過去最常被用來當作機器學習中 Support Vector Machine (SVM) 算法的核函數[12][18][49]，而其常見的函數有線性的多項式函數，也有非線性的高斯徑向基函數等等。RBF 的作用在於將輸入特徵來逼近某一個給定的函數。如 Figure 2.5 中，輸入特徵 x 會經某個 RBF 核函數 $y = f(x)$ 轉換後，RBF 中的高斯徑向基函數會用來擬和輸入特徵的分布，這種擬和特徵的能力在處理許多非線性特徵關係上有著很好的優勢，有學者透過 RBF 在機器學習的運用上取得良好的預測性能。而隨著近幾年深度學習的發展，有學者開始將 RBF 加入到 Artificial Neural Network (ANN) 的神經元當中。




Figure 2.5 Fitting Gaussian distribution




Figure 2.6 ANN-RBF Neural Network

例如 Yilmaz 等人[55]比較兩種人工神經網路 ANN-RBF 和 ANN-MLP 預測土壤膨脹百分比的性能，這兩種網路都是由輸入層、隱藏層與輸出層構成，其中 ANN-RBF 在隱藏層中加入高斯徑向基函數，如 Figure 2.6 所表示。由他們的實驗結果可得知，透過 RBF 中的高斯徑向函數轉換可減少神經網路中反向傳播進行搜索空間的維度，ANN-RBF 因為其良好的非線性的轉換能力使得收斂的速度比 ANN-MLP 來得更快。而 Zeng 等人[56]提出一種基於 RBF 神經網路的模型，用來預測短期的太陽功率。他們發現 RBF 神經網路能夠有效捕捉太陽輻射數據的非線性和時變的特性，因此該模型能取得更低的預測誤差。Wu 等人[50]透過將 Particle Swarm Optimization (PSO)與 Genetic Algorithm (GA)的概念融入 RBF 神經網路之中，來預測降雨機率。他們用融合最佳化演算法的方式為 RBF 神經網路的參數做調整，使模型具有更有效的預測能力以及避免模型提早收斂在局部最優點。Chen 等人[7]提出 RBF-LSTM 模型來預測空氣中 PM2.5 濃度的數值。他們利用分析 RBF 中的徑向基函數的輸出，以提取深度學習模型識別重要的關鍵特徵。透過這些關鍵特徵的建模預測來提升模型的準確性並且降低訓練成本。

而在都市中大眾運輸流量的預測問題上，一些學者也利用 RBF 神經網路來提取時空的特徵並做預測。如 Li 等人[26]結合 ARIMA 與 RBF-ANN 的混和模型對道路車流量做短期預測。他們的方法將兩種模型的優點相互結合。他們利用 ARIMA 模型來捕獲交通流時間序列的線性關係，並利用 RBF-ANN 模型來提取流量時序的非線性關係。他們的研究表明透過 RBF 神經網路中核函數的技術可以任意逼近任意非線性的特徵關係，同時 RBF 模型具有全局的逼近能力和更快的收斂速度。而 Chen 等人[4]提出基於改良 Artificial Bee Colony (ABC)與 RBF 網路融合的模型來預測道路的交通流量。該模型採用 ABC 算法來優化 RBF 神經網路中的權重和閾值。他們的實驗結果表明，與一般反向傳播的 RBF 神經網路相比，他們所提出優化 RBF 神經網路的方法更能捕捉交通流量變化的規律，以降低預測的誤差。最近，Hao 等人[19]提出基於 DE-RBF 混和模型的短期交通流量預測。他們利用 Differential Evolution Algorithm (DE)

來對 RBF 的參數進行優化，得到最良好的短期交通流量預測值。

上述我們回顧了 RBF 對於預測問題的相關研究，從他們的研究可得知，RBF 擁有對於非線性擬和傑出的能力，並且可以加快模型收斂的速度，降低建模所花費的成本。此外我們也回顧了使用 RBF 相關技術在都市中大眾運輸流量預測上的相關研究。根據他們所提出的方法，我們了解到 RBF 擁有良好的非線性擬和能力，能夠改善模型的性能。

2.4 U-Net

我們對 U-net 的相關研究進行調查，首先 U-net 最早是由 Ronneberger 等人[38]所提出，他們用根據 Fully Convolution Network (FCN)的概念而發明了 U-net 來對細胞膜影像進行辨識和分割。其結構如 Figure 2.7 所示為一個 U 形狀的 Convolutional encoder-decoder 對稱網路結構，前半段的 encoder 輸入圖像的特徵提取器，後半段的 decoder 會讀取特徵進行最終的輸出，並且兩者之間會使用 skip connections 傳遞重要的特徵訊息。此結構的效果在當時被證實擁有非常傑出的表現。




Figure 2.7 U-net structure

因此開始有許多學者研究基於 U-net 的改良模型或是將 U-Net 應用在醫學領域 [9][24][36]和其他領域[22][45][48]等等。例如 Oktay 等人[35]提出 Attention u-net 來進行 Pancreas 的分割任務，他們提出一種 attention gate 使模型能夠自動學習關注不同形狀和大小的目標醫療影像。Stoller 等人[40]提出 Wave-u-net 來進行端到端的 audio source separation。他們證實了這種 Unet-like 的結構提取的 feature maps 能夠有效地

使模型分辨不同時間尺度的特徵。最近有學者考慮了建模成本的問題，如 Zhang 等人[57]提出一種用於環境微生物(EM)圖像分割的低成本 U-Net (LCU-Net)，因此改善了 U-net 相對較高的內存成本問題。另外 Yu 等人[53]提出了 Spatio-Temporal U-Net (ST-UNet)來預測 spatio-temporal graph，他們實驗結果證實了此模型可以有效地從時空圖中探索局部和全局的空間特性。最近，Zhou 等人[60]在 ST-UNet 架構上加入注意力機制對車站級別人流時空 graph 做預測。他們利用模型內部分層的時空注意力機制來有效克服應人群流量而產生的複雜時空相關性。


上述我們回顧了 U-net 的相關研究，我們從中了解到 U-net 內部的連續卷積層能夠很好地對不同形狀和大小的輸入特徵進行特徵提取。其中雖然都市人流預測的相關研究僅有少數，但是根據這些研究我們即可得知 U-net 確實能夠根據其結構來有效捕捉複雜的人流時空關係，這證實了 U-net 在人流預測的有效性和潛力。然而，據我們所知將 U-net 應用在人流圖像的預測上的相關研究非常稀少，上述他們的模型都是應用在 graph 上，因此需要針對 U-net 提出一些改良的方法來應用在人流圖像的預測。

3. Definition and Dataset


在此節中，我們先在 3.1 說明所定義的符號意義，以幫助我們陳述所研究的問題，並給出一個正式的問題定義，以利於後續章節的說明。3.2 會介紹本研究使用的人流資料集和天氣資料集。

3.1 Definition

Definition 1 (Region) 我們將所要預測的目標城市依照經緯度均勻地將其分割成 $m \times n$ 個大小相同的網格 (e.g., $500m \times 500m$)，每一個網格代表一個 region，如同 Figure 3.1(a) 所示。在該區分割出的所有網格可以表示為一個 Region set $R = \{r_{1,1}, r_{i,j}, \dots, r_{m,n}\}$ ，where $r_{i,j}$ 代表在區域 c 中第 i 列和第 j 行的 region。



(a)



(b)

Figure 3.1 (a) Region-base map segmentation; (b) Crowd flow images

Definition 2 (Crowd Flow Images) Given a Region set $R = \{r_{1,1}, r_{i,j}, \dots, r_{m,n}\}$ ，在第 t 時間裡所有 region 所量測到的人流數值可表示為一個人流圖 $X_t = \{x_{1,1}, x_{i,j}, \dots, x_{m,n}\} \in \mathbb{R}^{m \times n}$ ，且 the length of the time-stamps t 所有的 crowd flow images 可被定義為 $X = \{X_k | k = 1, 2, \dots, t\} \in \mathbb{R}^{m \times n \times t}$ ，如 Figure 3.1(b)所示。其中 $X(i,j,k)$ 表示在第 k 時間段的 region $r_{i,j}$ 量測到的人流數值 $x_{i,j}$ 。

Definition 3 (External Factors) 外部因素包含許多關於氣象的資訊(e.g., 雨量、風速、氣溫等)。Given the length of the time-stamps t 的外部因素可表示為 $E = \{e_k | k = 1, 2, \dots, t\}$

其中 $e_t \in \mathbb{R}^{l_e}$ 代表第 t 時間段所量測到的外部因素， l_e 表示為量測到天氣特徵的數量。

Problem Formulation (Crowd Flow Image Prediction with Knowledge Transfer) 假設

現在有一個都市中豐富的歷史人群流量源資料序列 Source 為 $X^S = \{X_k^S | k = k_L, \dots, k_{LS}\}$ ，以及少量新取得的人群流量目標資料序列 Target 為 $X^T = \{X_k^T | k = k_L, \dots, k_{LT}\}$ ，且我們假設 Source 的資料長度遠大於 Target 的資料長度 $L^S \gg L^T$ 。我們首先會利用 Source 訓練模型得到模型 f^S ，接著利用該模型來為 Target 的預測任務作知識轉移，我們的目的的是最小化 Target 預測任務的誤差，針對該問題可定義為下列式子(3.1)以及式子(3.2):

$$\underset{f}{\operatorname{argmin}} \sum_k^n \operatorname{loss}(X_k^T, \bar{X}_k^T) \quad (3.1)$$

$$\bar{X}_k^T = f^S(\theta, X, e) \quad (3.2)$$

where S 代表 source series, T 則表示 target series， loss 可以是任何適合評估預測誤差的函數(e.g. mean absolute error)。 n 為從 Target 資料序列中切分的測試資料集數量。

$\bar{X}_k^T$ 為未來第 k 時間段的預測結果，其由模型 f^S 輸入 $X = \{X_t^T | t = 0, \dots, k-1\}$ 、外部因素 e 以及欲訓練的參數 θ 後所得出。 X_k^T 則為 ground truth。注意到這裡的參數 θ 若指定為全部模型的參數則表示對整個模型 Fine-tuning 的方式訓練。因此在此問題定義當中，我們旨在從任何少量目標資料的遷移學習預測任務中最小化其預測誤差。

3.2 Dataset

- Crowd Flow Dataset

本研究使用的人流資料集為台灣台北的真實電信資料集，其資料集的經緯度範圍由經度 121.46 至 121.665，緯度 24.965 至 25.21，如 Figure 3.2(a)所示。每個網格大小為 500m x 500m，這部分與台灣的逐時人流移動距離相符[23]。




Table 3.1 Examples from the dataset

Timestamp	Longitude	Latitude	Population
2018-01-01 00:00:00	121.53	25.115	274
2018-01-01 01:00:00	121.53	25.115	254
2018-01-01 02:00:00	121.53	25.115	241
...	...	...	...
2020-03-31 23:00:00	121.53	25.115	268

Table 3.1 為該人流資料範例資料。其資料集的時間範圍為 2018-01-01~2020-03-31，並以每個小時的單位長度作為每筆資料的間隔。表中第 2 筆範例資料表示在 2018 年 1 月 1 日的清晨 1 點時，在經度 121.53 以及緯度 25.115 的周圍 0.005 經緯度範圍內，共有 254 個移動裝置在該範圍內，它亦可表示為人數。將所有位置的人數以圖像的方式視覺化即可得到 Figure 3.1(b)的人群流量圖像。注意到此資料集為 Ministry of

Science and Technology Taiwan 所提供，由於我們須遵守其相關的保密協定，因此我們不能透漏關於此資料集更詳細的資訊。

- Weather Dataset

本研究所使用的外部因素資料為台灣中央氣象局提供的 the observation data of CWB's manned and automatic weather stations named CWB Observation Data Inquire System (CODiS)[6]，該網站可查詢以小時為單位的每日氣象資料。Table 3.2 展示其資料的欄位名稱、欄位單位以及欄位說明。

Table 3.2 External Features

Feature	Unit	Description
StnPres	hPa	station pressure
SeaPres	gpm	sea surface pressure
Temperature	°C	
Td dew point	°C	dew point temperature
RH	%	relative humidity
WS	m/s	wind speed
WD	degree	wind direction
WSGust	m/s	maximum wind speed
WDGust	degree	maximum wind direction
Precp	mm	precipitation
PrecpHour	hour	precipitation duration
SunShine	Hour	sunshine duration
GloblRad	MJ/m ²	global radiation
Visb	Km	visibility
UVI	number	
Cloud	0~10	cloud amount

我們會從該網站收集與人流資料對應時間的所有氣象資料加入到訓練資料的 external factors 當中。此外所有對應日期的假期資料也會依同併入其中，包含工作日、平日、周末、和節慶假日。根據上述提及，人流資料以及外部因素資料的總時間長度為 19704 個小時，而外部因素的數量為 48，其處理細節將在 4.2.2 節的 External Learner 進行說明。

4. Methodology

本章節介紹 Proposed system framework，共包含三個部分，分別為(4.1) Data Preprocessing、(4.2) Model Construction (4.3) Algorithms of CFRBF-UNet。Figure 4.1 描述這三個部分的關係和執行過程。我們目標是將在 Source domain 訓練完成的模型 f^S 轉移到 Target domain 進行 Fine-tuning 後取得最終的預測結果。以下將針對這三個部分進行說明。





Figure 4.1 System framework


4.1 Data Preprocessing

本節針對原始人流資料的前處理可分為三個步驟，分別為 Step 1 填補缺失資料、Step 2 資料正規化，以及 Step 3 時間序列特徵提取。

Step 1: Filling of missing data 人流資料為一種時間序列資料，在真實的時間序列資料中，少數狀況會因感測器故障或其他原因導致短暫地無法收集到資料(又稱為缺失值)，該缺少的數值可能會對我們訓練的類神經網路模型性能造成重大的影響，因此在訓練模型之前，我們必須填補資料中的缺失值。假設有一感測器收集資料的頻率是每小時，我們依照連續的小時將其收集到的資料畫出折線圖，而無資料的時間段則用 0 替代遺失的資料以便於觀察。如 Figure 4.2(a)所示，可看到圖中人流數值隨著時間有著正常幅度的連續變化，然而在某些時段中因遺失而突然驟降至 0。



(a) Before filling missing data



(b) After filling missing data

Figure 4.2 Filling of missing data

因此我們需要對這種情況作處理，來確保資料在時間上的連續性。假設有一 region $r_{i,j}$ 在 t 時間段上無法量測到資料，導致 $X(i,j,t)$ 的數值缺失。對此我們根據內插公式 4.1 來填補缺失值。Figure 4.2(b)的結果可看到其資料能夠維持在時間上的連續性。

$$X(i, j, t) = \frac{X(i, j, t-1) + X(i, j, t+1)}{2} \quad (4.1)$$

Step 2: Normalization 由於不同 region 的人流量數值可能差異很大，如在平日時都市的區域可能高達數萬人，而在住宅區可能只有幾百人，因此我們會將所有的數值正規化使得其數值範圍統一規範至 0~1 中，並且我們會依照每個 region 的最大值與最小值做資料正規化，而非根據所有 region 的數值來進行資料正規化。因此，對於第 i 列第 j 行的序列資料其正規化的算法可被表示為下列公式 4.2:

$$X(i, j) = \frac{X'(i, j) - \min(X'(i, j))}{\max(X'(i, j)) - \min(X'(i, j))} \quad (4.2)$$

其中 X 為做正規化之後的資料, $X'(i,j)$ 表示在 $r_{i,j}$ 測量到的所有時間的原始數值。Figure 4.3 顯示正規化後的結果, 可看到其數值範圍被規範至 0 到 1 且保持原本的起伏變化。




Figure 4.3 After data normalization (0-1)

Step 3: Time series feature extraction 在將資料輸入到模型訓練之前, 我們會根據三種的時間關係 hourly、daily 以及 weekly 來對整個序列進行資料分割 to construct three temporal dependent sequences。舉例來說, 對於一個長度為 L 的流量序列 $\{X_k | k = k_1, \dots, k_L\}$, 假設要預測的 ground truth 為 X_k , 其模型的輸入 $X_{in} = [X_h, X_d, X_w]$ 將依照下列公式(4.3)(4.4)(4.5)來提取:

$$X_h = [X_{k-l_h}, X_{k-(l_h-1)}, \dots, X_{k-1}] \quad (4.3)$$

$$X_d = [X_{k-l_d \cdot d}, X_{k-(l_d-1) \cdot d}, \dots, X_{k-d}] \quad (4.4)$$

$$X_w = [X_{k-l_w \cdot w}, X_{k-(l_w-1) \cdot w}, \dots, X_{k-w}] \quad (4.5)$$

其中 l_h, l_d, l_w 分別決定 hourly、daily 以及 weekly 三種矩陣的時間序列長度, 而 d 和 w 則代表兩種不同類型的時間區間。我們實際在提取資料時, 會將 d 設置為一天來描述




Figure 4.4 Hourly、daily、weekly

每日的時間相關性，而 w 則設置為一周來描述每周的時間相關性。以 Figure 4.4 舉例來說，當要預測 3 月 20 號下午 3 點的流量時，第一個時間段的輸入矩陣會提供模型




Figure 4.5 Temporal dependent sequences

與預測時間鄰近小時的歷史流量，如 3 月 20 號下午 2 點以及 3 月 20 號下午 1 點，這使模型能依據鄰近的時間依賴性來做預測；第二個時間段的輸入矩陣則提供模型前幾天與預測時間相同的歷史流量，例如 3 月 19 號下午 3 點以及 3 月 18 號下午 3 點，這使模型能依據過往每天的周期性來做預測；第三個時間段的輸入矩陣則提供模型前幾周與預測時間相同的歷史流量，例如 3 月 13 號下午 3 點以及 3 月 6 號下午 3 點，這使模型能依據過往每周的趨勢來做預測，這三種時間流量範例的關係描述在 Figure 4.5 中。因此，透過這三種不同時間特徵的 temporal dependent sequences 能有效使模型學習輸入特徵在時間上的依賴性[29][33][44][58]。接下來我們需要依照資料的時間段來提取模型的輸入以及輸出。首先，依照下列 Algorithm 1 的輸入為上步驟已填補並正規化後的資料序列 $X=\{X_1, X_2, \dots, X_{|X|}\}$ 以及給定三個決定時間序列長度大於零的參數 l_h, l_d, l_w 。而 d 設置為一天(24 小時)， w 則設置為一周(168 小時)。對於所要預測

的 i^{th} 時間段的流量數值，需準備其對應的三種時間段的歷史流量資料做為輸入。在這裡我們需要分別檢查三種時間關係上是否有足夠長度的歷史流量資料(line5、line11、line17)，當三種時間關係都有足夠長度的資料，才會將這筆資料加入(line 23)。演算法最終的生成的模型的輸入 I 以及 Ground Truth 為 O。

Algorithm 1: Time series feature extraction

Input: $X = \{X_1, X_2, \dots, X_{|X|}\}, l_h, l_d, l_w, d, w$

Output: $I = \{i_1, i_2, \dots, i_{|I|}\}, O = \{o_1, o_2, \dots, o_{|O|}\}$

```

1  I, O  $\leftarrow$  {}, {}
2  for  $i$  (1 to  $|X|$ ) do //  $X[i]$  is the target at time  $i$ 
3       $X_h, X_d, X_w \leftarrow$  three empty list
4      // hourly
5      if  $i - l_h > 0$  then
6          for  $k$  ( $l_h$  to 1 by -1) do
7               $X_h$  append  $X[i - k]$ 
8          end for
9      end if
10     // daily
11     if  $i - l_d \times d > 0$  then
12         for  $k$  ( $l_d$  to 1 by -1) do
13              $X_d$  append  $X[i - k \times d]$ 
14         end for
15     end if
16     // weekly
17     if  $i - l_w \times w > 0$  then
18         for  $k$  ( $l_w$  to 1 by -1) do
19              $X_w$  append  $X[i - k \times w]$ 
20         end for
21     end if
22     if  $X_h, X_d, X_w$  all are not empty then
23         I append  $[X_h, X_d, X_w]$ 
24         O append  $X[i]$ 
25     end if
26 end for

```

4.2 Model Construction

本節介紹本論文所提出的深度學習人流預測模型 CF-UNet 以及 CFRBF-UNet。前者透過所提出的 Spatial Temporal Learner 來改善 U-net[38]學習特徵時間依賴性的問題，並且我們透過加入外部因素組件 External Learner 使模型學習外部因素(如雨量、風速等)的相關特徵；後者則透過所提出的 RBF Transfer Learner 使模型能更有效地將知識轉移運用在遷移學習的預測任務上。以下將分成三個部份來進行詳細說明，分別為(4.2.1) CF-UNet、(4.2.2) CFRBF-UNet。

4.2.2 CF-UNet: UNet with Spatial Temporal Learner

Figure 4.6 為 Crowd Flow Prediction UNet (CF-UNet) 的模型架構，其組成由三個主要元件構成，分別為 4.2.1.1 External Learner、4.2.1.2 Spatial Temporal Learner，以及 4.2.1.3 U-Net。External Learner 負責將外部因素做初步的特徵提取，而 Spatial Temporal Learner 則負責萃取時空間的特徵，他們各自提取的特徵融合到 H_{hdwe} 後，我們最終將其輸入到 UNet 進行最終的預測 $\bar{X}_{k+1}$ 。以下將詳細說明各個元件的輸入以及輸出。




Figure 4.6 CF-UNet architecture

4.2.2.1 External Learner

都市中的人流數值可被許多因素所影響，除了包括人們主要規律的作息的因素之外，還包括許多外部因素，像是天氣和假期[58]。這些因素都會影響人們的生活作息，像是惡劣的天氣或周末可能驅使人們在家休息，導致較低的人流量；而工作日或是特別節日則可能會伴隨著高峰的人流量。因此，我們實際將這些外部因素透過 External Learner 將其融合到預測模型之內。Figure 4.7 顯示 External Learner 詳細的

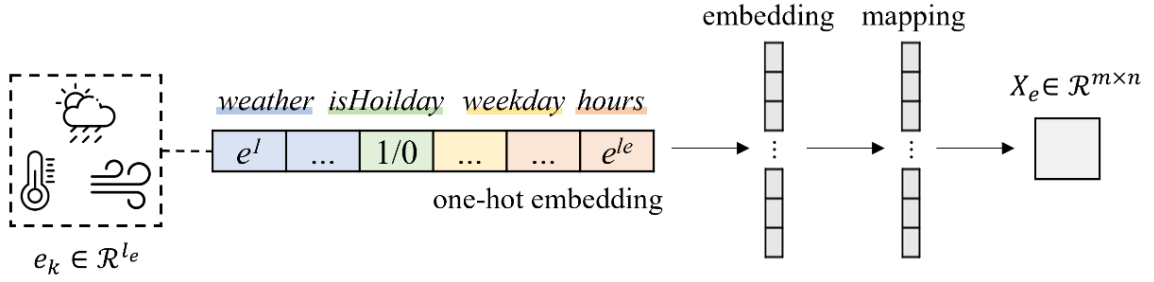


Figure 4.7 External Learner

資訊。首先他的輸入為在第 k^{th} 時間的外部因素為 e_k ，其組成可包括多個天氣觀測數值(如雨量、風速、氣溫等)，和一個描述當日是否為工作日的布林值，並且我們會將星期與小時的資訊進行 one-hot embedding 後加入到其中。接著這些加總長度為 l_e 的外部特徵會輸入到 fully-connected layers(FC)，FC layer 的輸出可被表示為：

$$y(x) = f(W \cdot x + b) \quad (4.6)$$

其中 x 為輸入特徵， $y(x)$ 為輸出特徵， f 為線性或非線性的激活函數， W 為 weights matrix， b 則為 bias term。神經網路會學習 W 來與 x 做矩陣相乘，並且加上偏移 b 並透過激活函數 f 轉換後即可得到輸出 y 。我們使用兩層 FC Layers 萃取外部特徵。第一層的 embedding 層用來將不同的外部因素嵌入到共同維度的特徵，第二層的 mapping 層則被設計用來將嵌入層的輸出映射到更高維度的特徵，and The mapping layer tends to learn a function that maps a 1N-dimension vector into a 2N-dimension space，最終的輸出 $X_e \in \mathcal{R}^{m \times n}$ 的維度與 crowd flow image 相同。

4.2.2.2 Spatial Temporal Learner

為了整合全市流量中時空間特徵的依賴性來幫助模型提取特徵，我們會在此 Learner 實作 convolutional neural network(CNN)來萃取相鄰 region 之間的空間依賴性，實際上，此 CNN 會分成三個平行網路將先前在 4.1 節提取三種不同的時間相關性矩陣 X_h 、 X_d 、 X_w 進行卷積運算來提取特徵。長度為 l_h 的矩陣 X_h 在卷積層中會透過公式 (4.7) 進行特徵提取。

$$X_h^{conv} = f\left(\sum_{j=1}^{l_h} W_{h,j} * X_{k-j} + b_h\right) \quad (4.7)$$

$$X_d^{conv} = f\left(\sum_{j=1}^{l_d} W_{d,j} * X_{k-j-d} + b_d\right) \quad (4.8)$$

$$X_w^{conv} = f\left(\sum_{j=1}^{l_w} W_{w,j} * X_{k-j-w} + b_w\right) \quad (4.9)$$

同樣地， X_d 和 X_w 也會分別按照公式 (4.8) 和 (4.9) 進行空間特徵提取。其中 W 和 b 為卷積層的參數，運算符 $*$ 代表卷積核的運算， f 是非線性激活函數(e.g., $\text{ReLU}(z) = \max(0, z)$ [43])。注意到這裡輸入矩陣的長度會依照如一張彩色圖像的 r、g、b 三種通道進行處理。可看到在 Figure 4.6 中為了提取 region 間不同距離的空間特徵，我們會同時用三種不同卷積核大小 $k_1 \times k_1$ 、 $k_2 \times k_2$ 、 $k_3 \times k_3$ 的卷積層，這些卷積核可依照資料特性進行調整，每層卷積層的通道數為 c ，並將他們按照下列公式 (4.10) 合併：

$$H = \begin{bmatrix} X^{conv k_1 \times k_1} \\ X^{conv k_2 \times k_2} \\ X^{conv k_3 \times k_3} \end{bmatrix} \quad (4.10)$$

其中 $H \in \mathbb{R}^{m \times n \times 3c}$ 為合併後的特徵。接下來，為了整合輸入矩陣 X_h 、 X_d 、 X_w 提取出的空間特徵 H_h 、 H_d 、 H_w ，我們實施一個融合機制來萃取出他們時空間的特徵 H_{hdw} ，該 Fusion 算法可被表示為：

$$H_{hdw} = w_h \otimes H_h + w_d \otimes H_d + w_w \otimes H_w \quad (4.11)$$

其中 $\otimes$ 為 element-wise multiplication， w_h 、 w_d 和 w_w 為可學習的權重，透過這個 Fusion 機制可以使模型能夠根據這些權重來調整 hourly、daily 和 weekly 三種關係的程度。

4.2.2.3 UNet

UNet 由 Ronneberger 等人[38]所提出，其架構圖顯示在 Figure 4.8 中。UNet 主要是以其網路形狀類似英文字母 U 而聞名，該網路全部由卷積層所構成，因此也可稱為所謂的 fully convolutional network(FCN)[42]。它由左側的收縮路徑和右側的擴展路徑所組成，每一個卷積層都搭載 3×3 的卷積核和 ReLU 激活函數。在收縮路徑中的 down sampling 由 2×2 的最大池化層負責處理，其會將特徵圖的長寬縮減並且將通道特徵數量加倍；而在擴展路徑中則會用 2×2 的 up sampling 將特徵圖的通道數量減半，並且會將在縮減路徑中對稱的特徵圖複製過來一併進行卷積來將特徵圖的大小還原。在最後一層會使用 1×1 的卷積層來進行最終的輸出。




Figure 4.8 U-net architecture

注意到，雖然該網路原先被設計用來做影像分割的任務，然而我們發現到該網路的架構也非常適合用來解決時空流量圖的預測問題，因為其架構能夠透過連續的卷積層有效地利用卷積核來提取輸入特徵中的空間的依賴性，如 Figure 4.9 中的多層卷積層範例中，我們可以發現，離預測結果越相近的卷積層可視為高水平的特徵圖，在高水平中的一個節點流量(紅色節點)，依賴於前一層特徵圖的 9 個鄰近節點，換句話說，每一層的特徵圖之中的節點都依賴於上一層水平特徵圖中鄰近的節點。因此，隨著卷積層層數的增加，模型就越可以提取特徵空間上遠近距離的依賴關係。




Figure 4.9 Convolutions

到目前為止，UNet 搭建的網路層數已經足以表達複雜的特徵，然而，越深的網路結構越有可能遇到梯度消失的問題[16]，或是導致神經網路的退化[34]，也就是神經網路無法有效傳遞過多的訊息，導致模型效能降低。因此為了解決上述問題，我們可以利用 UNet 對稱伸縮架構的特性，其架構可看作五層的對稱結構，左側收縮路徑的卷積層通道依序為 D、2D、4D、8D 以及 16D。這些 feature maps 透過 Figure 4.8 中標註的 skip connection path 將淺層卷積層的特徵圖直接傳遞給深層的卷積層做進一步的卷積提取特徵，此作法依據[22][45][48]證明其有效性。此外，在收縮路徑最後一層的輸出已經萃取出 high-level 的特徵，這個特徵可忽略原本人流特徵受限於空間上距離的限制，因此能夠更有效地捕獲人流全局的空間依賴性。然而，若將每個時段的 crowd flow images 直接輸入而沒有做任何處理，這會導致 UNet 在學習的過程中損失重要的時間相關的資訊，同時，目前的 UNet 在訓練時也無法參考外部因素造成的潛在影響。對此我們透過先前介紹的 External Learner 和 Spatial Temporal Learner 萃取的外部因素特徵 X_e 以及三種時空間特徵 X_h 、 X_d 、 X_w ，這些特徵會一併 concat 為 H_{hdwe} 輸入到 UNet 當中。

4.2.3 CFRBF-UNet: CF-UNet with RBF Transfer Learner

到目前為止，我們提出的 CF-UNet 模型已對人流資料的時空間依賴性擁有很好的建模性能。然而針對不同流量之間的性質差異，我們的模型還需要考慮如何藉由知識遷移來提升之後的預測表現。為了解決上述提及之問題，我們開發額外的時空間知識遷移學習 RBF Transfer Learner，並將其與 CF-UNet 結合成為 CFRBF-UNet 來改善模型遷移學習的能力，其模型架構圖顯示在 Figure 4.10 中。在這個架構中，我們會把額外把輸入特徵導入 RBF Transfer Learner 當中，因此整個網路會有三個 Feature Learner，一個負責萃取 flow image 的時空間的依賴性、一個負責捕捉 external factors 的資訊、一個則負責萃取所有輸入資料的遷移特徵。以下將對 RBF Transfer Learner 的實施細節進行說明。




Figure 4.10 CFRBF-UNet architecture

4.2.3.4 RBF Transfer Learner

為了賦予神經網路遷移學習的能力，也就是使模型能夠掌握豐富源資料的特徵分布，來更快進行新資料的遷移學習。對此我們將開發 RBF Transfer Learner 進行遷移特徵提取。如 Figure 4.11 所示，RBF Transfer Learner 的輸入為與 CF-UNet 相同的 X_{hdve} ，而 RBF Transfer Learner 提取後的遷移特徵 H_{rbf} 會一併輸入到 UNet。在 RBF Transfer Learner 當中，我們希望透過該 Learner 內部的 RBF 層以及卷積層能夠學習不

同的分布來做遷移學習，以解決前一部份所提及的缺點。




Figure 4.11 RBF transfer learner

具體而言，該模組裡的 RBF 層將對其輸入空間的特徵利用數個高斯分布擬和所有的輸入特徵分布，藉由這些模型學習資料分布的參數，來對新的資料做快速且有效的遷移學習。RBF 層的數學式如公式(4.12)所示：

$$RBF(x) = e^{-\beta(x-\mu)^2} \quad (4.12)$$

其中輸入 x 可表示為某個輸入空間(input space)的特徵向量。 β 和 μ are the learnable parameters。注意到這裡的 $\beta = (2\sigma^2)^{-1}$ ，我們將其簡化並省略 exponential function 的 the normalization constant 以提升神經單元的可學習性[3]。因此對於 RBF 層輸入輸出的維度，假設 RBF 層的神經單元數為 rs ，且輸入維度為 (m, n, q) 的矩陣，輸出維度則為 $(m, n, rs \times q)$ ，這裡的 q 為輸入矩陣 concat 起來的大小。對此模型會透過 RBF 層來學習相對應的平均為 μ 以及標準偏差為 σ 的高斯分布。也就是說，透過 RBF 層內部的特徵轉換，其可將輸入特徵轉換為數個具有不同平均和標準偏差的高斯分布。如 Figure 4.12 所示、假設設置 RBF 層的神經元的數量設置為 3，代表我們期望所有在 RBF 層裡學習到的混和分布能與輸入特徵的分布接近 μ_1, σ_1 、 μ_2, σ_2 和 μ_3, σ_3 這三組高斯分布，這三組高斯分布會將所有輸入空間的特徵向量分布包含在內。換句話說，高斯分布參數的

設置對於 RBF 層的訓練影響重大，因為其核函數的目的即是學習輸入特徵的分布。




Figure 4.12 RBF kernel mapping example

因此若是設置與輸入資料分布相近的參數可降低 RBF 的學習難度，但若是設置不適合的參數，也可能因為特徵的維度升高導致增加 RBF 訓練的難度[37]，對此我們會在 4.3.2 說明如何根據輸入訓練資料優化 RBF 的演算法。現在我們假設 Source 資料集與 Target 資料集的分布的直方圖如 Figure 4.13 所展示，這時模型就能透過 RBF 層掌握 Source 資料集的高斯分布 μ, σ ，這些學到的知識就能為接下來的遷移學習帶來幫助，模型能夠透過遷移學習更有效的調整符合 Target 數據集的高斯分布 μ', σ' 。




Figure 4.13 Source→Target distribution transfer

接下來，RBF 層的輸出會連接連續的卷積層，且 Conv 層與 Conv 層之間會使用 Squeeze-and-Excitation block(SE block)來連接彼此，其由 He[15]等人所提出，其細節

如 Figure 4.14 所示。SE Block 類似於一種基於卷積層 channel 的注意力機制，其功用可以賦予卷積層的通道不同的權重，進而達到篩選重要特徵的目的，來幫助模型提升特徵萃取的能力。我們透過該特性來使模型選擇通道中重要的 RBF 特徵。




Figure 4.14 A Squeeze-and-Excitation block

具體而言，假設 SE Block 的輸入是經卷積層後通道長度為 c 的特徵圖 $U = \{u_1, u_2, \dots, u_c\}$ ，首先會將特徵透過 Squeeze 來進行 global information embedding，這裡我們使用 Global Average Pooling (GAP) 對每個特徵圖 u_c 計算其 pixel 加總平均：

$$z_c = F_{sq}(u_c) = \frac{1}{m \times n} \sum_i^m \sum_j^n u_c(i, j) \quad (4.13)$$

其中 $z_c \in \mathbb{R}^{1 \times 1 \times c}$ 為 GAP 的輸出，其可代表模型對通道特徵的敏感度。接下來會進行 Excitation，在這個步驟我們會將 z_c 輸入到兩層 FC Layer 當中，一層負責降維來降低模型複雜度，一層則藉由升維以學習每個 channel 的權重，其公式可表示為：

$$s_c = F_{ex}(z, W) = \sigma(W_2 \delta(W_1 z)) \quad (4.14)$$

其中 $W_1 \in \mathbb{R}^{1 \times 1 \times (c' \times c)}$ 為第一層 FC layer 的權重， c' 為特徵縮減的比例。 δ 代表 ReLU function。第二層用來升維的 FC layer 其權重為 $W_2 \in \mathbb{R}^{1 \times 1 \times (c \times c')}$ ，此層輸出會經由 sigmoid function σ 將輸出值調整在 0~1 之間的門控機制而得到描述每個特徵圖重要程度的權重 $s_c \in \mathbb{R}^{1 \times 1 \times c}$ 。將該權重根據公式(4.15)進行相乘：

$$F_{scale}(s, u) = s_c u_c \quad (4.15)$$

注意到這裡會將每個特徵圖 u_c 與其對應的權重 s_c 進行 channel-wise multiplication。如此一來，重要的 channel 的特徵將透過權重被增強，而不重要的 channel 的特徵則會被權重所抑制。這些權重都是模型透過 squeeze 取得 channel 不同程度的重要性再將其做 excitation 而學習而來的。最終我們可從數量為 se 的連續 SE Block 取得 RBF Transfer Learner 最終的輸出 $H_{rbf} \in \mathbb{R}^{m \times n \times C}$ ，這個特徵包含了訓練資料的遷移知識資訊。而 Spatial Temporal Learner 的輸出 $H_{hdwe} \in \mathbb{R}^{m \times n \times C}$ 則富含了從訓練資料萃取的時空間特徵資訊，以及外部因素的特徵。我們會將兩個特徵相加輸入到 UNet 進行接下來的特徵提取和結果預測。

4.3 Algorithms of CFRBF-UNet

在此節中，我們先在 4.3.1 Optimization Algorithm 中說明如何根據訓練資料來優化 CFRBF-UNet 裡 RBF 層的初始參數值，接著在 4.3.2 Training Algorithm 中說明使用 Source 進行訓練的演算法，最後在 4.3.3 Fine-tuning Algorithm 中說明如何使用 Target 對 Source 訓練完成的 CFRBF-UNet 進行 Fine-tuning 的演算法。

4.3.2 Optimization Algorithm

先前我們介紹了本論文開發的 RBF Transfer Learner 來針對模型的遷移學習能力做改善，我們發現在此架構中，利用高斯分布來擬和輸入特徵分佈其在遷移學習的可行性，達到低時間成本且快速遷移學習的效果。並且我們也發現該方法中的 RBF 層在做遷移學習時，其參數還能夠做進一步的優化。一般類神經網路(Neural Network)會在訓練當中尋求最佳解，而學習最佳參數的方法是透過梯度下降法(Gradient descent, GD)按照損失函數(Loss function)的梯度不斷地學習更新參數來找尋最佳解。然而梯度下降法最大的問題就可能會在學習的過程中遇到局部最佳解(Local loss minimum)。因此，我們希望透過設置參數的初始值，使得模型能更快的收斂找到全局最佳解(Global loss minimum)。接著我們實際舉出例子來說明。假設模型已透過 RBF 層的數個高斯參數組學到 Source 資料集輸入到模型的特徵分布，接著準備將這些模型學到的知識

轉移到 Target 資料集中進行訓練，這時若 Source 資料的分布與 Target 資料的分布符合我們在 Figure 4.13 提及的狀況，模型便能很順利地進行遷移學習，但是這通常是在理想的情況當中。然而當 Source 資料的分布與 Target 資料的分布具有較大的差異時，也就如同在真實情況中像是疫情爆發等等的情形所產生的 Target 資料，這時如 Figure 4.15 所顯示的 Source distribution 以及 Target distribution 的資料分布情形具有較大的差異，模型若直接從 Source 分布的位置開始根據梯度下降法來更新參數，可能要花費較多的訓練成本，並且還有可能遇到局部最佳解的問題。假如我們能夠根據 Target 的分布來找到 RBF initial 的參數位置使得與輸入特徵的分布更接近。相較於隨機參數生成的位置需要花費 100 個 epoch，RBF initial 只要花 10 個 epoch 就能使模型更快收斂到達最佳解。




Figure 4.15 Set up RBF initial to accelerate model convergence

因此透過 RBF 層的作用可學習輸入特徵的分布，其中若能根據輸入特徵為 RBF 層找到一組合適的初始參數值，使得 RBF 層能夠在訓練過程中更快地掌握輸入特徵的分布，節省其訓練所花費的時間。對此我們介紹兩種 RBF 層的 initialization

algorithms, 分別為 4.3.1.1 RandomMean Initializer 和 4.3.1.2 GaussianMixture Initializer。

4.3.2.1 RandomMean Initializer

關於 RBF 層的初始值設置, 也就是對於 β 和 μ 這兩個可學習參數的初始值設置, 常見的作法像是隨機產生數值[21]或是隨機設置符合均勻分布的值[25]。然而這些初始器並不適用這裡的 RBF 層, 因為我們發現實際上輸入資料的分布有別於均勻分布, 如圖 Figure 4.16 所示。從這個例子我們可以發現其代表藍色點的輸入資料其數值範圍不一定在 0 與 1 之間均勻地分布, 而是落在大約 0.4 到 0.8 之間, 這時若以隨機生成初始值的方式並不恰當, 並且假設資料為均勻分布也不合適。




Figure 4.16 Example of RandomMean from input data

對此我們將使用 RandomMean 的方式來從 Source 資料中隨機 sample 數值如圖中紅色的點來當作 μ 的初始值。具體而言我們會依照每個 region 的三種時間序列進行隨機取樣。整體而言 RBF Transfer Learner 可為模型額外提供非線性擬和特徵的資訊以及特徵空間的轉換。另外, 在 RBF 層使用 RandomMean 能夠根據輸入特徵找到一組合適的初始參數值, 使得 RBF 層能夠在訓練過程中更快地掌握輸入特徵的分布, 節省其訓練所花費的時間。

4.3.2.2 GaussianMixture_INITIALIZER

在此節中，我們會用 Gaussian Mixture Model[31](GMM)來為 Target 訓練資料找到最合適的擬和模型，我們可以從 Figure 4.17 看到 GMM 擬和的成果範例。該擬和模型可將輸入特徵分解為若干基於高斯概率密度函數行程的模型，像是圖中的輸入特徵 x 被三組高斯模型的混和模型所逼近。




Figure 4.17 GaussianMixture fitting example

根據 GMM 的這種特性，非常符合我們設計 RBF Transfer Learner 的理念，因為這幾組高斯模型就能夠對應神經網路中 RBF 層的神經元個數。因此對於優化 RBF 的實際做法，我們會為每個 region 根據其量測到的人流量擬和一個 GMM。假設輸入長度為 N 且分布在一維空間的流量資料 $X_N = \{x_1, x_2, \dots, x_N\}$ ，我們找到由 M 個高斯常態模型組成的 GMM $G = \{g_1, g_2, \dots, g_M\}$ ，其數學式可表示如下：

$$p(x_N | G) = \sum_{i=1}^M w_i g_i(x_i) \quad (4.16)$$

$$g_i(x) = \frac{1}{(2\pi)^{1/2} \sigma} \exp\left\{-\frac{1}{2}(x-u)^2 \sigma^{-2}\right\} \quad (4.17)$$

其中 $g_i(x)$ 表示為第 i 個高斯常態分布的機率密度函數， w_i 為混和加權值，全部的加權

值總和為 1。我們可以將高斯混和模型的架構用 Figure 4.18 來表示之。常見 GMM 優化方法會透過 Expectation Maximization algorithm(EM)[11]更新每個高斯模型的參數 μ, σ 以及混和加權值來逼近輸入 X_N 的空間分布，如同 Figure 4.17 的範例所示。當 GMM 擁有與輸入特徵分布最大的相似度時，我們會將該 GMM 模型的參數轉移到 RBF 層的核函數對應的參數當中，使得模型在遷移學習時能夠快速地、精確地學習新的資料分布。透過設置參數的初始值的方法，針對模型知識轉移架構中的轉移速度及精準度進行優化的來為模型初始更新的參數對應位置能更接近全局最佳解的位置，使得模型能更快的學習輸入特徵的分布，以降低訓練成本並有良好的預測性能。




Figure 4.18 GMM Architecture

4.3.3 Training Algorithm

本節將說明模型使用 Source 進行訓練的流程。根據先前第三章的問題定義，我們會將資料分成豐富的 Source 資料集以及少量的 Target 資料集。我們首先會使用 Source 資料集來訓練一個模型，再將該模型學習到的知識遷移到 Target 資料集來做訓練以及預測。我們的模型 CFRBF-UNet 會根據三種時間序的流量矩陣以及外部因素特徵來預測未來第 t 時間的 crowd flow image，且我們會根據下列的公式 4.18 來評估預測結果與 ground truth 之間的誤差：

$$\text{loss}(X_t, \bar{X}_t) = \|X_t - \bar{X}_t\|_2^2 \quad (4.18)$$

根據該 objective function，我們的模型會最小化 predicted crowd flow image 和 true

crowd flow image 之間的 mean squared error。Algorithm 2 為 CFRBF-UNet 的訓練流程。該演算法的輸入 I 以及 O 已經在 4.1 節做說明， E 為對應時間的 external factors。而該演算法的輸出為一個使用 Source 資料集訓練完成的模型 f^S 。在演算法中首先我們會將 I 、 O 、 E 合併到 training instances 裡面(line1-line7)，接著我們會建構一個 CFRBF-UNet(line 8)，並且使用 RandomMean 為該模型的 RBF 層設置初始參數(line 9)。此模型的訓練會依照每筆 batch 進行更新(line 10-line13)，直到滿足停止訓練的條件後輸出訓練完成的模型(line 14)。

Algorithm 2: Model Training Algorithm

Input: Extracted time series $\mathbf{I} = \{i_1, i_2, \dots, i_n\}$, $\mathbf{O} = \{o_1, o_2, \dots, o_n\}$ from *Source*;
external factors: $\mathbf{E} = \{e_1, e_2, \dots, e_n\}$.

Output: Learned model f^S trained by source data.

```

1  SD  $\leftarrow \{\}$  // prepared training data
2  for  $i$  (1 to  $n$ ) do //  $n$  is the length of time series  $I$ 
3     $X_t \leftarrow O[i]$  // the target value at time interval  $t$ 
4     $X_h, X_d, X_w \leftarrow I[i]$  // three temporal dependent sequences
5     $e_t \leftarrow E[i]$  // the external factors at time interval  $t-1$ 
6    put a training instance ( $\{X_h, X_d, X_w, e_t\}, X_t$ ) into SD
7  end for
8  initialize Model  $f$ 
9   $f.RBF.mean \leftarrow \text{RandomMean}(I)$  // randomly pick values as mean parameters of RBF
10 repeat
11   randomly select a batch of training instances  $SD_b$  from SD
12   find  $f^S$  from  $f$  by minimizing the objective function (4.18) with  $SD_b$ 
13 until stopping criteria is satisfied
14 output the learned model  $f^S$ 

```

4.3.4 Fine-tuning Algorithm

本節將說明模型使用 Target 進行 Fine-tuning 的流程，其顯示在 Algorithm 3 中。演算法的輸入 I 以及 O 為從 Target 取出，且 E 為對應時間的外部因素， f^S 為前一節使用 Source 訓練完成的模型。此外我們使用此模型中的參數 θ 進行訓練。演算法的輸出為使用 Target 調整完的模型 f^S 。在演算法中首先我們會將 I 、 O 、 E 合併到 training instances 裡面(line1-line7)，接著我們會建構一個對 I 擬和的 GMM(line 8)，並且將這個 GMM 的參數轉移到 f^S 的 RBF 層當中(line 9)。此模型的訓練會依照每筆 batch 更新模型中的 θ (line 10-line13)，直到滿足停止訓練的條件後輸出調整完成的模型(line 14)。

Algorithm 3: Model Fine-tuning Algorithm

Input: Extracted time series $\mathbf{I} = \{i_1, i_2, \dots, i_n\}$, $\mathbf{O} = \{o_1, o_2, \dots, o_n\}$ from *Target*;
external factors: $\mathbf{E} = \{e_1, e_2, \dots, e_n\}$;
learned model f^S ;
trainable parameters: θ .

Output: Fine-tuned model f^S trained by target data.

```

1  TD  $\leftarrow \{\}$  // prepared training data
2  for  $i$  (1 to  $n$ ) do //  $n$  is the length of time series  $I$ 
3     $X_t \leftarrow O[i]$  // the target value at time interval  $t$ 
4     $X_h, X_d, X_w \leftarrow I[i]$  // three temporal dependent sequences
5     $e_t \leftarrow E[i]$  // the external factors at time interval  $t-1$ 
6    put a training instance ( $\{X_h, X_d, X_w, e_t\}, X_t$ ) into TD
7  end for
8   $G \leftarrow \text{GMM}(I)$  // fitting Gaussian Mixture Model
9  transfer the parameters of  $G$  to  $f^S$ 
10 repeat
11   randomly select a batch of training instances  $TD_b$  from TD
12   find  $\theta$  of  $f^S$  by minimizing the objective function (4.18) with  $TD_b$ 
13 until stopping criteria is satisfied
14 output the fine-tuned model  $f^S$ 

```

5. Experiment

本論文利用台灣台北市真實電信資料集以及台灣中央氣象局的觀測資料進行實驗來驗證提出方法的有效性及實用性，本章節共分兩大部分，第一部分在 5.1 Experimental Settings 中會介紹本論文研究使用的設定。第二部分 5.2 Experimental Results 則會呈現所有的實驗結果。在本研究中，all the experiments were implemented in python running Ubuntu 20.04 on 64-bit OS and an Intel Core i7-8700 processor at 3.2GHz with 6 cores, 64 GB of memory, and graphics card for EVGA GeForce GTX 1080 SC GAMING ACX 3.0.

5.1 Experimental Settings

在本節中我們將分成四個部分進行實驗設置的細節說明，其分別為 5.1.1 Suiting Dataset for Transfer Learning、5.1.2 Hyperparameters、5.1.3 Baselines 和 5.1.4 Evaluation Metrics。

5.1.1 Suiting Dataset for Transfer Learning

為了方便驗證所提出方法對於知識轉移的全市人群流量圖像預測的可行性與有效性，我們會將人流資料集分成三個 scenarios。對於每個 scenario，我們挑選較長的資料時間段當作 Source data，而少量的資料當作 Target data。並且在後續的實驗中我們會使用 Target data 資料中有限的人流數據做為測試資料(例如、1-day)。Table 5.1 描述三個 scenarios 的時間長度。以表中的 S2 來說，其 Source 的資料時間對應在台灣的氣候為冬天因此表示為 Winter，而 Target 的資料時間對應在台灣的氣候為夏天，這裡我們挑選第 7 月份的人流資料其表示為 Summer(7)。我們可以知道這兩種資料的差異與先前在第一章所提及之流量差異狀況相同，如 Figure 5.1 的範例流量所示。表中 S2 的最大流量差異 $\text{Max } \Delta = 268\%$ ，這個數值代表在 scenario 2 當中有某個 region 他的 Source 和 Target 兩者有著最大的流量差異，這個 region 的 Source 平均值與 Target 的平均值差異為 268%。

Table 5.1 Scenario Data

Scenario	Source → Target		Max Δ
S1	Summer → Winter(12)		+113%
	Summer: 06/01/2018-08/31/2018, 06/01/2019-08/31/2019	Winter: 12/01/2019-12/31/2019	
S2	Winter → Summer(7)		+268%
	Winter: 11/30/2018-02/28/2019	Summer: 07/01/2019-07/31/2019	
S3	Summer → Winter(2,3)		+97%
	Summer: 06/01/2018-08/31/2018, 06/01/2019-08/31/2019	Winter: 02/01/2020-03/31/2020	




Figure 5.1 Crowd flow difference in Scenario 2

因此，我們從資料集挑選的這三個 Scenario 其 Source 和 Target 都擁有相當程度的差異，我們會利用這些資料的特性來評估模型在遷移學習的表現。首先我們會使用豐富的 Source 來訓練一個 CFRBF-UNet，之後使用從 Target 中取出資料筆數為 24 筆(1-day)、72 筆(3-day)和 168 筆(7-day)的少量資料對模型 Fine-tuning，剩下的資料則當作測試資料。

另外我們會額外挑選 Figure 5.2 中的 regions 來顯示其預測的表現，這些地區的特性能夠幫助我們進一步的驗證所提出模型優越的性能。圖中的三個 region r1、r2 以及 r3 實際上就是在 Table 5.1 中 Max Δ 的 regions，其中 r1 的 Max Δ 為 +113%，r2 的

Max Δ 為+268%，r3 的 Max Δ 為+97%。這些 regions 都是在每個 scenario 中 Source 和 Target 差異最大的地區，它們的位置顯示在 Figure 5.2 中。因此我們會挑選這些區域來評估使用 Source 進行訓練的 CFRBF-UNet 對 Target 進行遷移學習的預測表現。




Figure 5.2 Locations of r1, r2, r3, k1, k2, k3



Figure 5.3 Kernel k1



Figure 5.4 Kernel k2



Figure 5.5 Kernel k3

此外，根據卷積層中大小為 3×3 的卷積核提取人流的空間依賴性，換句話說模型會依靠同樣的 3×3 卷積核來提取 9 個不同 regions 的人流量，如果這 9 個鄰近的 regions 的流量差異大可能影響模型最終的預測性能。為了方便觀察我們可將 3×3 regions 看作是一個 kernel。我們依照 kernel 內部最大平均流量的 region 和最小平均流量的 region 的差異為所有 kernels 進行降冪排序之後，挑選前三個 kernel k1、k2 和 k3 展示其的

預測結果，他們的位置顯示在 Figure 5.2 中。而他們的細節展示在 Figure 5.3、Figure 5.4、以及 Figure 5.5 中。這些地區的細節可以方便驗證我們的模型在 3×3 卷積核範圍內的預測表現。

5.1.2 Hyperparameters

對於訓練模型的參數設置，我們會根據測試資料集的性能設置超參數。首先訓練資料的 Batch size 為 32，訓練的 epoch 數為 1000，我們也加入 Early Stopping 的機制，當模型有 20 次 epoch 無進步時將提前終止訓練。所有模型的 loss 函數為 mean-square error(MSE)，並以初始 learning rate 為 0.0001 的 Adam 優化器進行迭代優化，且每個模型的最後一層卷積層的輸出都會使用 ReLU 激活函數，來當作最終的預測。此外，輸入外部因素的 embedding 層的維度統一設置為 128。最後，本研究依照時間排序資料集，使用前 80% 資料集做為訓練資料集，10% 作為驗證資料集，以及最後 10% 作為測試資料集，並且資料集所有數值都會正規化成 0 到 1。對於 CFRBF-UNet 的超參數設置，we set the lengths of the three temporally dependent sequences as $l_h = 6$, $l_d = 3$, and $l_w = 3$ ，Spatial Temporal Learner 的通道數 c 設為 16，該 Learner 合併後輸出的通道數為 48，此特徵會直接取代 UNet 第一層通道數為 64 的卷積層，且 RBF 神經元數量 rs 設置為 3，且我們設置 SE Block 的縮減比例 $c' = 0.25c$ ，層數 $se = 6$ ，其內部的卷積層大小都為 3×3 with 64 filters。

5.1.3 Baselines

接下來會介紹用來比較的 baselines 模型以及相關的實驗的設置。

- **TFFNet:** Traffic Flow Forecasting Network(TFFNet)由 Sun 等人[44]所提出，是一個用於全市交通流量預測的 deep convolutional neural network。我們參考他們在論文的設置將卷積層大小設為 3×3 with 64 filters，其中 residual unit 的單元數設置為 12。

- **STResNet:** Deep Spatio-Temporal Residual Networks(STResNet)由 Zhang 等人[58]所提出，是一個用於全市人群流量預測的模型。為了公平性我們同樣為該模型的每個卷積層大小設為 3×3 with 64 filters，其中三層平行網路的 residual unit 的單元數都設置為 12。
- **LDRSN:** Local-Dilated Region-Shifting Network(LDRSN)由 Tian 等人[46]所提出，是一個用於人流預測的深度網路。我們參考原論文的設置將該模型的 Dilated module 設置三個擴張單元，其對應的 dilation factors 設置為 2, 3, 5，而在 Local module 設置三層大小為 3×3 with 64 filters 的卷積層。為了設置同樣的特徵圖長度，我們為模型的 ConvLSTM 的卷積設為 1×1 with 32 filters，短期 temporal fragment 設置為 6 小時，長期時間段設置為 3 天，因此最終合併的卷積特徵通道長度為 64。
- **UNet:** U 型的 Fully Convolutional Network 由 Ronneberger 等人[38]所提出，在此 UNet 的 contracting path 參考原論文的設置，其 D 的特徵數量為 64，因此其收縮路徑的卷積大小依序為 64、128、256、512 以及 1024。

5.1.4 Evaluation Metrics

為了評估所有模型的預測表現，我們使用兩種評估函數來評估他們的預測表現，分別是 Mean Absolute Error (MAE)以及 Mean Absolute Percentage Error (MAPE)，他們的計算公式如下：

$$MAE = \frac{1}{n} \sum_{k=1}^n |X_k - \bar{X}_k| \quad (5.1)$$

$$MAPE = \frac{1}{n} \sum_{k=1}^n \frac{|X_k - \bar{X}_k|}{X_k} \quad (5.2)$$

其中 n 代表測試資料集的數量， X_k 為 ground truth， $\bar{X}_k$ 則為預測值。MAE 用於評估

模型的預測值以及實際值之間的絕對值誤差平均，MAPE 則表示平均絕對誤差對於實際值的比率。因此 MAE 更適合來描述一個預測結果的差距，其小數位也不容易被忽視，而 MAPE 則可提供該誤差實際所佔的比例，其可以更具體的了解預測結果誤差與實際值之間的比率。

5.2 Experimental Results

在此節會介紹本研究所有的實驗結果，我們將其分為三個部分進行說明以及討論，分別為 5.2.1 Source Data Only Performance、5.2.2 Target Data Performance，以及 5.2.3 Optimization results of RBF Transfer Learner。

5.2.1 Source Data Only Performance

在此節中所有的實驗結果都只使用豐富的 Source Data 進行訓練，注意到這裡的 Source Data 是使用 Table 5.1 的 Summer 和 Winter 資料。接下來的實驗將分成兩個部分：5.2.1.1 Evaluation of Prediction Accuracy 和 5.2.1.2 Results of Different CFRBF-UNet Variations。

5.2.1.1 Evaluation of Prediction Accuracy

我們在 Table 5.2 中展示了所有模型使用 Source Data Only 的比較結果。首先我們觀察到 TFFNet 的 MAE 以及 MAPE 都比 STResNet 還要高，這是因為 TFFNet 缺乏考慮三種時間依賴性之間的重要程度。另外這兩個模型被設計的輸出同樣地都有一半的貢獻來自於外部因素的特徵，這會使模型容易忽略重要的人流特徵，因此它們的誤差都較高。而 LDRSN 的預測結果就不會因為受外部特徵因素影響而增加誤差。UNet 的實驗結果表明了該模型的特性能夠以更有效的方式捕獲全市人流的空間依賴性，而我們的 CF-UNet 能夠為 UNet 提供更有效的方式捕獲時間依賴性。另外 CFRBF-UNet 主要是被設計來應付接下來的遷移學習，可看到該模型的性能能夠維持與 CF-UNet 一致，因此該表的實驗結果能夠這清楚地表明我們的方法捕獲特徵空間與時間的依賴性都獲勝。

Table 5.2 Model comparison on Source data

Source Data Only	Summer		Winter	
	MAE	MAPE	MAE	MAPE
TFFNet	15.8	6.28%	20.1	7.08%
STResNet	15.5	6.94%	18.7	6.52%
LDRSN	14.2	5.24%	15.9	5.61%
UNet	13.2	5.31%	16.8	5.91%
CF-UNet	10.6	4.47%	14.7	5.41%
CFRBF-UNet	10.1	4.41%	14.6	5.33%

接下來我們展示了 CFRBF-UNet 對於單個 region 的預測精度表現。為了克服先前在 Chapter 1 提及之全市預測的困難之處，CFRBF-UNet 需能同時預測全市所有的 region 的未來流量，而這些 region 各自都有著不同的流量性質。因此我們根據 Figure 1.3 中四個捷運站的位置顯示他們附近 region 的預測結果。首先 Figure 5.6 展示同時預測高流量和低流量的預測精度。




Figure 5.6 Small flow vs. Big flow: (a) Zhongyi Station; (b) Zhongxiao Fuxing Station

相較於位置在台北首都附近的 Zhongxiao Fuxing Station，離台北首都較遠的 Zhongyi Station 普遍日常的人數更為稀少，他們之間的流量差異可高達 1000 倍。而在圖中我們可發現他們的灰色線(prediction)和黑色線(groundTruth)幾乎重疊，這代表模型能夠同時學習到這兩個區域的流量變化。然而模型在低流量 region 的 MAPE 為 6.6%，其高於高流量區域的 MAPE 為 1.9%，這是因為預測誤差在小範圍的流量中更容易被強調，整體來說模型對於數值範圍小和數值範圍大的區域都能有很好的預測精度。




Figure 5.7 Similar pattern vs. Different flow: (a) Huzhou Station; (b) Jingmei Station

Figure 5.7 展示同時預測具相似模式但流量大小不同區域的預測精度。Figure 5.7 (a) Huzhou Station 和 Figure 5.7 (b) Jingmei Station 兩站附近 region 人流起伏具有相似的模式，然而他們之間的距離卻很遠。此外，Huzhou Station 的流量數值範圍普遍落在 50~150，但 Jingmei Station 的流量數值範圍普遍落在 2500~4000，兩站的流量數值範圍差異較高。這些性質都會影響模型的預測性能。模型在 Huzhou Station 的 MAPE 為 6.0%，MAE 為 5.9，Jingmei Station 的 MAPE 為 1.6%，MAE 為 55.2。我們可發現他們的灰色線(prediction)和黑色線(groundTruth)也幾乎重疊，這代表模型能夠同時捕捉到這些區域的空間依賴性與時間依賴性。整體而言，此節的實驗結果不僅能夠表明我

們提出的模型性能優於 baselines，也能夠表明我們的模型能夠有效地從全市人流萃取出有用的特徵，準確地預測每個 region 的人流量。

5.2.1.2 Results of Different CFRBF-UNet Variations

在此節我們會使用 Source Data 來評估 CFRBF-UNet 內部元件的相關參數所帶來的影響，包含了(1) Results of different layers of UNet、(2) Results of different input structure of CFRBF-UNet、(3) Results of External factors evaluation，以及(4) Results of different RBF Transfer Learner setting。

- Results of different layers of UNet

首先我們為驗證 UNet 內部的層數帶來的影響，我們按照 Figure 4.8 的 UNet 架構將其拆解為 5 個部分來進行實驗，Table 5.3 顯示這五個實驗結果。表中 UNet(1/5)的架構包含左側收縮路徑的第一層以及右側擴張路徑中上方對稱的第一層，兩者之間以 skip connection 連接，其中 downsampling 的特徵會直接輸入到 upsampling 層進行卷積運算產生最終的預測值。我們可從表格看到使用第一層的 UNet 其 MAE 為 15.4，MAPE 為 5.8%，模型使用的參數量為 0.9M，而隨著層數的增加，UNet 所使用的參數量也會越多，值得注意的是，其誤差最終降低至 MAE 為 10.1，MAPE 為 4.41%。

Table 5.3 Results of different layers of UNet

CFRBF-UNet(* / 5)	MAE	MAPE	Ptr.Size
UNet(1/5)	15.4	5.80%	0.9M
UNet(2/5)	12.6	5.20%	1.7M
UNet(3/5)	12.3	5.10%	4.6M
UNet(4/5)	11.1	4.60%	16.5M
UNet(5/5)	10.1	4.41%	31.7M

因此，這項實驗可以使我們清楚地了解到，UNet 的收縮路徑和擴張路徑中的特徵可以捕捉到人流更全局的空間依賴性，並且這個關鍵的模型結構可以彌補模型受限於卷積核大小來考慮不同距離的人流關係，讓最終模型的性能有所提升。此外我們可以透

過彈性調整 UNet 的層數來為模型準確度以及所使用參數量兩者之間找到一個可接受的參數設定值。

- Results of different input structure of CFRBF-UNet

接下來我們嘗試了解模型輸入中的不同時間對於最終的預測所帶來的影響，其實驗結果顯示在 Table 5.4 中。表中 CFRBF-UNet 預設的輸入為 Hourly、Daily 和 Weekly，三種時間序列，其預測的 MAE 為 10.1，MAPE 為 4.41%。我們首先將模型 CFRBF-UNet_HD 去除 Weekly 的時間序列進行比較，可發現其 MAE 升至 11.5，MAPE 升至 4.78%，此實驗結果表明模型考慮週期性的資料可為最終的預測性能帶來良好的提升。另外模型 CFRBF-UNet_H 去除了 Daily 和 Weekly 兩種時間序列的輸入，導致模型無法捕捉到更長遠的時間依賴性的相關特徵，因此無法擁有良好的預測性能，其 MAE 上升至 22.3，MAPE 為 9.01%。這項實驗證實了在 4.2.2 中提及的 Spatial Temporal Learner 的有效性。

Table 5.4 Comparison of the different input structure of CFRBF-UNet

Model	Input Data Structure			MAE	MAPE
	Hourly	Daily	Weekly		
CFRBF-UNet	■	■	■	10.1	4.41%
CFRBF-UNet_HD	■	■		11.5	4.78%
CFRBF-UNet_H	■			22.3	9.01%

- Results of External factors evaluation



接著我們也評估外部因素為最終預測所帶來的影響，我們將外部因素的資料與相關的參數從 CFRBF-UNet 中移除，並與原本的 CFRBF-UNet 進行比較，其實驗結果顯示在 Table 5.5 中。表中的 CFRBF-UNet_no_ext 模型為去除 External Learner 後的實驗結果，其 MAE 為 12.3，MAPE 為 5.11%，這兩個誤差均大於原本摘除外部因素前的模型。因此，我們可以了解到 External Learner 對於模型考慮外部因素來產生預測值有所貢獻，並且該實驗結果可表明為模型融入外部因素在一定程度上提高了模型的性能，這結果與我們在 Figure 1.4 中所提及之狀況一致。

Table 5.5 External factors evaluation

Model	Description	MAE	MAPE
CFRBF-UNet	with external	10.1	4.41%
CFRBF-UNet_no_ext	without external	12.3	5.11%

- Results of different RBF Transfer Learner settings

最後我們也為 RBF Transfer Learner 中的參數設定進行相關的實驗。首先我們在 Figure 5.8 呈現不同 RBF 神經元數量的實驗結果。我們實際在 RBF 網路的 rs 設置為 1、3、5 以及 7。當 $rs = 1$ 時 RBF 網路只能透過單個核函數來擬和具一定複雜程度的人流，但是單個核函數的非線性擬和能力效果有限，而當 $rs = 3$ 時模型的誤差有降低，注意到這兩種不同的設置對模型影響較小的原因是因為我們所提出的模型不會過於依賴 RBF Transfer Learner 的輸出特徵 H_{rbf} ，因為模型還會考慮 Spatial Temporal Learner 的輸出特徵 H_{hdwe} ，這個設計可以減輕 RBF 網路擬和特徵非線性關係的壓力。

Figure 5.8 Numbers of rbfSize(rs) vs. MAEFigure 5.9 Numbers of SE blocks(se) vs. MAE

然而，若將 rs 設置過高也容易導致 RBF 網路因為特徵升維而增加整體模型的複雜度，影響模型性能，可看到如圖中 $rs = 7$ 時對於模型整體的預測性能影響較大。從 Figure 5.8 的實驗結果中我們選擇最好的 $rs = 3$ 的實驗結果作為模型預設的參數設定值。另外我們在 Figure 5.9 呈現不同 SE Block 數量的實驗結果。一般來說，越深層的網路可顯著地提高特徵提取能力。SE Block 搭配卷積層最大的優勢為能夠考慮到特徵圖中不同通道的資訊，然而同樣地，隨著網路層數的增加也會導致更高的計算成本。因此

在 Figure 5.9 中我們選擇 $se = 6$ 作為模型默認的設置。

5.2.2 Target Data Performance

在此節我們會加入 Target Data 來評估前一節使用 Source Data 進行訓練的模型進行 Fine-tuning 的預測性能。我們將根據 Table 5.1 的三種 scenarios 來呈現其實驗結果。首先 Scenario 1 的 Table 5.6 為 Summer 模型對 Winter(12)Fine-tuning 後的實驗結果，這些模型在進行遷移學習之前與 Table 5.2 中 Summer 模型一致，而我們使用從 Winter(12)切分出來的長度為 1 天、3 天以及 7 天的訓練資料進行第二次的訓練，並使用 Winter(12)剩餘的測試資料進行評估。

Table 5.6 Model comparison on S1:Summer→Winter(12)

Scenario	S1: Summer → Winter(12)					
Model	1-day		3-day		7-day	
	MAE	MAPE	MAE	MAPE	MAE	MAPE
TFFNet	19.5	7.35%	14.5	5.83%	15.2	6.16%
STResNet	20.5	7.81%	15.4	6.15%	16.1	6.49%
LDRSN	15.8	5.85%	14.8	5.63%	15.1	6.01%
UNet	15.4	5.81%	13.2	5.32%	14.2	5.67%
CF-UNet	13.5	5.41%	11.9	4.87%	13.1	5.31%
CFRBF-UNet	13.0	5.31%	11.1	4.54%	12.6	5.18%

表中 TFFNet 與 STResNet 的模型性能不佳，尤其在只使用 1-day 進行 Fine-tuning 時最為明顯，這些模型因為少量的資料而無法擁有良好的模型性能。而 LDRSN 與 UNet 模型用少量的資料就有不錯的表現，而 CF-UNet 的表現比起上述提及之模型性能都還要更佳，因為 CF-UNet 在萃取時間與空間的依賴性都擁有良好的性能。表中表現最好的為本研究所提出的 CFRBF-UNet，該模型透過 RBF Transfer Learner 可比其他模型都更能夠掌握少量資料的資訊，並利用其資訊有效地使預測性能提升。

Table 5.7 Model comparison on S2:Winter→Summer(7)

Scenario	S2: Winter → Summer(7)					
Model	1-day		3-day		7-day	
	MAE	MAPE	MAE	MAPE	MAE	MAPE
TFFNet	24.6	9.81%	17.9	7.63%	15.9	6.83%
STResNet	24.8	9.86%	27.6	10.34%	16.6	6.88%
LDRSN	15.7	6.23%	14.7	5.79%	13.6	5.31%
UNet	16.5	6.51%	15.3	6.18%	13.5	5.47%
CF-UNet	16.3	6.34%	14.9	5.89%	12.9	5.27%
CFRBF-UNet	15.5	6.08%	14.1	5.63%	12.2	5.04%

Scenario 2 的 Table 5.7 為 Winter 模型對 Summer(7)進行 Fine-tuning 後的實驗結果。表中 TFFNet 與 STResNet 同樣因為只使用少量資料進行訓練因此無法取得良好的預測表現，但是 LDRSN 因為該模型的 short-term temporal module 更著重考慮鄰近時間的特徵，因此少量的訓練資料並不會對該模型造成太大的負面影響。而我們可以看到使用 1-day 的 UNet 與 CF-UNet 模型性能相差無幾，且比 LDRSN 的表現更差，原因是因為 Summer(7)的資料與 Winter 差異的程度較高，所以增加其遷移知識的難度，但是當 CF-UNet 使用 7-day 進行訓練時，該模型就能夠掌握特徵更長遠的時間依賴性而擁有良好的預測性能。

Table 5.8 Model comparison on S3:Winter(2,3) Only

Scenario	S3: Winter(2,3) Only					
Model	1-day		3-day		7-day	
	MAE	MAPE	MAE	MAPE	MAE	MAPE
TFFNet	263.3	69.11%	78.2	26.71%	49.6	18.52%
STResNet	1782.4	620.44%	195.2	61.50%	205.3	65.67%
LDRSN	94.2	36.11%	37.3	12.14%	24.1	10.91%
UNet	64.5	24.88%	41.8	13.17%	27.8	15.43%
CF-UNet	148.7	59.17%	119.5	39.41%	54.7	25.84%
CFRBF-UNet	140.6	39.91%	125.1	38.72%	87.2	32.16%

而最好模型同樣為 CFRBF-UNet，該模型在 1-day 時所擁有的良好性能與其他模型比較最為明顯。因此透過這兩個 Tables 的實驗結果我們可以明確地了解到 CF-UNet 中的 Spatial Temporal Learner 能夠有效增強 UNet 提取時間與空間的特徵，而 CFRBF-UNet 中知識遷移的能力能夠有效地從少量的訓練資料中取得良好的模型性能。

Table 5.9 Model comparison on S3:Summer→Winter(2,3)

Scenario		S3: Summer → Winter(2,3)				
Model	1-day		3-day		7-day	
	MAE	MAPE	MAE	MAPE	MAE	MAPE
TFFNet	16.5	6.62%	19.2	7.73%	12.1	6.20%
STResNet	21.4	8.47%	18.7	7.34%	14.7	8.33%
LDRSN	16.1	6.02%	17.9	6.24%	10.2	5.23%
UNet	14.5	5.72%	15.3	5.73%	10.7	5.52%
CF-UNet	13.9	5.55%	14.5	5.64%	9.9	5.16%
CFRBF-UNet	13.1	5.36%	13.6	5.42%	9.3	4.94%

Scenario 3 的相關實驗展示在 Table 5.8 和 Table 5.9 當中。首先我們在 Table 5.8 展示所有模型不使用遷移學習而只使用 Winter(2,3)中的 1 天、3 天以及 7 天的資料進行訓練的實驗結果，這些模型先前都還沒有經過任何訓練。表中除了 UNet 和 LDRSN，其他模型都無法擁有良好的預測性能，因為訓練資料過於稀少，且沒有任何的知識遷移來幫助訓練，表中 CFRBF-UNet 的模型性能也不理想，這是因為我們為其針遷移學習所開發的網路會增加整體模型的複雜度，若無依靠相關知識的遷移將難以用少量的資料進行訓練。而 UNet 與 LDRSN 因為其模型的特性，所以在 3-day 以及 7-day 資料時就能夠使模型收斂至一定程度。因此這項實驗可展現 UNet 更易於訓練的特性，並且若沒有依靠 Source 帶來的知識進行遷移學習，模型很難只依靠少量的資料來捕捉異常流量複雜的特徵關係。另外看到 Table 5.9 為 Summer 模型對 Winter(2,3)進行 Fine-tuning 後的實驗結果。透過這兩個 Tables 的比較我們可以知道對於同樣 1 天、3 天以及 7 天的測試資料 Winter(2,3)其遷移學習前後的性能差異。同樣地，這些實驗結

果表明了我們所提出的模型 CF-UNet 以及 CFRBF-UNet 良好的模型性能。

接下來我們評估 CFRBF-UNet 基於遷移學習對於單個 region r1、r2 以及 r3 的預測精度表現，這些地區先前在 5.1.1 提及過。Table 5.10 為 r1、r2 以及 r3 的實驗結果，其中 Before transfer 表示我們使用 Source 訓練完且尚未進行 Fine-tuning 的 CFRBF-UNet 來預測這些區域的 Target 測試資料，而 After transfer 表示我們的模型使用 1-day 的 Target 訓練資料進行 Fine-tuning 後再預測這些區域的 Target 測試資料。

Table 5.10 Comparison of Before and After transfer in proposed three regions

Region	region 1		region 2		region 3	
	MAE	Δ	MAE	Δ	MAE	Δ
Before transfer	34.8		82.1		19.1	
After transfer	22.8	-34%	27.4	-67%	16.6	-13%

從表中我們可以看到 r1 在 before transfer 的 MAE 原本為 34.8，再經過 Fine-tuning 之後其 MAE 下降至 22.8，其誤差降低了 34% 左右，而 r2 在 before transfer 時有相當高的 MAE 為 82.1，這個數值可以使我們知道 region 2 的 Source 和 Target 的流量差異使得 Source 訓練完的模型無法直接準確地預測 Target，與我們在 Chapter1 提及之困難點一致。在使用 1-day 的資料 Fine-tuning 之後 region 2 的 MAE 下降至 27.4，其誤差降低了 67% 左右。然而透過深度學習強大的學習能力，使得其模型仍然能夠應付一定程度流量差異的預測任務，像是 r3 在 before transfer 的 MAE 原本為 19.1，其已經有著不錯的預測性能，而再經過 Fine-tuning 之後其 MAE 下降至 16.6，其誤差降低了 13% 左右。另外我們也在 Figure 5.10 中展示這三個區域 Before transfer 和 After transfer 的誤差分布曲線。Figure 5.10 中的誤差分布越靠近中間 0 的位置且形狀越細長代表有越多預測值的誤差趨近於 0，因此透過這個誤差分布可從另外的角度觀察模型的預測性能。Figure 5.11 為他們的預測人數與 ground truth 的比較。從圖中 region 2 的預測結果能夠清楚地了解透過少量的資料進行遷移學習的模型能夠有效地將其預測水平往上提升，並減少預測的誤差。




Figure 5.10 Error distributions of Before and After in proposed three regions




Figure 5.11 Predictions of Before and After in proposed three regions

接著是 Figure 5.2 中 kernel 1、kernel 2 以及 kernel 3 的預測結果。首先 kernel 1 的預測結果顯示在 Figure 5.12 中，在此我們也比對 Figure 5.3 中 kernel 1 的細節進行探討。首先在 k1 內部的 regions 中，k1(2,1)購物區擁有最大的平均流量其高達 8911 人，而最小的 region 為 k1(1,2)住宅區其平均為 468 人，我們可從圖中的誤差分布曲線觀察到 TFFNet、STResNet 和 LDRSN 都無法同時對這兩個 region 擁有良好的預測性能。而我們的 CFRBF-UNet 在這 9 個 regions 都能取得良好的預測性能，這代表我們模型的結構能夠有效克服 3x3 卷積核大小的限制，萃取出更全局的空間依賴性。而 TFFNet 和 STResNet 僅能在部分 regions 準確地預測，他們無法考慮所有 regions 的關係。西相較之下 LDRSN 在 k1 中普遍都能夠擁有不錯的預測結果，但是當 region 的平均越大，其預測的精度也隨之下降。




Figure 5.12 Error distributions of kernel 1

接下來 kernel 2 的預測結果顯示在 Figure 5.13 中，而其地理細節顯示在 Figure 5.4 中。我們可看到在 k2 內部的 regions 中，k2(1,0)住宅區擁有最大的平均流量 7769 人，且 k2(2,1)購物區也擁有較高的平均流量 7581 人，而最小的 region 為 k2(2,0)Park 其平均僅有 272 人。首先 k2 表現出與 k1 不同的流量模式。其預測結果中，TFFNet 和 STResNet 在 k2(0,1)和 k2(1,0)都能準確預測他們的高人流量。然而，他們卻無法準確預測擁有較低人流的 k2(0,0)和 k2(1,1)。而 LDRSN 雖然在中心點 k2(1,1)表現良好，但是 LDRSN 無法同時在高流量的 k2(2,1)和低流量的 k2(2,2)維持預測精度。我們的 CFRBF-UNet 在最大流量的區域和最小流量的區域都能有最好的預測性能，並且在其他 regions 也擁有良好表現。




Figure 5.13 Error distributions of kernel 2

最後是 kernel 3 的預測結果顯示在 Figure 5.14 中，他的地理資訊顯示在 Figure 5.5 中。我們可看到在 k3 內部的 regions 中，k3(1,0)購物區擁有最大的平均流量 9344 人，而鄰近下方的 k3(2,0)觀光區其平均僅有 1917 人。相較於其他模型，我們的 CFRBF-UNet 可以克服鄰近區域流量差異的問題，做到同時在這兩個區域取得良好的預測精度。此外，相較於 k1 和 k2，在 k3 中普遍都擁有較高的人流量。所有模型在此 kernel 的誤差分布曲線都趨近 0，而我們的 CFRBF-UNet 在所有的 regions 都獲勝，且展現了明顯的優勢。




Figure 5.14 Error distributions of kernel 3

5.2.3 Optimization results of RBF Transfer Learner

在此節我們會針對 CFRBF-UNet 的 RBF Transfer Learner 的轉移速度以及預測精準度進行優化，並展示其優化後的實驗結果。首先我們評估 RBF Transfer Learner 使用三種初始器 RandomUniform、RandomMean 和 GaussianMixture 的訓練結果。Figure 5.15 為使用這三個初始器進行訓練的 Learning Curve。我們可以看到圖中灰色的學習曲線一開始的學習位置就不適當，此時模型為了收斂繼續不斷的更新參數，但是經過了約一百次的 epochs 後模型只能收斂在較高 loss 的位置，這是因為 RandomUniform 隨機從 0 到 1 之間挑選的參數可能導致模型無法很好地收斂，如同我們在第一章提及之問題。不好的初始參數設置可能導致模型陷入局部最佳解，使得模型無法擁有良好的預測性能。透過這項實驗我們能夠得知 CFRBF-UNet 可能因為其參數初始值設置不佳而無法很好地收斂，並且透過這個學習曲線我們也可以知道 RBF 核的初始參數設置對於整個 CFRBF-UNet 後續訓練是否能夠收斂影響程度非常大。




Figure 5.15 Examples of poor convergence of initial parameter settings

我們接下來為三個優化器挑選使用 Source 訓練後結果較一致的學習曲線圖，如 Figure 5.16 所示。這三個使用不同初始器所訓練出來的 CFRBF-UNet 有著相同的預測性能，然而我們可從圖中看到三種學習曲線在第 1 個 epoch 開始的 loss 不相同，RadnomUniform 的初始 loss 非常高，他需要花費更多的時間才能收斂到較佳的 loss，

而 RandomMean 因為能依據訓練資料來隨機生成初始參數，因此其學習的初始 loss 較低。而 GaussianMixture 設置的初始參數有著最低的 loss，這是因為透過對訓練資料的分布建立的 GMM 模型能夠掌握更全局的參數位置。




Figure 5.16 Learning curves of training CFRBF-UNet

我們從 Table 5.11 可看到這些訓練過程實際產生最佳 loss 所花費的 epochs。RandomUniform 花費了 190 個 epochs 取得最低的 loss，而 RandomMean 花費 168 個 epochs 取得最低的 loss，其節省了約 13%，GaussianMixture 花費 156 個 epochs 取得最低的 loss，其節省了 20%。因此，透過這項實驗我們可以知道比起隨機的設定初始餐，根據訓練資料來為模型設置的參數更能夠使模型在訓練時有效地收斂至最佳的 loss。然而考量所花費時間而言，RandomUniform 和 RandomMean 的時間複雜度皆為常數 $O(1)$ ，其能夠很快地為模型設置初始參數，但是 GaussianMixture 所花費的時間複雜度會根據其 GMM 最佳化的更新次數 EM 以及分群數量 G 和輸入資料筆數 N 而增加。因此若考量到收斂時間，使用豐富的 Source 訓練時不宜使用 GaussianMixture 來設置參數初始值，因為其花費的時間相較於 RandomUniform 和 RandomMean 非常長。因此我們會使用 RandomMean 來為使用 Source 訓練的 CFRBF-UNet 設置初始參數，而在遷移學習時，我們會使用 GaussianMixture 來為 CFRBF-UNet 設置一組針對 Target 的分布更全局的參數位置。

Table 5.11 Best Epoch of Three Initializers

CFRBF-UNet	Best_Ep	Δ	Complexity
RandomUniform	190	-	$O(1)$
RandomMean	168	-13%	$O(1)$
GaussianMixture	155	-20%	$O(EM * G * N)$

接下來為了進一步驗證 RBF Transfer Learner 對於 CFRBF-UNet 的有效性。我們嘗試僅透過 RBF Transfer Learner 進行 Fine-tuning 而非使用全部模型進行 Fine-tuning。首先我們在 Figure 5.17 比較這兩者所使用的參數量，CFRBF-UNet 全部的參數量為 31.7M，RBF Transfer Learner 的參數量為 0.7M，其參數量只有 CFRBF-UNet 參數量的百分之二。Table 5.12 為兩者使用 1-day 資料進行 Fine-tuning 的實驗結果。表中 Time 欄位表示訓練一筆資料實際花費的時間，我們可以發現僅使用 RBF Transfer Learner 進行 Fine-tuning 能夠節省將近 98% 的參數使用量，且其花費的訓練時間能夠節省 62%，而誤差卻只有大約 1.5% 的增加。




Figure 5.17 Parameters Usage

Table 5.12 Results of Fine-tuning with Different parameters

	#Param	Δ	MAE	Δ	Time	Δ
CFRBF-UNet-FT	31.7M		13.1		42ms	
RBFLearner-FT	0.7M	-98%	13.3	+1.5%	16ms	-62%

因此從這項實驗中我們可以驗證當模型進行 Fine-tuning 時，RBF Transfer Learner 在遷移學習時扮演一個重要的角色，他能夠有效掌握 Source 的知識並將其更快速且準確地轉移到 Target 的預測任務上。

最後我們也針對 Target 的訓練任務展示其使用不同初始器的學習曲線圖，如 Figure 5.18 所示。這些實驗同樣僅只用 RBF Transfer Learner 進行 Fine-tuning。我們看到圖中 RBF_FineTune 代表直接進行 Fine-tuning 而不使用 Target 資料重新設置參數。RBF_RandomUniform 則是使用隨機值取代 RBF 隱藏層原本從 Source 中學到的參數。RBF_RandomMean 和 RBF_GaussianMixture 則是根據 Target 的訓練資料進行優化。首先，從圖中我們可以發現 RBF_RandomUniform 因為被隨機參數影響而遺失了原本學習到關於輸入特徵分布的知識，該學習曲線在所有的 epochs 的 loss 都最高。接著我們發現 RBF_RandomMean 的 loss 都能夠優於 RBF_RandomUniform，因為 RandomMean 根據 Target 生成的參數更能夠幫助模型學習。值得注意的是，在這項實驗中 RBF_FineTune 由於經過訓練因此優於上述兩者，然而其有可能會因為在 Source 的訓練中陷入局部最佳解。我們可以看到圖中 RBF_GaussianMixture 因為根據 Target 優化後能夠設置更全局的參數，因此他可以找到一條與 RBF_RandomMean 和 RBF_FineTune 不同的起始位置為模型找到更好的收斂位置。




Figure 5.18 Learning curves of Fine-tuning RBF Transfer Learner

因此從這項實驗中我們可以得知兩點重要訊息:(1) RandomMean 比起一般的 RandomUniform 更能夠為 RBF 隱藏層設置一組益於訓練的參數。(2) 比起直接對模型做 Fine-tuning, 使用 GaussianMixture 能夠對 RBF 網路針對其收斂時間和精準度進行優化, 如此一來, 最終能夠使得模型取得更好的預測性能。

6. Conclusion and Future Work

本研究考慮到真實場景之下可能發生變化的全市人流, 模型需要為之隨時做調整以達到準確地預測。對此我們提出通過 CFRBF-UNet 進行知識轉移的全市人流圖像預測。首先我們發現 Unet 在萃取全市人流全局空間依賴性具有非常優勢的預測性能, 但是目前的 Unet 缺乏考量人流圖像的時間依賴性以及外部因素的影響, 因此我們提出了改良後針對人流圖像預測的 CF-UNet, 其中的 Spatial Temporal Learner 可以幫助 Unet 提供不同時間的視野以取得時間相關的特徵, 而 External Learner 則可以幫助 Unet 萃取外部因素的特徵以提升預測全市人流的準確度。此外, 我們在 CFRBF-UNet 中開發的 RBF Transfer Learner 能夠將模型從豐富歷史資料學習到的知識進行轉移, 因此我們的模型可以根據知識遷移並通過少量的新資料對任何發生變化的人流為模型做調整, 使預測模型能夠快速地恢復正常使用。最後我們也針對 RBF 網路開發了參數初始值優化的演算法, 其能夠針對模型知識轉移的速度以及精準度進行優化, 使模型可以在真實場景下持續應用。本研究使用了台灣真實人流資料集和天氣資料集做驗證, 其實驗結果表明我們的 CFRBF-UNet 比其他 baselines 模型表現還要好, 此外我們的模型能夠通過知識轉移來花費少量的訓練資料以及訓練參數來提升預測準確度。

我們所提出的方法除了能應用在都市的人流預測問題, 在未來也可以運用在其他都市時空間流量的預測問題上, 因為我們的方法不僅適用萃取時空間流量的時間和空間依賴性, 也能夠萃取時空間流量的相關知識並將其轉移到預測目標來幫助預測性能

的提升。此外，我們開發的 Spatial Temporal Learner 和 External Learner 可以幫助 Unet 提升預測性能，而我們開發的 RBF Transfer Learner 能夠使 Unet 通過遷移學習來改善預測性能。因此在未來我們可以繼續研究開發額外針對遷移學習的模組，並將其用來改善其他 state-of-the-art models 的預測性能，使得這些模型都能夠有效地在真實場景之下進行應用。

References

- [1] XXX
- [2] BL. Bai, L. Yao, C. Li, X. Wang, and C. Wang, "Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting," *arXiv preprint arXiv:2007.02842*, 2020.
- [3] BL. Brausch, H. Hewener, and P. Lukowicz, "Towards a wearable low-cost ultrasound device for classification of muscle activity and muscle fatigue," in *Proceedings of the 23rd International Symposium on Wearable Computers*, 2019, pp. 20-22.
- [4] CD. Chen, "Research on traffic flow prediction in the big data environment based on the improved RBF neural network," *IEEE Transactions on Industrial Informatics*, vol. 13, no. 4, pp. 2000-2008, 2017.
- [5] CJ. Chen *et al.*, "Fine-grained prediction of urban population using mobile phone location data," *International Journal of Geographical Information Science*, vol. 32, no. 9, pp. 1770-1786, 2018.
- [6] CWB Observation Data Inquire System v7.2. [Online]. Available: <https://e-service.cwb.gov.tw/HistoryDataQuery/index.jsp>. [Accessed: 11-May-2022].
- [7] CY.-C. Chen and D.-C. Li, "Selection of key features for PM2.5 prediction using a wavelet model and RBF-LSTM," *Applied Intelligence*, vol. 51, no. 4, pp. 2534-2555, 2021.
- [8] DC. Ding, J. Duan, Y. Zhang, X. Wu, and G. Yu, "Using an ARIMA-GARCH Modeling Approach to Improve Subway Short-Term Ridership Forecasting Accounting for Dynamic Volatility," *IEEE Transactions on Intelligent Transportation Systems*, vol. 19, no. 4, pp. 1054-1064, 2018.
- [9] DG. Du, X. Cao, J. Liang, X. Chen, and Y. Zhan, "Medical image segmentation based on u-net: A review," *Journal of Imaging Science and Technology*, vol. 64, no. 2, pp. 20508-1-20508-12, 2020.
- [10] FR. Fu, Z. Zhang, and L. Li, "Using LSTM and GRU neural network methods for traffic flow prediction," in *2016 31st Youth Academic Annual Conference of Chinese Association of Automation (YAC)*, 2016: IEEE, pp. 324-328.
- [11] GA. Ganjavi, E. Christopher, C. M. Johnson, and J. Clare, "A study on probability of distribution loads based on expectation maximization algorithm," in *2017 IEEE Power*

- & Energy Society Innovative Smart Grid Technologies Conference (ISGT), 2017: IEEE, pp. 1-5.
- [12] GA. P. Gopi, R. N. S. Jyothi, V. L. Narayana, and K. S. Sandeep, "Classification of tweets data based on polarity using improved RBF kernel of SVM," *International Journal of Information Technology*, pp. 1-16, 2020.
- [13] GGoogle, "Covid-19 Community mobility reports." [Online]. Available: <https://www.google.com/covid19/mobility/>. [Accessed: 27-May-2022].
- [14] HI. H. Sarker, "A machine learning based robust prediction model for real-life mobile phone data," *Internet of Things*, vol. 5, pp. 180-193, 2019.
- [15] HJ. Hu, L. Shen, and G. Sun, "Squeeze-and-excitation networks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 7132-7141.
- [16] HK. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770-778.
- [17] HQ. Hu, R. Zhang, and Y. Zhou, "Transfer learning for short-term wind speed prediction with deep neural networks," *Renewable Energy*, vol. 85, pp. 83-95, 2016.
- [18] HS. Han, C. Qubo, and H. Meng, "Parameter selection in SVM with RBF kernel function," in *World Automation Congress 2012*, 2012: IEEE, pp. 1-4.
- [19] HS. Hao, M. Zhang, and A. Hou, "Short-term Traffic Flow Forecast Based on DE-RBF Fussion Model," in *Journal of Physics: Conference Series*, 2021, vol. 1910, no. 1: IOP Publishing, p. 012035.
- [20] HY. Han, S. Wang, Y. Ren, C. Wang, P. Gao, and G. Chen, "Predicting station-level short-term passenger flow in a citywide metro network using spatiotemporal graph convolutional neural networks," *ISPRS International Journal of Geo-Information*, vol. 8, no. 6, p. 243, 2019.
- [21] HY.-L. He, X.-Z. Wang, and J. Z. Huang, "Fuzzy nonlinear regression analysis using a random weight network," *Information Sciences*, vol. 364, pp. 222-240, 2016.
- [22] JZ. Jiang, P. Tahmasebi, and Z. Mao, "Deep residual U-net convolution neural networks with autoregressive strategy for fluid flow predictions in large-scale geosystems," *Advances in Water Resources*, vol. 150, p. 103878, 2021.

- [23] KEditor Group, K., "Asia Taiwan Taipei 4 Days Travel Guide," KKday Blog, 21-Nov-2017. [Online]. Available: <https://blog.kkday.com/8088/asia-taiwan-taipei-4-days-travel-guide>. [Accessed: 10-May-2022].
- [24] LA. Lin, B. Chen, J. Xu, Z. Zhang, G. Lu, and D. Zhang, "Ds-transunet: Dual swin transformer u-net for medical image segmentation," *IEEE Transactions on Instrumentation and Measurement*, 2022.
- [25] LG. Li, Q. Zhang, Q. Lin, and W. Gao, "A three-level radial basis function method for expensive optimization," *IEEE Transactions on Cybernetics*, 2021.
- [26] LK.-L. Li, C.-J. Zhai, and J.-M. Xu, "Short-term traffic flow prediction using a methodology based on ARIMA and RBF-ANN," in *2017 Chinese Automation Congress (CAC)*, 2017: IEEE, pp. 2804-2807.
- [27] LS. Y. Liu, S. Liu, Y. Tian, Q. L. Sun, and Y. Y. Tang, "Research on Forecast of Rail Traffic Flow Based on ARIMA Model," in *Journal of Physics: Conference Series*, 2021, vol. 1792, no. 1: IOP Publishing, p. 012065.
- [28] LT. Li, J. Zhang, K. Bao, Y. Liang, Y. Li, and Y. Zheng, "Autost: Efficient neural architecture search for spatio-temporal prediction," in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2020, pp. 794-802.
- [29] LY. Liang *et al.*, "Fine-Grained Urban Flow Prediction," in *Proceedings of the Web Conference 2021*, 2021, pp. 1833-1845.
- [30] LY. Liu, H. Zheng, X. Feng, and Z. Chen, "Short-term traffic flow prediction with Conv-LSTM," in *2017 9th International Conference on Wireless Communications and Signal Processing (WCSP)*, 2017: IEEE, pp. 1-6.
- [31] LY. Lu, Z. Tian, P. Peng, J. Niu, W. Li, and H. Zhang, "GMM clustering for heating load patterns in-depth identification and prediction model accuracy improvement of district heating system," *Energy and Buildings*, vol. 190, pp. 49-60, 2019.
- [32] LY. Lv, Y. Duan, W. Kang, Z. Li, and F.-Y. Wang, "Traffic flow prediction with big data: a deep learning approach," *IEEE Transactions on Intelligent Transportation Systems*, vol. 16, no. 2, pp. 865-873, 2014.
- [33] LZ. Lin, J. Feng, Z. Lu, Y. Li, and D. Jin, "Deepstn+: Context-aware spatial-temporal neural network for crowd flow prediction in metropolis," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2019, vol. 33, no. 01, pp. 1020-1027.

- [34] OA. E. Orhan and X. Pitkow, "Skip connections eliminate singularities," *arXiv preprint arXiv:1701.09175*, 2017.
- [35] OO. Oktay *et al.*, "Attention u-net: Learning where to look for the pancreas," *arXiv preprint arXiv:1804.03999*, 2018.
- [36] PN. S. Punna and S. Agarwal, "Modality specific U-Net variants for biomedical image segmentation: a survey," *Artificial Intelligence Review*, pp. 1-45, 2022.
- [37] PS. Pineda-Arango, D. Obando-Paniagua, A. Dedeoglu, P. Kurzendörfer, F. Schestag, and R. Scholz, "Improving Sample Efficiency with Normalized RBF Kernels," *arXiv preprint arXiv:2007.15397*, 2020.
- [38] RO. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *International Conference on Medical image computing and computer-assisted intervention*, 2015: Springer, pp. 234-241.
- [39] SC. Sun, M. Ma, Z. Zhao, S. Tian, R. Yan, and X. Chen, "Deep transfer learning based on sparse autoencoder for remaining useful life prediction of tool in manufacturing," *IEEE Transactions on Industrial Informatics*, vol. 15, no. 4, pp. 2416-2425, 2018.
- [40] SD. Stoller, S. Ewert, and S. Dixon, "Wave-u-net: A multi-scale neural network for end-to-end audio source separation," *arXiv preprint arXiv:1806.03185*, 2018.
- [41] SH. Shi, L. Chen, Z. Xu, and D. Lyu, "Personalized location recommendation using mobile phone usage information," *Applied intelligence*, vol. 49, no. 10, pp. 3694-3707, 2019.
- [42] SJ. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic segmentation," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 3431-3440.
- [43] SJ. Schmidt-Hieber, "Nonparametric regression using deep neural networks with ReLU activation function," *The Annals of Statistics*, vol. 48, no. 4, pp. 1875-1897, 2020.
- [44] SS. Sun, H. Wu, and L. Xiang, "City-wide traffic flow forecasting using a deep convolutional neural network," *Sensors*, vol. 20, no. 2, p. 421, 2020.
- [45] SZ. Shen, Y. Xu, B. Ni, M. Wang, J. Hu, and X. Yang, "Crowd counting via adversarial cross-scale consistency pursuit," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 5245-5254.

- [46] TC. Tian, X. Zhu, Z. Hu, and J. Ma, "Deep spatial-temporal networks for crowd flows prediction by dilated convolutions and region-shifting attention mechanism," *Applied Intelligence*, vol. 50, no. 10, pp. 3057-3070, 2020.
- [47] TTaiwan Centers for Disease Control, "CECC raises epidemic warning to level 3 nationwide from May 19 to May 28; strengthened measures and restrictions introduced across Taiwan to reduce community transmission." [Online]. Available: https://www.cdc.gov.tw/En/Bulletin/Detail/VN_6yeoBTKhRKOsy2d0hJQ?typeid=158. [Accessed: 28-May-2022].
- [48] VV. K. Valloli and K. Mehta, "W-net: Reinforced u-net for density map estimation," *arXiv preprint arXiv:1903.11249*, 2019.
- [49] WJ. Wainer and P. Fonseca, "How to tune the RBF SVM hyperparameters? An empirical evaluation of 18 search algorithms," *Artificial Intelligence Review*, vol. 54, no. 6, pp. 4771-4797, 2021.
- [50] WJ. Wu, J. Long, and M. Liu, "Evolving RBF neural networks for rainfall prediction using hybrid particle swarm optimization and genetic algorithm," *Neurocomputing*, vol. 148, pp. 136-142, 2015.
- [51] WL. Wang, X. Geng, X. Ma, F. Liu, and Q. Yang, "Cross-city transfer learning for deep spatio-temporal prediction," *arXiv preprint arXiv:1802.00386*, 2018.
- [52] WS. Wang, H. Miao, J. Li, and J. Cao, "Spatio-Temporal Knowledge Transfer for Urban Crowd Flow Prediction via Deep Attentive Adaptation Networks," *IEEE Transactions on Intelligent Transportation Systems*, 2021.
- [53] YB. Yu, H. Yin, and Z. Zhu, "St-unet: A spatio-temporal u-network for graph-structured time series modeling," *arXiv preprint arXiv:1903.05631*, 2019.
- [54] YH. Yao, Y. Liu, Y. Wei, X. Tang, and Z. Li, "Learning from multiple cities: A meta-learning approach for spatial-temporal prediction," in *The World Wide Web Conference*, 2019, pp. 2181-2191.
- [55] YI. Yilmaz and O. Kaynar, "Multiple regression, ANN (RBF, MLP) and ANFIS models for prediction of swell potential of clayey soils," *Expert systems with applications*, vol. 38, no. 5, pp. 5958-5966, 2011.
- [56] ZJ. Zeng and W. Qiao, "Short-term solar power prediction using an RBF neural network," in *2011 IEEE power and energy society general meeting*, 2011: IEEE, pp. 1-8.

- [57] ZJ. Zhang *et al.*, "LCU-Net: A novel low-cost U-Net for environmental microorganism image segmentation," *Pattern Recognition*, vol. 115, p. 107885, 2021.
- [58] ZJ. Zhang, Y. Zheng, and D. Qi, "Deep spatio-temporal residual networks for citywide crowd flows prediction," in *Thirty-first AAAI conference on artificial intelligence*, 2017.
- [59] ZJ. Zhang, Y. Zheng, D. Qi, R. Li, and X. Yi, "DNN-based prediction model for spatio-temporal data," in *Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems*, 2016, pp. 1-4.
- [60] ZY. Zhou, J. Li, H. Chen, Y. Wu, J. Wu, and L. Chen, "A spatiotemporal hierarchical attention mechanism-based model for multi-step station-level crowd flow prediction," *Information Sciences*, vol. 544, pp. 308-324, 2021.