

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

應用三維高斯函數結合深度學習之區域 PM2.5 預測

Certain Region PM2.5 Prediction Based on Deep Learning

Models with Three Dimensional Gaussian Function

江吉晟

Ji-Cheng Jiang

指導教授：蘇純繒 博士

Advisor: Chwen-Tzeng Su, Ph.D.

中華民國 110 年 6 月

June 2021

摘要

空氣污染問題逐漸成為現今社會大眾越來越重視問題之一，為了能讓民眾提早得知未來的空氣品質資訊，讓他們有足夠的時間進行預防，因此針對長期預測 PM2.5 的趨勢成為一件刻不容緩的事情。一般而言，過往學者的研究都有不同的切入觀點，但大多研究都並未同時考慮到時間與空間整合的影響性，僅透過時間性趨勢資料是無法全面性了解到 PM2.5 污染的影響範圍，再加上要建立更加完善的模型則需耗費相當大的運算成本，因此本研究提出兩個概念去克服上述問題：(1)提出一個新的組合式模型 3D-RCL，該模型可以將時間序列以空間方式呈現，並考慮整體狀態之時空因素，(2)透過 RBF 函數來協助拆解網路，除了能夠篩選出重要的特徵，讓預測的準確度提高，同時也能降低深度學習模型所需耗費的運算成本。最後，本研究利用過往研究所提出的多種機器學習模型驗證下，不論是使用哪種預測方法，透過本研究所提出的組合式模型 3D-RCL，皆能有效地挑選出重要特徵的影響因子，提升長期預測準確度，由此可以證實本研究提出方法的有效性。

關鍵字：PM2.5 預測、深度學習、高斯函數、特徵工程

ABSTRACT

Preventing wide-spread pulmonary disorders depends on the long-term forecasting of PM_{2.5} trends. Most existing models do not account for time-space integration and are therefore unable to provide accurate long-term predictions of PM_{2.5} pollution. Models of greater complexity impose a heavy computational burden. In the current study, we developed a novel deep learning model in which time series are presented spatially and the RBF function is used to disassemble the neural network in order to identify important features, improve prediction accuracy, and lower computational costs. In experiments comparing performance of the proposed scheme with that of existing machine learning models, the proposed 3D-RCL model proved highly effective in selecting important features and performing long-term predictions of high accuracy.

Keywords: PM_{2.5} predictions, Deep learning, Gaussian function, Feature engineering

誌謝

能完成這份論文，首先我要先感謝我的兩位老師蘇純繒老師、陳奕中老師。兩年的時間真的不能只用感謝者兩個字來形容，兩位導師從我碩一到現在不僅僅讓我參與了許多重要的計畫、以及帶領我參加各個大小的比賽獲得不錯的成績，也常在我遇到困難與瓶頸總能包容我以及適時地提供寶貴的意見。另外，老師們在專業知識上的研究，也常深刻的影響著我，讓我了解到更多未知的知識，提升自我能力讓能找到好工作。這些日子裡，真的很感謝兩位老師的照顧。

另外，要特別感謝的是李東錡學長以及周映均學姊，從大學時期就帶領著我規劃未來方向，且得知我想轉換專業領域，就推薦我進入雲科工管那麼棒的實驗室裡。從一開始程式不太會的新手，到現在程式比賽可以拿下不錯的成績，也常常在我對人生感到迷惘時給予我幫助與鼓勵。在我就學的這段期間能成長那麼多，都要歸功於當初兩位學長姐的幫助，未來也祝福您們能完成自己的目標。

接著，也要感謝實驗室的諸多的學長姐志豪、富正、泊樣、紫平、宇哲、邵宸、怡婷在許多事情上的指導與幫助；以及同屆的柏翔、峻棠、姿靜、靜瑜、文成、詠緹、力誠、政傑的互相陪伴與支持，也很感謝需要援手給予幫助的學弟妹佳昇、重佑、香蘭、佑蓉。未來也祝福你們都能順利。

最後要感謝我的父母親對於我的栽培，很相信且支持我做的很多決定，辛苦的養育我能讓我就學期間無後顧之憂的完成學業，未來就換我來照顧您們了。最後我想謝謝在看這份論文的你，希望未來我們都能成為一個能幫助社會的人。

目錄

摘要	i
ABSTRACT	ii
誌謝	iii
目錄	iv
圖目錄	vi
表目錄	viii
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	8
1.3 研究範圍	9
1.4 研究限制	10
1.5 研究架構	10
第二章 文獻探討	11
2.1 懸浮微粒的組成	11
2.2 懸浮微粒的時空相關性	11
2.3 空氣品質的預測方法	12
2.3.1 大氣科學方法	12
2.3.2 機器學習與統計方法	13
2.3.3 深度學習方法	14
2.3.4 過往預測方法綜合比較	15
2.4 特徵工程	16
2.4.1 以統計方法進行特徵工程	16
2.4.2 以機器學習進行特徵工程	17

2.4.3 以高斯函數進行特徵工程	17
2.4.4 以二維高斯函數進行特徵工程	18
2.4.5 以深度學習進行特徵工程	18
2.5 類神經網路於空污議題上的應用	20
2.5.1 淺層類神經網路	20
2.5.2 卷積類神經網路	21
2.5.3 長短期類神經網路	22
2.6 小節	24
第三章 資料集	25
3.1 收集臺灣測站相關資料	25
3.2 目標預測站點資料分析	26
3.3 處理資料集所遇到的問題	30
第四章 研究方法	31
4.1 資料清洗-線性插值法	32
4.2 反距離權重法網格化資料	32
4.3 使用 3D-RBF 結合 CNN 與 LSTM 建模	34
4.4 使用 3D-RBF 篩選重要時間特徵與空間特徵	43
4.5 篩選後重要特徵進行即時預測	46
第五章 實驗模擬	49
5.1 資料集與實驗參數介紹	49
5.2 3DRCL 之 Threshold σ 選擇與量化合理性說明	50
5.3 模型與方法的有效性驗證	53
第六章 結論與未來研究	55
參考文獻	56
附錄	64

圖目錄

圖 1-1 2019 年 PM2.5 濃度變化圖[56]	2
圖 1-2 金門、馬祖、西屯真實空間位置圖	5
圖 1-3 2019/10/1 至 2019/11/31 金門、馬公、西屯測站實際 PM2.5 折線圖	5
圖 1-4 3D-RBF-CNN-LSTM 架構圖	8
圖 1-5 研究架構圖	10
圖 2-1 類神經網路示意圖	21
圖 2-2 卷積類神經網路示意圖	22
圖 2-3 長短期記憶類神經網路示意圖[61]	22
圖 3-1 環保署空氣品質監測站架設地點[59]	25
圖 3-2 目標預測空氣監測站位置分布	26
圖 3-3 豐原、沙鹿、西屯、忠明、大里 2018 至 2019 月平均折線圖	27
圖 3-4 豐原、沙鹿、西屯、忠明、大里 2018 至 2019 金鬚圖	28
圖 3-5 測站之間的相關性圖	29
圖 3-6 行政院環保署西屯測站 2019 年下半年 PM2.5 折線圖	29
圖 3-7 行政院環保署基隆測站 2021 年 5 月 10 日 PM2.5 缺失值折線圖[57]	30
圖 3-8 PM2.5 數值轉換空間示意圖[62]	30
圖 4-1 研究流程圖	31
圖 4-2 地形資料網格示意圖	33
圖 4-3 反距離權重法網格化地圖	34
圖 4-4 3D-RCL 模型研究架構圖	35
圖 4-5 RBF 訓練初始狀態示意圖	36
圖 4-6 RBF 訓練結束狀態示意圖	36
圖 4-7 壓縮時間 RBF 神經示意圖	36

圖 4-8 神經元相同時段回溯原始空間示意圖	37
圖 4-9 二維空間 RBF 產生初始中心點	38
圖 4-10 中心點落在中間 σ	39
圖 4-11 中心點落在右邊 σ	39
圖 4-12 5×5 像素圖	40
圖 4-13 3×3 像素圖	40
圖 4-14 卷積計算流程圖	40
圖 4-15 Pooling layer 介紹	41
圖 4-16 網格地圖解說參考示意圖	44
圖 4-17 T-11 至 T-6 二維空間 RBF 矩陣示意圖	45
圖 4-18 T-5 至 T 5×5 示意圖	45
圖 4-19 T-11 至 T-6 5×5 示意圖	45
圖 4-20 T-11 至 T-6 二維空間 RBF 中心擴散示意圖	46
圖 4-21 T-11 至 T-6 二維空間 RBF 訓練後示意圖	46
圖 4-22 隨機森林示意圖[60]	47
圖 5-1 30 次西屯測站預測未來 24 小時績效統計直方圖	51
圖 5-2 3D-RBF 挑選重要特徵 RandomForest 預測績效	512

表目錄

表 2-1 空氣品質預測方法之相關文獻整理.....	15
表 2-2 過往預測 PM2.5 方法比較表.....	16
表 2-3 特徵工程之相關文獻整理.....	19
表 2-4 類神經網路應用於空污議題之相關文獻整理.....	23
表 3-1 行政院環保署空氣品質監測網歷史資料.....	26
表 3-2 豐原、沙鹿、西屯、忠明、大里測站 2018 至 2019 描述性統計.....	27
表 5-1 排名內與排名外特徵數量之 RMSE 比較表.....	53
表 5-2 不同模型下有無篩選特徵值之 RMSE 比較表.....	54
表 5-3 3D-RBF 與其他特徵提取方法之 RMSE 比較表.....	54

第一章 緒論

1.1 研究背景與動機

近年來環境受到空氣污染的問題日益嚴重，除了世界衛生組織曾預估每年會有 57 萬名五歲以下的孩童受到空氣污染的危害所導致死亡的情況發生，也有許多因環境變遷所組成的公民團體逐漸重視空氣污染對人們所造成的影響。在面臨空氣品質的問題，日常生活中人民也有許多因應的方式，除了在家中擺放空氣清淨機，最常見的就是注意手機有關空污的資訊，並戴上口罩避免身體呼吸到過多的污染物質。但往往在他們注意到空氣品質不佳的時候，已經長時間呼吸到過多的污染物質，因此若能準確預測出長時間的 PM2.5，民眾就有足夠的時間進行預防。以圖 1-1 為例，可以看到在 2019 年 10 月 1 號時，全台的空氣狀態呈現良好的情形，不過 10 月 2 號的中午 12 點，風向從西南方吹拂，而這波西南風順勢將境外的污染物帶往台灣，使得整體空氣品質逐漸轉差，到了該日下午 3 點，此波西南風所帶來的污染物已進入台灣西半部以南沿海地區，且隨著時間增加，到了 10 月 3 日污染物已擴散並涵蓋住整個西半部區域，更甚影響至北部地區，接著時間來到 10 月 4 日，由於當天風速不如前幾日，風速呈現較為緩和情況趨於靜風，導致前幾日所帶來的污染物無法迅速飄散排除呈現滯留狀態，加上每個地區都有各自形成的污染物，如：工業區的廢氣排放、燒香等等，使得整體空氣品質情形越趨惡化。由上述可以得知污染物會受到兩個要素影響：第一個為當地的 PM2.5 濃度，第二個為不同地區的污染物兩者皆有機會影響到其他地區，導致其他地區空氣品質受到污染，不僅會影響 PM2.5 的波動，更間接影響到民眾造成健康問題。這兩項因素會提升過往學者進行 PM2.5 預測的難度。為了提供給民眾更準確 PM2.5 的長期趨勢，從過往測站的空氣污染資料，同時加入空間地圖觀察出大環境的趨勢，篩選出資料中的重要時空因子，不但可以降低長期預測的難度，進而提升長期預測的準確度，更能提供給民眾更準確 PM2.5 的未來趨勢，減少身體遭受到污染物影響的風險。




圖 一-1 2019 年 PM2.5 濃度變化圖[56]

由於 PM2.5 問題十分嚴峻，因此世界上的科學家們無不積極參與 PM2.5 的預測研究，然而本研究發現每篇研究都有不同的切入觀點，並有其各自的優缺點，因此本論文預計整理過往的所有觀點，評估每個觀點的優缺點，並因此設計出一個符合大部分觀點需求的方法。現介紹我們所整理出來的四大觀點如下。、

1. 考慮短期預測與長期預測：

短期預測是指針對 1 小時以內的目標發展變化去進行預測，主要因為目標的組成與來源複雜程度較低，且預測出來的結果往往會比長期預測的結果要準確，因此過往多數學者以短期預測作為研究重點。Du *et al.*[16]收集美國五個站點 PM2.5 數據預測休斯頓地區每小時 PM2.5 濃度，並驗證了這些地區特徵因子的組合。

Wang *et al.*[30]利用小波混合模型預測太原市每小時 PM2.5 濃度，該模型與人工類神經 Artificial Neural Network(ANN)和支援向量機 Support Vector Machine(SVM)的結果進行比較，混合模型的結果更加準確和穩定。Bai *et al.*[49]透過 Ensemble Long Short-Term Memory(E-LSTM)方法預測每小時的 PM2.5 濃度，實驗結果說明使用集成學習的 Long Short-Term Memory(LSTM)比單個 LSTM 模型更加準確。

Yuan *et al.*[46]透過多因素分析與多尺度分析預測中國每小時 PM2.5 濃度，並從分析結果中了解這些因素之間的關係。Zhang *et al.*[26]使用 Autoregressive Integrated Moving Average model(ARIMA)模型預測中國福州未來一小時 PM2.5 濃度並討論污染物濃度與氣象之間的相關性。Cobourn *et al.*[44]利用前 24 小時輸入預測未來 1 小

時，探討各因子之間與氣象的相關性。Lin *et al.*[52] 將空氣盒子的歷史數據透過 Kriging 方法進行時空插值，補齊了遺漏空氣品質資訊，進而提高了短期預測模型的準確率。

長期預測則是指預測 2 小時以上的目標發展變化，能提供民眾得知更久之後的 PM_{2.5} 濃度並提早防範。Wu *et al.*[15]收集中國四個不同城市預測未來 4 小時 PM_{2.5} 濃度，提出混合式模型可以在短時間內生成準確的預測結果。Biancofiore *et al.*[10]透過三種不同功能的統計與深度學習模型，以氣象數據與 PM₁₀ 當作輸入預測 PM₁₀ 未來 1~3 天的濃度。Xu *et al.*[48]設計 Temporal-Spatial-Regression-Tree Model(TSRT)模型分析 PM_{2.5} 的時空特徵，並預測未來 24 小時 PM_{2.5} 濃度。Liu *et al.*[13]設計了三階段的神經網路模型，預測中國四個城市未來五天的 PM_{2.5} 濃度，並證實此方法比常見的深度學習模型來得好。Chang-Hoi *et al.*[12]使用遞迴類神經網路模型(Recurrent Neural Network,RNN)與多尺度空氣質量模型(Community Multiscale Air Quality,CMAQ)於韓國首爾進行未來 2 天 PM_{2.5} 預測，證實遞迴類神經網路優於多尺度空氣質量模型。Pak *et al.*[43]使用混合時空卷積神經網絡(Convolutional Neural Network,CNN)和長短期記憶神經網路(LSTM)模型預測北京未來二日平均的 PM_{2.5} 濃度並獲得良好的預測結果。不過影響長期預測時間因子與空間因子較短期來得複雜，且預測結果較短期預測來得差，目前也較少有專家學者去討論長期預測的問題。

在過往研究許多學者都是針對短期預測去做研究，因為其預測效果比長期預測來得好，但是實際狀況下短期預測是不實用的，原因在於模型僅能預測未來 1 小時，無法提供民眾足夠的時間進行預防，因此本研究將考慮長期預測並解決長期預測的因子複雜性。

2. 使用單測站或多測站去進行預測：

根據過去研究中大多都主要透過收集單測站資料進行建模預測。Biancofiore *et al.*[10]收集義大利中部城市公園的一處監測站站點歷史資料，並將目標站點的空污

因子與氣象因子等五個特徵值，輸入至 ANN 中去預測未來該測站 PM2.5 濃度。Wang *et al.*[30]收集了中國太原市一處的監測站點，收集該站點的空污因子以及氣象因子共 11 種特徵值，利用類神經小波模型最後獲得良好的預測結果。Freeman *et al.*[3]收集了科威特州地區的空氣品質資料，透過決策樹挑選重要性較高的因子輸入至長短期類神經記憶模型進行預測及建模，證實此方法的預測精準度較 ARIMA 方法佳。

在過去文獻中也有少數學者使用多測站去預測未來 PM2.5 濃度，Ma *et al.*[20]收集了中國廣東省 100 個測站，透過雙向短期記憶類神經模型和反距離權重法捕捉資料集時間與空間特徵，成功預測 PM2.5。Tong *et al.*[45]收集了美國東南地區每日 PM2.5 數據，利用反距離權重法繪製空污矩陣圖，並使用 RNN、LSTM 演算法抓取 PM2.5 時間相關性，並準確預測此地區的 PM2.5。

在單測站與多測站的文獻中都有成功預測 PM2.5。但本研究在實際資料觀察中發現 PM2.5 的資料是一種時間與空間兼具的資料集，PM2.5 是會隨著季風被帶入國內，並會隨著風的強度與角度改變影響到周圍地區的 PM2.5，如圖 1-2、圖 1-3 為例，金門監測站和馬公監測站的歷史資料中看出這兩地區的在 2019 年 10 月 2 號期間發生空污上升的情形，隨著風向與風速的吹拂，西屯監測站在 2019 年 10 月 3 號期間也發生空污上升的情形。在 2019 年 11 月 1 號金門測站和馬公測站皆發生 PM2.5 數值下降，西屯監測站也在未來幾小時內也發生了 PM2.5 下降的情形，也因此證實了 PM2.5 每小時風向和強度可能都會受其他空間空氣污染擴散的影響下發生很大的變化，導致污染物停滯在當前地區或擴散到周圍地區，如果僅在時域中分析 PM2.5，則可能會忽略其他區域之間的影響和關係，而僅考慮空間關係可能會忽略 PM2.5 隨時間的擴散性，因此從時空綜合差異來看則需考量到其他地區的空氣污染，如果僅考慮單測站可能沒辦法達到較佳的預測結果。由於 PM2.5 時常會隨著風向與風速的改變，導致不同時間下要考慮的測站或因子也會不同。過往學者也嘗試加入多測站的資料進行分析。Soh *et al.*[31]透過土地利用參數、氣象參數、

對 PM2.5 進行時間和空間的交叉驗證，評估 PM2.5 受時間和空間的變異性，並提出時空融合方法 Spatial-Temporal Deep Neural Network (ST-DNN) 預測 PM2.5 濃度，獲得良好的預測結果。Li *et al.*[37]測量中國太原市周圍站點，並透過相關係數發現各站點空氣品質會隨著時間的拉長，彼此之間的相關性就會提高，同時也指出站點彼此之間的空污濃度會受到風速和風向的改變影響到周圍地區的空气品質。但過多不重要的測站反而有可能會導致預測結果變差，由此得知進行多測站預測時挑選出合適的測站可以有效提升預測績效。



圖 一-2 金門、馬祖、西屯真實空間位置圖




圖 一-3 2019/10/1 至 2019/11/31 金門、馬公、西屯測站實際 PM2.5 折線圖

3. 考慮哪些影響 PM2.5 的因子：

在過往的研究中，許多學者會直接使用眾多因子直接納入模型的訓練，例如：風向、降雨量、PM10、CO 等，但每個地區的 PM2.5 組成因素皆不同，若將所有的因子都放入模型中所得出來的預測結果，預測效果不一定會好，因為輸入了很多沒有意義的特徵輸入於模型中，可能會導致預測精準度因此下降，為了有效解決每個地區 PM2.5 的多因子組成問題，許多學者會針對這些多因子挑選出重要特徵帶入模型。Kumar *et al.*[35]為了有效預測 PM2.5，將風速、風向、太陽輻射、氣壓等多種因素，利用相關性分析當作因子篩選工具，最終將篩選後因子進行預測。Cobourn *et al.*[44]使用非線性回歸模型(Nonlinear Regression,NLR)從數據中探索空氣質量與氣象之間的非線性關係，並改善模型輸入獲得良好的結果。Zhang *et al.*[26]使用 Spearman 相關性分析 PM2.5 的濃度與其他污染物的濃度和氣象特徵，並將相關性高的特徵輸入於 ARIMA 模型成功預測中國福州 PM2.5 濃度。Pak *et al.*[43]使用相互資訊分析(Mutual Information,MI)特徵輸入的時空相關性，並使用深度學習成功預測北京 PM2.5 濃度。為了提升模型準確率與預防污染物的發生，因此本研究將挑出主要影響目標測站的影響因子。

4. 預測模型運算成本問題：

過往多篇文獻中發現準確率最高的模型是屬於深度學習模型，然而深度學習模型能維持高準確度的關鍵，往往帶來大量的運算成本。Chen *et al.*[51]在研究中提到深度學習運算成本的問題，氣象局於全台灣 500 站點進行天氣預報，假設數據每 5 天需更新一次並使用 LSTM 模型進行預測於不同設備所導致的貨幣成本和運算成本，(1)只有一個中央處理器(CPU)而沒有圖形處理器(GPU)的電腦(1000 美元；每次進行 LSTM 訓練需要 10,000 秒，在 500 個測站完成訓練則需要 289 天)、(2)具有三個 GPU 的中型電腦(17,000 美元；每次進行 LSTM 訓練需要 400 秒，在 500 個測站完成訓練則需要 11 天)。儘管硬件成本相對前者較低，但是計算時間還是過長，(3)四台上述中型電腦(68,000 美元；LSTM 訓練完 500 個站點則需要 3 天)、(4)

超級計算機(10,000,000 美元；0.1 s 來訓練每個 LSTM，訓練完 500 個站點則需要 250 秒)，上述(3)和(4)符合氣象局的要求，但是成本很高，因此龐大的運算成本，可能會導致民眾無法即時得知該地區未來空品指數，若想真正改善空污所造成的問題並準時提供預報空污作業給民眾使用，模型在訓練過程中能減少不必要的成本就顯得特別重要，否則模型過於龐大造成運算時間過長，可能會造成的嚴重問題是沒辦法準時提供給民眾空污預報。為了輕量化深度學習模型，目前的解決方法大致分為兩個方向，第一個方向，刪減深度學習模型中無用的架構以降低運算成本，Guo *et al.*[25]提出壓縮卷積神經網路的方法，作者透過所設計的演算法與神經元的重整，對網路層每一層去計算修剪百分比，進一步刪除相對較無影響的神經元，從實驗結果來看，該框架準確度略微降 1%，但在模型參數上減少 50%的空間。第二個方向，從深度學習中擷取對分析有用的特徵值，利用新的特徵值，去訓練低成本的機器學習模型，獲得與深度學習一樣的績效並能大幅降低總運算成本，Mohammad *et al.*[53]則是在類神經神經元中設計了新的公式來計算每個特徵值在深度學習中的重要程度，選取其他較重要的特徵值，再把重要的特徵值重新丟入深度學習模型中訓練，最終獲得了低成本的模型，但其效能跟原先的深度學習模型差不多，且辨識率優於傳統的分析，換言之，若本研究想探討的 PM2.5 影響的成因，能在訓練深度學習的過程中，不僅能夠提取重要資訊來達到此目的，也可以解決成本過高的問題。

根據上述，可以統整出以下三大問題：(1)輸入資料消耗大量計算成本，不論是長期預測或是多測站預測，所需的資料量都相當大，相對地計算成本一定會很高，又加上要考慮更多影響因子，計算成本儼然成為一大問題。(2)過去研究較少考慮時間與空間的整合。為了提升長期預測的準確性，除了考慮利用現有的測站所收集到具有時間性的資料之外，還有其他地區也會影響到其他測站的空間相關性，兩者皆為需要考慮的影響因子。(3)深度學習影響特徵難以拆解。深度學習如同一個黑盒子，又加上模型內有多個神經元與大量非線性性質的權重，其實難以理解該模型

輸入和輸出之間的關係，因此若希望能輕量化深度學習模型，與如何解釋該模型權重成為極為困難的事。然而大部分專家學者都只討論單一、二個問題，還沒有人把三大問題一起做討論的，因此本研究提出兩個概念解決這些問題。

1.2 研究目的

本研究提出兩個概念改善上述問題，分別為(1)利用全台空品測站提出一個新的組合式模型-3D-RCL 與(2) 透過 RBF 函數來協助拆解網路，以下將詳細說明這兩個概念。

(1) 利用全台空品測站提出一個新的組合式模型-3D-RCL：

為了解決上述所提出第二個未考慮時間和空間整合的問題，本研究提出了一個新的組合式類神網路 3D-RBF-CNN-LSTM 簡稱 3D-RCL 模型，如圖 1-4 對不同時間的 PM2.5 濃度進行時空預測。首先，收集全台灣空品測站歷史資料，並利用反距離權重法對資料進行網格化圖片切片，使得模型更能學習到全台空氣品質擴散情形，解決以往尚未考慮空間性的問題。接著，提取模型所學習的神經元輸出值，將訓練過後的模型進行拆解提取出 3D-RBF 第三層神經元輸出值，並透過使用者設定的閾值篩選網格內的重要時間與地點，篩選後的最終結果就為影響 PM2.5 的重要時空特徵。




圖 一-4 3D-RBF-CNN-LSTM 架構圖

(2) 透過 RBF 函數來協助拆解網路：

針對第一個輸入資料會導致消耗大量計算成本的問題以及第三個深度學習影響特徵難以拆解的問題，本研究將利用 Three Dimensional Radial Basis Function(3D-RBF)結合卷積類神經網路(Convolutional Neural Network,CNN)與長短期類神經網路(Long Short-Term Memory,LSTM)預測未來 PM2.5 濃度，此方法的關鍵就是在 CNN-LSTM 前串接三層使用不同方式所組成的 RBF 神經元網路架構，使用 RBF 的主要原因在各個時間段的網格空間中進行維度上升的動作，讓模型可以學到在不同時間下的空間特徵資訊，並透過 RBF 轉換，使資料更能找出關鍵因素，由此可以得知，透過額外的 RBF 函數是可以用來協助拆解網路，也可以減少深度學習所需耗費的大量計算成本問題。最終輸入至 CNN-LSTM 是可以透過 CNN 卷積層的功能提取 3D-RBF 升維轉換後的空間資訊結果，並利用池化層的輸入取出特徵圖數值中的最大值，再以 LSTM 學習 PM2.5 擴散情形進行並最終預測。

依據概念提出的 3D-RBF 結合 CNN-LSTM 模型，預期可以達到以下三種目標：

- (1)此方法能夠將時間序列以空間方式呈現，並考慮整體狀態之時空因素，便能夠解決過往只考慮單一測站以及時空整合問題，達到精準的長期預測。
- (2)透過閾值設定對 3D-RBF 層神經元輸出能進行重要特徵篩選，找出污染來源與主要造成污染的問題，並解釋各時空因子對 PM2.5 預測的影響。
- (3)本研究會將篩選出來的重要時間與空間因子，輸入至成本較低的模型完成個人化的即時預測。

1.3 研究範圍

在近幾年，台灣對於空氣污染議題開始密切關注，環保署也開始投入諸多資源在監測空氣污染物上，提升了資料的品質，為了證明本研究提出方法的有效性，透過收集行政院環保署空氣品質監測網所提供的空氣污染物濃度 PM2.5 資料，而研究區域為台灣中部五個監測站，分別為：西屯測站、忠明測站、豐原測站、大里測

站以及沙鹿測站。本研究選取 2018 年 1 月 1 日 0 時至 2019 年 12 月 31 日 23 時作為研究時間區段。

1.4 研究限制

1. 目前僅能依照到環署保提供的現有資料進行預測。
2. 資料本身沒有收集到或有缺失值，只能透過預估的方式補足資料遺漏的地方。
3. 資料集收集的範圍只有在台灣本島，最遠只到金門、澎湖、馬祖，所以本研究進行的分析只能以台灣中部地區為例，因為其他地區可能會受其他國家影響，無法進行精準預測。

1.5 研究架構

本篇論文之主要架構如下：第一階段收集全台空氣品質測站資料，因資料缺失值問題，將資料進行清洗以利於後續資料觀察，第二階段參考過去文獻與資料觀察後找出的問題提出解決方案，第三階段設計 3D-RCL 模型解決過往問題，第四階段提取模型中重要特徵值並解釋其原因，最後，第五階段將提取出的重要特徵值丟入機器學習模型進行長期預測。




圖 一-5 研究架構圖

第二章 文獻探討

本章節將介紹列舉與本研究相關的重要研究，包含懸浮微粒的影響與組成，以及懸浮微粒的時空關係，同時將著重介紹關於過去預測 PM2.5 幾個較常使用的方法，大致可分為大氣科學方法、統計與機器學習方法、深度學習方法，最後介紹過往和本研究所使用的特徵工程方法以及卷積、遞迴神經網路的相關研究。

2.1 懸浮微粒的組成

空氣中存在許多污染物，其中飄浮在空氣中類似灰塵的粒狀物稱為懸浮微粒 (particulate matter, PM)，不同粒徑大小的懸浮微粒，都有可衡為導致人體器官不同的危害。經過多年的醫學研究，Brunekreef *et al.* [2] 發現懸浮微粒污染物與呼吸道發病率和死亡率之前存在著顯著相關性。在 Analitis *et al.* [1] 發現每增加 10 微粒的懸浮微粒，呼吸道疾病死亡率就會增加 0.58%。根據行政院環保署訂定，依來源可區分為自然界產出與人類行為產出，依造性質可區分原生性 PM2.5 與衍生性 PM2.5，原生性 PM2.5 是指 PM2.5 直接從自然或人為活動所排放，如天然的海鹽飛沫、營建工地粉塵、車行揚塵及工廠直接排放。衍生性 PM2.5 是透過自然或人為排放到大氣中，再經由太陽光照或其他化學反應而形成。Gao *et al.* [17] 指出 PM2.5 及其主要化學物質與濃度和季節有關，北京的 PM2.5 污染主要由機動車排放造成，但是，在天津與河北地區中，兩地區為工業重鎮地區，燃燒排放為兩區主要造成 PM2.5 濃度上升的原因。從以上文獻了解到每個地區 PM2.5 的來源皆不同，因此要能夠找出影響 PM2.5 關鍵是一項具有挑戰的事情。

2.2 懸浮微粒的時空相關性

在空污問題變得日益嚴重時，許多專家學者使用許多大數據的方式收集歷史資料，透過數學的計算找出因子之間的關聯性，並使用資料剖析了解到不同地區的空污因子時常會隨著風向與風速的改變將污染因子帶往其他鄰近的地區，風帶來的影響，是在之後許多學者去做預測模型中提升準確率的一大關鍵。Qin *et al.* [38]

透過 Apriori 演算法挖掘了中國北方地區 PM2.5 時空關係，此方法主要是透過周圍的地區去討論彼此之間的相關性，進一步挖掘時空關聯規則，也發現周圍地區元素值減少時目標地區會發生增加的反比關係，但此篇學者也指出，並不是所有地區都有空間上的相關性，以北京為例，北京與周圍地區關聯性較低主要因為北京 PM2.5 污染主要是深受城市內部的排放，並非周圍擴散而來，歸咎此現象可能為化石燃料燃燒與交通等因素。Gao *et al.*[17]在北京、天津、河北地區進行化學成分採樣，表示 PM 2.5 濃度與其他因子在三個地區顯示出空間相似的變化，因此作者也透露只要加強三地區的區域污染管理就可以有效解決區域污染造成的危害。上述不同資料剖析方法對於不同地區的空污因子，發現風向與風速的改變，會使污染因子被帶往其他鄰近區域，因此風帶來的影響是在之後提升預測模型準確率的一大關鍵。

2.3 空氣品質的預測方法

2.3.1 大氣科學方法

大氣科學方式是專家學者利用透過自身的專業知識，探討空氣中化學因子的變化與因子之間的相關性，將交互作用的因子公式化進而推估出未來空氣品質的濃度，但空氣品質是屬於複雜的物理與化學所組成，環境影響因子時常在改變，因此大氣科學方法只適合當前時間或短時間預測，當長時間進行預測時預測效果會因為環境的改變導致模型的不準確。Balasubramanian *et al.*[34] 利用網格形式將影響 PM2.5 的因子經過實驗測試，找出影響最深的因子，再透過獨特的化學模型與天氣模型預測未來空氣品質狀況。雖然這類方法是可以成功預測 PM2.5 但是隨著網格越切越細，勢必模型就要重新探討因子與分析。Saide *et al.*[29] 透過 Weather Research and Forecasting 化學傳輸模型預測城市地區 PM10、PM2.5 的濃度，藉此瞭解該地區工廠廢氣排放是否超過當地法定標準並提供政府預報作業，研究中詳細分析 PM10、PM2.5 的成因和變化趨勢，其中包含污染物的整體擴散情形。

雖然這樣的方法可以瞭解空氣污染排放前後相對應關係，然而當範圍較大或時間較長預測時誤差也會較大，此方法而較不適用於空品長期預測問題上。

2.3.2 機器學習與統計方法

此方法與大氣方法相比，在做預測時不需要像大氣模型方法需要了解大量的專業知識，也是中期時期學者們最常使用預測的方法之一，從原本傳統統計的線性模型，但因線性模型較有局限性，且空污問題已被多位專家學者證實是屬於複雜非線性問題，因此非線性的機器學習模型，開始深受學者們重用。機器學習主要會根據所輸入特徵進行分群與分類，也可以根據學習到的特徵進行預測。Di *et al.*[32] 研究人員將美國東部及西部地區的 PM_{2.5} 與氣象衛星數據帶入梯度提升樹 (Gradient Boosting)、淺層類神經(Neural Network)、隨機森林(Random Forest)及三種模型共同集成學習進行預測及比較。每個機器學習都有著不同的特性，淺層類神經網路和隨機森林性能非常接近皆都同時優於梯度提升樹，則使用集成學習效果整體都優於三個演算法且最終在預測上獲得不錯的績效。Liu *et al.*[14]透過物理化學方式充分了解各污染物的影響，並挑選具有重要影響力的因子透過小波分解，輸入至自適應增強 (Adaptive Boosting, Adaboost)、支持向量機 (Support Vector Machine, SVM)、廣義迴歸神經網路 (Generalized Regression Neural Network, GRNN)，三種模型相比所得出模型 Adaboost 與 SVM 準確率明顯相同，但兩者皆明顯優於 GRNN 模型，證實了非線性模型的 Adaboost、SVM 模型優於線性模型 GRNN。從上述文獻中統計分析及機器學習方法都宣稱他們能成功的對空品問題進行預測，然而必須了解到機器學習方法最大的問題是必須先挑選到合適預測空品的特徵值，其預測效果才會達到不錯的績效，若是輸入對於目前空氣品質較不相關特徵，可能會造成模型在做分類分群時，將不同特徵相混起在一起，造成模型最後預測效果不佳。例如：PM_{2.5} 的組成因素很多，要進行長期預測時，勢必要考慮眾多組成因子與空污來源，與預測地區本身過去產生的空氣污染因子，但並不代表每個地區影響空氣污染因子的原因都一樣，但如果將眾多因子同時輸入在機器學習模型中，

模型也會將影響較低或者沒影響的特徵也考慮進去，這樣帶來的效果不但不能提升預測績效，還有可能會降低預測的準確性。

2.3.3 深度學習方法

為了克服先前方法所遇到的問題，專家人員開始採用深度學習方法，此方法是在後期專家學者最常使用的方法，該方法可以對神經元的進行多種功能的設計，來有效解決各地區複雜因素造成的空氣污染問題。例如神經元可以設計成具有記憶與遺忘的功能，或者能捕捉所輸入矩陣的空間關係，又或者能夠將自己設計的數學函數結合神經元進行計算與修正，也可透過神經元的升維或降維的方式將資料進行分割獲得良好的分類結果，在過去深度學習技術的論文中表示有一定程度上解決空污複雜問題。Ma *et al.*[20]學者收集了中國廣東地區的監測站一年的空氣污染資料，使用多種機器學習方法與深度學習方法預測中國廣東地區空氣污染數值，從中發現雙向長短期類神經網路(Bidirectional Long Short-Term Memory, BLSTM)方法有效捕捉時間序列特徵與空間關係，整體績效相較機器學習穩定與準確。Soh *et al.*[31]學者透過不同功能的深度學習網路，包含長短期類神經網路(LSTM)、卷積類神經網路(CNN)以及人工類神經網路(ANN)預測 PM2.5 濃度，利用不同的神經網路挖掘 PM2.5 的時空關係，從研究結果中得知捕捉空間關係的 CNN 績效表現較其他兩者類神經網路來得佳，且共同將三種網路融入在同一個模型中時，其表現結果最穩定。雖然空氣污染問題在深度學習網路中是可以獲得改善，且不需要大量的專業知識，可以將所有收集到的資訊丟入模型中，讓模型自行學習重要特徵，但面對要做提前預報讓民眾得知，深度學習模型龐大的運算量，會因為輸入資料的資訊過多或者模型本身的數學運算成本導致運算時間過久，且神經網路的運算過於複雜，想從中了解到底是何種物質或地區去影響這次 PM2.5 的準確率時，也相對較難從中去探討。

表 二-1 空氣品質預測方法之相關文獻整理

大氣科學方法		
作者	目標	方法
Balasubramanian <i>et al.</i> [34]	預測未來空氣品質狀況	網格、化學模型與天氣模型
Saide <i>et al.</i> [29]	預測地區的空气品質濃度	Weather Research and Forecasting 化學傳輸模型
機器學習方法		
作者	目標	方法
Di <i>et al.</i> [32]	提升預測 PM2.5 績效	集成學習
Liu <i>et al.</i> [14]	挑選具有重要影響力的因子進行預測	小波分解、Adaboost、SVM 模型、GRNN
深度學習方法		
作者	目標	方法
Ma <i>et al.</i> [20]	預測廣東地區空氣污染數值	BLSTM
Soh <i>et al.</i> [31]	預測 PM2.5 濃度	LSTM、CNN、ANN

2.3.4 過往預測方法綜合比較

在以上過去文獻中都有證實三種（大氣科學、統計與機器學習、深度學習）方法應用在 PM2.5 上都有成功被預測，以下我們將針對這三大方法進行綜合比較，根據表 2-1 比較三種方法在不同模型需求中的優劣。在短時間預測上可以看到大氣科學與深度學習都有著重考慮到因子的變化進行特徵挑選對於短期預測上較為準確，但在長時間預測上因為空氣品質會受到很多因素的影響，因此大氣科學較難判斷長時間會發生的情況，而深度學習會透過先前學習到的時間與空間特徵，有更好的長時間預測效果，也因為大氣科學較能考慮當下目前的因子的變化性，對於重要特徵以及解釋力也都會較其他兩種方法來得高。至於統計與機器學習與深度學習皆屬於透過歷史資料中學習，深度學習在訓練過程中過於複雜，因此對於因子解釋力較差，而統計與機器學習雖說可進行皮爾森相關性分析的研究，但會因所分析的時間長短，會導致分析結果因子的影響程度被降低或升高，對於空氣污染的問題較難抓取到重要影響因子。最後在模型運算成本上大氣科學的學者們需要不斷的透過化學物之間的影響性去分析與探討，從新定義數學模型，導致每次所使用的模型

皆不同且會帶來大量的運算時間。在深度學習隱藏層神經元中因擁有大量的數學運算與修正，這常常會導致輸入大量的資料，運算成本過高，沒辦法給予即時的資訊。

表 二-2 過往預測 PM2.5 方法比較表

	大氣科學	統計與機器學習	深度學習
短時間預測準確率	高	中	高
長時間預測準確率	低	中	高
歷史數據	X	V	V
重要因子解釋力	高	中	低
模型運算成本	高	中	高

2.4 特徵工程

本研究將使用深度學習模型建模，在上述介紹深度學習時，有提到深度學習具有大量的運算成本導致無法提供即時個人化預測，因此本研究將會對於空氣污染物進行特徵工程，特徵工程的主要目的：(1)在於從大量的原始資料中提取有用的資訊輸入在最終所使用的預測模型中，並將重要因子輸入至低成本模型中，(2)找出關鍵因子提前預防。而對於目前特徵工程的研究主要是早期的統計方法，但傳統方法較難解決空氣品質非線性的問題，因此將採用高斯函數與二維高斯函數結合深度學習進行特徵工程解決傳統模型的侷限性，以下將進行介紹。

2.4.1 以統計方法進行特徵工程

在早期學者對於空污的特徵工程分析大多是使用 Person Correlation 去分析及研究，像是 Filonchyk *et al.*[27] 使用 Person Correlation 去分析及研究 PM2.5 與其他氣態污染物之線性關聯性。Zhai *et al.*[4] 使用 Pearson Correlation 與空間分析，去了解 PM10 和 CO 是影響北京 PM2.5 的重要關鍵因素，也發現廊坊市的污染物是相較於其他地區而言影響北京空氣品質的因子之一，也說明各地區的影響因素皆需要個別研究才能去證實。Kumar *et al.*[35]為了有效解決 PM2.5 複雜組成因素的問題，將風速、風向、太陽輻射、氣壓等多種因素，利用相關性分析當作因

子篩選工具，最終篩選 13 個因子預測 PM2.5。然而，大多的統計方法只能提供探討到變數與變數之間的影響性，且需要具有穩定下的線性關係，對於像 PM2.5 這種非線性關係時則較難被探討到。

2.4.2 以機器學習進行特徵工程

傳統統計的線型模型局限性的問題，在中期時，開始有許多專家學者改用機器學習模型方法進行特徵挑選。Chen *et al.*[51] 透過虛假最近鄰居方法(Modified False Nearest Neighbor Method, MFNNM)將特徵映射到向量空間，並找出其空間相似性，挑選出與預測目標最相關的因子當作預測模型的輸入，獲得良好的預測結果。Zhu *et al.*[8]在糖尿病的研究中，由於資料混雜許多訊息，因此使用了 Principal Components Analysis(PCA)提取影響糖尿病發病因子，並發現了有提取因子的羅吉斯迴歸(Logistic regression, LR)模型準確率比沒提取因子前佳。Ali *et al.*[24]在疾病資料檢測上，使用線性判別分析(Linear Discriminant Analysis,LDA)去找尋影響肝癌的相關因子，並透過 SVM 進行預測得病率，透過提取因子不僅提高了預測準確率，更減少了模型的訓練時間。Zhang *et al.*[55]在用戶資料中，使用 LDA 提取用戶使用偏好，並透過 LSTM 網路預測使用者下一個動作，並依據動作推薦使用者服務，在結果上表明具有 LDA 提取用戶偏好準確率比只用 LSTM 預測來得佳。

2.4.3 以高斯函數進行特徵工程

高斯函數全名為 Radial Basis Function(RBF)，此方法主要是根據某種距離來描述點與各個中心點的相似度，樣本空間中非線性問題，本研究希望通過一種映射把他映射到高維空間裡使問題變得線性，讓資料可以線性分割，將此函數與類神經結合較能逼近最佳解。Rajkumar *et al.*[28] 透過具有一維高斯函數的徑向基函數核(Radial Basis Functio, RBF)類神經網路去挑選影響皮膚疾病的相關特徵，挑選後的準確度達到 96%，結果說明，在 RBF 神經元空間中進行的特徵選擇比在原始空間中獲得的結果更佳準確。Liu *et al.*[36] 透過一維高斯函數挑選多種得到癌症的重要基因並加以進行癌症分類，結果指出高斯函數挑選出來的特徵具有較高的準確性，

還可以加以了解導致得到不同癌症的基因狀況，而在兩類數據集和多類數據集的分類準確性方面，高斯函數優於所有其他使用的特徵選擇方法，尤其是在樣本較少的數據集中。

2.4.4 以二維高斯函數進行特徵工程

二維高斯函數在圖片上具有減少圖像雜訊以及降低細節層次，其視覺效果就像是經過一個半透明屏幕在觀察圖像，利用常態分佈計算圖像中每個像素矩陣進行高斯轉換，其公式產生的原理主要是透過中心點開始擴散產生常態分佈的同心圓，每個矩陣點的值透過周圍相鄰點的加權平均，原始中心點的值有最大的高斯分佈值且具有最大的權重，離中心點越遠，其權重就會越小，如果沒有模糊與清晰的邊界，這樣就不會在做濾波圖像中形成震盪，帶來良好的效果。Hwang *et al.*[18] 提出透過二維高斯函數的濾波檢測方法提取特徵向量，該種提取方式在支持向量機器分類上具有出色的結果。Mirzapour *et al.*[11] 透過具有二維高斯函數的高斯濾波器提取光譜圖中的空間特徵，透過濾波器過濾掉了不必要的空間資訊，透過篩選後的空間特徵在 SVM 中獲得良好的分類準確率。

2.4.5 以深度學習進行特徵工程

深度學習在預測表現上通常都有令人滿意的結果，但大部分的實驗都是將焦點放在模型最終的預測能力上，很少數的研究會將重點放在所輸入的特徵中，但實際上輸入的特徵就決定了這個模型效果的上限。接下來將介紹深度學習特徵工程的三種方法。(1)Word2Vec 模型是一種預測的深度學習模型，用於計算神經元中的單詞向量，並捕捉其上下文和句子的相似性，向量的總數就是所有輸入詞彙的大小，這使得該向量空間的維度明顯低於傳統詞帶模型高維度的向量空間，Zhang *et.al*[7]學者們指出新聞文章的專業術語常使讀者難以理解，因此在新聞中使用神經網路結合 Word2Vec 的方式訓練文本內容，計算單詞之間空間的相似性提取關鍵詞，並在實驗過程中驗證了此方法的可行性。(2)知識蒸餾(Knowledge Distillation)方法被應用在深度學習中，屬於模型壓縮的一種，此方法主要是訓練兩個模型一個

是學生模型一個是導師模型，導師模型透過蒸餾的方式萃取出所學習到的權重知識，並將這些精華的知識利用監督是方式訓練參數量較小的學生模型，透過不斷的學習，將重要特徵萃取出來，提升學生模型精準度，達到縮小模型提升準確率的目的。Cenggoro[40]學者對圖像進行分類，分類模型使用 EfficientNet 遷移學習模型，並使用蒸餾法將 EfficientNet 模型的特徵資訊轉移給較小的模型進行訓練，在結果表現幾個較小的模型中整體表現上更勝過原始的 EfficientNet 模型。(3)Grad-CAM(Gradient-weighted Class Activation Mapping)此方法是透過給定輸入影像，取得卷積層的輸出特徵圖，利用梯度值權重來加權輸入影像對各 Channel 激活的強度，判斷此圖像重要位置，He *et.al*[39]學者將 Grad-CAM 方法與深度學習 MLP(Multilayer perceptron)結合設計出 MediMLP 模型，研究肺癌術後併發症，在預測方法中，利用此模型來提取肺癌的關鍵特徵，其結果比原本的 MLP 模型與其他機器學習模型績效來得更佳。

表 二-3 特徵工程之相關文獻整理

統計分析方法		
作者	目標	方法
Filonchuk <i>et al.</i> [27]	PM2.5 與其他氣態污染物之線性關聯性	Person correlation
Zhai <i>et al.</i> [4]	找出影響北京 PM2.5 的重要關鍵因素	Pearson Correlation、空間分析
Kumar <i>et al.</i> [35]	篩選因子去預測 PM2.5	相關性分析
機器學習方法		
作者	目標	方法
Chen <i>et al.</i> [51]	挑選出與預測目標最相關的因子	MFNNM
Zhu <i>et al.</i> [8]	提取影響糖尿病發病因子	PCA、LR
Ali <i>et al.</i> [24]	提取影響得到肝癌的相關因子	LDA
Zhang <i>et al.</i> [55]	提取用戶使用偏好	LDA
高斯函數		
作者	目標	方法
Rajkumar <i>et al.</i> [28]	挑選影響皮膚疾病的相關特徵	一維高斯函數
Liu <i>et al.</i> [36]	挑選多種得到癌症的重要基因	

2D 高斯函數		
作者	目標	方法
Hwang <i>et al.</i> [18]	提取特徵向量	二維高斯函數
Mirzapour <i>et al.</i> [11]	提取光譜圖中的空間特徵	
深度學習方法		
作者	目標	方法
Zhang <i>et.al</i> [7]	計算單詞之間空間的相似性， 並提取關鍵詞	Word2Vec 模型
Cenggoro[40]	萃取重要特徵進行圖像分類	EfficientNet 遷移學習模型
He <i>et.al</i> [39]	提取肺癌的關鍵特徵	Grad-CAM、MLP

2.5 類神經網路於空污議題上的應用

2.5.1 淺層類神經網路

類神經網路的基礎概念是模擬人類大腦是如何來解決複雜問題的假設並予以模型化。神經網路可以將其拆分為輸入層(Input layer)、隱藏層(Hidden layer)及輸出層(Output layer)，如圖 2-1 所示，網路中的每一層都有許多神經元，而神經元與神經元的連接層主要是倚賴權重(Weight)和偏差(Bias)。除了權重和偏差外，網路層的輸出還需加上激活函數(Activation Function)，如果沒有加上激活函數的話，不管把網路增加多深，網路所能學習到的也只是一條線性方程式。在神經元的設計中，也可依造研究人員的需求去自行做調整，研究人員現今只需要輸入合適的特徵值，便可依照所要目標去設置類神經演算法以便去進行各種不同功能的預測。Chen *et al.*[50]使用 BP 神經網路的數學模型，透過衛星污染數據，預測未來 3 小時 PM2.5，該方法有效建立了 PM2.5 濃度之間的相關性，也彌補了機器學習預測的局限性。Wang *et al.*[47]提出了使用遺傳演算法改進前饋神經網路的結構，提出了一種改進的神經網路，此方法在預測 PM2.5 濃度上具有較好的績效，提高了預測的準確性，也降低了錯誤率。同時針對預測資料的目標與特性，調整神經元裡的架構或參數，可以帶來更好的結果。




圖 二-1 類神經網路示意圖

2.5.2 卷積類神經網路

卷積類神經網路(Convolutional neural network，以下簡稱 CNN)近年來在影像辨識和聲音辨識都有不錯的效果，特別是影像辨識。CNN 主要是影像做局部的特徵擷取，而每一層卷積負責檢測的特徵都不同，一個典型的卷積神經網路如圖 2-2，是由卷積層(Convolution layer)、池化層(Pooling Layer)。卷積層的原理是透過許多的卷積核(又稱濾波器)在圖片上進行滑動，透過不同濾波器在影像上滑動可以產生不同作用，例如：邊緣檢測、模糊等功能，但這些濾波器並不是剛開始就具有檢測圖像的功能，而是透過不斷的訓練與修正更新其參數，才具有學習有利於此圖像的濾波器。池化層常使用來進行下採樣運算，池化層大多都是透過 Max 或 Mean 的張量運算。一般來說，平均池化層保留更多的背景資訊，而最大池化層則保留更多的圖像資訊。Huang *et al.*[6]為了預測 PM2.5 濃度，將卷積類神經網路和長短期類神經模型結合起來預測 PM2.5，透過多次驗證證實了此方法的可行性與實用性。Zheng *et al.*[42]使用衛星圖像透過卷積類神經網路與隨機森林方法預測 PM2.5 濃度，此方法主要是利用卷積類神經網路抓取圖像的空間因子，並透過空間因子準確

的預測 PM2.5 濃度。Eslami *et al.*[9]使用卷積類神經模型預測韓國首爾的臭氧濃度，模型最終結果表示，目標氣象站的地形和氣象條件穩定，卷積類神經模型成功捕獲了臭氧濃度的每日趨勢以及每年的高低變化，成功預測該地區的臭氧。綜合上述可以得知，現今卷積類神經網路已經被運用在具有地形或圖像輸入的空氣污染模型中，都有不錯的績效，透過卷積的方式快速看出空污擴散情形，也具有提取關鍵地點的功能。




圖 二-2 卷積類神經網路示意圖

2.5.3 長短期類神經網路




圖 二-3 長短期記憶類神經網路示意圖[61]

長短期記憶類神經網路全名(Long Short-Term Memory, LSTM)又名 LSTM，是經過循環神經網路(Recurrent Neural Network, RNN)改良而來，主要是解決在 RNN 中，發生梯度消失的問題，導致長期記憶被短期記憶所隱蔽。LSTM 是目前常見的其中一種時間序列預測模型如圖 2-3 此種模型被廣泛使用在各種領域，如數理統計、經濟、天氣預報、控制系統等等。Zhao *et al.*[22] 利用 Long Short-Term Memory-

Fully Connected(LSTM-FC)神經網路預測內蒙古未來 48 小時 PM2.5，並與人工類神經網路進行比較，結果表明 LSTM 有更好的預測結果。Tsai *et al.*[54]使用 LSTM 預測台灣 66 個站點未來 4 小時數據，結果表明，該方可以有效預測 PM2.5。Zhang *et al.*[5]使用 Bi-directional Long Short-Term Memory(Bi-LSTM)成功預測 PM2.5 並揭露 PM2.5 與氣候之間的相關性。Ma *et al.*[19] 設計 Geographic Long Short-Term Memory (Geo-LSTM)，內插 PM2.5 空間分佈，並使用 LSTM 完成時間特徵提取，有效解決了 PM2.5 的時空相關性。綜合上述可以得知，現今長短期類神經網路已經被運用在各種領域且都有得到很好的績效，不僅是時序資料甚至到文本內容都可以處理。

表 二-4 類神經網路應用於空污議題之相關文獻整理

淺層類神經網路		
作者	目標	方法
Chen <i>et al.</i> [50]	預測未來 3 小時 PM2.5	BP 神經網路的數學模型
Wang <i>et al.</i> [47]	預測 PM2.5 濃度	前饋神經網路
卷積類神經網路		
作者	目標	方法
Huang <i>et al.</i> [6]	預測 PM2.5 濃度	卷積類神經網路
Zheng <i>et al.</i> [42]		長短期類神經模型 空間因子、隨機森林方法
Eslami <i>et al.</i> [9]	預測韓國首爾的臭氧濃度	卷積類神經網路 卷積類神經模型
長短期類神經網路		
作者	目標	方法
Zhao <i>et al.</i> [22]	預測內蒙古未來 48 小時 PM2.5	LSTM-FC
Tsai <i>et al.</i> [54]	預測台灣 66 個站點未來 4 小時數據	LSTM
Zhang <i>et al.</i> [5]	預測 PM2.5 以及 PM2.5 與氣候之間的相關性	Bi-LSTM
Ma <i>et al.</i> [19]	預測 PM2.5 以及解決時空相關性	Geo-LSTM

2.6 小節

綜合上述之文獻回顧，可歸納出下列幾點：

1. 綜觀過往對空氣污染的研究，無論是大氣科學方法、機器學習方法或是深度學習方法，都能成功進行預測。但若以本研究希望高精準度的預測結果而言，以深度學習方式進行預測會是目前最佳的選擇。
2. 為加強模型運作的整體效率及提高預測績效，進行特徵工程，由於本研究的模型輸入維度是由時間與空間組合而成，因此在特徵工程的選擇上使用三維的高斯函數進行特徵選取。
3. 依據不同資料的屬性進行不同模型的訓練，並將這些模型進行結合，使模型整體的訓練與預測績效提升。

第三章 資料集

本研究收集了行政院環保署提供的空氣品質資料集，針對空氣污染物 PM2.5 每小時尺度資料進行實驗，資料集測站收集範圍僅限臺灣本島，以及外島地區(金門、澎湖和馬祖)，本實驗預測範圍主要針對臺灣中部地區，因為臺灣其他地區的 PM2.5 數值可能會受到其他國家影響(南部地區會受菲律賓影響；北部地區會受日本、韓國等國家影響)，因此目標預測站為中部的五大測站，以下將說明本研究所收集到的測站相關資料以及針對其中的五個測站進行統計後的結果。

3.1 收集臺灣測站相關資料

本研究數據擷取自環保署空氣品質監測網，資料範圍為 2018 年 1 月 1 日 0 時至 2019 年 12 月 31 日 23 時，研究區段資料筆數共 17520 筆。本研究選擇的測站為行政院環保署空氣品質監測網全台灣測站點分布共 76 站如圖 3-1，北部空品區 25 站、竹苗空品區 6 站、中部空品區 11 站、雲嘉南空品區 11 站、高屏空品區 15 站、宜蘭空品區 2 站、花東空品區 3 站以及外島地區 3 站。另外，從網站上的多項污染物質中先挑選出空氣污染物(PM2.5)每小時濃度資料進行研究，其欄位名稱包含日期、測站以及 PM2.5 濃度，共 3 種資料欄位，其範例如表 3-1 所示。




圖 三-1 環保署空氣品質監測站架設地點[59]

表 三-1 行政院環保署空氣品質監測網歷史資料

日期	測站	PM2.5	日期	測站	PM2.5	日期	測站	PM2.5
2020/12/03 00:00:00	西屯	9	2020/12/03 00:00:00	金門	14.2	2020/12/03 00:00:00	富貴角	16.4
2020/12/03 01:00:00	豐原	7	2020/12/03 01:00:00	馬公	13.2	2020/12/03 01:00:00	觀音	16.5
2020/12/03 02:00:00	沙鹿	8	2020/12/03 02:00:00	高雄	11.3	2020/12/03 02:00:00	馬祖	17.2

3.2 目標預測站點資料分析

本研究從全臺灣測站點挑選出中部地區測站豐原、沙鹿、西屯、忠明以及大里測站設為目標預測站點，共 5 個測站，以下將分別統計 5 個測站在兩年期間的描述性統計、每月的平均空污數值、各測站的盒鬚圖，以及比較北中南及外島數值之間相關性。



圖 三-2 目標預測空氣監測站位置分布

本研究計算台中 5 個測站從 2018 年至 2019 年描述性統計值，如表 3-2 所示，以及每個月 PM2.5 濃度的平均值，如圖 3-3 所示。透過統計分析可以得知，本研究所收集的測站資料屬於時間序列資料，時間序列資料的特性為該資料的每一筆

資料之間具有相關性，另外也能從圖中發現在不同月份下，PM2.5 濃度的平均數值呈現不同趨勢，以及該數值的高低點皆不相同。

表 三-2 豐原、沙鹿、西屯、忠明、大里測站 2018 至 2019 描述性統計

描述性統計	豐原測站	沙鹿測站	西屯測站	忠明測站	大里測站
Count	17520	17520	17520	17520	17520
Mean	18.170	17.160	19.640	19.832	16.309
Std	11.732	12.946	13.042	13.508	11.756
Min	1.0	0	0	1.0	0
25%	10	8	10	10	8
50%	16	14	17	17	14
75%	24	23	26	26	23
max	110	137	106	104	98




圖 三-3 豐原、沙鹿、西屯、忠明、大里 2018 至 2019 月平均折線圖

為了得知測站數值的資料分布，本研究將台中 5 個測站從 2018 年至 2019 年 PM2.5 濃度的畫出盒鬚圖，如圖 3-4 所示，圖中可以得知在台中這 5 個測站的數值平均值與百分位數相似度較高，測站間濃度值較無明顯差異，但是在其中可以觀察到台中沙鹿地區的盒鬚圖具有離群值，而其他地區的趨勢都趨於一致，本研究推斷可能因為該地區的位置屬於工業區，在濃度上的數值會隨著工業區所排放的污染物而有變化，因此單特定區域可能會發生較高的 PM2.5 數值。




圖 三-4 豐原、沙鹿、西屯、忠明、大里 2018 至 2019 盒鬚圖

接著，透過實際資料觀察測站間彼此 PM2.5 數據相關性，如圖 3-5 所示，分析結果發現到測站與測站間是具有相關性的，因此後續研究將會使用多測站當作輸入進行預測建模。以沙鹿測站舉例，可以觀察出周圍距離較近的四個測站豐原、西屯、忠明和大里，其測站間的相關性至少都超過 0.6，而在距離較遠的外島金門、澎湖和馬祖地區，相關性也高達 0.4，因此可以得知測站之間皆具有一定程度的關聯。

	豐原	沙鹿	西屯	忠明	大里	富貴角	左營	花蓮	金門	馬祖	馬公
豐原	1	0.6	0.7	0.72	0.72	0.2	0.22	0.18	0.26	0.33	0.19
沙鹿	0.6	1	0.81	0.79	0.69	0.4	0.39	0.26	0.47	0.51	0.31
西屯	0.7	0.81	1	0.88	0.78	0.32	0.35	0.25	0.42	0.45	0.27
忠明	0.72	0.79	0.88	1	0.81	0.29	0.36	0.25	0.41	0.44	0.26
大里	0.72	0.69	0.78	0.81	1	0.23	0.35	0.25	0.35	0.38	0.23
富貴角	0.2	0.4	0.32	0.29	0.23	1	0.24	0.3	0.42	0.47	0.48
左營	0.22	0.39	0.35	0.36	0.35	0.24	1	0.19	0.44	0.43	0.32
花蓮	0.18	0.26	0.25	0.25	0.25	0.3	0.19	1	0.29	0.28	0.28
金門	0.26	0.47	0.42	0.41	0.35	0.42	0.44	0.29	1	0.5	0.56
馬祖	0.33	0.51	0.45	0.44	0.38	0.47	0.43	0.28	0.5	1	0.46
馬公	0.19	0.31	0.27	0.26	0.23	0.48	0.32	0.28	0.56	0.46	1

圖 三-5 測站之間的相關性圖

由於在資料觀察中，西屯測站 2019 年下半年資料中觀察在 6 月至 9 月時並未有特別高起伏的 PM2.5 數據出現(如圖 3-6 所示)，若預測時間在 9 月底之後，而訓練時間設置在 6 月至 9 月期間，可能會導致預測不到高點，因此訓練時間長度則需輸入具有明顯起伏的數值資料，否則預測結果可能會不如預期。




圖 三-6 行政院環保署西屯測站 2019 年下半年 PM2.5 折線圖

3.3 處理資料集所遇到的問題

本研究處理空污資料集所遇到的困難點以下將列點說明：

- (1) 裝置本身的問題：監測站所收集到的空氣污染資料，在傳輸的過程中就會有約 10% 的資料遺失，再加上其他因素的影響，導致更多的資料遺漏，而資料庫中有缺失值的存在，如圖 3-7 所示，往往會影響資料分析的品質，所以如何妥善處理這些缺失值會非常的關鍵。



圖 三-7 行政院環保署基隆測站 2021 年 5 月 10 日 PM_{2.5} 缺失值折線圖[57]

- (2) 資料轉換的問題：由於空污會隨著時間向不同的地點擴散，但本研究收集到的資料屬於時間性的數值資料，並未包含空間性的資料，所以透過將資料轉換成地圖的方式，如圖 3-8 所示，把原始時間性的數值資料結合空間性的地理資料，可以讓結果能更加符合現實情況。




圖 三-8 PM_{2.5} 數值轉換空間示意圖[62]

第四章 研究方法

本論文提出之模型 3D-RBF-CNN-LSTM(3D-RCL)概念以三維高斯函數結合卷積與長短期記憶類神經模型的方式，捕捉矩陣型態中時間序列資料與空間事件之特徵，本研究流程分為兩個部分，分別為 Offline 訓練、Online 運作兩個部分，首先在 Offline Processing 包含兩輪動作。第一輪分成 4 個步驟，(1)將所有收集到的空污數據進行資料清洗，而資料清洗過程採用線性插值法。(2)將清洗過後的資料使用反距離權重法，將實際測站資料與測站經緯度轉換成 150×150 的網格圖像。(3)以網格化後的 PM2.5 數值資料當作輸入，目標測站數值當作輸出來訓練 3D-RCL 模型。(4)將預測結果透過 Threshold 找出每個輸入因子在 3D-RBF 網路層的重要度。第二輪則包含三個步驟，包含(1)對 3D-RBF-CNN-LSTM 重複訓練多次，獲得訓練好的最終結果。(2)將訓練好的模型取出 3D-RBF 的第三層神經元輸出並計算其標準差。(3)進行最終階段的篩選，即挑選出重要時間段中的重要地點。最後經過 Offline 挑選的最佳時間與空間特徵後，將挑選特徵進行 Online 模型的輸入，並使用機器學習模型完成即時預測。以下介紹 3D-RCL 模型各步驟的細節。




圖 四-1 研究流程圖

4.1 資料清洗-線性插值法

空氣污染資料收集是藉由檢測器，若檢測器故障或是定期維護停機，將造成資料缺失，對於這樣的缺失值本組將採用線性插值法的方式來補齊。線性插值法是指透過已知的兩點的數值，透過線性的方式找出未知的值，如公式 1、公式 2。

$$V_n = V_{n-1} + n\Delta \quad (1)$$

$$\Delta = \frac{V_c + 1 - V_0}{c + 1} \quad (2)$$

V 代表 PM2.5 數值， c 則是代表資料中缺少的範圍數量， n 則是代表第 n 筆資料。然而資料缺失可能不僅僅是幾小時內的遺漏，倘若缺失時間超過 24 小時，將使用缺失時間前 24 小時與後 24 小時的值以平均方式進行線性插值，如公式 3。

$$V_{(t)} = \frac{V_{t+24} + V_{t-24}}{2} \quad (3)$$

採用此做法的主因是當缺失值範圍過大時，缺失資料很難反應當天的真實情況，因此才會使用前一天與後天一天來模擬當天相同時段可能的空污數值，以貼近真實情況。

4.2 反距離權重法網格化資料

由於空污會隨著時間向不同的地點擴散，但本研究收集到的資料屬於時間性的數值資料，並未包含空間性的資料，因此本研究參考行政院環保署監測網站給定的地形資料與反距離權重法將數值資料轉換成網格，首先將全台空污地圖 3×3 以公里的範圍將全台切割成 150×150 網格地圖，並根據環保署給出地形資料[62]判斷此網格是否需進行補值，如圖 4-2 地形資料網格示意圖，圖中 T 則代表該網格需進行補值，F 則環保署所述該網格位於山區或海上 PM2.5 暫不估計。




圖 四-2 地形資料網格示意圖

後續將需補值的網格以反距離權重法概念進行計算，以一網格為例計算方法主要分為四大步驟(1)投射 76 個測站經緯度資料至地圖中。(2)計算網格與每個測站座標的實際距離，如公式 4。

$$distance = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \quad (4)$$

其中 x_1 、 y_1 代表測站經緯度， x_2 、 y_2 則代表網格經緯度。(3)判斷每一個測站點與網格彼此距離是否具有影響性，有影響性則會將該測站 PM2.5 納入後續計算，無影響性則剔除。(4)參考行政院環保署計算公式，使用 IDW 反距離權重法概念進行網格補值，如公式 5、公式 6。

$$weight = 1 \div distance^3 \quad (5)$$

$$final_pm2.5 = \left[\sum_{i=1}^N weight_i \times pm_i \right] \div \left[\sum_{i=1}^N weight_i \right] \quad (6)$$

其中 weight 是影響性，weight 的大小是由 distance 三次方之反比計算得，主要計算測站對於目標影響性，如公式 5 所示。 pm_i 是目前該測站的 PM2.5 數值，最終透過公式 6 加總並平均所有測站對於網格之間的影響，計算結果為該網格的 PM2.5 數值，其餘網格也參考此方法，最終如圖 4-3 為完成後示意圖。透過此方法將原始時間性的數值資料結合空間性的地理資料，可以讓結果能更加符合現實情況。




圖 四-3 反距離權重法網格化地圖

4.3 使用 3D-RBF 結合 CNN 與 LSTM 建模

在訓練淺層類神經於矩陣型態之時間序列後，對於時間序列之預測可能無法掌握更細部之特徵與短期趨勢，使模型無法因應此狀況造成預測不準確，造成理想值與實際值有所差異，因此本研究透過 3D-RBF 函數結合卷積類神經網路(CNN)與長短期記憶類神經(LSTM)中進行建模。

本篇論文所使用的 3D-RBF-CNN-LSTM 模型如圖 4-4 所示，包含了輸入層、3D-RBF 層、CNN 層，以及 LSTM 層。以下說明各層於本研究中分別執行的工作內容。

首先是輸入層，一開始不對輸入層做任何運算，僅是把收集到的空污地圖特徵值輸入模型的輸入層中。假設收集的資料有 $m \times m$ 個 PM2.5 網格數值，首先取 T 個過去時間的 PM2.5 網格數值，則此研究模型就會預計有 $m \times m \times T$ 個輸入特徵，接著為 3D-RBF 層，3D-RBF 層裡面又會分成三層，而 3D-RBF 層的第一層功能是将所有輸入的空污地圖特徵值經過高斯函數的計算，轉換成新的特徵值，並將這些新的特徵值當作 3D-RBF 第一層神經元，此神經元的函數如公式 7，




圖 四-4 3D-RCL 模型研究架構圖

$$O_{ab} = \exp \left[\frac{-(Output_{input} - k_{ab})^2}{\sigma_{ab}^2} \right] \quad (7)$$

其中 a 與 b 分別表示模型的第 a 個輸入以及其第 b 個 RBF 函數，而 k 和 σ 則代表神經元中 RBF 函數的平均值及標準差。RBF 函數就是高斯函數，可以協助標記重點資料的區域，舉例來說，圖 4-5 為訓練初始狀態，此時要將三個不同深度的圓圈進行區隔，透過 X2 的 RBF_1 、 RBF_2 、 RBF_3 神經元與 X1 的 RBF_1 、 RBF_2 、 RBF_3 神經元進行訓練，在訓練最終結果如圖 4-6 發現已成功將三個不同深度圓圈區隔，但可以從訓練結果中發現主要讓此圓圈分開的神經元為 X2 的 RBF_1 、 RBF_2 、 RBF_3 神經元，X1 的 RBF_1 、 RBF_2 、 RBF_3 神經元在最終訓練結果中幾乎重疊，對於區隔圓圈影響力較小，此時將判斷 X2 為重要影響模型特徵，而 X1 為較不影響模型特徵，透過此概念，本研究將讓模型自行學習找尋到每個網格中最佳的時間點。




圖 四-5 RBF 訓練初始狀態示意圖




圖 四-6 RBF 訓練結束狀態示意圖

接著，第一層 RBF 層的輸出會透過兩個參數窗格大小 w 以及步伐 s 進行時間的壓縮，透過設置窗格大小 w 對每個網格過去時間 T 抓取 w 個神經元數量濃縮在同一個神經元中，接著依據所設定步伐 s 抓完空污地圖中該地區所有的時間點，最終第二層 RBF 的神經元將有 $m \times m \times ((T - w) / s + 1)$ 個神經元。舉例說明：假設輸入過去 12 小時的 5×5 網格中，取出其中一個 A 網格，將窗格大小 w 設置為 4，步伐 s 設置為 2，將會先抓取 T-11 至 T-8 過去 4 個時間段，輸入至第二層第一顆神經元中，接著會再依據移動步伐 2 抓取 T-9 至 T-6 過去的 4 個時間段輸入至第二層第二顆神經元中，依此類推最終在 A 網格總共會產生 5 個時間段神經元，如圖 4-7。




圖 四-7 壓縮時間 RBF 神經示意圖

接著其他網格參考此做法，最終在 3D-RBF 第二層總共會產生 $5 \times 5 \times 5$ 個神經元。會使用此做法主要是想透過前述 RBF 函數輔助類神經學習的概念，讓類神經可以在多個時間中經由完整的學習過程中找尋對於預測中較有幫助的時間段，優化學習。

經由 3D-RBF 第二層壓縮每個網格時間後，因前面處理時間關係目前神經元並無空間性，而後續需轉換二維空間 RBF 神經元，因此在輸入第三層前，本研究會將同一時間段的地區重新排列為具有空間性的矩陣，還原原本的空間型態。舉例說明如圖 4-8，時間段 T-11 至 T-8 的神經元 A 與時間段 T-11 至 T-8 的神經元 B 將會輸入至 T-11 至 T-8 的空間矩陣中，還原其原本的空間性，而後將所有同一時間段的神經元皆會重塑為原本具有空間矩陣的神經元。




圖 四-8 神經元相同時段回朔原始空間示意圖

轉換空間性神經元後每個時間段矩陣皆會輸入至 3D-RBF 中的第三層中，此層的主要功能是將每個邊長大小為 m 輸入轉換成 m^2 個特徵值，則代表本層的神經元有 $m \times m \times ((T-w)/s+1) \times m^2$ 個神經元，而每顆神經元中都包含了一個二維空間 RBF 函數，此二維空間 RBF 與第一層 RBF 差別在於此網路層是經由周圍空間模糊的方式所組成的高斯函數矩陣，經由輸入的空間矩陣與二維空間 RBF 計算後，透過完整的訓練，每顆時間段神經元輸出都代表在訓練過程中在這個時間段上此

空間的重要度。舉例來說：經由第二層 RBF 輸出重塑為 5 個時間段 5×5 的空間矩陣，經由此矩陣與二維空間 RBF 計算後，每一時間段內的每一網格皆會產生一個與二維空間 RBF 進行運算，運算後的神經元輸出結果，則代表該層具有 5×5^2 個神經元，神經元輸出則代表該時間段中該網格經過訓練後的重要性。其神經元公式如下：

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2} \quad (8)$$

$$\begin{bmatrix} (-2,-2) & (-1,-2) & (0,-2) & (1,-2) & (2,-2) \\ (-2,-1) & (-1,-1) & (0,-1) & (1,-1) & (2,-1) \\ (-2,0) & (-1,0) & (0,0) & (1,0) & (2,0) \\ (-2,1) & (-1,1) & (0,1) & (1,1) & (2,1) \\ (-2,2) & (-1,2) & (0,2) & (1,2) & (2,2) \end{bmatrix}$$

圖 四-9 二維空間 RBF 產生初始中心點

其中 x 與 y 代表二維空間 RBF 產生初始中心點位的絕對位置，如圖 4-9 所示，中心點會走訪每一個網格，而 σ 則是這個神經元中二維空間 RBF 的標準差。產生出來的二維空間 RBF 會對應每個輸入的矩陣做相乘。假設使用 5×5 地區進行建模，就會產生 25 個二維空間 RBF 來描述 5×5 地區的空間情況，則在訓練後其中兩個二維空間 RBF 如圖 4-10、圖 4-11，而圖 4-10 代表此神經元的二維空間 RBF 的中心點在此矩陣的中央， σ 會隨著神經元訓練過程中此 RBF 中心點越重要而讓二維空間 RBF 的寬度也隨之變窄，代表此顆中心點網格影響力對於模型訓練結果中屬於重要特徵。至於圖 4-11 神經元的二維空間 RBF 中心點落在此矩陣的右邊，由於神經元訓練後 σ 數值較大，會讓二維空間 RBF 的形狀變得非常扁平，代表此顆中心點網格影響力對於模型訓練結果中屬於較不重要特徵，在這個情況下，本論文會設定 Threshold，因子小於設定 Threshold 的狀況下，二維空間 RBF 較窄會影響 3D-RCL 的輸出，進而保留。大於設定 Threshold，二維空間 RBF 較寬不會影響 3D-RCL 的輸出，進而剔除。




圖 四-10 中心點落在中間 σ




圖 四-11 中心點落在右邊 σ

接著是 CNN 層，CNN 層主要是由卷積層 (Convolutional Layer) 與池化層 (Pooling Layer) 所組成，首先，3D-RBF 的輸出會與卷積層進行連接，而卷積層即是對輸入的空污地圖網格進行學習，並檢測網格中特定類型的空間特徵，從這些特徵中從中找出當污染物發生擴散情形時，不同網格地圖的空間所受到的效應大小。假設我們有張圖，5×5 的像素圖如圖 4-12，和一個 3×3 的矩陣圖如圖 4-13。

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

1	0	1
0	1	0
1	0	1

圖 四-13 3×3 像素圖

圖 四-12 5×5 像素圖

接著就是將3×3的矩陣在圖片上的像素一步一步移動(在卷積層中移動的步數稱為 Stride 步數)，在每個位置的時候，計算兩個矩陣相對元素的乘積並相加，輸出一個值然後放在一個矩陣(全灰的矩陣)，這就是基本的卷積運算如圖 4-14。




圖 四-14 卷積計算流程圖

透過上方的步驟我們發現，卷積層會依據指定的 Kernel 大小及 Stride，取圖像各區域的特徵值再與 Kernel 各點的權重相乘計算最後得到 Feature Map，此 Map 會傳給下一層的池化層。所以在多個卷積層中，圖像透過 Kernel 萃取後的特徵濃縮再傳遞給下一層，因此愈上層的卷積層會對更小的特徵起反應，而 Kernel 的 Weight 值會在反向傳播時逐次依 Loss 值用激活函數進行梯度修正。之後是池化層，池化層的功能不僅是要減少模型學習的參數量，更是要找出卷積層所生成的空污擴散

特徵圖每個區域中，最重要的特徵區域，其運作為將輸入的圖片尺寸縮小以減少每張 Feature Map 維度並保留重要的特徵，如圖 4-15 介紹 Max Pooling、Average Pooling，Max Pooling 的是用圖片區域中的最大值來表示該區域特徵。




圖 四-15 Pooling layer 介紹

而 Average Pooling 是用圖片區域中的均值來表示該區域的特徵，兩個的概念是當整個圖片進行平移時對判斷上完全不會造成影響，以及有很好的抗雜訊功能。從 Pooling 過程來看，如果原本的輸入圖片，經過 2×2 Pooling Kernel 之後，整個圖片的尺寸將會縮小，如此一來計算成本也將節省一半。本研究主要想找出高濃度 PM2.5 會不會透過風向的流動，對預測區域未來的時間有所影響，因此採用 Max Pooling 關注高濃度 PM2.5 的流動。前面所使用的卷積層和池化層，其主要是想要達到污染物發生擴散情形時，提取重要特徵值，觀測預測的目標區域未來會不會受到其他地區影響發生 PM2.5 濃度上升，最後本研究將 CNN 所擷取到的特徵丟入下一層 LSTM。

CNN 網路層輸出時，將會進入 LSTM 層，LSTM 是一種的遞迴類神經網路，此模型的特性會受到前一個時間點的輸出對現在這個時間點產生影響，適合用於時間序列數據預測。在資料觀察中發現當前的污染物濃度容易受到過去的污染物濃度因素影響，因此本研究使用 LSTM 提取時間序列空污特徵，使整體模型可以學習過去 PM2.5 趨勢，利於未來 PM2.5 預測，在進入此層網路前會先將圖片進行

攤平。舉例來說卷積類神經輸出時為 5×5 的矩陣時，在攤平過後就會變成 1×25 ，代表為 25 顆神經元會被送入 LSTM 層當作輸入。此層的神經元個數則以前一層神經元數目為基準，每個神經元彼此間為全連接關係，公式為：

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (9)$$

$$U_t = I^t \times w_i^t + b_i \quad (10)$$

$$S^t = h_i^t \times kw_i^t \quad (11)$$

$$h_i^t = O_i^{t-1} \quad (12)$$

$$O_i^t = \tanh(U^t + S^t) \quad (13)$$

公式 9 為激活函數其輸出為 0 到 1 之間的值。 U^t 代表的是第 T 的時間點的輸入公式，將輸入 I^t 乘上對應的權重值 w^t 並加上對應偏壓值 b_i ，而 S^t 則為前一個時間點的輸出 h_i^t (即 $h_i^t = O_i^{t-1}$) 乘上其對應的遞迴權重值 kw_i^t ，最後將這兩項輸出加總，並通過激活函數 $\tanh$ 輸出 O_i^t 。LSTM 模型與一般遞迴式類神經網路(RNN)不同主要是因為 LSTM 額外考慮了輸入閘、遺忘閘、記憶細胞向量、輸出閘、隱藏狀態向量等五個元素，解決 RNN 容易造成梯度消失的問題，可以更好的預測長期 PM2.5。

$$F_t = \sigma(W_f \times [H_{t-1}, P_t] + b_f) \quad (14)$$

$$I_t = \sigma(W_i \times [H_{t-1}, P_t] + b_i) \quad (15)$$

$$\bar{E}_t = \tanh(W_e \times [H_{t-1}, P_t] + b_e) \quad (16)$$

$$E_t = f_t(W_e \times E_{t-1} + I_t \cdot \bar{E}_t) \quad (17)$$

$$O_t = \sigma(W_o \times [H_{t-1}, P_t] + b_o) \quad (18)$$

$$H_t = O_t \times \tanh(E_t) \quad (19)$$

其中上述式子中的 W_f 、 W_i 、 W_e 、 W_o 為輸入權重值， b_f 、 b_i 、 b_e 、 b_o 為偏壓值權重， t 為當前時間， $t-1$ 為前一個時間狀態， P 表示為輸入， H 表示為輸出， E 則是代表目前神經元狀態，最後會由類神經網路訓練後求得最佳解。LSTM 的最後為輸出會進入全連接層當作輸入使用。

為能統整前面網路所學習到的重點特徵，在模型最後使用全連接層神經元，並與上一層的 LSTM 相連，各神經元連接點的權重是相同且共享的，因此可以讓各個連結都有獨立且相異的權重值，使預測未來 PM2.5 因應預測時間的不同能產生不同趨勢，例如有個圖像其尺寸是 15×15 ，那麼在第一層就會有 225 個參數 (15×15)，到了下一層隱藏層，將會平方成五萬多個帶有不同權重的連結 (225×225 平方)，因此為了能抓取重要特徵，統整預測結果在此層的付出相當大的運算成本。

$$o_j = \tanh(x_i \times w_{xj}) + b_j \quad (20)$$

其中 x_i 代表前一層神經元的輸出， $\tanh$ 為激活函數， w_{xj} 為前一層輸出對應的權重值， b_j 則是對應第 j 個神經元的偏壓值。

4.4 使用 3D-RBF 篩選重要時間特徵與空間特徵

此小節將介紹如何使用 3D-RBF 挑選時間與空間特徵，其挑選步驟總共有三步驟，首先(1)對 3D-RBF-CNN-LSTM 重複訓練多次，獲得訓練好的最終結果。(2)將訓練好的模型取出 3D-RBF 的第三層神經元輸出並計算其標準差。(3)進行最終階段的地點篩選，即挑選出重要時間段中的重要地點，以下將會詳細介紹上述三步驟，為方便解說此次解說會先將全台網格地圖只拿取一部分 5×5 地圖說明如圖 4-16，而圖片的一次輸入的時間長度則會固定拿取 T-11、T-10、T-9、T-8、T-7、T-6、T-5、T-4、T-3、T-2、T-1、T 過去 12 個時間點來說明。




圖 四-16 網格地圖解說參考示意圖

(1)首先經過 3D-RBF-CNN-LSTM 完整的訓練後，獲得訓練過程中模型每一層的參數資訊。(2)將要預測的時間輸入至訓練後的 3D-RBF-CNN-LSTM 模型中，並提取 3D-RBF 第三層的輸出結果。舉例說明：將 5×5 的空間網格過去的 T-11、T-10、T-9、T-8、T-7、T-6、T-5、T-4、T-3、T-2、T-1、T 當作輸入說明，在 3D-RBF 第一層中假設窗格 w 設置為 6，位移 s 設置為 6，此時在 3D-RBF 第一層與第二層進行時間壓縮時 T-11、T-10、T-9、T-8、T-7、T-6 會被分配到第二層第一顆神經元中，而 T-6、T-5、T-4、T-3、T-2、T-1、T 則會被分配到第二層第二顆神經元中，接著將所有空間網格時間都進行壓縮，具有相同時間段的空間會在第三層輸入前轉換為原本的空間矩陣型態，因此在 3D-RBF 第三層中則會有 2 個時間段的 5×5 網格，而每時間段中的網格皆會與不同中心點向外擴散的 5×5 二維空間 RBF 矩陣進行計算如圖 4-17、圖 4-18。最終計算該層輸出的矩陣標準差，此標準差代表該中心點網格對於模型的重要度。(3)透過各權重特徵圖給予標準差判斷，篩選出重要空間特徵。舉例來說假設將上述 T-11 至 T-6 時間段的空間矩陣 $X = [\text{因子 1}, \text{因子 2}, \text{因子 3}, \dots]$ 如圖 4-19 依序輸入二維空間 RBF 轉換後的隨機中心點的矩陣 $X = [\text{RBF}(\text{因子 1}), \text{RBF}(\text{因子 2}), \text{RBF}(\text{因子 3}), \dots]$ 如圖 4-20 進行計算，最終將輸出矩陣給予標準差判斷，篩選出重要空間特徵。在圖 4-21 可以看到 T-11 至 T-6 時間段在經過訓練後，取出每個網格的權重標準差值，中心點二維空間 RBF 數值越大，會隨之讓整體的二維空間 RBF 寬度隨之越窄，標準差也會隨之越小標示該中心點地

區空間因子較為集中，在後續模型的影像力較大。如範例中的因子 2、因子 3、因子 4、因子 5、因子 7、因子 8 有助於模型後續學習。進而完成篩選為重要特徵的動作。反之中心點二維空間 RBF 數值越小，標準差越大表示該空間因子的常態分布較為發散，對後面模型的影響力較小，如範例中的因子 1、因子 6、因子 9，因此該特徵會被當作雜訊予以剔除。




圖 四-17 T-11 至 T-6 二維空間 RBF 矩陣示意圖




圖 四-18 T-5 至 T 5×5 示意圖



圖 四-19 T-11 至 T-6 5×5 示意圖




圖 四-20 T-11 至 T-6 二維空間 RBF 中心擴散示意圖




圖 四-21 T-11 至 T-6 二維空間 RBF 訓練後示意圖

4.5 篩選後重要特徵進行即時預測

經由找出 3D-RBF 中重要特徵後，由於 3D-RBF 僅能找出輸入的重要時間段，因此要從歷史輸入資料中每筆資料進行過濾。因此，本小節會基於上一小節的概念，從歷史輸入資料中挑選出每個時間段的空間特徵，舉例來說，假設每一筆輸入資料中都含有每個地區的過去 T-11 至 T 的網格資料，而每個地區的網格資料以 5×5 進行切割，因此共有 300 個特徵因子($5 \times 5 \times 12$)，接著，將這 300 個特徵因子，放進 3D-RBF 層中進行重要特徵因子篩選，進而篩選出時間 T-11 至 T-6 六個時間點，且每個時間點中篩出了六個因子，為圖 4-21 較有影響力的因子分別為因子 2、因子 3、因子 4、因子 5、因子 7 和因子 8 作為重要特徵因子，此時共有 36 個特徵因子，之後將每一筆輸入資料按照上述所篩選出 36 個時間與空間因子進行選取，並將篩選出的資料集放入機器學習模型中進行訓練，並使用訓練完成後的模型完成即時預測。以下介紹本研究所使用的機器學習模型，分別為(1)決策樹、(2)隨機森林以及(3)淺層類神經網路。

- (1) 決策樹：決策樹是最常被用來做時間序列預測的方法之一[23][41]，該方法主要透過回歸概念來進行時間序列分析，其輸入的變數可以是任何的資料型態，輸出的目標值則為連續型變數，在分析的過程中，利用樹狀結構，由上而下反覆

進行分枝演算法，直到停止切割的條件為止，上述經過貪心分枝後的決策樹結果會導致複雜度較高，預測較為不穩定，因此為了優化決策樹在資料預測上的穩定度，加入目標函式的懲罰因子(Cost Complexity Parameter, α)來修剪出最適決策樹模型，其加入懲罰因子限制式的目標函數如下：

$$\text{minimize} \{SSE + \alpha |T|\} \quad (21)$$

其中， T 代表的是決策樹的終端節點(Terminal Nodes)數量， α 則為懲罰參數(Cost Complexity Parameter)。基於決策樹在資料預測能有較高穩定度的特性，因此將此方法應用於本論文上。

- (2) 隨機森林：隨機森林[21][32]是由 Bagging 演算法所衍生出的方法，其建構方式為透過多個決策樹建構而成的，但隨機森林與決策樹不同的地方是，隨機森林不需要進行剪枝步驟，因為該方法改採用隨機採樣的部分，就算不進行剪枝也不會出現 Over-Fitting 的情況發生，能夠預測出更準確的結果，因此本研究也利用該方法來進行 PM2.5 的預測。




圖 四-22 隨機森林示意圖[60]

- (3) 淺層類神經網路：淺層類神經網路概念在於，模擬人類大腦是如何來解決複雜問題的假設，並予以模型化。神經網路可以將其拆分為輸入層(Input Layer)、隱

藏層(Hidden Layer)及輸出層(Output Layer)每一層都有許多神經元，而神經元與神經元的連接層主要是倚賴權重(Weight)和偏差(Bias)，其數學式如下：

$$o_j = act(x_i \times w_{xj}) + b_j \quad (22)$$

其中 x_i 代表前一層神經元的輸出， $act(\cdot)$ 為激活函數， w_{xj} 為前一層輸出對應的權重值， b_j 則是對應第 j 個神經元的偏壓值。基於本研究需要進行即時預測的部分，若目標模型太大會影響到運算過程，導致運算時間太長，而淺層類神經的模型較小，在不同領域的應用也達到不錯的成效，因此本研究也將其應用在PM2.5 預測上。

第五章 實驗模擬

本章使用行政院環保署提供的真實 PM2.5 數據集來驗證本論文提出方法的有效性。內容分成三個部分，包含(1)資料集與實驗參數介紹，(2)Threshold σ 之選擇，以及(3)模型績效與評估，以下將會詳細說明。所有實驗則是以 Python 完成，並操作在 Intel(R) Xeon(R) Gold 6230R CPU @ 2.10GHz 的 CPU、Nvidia TITAN RTX 24GB 的 GPU、搭配約 72GB 記憶體以及 Windows 10 的作業軟體來完成。

5.1 資料集與實驗參數介紹

本研究使用行政院環保署提供的 2018 年 1 月 1 日 0 時 0 分至 2019 年 12 月 31 日臺灣本島，以及外島地區(金門、澎湖和馬祖)共 76 個站點每日每小時 PM2.5 資料。本研究使用全台灣 PM2.5 網格來預測測站 PM2.5 數值。首先，將資料切分時間區段 2018 年 1 月 1 日 0 時至 2019 年 8 月 31 日 23 時做為訓練集，剩下的時間區段 2019 年 9 月 1 日 0 時至 2019 年 12 月 31 日 23 時做為測試集，以過去 72 小時的 PM2.5 網格來預測後 24 小時的西屯測站 PM2.5 數值。

過去研究僅透過數值資料當作模型時的輸入，然而本研究為了讓模型能學習到空污的空間性特性，因此(1)先將站點資料與經緯度透過反距離權重法的方式換算轉換成 150x150 網格，嘗試使用不同的遮罩對原始網格切割，且切割不同網格尺寸，由於過大過小都會影響模型的精準度與運算成本，因此經過多次嘗試後決定以遮罩大小 10 將網格化成 15x15 作為本研究輸入。(2)將網格化後的 PM2.5 數值，輸入至本論文 3D-RBF 網路層，在 3D-RBF 第一層的網路層中需先將資料透過攤平的方式，將每個網格(15x15)的過去時間點(t-72)進行攤平並與 RBF 函數進行計算，計算後，將第一層輸出資料輸入至 3D-RBF 的第二層中，在輸入過程需先透過設置的參數窗格 Window 與步伐 Shift 將每個網格中過去多個時間點濃縮至單個時間神經元中，其目的是為了壓縮每個網格的時間維度，並透過類神經學習的方式找出最佳的時間段，在此壓縮階段不僅需考量時間窗格 Window 的設置以及 Shift 的步伐

壓縮的時間成本，同時預測績效也需維持與未壓縮前有相似的預測結果，因此本研究實驗將窗格 Window 嘗試使用 4、6、8、12、18、24、36、48，步伐 Shift 固定為 Window 的一半進行參數實驗，最終考量良好的壓縮時間成本與模型績效，結果在 Window 設置為 12，Shift 設置為 6 時效果為最佳，因此在 3D-RBF 網路的第二層輸出將會有 2475 個神經元，(3)將壓縮後的時間網格輸入至 3D-RBF 第三層中，在此網路層前需先轉換為原本的空間矩陣，轉換為 11 個時間壓縮後的空間網格，而每個空間因子會用都會經過二維空間 RBF 計算，因次在 3D-RBF 的第三層的輸出會有 11x225 個 15x15 的神經元，而後透過兩層的 CNN 卷積層 64，32 個神經元找出 3D-RBF 層輸出的空間關係，接著使用 LSTM 遞迴層 32 個神經元抓取過往空汙的時間關係，最後透過 24 個全連接層彙整並輸出預測結果。(4)將預測結果透過 Threshold 找出每個輸入因子在 3D-RBF 網路層的重要度，將每個因子重要度進行排名，並測試在每個排名中其重要度對於預測模型的準確率，並挑選表現最佳者來當作後續實驗的設定。最後為了驗證本方法有效性，實驗需模擬 30 次，本研究使用 Root Mean Squared Error(RMSE)來評估資料在測試集的預測結果，評估方式的公式則如下所示。

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (d_i - y_i)^2} \quad (23)$$

5.2 3DRCL 之 Threshold σ 選擇與量化合理性說明

本研究為了挑選出重要的閾值，首先，將資料經過 3D-RBF 模型中第二層的時間壓縮後，在最終 3D-RBF 網路輸出層共計 $11 \times 15 \times 15 = 2475$ 個排名結果，為加強後續實驗的正確性，需進行 30 次完整訓練，圖 5-1 為每次模型運行的績效結果，X 軸表示模型運行編號，Y 軸為代表相應的 RMSE 績效。總體平均 RMSE 為 8.450。透過 30 次完整訓練後，再將 30 次 3D-RBF 網路層輸出的結果加總平均，得出每個因子在此網路層的重要度排名，以進行後續的重要度篩選實驗。




圖 五-1 30 次西屯測站預測未來 24 小時績效統計直方圖

接著，得出每個因子重要度排名後，為了比較有無挑選出重要特徵下的績效差異，本研究選擇結果較平穩且較能處理高維度的資料模型 RandomForest 進行閾值篩選後的預測模型，首先要比較挑選前與挑選後差異，先對全部特徵進行預測，預測結果 RMSE 為 8.472，再透過 3D-RBF 所挑選出不同排名的特徵輸入至 RandomForest 進行訓練及預測，圖 5-2 為 3D-RBF 挑選重要特徵 RandomForest 預測績效，圖中 X 軸表示特徵重要度排名，Y 軸為代表相應的 RMSE 績效；藍色線代表使用排名內所有特徵預測結果，橘色線則是代表使用排名外所有特徵預測結果。以 x 軸 640 為例，640 對應的藍色線值約為 8.4 表示重要度排名前 640 的特徵值作為模型 Input 後所得的 RMSE 約為 8.4，而 640 對應的橘色線值約 8.8 則表示除去排名前 640 的特徵輸入所得 RMSE 約為 8.8。透過上述舉例，可以得知為 640 排名內的特徵所得出的績效較排名外的特徵好，證明挑選到的特徵重要性較沒挑選到的特徵來得高。另外，在圖中也可看出若只挑選排名前 60 為 Input 的話，其 RMSE 與 Input 為全部 2475 的績效 RMSE 不但相似，輸入成本也節省許多。而當挑選排名前 660 時，所得到的 RMSE 約為 8.3，該績效甚至比全部特徵作為 Input

還要好，同時也可以看出若使用排名前 660 以外的特徵作為 Input，所得的預測績效約為 8.9，這是合理的，因為已經將重要特徵選起，而剩餘的可能為雜訊。




圖 5 2 3D-RBF 挑選重要特徵 RandomForest 預測績效

透過前述可以得知挑選特徵的重要性，而本研究該選取何種排名閥值帶入後續模型，以下將透過表 5.1 挑出幾個具有不同意義的排名進行說明。在未挑選任何特徵的情況下，可以看到 RandomForest 預測結果為 8.472，而後在挑選排名 10、100、200 排名內的特徵時，其 RMSE 較原本不挑選時來得差，因此認為在績效的部分未達到本研究需要的精確度，而在挑選 2250、2300、2350 排名內的特徵時，精確度比原本未挑選前來得佳，雖然有達到本研究在績效上的要求，但是在特徵數量上與原本全部的特徵數量相差不多，運算成本方面並未達到本研究需求。最後本研究發現在排名 650、660、670 時，績效都比原本的來更佳，且在挑選特徵上減少了將近 10000 多個特徵，因此在績效與成本上都有達到本研究的需求，後續將會以排名前 660 當作設置的閥值以實驗其他模型。

表 五-1 排名內與排名外特徵數量之 RMSE 比較表

排名	排名內		排名外	
	RMSE	特徵數量	RMSE	特徵數量
All(2475)	8.472	16200	-	-
10	11.907	114	8.44	16086
100	8.562	1044	8.550	15156
200	8.667	1914	8.656	14286
650	8.353	5406	8.908	10794
660	8.317	5466	8.865	10734
670	8.395	5514	8.921	10686
2250	8.231	14316	9.736	1884
2300	8.325	14502	9.766	1698
2350	8.366	14658	10.066	1578

5.3 模型與方法的有效性驗證

為了驗證本研究所提出的模型與方法是否針對空氣品質預測的績效有顯著的提升，以下將有效性驗證分成兩個部分進行說明，(1)利用不同的預測模型，去進行有無篩選最佳特徵值後的預測，(2)本研究將與過去研究篩選特徵值的方法進行比較，接下來先針對第一部分進行說明。

本次實驗將篩選後的特徵，使用過往研究所提出的多種機器學習與深度學習模型進行有效性驗證，所使用的模型有 Decision Tree、ANN、DNN，其預測結果如表 5-2。在表中可以很明顯的發現，不論是使用哪種預測方法，有篩選過後的特徵預測績效都會比未篩選過後的預測績效來得好，由此可以證實本研究方法的有效性。

表 五-2 不同模型下有無篩選特徵值之 RMSE 比較表

Method	RMSE		
	全部特徵	挑選 660 名內	挑選 660 名外
Decision Tree	8.632	8.413	8.645
ANN	9.120	8.573	9.232
DNN	8.740	8.307	8.84

第二部分，本論文提出了使用 3D-RBF 方法從深度學習模型中取出重要特徵值。且在上小節的量化結果中也有獲得不錯的績效。為了驗證這方法的有效性，本研究將與過去研究取特徵值方法進行比較。其中過去方法分為兩種，(1)使用 RandomForest 取出特徵值，RandomForest、DecisionTree、ANN、DNN 四種預測方法進行預測，(2)使用 DecisionTree 取出特徵值，RandomForest、DecisionTree、ANN、DNN 四種預測方法進行預測。預測後的績效如表 5-3 所示，表中可以看出因為輸入的特徵為過去 72 小時的時間序列圖，對於機器學習對於特徵挑選，可能會造成特徵複雜度過高的問題，導致績效不佳，且 PM2.5 是會受到其他地區的空間性所影響，由此可以得知，本研究所提出 3D-RBF 篩選特徵值的方法優於機器學習篩選特徵值的方法，同時也證實了本研究提出方法的有效性。

表 五-3 3D-RBF 與其他特徵提取方法之 RMSE 比較表

Method	RMSE			
	RandomForest	Decision Tree	ANN	DNN
RandomForest	8.463	8.660	8.695	8.615
DecisionTree	8.912	8.853	8.886	8.746
Proposed Method	8.317	8.413	8.573	8.307

第六章 結論與未來研究

空氣污染問題逐漸成為現今社會大眾越來越重視問題之一，其影響最深的層面不外乎是人體呼吸道健康的問題，為了能讓民眾提早得知未來的空氣品質資訊，供民眾瞭解未來 PM2.5 的趨勢變化，讓他們有足夠的時間提早預防，因此針對長期預測 PM2.5 的趨勢成為一件刻不容緩的事情。一般而言，過往學者的研究大多針對短期預測為主，又未考慮到時間與空間的整合部分，僅透過時間性趨勢資料無法全面性了解到 PM2.5 污染的影響範圍，但是如果要建立包含更加完善的模型則需耗費相當大的計算成本，因此本研究提出兩個概念去克服問題。第一個概念是利用全台空品測站提出一個新的組合式模型 3D-RCL，該模型可以將時間序列以空間方式呈現，並考慮整體狀態之時空因素，便能夠解決過往只考慮單一測站以及時空整合問題，達到精準的長期預測；第二個概念為透過 RBF 函數來協助拆解網路，除了能夠篩選出重要的特徵，讓預測的準確度提高，同時也能降低深度學習模型所需耗費的運算成本。總體而言，本研究所提出的組合式模型 3D-RCL，能夠有效地挑選出重要特徵的影響因子，提升長期預測準確度。最後，本研究利用過往研究所提出的多種機器學習與深度學習模型驗證下，不論是使用哪種預測方法，有篩選過後的特徵預測績效都會比未篩選過後的預測績效來得好，由此可以證實本研究提出方法的有效性。

針對未來研究上，可由以下幾點繼續延伸探討：1.可再針對其他測站進行相同研究，進一步分析各地區之間彼此影響相關性，推論當前污染物擴散路徑。2.加入其他污染物物質，並找出污染當下主要污染物質。未來也可嘗試把此方法應用在其他時間序列空間資料研究中進行特徵篩選。

參考文獻

- [1] A. Analitis, K. Katsouyanni, K. Dimakopoulou, E. Samoli, A. K. Nikolouloupoulos, Y. Petasakis, ... and F. Forastiere, “Short-term effects of ambient particles on cardiovascular and respiratory mortality,” *Epidemiology*, vol. 17, no. 2, pp. 230-233, 2006
- [2] B. Brunekreef and S. T. Holgate, “Air pollution and health,” *The lancet*, vol. 360, no. 9341, pp. 1233-1242, 2002
- [3] B. S. Freeman, G. Taylor, B. Gharabaghi, and J. Thé, “Forecasting air quality time series using deep learning,” *Journal of the Air & Waste Management Association*, vol. 68, no. 8, pp. 866-886, 2018
- [4] B. Zhai, J. Chen, W. Yin, and Z. Huang, “Relevance Analysis on the Variety Characteristics of PM_{2.5} Concentrations in Beijing, China,” *Sustainability*, vol. 10, no. 9, pp. 3228, 2018
- [5] B. Zhang, H. Zhang, G. Zhao, and J. Lian, “Constructing a PM_{2.5} concentration prediction model by combining auto-encoder with Bi-LSTM neural networks,” *Environmental Modelling & Software*, vol. 124, pp. 104600, 2020
- [6] C. J. Huang and P. H. Kuo, “A deep cnn-lstm model for particulate matter (PM_{2.5}) forecasting in smart cities,” *Sensors*, vol. 18, no. 7, pp. 2220, 2018
- [7] C. Zhang, X. Wang, S. Yu and Y. Wang, “Research on Keyword Extraction of Word2vec Model in Chinese Corpus” *2018 IEEE/ACIS 17th International Conference on Computer and Information Science (ICIS)*, pp. 339-343, 2018
- [8] C. Zhu, C. U. Idemudia, and W. Feng, “Improved logistic regression model for diabetes prediction by integrating PCA and K-means techniques,” *Informatics in Medicine Unlocked*, vol. 17, pp. 100179, 2019

- [9] E. Eslami, Y. Choi, Y. Lops, and A. Sayeed, "A real-time hourly ozone prediction system using deep convolutional neural network," *Neural Computing and Applications*, vol. 32 , pp. 8783-8797, 2020.
- [10] F. Biancofiore, M. Busilacchio, M. Verdecchia, B. Tomassetti, E. Aruffo, S. Bianco, ... and P. Di Carlo, "Recursive neural network model for analysis and forecast of PM10 and PM2.5," *Atmospheric Pollution Research*, vol. 8, no. 4, pp. 652-659, 2017
- [11] F. Mirzapour and H. Ghassemian, "Multiscale Gaussian derivative functions for hyperspectral image feature extraction," *IEEE Geoscience and Remote Sensing Letters*, vol. 13, no. 4, pp. 525-529, 2016
- [12] H. Chang-Hoi, I. Park, H. R. Oh, H. J. Gim, S. K. Hur, J. Kim, and D. R. Choi, "Development of a PM2. 5 prediction model using a recurrent neural network algorithm for the Seoul metropolitan area, Republic of Korea," *Atmospheric Environment*, vol. 245, pp. 118021, 2021
- [13] H. Liu and C. Chen, "Prediction of outdoor PM2.5 concentrations based on a three-stage hybrid neural network model," *Atmospheric Pollution Research*, vol. 11, no. 3, pp. 469-481, 2020
- [14] H. Liu, K. Jin, and Z. Duan, "Air PM2.5 concentration multi-step forecasting using a new hybrid modeling method: comparing cases for four cities in China," *Atmospheric Pollution Research*, vol. 10, no. 5, pp. 1588-1600, 2019
- [15] H. Wu, H. Liu, and Z. Duan, "PM2.5 concentrations forecasting using a new multi-objective feature selection and ensemble framework," *Atmospheric Pollution Research*, vol. 11, no. 7, pp. 1187-1198, 2020

- [16] J. Du, F. Qiao, and L. Yu, "Temporal characteristics and forecasting of PM_{2.5} concentration based on historical data in Houston, USA," *Resources, Conservation and Recycling*, vol. 147, pp. 145-156, 2019
- [17] J. Gao, K. Wang, Y. Wang, S. Liu, C. Zhu, J. Hao, ... and H. Tian, "Temporal-spatial characteristics and source apportionment of PM_{2.5} as well as its associated chemical species in the Beijing-Tianjin-Hebei region of China," *Environmental Pollution*, vol. 233, pp. 714-724, 2018
- [18] J. J. Hwang and K. H. Rhee, "Gaussian filtering detection based on features of residuals in image forensics" *In 2016 IEEE RIVF International Conference on Computing & Communication Technologies, Research, Innovation, and Vision for the Future* , pp. 153-157, 2016
- [19] J. Ma, Y. Ding, J. C. Cheng, F. Jiang, and Z. Wan, "A temporal-spatial interpolation and extrapolation method based on geographic Long Short-Term Memory neural network for PM_{2.5}," *Journal of Cleaner Production*, vol. 237, pp. 117729, 2019
- [20] J. Ma, Y. Ding, V. J. Gan, C. Lin, and Z. Wan "Spatiotemporal prediction of PM_{2.5} concentrations at different time granularities using IDW-BLSTM," *IEEE Access*, vol. 7, pp. 107897-107907, 2019
- [21] J. Sethi and M. Mittal, "Ambient air quality estimation using supervised learning techniques. *EAI Endorsed Transactions on Scalable Information Systems*," vol. 6, no. 22, 2019
- [22] J. Zhao, F. Deng, Y. Cai, and J. Chen, "Long short-term memory-Fully connected (LSTM-FC) neural network for PM_{2.5} concentration prediction," *Chemosphere*, vol.220, pp. 486-492, 2019

- [23] K. S. Harishkumar, K. M. Yogesh, and I. Gad, "Forecasting air pollution particulate matter (PM_{2.5}) using machine learning regression models," *Procedia Computer Science*, vol. 171, pp. 2057-2066, 2020
- [24] L. Ali, I. Wajahat, N. A. Golilarz, F. Keshtkar, and S. A. C. Bukhari, "LDA–GA–SVM: improved hepatocellular carcinoma prediction through dimensionality reduction and genetically optimized support vector machine," *Neural Computing and Applications*, vol. 33, no. 7, pp. 2783-2792, 2021
- [25] L. Guo, D. Zhou, J. Zhou, and S. Kimura, "Sparseness Ratio Allocation and Neuron Re-pruning for Neural Networks Compression" *2018 IEEE International Symposium on Circuits and Systems*, pp. 1-5, 2018
- [26] L. Zhang, J. Lin, R. Qiu, X. Hu, H. Zhang, Q. Chen, ... and J. Wang, "Trend analysis and forecast of PM_{2.5} in Fuzhou, China using the ARIMA model," *Ecological indicators*, vol. 95, pp. 702-710, 2018
- [27] M. Filonchyk, H. Yan, S. Yang, and V. Hurynovich, "A study of PM_{2.5} and PM₁₀ concentrations in the atmosphere of large cities in Gansu Province, China, in summer period," *Journal of Earth System Science*, vol. 125, no. 6, pp. 1175-1187, 2016
- [28] N. Rajkumar and P. Jaganathan, "A new RBF kernel based learning method applied to multiclass dermatology diseases classification" *In 2013 IEEE Conference on Information & Communication Technologies*, pp. 551-556, 2015
- [29] P. E. Saide, M. Mena-Carrasco, S. Tolvett, P. Hernandez, and G. R. Carmichael, "Air quality forecasting for winter-time PM_{2.5} episodes occurring in multiple cities in central and southern Chile," *Journal of Geophysical Research: Atmospheres*, vol. 121, no. 1, pp. 558-575, 2016

- [30] P. Wang, G. Zhang, F. Chen, and Y. He, "A hybrid-wavelet model applied for forecasting PM_{2.5} concentrations in Taiyuan city, China," *Atmospheric Pollution Research*, vol. 10, no. 6, pp. 1884-1894, 2019
- [31] P. W. Soh, J. W. Chang, and J. W. Huang, "Adaptive deep learning-based air quality prediction model using the most relevant spatial-temporal relations," *Ieee Access*, vol. 6, pp. 38186-38199, 2018
- [32] Q. Di, H. Amini, L. Shi, I. Kloog, R. Silvern, J. Kelly, ... and Y. Wang, "An ensemble-based model of PM_{2.5} concentration across the contiguous United States with high spatiotemporal resolution," *Environment international*, vol. 130, pp. 104909, 2019
- [33] R. B. Hamanaka and G. M. Mutlu, "Particulate matter air pollution: effects on the cardiovascular system" *Frontiers in Endocrinology*, vol. 9, pp. 680, 2018
- [34] S. Balasubramanian, D. M. McFarland, S. Koloutsou-Vakakis, K. Fu, R. Menon, C. Lehmann, and M. J. Rood, "Effect of grid resolution and spatial representation of NH₃ emissions from fertilizer application on predictions of NH₃ and PM_{2.5} concentrations in the United States Corn Belt," *Environmental Research Communications*, vol. 2, no. 2, pp. 025001, 2020
- [35] S. Kumar, S. Mishra, and S. K. Singh, "A machine learning-based model to estimate PM_{2.5} concentration levels in Delhi's atmosphere," *Heliyon*, vol. 6, no. 11, pp. e05397, 2020
- [36] S. Liu, C. Xu, Y. Zhang, J. Liu, B. Yu, X. Liu, and M. Dehmer, "Feature selection of gene expression data for Cancer classification using double RBF-kernels," *BMC bioinformatics*, vol. 19, no. 1, pp. 1-14, 2018

- [37] S. Li, G. Xie, J. Ren, L. Guo, Y. Yang, and X. Xu, "Urban PM_{2.5} Concentration Prediction via Attention-Based CNN–LSTM," *Applied Sciences*, vol. 10, no. 6, pp.1953, 2020
- [38] S. Qin, F. Liu, C. Wang, Y. Song, and J. Qu, "Spatial-temporal analysis and projection of extreme particulate matter (PM₁₀ and PM_{2.5}) levels using association rules: A case study of the Jing-Jin-Ji region, China," *Atmospheric Environment*, vol. 120, pp. 339-350 , 2015
- [39] T. He, J. Guo, N. Chen, X. Xu, Z. Wang, K. Fu, ... and Z. Yi, "MediMLP: using grad-CAM to extract crucial variables for lung cancer postoperative complication prediction," *IEEE journal of biomedical and health informatics*, vol. 24, no. 6, pp. 1762-1771, 2019
- [40] T. W. Cenggoro, "Incorporating the Knowledge Distillation to Improve the EfficientNet Transfer Learning Capability," *2020 International Conference on Data Science and Its Applications (ICoDSA)*, pp. 1-5, 2020
- [41] T. Zhang, W. He, H. Zheng, Y. Cui, H. Song, and Fu, S. "Satellite-based ground PM_{2.5} estimation using a gradient boosting decision tree," *Chemosphere*, vol. 268, pp. 128801. 268, 2021
- [42] T. Zheng, M. H. Bergin, S. Hu, J. Miller, and D. E. Carlson, "Estimating ground-level PM_{2.5} using micro-satellite images by a convolutional neural network and random forest approach," *Atmospheric Environment*, vol. 230, pp. 117451, 2020
- [43] U. Pak, J. Ma, U. Ryu, K. Ryom, U. Juhyok, K. Pak, and C. Pak, "Deep learning-based PM_{2.5} prediction considering the spatiotemporal correlations: A case study of Beijing, China," *Science of The Total Environment*, vol. 699, pp. 133561, 2020

- [44] W. G. Cobourn, "An enhanced PM_{2.5} air quality forecast model based on nonlinear regression and back-trajectory concentrations," *Atmospheric Environment*, vol. 44, no. 25, pp. 3015-3023, 2010
- [45] W. Tong, L. Li, X. Zhou, A. Hamilton, and K. Zhang, "Deep learning PM _{2.5} concentrations with bidirectional LSTM RNN," *Air Quality, Atmosphere & Health*, vol. 12, no. 4, pp. 411-423, 2019
- [46] W. Yuan, K. Wang, X. Bo, L. Tang, and J. Wu, "A novel multi-factor & multi-scale method for PM_{2.5} concentration forecasting," *Environmental Pollution*, vol. 255, pp. 113187, 2019
- [47] X. Wang and B. Wang, "Research on prediction of environmental aerosol and PM_{2.5} based on artificial neural network," *Neural Computing and Applications*, vol. 31, no. 12, pp. 8217-8227, 2019
- [48] X. Xu, T. Tong, W. Zhang, and L. Meng, "Fine-grained prediction of PM_{2.5} concentration based on multisource data and deep learning," *Atmospheric Pollution Research*, vol. 11, no. 10, pp. 1728-1737, 2020
- [49] Y. Bai, B. Zeng, C. Li, and J. Zhang, "An ensemble long short-term memory neural network for hourly PM_{2.5} concentration forecasting," *Chemosphere*, vol. 222, pp. 286-294, 2019
- [50] Y. Chen, "Prediction algorithm of PM_{2.5} mass concentration based on adaptive BP neural network," *Computing*, vol. 100, no. 8, pp. 825-838, 2018
- [51] Y. C. Chen, T. C. Lei, S. Yao, and H. P. Wang, "PM_{2.5} Prediction Model Based on Combinational Hammerstein Recurrent Neural Networks," *Mathematics*, vol. 8, no. 12, pp. 2178, 2020

- [52] Y. C. Lin, J. W. Chi, and Y. Q. Lin, "The improvement of spatial-temporal resolution of PM2.5 estimation based on micro-air quality sensors by using data fusion technique," *Environment International*, vol. 134, pp. 105305, 2020
- [53] Y. Mohammad, K. Matsumoto, and K. Hoashi, "Deep feature learning and selection for activity recognition" *In Proceedings of the 33rd Annual ACM Symposium on Applied Computing*, pp. 930-939, 2018
- [54] Y. T. Tsai, Y. R. Zeng, and Y. S. Chang, "Air pollution forecasting using RNN with LSTM" *In 2018 IEEE 16th Intl Conf on Dependable, Autonomic and Secure Computing, 16th Intl Conf on Pervasive Intelligence and Computing, 4th Intl Conf on Big Data Intelligence and Computing and Cyber Science and Technology Congress (DASC/PiCom/DataCom/CyberSciTech)*, pp. 1074-1079, 2018
- [55] Y. Zhang, Y. Qian, M. Gan, X. Tang, and Z. Lin, "Service Recommendation Based on User Dynamic Preference Extraction and Prediction," *In 2019 IEEE World Congress on Services (SERVICES)*, vol. 2642, pp. 121-126, 2019
- [56] 台中市政府全球資訊網-秒懂空污！ 中市府圖解 PM2.5 風場變化並加強應變 (<https://www.taichung.gov.tw/1385597>)
- [57] 行政院環保署中央監測資料 (<https://airtw.epa.gov.tw/CHT/EnvMonitoring/Central/CentralMonitoring.aspx>)
- [58] 行政院環保署空氣品質監測日值(https://data.epa.gov.tw/dataset/aqx_p_19)
- [59] 行政院環保署空氣品質指標測站點位圖(<https://airtw.epa.gov.tw/>)
- [60] 隨機森林示意圖(<https://morioh.com/p/2d4243726fdb>)
- [61] LSTM 架構圖(<https://bigdatafinance.tw/index.php/tech/methodology/1421-lstm-2>)
- [62] PM2.5 全台即時概況(<https://env.healthinfo.tw/air/>)

附錄

表 1 全台空氣品質測站介紹[58]

測站	AreaName	County	經度	緯度	SiteType
二林	中部空品區	彰化縣	120.4096530000	23.9251750000	一般測站
三重	北部空品區	新北市	121.4938060000	25.0726110000	交通測站
三義	竹苗空品區	苗栗縣	120.7588330000	24.3829420000	一般測站
土城	北部空品區	新北市	121.4518610000	24.9825280000	一般測站
士林	北部空品區	臺北市	121.5145000000	25.1059170000	一般測站
大同	北部空品區	臺北市	121.5133110000	25.0632000000	交通測站
大里	中部空品區	臺中市	120.6776890000	24.0996110000	一般測站
大園	北部空品區	桃園市	121.2018110000	25.0603440000	一般測站
大寮	高屏空品區	高雄市	120.4253110000	22.5641360000	一般測站
小港	高屏空品區	高雄市	120.3377360000	22.5658330000	一般測站
中山	北部空品區	臺北市	121.5265280000	25.0623610000	一般測站
中壢	北部空品區	桃園市	121.2216670000	24.9532780000	交通測站
仁武	高屏空品區	高雄市	120.3326310000	22.6890560000	一般測站
斗六	雲嘉南空品區	雲林縣	120.5449940000	23.7118530000	一般測站
冬山	宜蘭空品區	宜蘭縣	121.7929280000	24.6322030000	一般測站
古亭	北部空品區	臺北市	121.5295560000	25.0206080000	一般測站
左營	高屏空品區	高雄市	120.2929170000	22.6748610000	一般測站
平鎮	北部空品區	桃園市	121.2049810000	24.9542080000	一般測站
永和	北部空品區	新北市	121.5163060000	25.0170000000	交通測站
安南	雲嘉南空品區	臺南市	120.2183330000	23.0483330000	一般測站
朴子	雲嘉南空品區	嘉義縣	120.2473500000	23.4653080000	一般測站
汐止	北部空品區	新北市	121.6408000000	25.0656690000	一般測站
竹山	中部空品區	南投縣	120.6773060000	23.7563890000	一般測站

竹東	竹苗空品區	新竹縣	121.0889030000	24.7406440000	一般測站
西屯	中部空品區	臺中市	120.6169170000	24.1621970000	一般測站
沙鹿	中部空品區	臺中市	120.5687940000	24.2256280000	一般測站
宜蘭	宜蘭空品區	宜蘭縣	121.7463940000	24.7479170000	一般測站
忠明	中部空品區	臺中市	120.6410920000	24.1519580000	一般測站
林口	北部空品區	新北市	121.3657030000	25.0785700000	一般測站
林園	高屏空品區	高雄市	120.4117500000	22.4795000000	一般測站
板橋	北部空品區	新北市	121.4586670000	25.0129720000	一般測站
松山	北部空品區	臺北市	121.5786110000	25.0500000000	一般測站
花蓮	花東空品區	花蓮縣	121.5997690000	23.9713060000	一般測站
金門	其他	金門縣	118.3122560000	24.4321330000	一般測站
前鎮	高屏空品區	高雄市	120.3075640000	22.6053860000	工業測站
南投	中部空品區	南投縣	120.6853060000	23.9130000000	一般測站
屏東	高屏空品區	屏東縣	120.4880330000	22.6730810000	一般測站
恆春	高屏空品區	屏東縣	120.7889280000	21.9580690000	一般測站
美濃	高屏空品區	高雄市	120.5305420000	22.8835830000	一般測站
苗栗	竹苗空品區	苗栗縣	120.8202000000	24.5652690000	一般測站
埔里	中部空品區	南投縣	120.9679030000	23.9688420000	其他測站
桃園	北部空品區	桃園市	121.3044170000	24.9956670000	一般測站
馬公	其他	澎湖縣	119.5661580000	23.5690310000	一般測站
馬祖	其他	連江縣	119.9525000000	26.1536110000	一般測站
基隆	北部空品區	基隆市	121.7600560000	25.1291670000	一般測站
崙背	雲嘉南空品區	雲林縣	120.3487420000	23.7575470000	一般測站
淡水	北部空品區	新北市	121.4492390000	25.1645000000	一般測站
麥寮	雲嘉南空品區	雲林縣	120.2518250000	23.7535060000	工業測站
復興	高屏空品區	高雄市	120.3120170000	22.6087110000	交通測站
湖口	竹苗空品區	新竹縣	121.0386530000	24.9001420000	一般測站

善化	雲嘉南空品區	臺南市	120.2971420000	23.1150970000	一般測站
菜寮	北部空品區	新北市	121.4810280000	25.0689500000	一般測站
陽明	北部空品區	臺北市	121.5295830000	25.1827220000	公園測站
新竹	竹苗空品區	新竹市	120.9720750000	24.8056190000	一般測站
新店	北部空品區	新北市	121.5377780000	24.9772220000	一般測站
新莊	北部空品區	新北市	121.4325000000	25.0379720000	一般測站
新港	雲嘉南空品區	嘉義縣	120.3455310000	23.5548390000	一般測站
新營	雲嘉南空品區	臺南市	120.3172500000	23.3056330000	一般測站
楠梓	高屏空品區	高雄市	120.3282890000	22.7336670000	一般測站
萬里	北部空品區	新北市	121.6898810000	25.1796670000	一般測站
萬華	北部空品區	臺北市	121.5079720000	25.0465030000	一般測站
嘉義	雲嘉南空品區	嘉義市	120.4408330000	23.4627780000	一般測站
彰化	中部空品區	彰化縣	120.5415190000	24.0660000000	一般測站
鳳山	高屏空品區	高雄市	120.3580830000	22.6273920000	交通測站
潮州	高屏空品區	屏東縣	120.5611750000	22.5231080000	一般測站
線西	中部空品區	彰化縣	120.4690610000	24.1316720000	工業測站
橋頭	高屏空品區	高雄市	120.3056890000	22.7575060000	背景測站
頭份	竹苗空品區	苗栗縣	120.8985720000	24.6969690000	工業測站
龍潭	北部空品區	桃園市	121.2163500000	24.8638690000	一般測站
豐原	中部空品區	臺中市	120.7417110000	24.2565860000	一般測站
關山	花東空品區	臺東縣	121.1619330000	23.0450830000	其他測站
觀音	北部空品區	桃園市	121.0827610000	25.0355030000	背景測站
臺西	雲嘉南空品區	雲林縣	120.2028420000	23.7175330000	工業測站
臺南	雲嘉南空品區	臺南市	120.2026170000	22.9845810000	一般測站
臺東	花東空品區	臺東縣	121.1504500000	22.7553580000	一般測站
富貴角	北部空品區	新北市	121.5379750000	25.2974360000	背景測站