

國立雲林科技大學研究生學位論文電子檔上傳同意書

National Yunlin University of Science and Technology Agreement on Uploading E-file of the Thesis

工業工程與管理系研究所 _____ 組

學號 M10921010 研究生 鄭佳昇 (請簽章)

論文已完成口試委員修改建議，並經系所辦查對以下事項無誤，請同意論文上傳學校圖書館。

■查對事項：

☒ 中文論文題目(研究生請於下方自填中文論文題目，請以電腦繕打，勿手寫。)：

基於 3D-RCL 與條件式生成對抗網路產生未來時刻人群分布之可能性探討

☒ 英文論文題目(研究生請於下方自填英文論文題目，請以電腦繕打，勿手寫。)：

The Possibility of Simulate Future Crowd Flow Distribution Based on 3D-RCL and Conditional Generative Adversarial Network

☒ 中文論文題目與學位論文考試委員會審定書之題目一致。

☒ 中、英文論文題目與單一/教務資訊系統/歷年成績之題目一致。

☒ 中、英文論文題目與學位論文 PDF 檔封面之題目一致。

查對人(系所辦承辦人員)： 林雅婷 (請簽章)

謹陳

論文指導教授： 陳克中 (請簽章)

使用說明：

1. 同意書送系所承辦人員查對時，請研究生提供「審定書」及「論文封面」檔案。
2. 學位論文電子檔上傳前，請將簽核完成之同意書掃描成電子檔併於學位論文 PDF 檔第一頁(封面的前一頁)。
3. 正本請自行留存，請勿裝訂於紙本學位論文內。

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

基於 3D-RCL 與條件式生成對抗網路產生

未來時刻人群分布之可能性探討

The Possibility of Simulate Future Crowd Flow
Distribution Based on 3D-RCL and Conditional
Generative Adversarial Network

鄭佳昇

Chia-Sheng Cheng

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D.

中華民國 111 年 06 月

June 2022

國立雲林科技大學
碩士班學位論文考試委員會審定書
National Yunlin University of Science and Technology
Thesis Oral Defense Approval Form

本論文係 鄭佳昇 君在本校 工業工程與管理系碩士班 所提論文
基於 3D-RCL 與條件式生成對抗網路產生未來時刻人群分布之可
能性探討 碩士資格水準，業經本委員會評審認可，特此證明。

The student CHENG, CHIA-SHENG enrolled in the Master's
program in Department of Industrial Engineering and Management
has satisfactorily passed the oral defense of the thesis The Possibility
of Simulate Future Crowd Flow Distribution Based on 3D-RCL and
Conditional Generative Adversarial Network.

口 試 委 員： 陳奕中 陳堯中

Oral defense

committee members

洪鈺欣

吳秉昇

指 導 教 授： 陳奕中 陳堯中

Advisor(s)

所 長：
Dean of Graduate
Institute

傅家啟

中 華 民 國 111 年 6 月 24 日

摘要

近年來隨著城市化及人口的快速增長，人口密度過高也成為許多問題的根本原因。國內政府針對人群分析所推動的眾多議題中，又以災防管理中的人群兵棋推演最受到關注，那是由於臺灣同時具有人口稠密及地理位置特殊的特性，使得災害來臨時總是造成許多生命財產的損失，若是能有效模擬城市中未來人群分布能使兵棋推演的效果最大化。綜觀過往人群分布預測方法中，又以條件式生成對抗網路(cGAN, Conditional Generative Adversarial Network)具備能夠訓練多個不同類別資料的特性，使該模型於訓練完成後能夠根據給予的條件生成人群分布資料。然而，雖然 cGAN 已被證實能產生未來時刻人群分布，但還有(1)無法考慮模擬區域內不同影響因子、(2)無法考慮到影響人群變化條件因子及不同時間有不同影響因子的問題，及(3)歷史資料過少的問題需要被解決。因此本研究針對上述問題提出三大概念，(1)利用分群演算法將區域人群做分群，解決模擬範圍內包含不同影響因子的問題，(2)訓練並拆解 3D-RCL(3D-RBF-CNN-LSTM)模型，找尋會影響該群人群分布的因子，(3)開發適用於人群分布的資料擴增技術解決歷史資料過少的問題。最終本研究將使用行動數據人流資料作為目標資料集，天氣及行事曆作為輔助資料集，並利用我們的方法預測未來時刻人群分布。

關鍵字：人群分布預測、特徵工程、條件式生成對抗網路、資料擴增

Abstract

Crowd chess projection is a crowd analysis method particularly suited to Taiwan, which, due to its dense population and unique geographical features, experiences high loss of life and property when natural disasters occur. Conditional generative adversarial networks (cGANs) are usually used to train the model to generate crowd distribution data according to given conditions. Although cGAN has proved capable of generating future moment population distribution, it is subject to the following limitations: (1) it does not consider different influencing factors in the simulation area, (2) it does not consider conditional factors affecting population change and different influencing factors at different times; and (3) it is only applicable to cases with large volumes of historical data. This study proposes three concepts to address these problems: (1) dividing the regional population into clusters to solve the problem of different influencing factors in the simulation area; (2) training and disassembling the 3D-RCL (3D-RBF-CNN-LSTM) model to identify factors affecting distribution of the population in the cluster; and (3) developing data augmentation techniques for population distribution to overcome a lack of historical data. We demonstrate the efficacy of the proposed approach through application to the target dataset of mobile flow data, with weather and calendar data serving as the auxiliary datasets, to predict long-term crowd distribution.

Keywords : Crowd Distribution, Feature Engineering, Conditional Generative Adversarial Network, Data Augmentation

誌謝

隨著碩士論文的完善，我的碩士生涯也進入了尾聲，回首在學期間遇到許多幫助我、關心我的師長、同學們，在此向你們致上最誠摯的謝意。

首先感謝我的指導教授 陳奕中老師，在大四那年有幸上到您的課而接觸到了資料科學，也在我升上碩士班之後讓我加入您的實驗室一同進行研究。在碩士期間您總是鼓勵我們多參與各種競賽、研討會及專案等，並且也在百忙之中耐心地給予學生許多指導及建議，使我在這條路上逐漸成長茁壯。除了課業之外，也謝謝您在我對未來感到徬徨的時候給予我許多建議及方向，讓我更確定了未來努力的方向，在此向我的恩師致上最誠摯的感激。

感謝帶領我入門的師父們，東錡學長、映均學姐、志豪學長、政傑學長，謝謝你們在我還是一張白紙的時候一步一步指導我資料分析的理論、口頭報告技巧及程式的撰寫，並且無私的給予我許多學習資源，使我能夠更順利的學習並且打下了深厚的基礎，也從單方面接受你們的指導到能跟你們一起討論研究內容及分享我的研究成果，這一路上非常感謝你們。也謝謝富正大哥、泊樣學長、振家學長在我做論文遇到瓶頸時，犧牲自己的休息時間給予我許多建議並且幫助我釐清研究上的盲點，因為有你們讓我的碩士論文能夠完成許多實驗並且更加完整。

此外也由衷感謝兩年期間與我一起奮戰的好戰友 香蘭、佑蓉、重佑及承安，謝謝你們不管是在課業、專案、論文，或是生活上都給予我非常多的協助及建議，因為有你們使我的碩士生活更加豐富多彩。也謝謝實驗室其它學長姐、學弟妹們的指導或協助，讓我能順利的完成許多專案及競賽。

最後特別感謝我最親愛的父母與弟弟們作為我最強大的後盾，你們總是在背後給我最大的支持與鼓勵，也在我最忙碌的時候關心我的身體健康，謝謝你們讓我能無後顧之憂的學習並且持續的給我能量完成碩士學位。最後僅以此篇論文獻給所有關心我、愛護我的人。

目錄

摘要	i
Abstract.....	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	4
1.3 研究範圍	5
1.4 研究限制	5
1.5 研究流程	5
第二章 文獻回顧	7
2.1 影響人流因素	7
2.2 時空資料預測演算法	7
2.3 時空資料分群演算法	9
2.3.1 考量時間特性做分群方法	9
2.3.2 考量空間特性做分群方法	10
2.3.3 同時考量時間及空間特性分群方法	10
2.3.4 時空資料分群方法小結	11
2.4 SMOTE.....	11
2.5 生成對抗網路	12
2.5.1 GAN	12
2.5.2 Conditional GAN.....	13
第三章 資料集	15
3.1 目標資料集	15
3.2 輔助資料集	16
3.2.1 天氣資料集	16
3.2.2 日曆資料集	17
第四章 研究方法	18

4.1	資料前處理	19
4.1.1	缺失值處理	19
4.1.2	資料正規化	19
4.1.3	時間序列切割處理	22
4.1.4	相似網格分群	23
4.1.5	分群網格數值加總	25
4.2	尋找各群重要因子	26
4.2.1	建立 3D-RCL 模型	26
4.2.2	篩選各群重要特徵	32
4.3	資料擴增	35
4.3.1	隨機增減方法	35
4.3.2	最大值互換方法	37
4.3.3	人群移動方法	38
4.4	訓練 cGAN 模型	39
4.4.1	cGAN 架構	39
4.4.2	損失函數	39
4.5	人群分布績效評估方法	40
第五章	實驗模擬	42
5.1	資料集與實驗參數介紹	42
5.2	決定模擬區域大小	43
5.3	決定每個模擬區域分群數量	45
5.4	選取作為 cGAN 條件的特徵	49
5.4.1	3D-RCL 特徵值重要度分析	50
5.4.2	用輕量化模型來挑選特徵並驗證挑選特徵之合理性	73
5.5	不同架構對 cGAN 訓練及預測的影響	83
5.6	不同正規化方法對 cGAN 訓練及預測結果的影響	100
5.7	不同資料擴增方法對 cGAN 預測結果的影響	118
5.7.1	不同資料擴增方法之預測數值變化	119
5.7.2	不同資料擴增方法預測差異小結	140
5.8	cGAN 預測結果之質化討論	141
第六章	結論與未來研究建議	145
	參考文獻	146

表目錄

表 1 天氣資料	16
表 2 時段資料	17
表 5 各模擬區域分群數量	48
表 4 各群 cGAN 除必要條件輸入之其他條件	82
表 5 不同 cGAN 架構於 Area 1 之 4 種條件 MAPE 比較	98
表 6 不同 cGAN 架構於 Area 2 之 4 種條件 MAPE 比較	98
表 7 不同 cGAN 架構於 Area 3 之 4 種條件 MAPE 比較	98
表 8 不同 cGAN 架構於 Area 4 之 4 種條件 MAPE 比較	99
表 9 不同 cGAN 架構於 Area 5 之 4 種條件 MAPE 比較	99
表 10 不同 cGAN 架構於 Area 6 之 4 種條件 MAPE 比較	99
表 11 不同 cGAN 架構於 Area 7 之 4 種條件 MAPE 比較	99
表 12 不同正規化方法於 Area 1 之 4 種條件 MAPE 比較	117
表 13 不同正規化方法於 Area 2 之 4 種條件 MAPE 比較	117
表 14 不同正規化方法於 Area 3 之 4 種條件 MAPE 比較	117
表 15 不同正規化方法於 Area 4 之 4 種條件 MAPE 比較	117
表 16 不同正規化方法於 Area 5 之 4 種條件 MAPE 比較	117
表 17 不同正規化方法於 Area 6 之 4 種條件 MAPE 比較	117
表 18 不同正規化方法於 Area 7 之 4 種條件 MAPE 比較	118
表 19 不同資料擴增方法預測星期六 9:00 之 MAPE 比較	119

圖目錄

圖 1 不同時段之臺北市人群分布，(a)2018/7/15 早上 11:00 之人群分布，(b) 2019/1/1 早上 6:00 之人群分布。	1
圖 2 (a)總統府與臺北車站周遭地理位置圖，(b)一般情形的人群分布，(c)總統府舉辦遊行時的人群分布，(d) cGAN 生成出的人群分布。	3
圖 3 平假日不同天氣下的人群數量示意圖	4
圖 4 研究流程圖	6
圖 5 人群流入/流出[65]	8
圖 6 ST-ResNet 模型架構[65]	9
圖 7 SMOTE 生成資料示意圖	11
圖 8 GAN 模型架構[65]	12
圖 9 Conditional GAN 模型架構[65]	13
圖 10 人流資料空間範圍示意圖	15
圖 11 CODIS 查詢首頁	16
圖 12 天氣觀測站分布點位	17
圖 13 研究架構流程圖	18
圖 14 補值前後示意圖	19
圖 15 Min-Max 正規化前後比較	20
圖 16 原始人群資料分布直方圖	21
圖 17 原始人群資料經過 Log 轉換後之數值分布直方圖	21
圖 18 Log-3std 正規化後之人群資料數值分布直方圖	22
圖 19 空間切割示意圖	22
圖 20 時間切割過程示意圖	23
圖 21 DTW 矩陣示意圖	24

圖 22 分群網格加總目的示意圖	25
圖 23 3D-RCL 方法流程圖	26
圖 24 3D-RCL 模型架構圖	27
圖 25 2D-RBF 的標準差，(a)中心點落在中央，(b)中心點落在右邊。	28
圖 26 卷積計算過程	29
圖 27 池化層介紹	29
圖 28 特徵提取過後攤平過程	30
圖 29 資料合併過程	30
圖 30 資料格式轉換	31
圖 31 1D-RBF 輸出後計算平均值及標準差	33
圖 32 網格地圖解說參考示意圖	34
圖 33 2D-RBF 矩陣示意圖	34
圖 34 2D-RBF 訓練後示意圖	35
圖 35 隨機增減資料擴增方法示意圖	36
圖 36 最大值互換資料擴增方法示意圖	37
圖 37 人群移動資料擴增方法示意圖	38
圖 38 本研究 cGAN 架構圖	39
圖 39 驗證方法示意圖	41
圖 40 臺北市 11*11 大小的模擬區域	43
圖 41 模擬區域大小之輪廓係數及 SEE score	44
圖 42 模擬區域 9*9 大小之分群結果	44
圖 43 模擬區域 7*7 大小之分群結果	44
圖 44 本研究選取之模擬區域	45
圖 45 各模擬區域分群數量之輪廓係數及 SEE score	45
圖 46 Area 2 分為 2 群之分群結果	46

圖 47 Area 2 分為 3 群之分群結果.....	46
圖 48 Area 5 分為 2 群之分群結果.....	47
圖 49 Area 5 分為 3 群之分群結果.....	47
圖 50 Area 6 分為 2 群之分群結果.....	48
圖 51 Area 6 分為 3 群之分群結果.....	48
圖 52 各 Area 分群之地理位置視覺化	49
圖 53 各群之 MAPE 比較	50
圖 54 Area 1 之特徵型態標準差比較.....	51
圖 55 Area 2 之特徵型態標準差比較.....	51
圖 56 Area 3 之特徵型態標準差比較.....	51
圖 57 Area 4 之特徵型態標準差比較.....	52
圖 58 Area 5 之特徵型態標準差比較.....	52
圖 59 Area 6 之特徵型態標準差比較.....	52
圖 60 Area 7 之特徵型態標準差比較.....	53
圖 61 Area 1 各時間點特徵之最大標準差比較.....	53
圖 62 Area 2 各時間點特徵之最大標準差比較.....	54
圖 63 Area 3 各時間點特徵之最大標準差比較.....	54
圖 64 Area 4 各時間點特徵之最大標準差比較.....	55
圖 65 Area 5 各時間點特徵之最大標準差比較.....	55
圖 66 Area 6 各時間點特徵之最大標準差比較.....	56
圖 67 Area 7 各時間點特徵之最大標準差比較.....	56
圖 68 Area 1 之 24 小時平均標準差.....	57
圖 69 Area 2 之 24 小時平均標準差.....	57
圖 70 Area 3 之 24 小時平均標準差.....	57
圖 71 Area 4 之 24 小時平均標準差.....	58

圖 72 Area 5 之 24 小時平均標準差.....	58
圖 73 Area 6 之 24 小時平均標準差.....	58
圖 74 Area 7 之 24 小時平均標準差.....	59
圖 75 Area 1 各群最大標準差網格之地理位置.....	59
圖 76 Area 2 各群最大標準差網格之地理位置.....	59
圖 77 Area 3 各群最大標準差網格之地理位置.....	60
圖 78 Area 4 各群最大標準差網格之地理位置.....	60
圖 79 Area 5 各群最大標準差網格之地理位置.....	61
圖 80 Area 6 各群最大標準差網格之地理位置.....	61
圖 81 Area 7 各群最大標準差網格之地理位置.....	62
圖 82 各群拿掉日曆後之 MAPE 比較.....	62
圖 83 少了日曆特徵後 Area 1 之特徵型態標準差比較	63
圖 84 少了日曆特徵後 Area 2 之特徵型態標準差比較	63
圖 85 少了日曆特徵後 Area 3 之特徵型態標準差比較	64
圖 86 少了日曆特徵後 Area 4 之特徵型態標準差比較	64
圖 87 少了日曆特徵後 Area 5 之特徵型態標準差比較	64
圖 88 少了日曆特徵後 Area 6 之特徵型態標準差比較	65
圖 89 少了日曆特徵後 Area 7 之特徵型態標準差比較	65
圖 90 少了日曆特徵後 Area 1 各時間點特徵之最大標準差比較	66
圖 91 少了日曆特徵後 Area 2 各時間點特徵之最大標準差比較	66
圖 92 少了日曆特徵後 Area 3 各時間點特徵之最大標準差比較	67
圖 93 少了日曆特徵後 Area 4 各時間點特徵之最大標準差比較	67
圖 94 少了日曆特徵後 Area 5 各時間點特徵之最大標準差比較	68
圖 95 少了日曆特徵後 Area 6 各時間點特徵之最大標準差比較	68
圖 96 少了日曆特徵後 Area 7 各時間點特徵之最大標準差比較	69

圖 97 Area 1 拿掉日曆前後之 24 小時平均標準差.....	69
圖 98 Area 2 拿掉日曆前後之 24 小時平均標準差.....	70
圖 99 Area 3 拿掉日曆前後之 24 小時平均標準差.....	70
圖 100 Area 4 拿掉日曆前後之 24 小時平均標準差.....	71
圖 101 Area 5 拿掉日曆前後之 24 小時平均標準差.....	71
圖 102 Area 6 拿掉日曆前後之 24 小時平均標準差.....	72
圖 103 Area 7 拿掉日曆前後之 24 小時平均標準差.....	72
圖 104 Area 1 群 1 之各特徵組合放入輕量化模型預測績效.....	73
圖 105 Area 1 群 2 之各特徵組合放入輕量化模型預測績效.....	74
圖 106 Area 2 群 1 各特徵組合放入輕量化模型之預測績效.....	74
圖 107 Area 2 群 2 各特徵組合放入輕量化模型之預測績效.....	74
圖 108 Area 3 群 1 各特徵組合放入輕量化模型之預測績效.....	75
圖 109 Area 3 群 2 各特徵組合放入輕量化模型之預測績效.....	75
圖 110 Area 4 群 1 各特徵組合放入輕量化模型之預測績效.....	75
圖 111 Area 4 群 2 各特徵組合放入輕量化模型之預測績效.....	76
圖 112 Area 5 群 1 各特徵組合放入輕量化模型之預測績效.....	76
圖 113 Area 5 群 2 各特徵組合放入輕量化模型之預測績效.....	76
圖 114 Area 6 群 1 各特徵組合放入輕量化模型之預測績效.....	77
圖 115 Area 6 群 2 各特徵組合放入輕量化模型之預測績效.....	77
圖 116 Area 6 群 3 各特徵組合放入輕量化模型之預測績效.....	77
圖 117 Area 7 群 1 各特徵組合放入輕量化模型之預測績效.....	78
圖 118 Area 7 群 2 各特徵組合放入輕量化模型之預測績效.....	78
圖 119 Area 1 群 1 前 25 名各特徵組合放入輕量化模型之預測績效，(a)排名 1 至 5，(b)排名 6 至 10，(c)排名 11 至 15，(d)排名 16 至 20，(e)排名 21 至 25	79
圖 120 Area 1 群 1 前 25 名累積特徵組合放入輕量化模型之預測績效，(a)排名 1	

至 5，(b)排名 1 至 10，(c)排名 1 至 15，(d)排名 1 至 20，(e)排名 1 至 25.....	80
圖 121 Area 1 群 1 後 25 名各特徵組合放入輕量化模型之預測績效，(a)排名 74 至 78，(b)排名 79 至 83，(c)排名 84 至 88，(d)排名 89 至 93，(e)排名 94 至 98.....	81
圖 122 卷積層架構於 Area 1_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	83
圖 123 全連接層架構於 Area 1_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	84
圖 124 卷積層架構於 Area 1_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	84
圖 125 全連接層架構於 Area 1_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	85
圖 126 卷積層架構於 Area 2_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	85
圖 127 全連接層架構於 Area 2_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	86
圖 128 卷積層架構於 Area 2_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	86
圖 129 全連接層架構於 Area 2_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	87
圖 130 卷積層架構於 Area 3_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	87
圖 131 全連接層架構於 Area 3_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	88
圖 132 卷積層架構於 Area 3_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	88

圖 133 全連接層架構於 Area 3_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	89
圖 134 卷積層架構於 Area 4_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	89
圖 135 全連接層架構於 Area 4_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	90
圖 136 卷積層架構於 Area 4_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	90
圖 137 全連接層架構於 Area 4_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	91
圖 138 卷積層架構於 Area 5_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	91
圖 139 全連接層架構於 Area 5_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	92
圖 140 卷積層架構於 Area 5_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	92
圖 141 全連接層架構於 Area 5_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	93
圖 142 卷積層架構於 Area 6_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	93
圖 143 全連接層架構於 Area 6_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	94
圖 144 卷積層架構於 Area 6_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	94
圖 145 全連接層架構於 Area 6_Group2 之訓練過程，(a)到(e)依次為第 1000、	

2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	95
圖 146 卷積層架構於 Area 6_Group3 之訓練過程，(a)到(e)依次為第 1000、 2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	95
圖 147 全連接層架構於 Area 6_Group3 之訓練過程，(a)到(e)依次為第 1000、 2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	96
圖 148 卷積層架構於 Area 7_Group1 之訓練過程，(a)到(e)依次為第 1000、 2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	96
圖 149 全連接層架構於 Area 7_Group1 之訓練過程，(a)到(e)依次為第 1000、 2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	97
圖 150 卷積層架構於 Area 7_Group2 之訓練過程，(a)到(e)依次為第 1000、 2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	97
圖 151 全連接層架構於 Area 7_Group2 之訓練過程，(a)到(e)依次為第 1000、 2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	98
圖 152 Area 1 取其中一個網格之人群分布直方圖.....	100
圖 153 Min-Max 正規化至 0~1 區間之人群數量分布圖.....	100
圖 154 Log 正規化至 0 至 1 區間之人群數量分布圖.....	101
圖 155 Log_3_std 正規化至-1 至 1 區間之人群數量分布圖.....	101
圖 156 Log 正規化方法於 Area 1_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	102
圖 157 Log_3std 正規化方法於 Area 1_Group1 之 cGAN 訓練過程，(a)到(e)依次為 第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	102
圖 158 Log 正規化方法於 Area 1_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	103
圖 159 Log_3std 正規化方法於 Area1_Group2 之 cGAN 訓練過程，(a)到(e)依次為 第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	103

圖 160 Log 正規化方法於 Area 2_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	104
圖 161 Log_3std 正規化方法於 Area 2_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	104
圖 162 Log 正規化方法於 Area 2_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	105
圖 163 Log_3std 正規化方法於 Area 2_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	105
圖 164 Log 正規化方法於 Area 3_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	106
圖 165 Log_3std 正規化方法於 Area 3_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	106
圖 166 Log 正規化方法於 Area 3_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	107
圖 167 Log_3std 正規化方法於 Area 3_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	107
圖 168 Log 正規化方法於 Area 4_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	108
圖 169 Log_3std 正規化方法於 Area 4_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	108
圖 170 Log 正規化方法於 Area 4_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	109
圖 171 Log_3std 正規化方法於 Area 4_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	109
圖 172 Log 正規化方法於 Area 5_Group1 之 cGAN 訓練過程，(a)到(e)依次為第	

1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	110
圖 173 Log_3std 正規化方法於 Area 5_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	110
圖 174 Log 正規化方法於 Area 5_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	111
圖 175 Log_3std 正規化方法於 Area 5_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	111
圖 176 Log 正規化方法於 Area 6_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	112
圖 177 Log_3std 正規化方法於 Area 6_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	112
圖 178 Log 正規化方法於 Area 6_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	113
圖 179 Log_3std 正規化方法於 Area 6_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	113
圖 180 Log 正規化方法於 Area 6_Group3 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	114
圖 181 Log_3std 正規化方法於 Area 6_Group3 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	114
圖 182 Log 正規化方法於 Area 7_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	115
圖 183 Log_3std 正規化方法於 Area 7_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	115
圖 184 Log 正規化方法於 Area 7_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。.....	116

圖 185 Log_3std 正規化方法於 Area 7_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。	116
圖 186 Area 1 使用原始資料預測星期六 09:00 之人群分布	120
圖 187 Area 1 使用隨機增減資料預測星期六 09:00 之人群分布	120
圖 188 Area 1 使用最大值互換資料預測星期六 09:00 之人群分布	121
圖 189 Area 1 使用人群移動資料預測星期六 09:00 之人群分布	121
圖 190 Area 1 使用所有資料預測星期六 09:00 之人群分布	122
圖 191 Area 2 使用原始資料預測星期六 09:00 之人群分布	123
圖 192 Area 2 使用隨機增減資料預測星期六 09:00 之人群分布	123
圖 193 Area 2 使用最大值互換資料預測星期六 09:00 之人群分布	124
圖 194 Area 2 使用人群移動資料預測星期六 09:00 之人群分布	124
圖 195 Area 2 使用所有資料預測星期六 09:00 之人群分布	125
圖 196 Area 3 使用原始資料預測星期六 09:00 之人群分布	126
圖 197 Area 3 使用隨機增減資料預測星期六 09:00 之人群分布	126
圖 198 Area 3 使用最大值互換資料預測星期六 09:00 之人群分布	127
圖 199 Area 3 使用人群移動資料預測星期六 09:00 之人群分布	127
圖 200 Area 3 使用所有資料預測星期六 09:00 之人群分布	128
圖 201 Area 4 使用原始資料預測星期六 09:00 之人群分布	129
圖 202 Area 4 使用隨機增減資料預測星期六 09:00 之人群分布	129
圖 203 Area 4 使用最大值互換資料預測星期六 09:00 之人群分布	130
圖 204 Area 4 使用人群移動資料預測星期六 09:00 之人群分布	130
圖 205 Area 4 使用所有資料預測星期六 09:00 之人群分布	131
圖 206 Area 5 使用原始資料預測星期六 09:00 之人群分布	132
圖 207 Area 5 使用隨機增減資料預測星期六 09:00 之人群分布	132
圖 208 Area 5 使用最大值互換資料預測星期六 09:00 之人群分布	133

圖 209 Area 5 使用人群移動資料預測星期六 09:00 之人群分布	133
圖 210 Area 5 使用所有資料預測星期六 09:00 之人群分布	134
圖 211 Area 6 使用原始資料預測星期六 09:00 之人群分布	135
圖 212 Area 6 使用隨機增減資料預測星期六 09:00 之人群分布	135
圖 213 Area 6 使用最大值互換資料預測星期六 09:00 之人群分布	136
圖 214 Area 6 使用人群移動資料預測星期六 09:00 之人群分布	136
圖 215 Area 6 使用所有資料預測星期六 09:00 之人群分布	137
圖 216 Area 7 使用原始資料預測星期六 09:00 之人群分布	138
圖 217 Area 7 使用隨機增減資料預測星期六 09:00 之人群分布	138
圖 218 Area 7 使用最大值互換資料預測星期六 09:00 之人群分布	139
圖 219 Area 7 使用人群移動資料預測星期六 09:00 之人群分布	139
圖 220 Area 7 使用所有資料預測星期六 09:00 之人群分布	140
圖 221 質化討論地理位置圖	141
圖 222 cGAN 預測星期三整天之預測結果，(a) 00:00，(b) 03:00，(c) 06:00，(d) 09:00，(e) 12:00，(f) 15:00，(g) 18:00，(h) 21:00 之人群分布。	143
圖 223 cGAN 預測星期天整天之預測結果，(a) 00:00，(b) 03:00，(c) 06:00，(d) 09:00，(e) 12:00，(f) 15:00，(g) 18:00，(h) 21:00 之人群分布。	144

第一章 緒論

1.1 研究背景與動機

近年來隨著城市化及人口的快速增長，人口密度過高也成為許多問題的根本原因，因此城市中的人群分析成為最受矚目的議題之一[69]。國內政府針對人群分析所推動的眾多議題中，又以災防管理中的人群兵棋推演最受到關注，那是由於臺灣同時具有人口稠密及地理位置特殊的特性，使得災害來臨時總是造成許多生命財產的損失。因此人群兵棋推演的目的是模擬災害來臨時城市中不同人群分布下的應變策略，使災害所帶來的損失最小化。城市中的人群分布即代表一座城市中居民的生活型態、城市的商圈位置和景點的人潮變化等，並且會隨著時間而有所改變，例如白天人群會集中到辦公大樓密集的商業區，夜晚人們會回到住宅區，因此人群分布可以說是一種時空資料。我們用圖 1 來介紹城市中的人群分布，通常會用幾月、幾日或是星期幾來描述人群分布的時間特徵，而人群分布的空間因素即代表人們居住的城市，並且由 N 個相同大小的網格來劃分，每一個網格內的數值則代表該時間下的人數。除了時間與空間外，人群分布還會受到額外特徵的影響，額外特徵通常是代表天氣(晴天或雨天)[1][15][62]。如圖 1 (a)為 2018/7/15、早上 11 點，天氣為晴天之條件下全臺北市的人群分布，如藍色方框的網格表示該區域有 1200 人、綠色方框的網格表示該區域有 500 人。圖 1 (b)則為 2019/1/1，早上 6 點，天氣為雨天時全臺北市的人群分布，從這些圖中可明顯看出不同條件下人群分布具有明顯差異，因此若是能有效模擬城市中未來人群分布能使兵棋推演的效果最大化。




圖 1 不同時段之臺北市人群分布，(a)2018/7/15 早上 11:00 之人群分布，(b) 2019/1/1 早上 6:00 之人群分布。

過往常見的人群相關研究有以下三項，分別是人群數值預測、人群移動 (Human-Mobility) 軌跡預測和人群數量統計。(1) 人群數值預測[32][42][50][61][63] 的目標主要是建立預測模型來輸出未來短時間內的人流數值，這些預測模型除了能夠預測人群數值外，也能夠應用於預測道路的交通流量[54][64]，或是計程車需求量[57]相關的時空間資料，但是這些模型的目標是預測短時間未來的數值，且隨著時間的推移，模型準確率會逐漸下降，而本研究的目標是模擬距離現在較長遠的時間(特定時間)，這導致低準確率的模型並不具參考性，因此，過往的短期預測模型不適用於本研究。(2) 人群移動軌跡預測的研究[21][40][55]主要是利用模型來學習手機的 GPS 資料並依此來預測某個時間區段的人群移動軌跡，然而本研究關注的是某個時間下於各個區域的人數數值，僅知道移動軌跡還是無法提供具有參考性的資訊。(3) 人群數量統計的研究[3][6][59][65]主要是利用城市中的攝影機來監控某個道路上的人數，或是計算著名景點中的觀光人數，但是此方法卻無法應用於模擬的假想情境。由於上述提到的方法皆屬於預測短期未來的人群分布狀況，無法應用在模擬特定時間情況下，因此有學者提出使用 k NN(k -Nearest Neighbour) [17] 來模擬各個事件的人群分布狀況[47]，然而卻有預測數值不連貫的問題。

為了改善上述缺點，有學者提出基於 cGAN(Conditional Generative Adversarial Network) 的深度學習模型來解決此問題[68]。cGAN[24]是由兩個子模型組成，其中一個是判別器(Discriminator)，該模型的用途是檢測生成資料，另外一個是生成器(Generator)，該模型的用途是生成與歷史資料相似的假資料，當生成器能夠騙過判別器時，即代表 cGAN 訓練完成，此時，生成器能夠生成與歷史資料相似的假資料。為了使 cGAN 能產生不同條件下的人群分布狀況[68]，此篇研究採用了 cGAN(Conditional GAN) [37] 的架構來訓練生成式模型，由於 cGAN 能夠訓練多個不同類別的資料，該模型於訓練完成後能夠根據給予的條件生成人群分布資料。然而，雖然 cGAN 已被證實能產生未來時刻人群分布，但是還有一些問題點沒有被考慮到，以下將分為四個部分做說明。

(1) 在模擬未來人群分布時，模擬範圍內可能有不同影響因子，因此將不同人群特性的區域用同一個 cGAN 模型產生未來人群分布是不合適的。舉例來說，下雨會使逛夜市及逛街的人群減少，而在車站，不管有無下雨，旅客仍然有搭乘交通




圖 2 (a)總統府與臺北車站周遭地理位置圖，(b)一般情形的人群分布，(c)總統府舉辦遊行時的人群分布，(d) cGAN 生成出的人群分布。

工具的需求。由此可知，人群數量在商圈夜市區域受到天氣因素影響較大，而交通樞紐區域則影響較小。

(2)無法完善考慮到影響人群變化的條件因子。以臺北市總統府與臺北車站之間的區域為例，相對地理位置如圖 2 (a)。一般情況下的人群分布如圖 2 (b)所示，人群數量較多的網格為圖中左下角的總統府及圖中右上角的臺北車站區域，中間區域人群則相對較少。若是總統府舉辦遊行如圖 2 (c)，則總統府周圍區域的人群數量也會跟著增加，而在臺北車站不管有無遊行，人數始終很多。若是將圖 2 (b)與圖 2 (c)這兩種資料都放入 cGAN 訓練而沒有考慮到遊行的因素，最終產生出來的未來人群分布將如圖 2 (d)所示，在總統府周遭的區域可能會有介於一般情況與遊行期間人數的情況發生，產生數值不連貫的情形。




圖 3 平假日不同天氣下的人群數量示意圖

(3)不同時間下，影響人群數量的因子可能不同。舉例來說，臺北市的 101 與信義商圈不只是休閒觀光景點，同時也屬於商業辦公區域。如圖 3 紅線及綠線所示，在假日 101 與信義商圈的人潮多數為觀光客，容易受到天氣影響而有人數上的改變。到了平日，大多數的人潮為辦公區的上班族，不管是晴天或是雨天都需要到公司上班，因此較不受天氣影響。若在不同時間下考慮相同因素，可能導致 cGAN 產生出來的未來人群分布不合理。

(4)為了訓練出一個能夠提供兵棋推演更多參考價值的 cGAN，往往需要大量的資料讓模型學習。隨著模擬條件的增加，可訓練的資料量也就越少，且人群分布資料屬於珍貴且較新穎的資料，在取得上較不容易，因此資料量不足的問題使 cGAN 更難以訓練出能產生多樣性人群分布的模型。

1.2 研究目的

本研究針對上述 cGAN 產生未來時刻人群分布的問題提出三大概念，(1)為解決模擬範圍內包含不同影響因子的問題，利用分群演算法將區域人群做分群，目標是讓人群變化相似的網格歸為同一群。(2)為解決無法考慮到影響人群變化條件因子及不同時間有不同影響因子的問題，針對分群結果訓練各群的 3D-RCL(3D-RBF-CNN-LSTM)模型，透過拆解模型找尋會影響該群人群分布的因子，並且把各群的因子當作各群 cGAN 的輸入。(3)為解決歷史資料過少的問題，自行開發模擬人群

移動的資料擴增技術來產生更多擴增資料讓模型訓練。

1.3 研究範圍

針對人群分布預測問題，由於所蒐集的資料在部分區域具有較多的缺失值，為了實驗的完整性，本研究僅使用臺北市及新北市的區域進行模擬。另外，由於人群較少的區域可能會受到隨機事件的影響使模型無法預測，為了能使產生出的結果更具有人群分布的差異性，本研究不考慮人群較少的區域並將模擬範圍限縮在人群較多的區域，如臺北市信義區、新北市中和區、新北市三重區等等。而為了使人群分布更符合現實情況，本研究將考量區域內的屬性進行範圍的調整，如學區，商圈、住宅區。

1.4 研究限制

1. 研究分析及結果

經過本研究分析所得之人群分布結果，雖然能當作各領域應用的參考，但由於本研究為預測未來較長時間後的人群分布，故僅能以現有已知的影響因子做預測，若是未來產生其它會嚴重影響人群分布的因子，例如捷運的新增、大型公共設施的建立等因素，必須再重新考量會影響區域人群變化的因子。

2. 驗證方式

GAN 的驗證方式可分為質化與量化，而過往研究中大部分都以質化驗證為主，因此在質化驗證會參考過往文獻的評估方式，量化驗證會根據研究問題及資料特性進行評估。

1.5 研究流程

本研究之流程如圖 4 所示，共包含七個階段，各階段內容以下分別說明：

1. 確認研究問題：藉由探討產生未來時刻人群分布之研究議題，針對過往研究預測人群分布不足之處，提出一種能同時考慮到時間、空間、條件因素的方法架構，並針對城市部分區域做預測。




圖 4 研究流程圖

2. 相關文獻回顧：針對人群分布之相關研究進行文獻回顧，探討會影響人群分布之原因，介紹人群預測相關的預測模型，及本研究將使用到的各種方法。
3. 資料蒐集與整理：本研究所蒐集的目標資料集為國內某電信商提供之電信資料。輔助資料集使用政府公開資料平台的開放資料集，包含天氣觀測資料及行事曆資料。
4. 建立研究方法：首先將資料整理成本研究所需之格式，並對目標區域的網格進行分群，接著訓練各自的 3D-RCL 模型用來挑選特徵，同時用自行開發之資料擴增方法對各群網格進行資料生成，最後將各群的特徵及生成資料做為 cGAN 的條件輸入及訓練資料。
5. 實驗模擬與分析：本研究依照研究方法的架構針對臺北市及新北市特定區域進行模擬，在不同區域輸入各種不同的條件輸入生成未來時刻的人群分布。
6. 結論與探討：根據實驗模擬後的預測結果進行不同輸入條件下人群分布的比較，驗證本研究所提出方法的有效性，最終根據研究結果提出結論與未來改善建議。

第二章 文獻回顧

本章節將分為五個小節介紹數個與本論文相關的研究，分別為影響人流因素、時空資料預測演算法、時空資料分群演算法、SMOTE(Synthetic Minority Over-sampling Technique)資料擴增演算法以及生成對抗網路相關研究。

2.1 影響人流因素

人群流動指的是人群從一個空間移動到另一個空間，例如每天的上班通勤，會從個人住家移動到辦公室，中午再從辦公室外出用餐等等，這些都可以算是一種人流。然而，許多外在因素會影響人流。Arnberger 等人[2]於 2007 年比較了城市與森林區的人群特徵，發現平假日會使人群數量改變。Zhang 等人[62]使用深度學習預測城市中的人群移動時發現天氣及節日會讓人群數量產生變化；Ali 等人[1]及 Cheng 等人[15]在預測城市中的交通流量時發現不同時間的人數會產生很大的差異，如白天與夜晚、平日與假日。Gong 等人[23]利用社群媒體中的資料發現，特殊事件或特殊活動會使人群數量有很大的改變，並且也會使周遭的區域人群增加。Deng 等人[18]於 2021 年用多種智慧卡(Smart-Card)電子票證資料尋找人群移動特徵時發現，不同城市有不同的人流模式。而在這些城市中，住宅區、商業區、休閒區均有各自的人群移動模式，並且也指出白天夜晚、平假日都會影響各區域的人群數量。

2.2 時空資料預測演算法

時空資料預測模型常用來預測像是空氣汙染測站監控的數值[8][13]，或是 GPS 軌跡資料[4][12]等，透過提取歷史資料的時間特徵及空間特徵來幫助進行未來數值的預測。而過往研究為了增加預測的準確率，也嘗試將其他可能影響預測目標的特徵加入模型的輸入資料中，例如在預測未來人群數值時加入天氣、日期等資訊，例如人們因為下大雨而減少出門或是平日假日的差異造成人數上的差異。因此以下將介紹與本研究預測目標較相似的時空資料預測模型 ST-ResNet[61]及其後續發展出的方法。




圖 5 人群流入/流出[68]

Zhang 等人[61]提出 ST-ResNet 預測時空資料中多個相鄰區域的未來數值。該方法先對人群流量進行進出流量分割，示意圖如圖 5 所示，圖中 R_1 、 R_2 和 R_3 分別代表城市中不同的區域，而在各個區域間有不同的流入量(Inflow)和流出量(Outflow)，如綠色箭頭表示在該時間區間下，從區域 R_2 移動至其他區域的數量(即為流出量)。而藍色箭頭則表示當下，從其他區域移動至 R_2 的流量數量(即流入量)。而 ST-ResNet 在資料的前處理上則是透過這個進出流量分割的概念，將原始資料處理成各時間區段中各區域的流入及流出，當作模型的訓練資料。

ST-ResNet 的模型架構圖如圖 6 所示，該篇作者認為未來數值會受到不同時間遠近資料影響，例如在預測早上 8 點人群流量時會受到前一個小時、前一天、前一個月的人流量影響。因此在資料前處理時，會依照歷史資料與預測目標的遠近程度分為近期、中期、遠期時間，再將不同遠近程度的資料各自用卷積類神經(Convolution Neural Network, CNN)去萃取歷史資料的空間特徵。該論文也提出使用殘差神經網絡(Deep Residual Networks, ResNet)的結構來防止 CNN 層數過多導致的梯度消失(Gradient Vanishing)問題。並在完成各時期的卷積運算之後，加上一層混和層(Fusion Layer)來整合各時期卷積層提取的空間特徵。在混和層中，各 CNN 的輸出會再乘上可學習的權重來進行資訊的彙整 (X_{Res})。同時在模型訓練時也會加入如氣溫和平日假日的額外因素 (X_{Ext})。最終模型將從歷史資料萃取出來的特徵和額外因素萃取出來的特徵合併後，輸出預測目標 $\hat{X}_t$ 。




圖 6 ST-ResNet 模型架構[68]

受到 ST-ResNet 的啟發，許多學者利用該模型的概念進行延伸，Chen[13]等人提出 LMST3D-ResNet 方法，透過提取資料中趨勢、週期之間的關係，並且將時空特徵與外部因素結合起來預測全城市未來交通運輸量的流入及流出。He 等人[29]提出 Spatio-Temporal 3D Densenet Multiscale ConvLSTM-Resnet Network (ST-3DDMCRN)的架構用來預測城市中未來計程車及自行車的交通流量。

2.3 時空資料分群演算法

由於本研究所使用的資料屬於時空資料，因此以下將分別介紹根據時間特性做分群、根據空間特性做分群、同時考慮時間及空間特性做分群的方法。

2.3.1 考量時間特性做分群方法

根據時間特性做分群的方法中，大多為提取時間資料中的某些特性當作指標，再用一般常見的分群方法進行資料的分群。Jiang 等人[33]使用 PCA (Principal Component Analysis) 主成分分析提取第一個成分的權重做為時間序列的特徵，再用 k -means 分群找出交通量變化相似的時間區間。Syaputra 等人[44]運用 DTW (Dynamic Time Warping) 計算出各個時間序列的相似程度，再用 k -means 分析出客

戶退貨的行為屬性。Wang 等人[51]則在原有的 DTW 上加入了 ED (Euclidean Distance) 的概念，再用 k -means 進行模擬實驗，最終於 k -means 的模擬實驗結果證實 ED-DTW 的效果優於 DTW。Vihanga 等人[49]運用 DTW 尋找每週遊戲玩家的相似性，再用 AHC (Agglomerative Hierarchical Clustering) 聚合式階層分群法找出遊戲玩家的相關性。You 等人[56]則運用 Wsim 整體相似度及 Tsim 趨勢相似度當作股票的時間特徵，再用 AHC 找出股票市場中具有價值的時間區段。

2.3.2 考量空間特性做分群方法

根據空間特性做分群的方法中，大致可分為以距離為基礎的 k -means 系列方法、以密度為基礎的 DBSCAN (Density-Based Spatial Clustering of Applications with Noise)方法、加上模糊 (Fuzzy) 概念的分群方法。Zhang 等人[60]用 k -means 方法將城市居民分群，找出人群集中的位置。Guan 等人[25]用 DBSCAN 規劃軍事偵察範圍。Jianzhuo 等人[35]用 DBSCAN 對城市供水需求點做分群，找出最佳供水位置。Tiessen 等人[46]則比較了 k -means 與 DBSCAN 方法，找出城市中貧民窟的位置及範圍。另外，Guan 等人[26]則運用模糊分群的概念，將城市中的土地進行分級。Ruyan 等人[41]用模糊分群對災害風險進行評估。

2.3.3 同時考量時間及空間特性分群方法

由於早期較多分群演算法都是針對非空間或是非時間數據做分析，較少專門針對時空數據的分群演算法，因此 Birant 等人[5]於 2007 年提出一種基於密度的分群演算法，名為 ST-DBSCAN，該演算法的特點是能同時考量時間跟空間的資料特性對資料做分群。相較於傳統的 DBSCAN 僅使用一個距離參數「Eps」來衡量一維空間數據的相似度，ST-DBSCAN 新增了另一個衡量非空間距離的參數「Eps2」。在時空資料上將「Eps1」設定為空間距離，「Eps2」設定為時間距離，即可將時空資料做分群。後續應用如 Chimwayi 等人[16]應用 ST-DBSCAN 對 2007 到 2017 年的西尼羅河病毒數據進行分群，探索相關的疾病、模式和趨勢。Chen 等人[11]也應用 ST-DBSCAN 對時空購物資料分群，找出不同地區的客户購買模式。




圖 7 SMOTE 生成資料示意圖

2.3.4 時空資料分群方法小結

過往時空資料分群的方法中可分為只考慮時間因素做分群、只考慮空間因素做分群，同時考慮時空資料做分群的方法。由於本研究的資料特性為網格化的資料，各個資料點的距離皆為相同，因此經過評估過後本研究將使用針對時間因素做分群的方法，找出人群變化相似的網格。

2.4 SMOTE

SMOTE 最早由 Chawla 等人[9]於 2002 年提出，其目標是為了要解決分類問題中各類別資料數量不平衡造成準確度不佳的問題。此方法會針對資料量少的類別進行資料擴增，針對資料隨機選擇 k 個相鄰點，再透過數值相加取平均的方式生成新的資料樣本。以圖 7 為例，假設欲針對 A 點產生新資料，當 k 為 3 時，會針對 A 周圍 3 個點相加取平均，最後生成 E 點。

目前許多研究也都利用 SMOTE 來解決各領域的問題，例如 Xu 等人[53]結合 SMOTE 和 k -means 方法提升醫療數據分類準確度；Ishaq 等人[30]運用 SMOTE 技術提升預測心臟病患者生存率準確度；Wei 等人[52]則用來提升預測藥物不良反應準確度。除了醫療領域，許多學者也用來解決工業上的問題，如 Bustillo 等人[7]用來提升加工機刀具破損檢測準確度；Mathew 等人[36]運用 SMOTE 對機器故障資料進行擴增，提升 SVM(Support Vector Machine)於機器故障階段診斷的準確度。




圖 8 GAN 模型架構[68]

2.5 生成對抗網路

生成式對抗網路(GAN, Generative Adversarial Network)在被提出時，其主要目標在於產生與歷史資料相似的資料，因此 GAN 被廣泛應用於醫療相關[10][22]、工業故障診斷[34][48]、交通[58][64]等領域。以下將分為兩小節介紹與本研究較相關的 GAN 與基於 GAN 改進的 Conditional GAN 模型。

2.5.1 GAN

GAN 是一種非監督式深度學習模型，主要的應用於產生與歷史資料相似的假資料。GAN 是由 Goodfellow 等人[24]提出，其模型架構如圖 8 所示，是由生成器(Generator)與判別器(Discriminator)兩個子模型組合而成。生成器的目標是生成與歷史資料相似的假資料，判別器的目標是判斷資料是真實資料或是由生成器產生的假資料。透過兩個子模型不斷的互相學習，使生成器生成的假資料能夠騙過判別器時，即代表 GAN 模型訓練完成。

過往研究常用 GAN 於資料生成的任務中，如 Shrivastava 等人[43]使用 GAN 生成手部姿勢圖片，使資料數量增加幫助模型進行訓練。Esteban 等人[20]提出 Recurrent Conditional GAN (RCGAN)，用於生成加護病房中病患被監測的時序資料藉此模擬病人的生理訊號，幫助解決重症病患資料過少和收集困難的問題。Hartmann 等人[28]提出 electroencephalographic-GAN(EEG-GAN)去生成醫學領域




圖 9 Conditional GAN 模型架構[68]

中的腦信號資料(EEG)，透過該模型能夠在神經科學和神經學方面增強收集不易的資料。

此外，其他研究也利用 GAN 模型中生成器與判別器會互相對抗學習的特性來訓練預測模型，希望透過判別器的檢測來提升預測模型的準確度。如 Saxena 等人[42]提出 D-GAN 模型，與過往非 GAN 架構的相異處是該研究利用判別器來評估預測模型的輸出數值，進而計算出對抗式模型的損失數值，藉由綜合多個損失函數的數值來改善模型。Wang 等人[50]提出 SeqST-GAN 模型，該研究認為僅僅預測下個時間區間的人流數值並不符合實際情況，因此提出預測後 n 步時間區段的人流數值，再訓練判別器來檢測連續時段的人流資料。

2.5.2 Conditional GAN

儘管 GAN 模型已被證實在許多領域都能夠生成接近真實情況的資料，但是該模型只能訓練單一類別資料的缺點也使其應用範圍受到限制。因此 Mirza 等人[37]提出 Conditional Generative Adversarial Network (cGAN)模型，其模型架構如圖 9 所示，在基於 GAN 模型的架構下再加入條件 c 來訓練不同的類別的資料，使模型能夠根據各種條件 c 生成不同類別的資料，大幅度提升了模型的應用範圍。

許多研究基於 cGAN 的架構提出不同的應用，如 Harada 等人[27]訓練 cGAN 模型並且應用於生醫訊號中的心電圖和腦波圖，透過給予不同條件 c 來指定生成正常標籤或是異常標籤的時序資料。Deng 等人[19]訓練 cGAN 模型來生成虛擬人臉圖片，透過指定不同條件產生不同表情的圖片，幫助訓練辨識人臉情緒變化模型。Tan 等人[45]基於 cGAN 架構提出 ArtGAN，用來生成不同條件下的藝術品圖片。

其他研究也應用 cGAN 模型於圖像資料風格轉換的任務中，此任務的目標是將輸入資料從領域 A 轉換至領域 B。Isola 等人[31]提出 Pix2pix 模型，模型透過監督式學習的方式來使得領域 A 的資料能夠轉換至領域 B，但是，該模型只能進行單方向的風格轉換，且監督式學習需要大量具有配對的資料，這些缺點也提升 Pix2pix 的訓練困難度。而後，Zhu 等人[66]提出 CycleGAN 來解決此問題，該論文使用 Cycle Consistency 概念，訓練兩組 GAN 模型來將 A 領域的訓練資料進行二次的領域轉換，例如原圖片需要從領域 A 轉換至領域 B，計算時將會圖片先轉換至領域 B，之後使用領域 B 輸出的圖片在轉換至領域 A，最後再與原始圖片進行 L1 距離計算，進而讓風格轉換的任務能夠使用非監督式學習的方式訓練，大幅的提升其應用範圍。

第三章 資料集

本研究蒐集過往文獻中會影響城市人群分布的因子，使模型能考慮到不同條件下的人群分布。本研究將不同類型的資料分為兩種，第一種為網格形式的目標資料集，以生成出人群分布網格為目標的人群分布資料。第二種為輔助資料集，目標為提供 cGAN 作為條件輸入的資料集，包含天氣資料集及日曆資料集。以下將分為兩小節進行資料集的介紹。

3.1 目標資料集

本研究所使用之目標資料集來源為電信人流資料，資料區間為 2018 年 1 月 1 日至 2019 年 12 月 31 日，資料分布範圍如圖 10 所示，每個紅色點為有資料的位置，以 500*500 公尺網格方式呈現該網格內人群數量，但因礙於產學合作保密協定的關係，我們無法提供更多細節。




圖 10 人流資料空間範圍示意圖



圖 11 CODIS 查詢首頁

表 1 天氣資料

觀測時間(hour)	氣溫(°C)	風速(m/s)	降水量(mm)
1	15.5	0.4	0
2	16.2	1.5	0
3	16.2	1.6	0
...	...	...	...
24	16.2	1.5	0

3.2 輔助資料集

3.2.1 天氣資料集

本研究之天氣資料集蒐集自交通部中央氣象局觀測資料查詢系統(CWB Observation Data Inquire System, CODIS)，查詢首頁如圖 11 所示，查詢資料區間為 2018 年 01 月 01 日至 2019 年 12 月 31 日每小時一筆資料，23 個測站分布點如圖 12 所示。本研究所使用的資料欄位包含「觀測時間(hour)」、「氣溫(°C)」、「風速(m/s)」、「降水量(mm)」，清洗後的天氣資料內容如表 1 所示。




圖 12 天氣觀測站分布點位

表 2 時段資料

西元日期	星期	是否放假	備註
20180101	一	2	開國紀念日
20180102	二	0	
20180103	三	0	
20180104	四	0	
...	...	...	...
20191231	二	0	

3.2.2 日曆資料集

為了獲取本研究所需的時間條件，自政府公開資料平台 (DATA.GOV.TW) 上蒐集了 2018 年及 2019 年之中華民國政府行政機關辦公日曆表，資料欄位包含「西元日期」、「星期」、「是否放假」、「備註」共五個欄位，如表 2 所示。其中，「是否放假」欄位中標記為「2」代表不用上班，標記為「0」則為需要上班。

第四章 研究方法

本研究提出一種基於條件式生成對抗網路之人群分布預測模型，應用於產生城市中未來時刻區域人群分布。本章節將介紹本研究提出之方法，研究架構流程圖如圖 13 所示，共分為 Offline 訓練與 Online 預測兩大部分。Offline 為訓練模型的過程，主要分為四部分，包含(1)資料前處理階段，包含資料清洗與針對各區域進行網格的分群、(2)針對分群結果訓練出各群的 3D-RCL 模型，再透過拆解 3D-RCL 模型尋找各群重要因子、(3)針對分群結果使用自行開發之資料擴增演算法對各群擴增資料、(4)使用資料擴增後的資料，及拆解 3D-RCL 模型找出的各群重要因子當作條件輸入各群的 cGAN 做訓練。Online 預測為輸入各群重要因子的條件後，用各群訓練出的 cGAN 預測未來時刻人群分布，再將各群 cGAN 產生之人群分布組合，最後進行生成資料的評估。




圖 13 研究架構流程圖




圖 14 補值前後示意圖

4.1 資料前處理

根據以往文獻中，資料前處理的最大用處在於將資料轉換成後續模型可用的格式，而處理後的質量會直接影響到模型訓練出來的績效。因此本研究將提出一連串資料前處理方法，分別為(1)缺失值處理、(2)資料正規化、(3)時間序列切片處理、(4)相似網格分群、(5)分群網格數值加總等五個部分，以下將分別進行說明。

4.1.1 缺失值處理

由於本研究所使用的人群分布資料集與天氣資料集皆為觀測資料，而這些資料通常於感測器觀測到數值後，需再透過傳輸設備將資料記錄到資料庫中。在感測器觀測資料及傳輸的過程中，可能會有設備故障、傳輸不穩、停機維護等情況發生而造成資料缺失的情況發生，因此我們需要針對缺失值作處理。常見的缺失值處理方法分別為刪除法、填補法、及不處理三種方法。由於本研究需要依賴大量的歷史資料來對模型做訓練，因此本研究選擇適用於時間序列資料的線性插值法(Linear Interpolation)來做填補的處理。線性插值法一般而言為對缺失值前後的資料相加取平均來做填補的動作，如圖 14 所示，左邊為補值前、右邊為補值後的資料情況。

4.1.2 資料正規化

本研究會同時使用到目標資料及輔助資料，然而這兩種資料的數值分布形態並不相同，因此我們將針對輔助資料使用 Min-Max 正規化，目標資料使用本研究自行開發之 Log-3std 正規化，以下將分為兩小節分別介紹兩種資料正規化方法。




圖 15 Min-Max 正規化前後比較

4.1.2.1 Min-Max 正規化

由於輔助資料中同時包含不同區間尺度的資料，為了使模型的訓練能更快收斂，因此我們將對資料進行資料正規化(Normalization)的動作。舉例來說，假設天氣資料集中的氣溫平均為 25 度，而雨量資料多時可達上百毫米，若是將兩種不同區間尺度的資料同時放入模型訓練，可能會使模型無法學習到真正會影響人群分布的特徵。因此我們使用最小值最大值正規化(Min-Max Normalization)來對資料作處理，此種方法可以在不改變資料分布的情況下將不同的資料區間都壓縮在 0 至 1 之間，如圖 15 為雨量資料經過正規化的前後比較。

4.1.2.1 Log-3std 正規化

本研究開發 Log-3std 正規化方法目的是縮小原始人流數值分布的數值區間，進而讓模型能夠有效地學習極端數值。圖 16 為人群分布資料的原始數值區間，該圖片的 x 軸表示人數， y 軸表示出現該人數的數量，從圖中可看出原始人群分布資料的數值區間相當寬，並且具有數值分配不均的問題。若是直接使用原始人群分布資料進行訓練，可能會讓模型難以學習較大數值出現的模式，因此該正規化方法會先利用公式 1 將數值進行轉換。

$$y = f(x) = \text{Log}_{10}^x \quad (1)$$




圖 16 原始人群資料分布直方圖




圖 17 原始人群資料經過 Log 轉換後之數值分布直方圖

原始人群數值經過 Log 轉換後之資料分布如圖 17 所示，從圖中可發現人群數值分布範圍增加。接著我們使用三倍標準差的界限，將正負三倍標準差以內之數值壓縮至 -0.9 至 0.9 之間，大於三倍標準差之數值壓縮至 0.9 至 1 之間，小於三倍標準差之數值則壓縮至 -1 至 -0.9 之間，藉此減少極端值對模型預測的影響，經過壓縮過後的人群資料分布如圖 18 所示。




圖 18 Log-3std 正規化後之人群資料數值分布直方圖




圖 19 空間切割示意圖

4.1.3 時間序列切割處理

為了符合模型的輸入格式需求，因此我們需針對人群分布資料中的時間及空間進行資料的切割處理，以下將分別介紹空間及時間的切割處理。在空間的切割上，由於本研究的研究範圍為臺北市及新北市人群較多的區域，因此我們將對欲模擬的區域進行網格切割。以圖 19 為例，假設本研究欲針對臺北車站周遭 2000 公尺的區域進行模擬，則會以人群分布資料每個網格為 500*500 公尺大小的基礎下，切割出一個 9*9 大小的網格。




圖 20 時間切割過程示意圖

空間範圍切割出來後，接著進行時間的切割。由於時間人群分布具有其週期性，因此我們將針對資料做觀察，選取適當的時間區間讓模型做訓練。舉例來說，假設在切格完的 9×9 區域中觀察到的人群分布週期為 3 小時，後續將以每 3 小時切割成一筆訓練資料，如圖 20 所示。

4.1.4 相似網格分群

本研究目標為考慮到不同時空下的人群分布變化，因此本階段將對切割出來網格進行分群的動作。為了使分群後群內的網格人數變化具有一定的相似性，因此我們參考過往文獻使用 DTW (Dynamic Time Warping) 計算出各個網格時間序列的相似程度，再用 k -means 進行分群，以下將分別介紹 DTW 及 k -means。

4.1.4.1 DTW 計算時間序列相似性

DTW 為基於動態規劃 (Dynamic Programming) 方法去計算兩組時間序列相似程度的方法，其最大的特點是能消除時間序列中位移或時間延遲的問題。在計算的過程中，會建立一個大小為 $x \times y$ 的矩陣 A ，其中 x 為第一組時間序列 $Q = q_1, q_2, \dots, q_x$ 的長度， y 為第二組時間序列 $C = c_1, c_2, \dots, c_y$ 的長度，如圖 21 所示。矩陣 A 中元素第 i 行第 j 列的值代表 q_i 和 c_j 兩個時間點的距離 $d(q_i, c_j)$ ，若是距離越小代表兩點間的相似性越高。在計算完各點與各點間的相似性後，會從最右上角第 x 行第




圖 21 DTW 矩陣示意圖

y 列的數字開始往左下角找尋最小的值，最終得出一條路徑 $R=r_1, r_2, \dots, r_k$ ，其中 DTW 計算的即為路徑 R 的總和，其公式如下：

$$DTW(Q, C) = \underset{R=r_1, r_2, r_3, \dots, r_k}{\operatorname{argmin}} \sqrt{\sum_{k=1}^k w_k = (i, j) (q_i, c_j)^2} \quad (2)$$

4.1.4.2 k -means 分群

k -means 是一種非監督式的機器學習演算法，可對高維度資料進行分群，讓群內 n 個點分為 k 個群，且所有點和其群中心的距離最小化，其公式如式 3 所示。

$$\arg \operatorname{Min}_{\mu} \sum_{c=1}^K \sum_{i=1}^{n_c} \|x_i - \mu_c\|^2 \quad (3)$$

k -means 算法首先需要設定分群數量 k ，其中 k 必須小於資料個數 n 。接著可分為四個步驟，(1)首先演算法會隨機選擇 k 個點當作起始重心，如式 4。(2)接著將每個資料點分配到最近的 k 點，如式 5。(3)第 3 步為根據第 2 步驟分群後的結果再計算一次群內重心的位置，如式 6。(4)接著重複步驟 2、3，直到群內重心位置不再改變為止，如式 7。




圖 22 分群網格加總目的示意圖

$$\mu_c^{(0)} \in R^d, c = 1, 2, \dots, K \quad (4)$$

$$S_c^{(t)} = \{x_i: \|x_i - \mu_c^{(t)}\| \leq \|x_i - \mu_{c^*}^{(t)}\|, \forall i = 1, \dots, n\} \quad (5)$$

$$\mu_c^{(t+1)} = \frac{\text{sum}(S_c^{(t)})}{n_c} = \sum_{i=1}^{n_c} x_i \quad (6)$$

$$S_c^{(t+1)} = S_c^{(t)}, \forall c = 1, \dots, K \quad (7)$$

4.1.5 分群網格數值加總

為了讓後續 3D-RBF 模型找出影響各群人群分布的因素，因此我們需要將分群網格數值加總。以被分群後的「群 A」做說明，由於我們希望找出影響「群 A」中的人數變化因子，因此將「群 A」內的人數加總後，可以讓 3D-RCL 模型學習到是那些因子影響「群 A」內的總人數變化，如圖 22 所示。舉例來說，假設在所有條件都不變的情況下，預測時間前 2 小時雨量增加 20 毫米，會讓預測時間的「群 A」內總人數減少 200 人，因此我們就可判斷前 2 小時雨量是影響「群 A」內總人數的因子。以另外一個例子舉例說明，假設在所有條件都不變的情況下，預測時間前 1 小時小巨蛋的網格人數增加 2000 人，會讓「群 A」的總人數增加 500 人，因




圖 23 3D-RCL 方法流程圖

此我們就可判斷前 1 小時小巨蛋網格的人數為造成「群 A」內的總人數變化的因子。

4.2 尋找各群重要因子

為了能夠找出分群後影響各群人流變化的因子，本研究將建立 3D-RCL (3D-RBF-CNN-LSTM) 模型，並透過拆解模型中的 3D-RBF 層，獲取重要因子。3D-RCL 方法流程如圖 23 所示，首先將目標資料與輔助資料放入 3D-RCL 模型訓練，接著拆解模型獲得各個因子的重要程度，最後篩選出影響各群人流變化的因子。以下將分為兩小節分別介紹(1)3D-RCL 的建立，及(2)篩選各群重要特徵。

4.2.1 建立 3D-RCL 模型

本篇論文所使用的 3D-RCL 模型架構如圖 24 所示，包含了(1)輸入層、(2)2D-RBF (2D-Radial Basis Function)層、(3)CNN(Convolutional Neural Network)層、(4)資料合併層、(5)1D-RBF (1D-Radial Basis Function)層、(6)LSTM(Long Short-Term Memory)層、(7)全連接層、(8)輸出層，以下將分別做介紹。






圖 24 3D-RCL 模型架構圖

(1)輸入層：由於 3D-RCL 模型同時考慮二維矩陣資料(目標資料)與一維向量資料(輔助資料)，因此會分成兩部分做輸入。首先是二維矩陣資料的輸入層，假設經過分群後的人群分布網格大小為 $m \times n$ ，時間為 t 個時間點，則輸入維度為 $t \times m \times n$ 。而在一維向量資料的輸入層方面，假設所有因子的個數為 z 個，則輸入維度為 $t \times z$ 。兩部分的資料進入到輸入層後皆不經過任何計算，保留原始數值輸出至下一層。

(2)2D-RBF 層：2D-RBF 層的功能為透過高斯函數的計算，將每一個時間的每一個網格特徵進行升維，轉換成新的特徵值(升維後的網格)當作 CNN 層的輸入。2D-RBF 的運作過程中會將 n 個特徵值轉換 n^2 個特徵值，也就是說在經過 2D-RBF 層後特徵數量會變成 $t \times (m \times n)^2$ ，其中每個神經元中都包含了一個 2D-RBF 函數，此 2D-RBF 的網路層是經由周圍空間模糊的方式所組成的高斯函數矩陣，經由輸入的空間矩陣與二維空間 RBF 計算後，透過完整的訓練，每顆時間段神經元輸出都代表在訓練過程中在這個時間段上此空間的重要度，



(a) [67]



(b) [67]

圖 25 2D-RBF 的標準差，(a)中心點落在中央，(b)中心點落在右邊。

2D-RBF 的計算過程如下式 8。

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2} \quad (8)$$

式 8 中 x 與 y 代表 2D-RBF 產生初始中心點位的絕對座標，且中心點位會走訪每一個網格，而 σ 代表的為此神經元中 2D-RBF 的標準差。如圖 25 (a)為中心點位於正中央，圖 25 (b)為中心點位於正右方。透過走訪每個網格並且與 CNN 一起訓練後，能產生每個網格的標準差，其中標準差代表每個特徵對預測目標的重要程度。

(3) CNN 層：CNN 層內共包含卷積層(Convolutional Layer)與池化層(Pooling Layer)。首先，CNN 的卷積層會接收來自 2D-RBF 層的輸出，透過卷積的過程讓模型學習人群分布網格特徵。卷積層的運作過程如圖 26 所示，假設欲學習的人群網格為 $6*6$ 的大小，而卷積核(Kernel)的大小為 $3*3$ ，透過由左上到右下一步一步移動來進行矩陣的乘積，最終會得到一個經過卷積核特徵提取後的矩陣，而模型主要是透過修正卷積核裡的數字讓模型能有更好的績效。




圖 26 卷積計算過程




圖 27 池化層介紹

卷積層之後為池化層，池化層的目的除了減少模型中的參數量，其最重要的功能便是找出卷積過後的人群分布網格中，影響最大的特徵區域。常見的卷積方法為最大池化(Max Pooling)與平均池化(Average Pooling)，運作方式如圖 27 所示，由於我們的目的是要找出影響最大的特徵，因此我們將採用最大池化法來做池化的動作。

(4)資料攤平層：經過 CNN 層的特徵提取後所產生的特徵網格大小會縮小為 $m_1 \times n_1$ 。假設為 3*3 的二維矩陣，為了能與之後的一維資料合併，會將資料維度轉換成長度為 9 的一維資料，轉換過程如圖 28 所示。




圖 28 特徵提取過後攤平過程




圖 29 資料合併過程

(5)合併層：為了使後半段的網路層能同時考慮到目標資料及輔助資料，首先，我們需要將攤平後的人群分布網格與輔助資料做合併，接著將資料格式轉換為 1D-RBF 的輸入格式。為了方便說明，假設我們輸入 T-3、T-2、T-1 三個時間點的資料、攤平後長度為 9 的目標資料、輔助資料考慮因子為時段、氣溫、雨量 3 個因子(k)。合併的過程如圖 29 所示，經過合併後的資料維度為 $[3, 12, 1]$ ，維度意義為 $[3$ 個時間點, 12 個因子特徵]。




圖 30 資料格式轉換

將目標資料與輔助資料合併完成後，為了要時間因素納入因子中，我們需要將維度轉換為一維向量，資料轉換的過程如圖 30 所示，T-3 的所有因子後面會接著 T-2 的所有因子，接著是 T-1，因此資料維度會變為[36, 1]。

(5) 1D-RBF 層：此的功能是把前一層的特徵升維成 q 個新的特徵值，目的是幫我們找出重要時間段中的重要影響因子，最終本層的神經元數量將有 $t * (m_1 * n_1 + k) * q$ 個，每個神經元皆包含一個 RBF 函數，其公式如式 9：

$$O_{ij} = \exp \left[\frac{-(Output_{Input_layer} - m_{ij})^2}{\sigma_{ij}^2} \right] \quad (9)$$

公式中 i 與 j 分別表示模型內第 i 個輸入及第 j 個 RBF 函數，而 σ_{ij} 和 m_{ij} 則代表此神經元中 RBF 函數的標準差及平均值。

(6) LSTM 層：為了能使模型學習到各個因子前後的時間關係，因此在 1D-RBF 進行特徵升維後會銜接到 LSTM 遞迴層。此層中的神經元數目會跟上一層神經元數目相同，並且會接收前一個時間點對現在時間點的影響當作輸入，其公式如式 10 至式 13 所示。

$$U_t = I^t \times w_i^t + bias_i \quad (10)$$

$$S^t = h_i^t \times k w_i^t \quad (11)$$

$$h_i^t = O_i^{t-1} \quad (12)$$

$$O_i^t = \text{act}(U^t + S^t) \quad (13)$$

(7) 全連接層：為了能使模型更完整學習到前面網路中的重要特徵，最後將使用全連接神經元與上一層的 LSTM 輸出相連。在全連接層中，各神經元連接點的權重皆為相同且共享的，因此各個連結都能有獨立且相異的權重值，使預測未來該地區總人數時能因應不同的條件因子達到預測的效果。在連接的過程中，由於每個神經元連接點皆會彼此相連，因此會產生出非常龐大的權重數量，其運算過程如式 14。

$$o_j = \tanh(x_i \times w_{xj}) + b_j \quad (14)$$

其中 x_i 為前一層神經元輸出的值， $\tanh$ 則為激活函數， w_{xj} 代表前一層輸出中對應的權重值， b_j 則為對應第 j 個神經元中的偏壓值。

(8) 輸出層：最終，輸出層會統合全連接層中所有神經元的權重進行區域內總人數的預測。

4.2.2 篩選各群重要特徵

此小節將講解如何拆解 3D-RCL 並且挑選影響人群分布的重要因子，共可分為四個步驟，首先(1)將目標資料與輔助資料放入 3D-RCL 模型中重複訓練多次，目標是能準確預測未來區域內的人群總數。(2)取出訓練好的模型中 1D-RBF 的輸出並計算其標準差。(3)進行初步的特徵篩選，即挑選出重要時間段中的重要因子，若挑選到的因子為人群分布網格，則進入第四步驟。(4) 取出 2D-RBF 的神經元輸出並計算其標準差，進行最終階段的人群分布網格篩選，即挑選出重要時間段中的重要網格。以下將會詳細介紹上述四步驟。為使解說容易，以下將設定目標資料的模擬範圍為 3*3 的大小，輔助資料則放入氣溫、雨量、是否上班三種因子，時間輸入為 T-3、T-2、T-1 過去 3 小時的資料，RBF 設定為產生 3 個新的特徵值(q)。

(1)首先經過 3D-RCL 完整的訓練多次後，選擇預測績效最好的一組超參數來




圖 31 1D-RBF 輸出後計算平均值及標準差

做測試。(2)將測試資料輸入至選擇的 3D-RCL 模型中，並提取 1D-RBF 層的輸出結果。(3)1D-RBF 篩選特徵的部分，由於每個 1D-RBF 會產生 3 筆新的特徵值，因此透過計算三組資料的標準差及平均值，我們就可以知道每個時間中的每個測站或地區的重要程度，如圖 31 所示，其中標準差越小代表資料分布越集中，重要程度也就越大。最後再透過 Threshold 的篩選找出在 1D-RBF 網路層中的重要因子。舉例來說，假設經過 Threshold 找出的重要因子為「T-1 時的氣溫」及「是否上班」，則代表「T-1 時的氣溫」及「是否上班」兩個因子會影響到 T 時間的人群數量。若 1D-RBF 所篩選出來的重要特徵為網格地區，則會進入第四步驟 2D-RBF 的篩選，找出會影響 T 時間人群數量的網格。

(4)為方便說明第二階段的 2D-RBF 篩選，此次先擷取人群分布網格中大小為 5*5 的一部分，如圖 32 所示，而時間輸入則設定為 T-3、T-2、T-1 過去 3 個時間點來做說明。




圖 32 網格地圖解說參考示意圖




圖 33 2D-RBF 矩陣示意圖

首先將測試資料輸入至訓練後的 3D-RCL 模型中，並提取 2D-RBF 的輸出結果。在 2D-RBF 層中每個時間段的網格皆會與不同中心點向外擴散的 5*5 2D-RBF 矩陣進行計算，如圖 33 所示。

在與所有 2D-RBF 矩陣計算完後，接著計算該層輸出矩陣的標準差，此標準差表示該中心點網格對於模型預測目標的重要程度。最後，透過 Threshold 的篩選找出在 2D-RBF 網路層中的重要網格。舉例來說，假設將上述空間矩陣 $\mathbf{X} = [\text{因子 1}, \text{因子 2}, \text{因子 3}, \dots]$ 依序跟 2D-RBF 轉換後的隨機中心點的矩陣 $\mathbf{X} = [\text{RBF1}(\text{因子 1}), \text{RBF2}(\text{因子 2}), \text{RBF3}(\text{因子 3}), \dots]$ 進行計算。接著計算輸出矩陣的標準差，篩選出




圖 34 2D-RBF 訓練後示意圖

重要空間特徵。在圖 34 的視覺化結果可以看到在經過訓練後每個網格的權重標準差值，中心點 2D-RBF 數值越大，會讓整體 2D-RBF 高度越高、寬度越窄，標準差也會隨之變小，表示該中心點地區空間因子較集中，對預測目標的影響程度較大。如範例中的因子 2、因子 3、因子 11、因子 12、因子 23、因子 24 有助於模型後續學習，進而完成篩選重要影響特徵的動作。反之中心點 2D-RBF 數值越小，標準差越大表示該空間因子的常態分布較為發散，對預測目標的影響程度較小，如範例中的因子 1、因子 13、因子 25，因此就會將該特徵剔除。

4.3 資料擴增

為了能使模型能預測出更多可能的人數變化，本研究希望透過資料擴增方法使模型之預測值能有更多變異性，讓災防兵棋推演時能產生更多參考價值。一般常見之圖片資料擴增方法大多為改變圖片方向、拉伸、翻轉、風格轉換等等，然而這些方法並不適用於人群分布資料。為了使模型能學習到更多可能的人群變化，我們開發了三種模擬人群移動模式之資料擴增方法。以下將分為 3 小節分別介紹(1)隨機增減資料擴增方法、(2)最大值互換資料擴增方法，及(3)人群移動資料擴增方法。

4.3.1. 隨機增減方法

隨機增減資料擴增方法為透過在一定區間內隨機的人數變異，加上基於衰退理論 (Distance Decay) 模擬人群外溢現象設計出的方法。此方法需要設定 3 個參數，分別為變異下限 LCL 、變異上限 UCL ，及人口外溢比例 S_rate 。此方法之輸入為一張人群分布圖 X_{in} ，輸出則為經過變異後的人群分布圖 X_{out} ，演算法步驟如下。




圖 35 隨機增減資料擴增方法示意圖

Step1：初始化 X_{out} 及 X_{in} 。

Step2：隨機產生一個經度座標 x 、緯度座標 y 。

Step3：在 X_{in} 中選擇座標 $[x, y]$ 為變異的目標網格，其網格人數為 G_{target} 。

Step4：在 LCL 及 UCL 之間隨機產生一個變異值 M_rate 。

Step5：計算出增減人數 G_{add} ，其算法為 G_{target} 乘上 M_rate 。

Step6：計算出外溢人數總和 S_value ，其算法為 G_{add} 乘上人口外溢比例 S_rate 。

Step7：計算 X_{in} 座標 $[x, y]$ 周圍各網格之外溢比例。

Step8：依照各網格之外溢比例分配外溢人數。

Step9：在 X_{out} 中更新座標 $[x, y]$ 網格之變異數值及周圍網格之外溢人數。

針對此方法本研究以 3×3 網格作為舉例說明， LCL 、 UCL 、 S_rate 分別設定為 -20%、20%、10%，範例示意如圖 35 所示。首先在 Step1 及 Step2 初始化過後，Step3 在 X_{in} 中選擇的變異目標網格為圖中的綠色網格，這時的 G_{target} 為 5000 人。接著 Step4 在 LCL 及 UCL 之間隨機產生 M_rate 假設為 20%，因此 Step5 得出隨機增減人數 G_{add} 為 1000 人，Step6 得出會從綠色網格外溢出的人數總共為 100 人。Step7 依照綠色網格周圍各個橘色網格人數計算出各網格之外溢比例，Step8 進而計算出各個橘色網格之外溢人數，最後 Step9 將目標網格之變異數值及周圍網格之外溢人數更新至 X_{out} 。




圖 36 最大值互換資料擴增方法示意圖

4.3.2. 最大值互換方法

最大值互換資料擴增方法之設計理念為希望透過人群密集地區之人數改變，來達到資料擴增的目的。此方法之輸入為兩個不同日期相同時段的人群分布圖 X_{in1} 及 X_{in2} ，輸出則為經過變異後的兩個人群分布圖 X_{out1} 及 X_{out2} ，此演算法步驟如下。

Step1：隨機選取兩個不同時間的人群分布圖 X_{in1} 及 X_{in2} 。

Step2：尋找 X_{in1} 中人數最大之網格座標 $[x, y]$ 。

Step3：分別匡列 X_{in1} 及 X_{in2} 中網格座標 $[x, y]$ 周圍九宮格之交換範圍為 $Change_1$ 及 $Change_2$ 。

Step4：將 X_{in1} 及 X_{in2} 中 $Change_1$ 及 $Change_2$ 區域人數互換為 X_{out1} 及 X_{out2} 。

針對此方法本研究以 5×5 網格作為舉例說明，範例示意如圖36所示。首先在Step1選取兩個不同時間的資料後，Step2在 X_{in1} 中找出最大網格座標為 $[2, 2]$ ，接著在Step3分別針對 X_{in1} 及 X_{in2} 框出座標 $[2, 2]$ 周圍九宮格之範圍 $Change_1$ 及 $Change_2$ ，最後Step4將 X_{in1} 中 $Change_1$ 取代為 $Change_2$ ， X_{in2} 中 $Change_2$ 取代為 $Change_1$ ，最終輸出 X_{out1} 及 X_{out2} 完成此演算法。




圖 37 人群移動資料擴增方法示意圖

4.3.3. 人群移動方法

此方法為模擬整個模擬區域中一定比例的人群往同個方向移動造成的人數變化，來達到資料擴增的目的。此方法需要設定 2 個參數，分別為人群移動下限 LCL 及人群移動上限 UCL 。此方法之輸入為一個人群分布圖 X_{in} ，輸出則為經過變異後的人群分布圖 X_{out} ，此演算法步驟如下。

Step1：初始化 X_{in} 。

Step2：隨機選取上下左右其中一個方向 D 。

Step3：在 LCL 及 UCL 之間隨機產生一個人群移動比例 M_rate 。

Step4：計算出各網格移動量，其算法為 X_{in} 中所有網格人數乘上 M_rate 。

Step5：將網格移動量往 D 方向移動一格，並且更新至 X_{out} 。

針對此方法本研究以 5×5 網格作為舉例說明， LCL 、 UCL 分別設定為-10%、10%，範例示意如圖 37 所示。假設在 Step2 隨機產生之方向 D 為向右邊移動，在 Step3 產生之變異值為 10%，Step4 會以 X_{in} 乘上 0.1 計算出移動量，Step5 將網格移動量往右邊移動一格，並且與原本的 X_{in} 相加，最後輸出 X_{out} 。




圖 38 本研究 cGAN 架構圖

4.4 訓練 cGAN 模型

經過上述的前處理後，本小節開始介紹基於 cGAN 的深度學習模型。以下將分為 2 小節說明本研究之 cGAN 架構及 cGAN 所使用的損失函數。

4.4.1. cGAN 架構

圖 38 是本研究提出的 cGAN 架構圖，其中 cGAN 模型由兩個子模型組成，分別是判別器 D 與生成器 G ，條件 c 則是由 3D-RCL 挑選之特徵組成的多維向量， X_{real} 代表從歷史資料分布採樣的真實資料， z 代表從高斯分布中採樣的隨機噪音 (Random Noise)， X_{fake} 代表生成器產生的假資料。判別器 D 的任務為預測實際值與預測值之間的差異，來給予生成器修正權重的方向。生成器的主要任務是讓生成資料盡可能的與歷史資料的人群分布相似，會接收來自高斯分布採樣的隨機亂數 z 與條件 c 來生成假資料 X_{fake} ，而後再輸入至判別器，當 X_{fake} 與 X_{real} 之間的差異減小後，代表生成器已經能夠生成具可靠性的假資料。

4.4.2. 損失函數

本小節介紹 cGAN 模型中應用的兩種損失函數 (Loss Function)，分別是 (1) Adversarial Loss，生成器與判別器利用此算法來進行對抗式訓練，(2) Punish Loss，

該方法會對誤差較大值賦予懲罰權重，使模型能更快的根據人群分布模式收斂。

4.4.2.1 Adversarial Loss

cGAN 模型的損失函數如式 15 描述，判別器會接收來自於條件 c 的真實資料 x 和生成器基於條件 c 生成的假資料 $G(c|z)$ ，判別器透過不斷的學習來分辨真實資料與假資料的差異，而生成器則是不斷地改善生成資料的品質，期望能夠產生接近真實的人群分布。在 D 與 G 模型互相對抗的過程中，生成器嘗試去最小化此目標，而判別器嘗試去最大化此目標。

$$\min_G \max_D L_{adv}(D, G) = \mathbb{E}_{x \sim p_{data}} \log[D(c|x)] + \mathbb{E}_{z \sim p_z} \log[1 - D(G(c|z))] \quad (15)$$

4.4.2.2 Punish loss

由於人群分布資料範圍不像一般圖像資料之數值固定介於 RGB 0 至 255 數值範圍內，在人群聚集的都會區人數可達到好幾萬，若是在模型訓練中用一般的 loss 修正模式會使模型難以收斂及有效預測。因此本研究開發出一種適用於訓練人群分布模型之損失函數。其核心概念在於會針對預測值與歷史資料差距過大之網格 loss 值，根據 loss 值排名分階賦予懲罰權重，使模型能更快的根據人群分布模式收斂。此損失函數需要設定賦予懲罰權重的個數 T 以及懲罰值 P 。舉一個 2 階分段懲罰為例說明，假設 T 設定為 10，懲罰值 P_1 及 P_2 設定為 1.8 及 1.5。模型會在每個 Iteration 過後針對每個網格之 loss 值進行排名，接著針對 loss 最大的前 5 名賦予 1.8 倍的懲罰權重，6 至 10 名賦予 1.5 倍的懲罰權重，透過加倍的懲罰權重，加大模型修正的步伐，藉此達到快速收斂及預測精準的目標。

4.5 人群分布績效評估方法

訓練完 cGAN 模型之後，本研究將會針對不同條件下的歷史資料平均與 cGAN 產生的人群分布進行績效評估，將使用 MAPE (Mean Absolute Percentage Error) 來比較歷史資料與生成資料的差異，MAPE 的公式如公式 16：




圖 39 驗證方法示意圖

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{actual_i - predict_i}{actual_i} \right| \times \frac{N}{100} \quad (16)$$

另外由於人群分布為多個網格之數值組成，若是只用 MAPE 當作績效評估指標可能會有其中數個網格預測誤差過大之問題。因此本研究將計算歷史資料中不同條件下人群數量的分配模式，並且用盒鬚圖中四分位數的概念與產生的未來時刻人群分布做比較，驗證所產生的人群分布是否接近過往分布狀態，其概念如圖 39 所示。舉例來說，假設欲生成條件為 [下雨、星期六、時段 16:00~17:00 之間] 臺北市信義區的人群分布狀態，我們會去計算過往時間條件同為 [下雨、星期六、時段 16:00~17:00 之間] 人群分布的歷史資料四分位數，並且比較生成的資料與歷史資料四分位數的人數差距。

第五章 實驗模擬

本研究使用某電信公司提供之行動數據人流資料作為目標資料集，天氣及行事曆作為輔助資料集，利用 cGAN 預測未來時刻之人群分布，最終透過質化方式驗證本研究提出方法之有效性，以下將分為八個部分，(1)資料集與實驗參數介紹，(2)決定模擬區域大小，(3)決定每個模擬區域分群數量，(4)選取作為 cGAN 條件的特徵，(5)不同架構對 cGAN 訓練及預測結果的影響，(6)不同正規化方法對 cGAN 訓練及預測結果的影響，(7)不同資料擴增方法對 cGAN 預測結果的影響，(8)不同條件下預測出的人群分布比較。本研究之實驗皆是利用 python 程式語言實作，並在 Intel i7-9700K 處理器、DDR4 64GB 記憶體以及 Windows 10 的作業系統上完成。

5.1 資料集與實驗參數介紹

本研究所使用之目標資料集來源為電信人流資料，輔助資料集則取自交通部中央氣象局觀測資料查詢系統及政府公開資料平台。為了能夠有效評估分群結果，本研究使用輪廓係數 (Silhouette Coefficient) 及 SSE (Sum of the Squared Errors) 作為分群結果之評估方法，希望能找出群內差異小，群間差異大的分群結果。在 3D-RCL 挑選特徵值部分，為了使模型能考慮到更多特徵對預測結果的影響，將使用前 24 小時 (T-1~T-24 時間) 預測下一小時 (T 時間) 群內總人數，評估指標將使用 RMSE (Root Mean Square Error) 及 MAPE。會使用前 24 小時的資料進行預測是因為人群分布資料最短週期性大約為一天，而使用 RMSE 及 MAPE 當作 3D-RCL 績效評估指標是希望能看出預測差異人數及百分比。而在 3D-RCL 模型架構的部分經過測試後使用 2 層卷積層及 2 層 LSTM 層，另受限於 GPU 記憶體大小，batch size 設定為 20，訓練 Epoch 為 100。輕量化模型之全連接層層數將由輸入維度大小先以 2 的次方升維一次後接著降維至 1，以 5 個維度輸入為例，第一層全連接層將升維至 8 維，接著降維至 4、2、1 維，最終以 1 維輸出，




圖 40 臺北市 11*11 大小的模擬區域

會這樣設定是因為若是將不同維度輸入至同一種架構中，對輸入維度較少的模型可能造成梯度消失問題使模型無法預測，對輸入維度較多之模型可能因模型內可訓練權重不足而造成準確率下降。輕量化模型的 batch size 及 Epoch 則與 3D-RCL 同樣設置為 20 及 100。在訓練人群分布模型部分，由於訓練 cGAN 模型通常需要大量迭代次數，為了取得訓練時間與預測準確度的平衡，本研究將 batch size 設定為 64，訓練之 Iteration 設定為 5000 次，並且使用 MAPE 作為與真實情況相比之量化評估指標。

5.2 決定模擬區域大小

模擬區域的大小會影響到模擬區域的選擇，為了選出一個適合用於預測人群分布的模擬區域大小，本研究以臺北市為中心，向外擴張成 3*3、5*5、7*7、9*9 及 11*11 大小的區域進行實驗，如圖 40 所示。實驗方法為針對這些網格一週共 168 小時平均的人群數量變化進行 2 到 10 群的分群，並且使用輪廓係數及 SSE 評估並且選擇合適的分群數量，實驗結果如圖 41 所示。透過圖 41 發現輪廓係數最高的為 9*9 大小、分群數量為 2 的組合，其分群結果如圖 42 所示，圖 41 中紅色線為時間序列群中心，每條黑線則為每個網格的時間序列變化，X 軸則為星期一 00:00 至星期天 23:00 的一週時間序量變化(168 小時)，圖中有 10 個網格(quantity=10)被歸類為 Cluster1，71 個網格(quantity=71)被歸類為 Cluster2。




圖 41 模擬區域大小之輪廓係數及 SEE score




圖 42 模擬區域 9*9 大小之分群結果




圖 43 模擬區域 7*7 大小之分群結果

而在圖 43 中的 7*7 大小為輪廓係數次高的組合，分群數量為 2 的結果有 21 個網格被歸類為 Cluster1，28 個網格被歸類為 Cluster2。從圖 43 可發現，7*7 大小分為兩群可看出兩種主要的人群數量變化，Cluster1 中各網格人群數量變化特性為白天人數較多，晚上人數較少，且星期一到日都重複維持著這種人群變化模式，Cluster2 中各網格人群數量變化特性一樣為白天人數較多，晚上人數較少，但是在




圖 44 本研究選取之模擬區域




圖 45 各模擬區域分群數量之輪廓係數及 SEE score

假日白天人數明顯少於平日之人數。從 9*9 及 7*7 分群過後的人群變化可發現無論在時間序列的分群或是群內數量(quantity)的差異皆為 7*7 大小的模擬區域較為平衡，因此後續實驗將以 7*7 作為模擬區域範圍的設定。

5.3 決定每個模擬區域分群數量

決定好模擬區域大小後，本研究基於人口密度及區域特性等因素選擇 7 個模擬區域 (Area) 作為實驗模擬的地區，區域分布如圖 44 所示。各 Area 中有空缺的部分為資料的缺失值，由於空缺部分大多位於河川中央或是人煙稀少的地區，因此後續將統一填補人數為 0。

接著本研究針對這 7 個模擬區域進行一週網格內平均人數分群的實驗，測試了 2 群、3 群、4 群、5 群、6 群、7 群、8 群、9 群、10 群共 9 種組合，實驗結果




圖 46 Area 2 分為 2 群之分群結果




圖 47 Area 2 分為 3 群之分群結果

如圖 45 所示。透過圖 45 觀察各實驗組合輪廓係數的變化可發現，除了 Area 2、Area 5 及 Area 6 在 2、3 群的輪廓係數差異較小之外，其餘 Area 在 2 群時的輪廓係數皆明顯高於其他實驗組合，因此我們將額外考慮 Area 2、Area 5 及 Area 6 的分群結果作為分群數量的依據。圖 46 至圖 51 為 Area 2、Area 5 及 Area 6 分為 2 及 3 群的結果，從圖 46 及圖 47 的分群結果可以看出 Area 2 分為 3 群時雖然能分




圖 48 Area 5 分為 2 群之分群結果




圖 49 Area 5 分為 3 群之分群結果

出 3 種主要的人群數量變化，但 Cluster3 群內數量僅有 2 個網格，針對兩個網格進行後續建模意義不大，因此本研究將原本 Area 2 中 Cluster 3 的 2 個網格視為雜訊，並設定 Area 2 分群數量為 2。從圖 48 及圖 49 中 Area 5 分為 2 群及 3 群時可發現分為 3 群並無法分出較明顯之人群數量變化差異，因此本研究將 Area 5 分群數量為 2。從圖 50 及圖 51 的分群結果可以看出 Area 6 分為 3 群時能分出 3 種主要的




圖 50 Area 6 分為 2 群之分群結果




圖 51 Area 6 分為 3 群之分群結果

表 3 各模擬區域分群數量

	Area 1	Area 2	Area 3	Area 4	Area 5	Area 6	Area 7
分群數量	2	2	2	2	2	3	2




圖 52 各 Area 分群之地理位置視覺化

人群數量變化，如 Cluster 1 的人群數量變化特性為白天人較少，晚上人數較多，假日人數則沒有像平日白天人數減少那麼多，可解釋為住宅區之人群變化，平日白天因為要上班，人群移動到工作區，晚上因為下班，人群從工作區移動到住宅區，使人數上升，而假日則因為不用上班，假日白天維持相較於平日白天較多人數。Cluster 2 的人群數量變化特性為 Cluster 1 的相反，白天人較多，晚上人數較少，假日人數則維持較少之人數，可解釋為工作區之人群變化，平日白天因為要上班而聚集大量人群，晚上因為下班人群移動到住宅區，使人數下降，而假日則因為不用上班，整天維持較少人數。Cluster 3 的人群數量變化特性為白天人群數量較多，晚上人群數量較少，平日人數多於假日，這類人群數量變化混合了住宅區與工作區的特性，因此本研究將 Area 6 分群數量為 3。最終本研究將所有 Area 分群數量整理如表 3 所示，所有群之地理位置如圖 52 所示。

5.4 選取作為 cGAN 條件的特徵

本研究選取各群 cGAN 條件之步驟為(1)使用 3D-RCL 對特徵值做重要度分析，接著(2)用輕量化模型實驗來挑選特徵並驗證挑選特徵之合理性，以下將分為兩小節分別介紹兩步驟之實驗結果。

5.4.1. 3D-RCL 特徵值重要度分析

本研究將所有目標資料與輔助資料放入 3D-RCL 中，以前 24 小時 (T-1~T-24 時間) 的資料預測下 1 小時 (T 時間) 各群內總人數，因此一共會建立 15 個 3D-RCL 模型 (7 個 Area 共 15 群)。各群之預測績效如圖 53 所示，可發現各群皆有良好的預測績效，各群之 MAPE 皆介於 3 至 7%。接著拆解各群模型中的 3D-RBF 層並進行標準差的分析，首先拆解 1D-RBF 層，比較不同特徵形態、不同時間點下各個特徵能提供模型預測的資訊量。圖 54 至圖 60 為各群不同形態特徵的標準差盒鬚圖，X 軸為不同形態特徵，Y 軸為 RBF 標準差，數值越大代表該類型特徵能提供模型更多資訊幫助預測。從圖 54 至圖 60 可發現日曆類型的特徵總是能提供模型最多資訊，再來是網格資訊，而天氣相關的特徵對模型預測的幫助則較小。會有這樣的結果是因為人群變化通常具有週期性，如固定的上下班時段，人們大多述情況不會因為下大雨而不用出門上班，這也使得日曆資訊成為最重要的特徵。




圖 53 各群之 MAPE 比較




圖 54 Area 1 之特徵型態標準差比較




圖 55 Area 2 之特徵型態標準差比較




圖 56 Area 3 之特徵型態標準差比較




圖 57 Area 4 之特徵型態標準差比較




圖 58 Area 5 之特徵型態標準差比較




圖 59 Area 6 之特徵型態標準差比較




圖 60 Area 7 之特徵型態標準差比較




圖 61 Area 1 各時間點特徵之最大標準差比較

接著比較各群不同時間點之標準差，如圖 61 至圖 67 所示，X 軸為 24 個時間點，Y 軸為該時間點最大之 RBF 標準差，數值越大代表該時間點之特徵能提供模型更多資訊幫助預測。從圖 61 至圖 67 發現各群中時間點標準差之最大值皆無明顯差異，推斷可能是因為有了日曆特徵使時間點的資訊較無明顯變化。




圖 62 Area 2 各時間點特徵之最大標準差比較




圖 63 Area 3 各時間點特徵之最大標準差比較




圖 64 Area 4 各時間點特徵之最大標準差比較




圖 65 Area 5 各時間點特徵之最大標準差比較



圖 66 Area 6 各時間點特徵之最大標準差比較




圖 67 Area 7 各時間點特徵之最大標準差比較

接著拆解 2D-RBF 層，觀察各群中每個網格的標準差，數值越大代表該網格之人數變化能提供模型更多資訊。圖 68 至圖 74 為各個 Area 中 24 小時平均的標準差，可發現各群皆有明顯能提供模型更多預測資訊的網格。圖 75 至圖 81 為各群最大標準差之地理位置，經過實際觀察各個網格的地理位置後，發現標準差最大之網格內常設至有住宅區、醫院、政府公家機關或是工業區等地標，推斷可能是這些地標之人數變化規律並且與整群總人數變化相近。




圖 68 Area 1 之 24 小時平均標準差




圖 69 Area 2 之 24 小時平均標準差




圖 70 Area 3 之 24 小時平均標準差




圖 71 Area 4 之 24 小時平均標準差




圖 72 Area 5 之 24 小時平均標準差




圖 73 Area 6 之 24 小時平均標準差




圖 74 Area 7 之 24 小時平均標準差



圖 75 Area 1 各群最大標準差網格之地理位置




圖 76 Area 2 各群最大標準差網格之地理位置



圖 77 Area 3 各群最大標準差網格之地理位置



圖 78 Area 4 各群最大標準差網格之地理位置




圖 79 Area 5 各群最大標準差網格之地理位置




圖 80 Area 6 各群最大標準差網格之地理位置




圖 81 Area 7 各群最大標準差網格之地理位置




圖 82 各群拿掉日曆後之 MAPE 比較

從上述實驗結果可得知各類型特徵中，日曆特徵能提供模型最多預測的幫助，而預測時間之前的各時間點標準差則較不具明顯差異。接下來為了驗證日曆特徵確實能提供模型預測最多資訊，本研究將日曆類型之特徵移除，再重新訓練 3D-RCL 模型，目的是為了驗證少了日曆特徵後其他類型的特徵重要程度是否改變。圖 82 整理了各 Area 刪除日曆資訊後之預測績效，從圖中可看出除 Area 5 少了日曆特徵之 MAPE 明顯增加之外，其他 Area 之預測績效並無明顯差異。




圖 83 少了日曆特徵後 Area 1 之特徵型態標準差比較




圖 84 少了日曆特徵後 Area 2 之特徵型態標準差比較

接著拆解少了日曆特徵後的 1D-RBF 層，比較不同特徵形態、不同時間點各個特徵提供模型預測資訊量之差異。圖 83 至圖 89 為各群不同形態特徵之標準差盒鬚圖，X 軸為不同形態特徵，Y 軸為 RBF 標準差，數值越大代表該特徵形態能提供模型更多預測上的幫助。從圖 83 至圖 89 各群之特徵形態標準差比較可發現少了日曆特徵後，能提供模型最多資訊依然是網格特徵，天氣相關的特徵依然對模型預測的影響較小。




圖 85 少了日曆特徵後 Area 3 之特徵型態標準差比較




圖 86 少了日曆特徵後 Area 4 之特徵型態標準差比較




圖 87 少了日曆特徵後 Area 5 之特徵型態標準差比較




圖 88 少了日曆特徵後 Area 6 之特徵型態標準差比較




圖 89 少了日曆特徵後 Area 7 之特徵型態標準差比較

接著比較少了日曆特徵後各群不同時間點的標準差，如圖 90 至圖 96 所示，X 軸為 24 個時間點，Y 軸為該時間點最大之 RBF 標準差，數值越大代表該時間點能提供模型更多資訊幫助預測。從圖 90 至圖 96 發現各 Area 中時間點標準差之最大值與拿掉日曆前相比，各小時的資訊有明顯差異。如 Area1、Area2、Area4、Area5、Area6、Area7 中 T-1 至 T-4 皆顯示出越靠近預測時間點的特徵越重要之情形。在 Area1、Area2、Area3、Area4、Area5、Area6 中也可以發現在 T-11 至 T-13 小時之間也是能提供模型預測幫助的時間。由上述分析發現少了日曆特徵會使時間點重要度提升，由此也可驗證日曆特徵確實是能提供模型最多預測幫助的特徵型態，因此在 cGAN 條件的設定將不額外考慮預測時間點資訊。




圖 90 少了日曆特徵後 Area 1 各時間點特徵之最大標準差比較



圖 91 少了日曆特徵後 Area 2 各時間點特徵之最大標準差比較




圖 92 少了日曆特徵後 Area 3 各時間點特徵之最大標準差比較




圖 93 少了日曆特徵後 Area 4 各時間點特徵之最大標準差比較




圖 94 少了日曆特徵後 Area 5 各時間點特徵之最大標準差比較




圖 95 少了日曆特徵後 Area 6 各時間點特徵之最大標準差比較




圖 96 少了日曆特徵後 Area 7 各時間點特徵之最大標準差比較




圖 97 Area 1 拿掉日曆前後之 24 小時平均標準差

接著拆解少了日曆特徵後的 2D-RBF 層，如圖 97 至圖 103 所示。從圖中可發現各群中標準差較大之網格皆無太大變化，也再次驗證 3D-RCL 確實能幫助找出與群內人數變化相近的網格。




圖 98 Area 2 拿掉日曆前後之 24 小時平均標準差




圖 99 Area 3 拿掉日曆前後之 24 小時平均標準差




圖 100 Area 4 拿掉日曆前後之 24 小時平均標準差




圖 101 Area 5 拿掉日曆前後之 24 小時平均標準差




圖 102 Area 6 拿掉日曆前後之 24 小時平均標準差




圖 103 Area 7 拿掉日曆前後之 24 小時平均標準差




圖 104 Area 1 群 1 之各特徵組合放入輕量化模型預測績效

5.4.2. 用輕量化模型來挑選特徵並驗證挑選特徵之合理性

經過拆解 3D-RCL 排序出各個特徵之重要程度後，我們測試各群中哪些特徵組合能使輕量化模型預測效果最佳。由於特徵數量過多，將所有特徵進行排列組合相當耗時，因此我們以 5 個特徵為單位，測試排名前 25 名、前 25 名累加與後 25 名特徵之預測績效，一群共測試 14 種特徵組合。圖 104 至圖 118 為各 Area 之所有特徵組合放入輕量化模型訓練後的績效比較，從這些結果可發現績效最好之組合皆位於排名前 25 名。接著從圖 104 中 Area1 群 1 之績效圖為例也可發現，排名前 10 名的組合看似與排名倒數 25 名組合之 MAPE 差不多，但實際觀察如圖 119 至圖 121 所示之實際預測值後卻發現排名前 10 名與排名倒數 25 名之預測值差很多。從圖 119 中可發現隨著特徵的增加，預測越來越準確，而到了 16 名以後由於特徵重要程度下降使模型預測達到極限，無法預測較高的值。圖 120 也可證明隨著特徵的增加使模型預測越來越準確，到 16 名以後預測績效便不會有太大提升。相反的從圖 121 中倒數名次預測結果可發現這些特徵僅能提供模型極少資訊，使預測結果不佳，到了最後 5 名則無法提供模型任何有用的預測資訊。




圖 105 Area 1 群 2 之各特徵組合放入輕量化模型預測績效




圖 106 Area 2 群 1 各特徵組合放入輕量化模型之預測績效




圖 107 Area 2 群 2 各特徵組合放入輕量化模型之預測績效




圖 108 Area 3 群 1 各特徵組合放入輕量化模型之預測績效




圖 109 Area 3 群 2 各特徵組合放入輕量化模型之預測績效




圖 110 Area 4 群 1 各特徵組合放入輕量化模型之預測績效




圖 111 Area 4 群 2 各特徵組合放入輕量化模型之預測績效




圖 112 Area 5 群 1 各特徵組合放入輕量化模型之預測績效




圖 113 Area 5 群 2 各特徵組合放入輕量化模型之預測績效




圖 114 Area 6 群 1 各特徵組合放入輕量化模型之預測績效




圖 115 Area 6 群 2 各特徵組合放入輕量化模型之預測績效




圖 116 Area 6 群 3 各特徵組合放入輕量化模型之預測績效




圖 117 Area 7 群 1 各特徵組合放入輕量化模型之預測績效




圖 118 Area 7 群 2 各特徵組合放入輕量化模型之預測績效




圖 119 Area 1 群 1 前 25 名各特徵組合放入輕量化模型之預測績效，(a)排名 1 至 5，(b)排名 6 至 10，(c)排名 11 至 15，(d)排名 16 至 20，(e)排名 21 至 25




圖 120 Area 1 群 1 前 25 名累積特徵組合放入輕量化模型之預測績效，(a)排名 1 至 5，(b)排名 1 至 10，(c)排名 1 至 15，(d)排名 1 至 20，(e)排名 1 至 25




圖 121 Area 1 群 1 後 25 名各特徵組合放入輕量化模型之預測績效，(a)排名 74 至 78，(b)排名 79 至 83，(c)排名 84 至 88，(d)排名 89 至 93，(e)排名 94 至 98

表 4 各群 cGAN 除必要條件輸入之其他條件

群	排名組合	特徵條件
Area 1_group1	11~15	最大標準差網格人數、C0A640 測站雨量
Area 1_group2	11~15	最大標準差網格人數、是否為假日、C0A870 測站溫度
Area 2_group1	5~10	最大標準差網格人數、是否為 9 月
Area 2_group2	1~5	最大標準差網格人數、是否為平日、是否為 10 月、是否為 11 月
Area 3_group1	5~10	最大標準差網格人數、是否為 9 月
Area 3_group2	5~10	最大標準差網格人數、是否為 9 月
Area 4_group1	10~15	最大標準差網格人數、C0A870 測站風速
Area 4_group2	1~5	最大標準差網格人數、是否為 10 月、是否為 11 月、是否為 12 月
Area 5_group1	1~20	最大標準差網格人數、是否為 9 月、是否為 10 月、是否為 11 月、 是否為 12 月、是否為平日、是否為假日、是否為連假、 C0A640 測站風速、C0A870 測站雨量
Area 5_group2	1~5	最大標準差網格人數、是否為 10 月、是否為 11 月、是否為 12 月
Area 6_group1	1~20	最大標準差網格人數、是否為 9 月、是否為 10 月、是否為 11 月、 是否為 12 月、是否為平日、是否為假日、是否為連假、 C0A870 測站雨量、C0A640 測站風速
Area 6_group2	1~5	最大標準差網格人數、是否為 10 月、是否為 12 月、 是否為平日、是否為假日
Area 6_group3	1~5	是否為 10 月、是否為 11 月、是否為 12 月、是否為平日、是否為假日
Area 7_group1	11~15	最大標準差網格人數、是否為 9 月、C0A640 測站雨量
Area 7_group2	11~15	最大標準差網格人數、C0A870 測站風速

經過上述討論可證明 3D-RCL 模型確實能找出輸入特徵之重要程度，再透過不同排名之實驗組合放入輕量化模型，可選出最能提供預測區域人數重要資訊的特徵當作 cGAN 之條件輸入。在 5.4.1 小節 3D-RCL 特徵類型重要程度分析可得出日曆特徵為最重要之特徵資訊，因此我們將星期及小時作為各群 cGAN 之必要條件，其餘條件依 5.4.2 小節之實驗整理如表 4 所示。




圖 122 卷積層架構於 Area 1_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。

5.5 不同架構對 cGAN 訓練及預測的影響

本小節將比較在 cGAN 模型中常見的卷積層架構與本研究提出之全連接層架構對模型訓練及預測之影響，並且比較 4 種條件，分別為星期一 9:00、星期一 18:00、星期六 9:00 及星期六 18:00。為了公平的比較，在這 2 種模型架構訓練時均使用 Min-Max 正規化方法至 0 至 1 區間，Batch size、訓練 Iteration、Learning rate 也都設置一樣的參數，分別為 64、5000、0.0002。以下將整理 cGAN 訓練過程及最後預測出來的結果來討論兩種模型在訓練與預測層面的差異。

圖 122 至圖 151 為兩種架構模型的訓練過程，透過兩兩比較可以發現卷積層架構在訓練時較不容易收斂，且對於人群分布預測能力較差，無法有效預測出人群分布的位置，而全連接層架構則較能針對分群區域產生出較接近真實情況的人群分布，且也較容易收斂。




圖 123 全連接層架構於 Area 1_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 124 卷積層架構於 Area 1_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 125 全連接層架構於 Area 1_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 126 卷積層架構於 Area 2_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 127 全連接層架構於 Area 2_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 128 卷積層架構於 Area 2_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 129 全連接層架構於 Area 2_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 130 卷積層架構於 Area 3_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 131 全連接層架構於 Area 3_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 132 卷積層架構於 Area 3_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 133 全連接層架構於 Area 3_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 134 卷積層架構於 Area 4_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 135 全連接層架構於 Area 4_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 136 卷積層架構於 Area 4_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 137 全連接層架構於 Area 4_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 138 卷積層架構於 Area 5_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 139 全連接層架構於 Area 5_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 140 卷積層架構於 Area 5_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 141 全連接層架構於 Area 5_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 142 卷積層架構於 Area 6_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 143 全連接層架構於 Area 6_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 144 卷積層架構於 Area 6_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 145 全連接層架構於 Area 6_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 146 卷積層架構於 Area 6_Group3 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 147 全連接層架構於 Area 6_Group3 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 148 卷積層架構於 Area 7_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 149 全連接層架構於 Area 7_Group1 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 150 卷積層架構於 Area 7_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 151 全連接層架構於 Area 7_Group2 之訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。

表 5 不同 cGAN 架構於 Area 1 之 4 種條件 MAPE 比較

架構	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
卷積層	130.671	110.532	94.281	105.279
全連接層	28.144	20.628	19.782	17.309

表 6 不同 cGAN 架構於 Area 2 之 4 種條件 MAPE 比較

架構	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
卷積層	124.009	135.596	178.105	143.127
全連接層	60.17	64.631	72.981	70.665

表 7 不同 cGAN 架構於 Area 3 之 4 種條件 MAPE 比較

架構	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
卷積層	194.004	202.545	228.314	202.504
全連接層	65.892	71.404	81.687	74.673

表 8 不同 cGAN 架構於 Area 4 之 4 種條件 MAPE 比較

架構	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
卷積層	192.004	146.729	129.377	119.882
全連接層	52.059	41.559	39.313	37.466

表 9 不同 cGAN 架構於 Area 5 之 4 種條件 MAPE 比較

架構	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
卷積層	222.256	159.373	146.937	150.733
全連接層	54.653	52.956	49.436	49.709

表 10 不同 cGAN 架構於 Area 6 之 4 種條件 MAPE 比較

架構	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
卷積層	106.066	126.183	156.656	164.821
全連接層	50.048	54.659	76.356	78.509

表 11 不同 cGAN 架構於 Area 7 之 4 種條件 MAPE 比較

架構	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
卷積層	159.715	150.281	147.338	162.055
全連接層	69.477	68.44	57.723	64.448

表 5 至表 11 整理各 Area 於不同條件下兩種架構之預測值與歷史資料平均之 MAPE，從這些表中可發現全連接層在每個 Area 及每個條件下均有較佳之預測結果。兩種架構會有這樣的差異是因為卷積層是透過卷積核滑動的原理，找尋圖片中的輪廓來訓練模型。然而人群分布圖與一般圖片最大的不同在於，人群分布圖通常不會有明顯輪廓，若是使用卷積方法會受到卷積核形狀的限制而無法學習到重要特徵，因此本研究將以全連接層架構進行後續實驗。




圖 152 Area 1 取其中一個網格之人群分布直方圖




圖 153 Min-Max 正規化至 0~1 區間之人群數量分布圖

5.6 不同正規化方法對 cGAN 訓練及預測結果的影響

經過 5.5 小節實驗後，本研究選擇全連接層作為 cGAN 之模型架構。然而經過觀察預測結果發現使用 Min-Max 正規化的模型容易有預測過少的問題，會有這樣的狀況是因為各群中人數數量呈現分布不均的情形，如圖 152 為 Area 3 取其中一區網格之人群分布直方圖，可發現人數大多集中在 0 至 7000 人，多於 7000 人之情況次數較少。這種資料分布不均的情況若是使用一般常見的 Min-Max 正規化方法，可能會使模型在預測時精度較差，造成高點較難預測問題，如圖 153 所示。因此本研究實驗數值取以 10 為底的對數後正規化至 0 至 1 區間，正規化後之資料分布如圖 154 所示，目的是希望數值分布更平均使模型能夠訓練更好。但經過觀察後發現取以 10 為底的對數正規化後，數值仍然過於集中。因此本研究提出將數值




圖 154 Log 正規化至 0 至 1 區間之人群數量分布圖




圖 155Log_3std 正規化至-1 至 1 區間之人群數量分布圖

取以 10 為底的對數後依照三倍標準差正規化至-1 至 1 區間方法，正規化後之資料分布如圖 155 所示，可發現與圖 153 相比數值分布更均勻。

圖 156 至圖 185 為使用 2 種正規化方法之模型訓練過程，表 12 至表 18 則為使用 3 種正規化方法之 MAPE。觀察圖 156 至圖 185 發現，與上一節 Min-Max 正規化方法相比，Log 正規化方法能使模型在預測分群邊界網格時預測更準確，會有這樣的差異是因為我們改變了數值分布區間，使模型在訓練較低數值時能有更大的數值區間調整模型權重。




圖 156 Log 正規化方法於 Area 1_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 157 Log_{3std} 正規化方法於 Area 1_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 158 Log 正規化方法於 Area 1_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 159 Log_{3std} 正規化方法於 Area1_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 160 Log 正規化方法於 Area 2_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 161 Log_{3std} 正規化方法於 Area 2_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 162 Log 正規化方法於 Area 2_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 163 Log_{3std} 正規化方法於 Area 2_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 164 Log 正規化方法於 Area 3_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 165 Log_{3std} 正規化方法於 Area 3_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 166 Log 正規化方法於 Area 3_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 167 Log_{3std} 正規化方法於 Area 3_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 168 Log 正規化方法於 Area 4_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 169 Log_{3std} 正規化方法於 Area 4_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 170 Log 正規化方法於 Area 4_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 171 Log_{3std} 正規化方法於 Area 4_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 172 Log 正規化方法於 Area 5_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 173 Log_{3std} 正規化方法於 Area 5_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 174 Log 正規化方法於 Area 5_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 175 Log_{3std} 正規化方法於 Area 5_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 176 Log 正規化方法於 Area 6_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 177 Log_{3std} 正規化方法於 Area 6_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 178 Log 正規化方法於 Area 6_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 179 Log_{3std} 正規化方法於 Area 6_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 180 Log 正規化方法於 Area 6_Group3 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 181 Log_{3std} 正規化方法於 Area 6_Group3 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 182 Log 正規化方法於 Area 7_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 183 Log_{3std} 正規化方法於 Area 7_Group1 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 184 Log 正規化方法於 Area 7_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。




圖 185 Log_{3std} 正規化方法於 Area 7_Group2 之 cGAN 訓練過程，(a)到(e)依次為第 1000、2000、3000、4000、5000 次迭代，(f)訓練之 loss 值。

表 12 不同正規化方法於 Area 1 之 4 種條件 MAPE 比較

正規化方法	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
Min-Max	28.144	20.628	19.782	17.309
Log	33.374	28.952	28.566	26.792
Log_3std	20.681	15.899	16.044	15.157

表 13 不同正規化方法於 Area 2 之 4 種條件 MAPE 比較

正規化方法	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
Min-Max	60.17	64.631	72.981	70.665
Log	46.658	41.172	46.934	47.329
Log_3std	15.629	13.045	13.029	14.017

表 14 不同正規化方法於 Area 3 之 4 種條件 MAPE 比較

正規化方法	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
Min-Max	65.892	71.404	81.687	74.673
Log	44.849	44.823	44.096	39.824
Log_3std	37.395	34.217	35.264	35.867

表 15 不同正規化方法於 Area 4 之 4 種條件 MAPE 比較

正規化方法	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
Min-Max	52.059	41.559	39.313	37.466
Log	53.43	49.381	51.083	46.535
Log_3std	20.21	14.315	12.9	13.45

表 16 不同正規化方法於 Area 5 之 4 種條件 MAPE 比較

正規化方法	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
Min-Max	54.653	52.956	49.436	49.709
Log	59.939	47.133	54.361	56.529
Log_3std	13.085	11.94	11.56	10.156

表 17 不同正規化方法於 Area 6 之 4 種條件 MAPE 比較

正規化方法	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
Min-Max	50.048	54.659	76.356	78.509
Log	48.657	45.605	69.513	69.624
Log_3std	30.671	21.099	20.412	23.302

表 18 不同正規化方法於 Area 7 之 4 種條件 MAPE 比較

正規化方法	星期一 9:00	星期一 18:00	星期六 9:00	星期六 18:00
Min-Max	69.477	68.44	57.723	64.448
Log	51.492	42.202	40.921	43.797
Log_3std	22.99	19.658	18.188	20.916

從表 12 至表 18 比較也可發現，Log_3std 方法均為 MAPE 最低之正規化方法，且除 Area 1 中 Min-Max 方法優於 Log 方法之外，其餘 Area 之 Log 方法皆明顯優於 Min-Max 方法。由此結論可證實使用 Log 方法改變數值分布確實能使模型預測績效大幅提升，因此後續實驗將以 Log_3std 方法作為後續實驗之正規化方法。

5.7 不同資料擴增方法對 cGAN 預測結果的影響

本小節整理了 5 種不同資料擴增方法組合產生之資料訓練 cGAN 之預測績效，分別為原始資料、隨機增減、最大值互換、人群移動及所有方法合併，各種資料擴增方法之隨機變異皆為正負 10%。其中隨機增減、最大值互換、人群移動 3 種方法是混合了原始資料放入模型做訓練，資料量為原始資料之 2 倍。所有方法合併則是混和了原始資料及 3 種資料擴增方法，資料量為原始資料之 5 倍。為了能夠更容易看出不同資料擴增方法之人群數量差異，本章節選擇各 Area 人數變化皆較大之星期六 9:00 時段來做比較。接著在 cGAN 條件設定上，由於各群 cGAN 皆有不同條件輸入，因此除了日曆之外的必要條件之外，各群之其他條件若有網格特徵，則設置為最大值人數之 0.8 倍；雨量、氣溫、風速皆分別設置為最大值之 0、0.7、0.2 倍，在天氣上的意義可解讀為沒下雨、溫暖、且有微風的好天氣。各群之 MAPE 比較整理如表 19 所示，從表中可發現各種資料擴增方法均能預測出與相同條件歷史平均相近之人群分布。從表中我們已知這些方法都能有不錯的績效，但畢竟我們使用擴增資料來訓練模型是為了使模型能考慮到更多可能的人群分布變化，因此在 5.7.1 小節將著重於觀察各網格之預測數值在不同資料擴增方法下的變化，最後於 5.7.2 小節總結由各 Area 觀察到不同資料擴增方法之差異。

表 19 不同資料擴增方法預測星期六 9:00 之 MAPE 比較

	原始資料	隨機增減	最大值互換	人群移動	所有方法合併
Area 1	16.044	13.93	15.693	22.534	19.772
Area 2	13.029	21.768	26.174	20.717	22.22
Area 3	35.264	21.653	36.908	34.854	32.638
Area 4	12.9	15.366	16.509	26.271	24.99
Area 5	11.56	12.068	10.611	23.737	20.005
Area 6	20.412	18.332	16.436	20.698	19.033
Area 7	18.188	26.442	31.299	44.224	33.787

5.7.1. 不同資料擴增方法之預測數值變化

圖 186 至圖 190 為使用不同資料擴增方法預測 Area 1 星期六 9:00 之人群數量。從這些圖中可發現，原始資料預測之人數較接近歷史資料平均，資料擴增方法則較容易預測高於歷史最大值或低於歷史最低值。圖 186 至圖 190 中 x3_y7 座標之網格，所有資料擴增方法皆預測高於最大值，實際觀察此網格跟周圍網格人數相比為最低值，各種資料擴增方法皆有可能使模型預測 x3_y7 較高人數，如使用隨機增減方法會使 x3_y7 具有正負 10% 之增減；使用最大值互換方法可能會因 x2_y6、x3_y6、x4_y6、x4_y7 之網格數值交換之人數外溢現象使 x3_y7 網格中人數增加；使用人群移動方法也可能因為從 x2_y7、x3_y6、x4_y7 移動過來之人數使 x3_y7 網格中人數變多；使用所有擴增資料則因為包含所有資料擴增方法之人數變異，而使 x3_y7 網格預測人數增加。




圖 186 Area 1 使用原始資料預測星期六 09:00 之人群分布




圖 187 Area 1 使用隨機增減資料預測星期六 09:00 之人群分布




圖 188 Area 1 使用最大值互換資料預測星期六 09:00 之人群分布




圖 189 Area 1 使用人群移動資料預測星期六 09:00 之人群分布






圖 190 Area 1 使用所有資料預測星期六 09:00 之人群分布

圖 191 至圖 195 為使用不同資料擴增方法預測 Area 2 星期六 9:00 之人群數量。從這些圖中可發現，原始資料預測之人數一樣均能預測介於歷史值之間，資料擴增方法則較容易預測高於歷史最大值或低於歷史最低值。如圖中 x1_y1 及 x7_y7 座標之網格，所有資料擴增方法皆預測高於歷史最大值，實際觀察此網格跟周圍網格人數相比為相對較低值，這種狀況與 Area 1 中 x3_y7 座標之網格相同，各種資料擴增方法皆有可能使模型在預測 x1_y1 及 x7_y7 網格時有較高人數。






圖 193 Area 2 使用最大值互換資料預測星期六 09:00 之人群分布




圖 194 Area 2 使用人群移動資料預測星期六 09:00 之人群分布




圖 195 Area 2 使用所有資料預測星期六 09:00 之人群分布

圖 196 至圖 200 為使用不同資料擴增方法預測 Area 3 星期六 9:00 之人群數量。從圖 196 中可發現，原始資料預測部分網格之人數與歷史資料平均有些落差，如圖中 x2_y4 及 x2_y5 網格，另外再觀察其他資料擴增方法之預測結果發現此二網格並無預測明顯高於歷史人數之情形，因此推斷可能是 Area 3 中網格人數變化較大，使模型較難以訓練。另外我們也可發現 cGAN 在預測人數變化較大之網格時，經常預測接近中位數或是介於中位數及最小值，如 x2_y1、x2_y2、x6_y2、x6_y3 網格。




圖 196 Area 3 使用原始資料預測星期六 09:00 之人群分布




圖 197 Area 3 使用隨機增減資料預測星期六 09:00 之人群分布




圖 198 Area 3 使用最大值互換資料預測星期六 09:00 之人群分布




圖 199 Area 3 使用人群移動資料預測星期六 09:00 之人群分布




圖 200 Area 3 使用所有資料預測星期六 09:00 之人群分布

圖 201 至圖 205 為使用不同資料擴增方法預測 Area 4 星期六 9:00 之人群數量。從這些圖中可發現，原始資料之預測較接近歷史資料平均，資料擴增方法則較容易預測超出歷史資料範圍。如圖 202 隨機增減方法中 x2_y5 網格之預測值高於歷史平均值，接著觀察周圍網格人數可發現 x3_y6 網格明顯高於 x2_y5 網格，從這裡可看出模型學習到 x3_y6 網格人群外溢後所增加的人數，使預測結果改變。在圖 203 最大值互換方法中，x2_y5 及 x7_y5 網格之預測值高於歷史最大值，從這裡可看出模型分別學習到 x3_y5 及 x6_y5 網格人群外溢之人數，導致預測人數增加。從圖 204 人群移動方法中也可觀察到 x4_y6 網格之預測值高於歷史最大值，x5_y6 網格之預測值低於歷史最小值，從這裡可看出模型學習到人群移動資料，使預測結果改變。從所有資料擴增方法合併的圖 205 中也可發現 x2_y5、x3_y5、x4_y5 網格皆預測高於歷史最大值，這些網格之人數跟周圍網格相比為相對較低值，因此三種資料擴增方法皆有可能使 cGAN 有這樣的預測結果。




圖 201 Area 4 使用原始資料預測星期六 09:00 之人群分布




圖 202 Area 4 使用隨機增減資料預測星期六 09:00 之人群分布




圖 203 Area 4 使用最大值互換資料預測星期六 09:00 之人群分布




圖 204 Area 4 使用人群移動資料預測星期六 09:00 之人群分布




圖 205 Area 4 使用所有資料預測星期六 09:00 之人群分布

圖 206 至圖 210 為使用不同資料擴增方法預測 Area 5 星期六 9:00 之人群數量，從這些圖中可發現 Area 5 相較於其他 Area，Area5 各種方法皆能預測接近歷史資料。而這些方法中，原始資料之預測值最接近歷史資料之平均，人群移動資料擴增方法則最有變化性。如圖 209 中 x1_y6 及 x3_y4 網格之預測人數皆明顯大於歷史最大值，仔細觀察後發現此二網格為周圍網格中人數相對較少之網格，因此模型會學到周圍人數較多之網格人群移動過後的資料，使預測結果大於歷史平均。相反的，在 x2_y6 及 x7_y1 網格則因為與周圍網格相比為人數較多之網格，因此在同樣比例之人群移動時可能使該網格人數變少，使模型學習到人數較少之情形。




圖 206 Area 5 使用原始資料預測星期六 09:00 之人群分布




圖 207 Area 5 使用隨機增減資料預測星期六 09:00 之人群分布




圖 208 Area 5 使用最大值互換資料預測星期六 09:00 之人群分布




圖 209 Area 5 使用人群移動資料預測星期六 09:00 之人群分布




圖 210 Area 5 使用所有資料預測星期六 09:00 之人群分布

圖 211 至圖 215 為使用不同資料擴增方法預測 Area 6 星期六 9:00 之人群數量，從這些圖中可發現 Area 5 相較於其他 Area，Area5 各種方法皆能預測接近歷史資料。在圖 213、圖 214、圖 215 中 x6_y4 網格都有預測高於歷史最大值之現象，觀察周圍網格可發現 x6_y4 網格相對其他網格來說人群數量較少，如 x7_y3 及 x7_y5 網格之人群數量幾乎為 x6_y4 網格之兩倍，因此當有使用到最大值互換跟人群移動資料時會使 x6_y4 網格人數預測較多。




圖 211 Area 6 使用原始資料預測星期六 09:00 之人群分布






圖 212 Area 6 使用隨機增減資料預測星期六 09:00 之人群分布






圖 215 Area 6 使用所有資料預測星期六 09:00 之人群分布

圖 216 至圖 220 為使用不同資料擴增方法預測 Area 7 星期六 9:00 之人群數量，從這些圖中可發現 Area 7 各種方法之預測值相較於其他 Area 皆具有更多變異性，如圖 216 使用原始資料方法之 $x3_y1$ 及 $x2_y6$ 網格預測人數皆明顯大於歷史最大值。從圖 217 也可觀察到 $x3_y4$ 網格預測人數明顯大於歷史最大值。圖 218 中 $x2_y3$ 、 $x1_y4$ 、 $x4_y2$ 網格相較於周圍其他網格人數較少，因此當模型學習到最大值互換造成的人數外溢時，會使這三個網格預測人數增加。




圖 216 Area 7 使用原始資料預測星期六 09:00 之人群分布






圖 217 Area 7 使用隨機增減資料預測星期六 09:00 之人群分布






圖 220 Area 7 使用所有資料預測星期六 09:00 之人群分布

5.7.2. 不同資料擴增方法預測差異小結

從以上各 Area 使用不同資料擴增方法於星期六 9:00 之預測結果分析，本研究針對不同資料擴增方法之預測差異整理了以下幾點結論：

1. 在大多數情況下，使用原始資料訓練 cGAN 模型之預測結果最接近歷史發生過的情況，這也符合我們想要藉由資料擴增增加模型預測數值變異性的目的。
2. 使用資料擴增方法訓練之 cGAN 模型的預測結果具有更大的變異性，較容易預測大於歷史最大值或小於歷史最小值，這種結果能讓災防兵棋推演時能有更多參考價值，考慮更多可能發生的情況。
3. 從多數 Area 之預測結果可以發現在歷史人數變化的網格中，使用資料擴增方法訓練之 cGAN 模型容易預測在介於歷史資料中位數及最小值附近，這可能跟我們的 loss 在預測值過大時會有更大的懲罰權重有關。




圖 221 質化討論地理位置圖

5.8 cGAN 預測結果之質化討論

本小節比較了不同時段下 cGAN 的生成資料，透過質化討論的方式探討 cGAN 產生人群分布資料的合理性。本研究選出幾個人群數量變化較大且較具有代表性的網格來觀察人群變化，其地理位置如圖 221 所示，網格中的地標從北至南依序為藍色框的內湖科技園區、棕色框的西門町、黃色框的東區商圈、紅色框的信義國小及三興國小、綠色框的大安國小、和平高中及芳合實驗中學。為了能完整的比較不同地點在不同時間下的人群變化差異，本研究選擇星期三及星期日當作平假日的比較，並且以三小時為間隔比較整天的人群分布差異，如圖 222 及圖 223 所示，以下依照本研究觀察到之人群數量變化與所在地之間的關係歸納出幾點區域人群變化特性。

- (1) 工業區之人群分布：圖中藍色框的人群分布在平日 9:00 至 18:00 之間人群數量較多，21:00 至 06:00 之間人群數量則較少，到了假日可發現整天人群數量均無太大變化，且維持較少人數。這是因為平日白天要上班，因此聚集了大量到內湖科技園區工作的上班族，到了平日晚上則因為工作結束使人群移動回住宅區，而休假日則因不用上班人群數量較少。
- (2) 學區之人群分布：圖中紅色框、綠色框的人群分布模式與工業區之人群

分布模式較相近，在平日 9:00 至 18:00 之間人群數量較多，21:00 至 06:00 之間人群數量則較少，與白天上課聚集較多學生，下課之後人數較少之情形相符。到了假日可發現，紅色框及綠色框的人群數量變化較小，且人數也與平日相比較少，符合學生們假日不用上課之情況。

- (3) 觀光區之人群分布：從圖中棕色框可發現，不管平日或是假日在早上 9:00 的人數皆為一天中最少的，過了中午 12:00 後人群數量會隨著逛街人潮增加，一直到深夜人數才會減少。而從平假日的比較可以發現，假日的人數會比平日還多，符合大眾會在不用上班的假日出門逛街的行為模式。
- (4) 商業觀光混和區之人群分布：由於臺北市人口密集，各種商業、休閒活動也容易聚集於此，因此常有同一區域內包含各種不同人群分布模式的情況發生，因此本研究選取黃色框作為混和區之質化討論。從圖中平日的人數變化可發現從早上 6:00 開始，人數會慢慢增加，至中午 12:00 時人數最多，接著從 18:00 後人數會有稍微的減少，但還是維持一定的人數，一直到凌晨 3:00 人數最少，到了假日可發現人數最多之時段為 18:00 至 03:00。會有這樣的情形是因為白天有許多上班族進到商業大樓上班，造成白天人數較多之現象，而晚上則因為東區商圈吸引許多逛街民眾，且酒吧、夜店數量較密集，造成深夜時段人數較多之現象。




圖 222 cGAN 預測星期三整天之預測結果，(a) 00:00，(b) 03:00，(c) 06:00，(d) 09:00，(e) 12:00，(f) 15:00，(g) 18:00，(h) 21:00 之人群分布。




圖 223 cGAN 預測星期天整天之預測結果，(a) 00:00，(b) 03:00，(c) 06:00，(d) 09:00，(e) 12:00，(f) 15:00，(g) 18:00，(h) 21:00 之人群分布。

第六章 結論與未來研究建議

綜觀過往人群分布預測方法中，又以 cGAN 具備能夠訓練多個不同類別資料的特性，使該模型於訓練完成後能夠根據給予的條件生成人群分布資料。然而，雖然 cGAN 已被證實能產生未來時刻人群分布，但還有(1)無法考慮模擬區域內不同影響因子、(2)無法考慮到影響人群變化條件因子及不同時間有不同影響因子的問題，及(3)歷史資料過少的問題需要被解決。因此本研究針對上述問題提出三大概念，(1)利用分群演算法將區域人群做分群，解決模擬範圍內包含不同影響因子的問題，(2)訓練並拆解 3D-RCL 模型，找尋會影響該群人群分布的因子，(3)開發適用於人群分布的資料擴增技術解決歷史資料過少的問題。在實驗模擬章節中，本研究透過一連串的實驗證實使用人群變化時間序列分群分出不同人群變化，再透過拆解 3D-RCL 模型確實能找出影響各群人群變化的影響因子。在 cGAN 產生人群分布實驗中，透過不同架構、不同正規化方法，及不同資料擴增方法的實驗組合中，我們得出以下幾點結論，(1)全連接層能使模型訓練時的收斂速度加快，且較適用於產生分群過後的人群分布。(2)透過 Log-3std 正規化方法調整人群數值區間能有效使人群分布之預測績效獲得大幅度的提升。(3)使用不同模擬人群移動的資料擴增模式皆能有效產生能提供兵棋推演參考價值之人群分布。

針對未來研究本研究提出幾點延伸探討及建議，(1)未來研究可加入更多可能影響人群分布之資料，探討這些資料對人群變化的影響性，如加入各大旅遊景點搜尋熱度、捷運各站進出量資料、YouBike 共享單車租還量資料等。(2)本研究受限於資料取得限制僅能使用 2018 年及 2019 年資料進行分析，然而自 2020 年爆發新型冠狀病毒後人群分布模式可能受到影響，因此若是能加入更多年分的資料便能使 cGAN 產生之人群分布更具參考價值。(3)加入消防局服務範圍、人力配置等資料產生不同人群分布下的救災配置圖。(4)使用人群分布網格解析度更高的資料套用至本研究的方法架構，產生的人群分布圖能使兵棋推演效果更好。

參考文獻

- [1] Ali, A., Zhu, Y., & Zakarya, M. (2021). Exploiting dynamic spatio-temporal correlations for citywide traffic flow prediction using attention based neural networks. *Information Sciences*, 577, 852-870.
- [2] Arnberger, A., & Haider, W. (2007). A comparison of global and actual measures of perceived crowding of urban forest visitors. *Journal of Leisure Research*, 39(4), 668-685.
- [3] Babu Sam, D., Surya, S., & Venkatesh Babu, R. (2017). Switching convolutional neural network for crowd counting. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 5744-5752).
- [4] Bhattacharya, T., Kulik, L., & Bailey, J. (2015). Automatically recognizing places of interest from unreliable GPS data using spatio-temporal density estimation and line intersections. *Pervasive and Mobile Computing*, 19, 86-107.
- [5] Birant, D., & Kut, A. (2007). ST-DBSCAN: An algorithm for clustering spatial-temporal data. *Data & knowledge engineering*, 60(1), 208-221.
- [6] BooMinathan, L., Kruthiventi, S. S., & Babu, R. V. (2016, October). Crowdnet: A deep convolutional network for dense crowd counting. In *Proceedings of the 24th ACM international conference on Multimedia* (pp. 640-644).
- [7] Bustillo, A., & Rodríguez, J. J. (2014). Online breakage detection of multitooth tools using classifier ensembles for imbalanced data. *International Journal of Systems Science*, 45(12), 2590-2602.
- [8] Chang, F. J., Chang, L. C., Kang, C. C., Wang, Y. S., & Huang, A. (2020). Explore spatio-temporal PM2. 5 features in northern Taiwan using machine learning techniques. *Science of the Total Environment*, 736, 139656.

- [9] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic Minority over-sampling technique. *Journal of artificial intelligence research*, 16, 321-357.
- [10] Che, Z., Cheng, Y., Zhai, S., Sun, Z., & Liu, Y. (2017, November). Boosting deep learning risk prediction with generative adversarial networks for electronic health records. In *2017 IEEE International Conference on Data Mining (ICDM)* (pp. 787-792). IEEE.
- [11] Chen, H., Yu, S., Huang, F., Zhu, B., Gao, L., & Qian, C. (2020, May). Spatio-temporal Analysis of Retail Customer Behavior based on Clustering and Sequential Pattern Mining. In *2020 3rd International Conference on Artificial Intelligence and Big Data (ICAIBD)* (pp. 284-288). IEEE.
- [12] Chen, J., Li, W., Zhang, H., Jiang, W., Li, W., Sui, Y., ... & Shibasaki, R. (2020). Mining urban sustainable performance: GPS data-based spatio-temporal analysis on on-road braking emission. *Journal of Cleaner Production*, 270, 122489.
- [13] Chen, Y., Zou, X., Li, K., Li, K., Yang, X., & Chen, C. (2021). Multiple local 3D CNNs for region-based prediction in smart cities. *Information Sciences*, 542, 476-491.
- [14] Chen, Z., Chen, D., Xie, X., Cai, J., Zhuang, Y., Cheng, N., ... & Gao, B. (2019). Spatial self-aggregation effects and national division of city-level PM_{2.5} concentrations in China based on spatio-temporal clustering. *Journal of Cleaner Production*, 207, 875-881.
- [15] Cheng, K., Lubamba, E. K., & Liu, Q. (2020). Action Prediction Based on Partial Video Observation via Context and Temporal Sequential Network With Deformable Convolution. *IEEE Access*, 8, 133527-133540.
- [16] Chimwayi, K. B., & Anuradha, J. (2018). Clustering West Nile Virus spatio-

- temporal data using ST-DBSCAN. *Procedia computer science*, 132, 1218-1227.
- [17] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE transactions on information theory*, 13(1), 21-27.
- [18] Deng, Y., Wang, J., Gao, C., Li, X., Wang, Z., & Li, X. (2021). Assessing temporal-spatial characteristics of urban travel behaviors from multiday smart-card data. *Physica A: Statistical Mechanics and its Applications*, 576, 126058.
- [19] Deng, J., Pang, G., Zhang, Z., Pang, Z., Yang, H., & Yang, G. (2019). cGAN based facial expression recognition for human-robot interaction. *IEEE Access*, 7, 9848-9859.
- [20] Esteban, C., Hyland, S. L., & Rätsch, G. (2017). Real-valued (medical) time series generation with recurrent conditional gans. *arXiv preprint arXiv:1706.02633*.
- [21] Feng, J., Yang, Z., Xu, F., Yu, H., Wang, M., & Li, Y. (2020, August). Learning to simulate human mobility. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 3426-3433).
- [22] Golany, T., Radinsky, K., & Freedman, D. (2020, November). Simgans: Simulator-based generative adversarial networks for ecg synthesis to improve deep ECG classification. In *International Conference on Machine Learning* (pp. 3597-3606). PMLR.
- [23] Gong, V. X., Daamen, W., Bozzon, A., & Hoogendoorn, S. P. (2020). Crowd characterization for crowd management using social media data in city events. *Travel behaviour and society*, 20, 192-212.
- [24] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. *Advances in neural information processing systems*, 27.
- [25] Guan, Q., Feng, S., & Cao, Y. (2011, July). Clustering analysis of space

reconnaissance intelligent service requirements in presence of military values.

In *2011 Second International Conference on Mechanic Automation and Control Engineering* (pp. 3951-3953). IEEE.

- [26] Guan, X., Fang, C., Dong, C., & Lu, S. Application of fuzzy comprehensive clustering in urban land gradation based on data field. In *2010 IEEE Youth Conference on Information, Computing and Telecommunications*.
- [27] Harada, S., Hayashi, H., & Uchida, S. (2019). Biosignal generation and latent variable analysis with recurrent generative adversarial networks. *IEEE Access*, 7, 144292-144302.
- [28] Hartmann, K. G., Schirrmester, R. T., & Ball, T. (2018). EEG-GAN: Generative adversarial networks for electroencephalographic (EEG) brain signals. *arXiv preprint arXiv:1806.01875*.
- [29] He, R., Liu, Y., Xiao, Y., Lu, X., & Zhang, S. (2022). Deep spatio-temporal 3D densenet with multiscale ConvLSTM-Resnet network for citywide traffic flow forecasting. *Knowledge-Based Systems*, 109054.
- [30] Ishaq, A., Sadiq, S., Umer, M., Ullah, S., Mirjalili, S., Rupapara, V., & Nappi, M. (2021). Improving the prediction of heart failure patients' survival using SMOTE and effective data Mining techniques. *IEEE Access*, 9, 39707-39716.
- [31] Isola, P., Zhu, J. Y., Zhou, T., & Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1125-1134).
- [32] Jiang, R., Song, X., Huang, D., Song, X., Xia, T., Cai, Z., ... & Shibasaki, R. (2019, July). Deepurbanevent: A system for predicting citywide crowd dynamics at big events. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2114-2122).

- [33] Jiang, S., Wang, S., Li, Z., Guo, W., & Pei, X. (2015, September). Fluctuation similarity modeling for traffic flow time series: a clustering approach. In *2015 IEEE 18th International Conference on Intelligent Transportation Systems* (pp. 848-853). IEEE.
- [34] Jiang, W., Hong, Y., Zhou, B., He, X., & Cheng, C. (2019). A GAN-based anomaly detection approach for imbalanced industrial time series. *IEEE Access*, 7, 143608-143619.
- [35] Jianzhuo, Y., Mengyao, Q., Liying, F., Ying, W., & Jianyun, Y. (2013, January). Forecast the distribution of urban water point by using improved DBSCAN algorithm. In *2013 Third International Conference on Intelligent System Design and Engineering Applications* (pp. 784-786). IEEE.
- [36] Mathew, J., Pang, C. K., Luo, M., & Leong, W. H. (2017). Classification of imbalanced data by oversampling in kernel space of support vector machines. *IEEE transactions on neural networks and learning systems*, 29(9), 4065-4076.
- [37] Mirza, M., & Osindero, S. (2014). Conditional generative adversarial nets. *arXiv preprint arXiv:1411.1784*.
- [38] Mogren, O. (2016). C-RNN-GAN: Continuous recurrent neural networks with adversarial training. *arXiv preprint arXiv:1611.09904*.
- [39] Odena, A., Olah, C., & Shlens, J. (2017, July). Conditional image synthesis with auxiliary classifier gans. *International conference on machine learning* (pp. 2642-2651).
- [40] Ouyang, K., Shokri, R., Rosenblum, D. S., & Yang, W. (2018, July). A Non-Parametric Generative Model for Human Trajectories. In *IJCAI* (pp. 3812-3817).
- [41] Ruyan, Z., & Shijun, H. (2009, August). The disaster risk assessment of urban storm surges based on the method of fuzzy clustering. In *2009 Sixth International*

- Conference on Fuzzy Systems and Knowledge Discovery* (Vol. 1, pp. 315-319). IEEE.
- [42] Saxena, D., & Cao, J. (2019). D-gan: Deep generative adversarial nets for spatio-temporal prediction. *arXiv preprint arXiv:1907.08556*.
- [43] Shrivastava, A., Pfister, T., Tuzel, O., Susskind, J., Wang, W., & Webb, R. (2017). Learning from simulated and unsupervised images through adversarial training. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2107-2116).
- [44] Syaputra, A., & Laoh, E. (2020, November). Customer Segmentation on Returned Product Customers Using Time Series Clustering Analysis. In *2020 International Conference on ICT for Smart Society (ICISS)* (pp. 1-5). IEEE.
- [45] Tan, W. R., Chan, C. S., Aguirre, H. E., & Tanaka, K. (2017, September). ArtGAN: Artwork synthesis with conditional categorical GANs. In *2017 IEEE International Conference on Image Processing (ICIP)* (pp. 3760-3764). IEEE.
- [46] Tiessen, T., Friesen, J., Rausch, L., & Pelz, P. F. (2019, May). Using remote sensing data and cluster algorithms to structure cities. In *2019 Joint Urban Remote Sensing Event (JURSE)* (pp. 1-4). IEEE.
- [47] Vermeulen, J. L., Hillebrand, A., & Geraerts, R. (2017). A comparative study of k-nearest neighbour techniques in crowd simulation. *Computer Animation and Virtual Worlds*, 28(3-4), e1775.
- [48] Viola, J., Chen, Y., & Wang, J. (2021). FaultFace: Deep convolutional generative adversarial network (DCGAN) based ball-bearing failure detection method. *Information Sciences*, 542, 195-211.
- [49] Vihanga, D., Barlow, M., Lakshika, E., & Kasmarik, K. (2019, August). Weekly seasonal player population patterns in online games: A time series clustering

- approach. In *2019 IEEE Conference on Games (CoG)* (pp. 1-8). IEEE.
- [50] Wang, S., Cao, J., Chen, H., Peng, H., & Huang, Z. (2020). SeqST-GAN: Seq2Seq generative adversarial nets for multi-step urban crowd flow prediction. *ACM Transactions on Spatial Algorithms and Systems (TSAS)*, 6(4), 1-24.
- [51] Wang, W., Lyu, G., Shi, Y., & Liang, X. (2018, November). Time series clustering based on dynamic time warping. In *2018 IEEE 9th international conference on software engineering and service science (ICSESS)* (pp. 487-490). IEEE.
- [52] Wei, J., Lu, Z., Qiu, K., Li, P., & Sun, H. (2020). Predicting drug risk level from adverse drug reactions using smote and machine learning approaches. *IEEE Access*, 8, 185761-185775.
- [53] Xu, Z., Shen, D., Nie, T., Kou, Y., Yin, N., & Han, X. (2021). A cluster-based oversampling algorithm combining SMOTE and k-means for imbalanced medical data. *Information Sciences*, 572, 574-589.
- [54] Yang, K., Menendez, M., & Guler, S. I. (2019). Implementing transit signal priority in a connected vehicle environment with and without bus stops. *Transportmetrica B: Transport Dynamics*, 7(1), 423-445.
- [55] Yin, M., Sheehan, M., Feygin, S., Paiement, J. F., & Pozdnoukhov, A. (2017). A generative model of urban activities from cellular data. *IEEE Transactions on Intelligent Transportation Systems*, 19(6), 1682-1696.
- [56] You, S. Y., Wang, Y. D., Luo, L. K., & Peng, H. (2016, August). Finding the clusters with potential value in financial time series based on agglomerative hierarchical clustering. In *2016 11th International Conference on Computer Science & Education (ICCSE)* (pp. 77-81). IEEE.
- [57] Yu, H., Chen, X., Li, Z., Zhang, G., Liu, P., Yang, J., & Yang, Y. (2019). Taxi-based mobility demand formulation and prediction using conditional generative

- adversarial network-driven learning approaches. *IEEE Transactions on Intelligent Transportation Systems*, 20(10), 3888-3899.
- [58] Yuan, J., Zheng, Y., Zhang, C., Xie, W., Xie, X., Sun, G., & Huang, Y. (2010, November). T-drive: driving directions based on taxi trajectories. In *Proceedings of the 18th SIGSPATIAL International conference on advances in geographic information systems* (pp. 99-108).
- [59] Zhang, C., Li, H., Wang, X., & Yang, X. (2015). Cross-scene crowd counting via deep convolutional neural networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 833-841).
- [60] Zhang, J., Liu, J., & Wang, B. (2010, May). Spatial cluster based on map algebra. In *2010 International Conference on E-Business and E-Government* (pp. 2335-2338). IEEE.
- [61] Zhang, J., Zheng, Y., & Qi, D. (2017, February). Deep spatio-temporal residual networks for citywide crowd flows prediction. In *Thirty-first AAAI conference on artificial intelligence*.
- [62] Zhang, J., Zheng, Y., Qi, D., Li, R., Yi, X., & Li, T. (2018). Predicting citywide crowd flows using deep spatio-temporal residual networks. *Artificial Intelligence*, 259, 147-166.
- [63] Zhang, J., Zheng, Y., Sun, J., & Qi, D. (2019). Flow prediction in spatio-temporal networks based on multitask deep learning. *IEEE Transactions on Knowledge and Data Engineering*, 32(3), 468-478.
- [64] Zhang, Y., Li, Y., Zhou, X., Kong, X., & Luo, J. (2020, August). Curb-GAN: Conditional Urban Traffic Estimation through Spatio-Temporal Generative Adversarial Networks. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 842-852).

- [65] Zhou, Y., Yang, J., Li, H., Cao, T., & Kung, S. Y. (2020). Adversarial learning for multiscale crowd counting under complex scenes. *IEEE transactions on cybernetics*.
- [66] Zhu, J. Y., Park, T., Isola, P., & Efros, A. A. (2017). Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Proceedings of the IEEE international conference on computer vision* (pp. 2223-2232).
- [67] 江吉晟（民 110 年）。應用三維高斯函數結合深度學習之區域 PM2.5 預測（未出版之碩士論文）。國立雲林科技大學，雲林縣。
- [68] 陳昱任（民 110 年）。運用 cGAN 產生未來時刻人流分布（未出版之碩士論文）。國立成功大學，台南市。
- [69] 詹大千（民 107 年 4 月 6 日）。從手機網路訊號資料，探勘人口動態奧妙（張語辰 & 廖英凱, Eds.）【新聞群組、線上論壇或討論群組】。取自 <https://research.sinica.edu.tw/human-dynamics-chan-ta-chien/>