

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

基於集成式生成對抗網路進行人流異常預測

Anomaly Detection of Crowd Flow by Using Ensemble
Generative Adversarial Networks

王詠緹

Yong-Ti Wang

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D.

中華民國 110 年 6 月

June 2021

摘要

隨著資通訊設備技術的開發與大數據概念的推廣，人流異常預測分析已成為目前政府與商界最重視的議題之一，因為若能讓政府或商界提早得知人流即將異常，則政府將能有效進行交通管理、災害管理、資源分配等，而商界則能制定人流異常時的銷售策略並因此獲利。然而綜觀過往的人流異常預測分析方法，包含統計方法與機器學習方法都有其缺陷。統計方法可能過於死板而無法隨真實狀況變動。至於機器學習的兩大類框架，監督式學習框架在本議題可能會遇到資料量不足及需要事先定義異常標籤而無法有效訓練的問題，非監督式學習框架在本議題則可能遇到異常特徵學習錯誤或學習不到異常特徵的狀況。有鑑於此，本論文提出一種新的人流異常預測分析方法，其中這方法包含三大概念，(1)基於 GAN 的概念產生幾已亂真的人流虛擬資料來避免人流資料不足的問題；(2)使用半監督式學習的框架來避免過往監督式與非監督式學習框架會遇到的困難；(3)訓練正反兩種人流異常預測分析模型，並使用集成式學習統整兩個模型的結果，以提升人流異常的預測準確性。最終，本研究將以北台灣部分商圈地區作為模擬區域，以真實人流資料為基礎，透過量化與質化方式驗證預測結果合理性。

關鍵字：人流異常、異常預測、生成對抗網路、集成式學習、深度學習

Abstract

With the development of communication equipment technology and the promotion of the concept of big data, the prediction and analysis of the abnormal crowd flow has become one of the most important issues for the government and the business. If the government or the business can learn about the imminent crowd flow early, the government will be able to carry out traffic management, disaster management, resource allocation, etc. The business can formulate sales strategies when the crowd flow is abnormal and profit from it. However, looking at the past anomaly prediction and analysis methods of crowd flow, both statistical methods and machine learning methods have their shortcomings. Statistical methods may be too rigid to follow the real situation. As for the two major types of machine learning, the supervised learning may encounter problems with insufficient data and the need to define abnormal labels in advance and cannot be effectively trained. Unsupervised learning may encounter abnormal feature learning in this topic. Errors or failure to learn abnormal characteristics. In view of this, this paper proposes a new method for predicting and analyzing the flow of people, which includes three concepts, (1) Based on the GAN to generate virtual data to avoid the problem of insufficient flow of data; (2) Use the semi-supervised learning to avoid the difficulties encountered in the past supervised and unsupervised learning; (3) Train the pros and cons of the models for the crowd flow, and use integrated learning to unify the results of the two models. In the end, this research use some commercial districts in northern Taiwan as a simulation area, and verify the rationality of the results through quantitative and qualitative methods.

Keywords : Crowd Flow, Anomaly Detection Prediction, GAN, Ensemble Learning, Analysis of Anomaly Detection

誌謝

時光飛逝，在論文即將完成的同時也代表著研究生活也接近尾聲了，此時此刻心中充滿無限的感謝，在此對所有人獻上最大的敬意。

首先，碩士生涯的這兩年，最感謝我的指導老師—陳奕中老師，謝謝老師讓我加入工商暨交通數據分析實驗室，並且願意為我們投入大量的心力與時間，作為老師能夠以身體力行的研究態度令我非常尊敬，也總是能帶給我前進的力量。感謝老師在我們有問題或是遇到瓶頸時，願意在忙碌之餘抽出時間與我們開會，並且不厭其煩的教導我們、鼓勵我們。實在難以用字句表達出所有的感謝，因此在此向恩師致上我最崇高的謝意與最誠摯的感激。再者，感謝國家災害防救科技中心災防資訊組組長張子瑩與尚榮康博士後研究員給予論文研究方向以及建議。

感謝從大學一路陪伴我到碩士的同學力誠，緣分讓我們在學生時期能夠看著彼此一路成長，成為彼此最好的學習夥伴與合作對象。在碩士生涯中與我相互砥礪，在彼此遇到困難時一起去思考出解決辦法，在我遇到挫折時不斷地給我加油打氣，給予我無限的關懷與勉勵。因為有你讓我可以順利完成碩士學位，謝謝你。

感謝非常照顧我們的宇哲學長與紫平學姊，傳承許多可貴的經驗跟知識。感謝實驗室的博士後研究員富正大哥、博士班志豪學長、東錡學長、映均學姐給予資源。感謝實驗室同學、實驗室碩士班學長姐及學弟妹、大學同學等各位大家給予我持續努力的動力。另外，感謝高中同學育誠、儀庭、渝淨給予我無限大的鼓勵跟滿滿的正能量，讓我知道有群朋友在臺北做我的後盾。

非常感謝我最親愛的家人們，非常謝謝你們在我忙碌的碩士期間還是不忘關心我的身體健康，給予我諸多的叮嚀，並且在臺北默默地支持我、關心我、呵護我，當我最溫暖也最可靠的避風港，因為有你們多方面的支持與鼓勵，讓我無後顧之憂的完成學士及碩士學業，朝目標向前。

最後，謹以此向所有幫助我的人致上最大的謝意，並將這份成果獻給你們。

目錄

摘要.....	i
Abstract.....	ii
誌謝.....	iii
目錄.....	iv
表目錄.....	vi
圖目錄.....	vii
第一章 緒論.....	1
1.1 研究背景與動機.....	1
1.2 研究目的.....	4
1.3 研究困難點.....	4
1.4 研究範圍.....	5
1.5 研究限制.....	6
1.6 研究流程.....	6
第二章 文獻回顧.....	9
2.1 傳統統計型異常預測方法.....	9
2.1.1 ARIMA	9
2.1.2 STL	9
2.2 機器學習異常預測方法.....	10
2.2.1 k -means	10
2.2.2 DBSCAN	10
2.3 深度學習異常預測方法.....	11
2.3.1 GAN.....	11
2.3.3 CNN.....	12
2.4 集成式學習.....	13

2.5	人流分析相關研究.....	14
2.6	文獻回顧小結.....	15
第三章	研究方法.....	16
3.1	資料前處理.....	17
3.1.1	缺漏值處理.....	17
3.1.2	時間序列分割處理.....	17
3.1.3	資料正規化.....	18
3.1.4	時間序列切片處理.....	18
3.2	建立人流異常預測分析模型.....	19
3.2.1	應用生成對抗網路進行異常預測.....	19
3.2.2	應用集成式學習於異常預測結果.....	24
3.3	人流異常預測分析模型績效評估.....	24
第四章	實驗模擬.....	26
4.1	模擬資料集與模擬區域介紹.....	26
4.2	PNE-ADGAN 模型訓練結果.....	28
4.3	提前預測時間設定.....	30
4.4	預測結果驗證與分析.....	32
第五章	結論與未來展望.....	46
參考文獻		47

表目錄

表 1 GAN 相關研究.....	12
表 2 CNN 相關研究.....	13
表 3 集成式學習相關研究.....	14
表 4 P-GAN 與 N-GAN 預測異常邏輯.....	22
表 5 混淆矩陣.....	25
表 6 信義商圈訓練模型生成結果.....	29
表 7 忠孝商圈訓練模型生成結果.....	29
表 8 士林商圈訓練模型生成結果.....	29
表 9 信義商圈 PNE-ADGAN 預測績效比較表.....	31
表 10 士林商圈 PNE-ADGAN 預測績效比較表.....	31
表 11 忠孝商圈 PNE-ADGAN 預測績效比較表.....	31
表 12 信義商圈預測方法績效比較表.....	33
表 13 士林商圈預測方法績效比較表.....	33
表 14 忠孝商圈預測方法績效比較表.....	34

圖目錄

圖 1 短時間內流量增加示意圖.....	1
圖 2 人流變化三種特性示意圖.....	2
圖 3 臺北 101 大樓周圍區域人流變化視覺化圖.....	5
圖 4 研究流程圖.....	8
圖 5 GAN 圖片生成網路架構示意圖[43].....	12
圖 6 CNN 網路架構示意圖[25].....	13
圖 7 集成學習模型示意圖.....	14
圖 8 研究架構流程圖.....	16
圖 9 時間序列分割處理示意圖.....	17
圖 10 時間序列切片處理 (a)時間序列切片示意圖 (b)時空序列的輸入資料	18
圖 11 人流異常預測分析模型架構圖.....	19
圖 12 生成對抗網路架構.....	20
圖 13 PNE-ADGAN 模型架構概念圖	21
圖 14 GAN 預測模型架構圖	23
圖 15 人流資料空間範圍示意圖.....	26
圖 16 台北市及新北市主要商圈地理位置分析圖.....	27
圖 17 模擬區域在人流網格資料中的 3×3 網格範圍	27
圖 18 信義商圈預測結果之實際人流分析圖(預測異常，實際為異常).....	36
圖 19 士林商圈預測結果之實際人流分析圖(預測異常，實際為異常).....	37
圖 20 士林商圈右網格人流時間熱區圖 (a) 2018 年(b) 2019 年	37
圖 21 信義商圈預測結果之實際人流分析圖(預測正常，實際為異常).....	39
圖 22 信義商圈上方網格人流時間熱區圖 (a) 2018 年(b) 2019 年	39
圖 23 士林商圈預測結果之實際人流分析圖(預測正常，實際為異常).....	40
圖 24 忠孝商圈預測結果之實際人流分析圖(預測正常，實際為異常).....	41

圖 25 信義商圈預測結果之實際人流分析圖(預測異常，實際為正常).....	42
圖 26 信義商圈下方網格人流時間熱區圖(a) 2018 年(b) 2019 年	43
圖 27 士林商圈預測結果之實際人流分析圖(預測異常，實際為正常).....	43
圖 28 忠孝商圈預測結果之實際人流分析圖(預測異常，實際為正常).....	44
圖 29 忠孝商圈中心網格人流時間熱區圖 (a) 2018 年(b) 2019 年	44
圖 30 忠孝商圈左上方網格人流時間熱區圖 (a) 2018 年(b) 2019 年	45



第一章 緒論

1.1 研究背景與動機

隨著工業化、城市化、資訊化加速推進，大數據影響著幾乎所有現今社會的行業組織[40]。而對空間分析領域學者來說，目前最受矚目的是人流異常之預測。其中所謂的人流是指隨著時間在區域變化的人數，可用來衡量區域內人群密度並分析出人的活動及行為特徵。至於人流異常是指某地看似有規律變化的人流受到人類活動影響造成短時間內增加或降低的特殊情形，如圖一紅色區塊即是人流在短時間內大量增加的一個案例。此議題現階段會受到許多學者矚目，一方面是因為資通訊設備的進步，電信商與政府開始能定時追蹤並記錄每部手機的位置，讓人流分析變得比過往更加簡易;一方面也是若政府或商界能提早預測人流是否異常，則政府或商界能提早做出反應，並避免災害發生或因此獲益。舉例來說，百貨商場若能得知自身點位周遭人流即將大幅增加，則他們可以提早準備特賣會以吸引更多人購買。又或者在疫情期間，政府若能預先得知某個景點人流即將異常，則政府能先在該景點管控進場的人流量，並因此避免人群的群聚。整體而言，人流異常預測分析對於交通管理、災害管理、公共安全和資源分配等相關人流控管方面都顯得至關重要[61]。




圖 1 短時間內流量增加示意圖

人流異常預測分析一直以來都具挑戰性，主要是因為人流特性受到交通、事件、天氣等複雜因素影響，以圖 2 三種特性舉例說明(1)規律的人流變化：規律間僅有微幅差距，並不會對人流控管有極大影響，因此不會是人流異常預測分析目標，例如每日上課學生人數。(2)短時間活動造成的人流變化：這類型的影響時間相對較短，異常流量增




圖 2 人流變化三種特性示意圖

加幅度較大，如果能提前預測出來則對人流控管影響性較大，例如一年一度的跨年慶祝活動或是特定節日的大型遊行活動。(3)長時間活動造成的人流變化：人流變化數影響時間較長，此種類型跟規律型人流相似，受到地區活動影響產生微幅增加的人流，這種狀況對於人流控管也非常重要，例如百貨公司週年慶活動。

根據人流特性可以知道人流是一種有間隔時間的時間序列型態資料(Time-Series)，以時間先後順序進行排列所構成的一組連續性隨機變量，因此人流異常預測分析為時間序列異常預測(Time-Series Anomaly Detection)的範疇[15][59]。近年來，討論時間序列異常預測的文獻主要可分為三大類型(1)統計模型(2)機器學習(3)深度學習[1][52]。基於統計的異常預測是最早期且研究最多的方法，概念上是以閾值來盡量保留正常數據資訊從中觀察異常值，優點是即使沒有大量的歷史數據也可以快速分析結果，直觀、複雜性低、計算速度快，但是缺點是僅適用於低維小數據，對於高維大數據預測效率較低且準確率與穩定性不高。然而良好異常預測需要大量異常資料才能有效預測，舉例來說，Fanaee 等人[15]在 2016 年的跨類別的異常預測綜合研究中提到，時間序列實際分佈通常是未知的，如果使用統計方法會難以檢測高維數據分佈，看不到部分有意義的異常；Zimek 等人[11]在 2018 年的城市交通流量時序異常預測研究中提到，統計方法僅能針對極端值判斷異常值或離群值，且上下限值的界定過於偏差，難以捕捉大量異常點。綜上所述，統計方法不能很好地檢測人流異常，所以現階段統計方法大多僅用於輔助分析。

有別於傳統統計方法，若要有效地進行異常預測需要大數據分析，目前有許多學者使用人工智慧領域的機器學習(Machine Learning)與深度學習(Deep Learning)進行異常流量預測，其運算方式和人類學習方式十分相似，透過一組數據訓練它能像人類一樣具有學習能力，準確率通常比統計模型高。機器學習在異常預測領域中普遍使用監督式學習(Supervised learning)、非監督式學習(Unsupervised Learning)[18]。有部分學者使用監督式學習預測異常，此作法是透過標記資料使模型在標籤之間找到合適對映關係，也就是將異常與非異常流量分類後標記，標記資料就好比標準答案，目的是讓模型能夠準確偵測異常，此作法優點是準確率高，缺點是其非常依賴於標記數據的可用性，因此大多數研究結果都碰到類似的困難點，即是需要給予模型大量異常資料進行訓練才能使預測結果準確，而此困難點主要受限於異常流量資料通常屬於少量資料，因此當目標範圍擴大、資訊量增加，會更難去對資料標記出所有特徵，而只能對於特定異常情況預測[62]。舉例來說，Zhao 學者[17]在 2019 年基於航空數據進行航班延誤預測，提出隨機森林模型預測異常，但經常會出現過度擬合問題。Liu 學者[62]在 2020 年基於交通流量異常預測研究中提出異常標記可作為時間序列預測特徵，但僅限於該時間範圍資料。Hussain 等人[21]在 2017 年網路異常檢測研究指出現實中難以取得完整標記數據。綜上所述，監督式學習在人流異常預測分析中有值得改善的空間。

針對監督式學習預測異常的困難點，有部分學者提出透過非監督式學習在事先沒有訓練標籤的情況下自行學習異常資料的共同點，將流量分群以偵測出異常，典型的聚類演算法例如 k -means[57]。然而，儘管不需要預先標記數據即可對相似數據進行分組，卻碰到其他困難點，像是模型過度放大不重要特徵，導致無意義結果，舉例來說，Zhu 等人[7]在 2020 年網路異常偵測研究中指出非監督式雖然比統計及監督式有效且合理，但是僅能檢測出極具異常流量，且難以驗證；Kurnianingsih[36]指出透過非監督式結合部分標記數據才更能有效地檢測異常。綜上所述，異常資料少會導致非監督式學習模型無法學習異常特徵，無法達到符合現實情況的目的，對於人流異常預測分析有一定的困難性。

綜觀以前做人流異常偵測的方法，都有兩大缺點(1)異常資料少導致模型無法學習異常特徵。(2)非常依賴於標記數據的可用性。因此我們將在下一節提出相對應的修正方法。

1.2 研究目的

為了克服上述的問題，本論文提出三大概念來處理，包含以下三點：

- (1)建立深度學習生成對抗網路處理異常資料不足的問題。
- (2)採用半監督式學習方法解決過去方法依賴於標記數據可用性的問題。
- (3)採用集成學習方法作為本研究提出的方法需要的工具。

首先，概念一是在現實中沒有大量異常資料的條件下，建立生成對抗網路模型使其在訓練過程中學習資料特徵，用以判別異常及正常時空資料，而如此做完以後，我們就可以依照生成對抗網路生成資料的特性，避免過往問題的第一個缺點。

接著，概念二是採用機器學習中的半監督式學習方法(Semi-supervised learning)，在這邊指的半監督是因為本研究是兩個正反非監督模型互相監督去做，因此稱作半監督。此方法介於監督學習與非監督學習之間，指根據給定的正常訓練資料建立一個表示正常行為的模型，然後檢測由模型生成的測試實例的可能性以提升準確性及效能，在本研究中是以正常資料訓練生成對抗網路模型，使模型學習正常資料特徵，而如此做完以後，就可以利用生成對抗網路解決缺點二。

最後，概念三是改良模型架構，其概念為透過不同面向的模型預測結果，採用集成學習綜合不同面向模型預測結果，達到畫龍點睛的作用。透過上述概念，對於人流異常預測分析，就可避免過去異常預測方法中異常資料少及過於依賴標記數據的缺點。

1.3 研究困難點

本研究的主要目標是要進行人流異常預測與分析，而對於異常這個詞涵蓋範圍較為廣泛，在不同的情況下，對於不同議題、不同角色來說，異常的意義都有所不同，舉例像是對於醫療領域來說，病患的檢查報告中有不同於正常人體上應有的病灶，這對於醫生及病患來說即為一種異常；又或者對於商業店家來說，來客數的變化在特殊的時間點有非同於平常會有的人數變化，這樣子的情況對於商業店家來說即為一種異常。因此，在本研究中必須對於異常有所定義，避免後續研究過程中有因為定義不明而判斷錯誤的情況。而針對異常的定義，本研究基於人流分析的領域來說，所謂人流異常即為在某些




圖 3 臺北 101 大樓周圍區域人流變化視覺化圖

情況下，無法意料到的情況或是跟過去不太一樣的情形即為異常，舉例像是對於商業店家來說，固定會發生的事件也對於他們的立場來說是一種例行性異常事件，因為對於店家來說不同於正常狀態下會有的突增人流數量即為一種人流異常流量，如節慶或假日等。

另外對於研究方法的部分，困難點是如何使模型以每個網格各自的時間序列資料進行訓練，但同時還要能在時空變動的條件下，捕捉目標網格周圍區域的人流異常特徵。過往應用於時間序列異常預測模型的研究大多只探討純時間與純空間的異常預測。以純時間預測即是以單一時間序列進行預測，並未考慮到人類在空間上活動的其他影響因素[31]；以純空間預測缺點包括學習不重要特徵及無法給予即時預測[45]。舉例來說，圖 3 為臺北 101 周圍區域在下午兩點至五點有發生人流超過平均流量的情況(紫色區塊)，人群在這段時間從中間移動到左上方，發生事件為同志彩虹大遊行，代表當一個區域隨時間變化產生人流異常也會影響到空間範圍。因此當目標預測區域為臺北 101，那周圍網格也要作為影響特徵。綜上所述，為了使人流時間變化能加入周圍空間特徵，本研究將輸入資料從單一時間序列轉換為矩陣時空序列，達到時空特徵一併考量的目的。

1.4 研究範圍

為了使研究結果達到能夠說明人流異常情況，本研究將範圍限縮在都市，而臺灣人口密度位居第一的臺北市都會區具有城市代表性，可作為其他城市人流異常研究之參考。本研究針對臺北市人流異常情形進行探討。另外，考量到局部空間異常可預測性較高，若以全城市人流進行探討會因為影響因素過多導致預測效果與現實不相符或驗證困難，因此將模擬區域設定在信義商圈、忠孝商圈、士林商圈，針對三個區域分別進行探討。

1.5 研究限制

(1)研究資料的限制

礙於蒐集資料過程中的多種限制條件，人流資料集時間範圍僅有 2018 至 2019 年，且為了保護使用者個資，原始資料的人流分布是以網格化方式在空間上呈現，即隨著時間變化在網格內之人流數量，無法得知單一使用者隨著時間在空間的活動行為，且有簽署保密協定無法透露資料資訊。

(2)研究分析及結果

本研究分析所得之結果，雖然僅能說明臺北市部分區域人流異常之情況，不能直接地推論至其他國家或區域，但是可以提供其他區域作為參考。

(3)異常狀況定義

由於短時間內人流增加的情況最為影響人流控管問題，因此本研究只考慮數值大的異常狀況進行預測，至於人流減少的狀況，因為人流減少並不會造成人流管控上的困難，所以此處並不討論。

1.6 研究流程

本研究之流程如圖 4 所示，共包含七個階段，分別為定義研究問題、文獻探討與回顧、蒐集研究資料、資料整理與分析、建立研究方法、實驗模擬與分析、結論與探討，在前三個階段主要是在擬定研究主題，並且在過往研究中篩選出可靠的證據與論點，進行批判分析以發想創新研究。後四個階段是實驗階段，主要針對自行定義的研究問題及方法進行實驗分析，並將結果進行比較，探討研究問題在不同方法下產生的結果，給予研究結論及建議。本論文中各階段內容以下分別說明：

1. 定義研究問題

藉由探討人流異常之研究議題，針對過往研究人流異常預測分析不足之處，提出一種能應用至人流異常之預測方法，並針對城市部分小區域的人流進行異常預測，透過異常分析探討人流異常原因，以及對於時間及空間上的影響。

2. 文獻探討與回顧

針對人流異常預測分析之相關背景進行文獻回顧，並且針對時間序列流量異常偵測所使用的不同研究方法進行探討，在此階段會說明本研究使用到的深度學習預測模型。

3. 蒐集研究資料

本研究蒐集的目標資料集為臺北市的人流資料，資料內容為某電信業者提供之 2018 年至 2019 年每小時行動數據資料。

4. 資料整理與分析

首先對於資料進行格式清洗再加以視覺化，此流程目的為瞭解目標資料之電信資料之人群的分佈狀況，依據分佈狀況確定研究問題與研究方法。

5. 建立研究方法

本研究以資料分析流程訂定研究方法，首先將人流資料進行資料前處理，再將正常人流資料輸入至預測模型，透過模型中的判別器偵測是否異常，以集成式學習模型得到最終結果，最終進行異常分析。

6. 實驗模擬與分析

針對研究範圍內的區域進行測試，將真實資料輸入至本研究提出之預測模型，並將輸出結果進行量化驗證及質化驗證，探討不同區域在不同時間下的異常原因。

7. 結論與探討

根據研究結果與分析提出具體結論與未來相關研究建議。




圖 4 研究流程圖

第二章 文獻回顧

本章節將列舉出與本研究相關的重要研究，著重在時間序列異常預測之熱門方法。異常預測是一種在給定數據集中搜索與預期行為不匹配的方法，在機器學習和統計領域中有許多關於異常預測的研究，過去文獻中異常預測有分成基於統計、基於分類以及基於聚類的方法，以模型技術又分為統計型、機器學習、深度學習。以下分別以六個小節進行介紹，分別為傳統統計型異常預測方法、機器學習異常預測方法、深度學習異常預測方法、集成式學習、人流分析相關研究，最後為文獻回顧小結。

2.1 傳統統計型異常預測方法

2.1.1 ARIMA

ARIMA(Autoregressive Integrated Moving Average model)又稱為整合移動平均自回歸模型，是一種統計領域上較常見的時間序列預測及異常預測方法，由自迴歸模型(Autoregressive Models, AR)以及移動平均模型(Moving Average Models, MA)混合而成。此方法基於過去一段時間內曾經發生的事來推估當下即將發生的事，較適合短期變動較不劇烈的資料，若目前值和預測值產生超過臨界值時就代表異常發生。過去學者Bianco[5]於2001年提出基於ARIMA對季節性時間序列數據建模可以有效地檢測常態數據，但無法動態確定季節性數據中的異常。Arumugam[3]於2018年基於季節性ARIMA進行降雨數據異常值和缺漏值檢測。Tron[49]於2018年基於ARIMA對精神分裂症患者進行運動異常檢測；Rodrigo[41]使用ARIMA於傳感器故障偵測。

2.1.2 STL

STL(Seasonal and Trend decomposition using Loess)又稱為STL分解法，是常用於時間序列分解的工具，能夠將時間序列的趨勢(Trend)、季節性(Seasonality)、週期性(Cycles)等特性，拆解成季節性(Seasonal component)、趨勢性(Trend component)以及殘差(Remainder component)，STL是處理時間序列較為穩健且簡單的統計型方法，常被使用於檢測時間序列資料的異常值。Duan[13]於2017年使用STL對網路基地台使用流量進行異常數值檢測；Liu[60]於2019年使用STL對捷運進出站流量時間序列資料進行異常

數值檢測；Chhetri[9]為了預測 Amazon Elastic Compute Cloud 現貨價格，將現貨價格的歷史資料利用 STL 拆解以利後續預測；Duan[12]於 2017 年使用 STL 對基地台的使用流量進行異常數值檢測；Ho 與 Ting[19]研究中，使用了 STL 分解法對關於登革熱之時間序列資料進行異常值的檢測

過去使用統計型預測模型進行異常預測的研究指出在萃取時間特徵上不足，因此需要利用特徵工程將其它演算法預測結果當作是額外輔助特徵，此種方式是運用演算法對於處理不同資料所產生不同結果的差異性給予特徵，但是通常加入其它演算法預測的結果會造成誤差不穩定，使得預測穩定性下降。

2.2 機器學習異常預測方法

2.2.1 k -means

k -means(k -means clustering algorithm)是一種機器學習的非監督式聚類演算法，模型基本上是依照著物以類聚的方式在進行訓練，自行決定要分成 k 組，並隨機選 k 個點作為群集中心開始分群，算是速度快、效果不差的分群演算法，但是每一次分群結果不同，如果初始群中心設定不好可能導致不好的分群結果。Kurnianingsih[35]於 2018 年基於 k -means 檢測老年人異常生命體徵異常。Lee[19]於 2020 年應用 k -means 於行動網路資料進行交通流量異常預測。Wang[51]於 2020 年應用 k -means 對工業數據進行異常檢測與分析。Neethu[35]於 2019 年應用 k -means 進行溫室監測之異常檢測。

2.2.2 DBSCAN

DBSCAN(Density-Based Spatial Clustering of Applications with Noise)是一種常用於空間上的分群的機器學習基於密度聚類演算法，DBSCAN 能分辨局外點，與 k -means 一樣具有發現異常數據的能力。相對於 k -means，DBSCAN 的優點是不需要預先給定聚類數量，基本上只需要設定兩個參數就可以找出任何形狀的聚類，然而困難點是很難選擇適當的參數以獲得最佳的分群結果，且在高維度的資料中很難找出一個合適的密度。Kurnianingsih 等人[63]於 2012 年使用 DBSCAN 檢測溫度數據中的異常，並發現 DBSCAN 在發現異常方面比統計方法具有更多優勢，能夠自主發現異常，但是在資料處理上需要

耗費大量時間，且資料量大會造成訓練過程耗時。Sunjana 和 Zakiah[55]於 2020 年基於 DBSCAN 對市場交易數據進行異常檢測。Rukmi 等人[42]於 2019 年利用 DBSCAN 篩選股票交易資料中異常數值。Ijaz 等人[18]為了使預測高血壓模型能更準確，利用 DBSCAN 處理異常數據。Chen 等人[8]利用網際網路公司每日收集到的數據，快速準確地檢測出數據中的異常值以排除故障發生。Muhammad 等人[22]於 2020 年建立子宮頸癌預測模型，其中使用 DBSCAN 進行異常檢測。

2.3 深度學習異常預測方法

基於深度學習的異常預測方法主要是透過預測流量進行異常預測，找出和模型中正常行為狀態不一致的時間點。以下分別介紹適用於本研究人流時間序列異常預測的深度學習模型以及其相關文獻，依序為 GAN、CNN。

2.3.1 GAN

GAN(Generative Adversarial Network)又稱作生成對抗網路，是神經網絡結構的類型，同時具有監督式學習與非監督式學習能力，非監督式學習用於學習數據的高斯分佈，並從學到的分佈中提取樣本並生成新數據，GAN 能夠生成符合學習模型的新數據。GAN 起初在 2014 年由 Ian[16]提出來用於學習圖像潛在空間的方法，藉由強制生成假圖樣與真實圖片幾乎無法區分的條件下，進而生成相當逼真的合成圖像。其運作原理主要由兩個神經網路相互運作而成，分別是生成器神經網路與判別器神經網路，生成器神經網路為了能夠欺騙判別器神經網路，因此隨著模型訓練逐漸產生越來越逼真的圖像，致使產生與真實圖像無法區分的人工圖像，判別器會不斷地適應生成器逐漸改進的能力，直到判別器網路無法判定兩者的差別，如圖 5 所示為 GAN 圖片生成網路架構示意圖。近年來，GAN 的研究日益趨增，目前 GAN 架構已超過三百種，而現實中也有許多相關應用，從最早貓圖片自動產生器、虛擬人臉生成器、換臉特效，目前除了橫跨醫學界、時尚界等應用，也有部分應用於時間序列相關研究的案例，如下表 1 為 GAN 相關研究。




圖 5 GAN 圖片生成網路架構示意圖[43]

表 1 GAN 相關研究

作者	目標	方法
Zhou <i>et al.</i> (2020)[57]	基於 GAN 之網路流量預測	ARIMA、GAN、LSTM、MLP
Zhu <i>et al.</i> (2019)[58]	心肌梗塞異常及計程車流量異常預測	LSTM-GAN
Mogren <i>et al.</i> (2016)[33]	以古典音樂資料生成音樂	C-RNN-GAN
Lin <i>et al.</i> (2018)[29]	網路入侵異常檢測系統	IDSGAN
Leangarun <i>et al.</i> (2018)[26]	使用生成對抗網路對股價操縱檢測	GAN、LSTM

2.3.3 CNN

CNN(Convolutional neural network)又稱作卷積類神經網路，是一種監督式學習方法，其最重要的特色及能力就是對輸入資料進行特徵提取，能夠看到資料細節的能力。CNN 可以良好地進行特徵提取的原因是因為 CNN 相較於一般傳統深層類神經網路(Deep neural network, DNN)只是全連接層(Fully connected)的神經網路，還多增加卷積層(Convolutional layer)和池化層(Pooling)，這兩層改善了 DNN 只能輸入一維資料而忽略資料的形狀、喪失原本空間排列的缺點，使 CNN 不只能將資料進行運算，還能維持形狀保留空間上的資訊，且能避免參數大幅增加，圖 6 為 CNN 網路架構示意圖[25]。目前 CNN 在圖片辨識上擁有相似於人類的辨識能力甚至更好，因為 CNN 的卷積層跟池化層




圖 6 CNN 網路架構示意圖[25]

可以將特徵資訊丟到全連接層來進行分類判別，而除了廣泛地應用於影像辨識，另外還有應用在物體分割、文本分類、特徵選取、時間序列、異常檢測等領域，表 2 為 CNN 應用於異常預測之相關研究。

表 2 CNN 相關研究

作者	目標	方法
Kwon <i>et al.</i> (2018)[25]	網路流量異常預測	CNN、LSTM、VAE
Munir <i>et al.</i> (2018)[34]	多種時間序列異常預測	CNN、LSTM
Esan <i>et al.</i> (2020)[14]	檢測大學環境中異常活動	CNN-LSTM

2.4 集成式學習

集成式學習(Ensemble Learning)又稱為集成學習，是機器學習中的一種提升模型績效的方法，概念上是訓練多個學習者來解決同一問題，以達到更好預測性能的方法，也就是合併所有不同學習來源的答案得到最終且最佳的決定，通常可以保證準確且防止過擬合。集成學習模型通常比單一模型具有更高的準確性，可以用於回歸、分類、聚類或任何模型。對於時間序列預測問題，線性組合器適用於輸出實數值的模型，而實際的人流時間序列不是絕對線性或非線性的，因此單一模型並不是預測的最佳方法，本研究應用集成學習模型於人流異常預測分析模型，將異常預測結果進行集成。




圖 7 集成學習模型示意圖

表 3 集成式學習相關研究

作者	目標	方法
Bai <i>et al.</i> (2010)[4]	財務金融時間序列預測	指數平滑法、ARIMA
Lei <i>et al.</i> (2010)[27]	金融用戶信用預測	SVM、AdaBoost
Staudemeyer <i>et al.</i> (2019)[46]	網絡用戶行為分析	LSTM 與 CNN
Lu <i>et al.</i> (2017)[32]	復發性卵巢癌資料探勘	SVM 和隨機森林
Poh <i>et al.</i> (2018)[39]	多種時間序列集成模型	CNN、RNN

2.5 人流分析相關研究

由於人流資料是較為新穎且稀有的資料，過去大多使用交通流量代替人流資料進行人流異常預測分析。Ceapa[6]利用旅行數據中了解地鐵站的擁堵狀況，並於 2012 年的研究中指出人群擁擠是一種高度規律的現象，在短時間間隔內會出現大幅度的峰值，地理位置會是影響時空分析的重要指標。Jamil[23]於 2017 年使用自動 ARIMA 進行出租車乘客熱點預測，並指出以 GPS 技術獲得的數據具有高度可用性，可獲得大量時空資訊。Liu[30]於 2019 年的公車流量預測研究中指出將公車流量以矩陣型態進行獲取人群移動產生的時空資訊，表明利用深度學習進行交通流量預測有效地幫助城市發展。Stenneth[47]於 2011 年基於用戶移動設備上的 GPS 傳感器和基礎交通網路知識來推斷用戶交通方式的方法，並表明利用人流資訊可找出影響事件。

2.6 文獻回顧小結

本研究將過往文獻中關於時間序列異常預測的方法，分別以統計型、機器學習、深度學習三種類型在第二章進行介紹，其中從文獻中可以發現統計型的異常預測方法較適合少量資料的預測分析，且適合短時間預測的問題，對於本研究的主題來說並不是最佳的方法；另外，非監督式中聚類型的方法較適用於具有明顯異常特徵的流量去做預測分析，對於異常特徵的依賴性也比較高；在深度學習中，有許多研究表明對於大量資料有較好的預測能力，其中卷積網路具有強大特徵擷取能力，因此對於本研究的人流異常預測來說，具有時空特徵的人流是適合去使用卷積網路來擷取空間特徵，並且可以開發或應用在其他的模型中。而本研究也針對異常資料少及異常特徵難擷取的問題進行研究，發現過去研究大多表明透過 GAN 能夠在少資料的情況下，學習大量異常特徵生成大量符合現況的資料，除了生成假資料，還能夠將其網路中的判別網路運用於異常預測問題。因此對於人流異常預測問題，深度學習的 GAN、CNN 可能比統計型與機器學習聚類型更適合作為研究方法，且可以透過方法比較探討其之間的差異。此外，除了上述針對不同方法的應用外，本研究也發現在不同的問題中，集成式學習是一個能幫助預測的方法，在絕大多數的情況下是可以優化所有類型模型的結果，其方法的應用很廣，可以幫助模型的預測結果進行集成，不只是產生單一結果而已，因此也符合本研究在建立多面向的模型後，需要進行綜合預測的目的。綜上所述，本研究根據前人在時間序列流量預測及異常預測上的經驗，以 GAN、CNN 為基礎建立半監督式人流異常預測分析模型，並且利用集成式學習模型集成出 GAN 對未來時空序列判斷異常的結果。

第三章 研究方法

本研究提出一種基於集成式生成對抗網路之人流異常預測分析模型(PNE-ADGAN)，應用於臺北市區域人流時間序列異常預測。本章節將介紹本研究所提出之研究方法，方法架構主要分為兩個部分，分別為離線訓練(Offline Processing)與在線運作(Online Processing)。Offline Processing 為訓練模型的過程，主要分為兩階段，包含(1)資料前處理(2)建立模型。首先，階段一將目標資料進行缺漏值補值處理，接著將目標資料依序進行時間序列分割處理、資料正規化、時間序列切片處理。階段二是將處理後的正常時空序列輸入至正生成對抗網路與反生成對抗網路中進行訓練，並且透過兩種不同面向的判別器判別資料是否異常，再將異常預測結果輸入至集成學習模型中，最終完成模型訓練。Online Processing 為實際將測試資料輸入 CNN 預測未來時間點的時空序列數值，以訓練完成的 PNE-ADGAN 進行區域人流異常預測，最後進行人流異常預測分析。




圖 8 研究架構流程圖




圖 9 時間序列分割處理示意圖

3.1 資料前處理

訓練模型如果沒有乾淨、有質量、適用於模型的資料，預測效果也不會有所提高。本研究考慮到輸入資料的重要性，因此在建模前對原始資料進行清洗。此節分為四個部分進行說明，分別為缺漏值處理、時間序列分割處理、資料正規化、時間序列切片處理。

3.1.1 缺漏值處理

一般而言，大型資料集的收集過程會受到多種因素干擾，像是維護停機、網路設備不穩的問題，而這些問題會造成收集到有缺漏值的不完整資料集，像是 NaN 或 Null 或數值為 0 的狀況。本研究在資料觀察階段有發現遺漏值，而處理缺漏值通常有三種方式，分別為刪除、填補、不處理，考慮到研究問題及資料特性，若直接刪除缺失值資料會丟失大量資訊，因此本研究採用一種廣泛用於處理時間序列資料的線性插值法(Linear interpolation)，此方法是連接兩個已知量的直線來確定在之間的未知量的方法。

3.1.2 時間序列分割處理

本研究考慮到影響異常時間序列的事件多而複雜，若缺乏異常事件的典型時間序列就會難以覆蓋異常事件分佈，因此本研究提出了一種只輸入正常資料訓練模型來實現人流異常預測分析，不需要標記出異常時間序列進行訓練的半監督式學習方法。首先，要先使訓練資料為正常時間序列，從而實現對異常事件的有效檢測，因此本研究針對每個網格資料進行時間序列分割處理，實驗會以分割標準為 2σ 、 3σ 進行模擬，後續將稱之為 Threshold。如圖 9 所示，每格網格有不同的標準，進行分割處理後就可以得到正常資料，並將分割後產生的缺漏值以線性插值法進行補值。




圖 10 時間序列切片處理 (a)時間序列切片示意圖 (b)時空序列的輸入資料

3.1.3 資料正規化

資料正規化(Normalization)是為了讓每個特徵值做出相近程度的貢獻，並且排除資料間單位的不同或落差，可提升模型收斂速度及精準度，避免模型無法收斂的情況。本研究採用的方法是最小值最大值正規化(Min-Max Normalization)，在保持原始樣態下將資料等比例縮放入 $[-1, 1]$ 區間，轉換成純量並且不改變資料原本分佈。

3.1.4 時間序列切片處理

此步驟是將人流時序資料轉換為具有時間及空間特徵的資料，使訓練資料保有時空序列本質。首先，將每格大小為 500×500 公尺之網格資料，以指定中心點擴散網格範圍變成正方形二維矩陣，如圖 10(a)所示為時間序列切片處理示意圖，x 軸與 y 軸分別為空間上的經度及緯度，假設藍色圓點為預測目標網格之中心點，本研究會以 3×3 大小進行擴散後，使模擬範圍變成紅色框大小的 3×3 空間網格，以網格方式進行切片產生矩陣後再輸入至模型中。時間長度設定為輸入過去 3 小時的人流時空序列，而本研究會設定提前預測時間觀察模型能提前多久小時預測到異常，空間範圍設定為 3×3 ，輸入資料(input shape)為 $3 \times 3 \times 3$ ，如圖 10(b)所示，而提前預測時間會以實驗設定合適之數值。其中空間範圍的設定是考慮到資料本身的一格網格即 500×500 公尺的大小，若以 3×3 以上的網格會包含太多時空資訊，對於異常預測與分析來說會難以判別異常原因，影響結果的分析。最終得到的資料在 Threshold 為 2σ 時，異常數量是 831，正常數量是 7926，在 Threshold 為 3σ 時，異常數量是 266，正常數量是 8491，若提前預測時間增加 1 小時則正常數量就會減少 1 個。




圖 11 人流異常預測分析模型架構圖

3.2 建立人流異常預測分析模型

本研究建立人流異常預測分析模型為以 CNN 為基礎架構去預測未來時間點的時空序列數值，接著再透過訓練好的 PNE-ADGAN 進行人流異常預測(圖 11)。本研究將 PNE-ADGAN 的建模方式主要分成兩階段進行介紹，依序為(1)應用生成對抗網路進行異常預測 (2)應用集成式學習於異常預測結果。

3.2.1 應用生成對抗網路進行異常預測

如同第一章緒論所說，一般而言異常資料會在整體資料中占少數比例，當比例懸殊時，模型常會把所有資料都預測為資料多的類別來達到高準確率，無法檢測出希望被檢測出的資料，通常是運用統計學的 oversampling、downsampling 等方法去處理不平衡資料的狀況，或是透過調整 class weights 去強迫模型判對資料量少的類別，但這不一定適用於每一個問題，有些情況用上述的方法會導致 overfitting，因此這時候就可以用異常檢測來代替分類。異常檢測的概念就是只使用資料多的那個類別的資料作為正常資料來訓練模型，在預測時就可以判斷資料是否正常。因此對於本研究要預測的人流異常來說，在僅有的訓練資料上，人流異常資料在其中比例相對較少，針對這個情況本研究利用 GAN 可以生成資料的特性，解決異常資料不足的問題，並且針對 GAN 的運算架構獲取其中一個架構的輸出機率，並且透過模擬結果發現可以調整方法，將原本只有一個 GAN 去做生成及判別的方法，調整成建立兩種不同面向的 GAN，而結果的呈現會在實驗模擬章節進行介紹。本節將分成兩個部分進行介紹(1)介紹生成對抗網路(GAN)如何訓練(2)本研究如何應用 GAN 改良為 PNE-ADGAN 進行異常預測。




圖 12 生成對抗網路架構

第一部分介紹 GAN 如何訓練，如圖 12 所示為生成對抗網路的基本架構，可以看到 GAN 有兩個關鍵的結構分別是生成器 (Generator Network) 和判別器 (Discriminator Network)，圖中分別顯示為大寫 G (Generator) 及大寫 D (Discriminator)，也就是 GAN 運作的必要網路模型。其中，生成器的工作是為了生成接近真實資料的虛假資料，判別器的工作是為了分辨資料是真實資料 (Real data) 還是來自生成器生成的虛假資料。GAN 的運作方式主要是透過生成器生成資料給判別器，生成器目的是希望判別器判不出來生成資料是假的。而判別器目的是不斷地判別資料是真實的還是判別器生成的假數據，透過兩者相互對抗就可獲得可生成真實資料的生成器及可判別是否為真實資料的判別器。

GAN 運作方式以擬人化的方式來說，假設城市治安混亂，很快地城市就會出現無數的小偷。在這些小偷中有的是技術高超的小偷，有的是毫無技術可言的小偷，假設生成器為小偷，判別器為警察，隨著警察開始下令抓小偷，小偷就不斷地以適者生存、不適者淘汰的方式提高自身水平來對抗警察以防被發現，警察也不斷提升自己的判斷能力去抓小偷，漸漸地相互對抗後，警察最終能判別出來誰是小偷，且一旦有新的可疑的小偷，警察就能馬上判別出來，而小偷也漸漸地表現得跟普通群眾一模一樣。因此最終，得到最強小偷和最強的警察。

透過 GAN 的訓練方式可以從中得知其有生成資料及判別真偽的能力，因此對於本研究的人流異常預測來說可運用其特性來改良模型，以進行後續的分析。




圖 13 PNE-ADGAN 模型架構概念圖

第二部分介紹本研究如何改良 GAN 進行人流異常預測分析，如圖 13 所示為 PNE-ADGAN 模型架構概念圖，本研究設計兩個面向的生成對抗網路，將之命名為正生成對抗網路(Positive Generative adversarial networks, P-GAN)及反生成對抗網路(Negative Generative adversarial networks, N-GAN)，也就是 PNE-ADGAN 當中的 P 與 N 代表的意思，而架構概念圖中可以看到本研究將 P-GAN 生成器稱之正生成器(Positive Generator, G_p)，判別器稱之正判別器(Positive Discriminator, D_p)。N-GAN 生成器稱之反生成器(Negative Generator, G_n)，判別器稱之反判別器(Negative Discriminator, D_n)。另外，在模型名稱中的 E 代表集成學習模型(Ensemble learning)的縮寫，AD 代表異常偵測(Anomaly Detection)的縮寫，而模型主要架構是以 GAN 去改良。綜上所述，即為 PNE-ADGAN 模型架構的簡寫名稱介紹以及模型架構的內容基本介紹。

P-GAN 運作方式與第一部分介紹的一般 GAN 運作方式相同，本研究以 2018 年人流資料作為訓練集，將目標網格的過去正常時空序列矩陣輸入至 P-GAN 的判別器中，藉由 G_p 以及 D_p 交互作用學習正常資料分布，直到產生合理的正常資料即模型訓練完成。接著，N-GAN 的運作方式是先以 P-GAN 訓練好的權重作為開端，並將 D_n 的判別目標改成與 D_p 判別目標為相反狀態，直到產生合理異常資料即訓練完成。訓練好的 P-GAN 與 N-GAN 已完整學習到訓練資料的特徵，則可輸入測試資料至兩者結合的 GAN 進行異常判斷。本研究異常判斷方式是將 2019 年人流資料作為測試資料，當測試資料的分布與

生成資料的分布不相似，則判別器會判別為假資料(Fake)，也就是測試資料為異常；當測試資料的分布與生成資料的分布相似，則判別器會判別為真資料(Real)，即測試資料為正常。反之，即為 D_n 的判斷模式。如表 4 所示為本研究設定 P-GAN、N-GAN 各自對於異常的判斷方式，也就是 P-GAN 跟 N-GAN 在不同的判別面向與邏輯下產生不同的預測異常機率。在輸入資料都是正常資料的情況下，P-GAN 的判別模型會去判斷生成出來的資料是否為相似分布，如果是相似即為正常，在模型中數值會越接近 1；反之，如果判斷生成出來的資料是不相似的即為異常，在模型中數值會越接近 0。而在輸入資料都是正常資料的情況下，N-GAN 的判別模型會去判斷生成出來的資料是否為相似分布，如果是相似即為異常，在模型中數值會越接近 0；反之，如果判斷生成出來的資料是不相似的即為正常，在模型中數值會越接近 1。

表 4 P-GAN 與 N-GAN 預測異常邏輯

從正常資料中判斷是否異常	P-GAN	N-GAN
相似分布	正常(1)	異常(0)
不相似分布	異常(0)	正常(1)

接著介紹 P-GAN 與 N-GAN 的演算法，首先先介紹 P-GAN 的部分。P-GAN 與一般 GAN 的訓練演算法相同，生成器和判別器均可以使用深度學習模型。其優化過程的訓練準則為極小極大博弈問題(Minimax game)，一般 GAN 主要流程為兩個階段的循環過程，以下說明過程。生成器為(G)、判別器為(D)，階段一，訓練判別器，判別器主要透過公式(1)來做訓練， $D(X)$ 為輸入真實數據(Real data)時的輸出值， $D(G(Z))$ 為輸入生成數據時的輸出值，即判別器判斷生成器生成的是否為真實的機率，在判別器中期望 $D(G(Z))$ 為越小，代表判別器越能判斷出真假。階段二，固定判別器，訓練生成器，主要透過公式(3)進行訓練，公式(3)為結合判別器公式(1)與生成器公式(2)得出，將隨機變量(Z)輸入至模型中，期望生成樣本的預測結果 $D(G(Z))$ 越大越好且 $1-D(G(Z))$ 越小越好，代表生成器生的越真實，最後再透過循環訓練將生成器訓練為能生成出的數據直到判別器無法判別出真假。反之，N-GAN 與 P-GAN 的訓練演算法差別在於，兩者判斷方式不同，在 N-




圖 14 GAN 預測模型架構圖

GAN 中，透過改變判別器判斷方式使生成器生成與 P-GAN 生成的正常資料不同，如公式(4)，本研究改良 P-GAN 的判斷方式作為 N-GAN 的判斷，目的是希望不只利用 P-GAN 的判別器作為異常判斷工具，而是以這兩者不同面向的模型共同作為預測模型架構，希望達到畫龍點睛的作用。

$$\max_D V(D, G) = E_{x \sim p(x)} (\ln D(X)) + E_{z \sim p(z)} (\ln(1 - D(G(Z)))) \quad (1)$$

$$\min_G V(D, G) = E_{z \sim p(z)} (\ln(1 - D(G(Z)))) \quad (2)$$

$$\min_G \max_D V(D, G) = E_{x \sim p(x)} (\ln D(X)) + E_{z \sim p(z)} (\ln(1 - D(G(Z)))) \quad (3)$$

$$\min_G V(D, G) = E_{z \sim p(z)} (\ln(D(G(Z)))) \quad (4)$$

本研究創建的正生成對抗網路與反生成對抗網路模型架構如圖 14 所示，判別器與生成器皆以 CNN 作為基礎架構，以下分別介紹。首先介紹判別器的模型架構及運算方式，包含輸入層、卷積層、攤平層、全連接層。輸入層的輸入尺寸(Input_shape)以模擬

區域的列數(Rows) $\times$ 欄數(Cols) $\times$ 通道數(Channels)設定為 $3 \times 3 \times 1$ ，輸出為 32 維，第一層添加從輸入資料提取特徵的二維卷積層，卷積核(Kernel)大小設 2×2 ，激活函數(Activation)設為 tanh 符合資料正規化的範圍，透過濾波器(Filter)來學習圖像特徵，考慮到卷積運算後輸出矩陣會縮小，本研究利用補充像素(Padding)對輸入外圍補充像素點，使用後 feature map 將會與計算前大小一致。卷積層後接著為上取樣層(Upsampling)，上取樣層會接收來自卷積層萃取出來的矩陣將圖像放大。上取樣層結束後為攤平層(Flatten)把多維輸入一維化，假設前一層輸出的 feature map 為 3×3 矩陣，則攤平過後會變成 1×9 ，那全連接層的神經元顆數就為 9，即前一層攤平後數量。最後為全連接層，Activation 採用 sigmoid 函數對一個節點進行二值分類，輸出 1 或 0 的結果。接著介紹生成器的模型架構及運算方式，生成器的 Input 是隨機產生的雜訊，用這個雜訊來產生模擬資料，主要架構包含全連接層、二維卷積層、批量標準化層(BatchNormalization)。

3.2.2 應用集成式學習於異常預測結果

本節介紹使用集成式學習原因是源於本研究建立的模型架構。本研究只透過正常時空序列訓練生成器與判別器，模型只會學習過去正常資料分布，可是每年異常特徵不同，如果只生成正常時空序列，會發生只要預測資料跟過去正常資料分布容易不相似，就會造成實際異常狀況與預測異常狀況結果不理想的情形。因此，本研究使用兩個面向功用不同的 P-GAN 與 N-GAN，每一次預測會產生兩個異常機率，假設模型進行 11 次預測，那每小時會有 11 個預測異常的機率，將之一起輸入至集成學習模型來優化預測結果。綜上所述，本研究透過 P-GAN 與 N-GAN 獲得許多判斷結果，再將結果輸入至集成學習模型進行二次預測，最後得到未來是否異常的結果，因此模型命名為 PNE-ADGAN。

3.3 人流異常預測分析模型績效評估

在機器學習領域和統計分類問題中，混淆矩陣(Confusion matrix)是一種常用的可視化工具，也稱誤差矩陣。這個矩陣可以方便地看出模型是否混淆了不同的類別，因此判定一個分類模型表現可以參考混淆矩陣的各項指標，包含 True Positive(TP)、True Negative(TN)、False Positive(FP)、False Negative(FN)，其中 TP 與 TN 為分類正確數量，

TP 為正確預測成功的正樣本， TN 為正確預測成功的負樣本，這兩個指標要越大越好； FP 與 FN 為分類錯誤數量， FP 為錯誤預測成正樣本， FN 為錯誤預測成負樣本，這兩個指標要越小越好。本研究考慮到只使用 TP 、 TN 、 FP 、 FN 不好看出模型的好壞，所以會透過混淆矩陣中的四個數值計算出正確率(*Accuracy*)、召回率(*Recall*,也稱為靈敏度(*Sensitivity*))、精確率(*Precision*)及 F_1 -score 這些指標來評估模型的好壞，作為人流異常預測分析模型績效評估指標，分別依序為式(5)(6)(7)(8)。*Accuracy* 指在預測為正樣本中，多少為正樣本，即預測正確的比率，當訓練資料的目標變數不平衡時，就不能只使用 *Accuracy* 衡量模型的效能。*Recall* 指在所有正樣本中，能預測正樣本的比例。*Precision* 指分類為正確中，占有所有被分類為正確的比例。*Precision* 和 *Recall* 都不去考慮 TN ，因為通常 TN 會是答對的 Null Hypothesis，例如在信用卡盜刷的例子，機器人認為正常的刷卡紀錄，其實也正是正常的。實際是正向的結果通常是比負向少的，理所當然預測正向的結果也要比負向少，所以 TN 通常是量最多的，因此本研究在實驗模擬階段主要會參考 *Precision* 和 *Recall* 進行績效評估。 F_1 -score 即 *Precision* 和 *Recall* 的調和平均數(Harmonic mean)，其中 1 代表參數 $\alpha=1$ ，即認為 *Precision* 和 *Recall* 一樣重要，一般最常見即 F_1 -score，也稱作 F -score。表 5 即二元混淆矩陣。

表 5 混淆矩陣

真實資料 預測結果		Real	
		Positive	Negative
Prediction	Positive	True Positive (TP)	False Positive (FP)
	Negative	False Negative (FN)	True Negative (TN)

$$Accuracy = \frac{TP + TN}{(TP + TN + FP + FN)} \quad (5)$$

$$recall = \frac{TP}{TP + FN} \quad (6)$$

$$precision = \frac{TP}{TP + FP} \quad (7)$$

$$F_1 - score = \frac{2 \times precision \times recall}{(precision + recall)} \quad (8)$$

第四章 實驗模擬

本章節將介紹實驗模擬結果與分析，使用了真實人流資料集來驗證本研究提出方法之有效性。內容共包含四個部分，分別依序為模擬資料集與模擬區域介紹、PNE-ADGAN 模型訓練結果、提前預測時間設定、預測結果驗證與分析。本研究使用 Python 程式語言完成實驗模擬的部分，並操作在 Intel i7-8700K 3.70GHz 的 CPU、Nvidia GTX 1080ti 的 GPU、搭配 64GB 記憶體以及 Windows 10 的作業軟體來完成。

4.1 模擬資料集與模擬區域介紹

本研究以人流異常預測分析為目標，選用模擬資料集為台灣某電信商提供之人流數據資料，資料類型為行動裝置使用數據人流資料，資料來源單位為了保護行動裝置使用者的個資隱私，因此資料空間範圍是以網格化方式呈現人流分佈，網格邊長為 500 公尺，每個網格都只有一個中心點地理座標(WGS84)，圖 15 為人流資料空間範圍示意圖，圖中顯示灰色的網格代表有人流資料。時間範圍為 2018 年至 2019 年每小時資料，兩年資料集各自獨立，資料內容及格式不相同。而基於資料來源以簽署保密協定，因此資料內容僅敘述於此，將不多贅述詳細資訊。




圖 15 人流資料空間範圍示意圖




圖 16 台北市及新北市主要商圈地理位置分析圖



(a) 模擬區域在人流網絡資料中的 3x3 網格範圍



(b) 三個模擬區域在 google map 上包含的空間資訊-主要地標

圖 17 模擬區域在人流網絡資料中的 3x3 網格範圍

為了驗證本論文研究方法之有效性，並且達到本研究進行人流異常預測分析可探討不同區域異常原因之目的，本研究選擇三個同屬性區域作為模擬區域，而選擇區域主要考慮到三個條件，分別為區域屬性的選擇、區域資料完整性，及區域在空間上的範圍限制。基於研究限制，考慮到商圈區域事件較多，因此將模擬範圍設定在具有商圈屬性之地區。考慮到空間上的影響因素，例如：西門商圈台北商圈及光華商圈太過於鄰近甚至有明顯重疊的部分，因此本研究選擇信義商圈、忠孝商圈、士林商圈，三區域皆屬於商圈代表區域，且所選區域在模擬資料中皆為完整網格，因此選擇作為實驗模擬之研究範圍。如圖 16 所示為台北市及新北市主要商圈地理位置分析圖，由圖中可觀察到大台北地區主要商圈大致可分為 10 個，圖上所圈選的主要商圈範圍為約略大小，並非實際商圈範圍。實驗模擬範圍選擇為圖中紅色範圍，其中信義商圈與忠孝商圈距離近但是範圍無重疊。圖 17 為模擬區域在人流網格資料中的 3x3 網格範圍，由左至右依序為信義商圈、忠孝商圈及士林商圈，其中信義商圈包含的主要地標有市政府站、台北 101/世貿站、世貿中心、市政府、101 大樓、新光三越、信義威秀商圈、ATT4FUN 百貨、信義區運動中心。忠孝商圈主要包含的地標有忠孝復興站、忠孝敦化站、東區巷弄商圈、東區地下街商圈、遠東 SOGO、仁愛醫院、中山醫院、國泰醫院。士林商圈主要包含的地標有士林站、劍潭站、士林夜市商圈、兒童新樂園、科教館、士林高商、陽明高中、百齡高中。綜上所述，本研究選擇的三個模擬區域的空間特徵皆符合都市中的商圈屬性，皆有地狹人稠的特性，因此適合本研究進行人流異常預測分析與分析。

4.2 PNE-ADGAN 模型訓練結果

本節介紹本研究提出的 PNE-ADGAN 異常預測模型以模擬區域進行訓練的結果。本研究以 2018 年人流資料作為訓練資料，以 2019 年人流資料作為測試資料，訓練好的 PNE-ADGAN 會完整學習到 2018 年訓練資料的時空序列分布及資料特徵，則可輸入測試資料至 PNE-ADGAN 進行異常判斷。PNE-ADGAN 模型訓練結果如表 6 至表 8 所示，分別為信義商圈訓練模型生成結果、忠孝商圈訓練模型生成結果、士林商圈訓練模型生成結果。

表 6 信義商圈訓練模型生成結果




表 7 忠孝商圈訓練模型生成結果





表 8 士林商圈訓練模型生成結果



PNE-ADGAN 訓練方式是將模擬區域之目標預測網格的過去正常時空序列矩陣輸入至 P-GAN 的 D_p ，藉由 G_p 及 D_p 交互作用學習正常資料分布，直到產生合理的正常資料即模型訓練完成。接著，N-GAN 的訓練過程是先將 P-GAN 訓練好的權重作為訓練開端，並將 D_n 的判別目標 改成與 D_p 相反，則可以產生異常資料。PNE-ADGAN 模型訓練結果如表 6 至表 8 所示，分別依序為模擬區域信義商圈、忠孝商圈、士林商圈在 Threshold 為 2σ 時，各自訓練模型下的資料生成情形，並且以空間網格矩陣視覺化方式呈現，幫助查看訓練結果的好壞，其中矩陣上的顏色由藍至紅代表著人流由高到低的數量變化，如藍色越深代表該網格的人流數量越多，紅色越深代表該網格人流數量越少。每個區域各自的表中皆包含 P-GAN 及 N-GAN 隨著 epoch 數量增加的生成資料，本研究針對不同區域進行訓練後得出其最佳訓練的成果，分別以其合適的 epoch 數量呈現，而 PNE-ADGAN 每一次訓練皆產生不同面向的結果，為達到預測人流異常目的，本研究將 10 種模型判斷結果進行集成式學習，表 6 至表 8 為截取其中一次的訓練結果，每一種模型的訓練狀況皆如前述所說以網格矩陣進行可視化分析。

從各商圈區域各自訓練模型的生成結果可以發現隨著 epoch 數量增加，P-GAN 生成器(G_p)生成資料與真實資料(Real data)越來越相似，在 epoch 到達 30 至 60 以內即可達到生成正常資料的目標，且可明顯看出其生成資料有學習到不同區域的人流高點及低點特徵。從各商圈 N-GAN 生成結果也可以看到生成器(G_n)隨著 epoch 增加至適當數量後，可生成與 Real data 不相似資料。綜上所述，從訓練結果可以得知 GAN 在不同面向的判斷邏輯下，透過 P-GAN 訓練好的權重學習正常資料特徵，以 N-GAN 模型訓練過程中學習異常特徵，並生成與正常資料不相似的異常人流時空資料。

4.3 提前預測時間設定

考慮到異常預測的目標是越早預測越好，因此本研究在此節針對 PNE-ADGAN 模型在 CNN 不同提前預測時間(long)的條件下進行實驗模擬分析其預測效果。訓練參數設置是以過去時間長度為 3 小時資料的條件下，預測下 1 小時人流異常，舉例說明：當 long 為 1 時，模型是以 $t-2$ 、 $t-1$ 、 t 這三個時間點的人流數值去預測下一個時間點 $t+1$ 的

人流異常情形；當 long 為 2 時，模型是以 $t-3$ 、 $t-2$ 、 $t-1$ 這三個時間點的人流數值去預測下一個時間點 $t+1$ 的人流異常情形，而全年時間序列的預測皆以此規則類推。

PNE-ADGAN 模型另外一個參數設置是模型建立的數量，因為每一次的建立的模型都可以產生不一樣的預測機率，因此建立多個模型作後續的預測，而實驗模擬的部分是以 10 個模型數量來將多種模型結果進行集成學習，也就是將多種預測結果做二次預測。

本研究將不同模擬區域在不同參數下的結果呈現於表 9 至表 11，分別為模擬區域信義商圈、忠孝商圈、士林商圈在兩種不同 Threshold 標準時，long 在 1 至 5 小時的預測績效比較表。

表 9 信義商圈 PNE-ADGAN 預測績效比較表

Threshold \ long	Accuracy		F-score		Recall		Precision	
	2σ	3σ	2σ	3σ	2σ	3σ	2σ	3σ
1	0.95	0.98	0.65	0.51	0.51	0.38	0.88	0.80
2	0.94	0.98	0.60	0.50	0.49	0.37	0.79	0.77
3	0.93	0.97	0.49	0.33	0.35	0.22	0.79	0.71
4	0.92	0.97	0.53	0.34	0.49	0.23	0.58	0.61
5	0.92	0.97	0.42	0.26	0.31	0.16	0.66	0.67

表 10 士林商圈 PNE-ADGAN 預測績效比較表

Threshold \ long	Accuracy		F-score		Recall		Precision	
	2σ	3σ	2σ	3σ	2σ	3σ	2σ	3σ
1	0.96	0.99	0.51	0.52	0.37	0.51	0.81	0.53
2	0.95	0.99	0.39	0.43	0.26	0.35	0.75	0.57
3	0.94	0.99	0.38	0.30	0.30	0.19	0.54	0.70
4	0.95	0.99	0.35	0.37	0.23	0.24	0.72	0.75
5	0.95	0.99	0.35	0.24	0.24	0.14	0.63	1

表 11 忠孝商圈 PNE-ADGAN 預測績效比較表

Threshold= 2σ	Accuracy	F-score	Recall	Precision
1	0.37	0.23	0.87	0.37
2	0.37	0.29	0.49	0.37
3	0.24	0.15	0.57	0.24
4	0.25	0.16	0.62	0.25
5	0.26	0.16	0.71	0.26

Threshold 為 2σ 時，代表模型是以兩倍標準差下的正常資料進行訓練，Threshold 為 3σ 時代表模型是以三倍標準差下的正常資料進行訓練。由三個區域各自的預測績效比較表可以看到，異常判斷結果 Accuracy 皆在 0.90 以上，且在提前預測時間為 1 至 2 小時的模型績效較佳。以信義商圈來說，在 Threshold 為 2σ 時， F_1 -score 最高為 0.65 其次為 0.60，而 Precision 最高為 0.88 其次為 0.79，而 long 為 4 時雖然 Recall 可以達到一定的標準，但相對其他 long 來說 Precision 是整體較低的，而在 Threshold 為 3σ 時的預測結果與在 Threshold 為 2σ 時一樣是 long 為 1 至 2 時為此區域最適提前預測時間，因此在綜觀考量下，此區域的預測模型最適提前預測時間為 1 至 2 小時。以士林商圈來說，在 Threshold 為 2σ 時，以 F_1 -score 最高可到達 0.51，Precision 最高可到達 0.81，而在不同 Threshold 之下的 long 在 1 時的預測結果相對其他預測結果較佳，因此針對此區域的最適提前時間為一小時。另外，由於忠孝商圈在 Threshold 為 3σ 時是測試資料沒有異常，因此針對此區域僅呈現 Threshold 為 2σ 時的情況，從預測結果可以看到此區域 Recall 值最高可達 0.87，最適提前預測時間為 1 小時，但是相較其他兩個模擬區域較無法精確預測異常，因此後續會針對模型預測的結果進行討論與分析。綜上所述，三個區域隨著提前預測時間的增加，預測績效會逐漸降低，而不同區域的最適提前預測有所不同，以模擬區域來說，信義商圈模型的最適提前預測時間為 1 至 2 小時，士林商圈及忠孝模型的最適提前預測時間為 1 小時，可以推出這些區域在 1~2 小時前會有異常的跡象，因此模在各區域可針對其提前預測時間進行人流異常預測分析。

4.4 預測結果驗證與分析

本節以量化與質化的方式對於 PNE-ADGAN 人流異常預測分析結果進行驗證與分析，討論本研究提出的方法對於人流異常預測分析的合理性，並且透過異常分析探討人流異常事件及對於時間及空間上的影響。以下分成兩個部分進行介紹(1)針對量化分析的部分，將本研究提出的半監督式學習 PNE-ADGAN 與其他兩個監督式學習異常預測方法進行比較分析。(2)針對質化分析的部分，討論三個模擬區域預測結果為異常的原因。

首先介紹量化分析的部分，本研究在實驗模擬採用了三個方法進行比較，分別是

PNE-ADGAN、SVM、Random Forest，而三個方法使用的訓練資料都是 2018 年的人流資料。其中，PNE-ADGAN 的訓練資料有兩個階段，第一階段中 P-GAN 及 N-GAN 的訓練資料只有正常的資料。第二階段中，透過輸入正常與異常的資料至 P-GAN 及 N-GAN 的判別器，判別後產生的多個判別機率即為集成模型的訓練資料。

實驗組為半監督式學習 PNE-ADGAN 的預測結果，訓練資料為集成模型的輸入資料。對照組為 SVM 與 Random Forest 兩個監督式學習方法的預測結果，訓練資料為原始資料。由 4.3 節的結果中可以得知三個模擬區域各自應要設定的提前預測時間，因此在這部份的分析即以該設定之提前預測時間作分析，如表 12 至表 14 即為模擬區域信義商圈、士林商圈、忠孝商圈分別對照其提前預測時間進行人流異常預測分析的方法績效比較表，信義商圈設定為提前 2 小時預測，士林商圈及忠孝商圈設定為提前 1 小時預測。

表 12 信義商圈預測方法績效比較表

long=2		Accuracy		F-score		Recall		Precision	
Method	Threshold	2 σ	3 σ	2 σ	3 σ	2 σ	3 σ	2 σ	3 σ
SVM		0.92	0.97	0.33	0.33	0.20	0.21	0.96	0.80
Random Forest		0.95	0.98	0.65	0.46	0.54	0.32	0.82	0.82
PNE-ADGAN		0.94	0.98	0.60	0.50	0.49	0.37	0.79	0.77

表 13 士林商圈預測方法績效比較表

long=1		Accuracy		F-score		Recall		Precision	
Method	Threshold	2 σ	3 σ	2 σ	3 σ	2 σ	3 σ	2 σ	3 σ
SVM		0.95	1	0.34	0.27	0.21	0.16	0.91	0.86
Random Forest		0.96	1	0.48	0.41	0.33	0.27	0.88	0.91
PNE-ADGAN		0.96	0.96	0.51	0.52	0.37	0.53	0.81	0.53

表 14 忠孝商圈預測方法績效比較表

Threshold=2 σ /long=1	Accuracy	F-score	Recall	Precision
SVM	0.98	0.30	0.19	0.83
Random Forest	0.98	0.38	0.25	0.78
PNE-ADGAN	0.98	0.38	0.24	0.88

透過三個模擬區域的方法績效比較表可以看到，當 Threshold 為 3σ 時，信義商圈 F_1 -score 以 PNE-ADGAN 最高為 0.50，而 SVM 及 Random Forest 分別為 0.33 及 0.46，Recall 以 PNE-ADGAN 最高為 0.37，而 SVM 及 Random Forest 分別為 0.21 及 0.32。士林商圈 F_1 -score 以 PNE-ADGAN 最高為 0.52，而 SVM 及 Random Forest 分別為 0.27 及 0.41，Recall 以 PNE-ADGAN 最高為 0.53，而 SVM 及 Random Forest 分別為 0.16 及 0.27。整體而言，當 Threshold 為 3σ 時，PNE-ADGAN 表現較佳，優於監督式學習方法，模型績效由高至低依序為 PNE-ADGAN、Random Forest、SVM。當 Threshold 為 2σ 時，模型績效以 SVM 為最低，而在信義商圈及忠孝商圈的 PNE-ADGAN 與 Random Forest 模型績效差距不大，但是 PNE-ADGAN 略低於監督式學習方法，本研究針對這部分量化結果進行探討來推測模型的判別能力。而在 Threshold 為 2σ 時，Random forest 與 PNE-ADGAN 表現差異不大，監督式學習方法雖然在 Threshold 為 2σ 時表現較佳，但是可以發現監督式學習方法對於 Threshold 為 3σ 時的高異常流量較無法進行異常判別，因為其主要透過閾值訓練模型，造成模型對於異常的閾值界定依賴性很高，如果閾值設定的不符合測試資料集的異常標準，則無法對未來異常進行準確預測。當 Threshold 為 3σ 時，半監督式學習 PNE-ADGAN 方法的預測結果相較於監督式學習方法有效，主要原因在於模型的優勢在於異常判別模型並非依靠異常閾值界定異常資料，因此 PNE-ADGAN 能夠對於高異常流量狀況進行異常判別。

綜上量化分析的結果，在人流異常預測分析困難的情況下，若使用監督式學習方法，則在兩倍標準差資料多時，監督式好訓練，在三倍標準差資料少時，監督式不好訓練，預測時會無法對於高異常流量進行準確預測。而半監督式學習 PNE-ADGAN 優勢是在

未知異常下，PNE-ADGAN 能夠補足監督式學習的問題，能夠對於高異常流量進行預測，有利於人流控管。而對於 Random forest 的結果，也可以發現其績效與 PNE-ADGAN 的結果差不多，因此若要提升績效未來也可以透過 GAN 生成出來的資料再拿出來訓練 Random forest，但是要以時間序列去生成，難易度及驗證性可能會較複雜。另外，本研究實驗模擬是以 2018 年人流資料作為訓練資料去預測 2019 年人流異常，發現這種方式可能會造成有些資料判視度不準確的情形，因此本研究認為未來研究可以針對這個部分校正 model 準確度，方式是可以透過定義出的時間間隔及延遲時間，持續加入 2019 年的真實時間序列進行更新。像是預測 2019 年 1 月 1 日 02:00 的時候，可以把 2019 年 1 月 1 日 00:00 至 01:00 的真實數值去訓練模型，使它持續更新。

接著介紹質化分析的部分，目的除了探討模型解釋能力，也討論模擬區域在特定時間會發生的異常事件。本研究以人流異常預測分析為目標分成三個部分進行討論(1)預測未來一小時人流為異常，實際人流同樣為異常的情況。(2)預測未來一小時人流為正常，實際人流為異常的情況。(3)預測未來一小時人流為異常，實際人流為正常的情况。以下對於這三個部分的預測結果進行分析，將預測異常時間點的測試資料進行視覺化，觀察在相對應的提前預測時間下，過去 3 小時的實際人流狀況。

第一部分，針對預測未來一小時人流為異常，實際人流同樣為異常的情況分模擬區域進行討論。首先介紹第一部分信義商圈的分析結果，圖 18 為信義商圈預測結果之實際人流分析圖，其中圖 18(g)有包含每一條線的顏色圖示，以 9 種顏色線分別代表 3x3 網格中每一網格的人流，其中深藍色表示左上網格(left_top)，紅色表示上方網格(top)，綠色表示右上網格(right_top)，紫色表示左網格(left)，橘色表示中心網格(centor)，淺藍色表示右網格(right)，桃色表示左下網格(right_down)，螢光綠表示下方網格(down)，粉紅色表示右下網格(right_down)，圖 18(a)至(f)則是本研究舉例部分時間段的預測結果，每一張圖的 x 軸座標代表以小時為單位的時間點，由左至右依序為 $t-3$ 、 $t-2$ 、 $t-1$ 、 $t+1$ ，y 軸代表實際人流，實線為實際人流折線，虛線為 $t-1$ 人流至 CNN 預測 $t+1$ 人流的折線，如圖 18(i)的左上網格舉例虛線圖示即名為 left_top_pre 的圖例。




圖 18 信義商圈預測結果之實際人流分析圖(預測異常，實際為異常)

(a)10/10-下午 14 點(b)10/10-下午 15 點(c)10/11-下午 14 點(d)10/11-下午 15 點

(e)10/13-下午 14 點(f)10/13-下午 15 點(g)圖示說明




圖 19 士林商圈預測結果之實際人流分析圖(預測異常，實際為異常)
 (a)02/28-19 點(b)02/28-20 點(c)02/28-21 點(d)03/01-18 點(e)03/01-19 點(f)03/01-20 點




圖 20 士林商圈右網格人流時間熱區圖 (a) 2018 年(b) 2019 年

以信義商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 10 月 10 日下午 14 點至 15 點、10 月 11 日下午 14 點至 15 點、10 月 13 日下午 14 點至 15 點會發生人流異常，從圖中可以看到模型根據 $t-3$ 、 $t-2$ 、 $t-1$ 實際人流上升趨勢去判斷 $t+1$ 會發生人流異常，而 10 月 10 日及 10 月 11 日雖然為平日時間，但是這兩天適逢雙十連續假期 10 月 10 至 10 月 13 日，因此模型根據人流變化判斷在這兩天中有部分時間點人數異常，且異常時間點也相似於 10 月 13 日假日人潮巔峰時段，即商圈人潮。

接著介紹士林商圈的分析結果，圖 19 為士林商圈預測結果之實際人流分析圖，x 軸座標代表以小時為單位的時間點，由左至右依序為 $t-2$ 、 $t-1$ 、 t 、 $t+1$ ，y 軸代表實際人流，實線為實際人流折線，虛線為 t 人流至 CNN 預測 $t+1$ 人流的折線，以 9 種顏色線分別代表 3×3 網格中每一網格的人流。以士林商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 2 月 28 日晚上 19 點至 21 點、3 月 1 日晚上 18 點至 20 點會發生人流異常，圖中可以看到淺藍色實線(圖例名為 right，稱之右網格)整體上來看上升趨勢最為明顯，且模型主要根據該網格在 $t-2$ 、 $t-1$ 、 t 的實際人流變化去判斷 $t+1$ 會發生異常，因此該網格是影響模型判斷異常的重要因素，而該網格的主要地標為士林夜市商圈，因此由結果可以得知，此區域的空間特徵以士林商圈為重要影響異常判斷的因素。2 月 28 日及 3 月 1 日雖然為平日時間，但是這兩天適逢二二八連續假期，因此模型合理地判斷在這兩天中有部分時間點為異常，且判斷異常時間點的人潮巔峰為晚上時段，與右網格人流特性相符，如圖 20 為該網格分別在 2018 年及 2019 年的人流時間熱區圖。x 軸座標代表每日從 0 時至 24 時的時間點，y 軸代表星期幾，而網格內以顏色由深至淺代表人流由多至寡，從圖可以看到該網格在週休假日人流巔峰時段約為晚上 19 點至 21 點，符合模型在士林商圈預測出來的異常時間點。因此合理地判斷這兩天中有部分時間點為異常。

綜合上述第一部分的分析結果可以得出模型不只學習到訓練資料的異常特徵，且在過去時序資料為上升趨勢的情況下能夠對於連續假日或一般假日的人流異常能夠有效預測，本研究將此類型預測異常，實際為異常的情況定義為例行性人流異常事件。




圖 21 信義商圈預測結果之實際人流分析圖(預測正常，實際為異常)

(a)12/31-晚上 22 點(b)12/31-晚上 23 點




圖 22 信義商圈上方網格人流時間熱區圖 (a) 2018 年(b) 2019 年

第二部分，針對預測未來一小時人流為正常，實際人流為異常的情況分模擬區域進行討論。首先介紹第二部分的信義商圈分析結果，圖 21 為信義商圈預測結果之實際人流分析圖，圖例說明如同圖 18 所述。以信義商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 12 月 31 日晚上 22 點至 23 點不會發生人流異常，但實際卻發生異常，如圖所示 CNN 在提前 2 小時預測條件下，根據 19 點至 21 點實際人流逐漸下降的趨勢去預測出較低人流，然而 12 月 31 日雖然為平日時間，但是鄰近台北 101 跨年時間，因此人流在晚上 22 至 23 點時突然激增的事件與平日下班時間或營業店家準備打烊時間不同，因此造成 PNE-ADGAN 判斷 $t+1$ 不會發生異常。另外，從圖中可以發現在 9 個網格中以橘色實線(圖例名為 top，稱之上方網格)趨勢較為明顯與其他不同，而該網格主要地標為台北市政府，在平日時段晚間 22 點至 23 點是無高流量的變化，




圖 23 士林商圈預測結果之實際人流分析圖(預測正常，實際為異常)

(a) 03/01-下午 15 點(b) 03/01-下午 16 點

如圖 22 為該網格分別在 2018 年及 2019 年的人流時間熱區圖，圖例說明如同圖 20 所述，從圖中可以看到平日晚上約 19 點過後人數大幅減少。綜上所述，模型判斷結果會受到區域空間特徵影響，如果過去 3 小時的趨勢無明顯上升且訓練資料在該時間點非熱門時段，則無法準確預測。

接著介紹第二部分士林商圈的分析結果，圖 23 為士林商圈預測結果之實際人流分析圖，圖例說明如同圖 19 所述。以士林商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 3 月 1 日 15 點及 16 點不會發生人流異常，但實際卻發生異常，如圖所示 CNN 在提前 1 小時預測的條件下，根據過去 3 小時人流的平穩且微幅下降趨勢對整體預測出較低人流，造成 PNE-ADGAN 判斷 $t+1$ 不會發生異常，而其中以上方網格影響最大，該網格為住宅區無重要地標，其次為左網格(圖例名為 left)，該網格約一半面積是基隆河，這兩個網格趨勢是主要影響模型誤判的因素。且 3 月 1 日雖然是在國定連假期間，但對於模型來說此區域在平日下午時段並非異常熱門時段，因此一般來說，士林商圈的中午時段是屬於如下圖的平穩趨勢，中午時段趨勢會預測為正常，而異常原因是 3 月 1 日國定假日下午 15~16 點時間段會有人潮湧入，屬於突發性事件，使模型難以判別異常。




圖 24 忠孝商圈預測結果之實際人流分析圖(預測正常，實際為異常)

(a)11/18-晚上 19 點(b)01/19-晚上 19 點

接著介紹第二部分忠孝商圈的分析結果，圖 24 為忠孝商圈預測結果之實際人流分析圖，如同圖 19 所述。以忠孝商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 11 月 18 日 19 點不會發生人流異常，但實際卻發生異常，如圖 24(a)所示 CNN 在提前 1 小時預測的條件下，根據過去 3 小時人流處於高平穩流量且趨勢微幅下降對整體預測出較低且平穩的人流，造成 PNE-ADGAN 判斷 $t+1$ 不會發生異常，而其中以上方網格影響最大，該網格內的主要地標為台北遠東 SOGO 忠孝復興館，屬於模擬區域忠孝商圈中的百貨商圈，而該時間點雖然為平日，但正逢週年慶最後一日，因此人流在晚上 19 點後有明顯增加的情形，正符合週年慶主要客群在約 18 點下班時間後去購物的時間點。舉另一例如圖 24(b)所示，其影響判斷的因素與前述所說相同，不同的點在於其主要影響網格為中間網格，其次為左邊網格。中間網格主要地標為忠孝敦化徒步巷弄商圈、東區地下街等，因此在該時間點人流皆高平穩的情況下，當趨勢不明顯時突然增加的人流量就不容易被模型判斷為異常。

綜合上述第二部分的分析結果可以得出模型會根據訓練資料學習到異常特徵進行異常判斷，對於時序資料無明顯上升趨勢的情況較無法準確判別人流異常，本研究將此類型預測正常，實際為異常的情況定義為突發性人流異常事件。




圖 25 信義商圈預測結果之實際人流分析圖(預測異常，實際為正常)

(a) 01/05-下午 18 點 (b) 01/06-下午 18 點

第三部分，針對預測未來一小時人流為異常，實際為正常的情況分模擬區域進行討論。首先介紹第三部分信義商圈的分析結果，圖 25 為信義商圈預測結果之實際人流分析圖，如同圖 18 所述。以信義商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 1 月 5 日及 1 月 6 日同為周末晚上 18 點會發生人流異常，但實際卻沒發生異常的情況，如圖可以看到人流在 CNN 提前 2 小時預測下，過去 3 小時人流微上升趨勢是模型判為異常的關鍵因素，而最具影響的淺綠色實線(圖例名為 down，稱之下方網格)在 $t+1$ 人流明顯驟降，原因從該網格主要地標有信義國小及信義區運動中心主要推測出其假日人流熱門時段會在白天，從圖 26 也可以發現該網格在假日並非人流冷門時段，而是在該時間點後人數開始驟降。另外舉例，PNE-ADGAN 判斷 2 月 19 日晚上 17 點、6 月 14 日 13 點的時間段會發生人流異常，但實際卻沒發生異常，從結果中可




圖 26 信義商圈下方網格人流時間熱區圖(a) 2018 年(b) 2019 年




圖 27 士林商圈預測結果之實際人流分析圖(預測異常，實際為正常)

(a) 02/07-晚上 19 點(b) 02/08-晚上 19 點

以發現過去上升趨勢是判為異常的關鍵，結果可分為兩種情況(1)實際人流在未來一小時是向下趨勢(2)過去同是上升趨勢，預測結果比正常情況更高，導致誤判為異常。

接著介紹第三部分士林商圈的分析結果，圖 27 為士林商圈預測結果之實際人流分析圖(預測異常，實際為正常)，如同圖 19 所述。以士林商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 2 月 7 日晚上 19 點及 2 月 8 日晚上 19 點為異常，從圖上可以看到在這兩個時間點的人流變化對於晚上 19 點的異常皆以淺藍色實線(右網格)為主要影響結果的網格，而此網格在前 3 小時人流變化急遽上升，因此模型判斷下 1 小時為異常。





圖 28 忠孝商圈預測結果之實際人流分析圖(預測異常，實際為正常)
(a) 02/07-晚上 19 點 (b) 02/08-晚上 19 點 (c) 03/29-晚上 21 點




圖 29 忠孝商圈中心網格人流時間熱區圖 (a) 2018 年 (b) 2019 年




圖 30 忠孝商圈左上方網格人流時間熱區圖 (a) 2018 年(b) 2019 年

接著介紹第三部分忠孝商圈的分析結果，圖 28 為忠孝商圈預測結果之實際人流分析圖(預測異常，實際為正常)，如同圖 19 所述。以忠孝商圈部分預測結果舉例說明，PNE-ADGAN 判斷 2019 年 1 月 18 日晚上 21 點及 3 月 29 日晚上 21 點為異常，從圖上可以看到在這兩個時間點的人流變化在前 3 小時人流趨勢微幅上升使模型預測異常，實際人流明顯下降，對於晚上 21 點的異常皆以橘黃實線(中心網格)及紫色實線(左網格)最為影響網格，也就是位在忠孝敦化及忠孝復興商圈的區域，如圖 29、圖 30 所示這兩個網格通常在晚間 21 點還是屬於人流熱門時段，因此模型會對該時段容易預測異常。另外舉例，PNE-ADGAN 判斷 3 月 29 日晚上 21 點為異常，實際為正常，以橘黃線為最高流量影響網格，這網格位在忠孝敦化商圈，在晚間 21 點的時間段是屬於熱門時段預測值較實際高，因此誤判為異常。

綜合上述第三部分的分析結果可以得出模型會學習到訓練資料在時空上的異常特徵，對於過去上升趨勢以及預測值偏高的情況容易判斷為異常，本研究將此類型預測異常，實際為正常的情況定義為虛警型人流異常事件。

本研究在模擬實驗中以 2018 年及 2019 年行動數據人流資料分別作為訓練集與測試集，採用分類型績效評估指標進行量化分析，採用資料視覺化分析進行質化分析與討論，最終本依據模擬結果定義出異常事件包含例行性、突發性、虛警型，其中本研究提出的方法對於例行性人流異常預測分析較為準確，可用於人流控管的重點參考指標。對於突發性人流異常事件，雖然較不像例行性異常事件普遍，但可推測其可能未來會發生的事件，可用作於輔助決策的次要參考指標。

第五章 結論與未來展望

人流受到人類複雜性活動的影響，預測人流異常問題一直以來都極具挑戰性，本研究針對過去方法不足進行改良，建立一種半監督式學習異常預測方法——基於集成式生成對抗網路之人流異常預測分析模型(PNE-ADGAN)，建立不同面向生成對抗網路，在異常資料少量的情況下，僅以過去正常資料訓練模型，將多個判別模型預測結果透過集成學習進行二次預測，使模型對未知異常預警，最終以真實行動數據人流資料測試，並與監督式學習方法進行比較，得知半監督式學習模型的優勢適用於人流異常預測分析問題，最終透過量化與質化的驗證方式進行人流異常預測分析預測結果合理性。除了提出方法外，本研究在異常分析階段，針對三個模擬區域將異常預測結果以事件類型區分，定義為例行性、突發性、虛警型，分析不同網格會發生異常的時間點以及其空間上的影響來源。最終達到研究目的(1)僅透過正常資料建立學習異常特徵的半監督式學習模型，使生成對抗網路在訓練過程中學習正常特徵，以判別異常及正常時空資料(2)建立多面向半監督式預測模型，透過集成學習優化生成對抗網路中的判別器的異常判別結果(3)透過人流異常預測分析幫助人流相關管理單位了解異常原因。本研究認為未來可透過 GAN 生成異常資料輸入給其他分類模型做訓練再與 PNE-ADGAN 比較。另外，從模擬分析中也可以得出 PNE-ADGAN 已降低了監督式方法對於異常標準的依賴性，未來要使預測績效大幅提升，建議(1)增加輔助資料，加入特徵幫助模型學習，例如：天氣、捷運資料。(2)使用時間序列模型，增加人流異常預測有效性。

參考文獻

- [1] Alam, M. R., Gerostathopoulos, I., Amini, S., Prehofer, C., & Attanasi, A. (2019). Adaptable Anomaly Detection in Traffic Flow Time Series. In *2019 6th International Conference on Models and Technologies for Intelligent Transportation Systems (MT-ITS)* (pp. 1-9). IEEE.
- [2] Alonso, E., Moysset, B., & Messina, R. (2019). Adversarial generation of handwritten text images conditioned on sequences. In *2019 International Conference on Document Analysis and Recognition (ICDAR)* (pp. 481-486). IEEE.
- [3] Arumugam, P., & Saranya, R. (2018). Outlier detection and missing value in seasonal ARIMA model using rainfall data. *Materials Today: Proceedings*, 5(1), 1791-1799.
- [4] Bai, Y., Sun, J., Luo, J., & Zhang, X. (2010). Forecasting financial time series with ensemble learning. In *2010 International Symposium on Intelligent Signal Processing and Communication Systems* (pp. 1-4). IEEE.
- [5] Bianco, A. M., Garcia Ben, M., Martinez, E. J., & Yohai, V. J. (2001). Outlier detection in regression models with arima errors using robust estimates. *Journal of Forecasting*, 20(8), 565-579.
- [6] Ceapa, I., Smith, C., & Capra, L. (2012). Avoiding the crowds: understanding tube station congestion patterns from trip data. In *Proceedings of the ACM SIGKDD international workshop on urban computing* (pp. 134-141).
- [7] Çelik, M., Dadaşer-Çelik, F., & Dokuz, A. Ş. (2011). Anomaly detection in temperature data using dbscan algorithm. In *2011 international symposium on innovations in intelligent systems and applications* (pp. 91-95). IEEE.
- [8] Chen, H., Yu, G., Liu, F., Cai, Z., Liu, A., Chen, S., ... & Cheang, C. F. (2020). Unsupervised Anomaly Detection via DBSCAN for KPIs Jitters in Network Managements. *Computers, Materials & Continua*, 62(2), 917-927.
- [9] Chhetri, M. B., Lumpe, M., Vo, Q. B., & Kowalczyk, R. (2017). On forecasting amazon ec2 spot prices using time-series decomposition with hybrid look-backs. In *2017 IEEE International Conference on Edge Computing (EDGE)* (pp. 158-165). IEEE.
- [10] COVID-19 - Mobility Trends Reports. (n.d.). Retrieved from <https://covid19.apple.com/mobility>
- [11] Djenouri, Y., & Zimek, A. (2018). Outlier detection in urban traffic data. In *Proceedings of the 8th International Conference on Web Intelligence, Mining and Semantics* (pp. 1-12).
- [12] Duan, Q., Wei, X., Gao, Y., & Zhou, F. (2018). Base Station Traffic Prediction based on STL-LSTM Networks. In *2018 24th Asia-Pacific Conference on Communications (APCC)* (pp. 407-412). IEEE.
- [13] Duan, Y., Zhao, Y., Pang, J., Liu, L., & Liu, D. (2017). Unmanned Aerial Vehicle Sensing Data Anomaly Detection by Relevance Vector Machine. In *2017 International*

- Conference on Sensing, Diagnostics, Prognostics, and Control* (pp. 638-641). IEEE.
- [14] Esan, D. O., Owolawi, P. A., & Tu, C. (2020). Detection of Anomalous Behavioural Patterns In University Environment Using CNN-LSTM. In *2020 IEEE 23rd International Conference on Information Fusion (FUSION)* (pp. 1-8). IEEE.
- [15] Fanaee-T, H., & Gama, J. (2016). Tensor-based anomaly detection: An interdisciplinary survey. *Knowledge-Based Systems*, 98, 130-147.
- [16] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. In *Advances in neural information processing systems* (pp. 2672-2680).
- [17] Gui, G., Liu, F., Sun, J., Yang, J., Zhou, Z., & Zhao, D. (2019). Flight delay prediction based on aviation big data and machine learning. *IEEE Transactions on Vehicular Technology*, 69(1), 140-150.
- [18] Habeeb, R. A. A., Nasaruddin, F., Gani, A., Hashem, I. A. T., Ahmed, E., & Imran, M. (2019). Real-time big data processing for anomaly detection: A survey. *International Journal of Information Management*, 45, 289-307.
- [19] Ho, C. C., & Ting, C. Y. (2015). Time series analysis and forecasting of dengue using open data. In *International Visual Informatics Conference* (pp. 51-63). Springer, Cham.
- [20] Hu, P., Tong, J., Wang, J., Yang, Y., & de Oliveira Turci, L. (2019). A hybrid model based on CNN and Bi-LSTM for urban water demand prediction. In *2019 IEEE Congress on Evolutionary Computation (CEC)* (pp. 1088-1094). IEEE.
- [21] Hussain, B., Du, Q., & Ren, P. (2017). Big data-driven anomaly detection in cellular networks. In *2017 IEEE/CIC International Conference on Communications in China (ICCC)* (pp. 1-6). IEEE.
- [22] Ijaz, M. F., Attique, M., & Son, Y. (2020). Data-Driven Cervical Cancer Prediction Model with Outlier Detection and Over-Sampling Methods. *Sensors*, 20(10), 2809.
- [23] Jamil, M. S., & Akbar, S. (2017). Taxi passenger hotspot prediction using automatic ARIMA model. In *2017 3rd International Conference on Science in Information Technology (ICSITech)* (pp. 23-28). IEEE.
- [24] Kaibei, P. E. N. G., Wei, B. A. I., & Liu Yi, W. U. (2020). Passenger flow forecast of railway station based on improved LSTM. In *2020 2nd International Conference on Advances in Computer Technology, Information Science and Communications (CTISC)* (pp. 166-170). IEEE.
- [25] Kwon, D., Natarajan, K., Suh, S. C., Kim, H., & Kim, J. (2018). An empirical study on network anomaly detection using convolutional neural networks. In *2018 IEEE 38th International Conference on Distributed Computing Systems (ICDCS)* (pp. 1595-1598). IEEE.
- [26] Leangarun, T., Tangamchit, P., & Thajchayapong, S. (2018). Stock Price Manipulation Detection using Generative Adversarial Networks. In *2018 IEEE Symposium Series on Computational Intelligence (SSCI)* (pp. 2104-2111). IEEE.

- [27] Lei, S., Xinming, M., Lei, X., & Xiaohong, H. (2010). Financial data mining based on support vector machines and ensemble learning. In *2010 International Conference on Intelligent Computation Technology and Automation* (Vol. 2, pp. 313-314). IEEE.
- [28] Lin, S., Clark, R., Birke, R., Schönborn, S., Trigoni, N., & Roberts, S. (2020). Anomaly Detection for Time Series Using VAE-LSTM Hybrid Model. In *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 4322-4326). IEEE.
- [29] Lin, Z., Shi, Y., & Xue, Z. (2018). Idsgan: Generative adversarial networks for attack generation against intrusion detection. *arXiv preprint arXiv:1809.02077*.
- [30] Liu, P., Zhang, Y., Kong, D., & Yin, B. (2019). Improved Spatio-Temporal Residual Networks for Bus Traffic Flow Prediction. *Applied Sciences*, 9(4), 615.
- [31] Liu, Y., Xiao, H., Pan, Y., Huang, D., & Wang, Q. (2016). Development of multiple-step soft-sensors using a Gaussian process model with application for fault prognosis. *Chemometrics and Intelligent Laboratory Systems*, 157, 85-95.
- [32] Lu, Y. C., Lu, C. J., Chang, C. C., & Lin, Y. W. (2017). A hybrid of data mining and ensemble learning forecasting for recurrent ovarian cancer. In *2017 International Conference on Intelligent Informatics and Biomedical Sciences (ICIIBMS)* (pp. 216-216). IEEE.
- [33] Mogren, O. (2016). C-RNN-GAN: Continuous recurrent neural networks with adversarial training. *arXiv preprint arXiv:1611.09904*.
- [34] Munir, M., Siddiqui, S. A., Dengel, A., & Ahmed, S. (2018). DeepAnT: A deep learning approach for unsupervised anomaly detection in time series. *IEEE Access*, 7, 1991-2005.
- [35] Neethu, B. N., & Jayanthi, S. (2019). Greenhouse Monitoring and Controlling using Modified K Means Clustering Algorithm. In *2019 Third International conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud)(I-SMAC)* (pp. 456-462). IEEE.
- [36] Nugroho, L. E., Lazuardi, L., & Prabuwo, A. S. (2018). Detection of Anomalous Vital Sign of Elderly Using Hybrid K-means Clustering and Isolation Forest. In *TENCON 2018-2018 IEEE Region 10 Conference* (pp. 0913-0918). IEEE.
- [37] Olah, C. (2020). Understanding LSTM Networks -- colah's blog. Retrieved 9 December 2020, from <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- [38] Pathak, S., Cai, X., & Rajasekaran, S. (2018). Ensemble deep TimeNet: An ensemble learning approach with deep neural networks for time series. In *2018 IEEE 8th International Conference on Computational Advances in Bio and Medical Sciences (ICCABS)* (pp. 1-1). IEEE.
- [39] Poh, S. C., Tan, Y. F., Guo, X., Cheong, S. N., Ooi, C. P., & Tan, W. H. (2019). LSTM and HMM comparison for home activity anomaly detection. In *2019 IEEE 3rd Information Technology, Networking, Electronic and Automation Control Conference (ITNEC)* (pp. 1564-1568). IEEE.
- [40] Qiu, J., Wu, Q., Ding, G., Xu, Y., & Feng, S. (2016). A survey of machine learning for

- big data processing. *EURASIP Journal on Advances in Signal Processing*, 2016(1), 67.
- [41] Rodrigo, R., Patiño, D. H., & Schweickardt, G. (2018). ARIMA and Neural Network for Sensors Failure Detection. In *2018 Congreso Argentino de Ciencias de la Informática y Desarrollos de Investigación (CACIDI)* (pp. 1-6). IEEE.
- [42] Rukmi, A. M., & Wahid, A. (2019). Role of clustering based on density to detect patterns of stock trading deviation. In *Journal of Physics: Conference Series* (Vol. 1218, No. 1, p. 012053). IOP Publishing.
- [43] Silva, T. (2020). An intuitive introduction to Generative Adversarial Networks (GANs). Retrieved December 09, 2020, from <https://www.freecodecamp.org/news/an-intuitive-introduction-to-generative-adversarial-networks-gans-7a2264a81394/>
- [44] Singh, M., Mehtre, B. M., & Sangeetha, S. (2019). User Behavior Profiling using Ensemble Approach for Insider Threat Detection. In *2019 IEEE 5th International Conference on Identity, Security, and Behavior Analysis (ISBA)* (pp. 1-8). IEEE.
- [45] Smith, B. L., Williams, B. M., & Oswald, R. K. (2002). Comparison of parametric and nonparametric models for traffic flow forecasting. *Transportation Research Part C: Emerging Technologies*, 10(4), 303-321.
- [46] Staudemeyer, R. C., & Morris, E. R. (2019). Understanding LSTM--a tutorial into Long Short-Term Memory Recurrent Neural Networks. *arXiv preprint arXiv:1909.09586*.
- [47] Stenneth, L., Wolfson, O., Yu, P. S., & Xu, B. (2011, November). Transportation mode detection using mobile phones and GIS information. In *Proceedings of the 19th ACM SIGSPATIAL international conference on advances in geographic information systems* (pp. 54-63).
- [48] Trinh, H. D., Giupponi, L., & Dini, P. (2019). Urban anomaly detection by processing mobile traffic traces with LSTM neural networks. In *2019 16th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON)* (pp. 1-8). IEEE.
- [49] Tron, T., Resheff, Y. S., Bazhmin, M., Weinshall, D., & Peled, A. (2018). Arima-based motor anomaly detection in schizophrenia inpatients. In *2018 IEEE EMBS International Conference on Biomedical & Health Informatics (BHI)* (pp. 430-433). IEEE.
- [50] Wang, Z., & Lou, Y. (2019). Hydrological time series forecast model based on wavelet de-noising and ARIMA-LSTM. In *2019 IEEE 3rd Information Technology, Networking, Electronic and Automation Control Conference (ITNEC)* (pp. 1697-1701). IEEE.
- [51] Wang, Z., Zhou, Y., & Li, G. (2020). Anomaly Detection by Using Streaming K-means and Batch K-means. In *2020 5th IEEE International Conference on Big Data Analytics (ICBDA)* (pp. 11-17). IEEE.
- [52] Wu, H. S. (2016). A survey of research on anomaly detection for time series. In *2016 13th International Computer Conference on Wavelet Active Media Technology and Information Processing (ICCWAMTIP)* (pp. 426-431). IEEE.
- [53] Xu, F., Lin, Y., Huang, J., Wu, D., Shi, H., Song, J., & Li, Y. (2016). Big data driven

- mobile traffic understanding and forecasting: A time series approach. *IEEE transactions on services computing*, 9(5), 796-805.
- [54] Xue, H., Huynh, D. Q., & Reynolds, M. (2018). SS-LSTM: A hierarchical LSTM model for pedestrian trajectory prediction. In *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)* (pp. 1186-1194). IEEE.
- [55] Zakiah, A. (2020). Outlier Detection of Transaction Data Using DBSCAN Algorithm. *International Journal of Psychosocial Rehabilitation*, 24(2).
- [56] Zheng, J., & Huang, M. (2020). Traffic Flow Forecast Through Time Series Analysis Based on Deep Learning. *IEEE Access*, 8, 82562-82570.
- [57] Zhou, K., Wang, W., Huang, L., & Liu, B. (2020). Comparative study on the time series forecasting of web traffic based on statistical model and Generative Adversarial model. *Knowledge-Based Systems*, 106467.
- [58] Zhu, G., Zhao, H., Liu, H., & Sun, H. (2019). A Novel LSTM-GAN Algorithm for Time Series Anomaly Detection. In *2019 Prognostics and System Health Management Conference (PHM-Qingdao)* (pp. 1-6). IEEE.
- [59] Zhu, Q., & Sun, L. (2020). Big Data Driven Anomaly Detection for Cellular Networks. *IEEE Access*, 8, 31398-31408.
- [60] 詹大千. (2018). 從手機網路訊號資料，探勘人口動態奧妙 (張語辰 & 廖英凱, Eds.). Retrieved from <https://research.sinica.edu.tw/human-dynamics-chan-ta-chien/>
- [61] 孫贊, 李明濤, & 姚曉暉. (2010). 基於 BP 神經網絡人流預測的實現. *中國安全生產科學技術*, 6 (2), 61-65.
- [62] 劉邵宸(2020)。臺北捷運人流量異常分析及預測。國立雲林科技大學工業工程與管理系碩士論文，雲林縣。
- [63] 潘淵洋, 李光輝, & 徐勇軍. (2012). 基於 DBSCAN 的環境傳感器網絡異常數據檢測方法. *計算機應用與軟體*, (2012 年), 69-72.