

逢 甲 大 學

資 訊 工 程 學 系 碩 士 班

碩 士 論 文

基於模糊類神經網路的

路網旅行時間預測方法

**Using Fuzzy Neural Network to Predict
the Traveling Time on Road Network**

指導教授：陳奕中、洪維志

研 究 生：歐晉佑

中 華 民 國 一 百 零 六 年 七 月

誌謝



摘要

近年來，交通路網的旅行時間預測已經成為一個重要議題。旅行時間預測的目的在於利用即時的交通資訊，即時、準確的預測從起點至終點所需花費的時間，作為使用者進行分析或決策的參考。然而用於預測之交通資料來自不同的政府或民間單位，資料的格式、完整性等都不盡相同。現有的方法需要充足的路段資料集才能進行旅行時間預測，當路段資料過少甚至是缺乏時，這些方法將無法進行預測工作。因此本研究提出一個基於模糊類神經網路的路網旅行時間預測方法。透過將路段資料集轉換成編碼的方式來統一資料格式，並使用編碼後的路段資料集進行路網旅行時間預測。本研究提出之路網旅行時間預測方法能夠透過由單個或多個路段組成的路徑旅行資料預測路網中任一路段的旅行時間。本研究使用兩種資料集對該路網旅行時間預測方法進行驗證。使用模擬路網資料集之模擬實驗證明該方法應用於路網旅行時間預測上的可靠性和穩定性。使用中國驛站路網資料集之模擬實驗證明該方法能夠透過路徑旅行資料預測路徑經過之任一路段的旅行時間。

關鍵詞：模糊類神經網路、旅行時間預測、路徑旅行紀錄

Abstract

In recent year, traveling time prediction on road network become an important issue. Traveling time prediction provide real-time and accurate time from start point to endpoint to help users decide the policies. Because traveling data and road network data from different organization have different formats, the methods which be proposed previously cannot adapt to use on all type formats. This research proposes a prediction method based on fuzzy neural network and a common swap format for the data which be used on the method. This method can use not only the traveling data of road section but also the traveling data of path data to predict the traveling time for any road section or path on the road network.

Five type of road network data of simulation and one type of road network data of real world were used to experiment the available and reliable of the prediction method. The prediction results of the experiment proved that the prediction method can predict the traveling time for any road section or path on the road network by the traveling data of road section and the traveling data of path.

Key Word : Fuzzy Neural Network, Traveling Time Prediction, Traveling Data of Path

目錄

誌謝.....	i
摘要.....	ii
目錄.....	iv
圖目錄.....	vi
表目錄.....	vii
第一章 緒論.....	1
1.1 研究背景.....	1
1.2 研究動機.....	2
1.3 研究目的.....	4
1.4 研究流程.....	6
1.5 章節介紹.....	7
第二章 技術介紹.....	錯誤! 尚未定義書籤。
2.1 MATLAB	錯誤! 尚未定義書籤。
2.2 數據分析.....	8
2.3 模糊理論.....	9
2.4 KNN 應用於路段旅行時間預測.....	10
2.5 類神經網路應用於路段旅行時間預測.....	13
第三章 研究方法.....	14
3.1 應用之原始資料集.....	15
3.1.1 模擬資料.....	15
3.1.2 實際資料.....	19

3.2 資料前處理.....	22
3.2.1 資料編碼.....	24
3.2.2 資料清理.....	27
3.2.3 資料整合.....	31
3.2.4 格式轉換.....	32
3.3 路線與旅行時間相關之模型.....	34
3.3.1 資料之正規化(Normalization).....	35
3.4 Fuzzy Neural Network.....	36
3.4.1 FNN 的結構.....	37
3.4.2 FNN 之訓練演算法.....	40
3.4.3 FNN 之測試演算法.....	43
第四章 應用實驗.....	44
4.1 模擬路網之旅行時間預測.....	44
4.2 實際路網資料之旅行時間預測.....	55
第五章 結論.....	61
參考文獻.....	62

圖目錄

圖 1.1 研究流程圖	6
圖 3.1 路網旅行時間預測之架構圖	14
圖 3.2 路網旅行時間預測之細部架構圖	23
圖 3.3 格式轉換之說明範例圖	33
圖 3.4 FNN 之訓練演算法	36
圖 3.5 FNN 之架構	37
圖 4.1 路網 A 之路網圖	45
圖 4.2 路網 B 之路網圖	46
圖 4.3 路網 C 之路網圖	46
圖 4.4 路網 D 之路網圖	47
圖 4.5 路網 E 之路網圖	47
圖 4.6 模擬路網 Epoch 實驗之誤差變化量	49
圖 4.7 路網 A 之各分割資料預測表現	51
圖 4.8 路網 B 之各分割資料預測表現.....	錯誤! 尚未定義書籤。
圖 4.9 路網 C 之各分割資料預測表現.....	錯誤! 尚未定義書籤。
圖 4.10 路網 D 之各分割資料預測表現	錯誤! 尚未定義書籤。
圖 4.11 路網 E 之各分割資料預測表現.....	錯誤! 尚未定義書籤。
圖 4.12 模擬路網資料集之預測時間成本比較圖	53
圖 4.13 中國驛站資料之路網圖	55
圖 4.14 中國驛站路網 Epoch 實驗之誤差變化量	56
圖 4.15 中國驛站路網之各分割資料預測表現	58
圖 4.16 中國驛站路網之各分割資料預測時間成本	59

表目錄

表 1.1 路網資料編碼格式	4
表 3.1 本研究使用之所有資料與資料來源	15
表 3.2 模擬之站點資料	15
表 3.3 模擬之路段資料(道路數量變數為 2).....	17
表 3.4 模擬之路段資料(道路數量變數為 3).....	17
表 3.5 模擬之旅行資料(道路數量變數為 2).....	18
表 3.6 模擬之旅行資料(道路數量變數為 3).....	18
表 3.7 中國明、清兩代之驛站座標資料(中央研究院歷史語言研究所).....	19
表 3.8 中國清代之驛站路段資料(中央研究院歷史語言研究所).....	20
表 3.9 中國清代之驛站旅行資料(中央研究院歷史語言研究所).....	21
表 3.10 中國清代之驛站路段_數值型態資料補值	25
表 3.11 中國清代之驛站旅行資料_字串型態資料補值	25
表 3.12 驛站名稱重複之驛站點	28
表 3.13 因驛站名稱重複而無法辨識之路段資料(部分剔除).....	29
表 3.14 缺乏路徑距離訊息之路段資料(剔除).....	30
表 3.15 模型之輸入資料集	31
表 4.1 模擬路網之比較	48
表 4.2 模擬路網之訓練資料集與測試資料集分隔結果	50
表 4.3 模擬路網之訓練資料集與測試資料集分割結果	57

第一章 緒論

1.1 研究背景

近年來，交通路網的旅行時間預測已經成為一個重要議題。旅行時間預測的目的在於利用即時的交通資訊，例如車流量、車輛速度、道路狀況等，即時、準確的預測從起點至終點所需花費的時間，作為使用者進行分析或決策的參考。對一般使用者來說，旅行時間預測可以做為旅程決定之參考依據，以降低花費在交通上的時間成本[1]。對管理者來說，旅行時間預測可以做為政策決定之參考依據，以降低交通問題帶來的社會成本。

隨著大數據資料不斷開放，越來越多路網資料被應用於旅行時間預測[2][3][4]，然而因為資料種類的不同，進行旅行時間預測的條件和方法也不盡相同。除此之外，部分資料因為年代久遠，記錄之資料不如現代資料這般完整齊全，難以透過一般方法進行旅行時間預測。在這樣的情況下，我們希望找出一個可靠的泛用型路網旅行時間重建方法。

1.2 研究動機

近年來隨著開放大數據與政府數據開放平台的興起，使用者可以透過不同管道取得越來越多平時無法取得的數據資料，其中就有各個地區、各個時期、各個時間的交通資料，然而這些資料大多來自不同的政府或民間單位，資料的格式、完整性等都不盡相同。

台灣政府在 2012 年 11 月開始推動開放平台計畫，並在 2013 年 4 月推出第一版開放平台，直到今天，政府資料開放平台上已經存在高達兩萬多個資料集，其中交通方面的資料集有一千多個。在這些資料集中，公車之站點資料、公車之路徑資料、公車之到站時間資料將可以被用來進行公車之到站時間預測。

自 2015 年開始，台灣國道高速公路局開始舉辦高速公路 ETC 資料應用創意競賽，競賽目的是透過公路局開放之 ETC 交通資料，進行特定時期的高速公路路段之旅行時間預測。公路局開放之 ETC 交通資料包含未處理之車輛原始資料、車流量、平均旅行時間、平均行駛速率、旅行路徑資料、旅行長度資料、旅行起訖資料等，在這些資料集中，平均旅行時間、旅行路徑資料、旅行長度資料、旅行起訖資料可以被用來進行公路之旅行時間預測。

除了現代資料之外，古代之交通路網資料也能被用來進行古代道路之旅行時間預測，該預測結果能夠讓研究學者更進一步了解和分析古人的各項活動，例如美國的 Orbis 系統[5]。該系統通過模擬羅馬公路網主要航線，重建了古代旅遊的時間和財務成本。

作為中國近代著名的歷史和語言研究機構，台灣的中央研究院歷史語言研究所希望能夠透過中國之驛站資料，完成一個中國版本的歷史旅行時間查詢系統，協助研究人員更深入的去探討中國歷史。

上述幾個資料集的目的都是預測交通路網的旅行時間。為了進行路網資料的預測，過去許多研究人員提出了許多旅行時間預測的方法[2][3][4]，然而這些方法並不能直接套用到本研究使用之資料集，原因有以下幾點：

1. 這些預測方法都是針對路網中的部分路段，當要進行整個路網的旅行時間預測時，必須將整個路網分割成無數的小路段，再使用這些預測方法對每個小路段進行旅行時間預測，如果路網較為複雜時，這些方法將會浪費許多時間。
2. 這些預測方法都是建立在該預測路段存在旅行資料的前提下，也就是說，如果要進行某一路段的旅行時間預測，需要一組屬於這個路段，而且「正確」的旅行時間資料。今天若有一路段之旅行時間資料全部遺失，這些預測方法將無法對該路段進行旅行時間預測。
3. 這些預測方法都是透過路段之特徵來尋找即時資料與歷史資料之相似性，進而利用歷史資料推估現在可能的旅行時間。這些方法應用在路段上或許可行，但當旅行資料並非路段，而是由多條路段組合成的路徑時，這些方法將無法透過路段之特徵來尋找即時資料與歷史資料之相似性。

1.3 研究目的

為了解決上述問題，本研究提出一個標準化的路網資料編碼格式，如表 1.1，以及一個泛用型交通路網旅行時間預測方法，讓使用者在投入交通路網資料集後，能夠迅速且準確的得到該交通路網之旅行時間。

表 1.1 路網資料編碼格式

路段編號	甲	乙	丙	...
旅程是否經過	1	1	1	...
路段特徵 1	...	...	...	...
路段特徵 2	...	...	...	...
...	...	...	...	...

該路網資料編碼格式的目的主要是為了解決輸入資料的問題。因為不同來源之資料集都存在相當程度的差異性，若沒有一個統一的格式，在進行交通路網之旅行時間預測時必須要針對每個案例人工進行架構或資料的調整，增加不必要的工作成本，因此本論文提出了該路網資料編碼格式，使這些資料集能夠簡單的應用在該交通路網旅行時間預測方法上。

除此之外，該資料編碼格式不僅可以描述路網中的某一路段，也可以表示路網中的某一路徑，這對某些擁有路徑旅行資料卻缺乏路段旅行資料的資料集相當重要，例如中研院的中國驛站資料。

而在預測方法上，本研究提出一個模糊類神經網路(Fuzzy Neural Network，FNN)預測方法，用於預測交通路網的旅行時間。

FNN 的架構為模糊邏輯技術與類神經網路的結合[6]，目的是在於同時獲得雙方的優點(類神經網路的學習能力、最佳化能力、連結式的結構，模糊邏輯系統接近人類思考行為的能力)，並消除彼此的缺點。

模糊邏輯系統通常直接面對資料，在根據一連串的經驗觀察後，根據觀察結果給予一個合適的答案，這與以大量的歷史路段旅行時間預測即時路段旅行時間的預測方式不謀而合。然而模糊系統需要考慮到初始的模糊法則和調整方式、歸屬函數，傳統由專家進行調整的作法容易參雜人的主觀印象，因此為了降低人為的干預，以及得到自我調整能力和最佳化的結果，將類神經網路導入模糊邏輯系統，由類神經網路分析並設計模糊邏輯系統。

在本研究中，我們將分析多種類型之路網旅行資料，並實驗泛用化之模糊類神經網路是否能完成交通路網之旅行時間預測，與評估重建結果是否達到應用之門檻。本研究將設計兩個使用模糊類神經網路之路網旅行時間資料預測實驗，以評估該方法之模型結構是否穩定可靠，以及其泛用化之能力。

1.4 研究流程

本研究之研究流程圖如圖1.1所示。首先確定研究之方向，並對研究之動機和目的進行近一步的說明，之後對本研究相關之論文進行回顧，包含資料之格式、模糊類神經網路的架構，以及其於交通路網上的應用。接著定義路網資料編碼格式與模糊類神經網路的架構，並將原始資料依定義之格式投入模糊類神經網路之架構進行預測，觀察和分析其預測結果。之後依照觀察和分析結果建立路網旅行時間預測模型，將所有原始資料依定義之格式投入該模型進行旅行時間預測，並進行應用之可行性評估。最後提出本研究之結論與建議。




圖 1.1 研究流程圖

1.5 章節介紹

本研究論文之章節編排如下。第一章節為緒論，說明本論文的研究背景、研究動機與研究目的。第二章節為技術介紹，說明本論文所使用之技術。第三章節為研究方法，說明應用於本研究之所有交通路網資料、該交通路網之分析方法、分析結果，以及用於預測路網旅行時間之方法。第四章節為模擬實驗，說明本論文之實驗方法、實驗步驟，以及實驗結果。第五章節為本論文之結論。



第二章 相關工作

2.1 數據分析

數據分析[8]指的是通過建立模型對數據進行核對、檢查、複算、判斷等操作，再將產生出來現實結果與理想結果相互比較，從中找出相異之處，以及造成上述結果發生之原因的過程，其目的是從一大批看來雜亂無章的數據中的信息集中找出所研究對象的內在規律，使之成為人可以使用和做出決策的信息。

在實際生活中，數據分析可幫助人們作出適當判斷和行動，例如對顧客在網購平台觀看的紀錄進行分析，找出顧客的購買習慣和興趣，以提升顧客購買的可能性，增加平台收益。又如，一個企業的領導人要通過市場調查，分析所得數據以判定市場動向，從而制定合適的生產及銷售計劃。由此可知，數據分析有極為廣泛的應用空間。

2.2 模糊理論

「概念」[6]是思維的基本形式之一，它可以客觀的表示事物的本質特征。在人類對事物的認識過程中，會把從事物上感覺到的特點抽象出來並加以概括，形成「概念」。例如從白雪、白馬和白紙等事物中，我們可以抽象出「白色」的「概念」。每個「概念」都有它的內涵和延伸，內涵是該概念所反映之事物本質的屬性，也就是概念的內容，而延伸是一個「概念」所覆蓋的範圍。例如「人」這個概念，它的內涵是能製造工具，並使用工具進行勞動的動物，而延伸則代表古今中外存在於地球上的所有人，不論地區、不論膚色、不論生死。

「模糊」是指某些概念的內涵部分相當清楚，但在延伸部分不夠清晰和明確，其界限容易受到人的主觀性的影響。以「青年」為例，我們知道這個概念想傳達的內涵，但我們無法很清楚的界定究竟哪個年齡區段的人可以被判斷為青年。

模糊理論的主旨是接受事物的模糊性，並試圖找出一方法將概念模糊之事物量化成電腦能處理之資訊。例如當我們用「十分鐘抵達目的地」這個問題詢問 100 個人時，我們很可能會得到 100 個不同的答案。然而從這些答案中，我們可以找出一個規律性。循著這個規律性，我們就可以得出下列結論。當所有人都認為「九分五十九秒」抵達目的地「沒有遲到」時，那麼在「九分五十九秒」之前到達目的地都「沒有遲到」；當一部分的人認為「十分五十九秒」抵達目的地「沒有遲到」時，「十分五十九秒」抵達目的地「可能沒有遲到」，不過需要其他資料佐證；最後，當所有人都不認為「十一分」抵達目的地「沒有遲到」時，「十一分」抵達目的地就無法代表「沒有遲到」。

2.3 類神經網路

類神經網路(artificial neural network)[15]，或譯為人工神經網路，是一種透過數學模型模仿生物神經網路之結構和功能的資訊處理系統，是一種非線性數據建模工具，常用於對輸入和輸出資料間的關係進行建模，或者用來探索數據的模式。

依照學習方法的不同，類神經網路可以分成以下四種類型：

1. 監督式學習網路(Supervised Learning Network)
2. 非監督式學習網路(Unsupervised Learning Network)
3. 聯想式學習網路(Associate Learning Network)
4. 最適化學習網路(Optimization Application Network)

類神經網路與人類的大腦一樣，需要透過學習才能知道如何解決問題。以監督式學習網路為例，要使得類神經網路能正確的運作，類神經網路必須經過訓練(training)，也就是學習的過程。在這個過程中，我們會使用訓練樣本(training pattern)作為輸入，並監督類神經網路的輸出，當輸出不符合輸入樣本的期望時，系統將自動進行內部修正，之後重新進行訓練，直到對於每個輸入都能正確對應到所需要的輸出為止。

類神經網路被認為是處理複雜且動態的問題最有效率的方法之一[16] [17]，因為它擁有自我學習的能力，並能將動態的因子結合進架構中[18] [19]。

模糊類神經網路為模糊理論與類神經網路結合而成的結果。透過模糊理論將許多不確定因素、感受因素、人為因素等傳統無法量化或衡量的項目化成電腦能處理之資訊後，再透過選定好的類神經網路進行學習，就可以建立起一套「專家系統」的架構[20]，作為推論、預測與決策的客觀依據。

2.4 KNN 應用於路段旅行時間預測

K-最近鄰法(K-Nearest Neighbor, KNN)是一個在分類工作上被廣為使用的方法，其概念為「屬於相同類別的資料有相似的特徵向量」。在分類開始之前，它必須要有一組「已知分類」的資料集，而在分類的過程中，它會去計算「未知分類」之資料特徵與這些「已知分類」之資料特徵的相似性，並找出 K 筆最接近該「未知分類」之資料的「已知分類」之資料，將這 K 筆資料的輸出值經過一連串的運算後，即為該「未知分類」之資料的預測值。

Altman[9]以單一屬性相似度量測的最近鄰點法為基礎，提出了多屬性的相似度量測(multivariate location estimators)和 K-最近鄰法(K-Nearest Neighbor, KNN)。

Smith、Demetsky(1997)[10]將四種不同的預測方法進行比較，分別為歷史平均法、時間序列法、類神經網路法和 K-NN 法。該研究之結果顯示，當歷史資料的數量足夠大時，K-NN 法的結果會比其他三種方法得到的結果要好，證明了 K-NN 為一個有效的預測方法。

Clark[11]除了預測流量之外，也使用 K-NN 法對其他交通資訊進行預測，如速度和佔有率。該研究除了將三種參數逐一進行預測測試，也使用三種參數的交叉排列進行預測測試。結果顯示，同時使用三種參數進行預測的預測結果誤差要小於其他使用兩種參數或單一參數進行預測的預測結果，證明在使用 K-NN 法進行預測時，採用越多的參數將會得到越精確的結果。

Rice、Zwet(2004)[12]選擇了另外兩種特徵來進行 K-NN 法的預測，一種是由偵測器所獲得的車輛速度，另一種則為旅行之時間。該研究將一固定時間範圍內

的資料作為向量計算相似度，最後再取最接近的 K 筆資料的輸出進行計算，得到旅行時間之預測結果。

Robinson、Polak(2005)[13]提出在建立 k-NN 模型時需要注意的四個條件，分別為特徵向量的選擇、建立適當的距離量度(distance metric)量測方式、決定用於預測時的資料數量(k 值)，以及利用加權法來減少誤差。

Chang(2006)[14]將旅行時間預測分成兩個階段，分別為旅行時間推估(estimation)與旅行時間預測(prediction)。在旅行時間推估階段，該模式會將偵測器所偵測到的即時交通資訊轉換為路段的旅行時間，以建立歷史旅行時間資料庫。而在預測的階段，偵測器所偵測到的即時交通資訊將會與歷史資料庫進行 k-NN 方法的比對，得到旅行時間之預測結果。

而在國內，蔡繼光(2009)[2]利用 k-NN 法，在一段固定時間中找出與高速公路偵測器所收集到的即時交通資訊(速度、流量)具有高相似度的電子收費系統之歷史交通資訊，並給予偵測器權重反應交通特徵差異，之後利用電子收費系統之資訊計算該歷史時間點之旅行時間，最後進行旅行時間預測。

國道高速公路局與交通大學(2013)[3]則改良 k-NN 法，在 k-NN 法的距離量度計算中加入門檻值，當該筆歷史資料的距離量度高於門檻值，則該歷史旅行時間資料將參與預測，反之則不參與，這種篩選提高精確度，但不一定能找到匹配資料，因此當所有的距離量度皆在門檻值外時，系統便利用事先校估完成之迴歸模式進行旅行時間預測。

2.5 類神經網路應用於路段旅行時間預測

在國內，張修榕(2001) [21]使用感應線圈偵測器蒐集車流速度及流量等交通特徵，並透過模擬的方式產生交通資料集，最後使用三層、完全連結及前向式的類神經網路架構，配合倒傳遞(feed-forward back propagation)的訓練方法，建立不同交通車流型態下的旅行時間預測模式。

許正憲(2006)[22]將真實事件、行車資料等資料來源整合成一交通資料集，並運用類神經網路進行模式建構與分析，得到準確的交通事故延時與旅行時間預測成果，證明了類神經網路在交通事故延時與旅行時間預測模式之適用性。

楊易哲(2017)[23]



第三章 研究方法

路網旅行時間預測之架構主要包含原始資料的前處理、旅行時間預測模型訓練、旅行時間預測模型測試，以及測試結果檢測，最後得出該路網之旅行時間預測結果，其架構如圖 3.1 所示。




圖 3.1 路網旅行時間預測之架構圖

3.1 應用之原始資料集

本研究總共使用了兩筆不同來源的資料集，其中有一筆為隨機生成之模擬資料集，另一筆則為中央研究院歷史語言研究所的中國驛站資料，詳細資料來源如表 3.1。

表 3.1 本研究使用之所有資料與資料來源

交通路網資料	資料來源
模擬路網資料	模擬路網資料產生器
中國驛站資料	中央研究院歷史語言研究所

3.1.1 模擬資料

模擬路網之資料為模擬資料產生器隨機生成之資料。該模擬資料產生器會隨機生成一定數量的資料點與相關的站點特徵(站點、地理高度)，而在本實驗中，我們使用了 400 個隨機生成的站點資料。資料格式如表 3.2。

表 3.2 模擬之站點資料

站點編號	站點經度	站點緯度	站點高度
1	81.4724	90.5792	-0.7460
2	91.3376	63.2359	-0.8049
...	...	...	...
400	58.8209	36.6157	0.6135

完成資料點的新增後，模擬資料產生器會依照一定的規則(該站點的邊數、站點與站點的最短距離)將資料點相連形成路段，形成一完整路網。為了讓模擬資料更逼近真實資料，模擬資料產生器會讓使用者輸入一個道路數量變數，以控制每個站點對外的通道數量。下面使用一個範例來說明模擬資料產生器如何產生一完整路網。

模擬資料產生器之生成範例如圖 3.2。在該範例中，總共生成 10 個資料站點，並將道路數量變數設為 5，那麼資料產生器在產生該站點之路段資料時，會隨機從選擇一個 1~5 的數字，作為該站點對外的路段數，之後依照條件尋找將要與它形成路段的其他站點。

站點 A 和站點 J 的道路數量變數為 1，在路網上只會有一條與它們連接的道路。站點 B、站點 D、站點 F、站點 H 和站點 G 的道路數量變數為 2 在路網上會有兩條與它們連接的道路。站點 C 的道路數量變數為 3，在路網上會有三條與它連接的道路。站點 E 的道路數量變數為 4，在路網上會有四條與它連接的道路。站點 I 的道路數量變數為 5，在路網上會有五條與它連接的道路。因為道路數量變數的最小值為 1，最大值為 5，因此模擬資料產生器不會產生路段數量低於 1 或高於 5 的站點。




圖 3.2 模擬路網產生器產生之範例路網

在決定好每個站點對外的路段數量後，模擬資料產生器會依照條件在其他站點中找出最適當的連接對象，並形成路段。路段之資料格式如表 3.3、表 3.4。

表 3.3 模擬之路段資料(道路數量變數為 2)

路段編號	路段起點編號	路段終點編號	路段距離	起訖點高度差
1	54	281	0.4314	-0.1963
2	54	255	3.0489	1.0308
...	...	...	...	...
399	123	84	1.8644	0.7808

表 3.4 模擬之路段資料(道路數量變數為 3)

路段編號	路段起點編號	路段終點編號	路段距離	起訖點高度差
1	98	157	3.1050	0.4808
2	157	243	3.6055	0.8127
...	...	...	...	...
399	76	364	8.5917	1.7203

最後，模擬資料產生器會搜尋整個路網，從中尋找任兩點間可能的訪問路徑，最後以該路徑隨機生成一到二十筆旅行資料。該旅行資料包含經過之路段與完成該路徑之旅行時間，路徑旅行時間為「經過之路段的旅行時間的總和」，路段之旅行時間的估算則是以兩點距離為基底，乘以兩個站點間地理高度差的權重值，最後取標準差 2 的高斯函數。路段之資料格式如表 3.5、表 3.6。

表 3.5 模擬之旅行資料(道路數量變數為 2)

路徑編號	路段一啟動碼	...	路段 399 啟動碼	旅行花費時間
1	0	...	0	53.6330
2	0	...	0	54.4012
...	...	...	...	...
79800	0	...	0	557.3717

表 3.6 模擬之旅行資料(道路數量變數為 3)

路徑編號	路段一啟動碼	...	路段 399 啟動碼	旅行花費時間
1	0	...	0	51.0128
2	0	...	0	419.5929
...	...	...	...	...
79987	0	...	0	313.4307

3.1.2 實際資料

古代中國驛站交通路網資料由中央研究院歷史語言研究所提供，該路網資料種類包括：

1. 中國明、清兩代之驛站座標資料
2. 中國清代之驛站路段資料
3. 中國清代之驛站旅行資料

3.1.2.1 中國明、清兩代之驛站座標資料

中國明、清兩代之驛站座標資料為中國明、清兩代已知的驛站座標，由於清代部分驛站座標資料以不可考，而清代之驛站大多繼承自明代之驛站，因此選擇用兩代之驛站作為研究之站點座標資料。驛站座標資料集包含「驛站 ID」、「驛站名稱」、「驛站經度」、「驛站緯度」。詳細資料如表 3.7。

表 3.7 中國明、清兩代之驛站座標資料(中央研究院歷史語言研究所)

ID	時代	驛站名稱	經度	緯度
A01.2	清	會同館	116.416588403	39.9165045953
A02	清	烏蠻驛	116.400017871	39.9052907006
...	...	...	...	...
G077	明	黃堡驛	112.872911039	27.2380521048

3.1.2.2 中國清代之驛站路段資料

中國清代之驛站路段資料集為中國清代驛站與驛站之間的行駛路段，資料集內容包含「路段距離」、「路段所屬路網」、「路段 ID」、「路線方向」、「路線種類」、「起訖點」。與其他資料集不相同的是，中國清代之驛站路段資料集的「起訖點」內容並不是能夠直接辨識驛站身分的「驛站 ID」，而是可能出現重複名稱的「驛站名稱」，因此在進行之後的資料處理時必須多加注意。詳細資料如表 3.8。

表 3.8 中國清代之驛站路段資料(中央研究院歷史語言研究所)

距離(華里)	所屬路網	ID	路線方向	路段種類	起訖點
70	a 京師、b 北直隸	a01.01	北京往山東	陸	會同館～固節驛
70	a 京師、b 北直隸	a01-02	北京往山東	陸	固節驛～涿鹿驛
...	...	...	...	...	...
	g 湖廣	g29.01	襄宇通衢	水	巴山驛～萬流水驛

3.1.2.3 中國清代之驛站旅行資料

中國清代之驛站旅行資料集為中國清代驛站與驛站間的旅行資料，資料集範圍涵蓋整個清代，資料集內容包含「旅行資料 ID」、「起點驛站名稱」、「起點驛站經度」、「起點驛站緯度」、「起點驛站名稱」、「終點驛站名稱」、「出發時間」、「到達時間」、「中國年分」、「西元年分」、「距離」。由於該資料集的兩個「起點驛站名稱」皆不是能夠直接辨識驛站身分的「驛站 ID」，因此必須透過「起點驛站經度」和「起點驛站緯度」進行驛站的比對。而在「終點驛站名稱」上，則必須透過驛站路段資料集之「起訖點」與「路段距離」進行比對。詳細資料如表 3.9。

表 3.9 中國清代之驛站旅行資料(中央研究院歷史語言研究所)

ID	驛站名稱	經度	緯度	起點	終點	出發時間	到達時間	中國年分	西元年分	距離
A04.2	和合驛	116.7	39.833	和合	張家灣	4.12 卯	4.13 巳	嘉靖 28 年	1549	76
A07	河西水驛	116.95	39.62	河西	和合	4.10 辰	4.11 未	嘉靖 28 年	1549	75
...	...	...	...	...	...	...	...	...	...	...
I76	魯橋驛	116.71	35.19	魯橋	南城	2.晦午	2.晦酉	嘉靖 28 年	1549	53

3.2 資料前處理

在使用上述之資料集進行旅行時間預測之前，我們勢必要先進行資料的分類和整理，這麼做的目的有幾個：

(1)確保資料之格式無異常，以中國驛站資料為例，若資料缺失時，則該位置將為空集合，空集合不屬於任何資料型態；

(2)確保資料符合我們之常識，以中國驛站資料為例，驛站與驛站之間的路程距離為 0，違反常識，應做例外處理；

(3)確保資料格式，以中國驛站資料為例，驛站 B 之預估到站時間為酉時(假設上一站驛站 A 之預估到站時間為申時)，則應將資料整理成「A 站點到 B 站點預計花費兩個小時」；

(4)確保資料之可用性，以中國驛站資料為例，該資料大多來自歷史文獻資料，資料缺失或異常時有所聞，為了避免這些資料影響到正常資料之預測結果，在進行路網旅行時間預測時必須將不穩定之資料從資料集中剷除掉。

因此，為了確保預測結果的準確性，在預測開始前我們將對資料進行「資料前處理」。「資料前處理」可以分成兩個部分，第一部分的「資料整理」是為了確保資料之完整性、正確性與可用性。第二部分的「資料轉換」則是為了讓這些資料集可以透過同一個預測方法進行預測，而將完成整理之資料集轉換成一個統一的應用格式。而在第一部分中，「資料整理」又可被細分為「資料編碼」、「資料清理」、「資料整合」。「資料前處理」之流程如圖 3.3 所示




圖 3.3 路網旅行時間預測之細部架構圖

3.2.1 資料編碼

在進行資料分析之前，我們首先要進行資料編碼。資料編碼的目的在於辨識內部特徵資料，以利使用者在處理過程中辨識該特徵欄位所代表的意義、資料型態、編號意義等。這個步驟解決上述問題中的(1)和(3)。

由於研究應用之資料集數量龐大，為了節省篇幅，本章節針對每個問題只選擇部分資料集做範例說明。

為了說明問題(1)，以下以中國驛站資料集為例。在中國驛站資料集中，可以依照資料集欄位之資料型態分成數值和字串兩種類別。「距離」、「經度」、「緯度」、「西元年份」等特徵為數值資料型態，「ID」、「驛站名稱」、「所屬路網」、「路線方向」、「路線種類」、「起訖點」、「起點」、「終點」、「出發時間」、「到達時間」、「中國年份」等特徵則為字串資料型態。

而依照資料型態的不同，本論文重新定義了缺漏資料的編碼。不論是數值型態或是字串型態的特徵，只要該筆資料的特徵不存在，該特徵欄位會以空格表示。為了讓我們更好的進行資料分析，將對缺漏的資料進行編碼。當「距離」、「經度」、「緯度」、「西元年份」等數值型態之特徵出現缺漏時，我們將空格重新編碼為數值“0”，如表 3.10。

表 3.10 中國清代之驛站路段_數值型態資料補值

距離(華里)	所屬路網	ID	路線方向	路段種類	起訖點
0	a 京師、b 北直隸	a01.11	北京往山東	陸	東光驛～安德馬驛
0	a 京師、b 北直隸	a04-05	北京往山西(北路)	陸	上陳驛～香山馬驛
...	...	...	...	...	...
0	g 湖廣	g29.01	襄宇通衢	水	巴山驛～萬流水驛

當「ID」、「驛站名稱」、「所屬路網」、「路線方向」、「路線種類」、「起訖點」、「起點」、「終點」、「出發時間」、「到達時間」、「中國年份」等字串型態之特徵出現缺漏時，我們將空格重新編碼為字串” loss”，如表 3.11。

表 3.11 中國清代之驛站旅行資料_字串型態資料補值

ID	驛站名稱	經度	緯度	起點	終點	出發時間	到達時間	中國年分	西元年分	距離
D020-3	淮陰驛	119.1413	33.50321	淮陰	閘前	2.5 寅	2.5	嘉靖 27 年	1548	39
D029	界首驛	119.4238	33.00303	界首	安平	1.29	1.29 未	嘉靖 27 年	1548	37
...	...	...	...	...	...	...	...	...	...	...
I28	崇武水驛	115.9888	36.44822	崇武	清陽	3.14	3.15 卯	嘉靖 28 年	1549	58

為了說明問題(3)，以下以中國驛站資料為例。中國驛站資料之「出發時間」與「到達時間」為文獻紀錄之旅行時間。然而該資料的定義與我們定義之「路段旅行時間」並不相同。其次，該資料之「出發時間」和「到達時間」是以「時辰」為單位，想要精確定義時間有所困難，因此本研究統一以「時辰」(兩個小時)為單位進行換算。



3.2.2 資料清理

在完成資料編碼後，我們將進行第二步的資料清理。資料清理的目的在於清除資料中異常或缺失的部分，以避免這些資料影響到其他正常的資料，進而造成重建結果的誤差。這個步驟解決上述問題中的(2)和(4)。

為了說明問題(2)，以下以中國驛站資料為例。中國驛站路段資料中的「距離」來自文獻與實際考察等資料，然而部分資料缺漏導致空集合，並在上一步驟中接受補值為 0，驛站與驛站之間的距離為 0，不符合常識。然而現階段並沒重建這些資訊的方法，因此這些異常之資料將無法投入訓練，避免異常資料影響到正常資料之預測。

為了說明問題(4)，以下以中國驛站資料集為例。在中國驛站資料中，驛站與路線是最重要的資料，然而這些旅行資料大多來自文獻資料，當文獻資料不夠完整時，將會導致旅行資料出現缺漏。現階段我們並沒有方法可以彌補缺漏的資料，因此只能採取剔除的辦法，以避免缺漏資料影響到其他完整資料，最後導致重建結果不符合預期結果。

除此之外，中國驛站資料中還存在其他問題。

在驛站站點資料中，透過「ID 名稱」可以確實找出每一個驛站點，然而在使用「驛站名稱」時，出現名稱相同但 ID 不同、位置不同的驛站點，如表 3.12。我們將這些重複的資料特別取出，作為整合時必須注意的問題。

表 3.12 驛站名稱重複之驛站點

驛站名稱	重複 ID	重複 ID
會同館	A01.2	C01
烏蠻驛	A02	C02
...	...	...
松林驛	R038	M025

在驛站路線資料中，透過「ID 名稱」可以確實找出每一條路徑資料。為了找出與路徑相關的驛站點，我們將驛站資料和路線資料中的起訖點做比較和整合。結果發現，起訖點使用的是驛站資料可能重複的「驛站名稱」，而不是能確實找出每一個驛站點的「ID 名稱」，造成無法找出正確的驛站點連成路線。另外，路線資料只記錄了起點和終點，當路網過於龐大和複雜時，我們無法決定該筆路線資料的移動路徑，因此難以整理成模型之輸入資料，如表 3.13。

表 3.13 因驛站名稱重複而無法辨識之路段資料(部分剔除)

距離(華里)	所屬路網	ID	路線方向	路段種類	起訖點
70	a 京師、b 北 直隸	a01.01	北京往山東	陸	會同館～固 節驛
70	a 京師、b 北 直隸	a08-02	北京往遼東	陸	潞河水馬驛 ～三河驛
...	...	...	...	...	...
70	r 雲南	r02.07	雲南往四川 (經曲靖府)	陸	松林驛～炎 方驛

最後是距離問題，有些路線沒有路線距離，無法蒐集到訓練模型時必要的距離資訊，如表 3.14。

表 3.14 缺乏路徑距離訊息之路段資料(剔除)

距離(華里)	所屬路網	ID	路線方向	路段種類	起訖點
0	a 京師、b 北 直隸	a01.11	北京往山東	陸	東光驛～安 德馬驛
0	a 京師、b 北 直隸	a04-05	北京往山西 (北路)	陸	上陳驛～香 山馬驛
...	...	...	...	...	...
0	g 湖廣	g29.01	震字通衢	水	巴山驛～萬 流水驛

3.2.3 資料整合

在完成資料清理後，我們將進行第三步的資料整合。資料整合的目的在於整合所有資料，找出可以被用於進行路網旅行資料預測的資料集。

在本小節中，我們將以中國驛站資料集為例進行說明。經過編碼和清理後，我們可以將剩下的資料進行整合和揀選，最後獲得一個完整的驛站路段資料集。該路段資料具有「ID」、「上游驛站點 ID」、「上游驛站點 ID」、「下游驛站點 ID」、「路線方向」、「所屬路網」、「路段種類」、「路線距離(華里)」等特徵。詳細資料如表 3.15。

表 3.15 模型之輸入資料集

ID	上游驛站 點 ID	下游驛站 點 ID	路線名稱	所屬路網 區預	路段種類	路線距離 (里)
1	A04-2	A07	運河水路	a 京師、b 北直隸	水	70
2	B24	B22	運河水路	a 京師、b 北直隸	水	90
...	...	...	...	...	...	...
116	I75	I76	震宇通衢	山東	水	53

3.2.4 格式轉換

在前處理的最後一個步驟，我們必須將完成資料編碼、清理和整合的資料進行格式轉換，使這些資料集能夠簡單的應用在該交通路網旅行時間預測方法上。

以下我們將用一個簡單的範例來做說明。

今天在透過上述之資料整理後，我們找出了 5 個點(點 A、點 B、點 C、點 D、點 E)，以及連接點 A 和點 C 的邊甲、連接點 B 和點 C 的邊乙、連接點 B 和點 E 的邊丙和連接點 C 和點 D 的邊丁，同時每個邊上還具備若干特徵(道路種類、距離等)，如圖 3.3 中的路網圖。

之後我們將蒐集該路網的旅行資料，這些旅行資料將會是我們用來進行旅行時間預測之資料集。旅行時間預測之資料集通常會說明該旅次之路徑，以及完成該旅次所花費的時間。以上述的路網為例，假設今天有一旅次資料在起點記錄點 A，在迄點記錄點 E，在旅行時間記錄了 100 分鐘，那麼我們就知道該旅次從點 A 到點 E 花了 100 分鐘，如圖 3.3 中的旅行資料。

然而這樣的資料格式無法用於旅行時間的預測，因此必須將旅行資料轉換成另一種編碼格式。該編碼格式由路段資料所組成，除了原本的路段特徵外，還額外的增加了一個「啟動碼」特徵。以上述之旅次資料為例，從點 A 到點 E 經過了邊甲、邊乙和邊丙，因此這三個邊的「啟動碼」特徵應該為 1，而沒有經過之邊丁的「啟動碼」特徵則應該為 0。如圖 3.4 中的編碼格式。




圖 3.4 格式轉換之說明範例圖(a)正常資料之路網圖架構(b)符合該路網架構之旅行資料(c)轉換格式後的旅行資料

3.3 路線與旅行時間相關之模型

路線與旅行時間之相關模型主要是藉由「是否經過該路段的啟動碼」 o ，以及單個或多個「影響該路段旅行時間的參考條件」 c ，來推估「路網中任意兩點的旅程所需要的時間」 t 。以上述圖 3.3 之資料為例，「是否經過該路段的啟動碼」 o ，「該路段的路段種類」 y ，以及「該路徑的距離」 d 將作為相關模型之輸入，而「該路網中任兩點的旅程所需要的時間」 t 則為相關模型之輸出。

為了達成這個目的，本研究使用兩個步驟來完成此模型。以上述圖 3.3 之資料為例，首先在第一步驟，我們會先決定「影響該路段旅行時間的參考條件」(為預測模型的輸入資料)以及「該路段之旅行時間」(為預測模型的期望輸出資料)，並將整理好的輸入和輸出資料集進行正規化，最後將整個資料集分割成訓練資料集與測試資料集。而在第二步驟，我們將透過模糊類神經網路(Fuzzy Neural Network, FNN)來進行路網旅行時間的學習和預測。為了盡可能模擬現實的狀況，我們將讓模型依照不同標準將資料分割成不同的模式，並且每種模式都使用一個模糊類神經網路進行路網旅行時間的學習和預測。在每個 FNN 的架構中，其輸入將會是 o ， y ，以及 d ，輸出則是 t 。在 FNN 的演算法中，總共可以分成兩個子步驟，分別是 FNN 的訓練演算法與測試演算法。第一個子步驟為訓練演算法，主要使用訓練資料，該演算法的目的是透過這些訓練資料讓 FNN 學習相關的旅行時間。而第二個子步驟為測試演算法，主要使用測試資料，該演算法的目的是透過觀察測試資料輸入 FNN 後獲得的旅行時間結果，驗證模型的可用性。

3.3.1 資料之正規化(Normalization)

資料正規化，或稱數據標準化，是指研究、制定和推廣統一的數據分類分級、轉換和編碼等技術的過程。資料正規化在統計學上經常被用來消除資料上不同屬性的不齊性，或者是為了限制資料的範圍，例如將資料寬度限制在〔0,1〕之間。

在類神經網路上，通常會有一個或多個輸入，最後產生一個或多個輸出，每一個輸出都是相關輸入總和的非線性函數。為了計算相關輸入的總合，在資料集進入類神經網路之前，必須將輸入資料之屬性轉換成可以彼此互相比較並加權的數值。例如當其中一個輸入屬性為「路段種類」，可能的值為「國道」和「省道」，另一個輸入屬性為「路段行進方向」，可能的值為「順向」和「逆向」，則兩個屬性的值無法直接比較，因此必須將兩種屬性進行編碼，並將資料寬度限制在〔-1,1〕之間，讓加權可以計算。最後當類神經網路輸出時，輸出結果也會是一個或多個一般小數位數，必須再經過編碼才能將輸出結果恢復成初始屬性。

以本研究中的中國驛站資料為例，輸入資料「是否經過該路徑的啟動碼」 o ，「該路徑的距離」 d ，「該路段的 hop 距離」 h ，以及輸出資料「中國驛站任兩點間的旅程所需要的時間」 t 皆為數值資料，因此不需要重新編碼，只需要統一正規化到數值範圍〔-1,1〕之間，正規化之數學表示式為：

$$y = \frac{(x - x_{\min}) \times (Range_{\max} - Range_{\min})}{x_{\max} - x_{\min}} + Range_{\min} \quad (1)$$

其中 x 為正規化的輸出結果， y 為輸入的數值。 $x_{\max}$ 和 $x_{\min}$ 分別為該屬性資料集中的最大值和最小值。 $Range_{\max}$ 和 $Range_{\min}$ 則分別為正規化範圍的最大值和最小值。

3.4 Fuzzy Neural Network

在本研究的模型中，將上述小節中所劃分出的每份分割資料都視為一個獨立事件。每份分割資料將有一個專屬的 FNN 來學習及模擬路線與旅行時間的關係。假設所有資料依比例分成 n 種分割方式，則會用 n 個 FNN 來進行所有資料的模擬。對每個 FNN 而言，他們接受各路線(假設有 m 條路段)所提供的啟動碼 $o1$ 、 $o2$ 、...、 om ，距離 $d1$ 、 $d2$ 、...、 dm ，以及該路段的 hop 距離 $h1$ 、 $h2$ 、...、 hm 作為輸入，接著，這些 FNN 將輸出每個類別的旅行時間 $t1$ 、 $t2$ 、...、 tn 。

而除了上述的架構外，我們仍需要一個演算法來完成路線與旅行時間相關的模型。此演算法將透過各訓練資料集之訓練資料訓練相對應的 FNN，讓這些 FNN 能夠模擬其專屬路線與旅行時間關係。FNN 之訓練過程如圖 3.5 所示。




圖 3.5 FNN 之訓練演算法

首先，FNN 會將不同的輸入參數 $o(k)$ 、 $d(k)$ 、 $h(k)$ 與當下的權重參數 $v(k)$ 進行運算，推算該路線當下的旅行時間 $dt(k)$ 。之後將推算出來的 $dt(k)$ 與實際的理想數值 $t(k)$ 進行比較，而 $dt(k)$ 與 $t(k)$ 的誤差將被拿來調整 FNN 內部的權重參數 $v(k)$ ，並獲得應用於下一筆訓練資料的權重參數 $v(k+1)$ ，使其能更貼切的模擬該路網的旅行時間。以下將分別介紹 FNN 的架構與演算法。

3.4.1 FNN 的結構

FNN 是由模糊邏輯與類神經網路結合而成。該架構讓 FNN 不但擁有模糊邏輯中所強調的「模糊描述方式」，更具備類神經網路從案例進行學習的能力，使 FNN 適用於本研究之路線與旅行時間相關模型。

FNN 的架構主要分為四層，分別為 Input Layer、Membership Layer、Rule Layer 和 Output Layer，如圖 3.6 所示。




圖 3.6 FNN 之架構

以中國驛站資料為例，當訓練開始時，啟動碼、距離、hop 等資訊會透過第一層的 Input Layer 進入網路，並在 Input Layer 進行資訊整合後傳遞至第二層的 Membership Layer。Membership Layer 在收到資料後，會藉由多個高斯函數來模糊並描述路段資訊，並將該敘述傳遞至第三層的 Rule Layer。接著，Rule Layer 將根據此敘述來判斷 FNN 該對此敘述做何種反應，並將結果傳遞至第四層的 Output Layer。最終，Output Layer 將整合這些反應，並決定 FNN 的輸出值。

以下將詳細介紹 FNN 的每層實現方式。為了簡化討論，首先定義 FNN 第 j 層第 i 個節點的輸入值及輸出值為 u_j^i 和 o_j^i 。

Layer 1: Input Layer. 本層節點將會結合輸入的路段資訊，輸出該路段的特徵資料至第二層。因此，此層的第 i 個節點的數學表示式為：

$$o_i^1 = pw_i^1 \times u_i^1 \quad (2)$$

其中 pw_i^1 為 1×3 的權重矩陣， u_i^1 是由輸入的三個輸入值組成的 3×1 資料矩陣。

Layer 2: Membership Layer. 本層節點首先結合來自前一層的輸入資訊，接著節點們將使用高斯函數(Gaussian function)來將輸入資訊轉為「模糊的敘述」。其第 i 、 j 個節點可表示為：

$$o_{ij}^2 = \exp \left\{ -\frac{(o_i^2 - m_{ij})^2}{(\sigma_{ij})^2} \right\} \quad (3)$$

其中， m_{ij} 和 σ_{ij} 是高斯函數的平均值及標準差。

Layer 3: Rule Layer. 此層節點採用了「AND」方式來整合上一層所傳遞而來的模糊資訊，其整合方式如下所示：

$$o_i^3 = \prod u_i^3 \quad (4)$$

Layer 4: Output Layer. 本層節點為 FNN 的最後一層。本層主要負責解模糊化的過程。前一層的模糊資訊傳遞至此層後，會透過一個線性組合的方式來解模糊化，並輸出 FNN 最終的結果。其數學式子為：

$$o_j^4 = \sum_i^m u_{ij}^4 w_i^4 \quad (5)$$

最後，在整合式子(1)至(4)後，可以將 FNN 以式子(5)表示。其中， x 與 y 分別為 FNN 的輸入與輸出。

$$y_m = t = \sum_i^m w_{mi}^4 \prod_{i=1}^n \exp \left[-\frac{(x_i - m_{ij})^2}{(\sigma_{ij})^2} \right] \quad (6)$$

3.4.2 FNN 之訓練演算法

介紹完 FNN 的架構之後，後面將依據此架構來推導 FNN 的訓練演算法。此演算法能夠透過調整 FNN 內的參數來使 FNN 更進一步的逼近本研究內的路線與旅行時間相關模型。要推導此演算法，主要是以第三章的式子(2)至式子(5)為基底，並採用倒傳遞的方法來推算各個參數的訓練公式。在 FNN 中，主要有五個參數需要在訓練時被調整。分別是輸入與第一層的權重值 pw 、第一層與第二層間的權重值 w 、第二層高斯函數的平均值與標準差 m, σ ，以及第四層的 v 。該五筆參數之訓練數學式推導如下所示。

首先，FNN 的訓練演算法應以降低以下的單維輸入單維輸出的錯誤函數為主要目標。

$$E(w, k) = \frac{1}{2} (yd(k) - y(k))^2 = \frac{1}{2} e(k)^2 \quad (7)$$

其中， $e(k) = yd(k) - y(k)$ ，且為 FNN 的理想輸出與實際輸出。以下使用 v 來做為 FNN 內的權重的總稱，包含了 pw, w, m, σ ，其參數調整公式則為：

$$v(k+1) = v(k) - \xi \left(\frac{\partial E}{\partial v} \right) \quad (8)$$

其中， $\partial E / \partial v$ 代表了參數 v 對於誤差 E 的影響。也因此將原本的參數值 $v(k)$ 減掉 $\partial E / \partial v$ 後，新得到的參數 $v(k+1)$ 將能夠比原本的參數 $v(k)$ 降低許多誤差。而 ξ 則為參數的 learning rate，主要控制了調整誤差的比率，通常則落於 0 到 1 之間。

以下根據式子(6)及(7)來推導 FNN 的訓練演算法。首先是高斯函數的平均值 m 。依據式子(7)， m 的參數調整公式為：

$$m(k+1) = m(k) - \xi \left(\frac{\partial E}{\partial m} \right) \quad (9)$$

而根據式子(2)~式子(4)計算後， $\partial E / \partial m$ 為：

$$\frac{\partial E}{\partial m} = -ew \prod o^2 \frac{1}{\sigma} \quad (10)$$

也因此， $m(k)$ 的參數調整公式為：

$$m(k+1) = m(k) - \xi ew \prod o^2 \frac{1}{\sigma} \quad (11)$$

接著採用相同的概念來推導高斯函數標準差 σ 的調整公式。 σ 的調整公式為：

$$\sigma(k+1) = \sigma(k) - \xi \left(\frac{\partial E}{\partial \sigma} \right) \quad (12)$$

$\partial E / \partial \sigma$ 則為：

$$\frac{\partial E}{\partial \sigma} = -ew \prod o^2 \left[\frac{o^1 - m}{\sigma^2} \right] \quad (13)$$

也因此， $\sigma(k)$ 的參數調整公式為：

$$\sigma(k+1) = \sigma(k) + \xi ew \prod o^2 \left[\frac{o^1 - m}{\sigma^2} \right] \quad (14)$$

之後以倒傳遞演算法來推導第一層與第二層之間的權重值 w 和第一層的權重值 pw ，獲得 w 的參數調整公式為：

$$w(k+1) = w(k) + \xi eo^3 \quad (15)$$

以及 pw 的參數調整公式為：

$$pw(k+1) = pw(k) + \xi eo^3 \quad (16)$$

藉由上述的公式將可分別調整第一層的權重值 pw ，第一層與第二層間的權重值 w 以及第二層高斯函數的平均值與標準差 m, σ ，進而讓 FNN 學習到路線與旅行時間的關係。而這也完成了 FNN 的訓練演算法。



3.4.3 FNN 之測試演算法

FNN 的測試演算法主要是以式子(2)至式子(6)為主。測試演算法的目的在於驗證完成訓練的預測模型的表現是否符合應用標準。

原始資料集在訓練開始之前會被分成訓練資料集和測試資料集兩個部分。訓練資料集用於訓練預測模型，測試資料集則用於驗證完成訓練的預測模型。在訓練階段，訓練資料集會被投入 FNN，與式子(2)至式子(6)內的權重 v 進行運算並計算誤差，最後透過式子(7)至式子(16)對 FNN 內的權重 v 進行調整。完成訓練後，測試資料集將會被投入這個擁有調整好的權重 v 的 FNN，在經過式子(2)到式子(6)的運算後，將可以獲得測試資料集的預測旅行時間 t 。最後，測試資料集的預測結果將與理想結果做比較，並計算其誤差，以評量該預測模型是否符合應用標準。

第四章 應用實驗

本章節將介紹本研究之模擬實驗。本研究使用了一種模擬路網資料和一種實際路網資料來實行路網旅行時間預測。模擬路網之資料為模擬資料產生器自動生成之資料，實際路網資料則為中國驛站資料。

本研究使用之路網資料在經過資料前處理後，將依照一定比例分割成訓練資料集與測試資料集，之後將各資料之訓練資料集分別投入對應之 FNN 中進行訓練，之後以各資料之測試資料集測試對應之 FNN 的訓練結果，並觀察該預測結果與實際路網旅行時間資料的差異，以及該預測結果是否達到應用之標準。

4.1 模擬路網之旅行時間預測

本實驗使用之模擬路網資料集為模擬資料產生器隨機生成之資料。該模擬資料產生器會依照輸入的參數建立路網，並自動生成路網旅行時間資料。為了驗證旅行時間之預測模型，本實驗透過模擬資料產生器產生了五組路網資料集。之所以使用模擬資料進行旅行時間預測，是因為中研院提供之實際資料未臻完整，因此必須透過模擬路網之完整資料來驗證模型之預測能力。為了讓實驗更加完整，本研究提出了一個路網複雜度的定義。該定義的目的是比較不同路網之間的複雜度高低。路網複雜度的計算方法為該路網中所有站點的對外道路的平均值。

在這五組模擬路網資料集中，路網 A 之路網複雜度較低，路網 B 之路網複雜度最貼近中國驛站資料，路網 C、路網 D、路網 F 之路網複雜度則較高。路網複雜度的判斷是以位於該路網中的所有。本實驗透過使用上述之路網資料集進行旅行時間預測來模擬該方法在不同的路網複雜度下的預測行為，並觀察該方法在預測不同複雜度之路網時的穩定性和可靠性。

五個模擬路網之資料如下：

路網 A：400 個站點數量，每個站點具有 1 到 2 個通道，共 399 個路段，每個路段有 3 種預測特徵，共 874529 筆路網旅行資料。路網圖如圖 4.1。




圖 4.1 路網 A 之路網圖

路網 B：400 個站點數量，每個站點具有 1 到 3 個通道，共 399 個路段，每個路段有 3 種預測特徵，共 879987 筆路網旅行資料。路網圖如圖 4.2。




圖 4.2 路網 B 之路網圖

路網 C：400 個站點數量，每個站點具有 1 到 4 個通道，共 922 個路段，每個路段有 3 種預測特徵，共 1607132 筆路網旅行資料。路網圖如圖 4.3。




圖 4.3 路網 C 之路網圖

路網 D：400 個站點數量，每個站點具有 1 到 5 個通道，共 1127 個路段，每個路段有 3 種預測特徵，共 1720230 筆路網旅行資料。路網圖如圖 4.4。




圖 4.4 路網 D 之路網圖

路網 E：400 個站點數量，每個站點具有 1 到 6 個通道，共 1317 個路段，每個路段有 3 種預測特徵，共 2072467 筆路網旅行資料。路網圖如圖 4.5。




圖 4.5 路網 E 之路網圖

五個路網之比較如表 4.1。

表 4.1 模擬路網之比較

	站點數量	最大邊數	路段數量	資料筆數
路網 A	400	2	399	874529
路網 B	400	3	399	879987
路網 C	400	4	922	1607132
路網 D	400	5	1127	1720230
路網 E	400	6	1317	2072467



在開始進行路網旅行時間預測之前，有兩個參數必須先決定，一個是學習速率，一個是循環週期(Epoch)。在學習速率上，所有進行路網旅行時間預測的類神經網路皆為 0.01。

循環週期(Epoch)為訓練資料循環投入類神經網路進行訓練的次數，當循環週期(Epoch)為 1 時，代表訓練資料會循環投入類神經網路進行訓練一次。之所以要決定訓練過程的循環週期(Epoch)，目的是為了避免過度訓練(over fitting)的問題，過度訓練(over fitting)會使類神經網路只記下了訓練資料的學習結果，卻沒有建立非線性映射關係。

因此為了決定類神經網路的循環週期(Epoch)，我們選擇路網 E 之資料做為訓練對象投入類神經網路。我們使用路網 E 之所有旅行資料進行訓練，並調整學習速率為 0.01，Max Epoch 為 1000，每一次循環後計算其誤差值(MSE)與誤差變化量(該次誤差值與上一次誤差值的變化比例)，並觀察其趨勢變化。如圖 4.6。該圖之 X 軸為誤差變化量，Y 軸為 Epoch 的次數。由圖中我們可以發現預測值的誤差變化量在第 7 個 Epoch 後並沒有顯著的下降幅度，因此我們認為 7 個 Epoch 是最適合模擬資料進行預測訓練的循環次數。




圖 4.6 模擬路網 Epoch 實驗之誤差變化量

決定好 Epoch 數後，接下來將針對五個模擬路網進行路網旅行時間預測。在實驗的過程中，我們將依照不同比例將原始資料集分割成訓練資料集與測試資料集，並進行旅行時間預測，觀察不同比例的分割方式對預測表現和預測效率的影響。我們一共使用了五種不同比例的分割方法，其訓練資料集與測試資料集的比例分別為 9：1，8：2，7：3，6：4，5：5，詳細資料如表 4.2。

表 4.2 模擬路網之訓練資料集與測試資料集分割結果

	9-1		8-2		7-3		6-4		5-5	
路網 A	(787076	87453)	(699623	175106)	(612170	262359)	(524717	349812)	(437264	437265)
路網 B	(791988	87999)	(703989	175998)	(615990	263997)	(527992	351995)	(439993	439994)
路網 C	(1446419	160713)	(1285706	321426)	(1124992	482140)	(964279	642853)	(803566	803566)
路網 D	(1548207	172023)	(1386184	334046)	(1204161	516069)	(1032138	688092)	(860115	860115)
路網 E	(1865220	207247)	(1657974	414493)	(1450727	621740)	(1243480	828987)	(1036234	1036233)

完成資料集的分割後，依序將五個路網資料集之不同比例的訓練資料集分別投入學習速率為 0.01，Epoch 數為 7 的模糊類神經網路進行訓練，並在訓練結束後將相應的測試資料集投入訓練完畢的預測模型中進行旅行時間預測，以驗證訓練成果。其結果如圖 4.7。圖 4.7 為各路網各訓練資料比例之預測模型於驗證階段的表現。圖 4.7 之 X 軸為預測結果與實際結果的平均誤差值，單位為秒，Y 軸則為資料分割的比例。

在該實驗中，路網 A 與路網 B 的平均誤差值變化在訓練資料集與測試資料集之比例為 9：1，8：2 和 7：3 時較為穩定，然而在訓練資料集與測試資料集之比例為 6：4 和 5：5 時，平均誤差值的增加幅度較大。造成這個現象的原因在於訓練資料集的減少。因為參與訓練的訓練資料集減少，部分路段沒有充足的資料樣本數可以學習，最後在使用測試資料集對訓練完成的預測模型進行驗證時得到了較差的預測表現。該現象證明當路網 A 與路網 B 的訓練資料小於整體資料的百分之七十時，預測結果將不再可靠。

路網 C、路網 D 和路網 E 的平均誤差值變化在訓練資料集與測試資料集之比例為 9：1 和 8：2 時較為穩定，然而在訓練資料集與測試資料集之比例為 7：3，6：4 和 5：5 時，平均誤差值的增加幅度較大。造成這個現象的原因在於訓練資料集的減少。因為參與訓練的訓練資料集減少，部分路段沒有充足的資料樣本數可以學習，最後在使用測試資料集對訓練完成的預測模型進行驗證時得到了較差的預測表現。該現象證明當路網 C、路網 D 和路網 E 的訓練資料小於整體資料的百分之八十時，預測結果將不再可靠。




圖 4.7 各路網各訓練資料比例之預測模型於驗證階段的表現

依照上述的實驗結果，五種模擬資料能夠被分成兩個類別。路網 A 和路網 B 屬於類別一，路網 C、路網 D 和路網 E 屬於類別二。這兩個類別將進行比較。

在預測成本上，類別一的路網只需要全部旅程資料的百分之七十做為訓練資料，就可以得到一個穩定且可靠的預測模型。類別二的路網則需要全部旅程資料的百分之八十做為訓練資料，才可以得到一個穩定且可靠的預測模型。造成這個現象的原因在於路網複雜度的差異。因為該預測模型必須透過經過該路段的路徑旅行資料進行旅行時間預測，因此如果在訓練過程中出現某些路段完全沒有被路徑旅行資料使用到時，該預測模型將無法學習到這些路段的旅行時間。

在該實驗中，類別一的路網較為簡單，減少訓練資料的比例不容易發生某些路段在訓練過程中無法被該預測模型學習的情況，因此能夠用較低比例的訓練資料集得到一個穩定且可靠的預測模型。類別二的路網則因為較為複雜，減少訓練資料的比例容易發生某些路段在訓練過程中無法被該預測模型學習的情況，因此必須使用較高比例的訓練資料集才能得到一個穩定且可靠的預測模型。

在效率方面，我們依序將五個路網資料集之不同比例的訓練資料集分別投入學習速率為 0.01，Epoch 數為 7 的模糊類神經網路進行訓練，並記錄其完成預測模型訓練所花費的時間，其結果下圖 4.8。

圖 4.8 為五組路網資料集在不同比例之分割結果下的預測時間成本比較圖。該圖之 X 軸為時間，單位為小時，Y 軸為訓練資料集與測試資料集的分割比例。由圖中我們可以發現，不同路網在相同分割比例下，資料集的數量越大，所花費的訓練時間成本越大。而相同路網在不同分割比例下，訓練資料集的比例越高，所花費的訓練時間成本越大。




圖 4.8 模擬路網資料集之預測時間成本比較圖

從上述的模擬路網資料集預測實驗中，可以觀察到當路網之訓練資料集佔整個資料集的比例越高時，路網旅行時間的預測結果將越準確，不過相對的，越多的訓練資料代表訓練的時間成本也越高。

該模型在處理簡單路網上有較好的穩定性。路網 A 和路網 B 在資料分割比例從 9：1 改變至 7：3 時，平均誤差值的數值的增加幅度都相當微小，到了 6：4、5：5 才有明顯的增加幅度。而在處理較複雜的路網 C、路網 D 和路網 E 時，隨著每次資料分割比例的變化，都可以觀察到一定程度的平均誤差值的數值的增加幅度，證明該模型在面對複雜路網時，預測結果容易出現波動。

該模型的預測時間成本受到訓練資料的數量和路網複雜度的影響。訓練資料的數量越多，該模型就必須花費越多的時間進行訓練。路網複雜度的高低代表每次訓練時投入該模型的輸入參數的多寡。當路網複雜度越高，每次訓練時投入該模型的輸入參數就越多，當輸入的參數越多，模型的計算量也會隨之增加，進而造成時間成本的增加。

4.2 實際路網資料之旅行時間預測

中國驛站資料包含 217 個站點數量，165 個路段，每個路段擁有 3 種預測特徵，以及共 4673 筆路網旅行資料。路網圖如圖 4.9。在該圖中，紅點為資料遺失之驛站站點(該驛站站點在旅行資料中不曾被使用，或是相關之路段資料遺失)，藍點為資料齊全之驛站站點(該驛站站點在旅行資料中被使用，而且相關之路段資料沒有遺失)。藍色實線部分為則是依照路段之起迄點資料相連後的結果。在這個過程中，路網圖上出現部分站點連接到異常位置的站點(圖中明顯跨區的藍色實線)，該現象證明重複之驛站名稱資訊的確會對資料的判讀和旅行時間的預測造成影響。因為現階段並沒有恢復這些路段資料的方法，因此這些資料將在進行旅行時間預測之前予以剔除。




圖 4.9 中國驛站資料之路網圖

同樣的，我們必須透過循環選擇實驗來決定訓練時的 Epoch 數。我們使用所有驛站旅行資料進行訓練，並調整學習速率為 0.01，Max Epoch 為 1000，每一次循環後計算其誤差值(MSE)與誤差變化量(該次誤差值與上一次誤差值的變化比例)，並觀察其趨勢變化。如圖 4.10。該圖之 X 軸為誤差變化量，Y 軸為 Epoch 的次數。由圖中我們可以發現預測值的誤差變化量在第 7 個 Epoch 後下降幅度大幅縮小，甚至開始出現重複，因此我們認為 7 個 Epoch 是最適合中國驛站資料進行預測訓練的循環次數。




圖 4.10 中國驛站路網 Epoch 實驗之誤差變化量

依照不同比例將原始資料集分割成訓練資料集與測試資料集，並將進行旅行時間預測，觀察不同比例的分割方式對預測表現和預測效率的影響。我們一共使用了 9 種不同比例的分割方法，其訓練資料集與測試資料集的比例分別為 9：1，8：2，7：3，6：4，5：5，4：6，3：7，2：8，1：9，詳細資料如表 4.3。

表 4.3 中國驛站路網之訓練資料集與測試資料集分割結果

	9-1		8-2		7-3		6-4		5-5	
中國驛站路網	(4206	467)	(3818	855)	(3271	1402)	(2804	1869)	(2337	2336)
	4-6		3-7		2-8		1-9			
中國驛站路網	(1869	2804)	(1402	3271)	(855	3818)	(467	4206)		

完成資料集的分割後，依序將中國驛站路網資料集之不同比例的訓練資料集分別投入學習速率為 0.01，Epoch 數為 7 的模糊類神經網路進行訓練，並在訓練結束後將相應的測試資料集投入訓練完畢的預測模型中進行旅行時間預測，以驗證訓練成果。其結果如圖 4.11。圖 4.11 為中國驛站路網各訓練資料比例之預測模型於驗證階段的表現。其 X 軸為平均誤差值，單位為時辰，Y 軸為資料分割的比例。從圖 4.11 中可以觀察到隨著訓練資料集的比例逐漸減少，平均誤差值的數值不斷提高。中國驛站路網的平均誤差值變化在訓練資料集與測試資料集之比例為 9：1 和 8：2 時較為穩定，然而在訓練資料集與測試資料集之比例為 7：3 和以下的分割方法時，平均誤差值的增加幅度較大。造成這個現象的原因在於原始資料集的缺乏以及訓練資料集的減少。




圖 4.11 中國驛站路網之各分割資料預測表現

中國驛站路網之原始資料集因為部分資料不齊全之問題，許多資料在資料處理的過程中被剔除，大幅減少了能用於訓練預測模型的旅行資料。之後為了訓練及驗證預測模型，原始資料集又被分割成訓練資料集和測試資料集，這又進一步的減少了參與訓練的訓練資料集的大小。因為參與訓練的訓練資料集減少，部分路段沒有充足的資料樣本數可以學習，最後在使用測試資料集對訓練完成的預測模型進行驗證時得到了較差的預測表現。該現象證明當中國驛站路網的訓練資料小於整體資料的百分之八十時，預測結果將不再可靠。

在效率方面，我們依序將中國驛站路網資料集之不同比例的訓練資料集分別投入學習速率為 0.01，Epoch 數為 7 的模糊類神經網路進行訓練，並記錄其完成預測模型訓練所花費的時間。其結果如圖 4.12。該圖之 X 軸為時間，單位為小時，Y 軸為訓練資料集與測試資料集的分割比例。由圖中我們可以發現，訓練資料集的比例越高，所花費的訓練時間成本就越大。

(小時)




圖 4.12 中國驛站路網之各分割資料預測時間成本

考慮到中國驛站路網之資料未臻完善，我們將該預測結果與模擬路網中複雜度最相近的路網 B 預測結果進行比較。

在訓練表現上，路網 B 即使在資料分割為 7：3 的狀況下仍然保有較好的預測結果，反觀中國驛站路網，除了資料分割為 9：1 的狀況之外，其他分割方法的預測結果都相當不理想。造成這個情形的原因在於資料的缺乏。

路網 B 的資料量較大也較完整，在進行資料分割後，訓練資料中所有移動路徑可以涵蓋整個路網中的路段，因此可以預測出路網中所有路段的旅行時間，進而預測測試資料的旅行時間。

與之相比，中國驛站路網的資料量較少，某些偏遠的路段只有在特定的幾筆資料中有移動紀錄。如果在資料分割的過程中，這些資料全部被分到測試資料之中，那麼預測模型在訓練過程中將不會學習到這些偏遠路段的旅行時間，這導致訓練後的預測模型在測試過程中對這些偏遠路段給出錯誤的預測結果，最後造成平均誤差值的增加。

而在訓練時間上，路網 B 不論是在資料量，還是輸入參數的數量上都高於中國驛站路網，因此在訓練時間的成本上，路網 B 都會高於中國驛站路網。

第五章 結論與未來工作

本研究提出一個基於模糊類神經的交通路網預測方法。該方法不只能透過單一路段的旅行紀錄進行旅行時間預測，還能透過路徑旅行紀錄對路徑中的單一路段進行旅行時間預測，克服了 KNN 法和類神經法無法透過路徑旅行紀錄進行路段旅行時間預測的問題。

在模擬實驗中，我們透過模擬路網資料產生器生成五組不同複雜度的模擬路網資料，並使用該方法進行旅行時間預測。根據模擬實驗的結果，該方法確實可以透過路徑旅行紀錄實現單一路段的路網旅行時間預測，其預測表現會受到訓練資料集的完整性影響，時間成本則受到路網的複雜度、訓練資料集的大小和路段的特徵維度影響。

而在實際資料集的預測應用上，該方法確實的完成了預測任務。中國驛站路網資料集為一個資料不齊全之路徑旅行紀錄資料集，在進行路網旅行時間預測時，如果參與訓練的訓練資料集不夠完全(部分路段並沒有出現在路徑旅行紀錄中的情況)，預測模型將無法完整學習到整個路網的旅行時間，訓練後的預測模型將無法準確預測這些沒有經過紀錄的路段。

然而在訓練成本上，該方法需要花費相當大量的訓練時間成本才能完成預測任務，其原因來自於大量的輸入參數和訓練資料集。由於該編碼方式的影響，每一筆旅行資料投入預測模型中進行訓練時，必然會將整個路網的路段參數投入預測模型中，因此增加許多不必要的運算。在之後的研究裡，我們將嘗試對路網進行分區分群，減少訓練過程中不必要的計算，以降低完成預測任務的訓練時間成本。

參考文獻

- [1] M. Wachs, "Relationships between drivers' attitudes toward alternate routes and driver and route characteristics", *Highway Research Record*, no.197, pp.70-87, 1967.
- [2] 蔡繼光, "高速公路旅行時間預測-以 k-NN 法及分群方法探討", 國立交通大學運輸科技與管理學系, 碩士論文, 2009
- [3] 王晉元, 陳彥佑, "高速公路中長程旅行時間預測模式之建立與應用報告書", 交通部臺灣區國道高速公路局, 2012
- [4] 王晉元, "變動 k 值之 k-NN 法應用於高速公路旅行時間預測之研究", 國立交通大學運輸與物流管理學系, 碩士論文, 2016
- [5] W. Scheidel, E. Meeks and J. Weiland, "Orbis: The Stanford Geospatial Network Model of the Roman World", Stanford University, 2015.
- [6] E. Kayacan and M. Ahmadi Khansar, "Fuzzy Neural Networks for Real Time Control Applications", Elsevier Science Ltd, 2016
- [7] S. J. Chapman, "MATLAB Programming for Engineers", CI-Engineering, 2007.
- [8] J. W. Tukey, "The Future of Data Analysis", *Institute of Mathematical Statistics*, vol.33, no.1, pp.1-67, 1962
- [9] N. S. Altman, "An Introduction to Kernel and Nearest Neighbor Nonparametric Regression", *The American Statistician*, vol.46, no.3, pp.175-185, 1992.
- [10] B. Smith, and M. Demetsky, "Traffic Flow Forecasting: Comparison of Modeling Approaches", *Journal of Transportation Engineering*, vol.123, no.4, pp.261-266, 1997.
- [11] S. Clark, "Traffic Prediction using Multivariate Nonparametric Regression", *Journal of Transportation Engineering*, vol.129, no.2, pp.161-167, 2003.

- [12] J. Rice, and E.V. Zwet: "A Simple and Effective Method for Predicting Travel Time on Freeways", *IEEE Transactions on Intelligent Transportation Systems*, vol.5, no.3, pp.200-207, 2004.
- [13] S. Robinson, and J. Polak, "Modeling Urban Link Travel Time with Inductive Loop Detector Data by Using the k-NN Method", *Transportation Research Record: Journal of the Transportation Research Board*, no.1935, pp.47-56, 2005.
- [14] G. L. Chang, N. Zou, and J. Wang, "Development and Field Evaluation of a Real-Time Travel Time Prediction System", Maryland Department of Transportation State Highway Administration, 2006.
- [15] 葉怡成, "類神經網路模式應用與實作", 儒林圖書股份有限公司, 2000.
- [16] T. W. S. Chow, and Y. Fang, "A recurrent neural-network-based real-time learning control strategy applying to nonlinear systems with unknown dynamics," *IEEE Transactions on Industrial Electronics*, vol.45, no.1, pp.151-161, 1998.
- [17] J. Wang, Y. Zhang, Y. Gao, and C. Xing, "PLSM: A highly efficient LSM-tree index supporting real-time big data analysis," *Proceeding COMPSAC '13 Proceedings of the 2013 IEEE 37th Annual Computer Software and Applications Conference*, pp.240-245, 2013.
- [18] J. L. Elman, "Finding structure in time," *Cognitive Science*, vol.14, no.2, pp.179-211, 1990.
- [19] C. Gan and K. Danai, "Model-based recurrent neural network for modeling nonlinear dynamic systems," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol.30, no.2, pp.344-351, 2000.

- [20] Y. C. Chen and C. Lee, "A Neural Skyline Filter for Accelerating the Skyline Search Algorithms," *Expert Systems*, vol.32, no.1, pp.108-131, 2015.
- [21] 張修榕, “高速公路旅行時間預測之研究”, 國立中央大學土木工程研究所, 碩士論文, 2001.
- [22] 許正憲, “資料融合技術應用於事故影響下高速公路旅行時間預測之研究”, 國立成功大學交通管理科學研究所, 碩士論文, 2006.
- [23] R. K. Lee, Y. C. Yang, J. H. Chen, and Y. C. Chen, “Freeway Travel Time Prediction by Using the GA-based Hammerstein Recurrent Neural Network”, , 2017

