

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

基於生成對抗網路設計循環風扇控制系統以進行冷氣
房之微空間溫度調整

Temperature Adjustment in Everywhere of the Air-
Conditioned Room by Using the Air Circulator Control
System Constructed by Generative Adversarial Networks

李靜瑜

Ching-Yu Lee

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D.

中華民國 110 年 6 月

June 2021

摘要

辦公環境溫度一直以來都是備受矚目的議題，而勞工對於環境溫度的熱感覺滿意度與工作生產率息息相關，若能提升勞工在冷氣工作環境中的熱感覺滿意度，便能促進生產率的提升，對管理者相當重要。在過去，有許多學者提出了不同的提高熱滿意度的相關研究，但能改善熱滿意度的提案可能不符合成本。因此，本研究提出了在冷氣房中，以一台循環風扇結合智慧型控制的方法，對於辦公環境個別座位之溫度進行調整，使溫度能符合使用者需求。本論文採用生成對抗網路產生冷氣房辦公環境座位溫度之時間序列模擬資料，來減少長時間資料蒐集的時間與人力成本，並利用類神經網路訓練循環風扇的控制模型。最後，本研究證實生成對抗網路可以模擬出符合實際狀況的座位溫度時間序列資料，且透過本研究建立的類神經網路架構，所產生之循環風扇擺頭角度與轉速檔位，可以使各座位溫度趨近於使用者期望溫度。

關鍵字：辦公溫度、生成對抗網路、智慧型控制



Abstract

The temperature of the office environment is an important concern for office managers as workers' comfort levels directly affect their productivity. While air-conditioned environments are conducive to thermal satisfaction, the related costs are high. In this paper, we propose a novel method of thermal control combining a circulating fan with intelligent control to adjust the temperature of each seat in the office to meet the individual needs of users. We apply a generative adversarial network to simulate time series data regarding seat temperature within an air-conditioned office environment to reduce the cost of long-term data collection. We further apply artificial neural networks to control the circulating fan. We conducted experiments to verify the accuracy of the data simulated by the generative adversarial network. Through the neural network architecture established in this study, the circulating fan angle and speed can bring individual seat temperatures closer to the temperature preferred by each user.

Keywords: Office Temperature, Generative Adversarial Network, Intelligent Control

目錄

第一章	緒論	1
1.1	背景與研究動機	1
1.2	研究目的	2
1.3	研究範圍與限制	4
1.4	研究架構	5
第二章	文獻回顧	6
2.1	智慧型控制	6
2.2	生成對抗網路	7
2.3	時間序列相關研究	8
2.3.1	統計模型	9
2.3.2	機器學習模型	10
2.3.3	淺層遞迴類神經網路	12
2.3.4	深度學習	14
第三章	實驗設計與資料蒐集	15
3.1	實驗場所介紹	15
3.2	儀器設備介紹	15
3.3	資料蒐集	16
3.3.1	空間溫度資料	16
3.3.2	天氣資料集	18
3.4	Line bot 缺失值提醒	19
第四章	研究方法	20
4.1	資料清洗	20
4.2	資料統整合併	21
4.3	運用 GAN 產生訓練資料	21
4.3.1	GAN 框架介紹	21
4.3.2	使用 LSTM 與 CNN 實現 GAN 框架	22
4.4	運用類神經網路控制風扇的合適參數	26
第五章	實驗模擬	28
5.1	資料集與實驗參數介紹	28
5.2	資料前處理	28
5.3	GAN 模擬資料結果	29
5.4	風扇控制模型實驗結果	31
5.4.1	循環風扇角度模型量化合理性說明	32
5.4.2	循環風扇轉速檔位模型量化合理性說明	32
5.4.3	循環風扇控制模型整體量化合理性說明	33

5.5	質化合理性說明	34
第六章	結論與未來研究	36
參考文獻		37



圖目錄

圖 1.1 Xu et al. [45]實驗空間與風扇擺設示意圖	2
圖 1.2 單一出風口冷氣辦公空間溫度分布示意圖	3
圖 1.3 單一出風口冷氣加入循環風扇改善辦公空間溫度分布示意圖	4
圖 1.4 研究架構圖	5
圖 2.1 智慧控制流程圖	7
圖 2.2 生成對抗網路的架構圖[46]	7
圖 2.3 2020 年 9 月 21 日到 2020 年 9 月 23 日的室內溫度	9
圖 2.4 2020 年 9 月 21 日到 2020 年 9 月 23 日的室內 PM2.5	9
圖 2.5 馬可夫模型事件狀態機率轉變示意圖	11
圖 2.6 淺層遞迴神經網路架構圖	12
圖 2.7 Hammerstein Recurrent Neural Network 架構圖	13
圖 2.8 Hammerstein-Wiener Recurrent Neural Network 架構圖[17]	13
圖 2.9 深層神經網路架構圖	14
圖 3.1 單一出風口冷氣辦公空間之結構示意圖	15
圖 3.2 AT-CF26RTW-W 循環風扇	16
圖 3.3 WeMos D1 外觀	16
圖 3.4 單一出風口冷氣辦公空間之感測器置圖	17
圖 3.5 感測器上傳至 Firebase RealTime Database 流程	17
圖 3.6 資料上傳至 Firebase RealTime Database 格式	17
圖 3.7 Line Bot 缺失值提醒	19
圖 4.1 研究流程圖	20
圖 4.2 GAN 訓練流程	23
圖 4.3 LSTM 閥門架構圖	23
圖 5.1 補值結果	29
圖 5.2 模型訓練中的 RMSE	30
圖 5.3 Generator 模擬資料與原始資料比較圖	30
圖 5.4 Generator 模擬不同冷氣設定溫度的座位溫度分佈圖	30
圖 5.5 風扇轉速檔位經 One Hot Encoding 轉換	31
圖 5.6 模型輸出角度與原始風扇角度比較圖	32
圖 5.7 模型輸出之誤差長條圖	32
圖 5.8 使用者期望溫度與風扇模型預測條件下的各座位溫度比較圖	34
圖 5.9 冷氣設定 19 度之各座位溫度變化	34
圖 5.10 使用者座位期望溫度 28 度的溫度分布	35

表目錄

表 3.1 循環風扇資料蒐集格式	18
表 3.2 室內人數蒐集紀錄	18
表 3.3 氣象即時觀測資料	19
表 4.1 室內氣溫資料	21
表 4.2 Generator 網路架構	23
表 4.3 Discriminator 網路架構	26
表 4.4 風扇角度 ANN 架構	26
表 4.5 風扇轉速 ANN 架構	26
表 5.1 輸入 Generator 的亂數資料	31
表 5.2 循環風扇轉速檔位模型之混淆矩陣	33
表 5.3 循環風扇轉速檔位模型之混淆矩陣	33



第一章 緒論

1.1 背景與研究動機

隨著全球暖化，各地的溫度越來越高，民眾對於冷氣的需求也逐漸提升。許多地區也紛紛提出了針對室內溫度的節能措施，像是冷氣溫度不可低於 27 攝氏度來減少夏季用電的能源的負荷。但位於辦公環境，例如實驗室、辦公室等固定座位形式的空間中，會因為距離冷氣的遠近感受到不同的溫度。例如，將冷氣設定在攝氏 27 度時，位於冷氣出風口的座位的辦公人員可能會感受舒適，而距離冷氣較遠的座位的人員可能就覺得非常炎熱。Niemelä *et al.* [28] 在 2000 年時，針對了溫度對於電信公司辦公室勞動生產率的影響，研究結果表明，當室內溫度超出攝氏 25 度時，勞動生產率平均下降了 5%~7%。Hedge *et al.* [1] 對美國佛羅里達州一家保險公司做了溫度與生產率的研究，研究結果指出，相較於攝氏 20 度時，辦公室溫度在接近攝氏 25 度時，生產率較高，且錯誤率較低。另外，Riya Sander 2019 年時在 *Lead Change* 發表了一篇文章，內容提到，當辦公溫度在華氏 77 度時，勞工的生產率是華氏 68 度的兩倍。但當溫度過高時，生產率就會下降。溫度每超過平均溫度 1 度時，勞工的生產率就會下降約 3% 左右。Lipczynska *et al.* [2] 的研究指出，辦公室溫度與生產率的關係主要是源自於人對於熱感覺的滿意度，當人的熱感覺滿意度提高時，其警覺性、注意力水平和工作生產率會提高，尤其室內溫度在攝氏 26 度時，可以達到最好的熱感覺滿意度。整合上述研究結果，可以得知辦公室的溫度如果能滿足個人的熱感覺滿意度，工作生產率就會提高。為了提升勞工的熱感覺滿意度，進而促進工作的生產率，解決辦公室溫度分布不均的情形是一件至關重要的事情。為了解決室內溫度分布不均勻的問題，許多研究提出利用風扇裝置來增加室內循環，以增加室內氣體的流動。Chen *et al.* [34] 就提出了一種新的空調概念，他們透過吊扇的旋轉速度和風扇旋轉方向改變室內空間整體的氣流上升或下降，並結合側壁通風孔噴射氣流以優化室內溫度分布。雖然吊扇裝置增加了空間氣體流動，




圖 1.1 Xu *et al.* [45]實驗空間與風扇擺設示意圖

改善整體空間溫度分布不均的問題，卻不能滿足個人的熱感覺滿意度，且不是所有的空間都適用吊扇系統。對此，Xu *et al.* [45]提出了利用個人風扇搭配空調來改善個人熱感覺滿意度的問題。該研究結果證實該方法確實能提升個別使用者的熱感覺滿意度並提升勞工的生產率，但實驗中在個別座位旁分別架設個人電扇，如圖 1.1 所示。這樣多台個人風扇的擺設並不符合實際辦公室環境應用，除了需要花費一些空間擺放風扇之外，多台風扇的運行電量也是不可小覷的。第三種方法則是交換座位，交換座位的方法雖然可以很好的滿足每個使用者當下對於熱滿意度的需求，但人體每天的感受溫度的狀況不同，對於選擇座位的熱感覺滿意度每天都會有差異。舉例來說，一個怕熱的勞工選擇在靠近冷氣出風口的座位，但若他患上風寒型的感冒，這時在冷氣出風口座位對他來說，溫度就太低，熱感覺滿意度就會下降。整體而言，上述的三種解決方法皆有提升個人熱感覺滿意度的效果，但仍有可改善的空間。

1.2 研究目的

本研究提出以下兩點概念來改善上述方法的不足，(1)本研究加入一台循環風扇調整空間中個別座位之溫度，並利用智慧型控制的方式來讓辦公室各座位溫度趨近使用者最理想的數值。而完善的智慧型控制模型依賴大量的數據進行訓練，但蒐集數據的過程需耗費大量的時間與人力成本，因此本研究透過(2)利用生成對抗




圖 1.2 單一出風口冷氣辦公空間溫度分布示意圖

網路模擬近似真實的數據來解決資料蒐集成本問題，接下來將詳細介紹這兩點概念。概念一，本論文採用一台循環風扇，結合智慧型控制的想法，達成個別座位溫度之差異。智慧型控制是一種透過感知獲得環境信息，再利用獲得的訊息進行知識推理，最後做出相對應的決策或行動。例如家用的洗衣機，可以偵測放入的衣物重量，並透過重量來判定該次洗衣需要使用多少水量來清洗衣物。本研究目的為使用一台循環風扇設置於空調系統出風口下方，透過控制循環風扇的轉速與左右角度，使個別座位的溫度趨近使用者期望。舉例來說，有個辦公空間，空間右側為單一出風口的冷氣門口位置，內有 6 個座位。假設冷氣的溫度設置為攝氏 25 度，空間的溫度分布如圖 1.2 所示，可以發現空間中最右方靠近冷氣出風口的座位與最左方的座位溫度有明顯差異。若 A 到 D 使用者對於目前溫度感到滿意，但 E 與 F 兩位使用者希望溫度能分別降低到 25.3 攝氏度和 25.6 攝氏度，要達到 E、F 使用者所期望的溫度，則可加入循環電扇於冷氣出風口的下方，並調整循環風扇的角度與轉速，透過風扇將空間中的冷空氣往左下方運送，使 E、F 座位溫度達到降溫的需求，如圖 1.3 所示。因為循環風扇可以利用風扇的轉速幫助將冷氣所吹出來的冷空氣吹得更遠，使距離冷氣出風口較遠的座位能達到良好的降溫效果，且可以彈性調整吹拂方向，使個別座位溫度趨近於使用者期望。




圖 1.3 單一出風口冷氣加入循環風扇改善辦公空間溫度分布示意圖

雖然上述作法可以達到本研究控制個別座位溫度的目標，但實驗所蒐集的資料需要消耗大量的時間與人力成本來達成完善資料的蒐集，若要在短期內就能建立風扇控制模型，則需要產生大量的模擬資料來彌補現實短期內資料蒐集不足的狀況。概念二，利用生成對抗網路產生符合實際狀況的資料。為了解決資料筆數少及分布不均勻的情況，本研究引入生成對抗網路來產生符合狀況的模擬資料，彌補資料筆數少與分布不均勻的情形。生成對抗網路常用於生成以假亂真的圖片，但因本研究實驗所設置的座位數量較少，因此不適合使用圖片的形式來表達個別座位溫度，故本研究將採用時間序列的模型帶入生成對抗網路的框架中，使其產生符合本研究需求的模擬資料。透過概念二模擬出足夠的資料後，就可以將真實資料與模擬資料帶入概念一，進行時間序列模型訓練、建模，使訓練後的模型能產出符合使用者設定溫度之最佳循環風扇設定參數，達到個別座位溫度調控之結果。

1.3 研究範圍與限制

本研究限制如下：

1. 感測器在蒐集的過程中會出現缺失值或異常值。
2. 本研究僅針對實驗空間的座位溫度，對於同空間的其他位置溫度不加以考慮。
3. 本研究僅針對循環風扇之模型輸出，對於控制方式不進行探討。

1.4 研究架構

本研究之架構如圖 1.4 所示，研究架構如下：

第一階段：蒐集實驗空間約 4 個月的冷氣溫度、室內人數、循環風扇左右角度、循環風扇轉速、個別座位之溫度、濕度與外部天氣資料。

第二階段：將蒐集到的資料整理、合併，進行初步觀察與分析。

第三階段：使用時間序列的生成對抗網路產生符合實際狀況的模擬資料。

第四階段：將真實資料與模擬資料輸入類神經模型訓練，產生循環風扇的控制模型。




圖 1.4 研究架構圖

第二章 文獻回顧

在本章節中共分成三個小節，分別為智慧型控制、生成對抗網路、時間序列相關研究。在 2.1 節中介紹智慧型控制的相關研究與應用，藉此了解智慧型控制的優點及特色，接著在第 2.2 節中介紹生成對抗網路的網路架構與原理，並針對該模型的時間序列相關應用進行探討，而 2.3 節中，則是介紹目前時間序列的主流方法，如統計模型、隱藏式馬可夫模型、遞迴類神經網路等多種方法。

2.1 智慧型控制

智慧型控制的概念是由美國普渡大學的 King-Sun Fu 教授於 1971 年提出，是一種將人工智慧的知識推理應用於控制領域當中的方法。一個智慧型控制系統通常會具備感知、做決策與行動的能力。控制器透過感測器感知環境的資訊，經過進行知識推理獲得適合該環境資訊的決策，再利用信號控制使該決策能做出對應的行動，整體流程如圖 2.1 所示。智慧型控制常見的方法有，機器學習、類神經網路、模糊邏輯、與基因演算法等多知識推理方法。機器學習演算法是從資料中找出規律，並利用此規律對於未知的資料進行判斷；類神經網路是透過與模型輸出與實際資料的誤差來學習資料的特性；模糊邏輯是找出資料集合中的歸屬關係，並將未知的資料轉變為其中一個歸屬；基因演算法則是運用電腦模擬生物演化過程來進行，其中包含交配、遺傳、突變等方式。透過上述這幾個演化現象不斷的進行世代繁衍，來找尋最佳解。

目前有許多智慧型控制的系統應用在日常生活中，例如，Lennon & Passino [38] 在 1999 年時就分別運用模糊控制、遺傳演算法以及自適應控制系統，開發了三種控制系統運用在防鎖死煞車系統(ABS)中；Akram & Javed [20]在 2014 年應用直覺模糊控制在洗衣機上，洗衣機可透過污垢類型及髒污程度判斷需要清洗多長的時間；Wang *et al.* [32]在 2017 年將 RBF 類神經網路應用在智慧車輛中，提升車輛的運動控制效能；Chiesa *et al.* [9]在 2020 年利用模糊控制結合物聯網，對於建築物的




圖 2.1 智慧控制流程圖

照明系統進行控制。除了生活上的應用，智慧型控制也活絡於許多產業中，Kang *et al.* [22]就將智慧型控制應用在植物的生長控制與管理上；Wu *et al.* [26]將模糊控制和專家系統應用在氣體加壓控制上，結果不僅降低了生產成本還提升了品質。由此可見，智慧型控制已是應用非常普及的科技，也是未來發展的趨勢。

2.2 生成對抗網路

生成對抗網路(Generative Adversarial Network, GAN)是 Goodfellow *et al.* [13] 在 2014 年提出的一種非監督式學習方法，由兩個神經網路組合而成，分別由生成網路(Generative Network)與判別網路(Discriminating Network)，架構如圖 2.2 所示。而生成對抗網路的運作機制是透過生成網路與判別網路以互相博弈的方式進行學習。




圖 2.2 生成對抗網路的架構圖[46]

其中，生成網路會隨機抽取樣本作為輸入，輸出是產出與訓練集中的真實資料盡可能相似的結果；而判別模型的輸入則是真實資料或生成網路的輸出，目的是辨別出生成網路的輸出。生成網路的目的則是製造出能夠假以亂真讓判別模型無法

辨認是否為生成網路產生的輸出。每當判別網路辨識出一個結果後，就會將判別的資訊回饋給生成網路，使生成網路能修正並產生與真實資料更相近的輸出，在這樣互相博弈、對抗的方式學習下調整參數，直到判別網路最終無法辨別生成網路產出資料的真偽。

生成對抗網路目前大多數還是應用在生成圖片、圖像辨識與合成等，例如，Yang *et al.* [12]在 2018 年將 ContourGAN 應用在輪廓辨識上；Yu *et al.* [41]在 2019 年使用 GAN 產生鋼產品的表面圖片進行表面缺陷檢測。Ma *et al.* [15]利用 FusionGAN 將紅外光圖片與可見光圖片合成。雖然大多的研究都是將 GAN 生成圖片，進行影像相的研究，但還是有將 GAN 應用在時間序列上的研究，例如 Takahashi *et al.* [31]將 GAN 應用在生成金融時間序列中；Guo *et al.* [43]應用 GAN 在產生多元時間序列；Jiang *et al.* [35]利用 GAN 產生異常情況的樣本，來解決工廠資料不平衡的情形；Mao *et al.* [37]利用 GAN 生成少數故障類別的綜合樣本，來提高故障診斷模型的預測能力。綜合上述結果可以得知，GAN 不但可以自行生成資料補足缺失或是不平衡的情形，以提升模型的效能，還可以藉此降低企業資料蒐集的成本。

2.3 時間序列相關研究

時間序列是目前很常見到的資料型態，通常是由間隔時間相同(如 10 秒、1 分鐘、10 分鐘、1 小時)的連續資料所組成，並且按照先後發生的時間順序排序組合而成。時間序列已被廣泛應用於多種領域當中，如信號處理、天氣預報、地震預測、空氣品質預測、通訊工程、數理統計、經濟學、控制系統等。

依照資料型態的不同，時間序列又可分為規律的時間序列與不規則時間序列。圖 2.3 為 2020 年 9 月 21 日到 2020 年 9 月 23 日的室內溫度資料，可以看到溫度的起伏有一定的規律，此種類型的資料為規律的時間序列資料；圖 2.4 為 2020 年 9 月 21 日到 2020 年 9 月 23 日的室內 PM2.5，可以看到 PM2.5 的起伏是較不規則的，則為不規則時間序列資料。這類型的資料大部分是由特殊情形造成數值突發性

的變動，例如在室內點燃香菸，會造成室內的 PM2.5 突然上升。目前有許多熱門的處理時間序列的研究方法，如統計模型、隱藏式馬可夫模型、遞迴類神經網路、長短期記憶類神經等，接下來會探討與時間序列相關之研究。




圖 2.3 2020 年 9 月 21 日到 2020 年 9 月 23 日的室內溫度




圖 2.4 2020 年 9 月 21 日到 2020 年 9 月 23 日的室內 PM2.5

2.3.1 統計模型

目前時間序列常使用的統計模型有自迴歸移動平均模型、整合移動平均自迴歸模型，接下來會依序對兩種方法進行探討。

自迴歸移動平均模型(Autoregressive Moving Average Model, ARMA)是統計上常見的時間序列方法之一，由自迴歸模型(Autoregressive model)和移動平均模型(Moving Average Model)為基礎所混合而成，其中，自迴歸模型是描述當前時間點資料與歷史資料的關係。假設當前資料點為 x_t ， x_t 的值為前 p 點的數值乘上一個

相對應的權重後相加，再加上一個常數 c ，最後再加上一個隨機誤差值而成，其公式如下：

$$x_t = c + \sum_{i=1}^p \varphi_i x_{t-i} + \varepsilon_t \quad (1)$$

移動平均模型則是描述自迴歸模型的誤差累積，假設當前資料點為 x_t ，移動平均模型會計算前 p 點的數值的平均，並將每個點與平均數相減，獲得誤差，再將每個誤差乘上一個相對應的權重後相加，再加上平均值即可得到 x_t 的值，公式如下：

$$x_t = \mu + \varepsilon_t + \sum_{i=1}^p \theta_i \varepsilon_{t-i} \quad (2)$$

而 ARMA(p, q)模型中包含了自迴歸 p 項與平均移動 q 項，則 ARMA(p, q)模型就可表示為：

$$x_t = c + \varepsilon_t + \sum_{i=1}^p \varphi_i x_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} \quad (3)$$

Liu *et al.* [30]基於 ARMA 模型對單變量時間序列進行預測；Wang *et al.* [19]使用基於 ARMA 模型對極限開關進行故障診斷；Liu *et al.* [44]基於 ARMA 模型進行航空發動機轉速的信號預測。

整合移動平均自迴歸模型(Autoregressive Integrated Moving Average model，ARIMA)是由 Box & Pierce [10]於 1968 年提出，是 ARMA 的改良版，此模型在 AR 和 MA 中間加入了差分導入模式來處理非平穩序列。Guo *et al.* [14]使用 ARIMA 進行道路坡度與車速，來對油電混合車進行能源管理；Cardoso & Cruz [7]使用 ARIMA 結合類神經網路進行天然氣消耗預測；Aasim *et al.* [33]使用基於 ARIMA 模型進行短期風速的預測。

2.3.2 機器學習模型

常見的機器學習模型有隱藏式馬可夫模型和分類與迴歸樹，下面會針對這兩

種方法進行探討。

隱藏式馬可夫模型(Hidden Markov Model, HMM)是統計方法馬可夫模型(Markov Model)的延伸。馬可夫模型，是一種描述一連串事件接連發生的機率，模型中有多種不同狀態(State)的同類型事件，各個狀態到其他狀態以箭頭相連，每個箭頭有不同機率(權重)，代表狀態之間轉換的機率，如圖 2.5 所示。 S_i 表示事件狀態， a_{ij} 表示狀態轉換機率。而隱藏式馬可夫模型，則是將模型中事件的狀態隱藏起來，雖然狀態被隱藏，但可以透過序列的觀察找出狀態的資訊。Lasfar & Bouden [23] 於 2018 年使用隱藏式馬可夫模型對蛋白質二級結構進行預測；Li & Liu [36] 使用基於隱藏式馬可夫模型預測刀具的剩餘壽命；Stanislavsky *et al.* [3] 使用隱藏式馬可夫模型預測日焰週期。




圖 2.5 馬可夫模型事件狀態機率轉變示意圖

分類與迴歸樹(Classification and Regression Tree, CART)是由決策樹衍伸出的方法，可以運用在迴歸與分類問題中。CART 結合了分類和迴歸的功能，它的運作原理與二元樹相同，將資料分割成兩個子集合，再從子集合中分割兩個子集合，不斷的重複上述步驟，直到找出資料的規律將大量的資料進行分類或預測。Zhao *et al.* [42] 運用 CART 對於中國三峽地區的滑坡地段進行下水道預測；Fei *et al.* [40] 運用 CART 來預測急性胰臟炎患者發生門靜脈血栓形成的機率。

2.3.3 淺層遞迴類神經網路

淺層遞迴神經網路(Recurrent Neural Network)目前已被廣泛且成功地運用於各時間序列預測之研究中,如圖 2.6 所示。遞迴神經網路與傳統神經網路的差別在於,遞迴神經網路具有記憶功能。遞迴神經網路可分為輸入層、隱藏層及輸出層,隱藏層可以是一層或多層,每層可有多顆神經元,各層神經元皆為前一層之輸出值乘上權重,再經過非線性轉換,輸出至下層網路。在運算過程中,會將每次的輸出儲存,並加入下一次的運算。模型中的層數、神經元個數、權重、皆可依使用者需求自行調整。因此,隨著不同研究領域,可以設計不同的架構與演算法,可適應各種時間序列之預測。Yu *et al.* [6]使用遞迴神經網路與支持向量機進行風速預測;Rhode *et al.* [25]使用遞迴神經網路進行惡意軟體執行前之預測。




圖 2.6 淺層遞迴神經網路架構圖

時間序列類神經模型有許多架構上的變化,例如 Hammerstein Recurrent Neural Network (HRNN),是遞迴神經網路的一種延伸,由輸入層、隱藏層、動態層與輸出層組成,模型架構如圖 2.7 所示。Narendra & Gallman [18]在 1966 年應用於非線性系統的迭代方法。此模型特點為面對輸入輸出靜態非線性愈動態線性之時間序列有良好且穩定之準確度,在訓練過程確保模型能收斂的更快速, Satpati *et al.* [5]

使用 HRNN 對於工業的空氣預熱爐的氣動輸送與乾燥過程進行辨識。Wang & Chen [17]在 2008 年時，提出了另一種遞迴類神經網路的延伸，應用在時間序列的改良模型—Hammerstein-Wiener Recurrent Neural Network，用於識別未知的動態非線性系統，圖 2.8 為 Hammerstein-Wiener Recurrent Neural Network 的架構圖。該模型比 Hammerstein Recurrent Neural Network 多了一層靜態隱藏層，透過這樣的方式能將模型的輸出以線性狀態表示非線性的資料。




圖 2.7 Hammerstein Recurrent Neural Network 架構圖




圖 2.8 Hammerstein-Wiener Recurrent Neural Network 架構圖[17]

2.3.4 深度學習

一般深度學習用於時間序列的方法有兩種，一為長短期記憶模型(Long Short-Term Memory, LSTM)，二為深層神經網路(Deep Neural Network, DNN)。LSTM 是遞迴類神經網路的一種改良，由 Hochreiter & Schmidhuber [29]於 1997 年首次發表。長短期記憶模型的主要目的是為了解決遞迴類神經網路權重指數梯度爆炸或梯度消失的問題。其主流架構是由 Gers *et al.* [8]於 2000 年提出，在記憶神經元(Memory Cell)前後增加三種閥門(gate)，來調整模型的權重與影響記憶。這三個閥門分別為輸入閥(Input Gate)、遺忘閥(Forget Gate)與輸出閥(Output Gate)。輸入閥透過模型的自我學習，判斷是否要將資料輸入至記憶神經元當中；遺忘閥的功能則是，決定當前要輸入至記憶神經元當中的資料，需要保留或者捨棄；輸出閥則是控制記憶神經元中的資料，是否送往下一層網路中運算。Shi *et al.* [16]基於 LSTM 對間歇性斷路故障的研究性進行評估；Yan *et al.* [11]使用 LSTM 來預測機械齒輪的壽命；Hossain *et al.* [21]使用基於 LSTM 的模型進行車載控制區域網路之入侵檢測。

深層神經網路顧名思義就是將網路的隱藏層數量與神經元數量大量擴充，用後面的網路層可以直接學到前面網路層已經學習的知識，透過這樣一層一層的學習過程，使其能有更好的表現，架構如圖 2.9 所示。Radaideh *et al.* [24]使用了 DNN 和 LSTM 來預測核電廠的冷卻系統失誤；Lu *et al.* [39]使用 DNN 結合 DBSCAN 進行 PM2.5 之預測；Formosa *et al.* [27]使用 DNN 對即時的交通衝突進行預測；Chen *et al.* [4]使用 DNN 進行設備可靠度預測。




圖 2.9 深層神經網路架構圖

第三章 實驗設計與資料蒐集

本研究的目標為在冷氣房間內設置一台循環風扇，並利用神經網路調整循環風扇之參數，使個別座位溫度符合使用者之需求。對此，本研究將蒐集實驗環境中循環風扇的左右角度、轉速檔位、個別座位之溫度與濕度的變化，並且加入室外天氣、溫度、濕度、室內人數等因素。本章節將依序介紹研究資料蒐集之實驗場所、使用之儀器設備與配置和所蒐集的資料格式。

3.1 實驗場所介紹

本研究將於安裝單一出風口冷氣的辦公空間進行資料蒐集，接下來將介紹該空間結構。

單一出風口冷氣辦公空間的大小約為長 6.43 公尺、寬 2.97 公尺、高 3 公尺，門與冷氣位於空間西側，窗戶位於南側，該空間的窗戶長期屬於封閉狀態，只使用冷氣調節環境溫度。另外，該環境位於樓層頂端，房頂無其他遮蔽物，且午後陽光會透過左側的窗戶照射進室內。圖 3.1 為單一出風口冷氣辦公空間之結構示意圖。



圖 3.1 單一出風口冷氣辦公空間之結構示意圖

3.2 儀器設備介紹

本研究使用型號為 AT-CF26RTW-W 之循環風扇，如圖 3.2 所示。該循環風扇大小為寬 33 公分、深 26 公分、高 38 公分；風量分成高、中、低三個檔位，由高



圖 3.2 AT-CF26RTW-W 循環風扇




圖 3.3 WeMos D1 外觀

至低檔位的風量分別為 22.5 立方公尺/分鐘、17.1 立方公尺/分鐘與 6.0 立方公尺/分鐘。該循環風扇的優點為風量大、噪音低且耗電量少。數據蒐集則使用 WeMos D1 物聯網應用開發板搭配 DHT22 溫溼度感測器來進行，WeMos D1 外觀如圖 3.3 所示。WeMos D1 是一款可以相容於開放資源公司 Arduino IDE 的開發板，微控制器採用 ESP8266，含有 11 個數位接腳及 1 個類比輸入接腳。他的優點除了可上網之外，還支援多種傳輸協定、韌體更新、消耗功率低且價格便宜。

3.3 資料蒐集

3.3.1 空間溫度資料

本研究將循環風扇位置固定在冷氣出風口下方，採用固定仰角搭配調整不同左右角度的方式送風，進行實驗資料的蒐集。感測器的部分，則是架設在各座位上以及冷氣出風口處，如圖 3.4 所示。經由感測器感測環境後，透過 WeMos D1 開發版進行溫度與濕度的資料蒐集，接著將感測器傳至 WeMos D1 中的溫度與溼度資料，藉由 WeMos D1 與 Google 提供的雲端資料庫——Firebase RealTime Database 進行連動並且上傳，如圖 3.5 所示。上傳的資料格式，則是以個別座位的日期為一個 JSON 檔案上傳至 Firebase RealTime Database 中。本研究的實驗資料採用即時上傳的方式，也就是感測器在每一分鐘蒐集到一筆資料後，WeMos D1 就會透過網路馬上將資料儲存至資料庫當中。資料上傳的內容包含當下的日期、時間、溫度和濕度，如圖 3.6 所示。





表 3.1 循環風扇資料蒐集格式

日期(Y/M/D)	時間(H:M)	風扇擺頭角度	風扇風量檔位
2021/3/4	13:30	0	1
2021/3/4	17:30	0	2
2021/3/4	19:30	0	3

表 3.2 室內人數蒐集紀錄

日期(Y/M/D)	時間(H:M)	進入人數	離開人數
2021/3/4	13:00	2	0
2021/3/4	13:30	1	0
2021/3/4	14:43	1	0

除了上述溫溼度資料外，本研究還會蒐集循環風扇的左右角度、轉速檔位和室內人數，這三種資料是藉由 google 表單進行蒐集。假設今日同學 A 與 B 在 2021 年 3 月 5 日於 13:30 一同進入實驗空間中，則他們就會在表單上填寫進入的時間與人數，循環風扇的調整亦是如此。最終彙整的資料格式如表 3.1 與表 3.2 所述。由於循環風扇擺設於冷氣下方且位於牆邊，因此循環風扇角度只蒐集 180 度，以 30 度為一個調整的方式蒐集，實驗蒐集的時間於 3~6 月間，每個月蒐集一次循環風扇角度與轉速的所有搭配可能。

3.3.2 天氣資料集

外在的天氣因素也會影響室內溫度的變化，由於斗六地區只有以一小時為更新頻率的自動氣象站資料，無法顯示短時間內的室外氣溫變化，因此本研究採用中央氣象局設置在雲林地區的四個即時觀測站(古坑、西螺、林內、麥寮)資料之平均作為本研究的室外天氣資料，並將資料整理成表 3.3 之資料格式，欄位內容包含日期(date)、時間(hour)、氣溫(°C)、相對溼度(%)。透過天氣資料增加模型可以學習的資訊，以利後續對於個別座位溫度調整有更好的成效。

表 3.3 氣象即時觀測資料

日期 (date)	時間 (hour)	氣溫 (°C)	相對濕度 (%)
2021/3/1	00:00	18.125	95
2021/3/1	00:10	18.1	95
2021/3/1	00:20	18.225	95

3.4 Line bot 缺失值提醒

由於感測器在資料蒐集的過程中，可能會因為網路、電源供應情況或感測器本身異常，而造成感測器上傳缺值或未上傳資料。如未定時去檢查資料是否有正確上傳至資料庫，則會有長時間異常值或缺失值的情形，但若人工定期檢查又會造成人力的負擔。因此本研究採用網路爬蟲結合 Line Bot 的方式，針對即時資料進行檢測，如資料上傳空值或未上傳資料時，Line Bot 會傳送訊息提醒，減少長時間資料遺漏的情形發生，如圖 3.7 所示。



圖 3.7 Line Bot 缺失值提醒

第四章 研究方法

本章節將依序介紹本研究所提出之方法，研究流程如圖 4.1 所示，接下來將詳細說明研究流程之個別方法之工作內容。




圖 4.1 研究流程圖

4.1 資料清洗

由於資料的蒐集都是藉由感測器上傳至雲端資料庫，因此在使用上可能會遇到感測器接觸不良、電源故障、網路設備不穩定、延遲、感測器故障等狀況，這些狀況會導致上傳雲端的資料產生遺漏、超出正常範圍的值、負值或 Null 等。若將這些異常的資料輸入至模型訓練，會造成模型成效不佳甚至是無法建立模型，因此需要將這些異常資料先行進行清洗。本研究參考了過往研究處理異常資料的方法——線性插值法來取代異常值或填補遺漏值，公式如下：

$$x_n = x_{n-1} + n\Delta \quad (4)$$

$$\Delta = \frac{x_{g+1} - x_0}{g+1} \quad (5)$$

其中 g 表示需要填補資料之範圍大小； n 表示第 n 筆需要填補之資料。另外，針對大於 24 小時的資料異常或填補遺漏的部分，本研究採用前 24 小時與後 24 小時的資料平均，來取代異常或遺漏的資料。

4.2 資料統整合併

本研究所蒐集之室內氣溫資料分別以各座位及冷氣出風口之溫、溼度，還包含了冷氣設定溫度、循環風扇角度、循環風扇檔位、室內人數等個別紀錄之資料，因此需要將資料整理且合併在一起。由於交通部中央氣象局開放資料平臺中的天氣資料的最小更新時間為 10 分鐘一筆，於是本研究參照其資料更新時間，將資料合併成以 10 分鐘為單位的時間序列資料，如表 4.1 所示。

表 4.1 室內氣溫資料

時 間	室 外 溫 度	室 外 濕 度	座 位 1 溫 度	座 位 1 濕 度	座 位 2 溫 度	座 位 2 濕 度	座 位 3 溫 度	座 位 3 濕 度	座 位 4 溫 度	座 位 4 濕 度	座 位 5 溫 度	座 位 5 濕 度	冷 氣 設 定 溫 度	風 扇 擺 頭 角 度	風 扇 轉 速 檔 位	室 內 人 數
(Y/M/D H:M)	(°C)	(%)	(°C)	(%)	(°C)	(%)	(°C)	(%)	(°C)	(%)	(°C)	(%)	(°C)	(度)	(檔 位)	(人)
2021/3/4 13:30	24.95	79.5	24.86	52.75	24.59	44.06	25.43	38.52	26.15	36.73	23.56	41.15	17	0	1	2
2021/3/4 13:40	25.00	79	24.91	52.26	24.6	43.31	25.49	37.46	26.12	36.03	23.5	40.58	16	0	1	2
2021/3/4 13:50	24.68	79.5	24.91	51.94	24.61	43.22	25.5	37.15	26.35	35.42	23.6	40.12	16	0	1	2
2021/3/4 14:00	24.21	79.75	24.9	51.52	24.6	42.52	25.51	36.64	26.34	34.92	23.52	40	16	0	1	2
2021/3/4 14:10	23.78	80.50	24.9	51.46	24.64	42.3	25.53	36.5	26.32	34.81	23.5	39.86	16	0	1	2

4.3 運用 GAN 產生訓練資料

4.3.1 GAN 框架介紹

GAN 是一種非監督式學習的方法，其架構中有兩個模型運行，分別為生成模型與判別模型。透過生成模型與判別模型相互博弈的方式進行學習，來產生與真實情況相符的模擬資料。首先，生成模型先產出模擬資料，且將模擬資料標記後與真實資料一併輸入進判別模型中。判別模型會判別真假，並回饋給生成模型，讓生成模型能調整參數，產生更接近真實的模擬資料。GAN 的訓練會透過上述不自不斷的輪迴，直到判別模型無法辨識出生成模型輸出的真偽。

舉例來說，將判別網路假設為一位鈔票鑑定員，生成網路假設為一位偽鈔製造

者。鑑定員除了要有能分辨真偽鈔的能力外，還要將判斷完後相關資訊回饋給偽鈔製造者；而偽鈔製造者要根據鑑定員所提供的回饋不斷地修正，並製造出與真鈔相似度更高的偽鈔，直到鑑定員最終無法辨別出鈔票的真偽為止。經由這樣不斷生產和回饋的過程，最終能產生出足夠假以亂真的資料，也就是說，只需要蒐集較少的資料量輸入，就可以透過這個方法模擬出滿足使用者需求的資料量。本研究包含實驗空間中 5 個座位的溫、溼度資料、冷氣設定溫度、風扇擺頭角度、風扇轉速檔位與室內空間人數的時間序列資料，並將室外溫度、室外濕度、冷氣設定溫度、風扇角度、風扇檔位與室內人數資料作為生成模型的輸入，將 5 個座位的溫度作為生成模型的輸。而對抗模型的輸入則是將生成模型的輸入輸出合併，再加上原始資料作為輸入，輸出為真實資料與模擬資料的相似程度。由於本研究的資料形式為時間序列，且座位數量較少，不適用圖片方式呈現，因此本研究 GAN 架構中的模型採用時間序列相關的模型，以產生模擬的室內溫度資料。

4.3.2 使用 LSTM 與 CNN 實現 GAN 框架

因為本研究 GAN 架構中的 Generator 目的是為了產生時間序列座位溫度的模擬資料，因此將使用 Long Short-Term Memory (LSTM) 模型作為網路模型；Discriminator 目的是為了要評估 Generator 產生的模擬資料與真實資料的相似程度，因此採用 CNN 模型作為網路模型，GAN 整體架構如圖 4.2 所示。本研究所使用的 Generator 與 Discriminator 兩個模型的網路架構，是參考過往研究的網路架構，透過不斷的嘗試調整參數、層數、激活函數等所得出。接下來將分別介紹兩個網路。




圖 4.2 GAN 訓練流程

表 4.2 Generator 網路架構

階層	類型	輸出大小	激活函數
輸入	輸入	1×6	-
隱藏層	全連接	1×6	tanh
遞迴層	LSTM	1×6	tanh
隱藏層	全連接	1×6	tanh
輸出	全連接	5	-




圖 4.3 LSTM 閥門架構圖

Generator 模型由輸入層、全連接層、LSTM、全連接層與輸出層組成，整體架構如表 4.2 所示。首先為輸入層的部分，此層網路的輸入即輸出結果，可以表示為下列公式：

$$Input_i = Output_i \quad (6)$$

其中 $Input_i$ 為輸入的 i 筆輸入， $Output_i$ 為第 i 筆輸出。接著為全連接層，其運算方式如以下公式表示：

$$m_i = \sum (w_{ij}u_i) + d_i \quad (7)$$

$$n_i = f(m_i) \quad (8)$$

其中 u_i 為第 i 筆輸入， w_{ij} 為輸入層與隱藏層連接之權重， d_i 為隱藏層偏壓值， $f(\cdot)$ 為使用的激活函數，本研究 Generator 中所使用的激活函數皆為 Tangent Sigmoid。

接著為 LSTM，此層由輸入閥、忘記閥、記憶神經元、輸出閥、隱藏狀態向量等元素構成，如圖 4.3 所示，其運作方式由以下數學式表示：

(i) 輸入閥：

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + w_{ci}c_{t-1} + b_i) \quad (9)$$

(ii) 遺忘閥：

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + w_{cf}c_{t-1} + b_f) \quad (10)$$

(iii) 記憶神經元：

$$c_t = f_t c_{t-1} + i_t \cdot \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (11)$$

(iv) 輸出閥：

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + w_{co}c_t + b_o) \quad (12)$$

(v) 隱藏狀態向量：

$$h_i = o_i \cdot \tanh(c_i) \quad (13)$$

其中 W_{xi} 、 W_{hi} 、 W_{ci} 、 W_{xf} 、 W_{hf} 、 W_{cf} 、 W_{xc} 、 W_{hc} 、 W_{xo} 、 W_{ho} 、 W_{hc} 為層與層之間的連接權重， b_i 、 b_f 、 b_c 、 b_o 為每一層的偏壓值。透過這三道閥門的自我學習，LSTM 可以適時的記憶重要的資料，並將與結果相關度較低的資訊遺忘，解決了 RNN 梯度消失與梯度爆炸的問題。

本研究所使用的 Discriminator 架構由輸入層、4 層卷積層以及輸出層組成，其統整架構如表 4.3 所示。卷積層中每個節點都有卷積核為 k ，每個卷積核的大小為 m ，可以表示為：

$$O_i = f\left(\sum_{k=0}^{k=m-1} x_{i+m-k} w_k + b_i\right) \quad (14)$$

其中 O_i 表示第 i 個神經元的輸出， x_i 表示第 i 個原始輸入， w 為濾波器， $f(\cdot)$ 為激活函數，本研究 Discriminator 中所使用的激活函數為 LeakyReLU。

GAN 模型架構完成後，根據倒傳遞演算法對模型權重進行更新，過程中 Generator 追求 Generator Loss 越低越好，表示 Generator 產出的資料越接近現實。Generator Loss 公式如下：

$$GeneratorLoss = \frac{1}{N} \sum_{i=1}^N \log(1 - D(G(R^i))) \quad (15)$$

其中， R 為 Generator 的輸入向量， D 為 Discriminator， G 為 Generator， N 為訓練資料。而 Discriminator 則是以 Discriminator Loss 來評估模型，Discriminator Loss 表示 Discriminator 越能判別數據的真假。Discriminator Loss 公式如下：

$$Discriminator = -\frac{1}{N} \sum_{i=1}^N \log D(X^i) - \frac{1}{N} \sum_{i=1}^N \log(1 - D(\hat{X}^i)) \quad (16)$$

其中 X 為原始資料， $\hat{X}$ 為 Generator 模擬的資料， D 為 Discriminator， N 為訓練資料。本研究透過生成對抗網路模擬符合現實狀況的資料，以減少資料蒐集所消耗的時間與人力成本。

表 4.3 Discriminator 網路架構

階層	類型	輸出大小	卷積核尺寸	步伐	標準化	激活函數
輸入	輸入層	1×11	-		-	-
C1	卷積層	1×128	3	2	-	LeakyReLU
C2	卷積層	1×128	3	2	批量標準化	LeakyReLU
C3	卷積層	1×64	3	1	批量標準化	LeakyReLU
C4	卷積層	1×64	3	1	批量標準化	LeakyReLU
輸出	全連接	1	-		-	-

4.4 運用類神經網路控制風扇的合適參數

根據上述過程產生與實際情況相符的模擬資料後，接著要訓練能給定最佳循環風扇參數的模型。由於風扇檔位屬於分類議題，風扇角度屬於迴歸議題，因此風扇的控制模型需要有兩個神經網路來找出合適的風扇檔位與風扇角度。本研究的兩個風扇控制模型輸入皆為冷氣設定溫度、室外溫度、室內人數以及各座位使用者的期望溫度，模型的輸出分別為循環風扇擺頭角度與循環風扇轉速檔位。本研究所使用的兩個模型架構分別為表 4.4 與表 4.5 所示。

表 4.4 風扇角度 ANN 架構

階層	類型	神經元數量	激活函數
輸入	輸入層	8	-
隱藏層	全連接	64	tanh
隱藏層	全連接	32	tanh
隱藏層	全連接	8	tanh
輸出	全連接	1	-

表 4.5 風扇轉速 ANN 架構

階層	類型	神經元數量	激活函數
輸入	輸入層	8	-
隱藏層	全連接	64	Relu
隱藏層	全連接	32	Relu
隱藏層	全連接	8	Relu
輸出	全連接	4	Softmax

類神經網路的各層運算方式可由以下方式表示，首先為輸入層的部分，此層網路的輸入即輸出結果，其公式如下：

$$Input_i = Output_i \quad (17)$$

其中 $Input_i$ 為輸入的 i 筆輸入， $Output_i$ 為第 i 筆輸出。接著為全連接層，其運算方式如以下公式表示：

$$m_i = \sum (w_{ij}u_i) + d_i \quad (18)$$

$$n_i = f(m_i) \quad (19)$$

其中 u_i 為第 i 筆輸入， w_{ij} 為輸入層與隱藏層連接之權重， d_i 為隱藏層偏壓值， $f(\cdot)$ 為使用的激活函數，本研究風扇角度的模型中所使用的激活函數為 Tangent Sigmoid；在風扇轉速檔位的模型中使用了 Relu 與 Softmax 兩種激活函數。



第五章 實驗模擬

本章將使用感測器蒐集的空間溫度資料集與中央氣象局雲林地區的觀測資料集來驗證本論文提出方法的有效性。內容分成四個部分，包含資料集與實驗參數介紹、GAN 模擬資料結果、風扇控制模型實驗結果，以及質化與值化合理性說明。實驗是以 Arduino C 以及 Python 所完成，並操作在 Intel Core I7- 9700K at 3.60GHz 的 CPU、Nvidia GTX 2080ti 的 GPU、搭配 16GB 記憶體以及 Windows 10 的作業軟體來完成。

5.1 資料集與實驗參數介紹

本研究使用了 2021 年 3 月 1 日 0:00 至 2021 年 6 月 15 日 23:50 分的雲林地區(古坑、西螺、林內、麥寮)氣象即時觀測資料，每 10 分鐘一筆，包含室外天氣溫度與濕度，共 15408 筆。實驗蒐集了 3 至 6 月，每個月蒐集一次的循環風扇角度搭配轉速檔位所有組合的室內 5 個座位的溫溼度資料，每 10 分鐘一筆，資料包含冷氣設定溫度、循環風扇角度、循環風扇轉速檔位、室內人數與 5 個座位的溫度、濕度，每 10 分鐘一筆，共 1692 筆。

5.2 資料前處理

由於氣象資料與實驗場所蒐集的資料皆是由感測器蒐集並上傳，在蒐集資料的過程，可能會有電源故障、網路不穩定、感測器故障等情況發生，這些狀況可能會導致缺失值或異常值的發生。本研究將缺值時長小於 24 小時的資料，利用線性插值法進行補值；大於 24 小時的缺值，以前後 24 小時的資料平均，進行補值，如圖 5.1 所示。




圖 5.1 補值結果

5.3 GAN 模擬資料結果

為了確保 GAN 模擬的資料與原始資料的分布相似，本研究採用方均跟誤差 (Root Mean Square Error, RMSE) 來評估模擬資料的相似性。RMSE 是一種常用來測量模型預測數值與期望數值之差異估計方法，RMSE 的數值越小，表示模型預測數值與期望值的差異越小，其公式如下所示：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=0}^n (prediction_i - Actual_i)^2} \quad (20)$$

圖 5.2 為模型訓練中的 RMSE 圖，可以發現在第 978 Epoch 的 RMSE 最低，因此選擇此模型作為本研究模擬室內溫度的模型。圖 5.3 為本研究所蒐集的各座位溫度資料與 Generator 產生的模擬資料的比較圖，藍色為原始資料，橘色為 Generator 產生的模擬資料，可以發現兩這的分布相近，趨勢也類似，其整體平均 RMSE 為 1.529。

為了避免模型只學習歷史資料有的各座位溫度，因此本研究分別輸入了天氣資料、冷氣設定溫度落在 16°C、20°C 和 25°C，且其他資料固定條件的情況下，Generator 所產出的各座位溫度，如圖 5.4 所示。可以發現模擬資料的各座位溫度有隨著設定溫度不同，溫度的分布也不同，證實了本研究之 GAN 模型可模擬不同冷氣設定溫度的情形。




圖 5.2 模型訓練中的 RMSE




圖 5.3 Generator 模擬資料與原始資料比較圖




圖 5.4 Generator 模擬不同冷氣設定溫度的座位溫度分佈圖

表 5.1 輸入 Generator 的亂數資料

時間 (Y/M/D h:m)	室外溫度 (°C)	室外濕度 (%)	冷氣設定溫度 (°C)	循環風扇角度 (°)	循環風扇 轉速檔位	室內 人數
2021/3/1 00:00	18.13	95	22	140	3	10
2021/3/1 00:10	18.10	95	22	140	3	7
2021/3/1 00:20	18.23	95	22	140	3	4
2021/3/1 00:30	18.15	95	22	140	3	6
2021/3/1 00:40	18.18	95	22	140	3	9
2021/3/1 00:50	18.15	95	22	140	3	2
2021/3/1 01:00	18.08	95	20	100	2	7
2021/3/1 01:10	18.05	95	20	100	2	4

本研究利用 GAN 模擬真實資料的目的在於彌補短時間資料蒐集不足與分布不均勻的問題，因此本研究以模擬人員在蒐集資料時的情況，以一個小時為更新，產生隨機冷氣設定溫度、循環風扇角度，在室內人數的部分，則是以隨機亂數產生來模擬人員在實驗空間中進出，再配合實際的氣象溫溼度，總共 6 個維度的時間序列輸入至 Generator 來產生個座位溫度的模擬資料，其輸入資料如表 5.1 所示。

5.4 風扇控制模型實驗結果

經由 Generator 模擬完資料後，本研究將模擬資料與真實資料混合在一起，並切分成 70%訓練集、15%驗證集與 15%的測試集。在循環風扇角度模型的部分，本研究將室外溫度、冷氣設定溫度、室內人數與各座位使用者的期望溫度作為模型的輸入，循環風扇的角度作為輸出；在循環風扇轉速檔位模型部分，與循環風扇角度模型的輸入相同，輸出為循環風扇轉速檔位，並且將循環風扇轉速檔位以 One Hot Encoding 進行轉換，如圖 5.5 所示。




圖 5.5 風扇轉速檔位經 One Hot Encoding 轉換

5.4.1 循環風扇角度模型量化合理性說明

經由類神經網路訓練完畢後，為了驗證模型的有效性，本研究將測試資料與模型的輸出視覺化前 500 筆資料，如圖 5.6 所示，並以 RMSE 進行評估，其 RMSE 結果為 10.56，可以發現，模型的輸出角度皆與測試資料及相似。除了以 RMSE 來評估模型，本研究也將模型的輸出與原始資料進行 Error Histogram 繪製，若其誤差越接近常態分布，則表示模型的輸出績效越佳，若誤差非常態分布，則反之。其結果如圖 5.7 顯示，模型的輸出角度的誤差值呈現常態分布，驗證此模型的有效性。




圖 5.6 模型輸出角度與原始風扇角度比較圖




圖 5.7 模型輸出之誤差長條圖

5.4.2 循環風扇轉速檔位模型量化合理性說明

因為循環風扇轉速檔位屬於分類議題，為了驗證模型的準確性，本研究將以混淆矩陣與 precision 與 recall 的評分結果進行評估。混淆矩陣結果如表 5.2 所示。模型輸出的正確率約 95.3%。模型準確性評估除了觀察混淆矩陣外還要考慮 precision 與 recall 分類評分結果如表 5.3 所示。

表 5.2 循環風扇轉速檔位模型之混淆矩陣

Total population(T=2565)		True Condition			
		0	1	2	3
Predicted Outcome	0	597	17	2	0
	1	28	572	16	3
	2	0	23	585	14
	3	0	2	16	690

表 5.3 循環風扇轉速檔位模型之混淆矩陣

循環風扇轉速檔位	precision	recall
0	0.96	0.97
1	0.93	0.92
2	0.95	0.94
3	0.98	0.97

表中 precision 表示在預測都是正確的狀況下判斷真假的準確度為多少，而 Recall 為在都是真的情況下，能模型能正確判斷有多少，如果這兩個評分結果皆為 0% 表示模型無法判斷真假，但從表格可以看出，各類別的 precision 與 recall 都達到 90% 以上的水平，可以證明本研究所訓練出來的模型有很高的準確性。

5.4.3 循環風扇控制模型整體量化合理性說明

接著，本研究要驗證風扇控制模型是否能如期達到使用者的理想溫度，因此將控制模型預測的循環風扇設定與室外溫度、室外濕度、冷氣設定溫度、室內人數輸入至 Generator 觀察輸出的溫度是否接近使用者的期望溫度，其 RMSE 為 4.19，前 150 筆的結果如圖 5.8 所示。從圖 5.8 中可以觀察到，在循環風扇模型預測條件下的各座位溫度，都非常趨近於使用者的期望溫度，表示本研究所使用的循環風扇模型效果良好。




圖 5.8 使用者期望溫度與風扇模型預測條件下的各座位溫度比較圖

5.5 質化合理性說明

本小節將以幾種風扇控制模型的輸出進行質化驗證的說明。本研究的實驗空間位於頂樓且西曬，再加上冷氣的出風口在實驗空間之東南方，因此於位於西側的座位 3 和座位 4 會相對於座位 1、座位 2 與座位 5 較炎熱。圖 5.9 為冷氣設定 19 度時，風扇未啟動的狀態，由圖 5.9 中可以觀察出，座位 3 和座位 4 的溫度確實比其他座位溫度要高出許多。




圖 5.9 冷氣設定 19 度之各座位溫度變化




圖 5.10 使用者座位期望溫度 28 度的溫度分布

若使用者期望座位 3 與座位 4 溫度與其他座位相似時，循環風扇的角度應向實驗空間的中間或者西邊進行送風，假設室外溫度大於 30 度，冷氣設定在 16 度時，所有座位的使用者期望溫度皆為 28 度，經由循環風扇控制模型產出的角度落在 100 度至 130 度之間、轉速檔位為 2，其溫度分布如圖 5.10 所示。從圖 5.10 中可以發現，座位 5 的溫度相較於其他座位溫度較低，是因為座位 5 位於冷氣出風口的下方；座位 3 的溫度比座位 4 要低，是因為風扇角度在 100 至 130 度的方向時，往座位 3 送的風較座位 4 多；而座位 2 比起座位 1，距離冷氣出風口較遠，且循環風扇的方向並向座位 2 送風，因此座位 2 的溫度普遍高於其他座位。最終，風扇所建議的角度，是在循環風扇未啟動時，座位溫度較熱的座位 3 與座位 4 方向送風。而經由循環風扇送風後，該座位溫度也明顯降低，可以證實本研究所提出的方法合理性。

第六章 結論與未來研究

辦公室溫度分布不均一直都是備受矚目的話題，勞工對於環境溫度的舒適度，也會影響工作的效率。若能提升勞工在辦公環境的舒適度，進而促使整體生產率的提昇，對於管理者是相當重要的調整策略。要建立一個循環風扇系統使各座位溫度符合使用者的期望，則需要花費大量的時間與人力來蒐集資料進行訓練。因此本研究提出了兩個概念，一是透過 GAN 的方式來模擬大量的歷史資料，減少人力與時間的耗費；二是以智慧型控制的概念，建立循環風扇的控制模型來產生循環風扇的參數，使各座位的溫度能趨近於使用者的期望。整體而言，本研究證實生成對抗網路可以模擬出符合實際狀況的時間序列資料，且透過本研究建立的類神經網路架構，在合適的冷氣設定溫度條件下，所產生之循環風扇擺頭角度與轉速檔位，可以使各座位溫度趨近於使用者期望溫度。最後，本研究在空間溫度的時間序列資料驗證下，證明方法的有效性，若要實現自動化的應用，還需要縮減風扇的控制模型，來減少硬體上的大量計算成本。

針對未來的研究，可由以下幾個討論點進行延伸：1.可將循環風扇的控制模型壓縮或刪減，並應用至控制板上，達到全自動化的應用；2.可以將本研究的概念應用到其他時間序列相關的議題上，來驗證本研究所提出的概念。

參考文獻

- [1] Hedge, W. Sakr, and A. Agarwal, "Thermal effects on office productivity," *Proceeding on Proceedings of the human factors and ergonomics society annual meeting*, vol. 49, no. 8, pp. 823-827, 2005.
- [2] A. Lipczynska, S. Schiavon, and LT. Graham, "Thermal comfort and self-reported productivity in an office with ceiling fans in the tropics," *Building and Environment*, vol. 135, pp. 202-212, 2018.
- [3] A. Stanislavsky, W. Nitka, M. Małek, K. Burnecki, and J. Janczura, "Prediction performance of Hidden Markov modelling for solar flares," *Journal of Atmospheric and Solar-Terrestrial Physics*, vol. 208, 2020.
- [4] B. Chen, Y. Liu, C. Zhang, and Z. Wang, "Time series data for equipment reliability analysis with deep learning," *IEEE Access*, vol. 8, pp. 105484-105493, 2020.
- [5] B. Satpati, C. Koley, PS. Bhowmik, and S. Datta, "Nonlinear Hammerstein-Hammerstein identification of air preheating furnace of a pneumatic conveying and drying process," *Proceeding on IEEE Conference on Control Applications*, pp. 397-402, 2014.
- [6] C. Yu, Y. Li, Y. Bao, H. Tang, and G. Zhai, "A novel framework for wind speed prediction based on recurrent neural networks and support vector machine," *Management*, vol. 178, pp. 137-145, 2018.
- [7] C.A.V. Cardoso, and G.L. Cruz, "Forecasting natural gas consumption using ARIMA models and artificial neural networks," *IEEE Latin America Transactions*, vol. 14, pp. 2233-2238, 2016.
- [8] FA. Gers, J. Schmidhuber, and F. Cummins, "Learning to Forget: Continual Prediction with LSTM," *Neural Computation*, vol. 12, 2000.

- [9] G. Chiesa, D.D. Vita, A. Ghadirzadeh, A.H.M. Herrera, and J.C.L. Rodriguez, "A fuzzy-logic IoT lighting and shading control system for smart buildings," *Automation in Construction*, vol. 120, 2020.
- [10] G.E.P. Box, and G.M. Jenkins, "Some recent advances in forecasting and control," *Journal of the Royal Statistical Society. Series C*, vol. 17, pp. 91-109, 1968.
- [11] H. Yan, Y. Qin, S. Xiang, Y. Wang, and H. Chen, "Long-term gear life prediction based on ordered neurons LSTM neural networks," *Measurement*, vol. 165, 2020.
- [12] H. Yang, Y. Li, X. Yan, and F. Cao, "ContourGAN: Image contour detection with generative adversarial network," *Knowledge-Based Systems*, vol. 164, pp. 21-28, 2019.
- [13] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial nets," *Proceeding on Advances in neural information processing systems*, vol. 27, 2014.
- [14] J. Guo, H. He, and C. Sun, "ARIMA-Based Road Gradient and Vehicle Velocity Prediction for Hybrid Electric Vehicle Energy Management," *IEEE Transactions on Vehicular Technology*, vol. 68, 2019.
- [15] J. Ma, W. Yu, P. Liang, C. Li, and J. Jiang, "FusionGAN: A generative adversarial network for infrared and visible image fusion," *Information Fusion*, vol. 48, pp. 11-26, 2019.
- [16] J. Shi, Q. He, and Z. Wang, "An LSTM-based severity evaluation method for intermittent open faults of an electrical connector under a shock test," *Measurement*, vol. 173, 2021.
- [17] JS. Wang, and YC. Chen, "A Hammerstein-Wiener recurrent neural network with universal approximation capability," *Proceeding on IEEE International Conference on Systems, Man and Cybernetics*, pp. 1832-1837, 2008.

- [18] K. Narendra, and P. Gallman, "An iterative method for the identification of nonlinear systems using a Hammerstein model," *IEEE Transactions on Automatic control*, vol. 11, pp. 546-550, 1966.
- [19] L. Wang, J. Pan, Y. Gao, B. Wang, K. Hong, and X. Chen, "Incipient fault diagnosis of limit switch based on a ARMA model," *Measurement*, vol. 135, pp. 473-480, 2019.
- [20] M. Akram, S. Habib, and I. Javed, "Intuitionistic fuzzy logic control for washing machines," *Indian Journal of Science and Technology*, vol. 7, pp. 654, 2014.
- [21] M. Delwar Hossain, H. Inoue, H. Ochiai, D. Fall, and Y. Kadobayashi, "LSTM-Based Intrusion Detection System for In-Vehicle Can Bus Communications," *IEEE Access*, vol. 8, pp. 185489-185502, 2020.
- [22] M. Kang, and FY. Wang, "From parallel plants to smart plants: intelligent control and management for plant growth," *IEEE/CAA Journal of Automatica Sinica*, vol. 4, pp. 161-166, 2017.
- [23] M. Lasfar, and H. Bouden, "A method of data mining using Hidden Markov Models (HMMs) for protein secondary structure prediction," *Procedia Computer Science*, vol. 127, pp. 42-51, 2018.
- [24] M. Radaideh, C. Pigg, T. Kozlowski, Y. Deng, and A. Qu, "Neural-based time series forecasting of loss of coolant accidents in nuclear power plants," *Expert Systems with Applications*, vol. 160, 2020.
- [25] M. Rhode, P. Burnap, and K. Jones, "Early-stage malware prediction using recurrent neural networks," *Computers & Security*, vol. 77, pp. 578-594, 2018.
- [26] M. Wu, WH. Cao, CY. He, and JH. She, "Integrated Intelligent Control of Gas Mixing-and-Pressurization Process," *IEEE Transactions on Control Systems Technology*, vol. 17, pp. 68-77, 2009.
- [27] N. Formosa, M. Quddus, S. Ison, M. Abdel-Aty, and j. Yuan, "Predicting real-time

- traffic conflicts using deep learning," *Accident Analysis & Prevention*, vol. 136, 2020.
- [28] R. Niemelä, M. Hannula, S. Rautio, K. Reijula, J. Railio, "The effect of air temperature on labour productivity in call centres—a case study," *Energy and Buildings*, vol. 34, pp. 759-764, 2002.
- [29] S. Hochreiter, and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, pp. 1735-1780, 1997.
- [30] S. Liu, S. Gu, and J. Peng, "Self-adaptive processing and forecasting algorithm for univariate linear time series," *Chinese Journal of Electronics*, vol. 26, pp. 1147-1153, 2017.
- [31] S. Takahashi, Y. Chen, and K. Tanaka-Ishii, "Modeling financial time-series with generative adversarial networks," *Physica A: Statistical Mechanics and its Applications*, vol. 527, 2019
- [32] S. Wang, Y. Hui, X. Sun, and D. Shi, "Neural Network Sliding Mode Control of Intelligent Vehicle Longitudinal Dynamics," *IEEE Access*, vol. 7, pp. 162333-162342, 2019.
- [33] SN. Singh, and A. Mohapatra, "Repeated wavelet transform based ARIMA model for very short-term wind speed forecasting," *Renewable Energy*, vol. 136, pp. 758-768, 2019.
- [34] W. Chen, H. Zhang, E. Arens, M. Luo, Z. Wang, L. Jin, J. Liu, F.S. Bauman, P. Raftery, "Ceiling-fan-integrated air conditioning: Airflow and temperature characteristics of a sidewall-supply jet interacting with a ceiling fan," *Building and Environment*, vol. 171, 2020.
- [35] W. Jiang, Y. Hong, B. Zhou, X. He, and C. Cheng, "A GAN-based anomaly detection approach for imbalanced industrial time series," *IEEE Access*, vol. 7, pp. 143608-

143619, 2019.

- [36] W. Li, and T. Liu, "Time varying and condition adaptive hidden Markov model for tool wear state estimation and remaining useful life prediction in micro-milling," *Mechanical Systems and Signal Processing*, vol. 131, pp. 689-702, 2019.
- [37] W. Mao, Y. Liu, L. Ding, and Y. Li, "Imbalanced Fault Diagnosis of Rolling Bearing Based on Generative Adversarial Network: A Comparative Study," *IEEE Access*, vol. 7, pp. 9515-9530, 2019.
- [38] WK. Lennon, and KM. Passino, "Intelligent control for brake systems," *IEEE Transactions on control systems technology*, vol. 7, pp. 188-202, 1999.
- [39] X. Lu, J. Wang, Y. Yan, L. Zhou, and W. Ma, "Estimating hourly PM2.5 concentrations using Himawari-8 AOD and a DBSCAN-modified deep learning model over the YRDUA, China," *Atmospheric Pollution Research*, vol. 12, pp. 183-192, 2021.
- [40] Y. Fei, K. Gao, J. Hu, J. Tu, W. Li, W. Wang, and G. Zong, "Predicting the incidence of portosplenomesenteric vein thrombosis in patients with acute pancreatitis using classification and regression tree algorithm," *Journal of Critical Care*, col. 39, pp. 124-130, 2017.
- [41] Y. He, K. Song, H. Dong, and Y. Yan, "Semi-supervised defect classification of steel surface based on multi-training and generative adversarial network," *Optics and Lasers in Engineering*, vol. 122, pp. 294-302, 2019.
- [42] Y. Zhao, Y. Li, L. Zhang, and Q. Wang, "Groundwater level prediction of landslide based on classification and regression tree," *Geodesy and Geodynamics*, vol. 7, pp. 348-355, 2016.
- [43] Z. Guo, Y. Wan, and H. Ye, "A data imputation method for multivariate time series based on generative adversarial network," *Neurocomputing*, vol. 360, pp. 185-197,

2019.

- [44] Z. Liu, Z. Cai, and X. Tan, "Forecasting research of aero-engine rotate speed signal based on ARMA model," *Procedia Engineering*, vol. 15, pp. 115-121, 2011.
- [45] Z. Xu, S. Liu, G. Hu, and C.J. Spanos, "Optimal coordination of air conditioning system and personal fans for building energy efficiency improvement," *Energy and Buildings*, vol. 141, pp. 308-320, 2017.
- [46] <https://github.com/jonbruner/generative-adversarial-networks/blob/master/gan-notebook.ipynb>

