

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management
National Yunlin University of Science & Technology
Master Thesis

利用生成對抗網路產生模擬資料以提昇刀具磨耗預測
之準確率

Improve the Accuracy of Tool Wearing Prediction by
Using the Mock Data Generated by Generative
Adversarial Networks



陳柏翔

Bo-Xiang Chen

指導教授：蘇純繒 博士

Advisor: Chwen-Tzeng Su, Ph.D.

中華民國 110 年 6 月

June 2021

摘要

刀具壽命一直是工廠所重視的問題之一。一個好的刀具監控系統，可以讓工廠準確判斷刀具更換的時間點，以減少產品損壞。一般來說，建立刀具監控系統需要大量的刀具磨耗數據，讓系統能夠更加完善，但在蒐集數據上會造成耗費太多時間與人力。另外，現有的大多數研究也僅考慮了單一模型進行刀具磨耗分類，導致能提升的績效有限。因此，本研究提出了 GCEL 架構 (GAN-CNN-Ensemble Learning) 來解決過往研究的問題。首先，利用生成對抗網路產生模擬實際狀況資料，降低工廠蒐集數據的成本，接著，使用卷積類神經網路進行分類，並結合集成式學習框架提升模型分類準確性，最後，本研究使用原始刀具磨耗資料進行驗證，結果證明本研究所提出的架構能夠有效提升刀具磨耗分類的準確率。


關鍵字：刀具磨耗預測、生成對抗網路、深度學習模型、集成式學習



Abstract

Tool life is one of the many important issues in any factory. A good tool monitoring system allows a factory to accurately determine the tool replacement time and reduce damage to products. Establishing a tool monitoring system generally requires a large amount of data on tool wear to make the system more complete; however, collecting data often requires too much time and too many resources. Most studies have only considered a single model to classify tool wear, resulting in limited improvements in performance. In this paper, we propose the use of GCEL Architecture (GAN-CNN-Ensemble Learning) to solve the aforementioned problems by (1) using the Generative Adversarial Network to simulate actual situation data to reduce the cost of data collection and (2) using a convolutional neural network combined with ensemble learning to improve the accuracy of classification in this model. Original tool wear data were used for verification. The results show that the structure proposed in this paper can effectively improve the accuracy of tool wear classification.

Keywords: Tool Wear, Generative Adversarial Network, Deep Learning, Ensemble Learning



誌謝

原先在台中讀書的我，一開始剛到斗六這個不熟悉的环境時，其實有些不習慣，但多虧我的兩位指導老師蘇純繒老師以及陳奕中老師，純繒老師在這兩年中給予我許多資源，讓我很棒的實驗室可以在裡面進行研究，也提供我足夠的電腦設備學習以及論文方向的建議，使我在研究上沒有後顧之憂；再來是奕中老師，除了大學階段以及研究所階段皆有他的教導，在研究上遇到困難時，老師通常都是引導我去思考，放手讓我去嘗試，即使遇到困難了老師仍不厭其煩的指導著我，除了精進我在程式撰寫上的能力，更提升我在報告上以及文書編排上的能力，只能說在外縣市求學的這兩個階段，奕中老師不僅在學業上用心的指導，更在生疏的環境因為有他，讓我多了份安全感。在此向我敬愛兩位指導老師蘇老師和陳老師致上最誠摯的謝意。研究所短短兩年的時光就此畫下句點，人生也要開始要起步，在學期間除了兩位指導老師以外，也得到許多人的幫助，首先感謝富正學長、志豪學長、東錡學長、映均學姊，幾位學長姊們一直都是我非常崇拜的對象，他們的思考邏輯以及口條方面皆非常傑出，也在我報告上給予我許多建議，讓我在發表時更加流暢。接著，感謝我的同窗吉晟、峻棠、姿靜、靜瑜、文成、力誠、詠緹、政傑、瀚毅，與學弟妹香蘭、佳昇、佑蓉、重佑、承安，他們除了給予我課業上的幫助與支持，實驗室也會參與校外競賽或研討會，我也時常與他們進行討論與問題的交流，未來也許我們不一定會在同縣市工作，但在研究所這段日子的點點滴滴我會銘記在心。最後我要感謝一直在背後默默支持著我的爸爸媽媽，雖然他們心中總希望我能趕快出社會去磨練並累積經驗，但仍支持我想要繼續進修的目標，並給我支持與鼓勵，讓我沒有後顧之憂的完成碩士學位。在人生的這條道路上，最初是他們牽著我開始認識這個世界，隨著時光的流逝，在外縣市求學的階段，有時候回到家看到父母總會覺得他們又老了一些，心中總會覺得有點不捨又有點愧疚，他們不求回報的支持讓我可以順利完成學業，未來期望我能在社會上透過我在學階段所學習到的東西獲得一些成就，讓我的父母以後在退休後能夠有好的生活可以享福。最後再次真摯的感謝所有在我求學階段所幫助過我的所有人，我未來會更努力為這個社會奉獻更多的價值。

目錄

第一章	緒論	1
1.1	研究背景與動機	1
1.2	研究目的	3
1.3	研究限制	3
1.4	論文架構	3
第二章	文獻回顧	4
2.1	刀具磨耗預測方法	4
2.1.1	影響刀具磨耗因素	4
2.1.2	機器學習	5
2.1.3	深度學習	7
2.2	數據生成	8
2.2.1	上採樣(Oversampling)	9
2.2.2	下採樣(Downsampling)	12
2.3	集成式學習(Ensemble Learning)	13
2.4	小結	15
第三章	資料集	16
3.1	資料集介紹	16
3.2	資料集觀察	16
3.3	處理資料集所遇到的困難	19
第四章	研究方法	20
4.1	資料清洗	20
4.1.1	線性補值	20
4.1.2	時序矩陣資料	21
4.1.3	利用生成對抗網路增生資料	21
4.2	利用時域與頻域提取重要特徵值	24
4.2.1	時序特徵提取	25
4.2.2	快速傅立葉轉換	26
4.2.3	連續小波轉換	26
4.3	卷積類神經網路	27
4.4	結合集成式學習提昇刀具磨耗分類準確性	30
第五章	實驗模擬	32
5.1	資料前處理	32
5.2	平衡資料集與結果	32
5.2.1	資料平衡結果	32
5.2.2	混淆矩陣結果	34
5.2.3	敏感度分析(ROC 曲線與 mAP 曲線)	37
5.2.4	小結	42
5.3	提升績效方法	42
第六章	結論與未來研究	43
	參考文獻	44

圖目錄

圖 1.1 蒐集數據過程	2
圖 1.2 機器學習方法流程	2
圖 2.1 刀具磨損階段曲線[34]	5
圖 2.2 機器學習與深度學習的差異	7
圖 2.3 資料增強	9
圖 2.4 smote 生成方法	10
圖 2.5 生成對抗網路架構圖[56]	11
圖 2.6 下採樣	13
圖 3.1 PHM2010 資料視覺化結果	17
圖 3.2 刀具狀態分界	17
圖 3.3 聲發射(Acoustic Emission,AE)箱型圖	18
圖 3.4 其餘六個特徵箱型圖	18
圖 3.5 刀具磨耗類別分佈	19
圖 4.1 研究流程圖	20
圖 4.2 序列轉換時序矩陣	21
圖 4.3 生成對抗網路模型	22
圖 4.4 透過快速傅立葉轉換成頻域	26
圖 4.5 透過連續小波轉換之時頻圖	27
圖 4.6 矩陣資料圖	28
圖 4.7 卷積過程圖	28
圖 4.8 最大池化過程圖	29
圖 5.1 線性插值方法結果	32
圖 5.2 生成資料前後比較圖	33
圖 5.3 訓練過程的 FID score	33
圖 5.4 迭代次數比較圖	34
圖 5.5 原始資料經由 GAN 平衡後提取時序特徵的 ROC 圖	37
圖 5.6 原始資料經由 GAN 平衡後提取時序特徵的 mAP 圖	38
圖 5.7 未處理平衡資料與平衡後的 ROC 比較圖(上圖為未資料平衡下圖為資料平衡後).....	40
圖 5.8 未處理平衡資料與平衡後的 mAP 比較圖(上圖為未資料平衡下圖為資料平衡後).....	41

表目錄

表 2.1 刀具磨耗統計分析之相關文獻整理	5
表 2.2 刀具磨耗機器學習之相關文獻整理	7
表 2.3 刀具磨耗機器學習之相關文獻整理	8
表 2.4 SOMTE 之相關文獻整理	10
表 2.5 生成對抗網路之相關文獻整理	12
表 2.6 刀具磨耗機器學習之相關文獻整理	14
表 3.1 PHM2010 資料欄位	16
表 4.1 生成網路架構	23
表 4.2 鑑別網路架構	24
表 4.3 卷積類神經架構	30
表 5.1 所有方法之混淆矩陣	34
表 5.2 所有方法 ROC 曲面下面積結果	39
表 5.3 所有方法 mAP 曲面下面積結果	40
表 5.4 生成資料評估	42
表 5.5 集成學習評估	42



第一章緒論

1.1 研究背景與動機

一直以來，機台的定期維修及耗材的更換對於工廠的成本花費而言，有著舉足輕重的影響力。根據統計，在加工的過程中有 75% 的故障是由刀具損毀引起的[44]，且生產成本約有 18% 是與刀具狀況有直接或間接關係[32]。一般工廠常使用 CNC 工具機進行加工，在加工的過程中，刀具的磨損狀態是影響工件品質的主要因素。舉例來說，在銑削的加工過程中刀具會高速旋轉對工件進行平面的切削，刀具與工件接觸會產生磨擦導致刀具磨損，磨損達到一定程度時，刀具會變鈍或者斷裂。斷裂嚴重的情況下會導致加工機台停頓且會刮傷工件，造成工廠的損失。然而在實際工廠生產的情況下，通常都是依據作業員個人經驗判斷刀具的更換時間點。而這產生的主要問題點是無法決定做下一個工單之前是否要更換刀具，造成(1)作業員為了不損毀工件，在執行加工前都更換新的刀具，導致刀具更換太早，造成生產成本提高，或者(2)使用同一把刀具進行加工，超出刀具使用壽命，可能導致工件損壞或機台故障。若要達成生產成本與停機時間最小化，就必須知道最佳的換刀具時間點。如果能知道加工時的刀具磨耗就能有效做到刀具壽命的控管，進而可以做到刀具與工件的排程。因此，近年來機台加工過程的刀具監控也引起了學界與業界的關注，過往許多學者運用不同方法，針對刀具監控議題做了很多不同的嘗試，進而解決工廠中的刀具磨耗導致機台受損的問題，大致可以分為以下步驟 1. 刀具磨耗相關數據蒐集 2. 使用模型進行預測刀具磨耗量：

1. 刀具磨耗相關數據蒐集

在進行刀具監控之前，需要蒐集相關數據，因此過往研究為了蒐集數據進行分析，通常學者使用的蒐集方式都是採用切削工件一次，並用儀器測量刀具磨耗值做紀錄，重複以上動作直到刀具壽命結束，如圖 1.1 所示。但是這樣蒐集數據方式與工廠真實加工情況是不相符的，主要是因為工廠在每次加工過程都是有連貫性的，不會每刀都停機做刀具磨耗的測量，又加上目前刀具磨耗可以蒐集到的數據大多都是以正常磨耗值為主，而不在正常磨耗值的數值則相較下較為少量，導致資料不平衡的問題發生。




圖 1.1 蒐集數據過程

2. 應用模型預測刀具的磨耗量

(1) 應用機器學習預測刀具的磨耗量

機器學習方法是將原始資料進行視覺化，觀察特徵之間的關係，並運用到大量的專業知識提取特徵值，經過降維後進行建立模型，圖 1.2 所示。Wang *et al.* [33] 提出了運用提取頻率與時頻特徵，結合多種降維及統計方法並用支持向量機(SVR)來預測刀具磨耗，Kong *et al.*[4]則是運用小波提取特徵，並用高斯過程回歸(GPR)計算刀具的磨損。




圖 1.2 機器學習方法流程

上述的方法雖然可以預測刀具的磨耗量，但是過程還是有以下缺點 I)需要依賴專業人士的先驗知識，II)在進行降維方法時經常會都失原始資料部分資訊，導致準確度受到限制。

(2) 應用深度學習預測刀具的磨耗量

近年來，深度學習已被廣泛用運在不同的議題上，智慧製造議題也不例外，除了突破機器學習所到達不到的準確性外也解決了機器學習依賴專業知識提取特徵的方法，運用強大的模型如：卷積類神經網路(CNN)、遞迴類神經網路(RNN)、長短期記憶網路(LSTM)等，進行刀具磨耗的預估。如 Shi *et al.*[27]提取多維度空間運用深度學習來監控刀具狀態，Cheng *et al.*[44]運用小波分析結合卷積類神經網路(CNN)監控機台狀況。雖然深度學習相較於機器學習具有更高的準確性，但深度學習在訓練過程需要大量資料，對於一般工廠來說是一大負擔。

綜合上述兩點作法可以發現到以下幾項問題，(1)過去學者在蒐集資料方法的過程中，效率較差且較不符合實際工廠真實加工情況。(2)資料內容大多都以正常磨

耗值為主，導致資料不平衡的問題。(3)雖然深度學習可以解決機器學習的模型缺點，但若要使用深度學習進行模型訓練，則需要大量的歷史資料，反而導致花費更多的蒐集資料成本。(4)只運用單一模型進行預測，過去學者不論是建立機器學習模型或是深度學習模型大多都以單一模型進行刀具磨耗預測，大多都能提升預測模型能力，但能夠提升的績效較為有限。因此如何運用少量的資料，使訓練模型達到良好的績效，並有效控管刀具壽命以維護加工的穩定性，都是目前需要解決的一大課題。

1.2 研究目的

為了解決上述的問題，本研究建立 GCEL 架構(GAN-CNN-Ensemble Learning)，該架構利用生成對抗網路來解決資料不平衡的問題，並結合集成式學習框架進行刀具磨耗分類，而 GCEL 架構主要提出兩個概念解決過往研究的問題，(1)利用生成對抗網路產生模擬實際狀況資料，降低工廠蒐集數據的成本，(2)使用卷積類神經網路進行分類，並結合集成式學習框架提升模型分類準確性。以下將詳細說明。

(1)針對過往繁瑣的蒐集磨耗量的方式難以蒐集到大量數據，為了解決該問題，本研究運用生成對抗網路，只需要使用少許資料就能生成符合現實情況的資料，以及生成更多不同狀況下的資料，使資料集更完整，讓結果可以更符合實際工廠運作。

(2)利用不同特徵擷取的方法，有時間序列特徵擷取、快速傅立葉轉換與連續小波轉換的手法將原始資料轉為不同變化的型態，將結果當作卷積類神經模型的輸入並進行訓練，最後透將每個模型結合淺層類神經網路，運用集成式學習堆疊法來提升刀具磨耗分類的準確率。

1.3 研究限制

本研究所使用的磨耗數據，只考慮機台參數固定下，單一刀具與不鏽鋼(HRC52)材質工件一對一的磨耗情況，不考慮其他金屬材質的工件磨耗。

1.4 論文架構

本篇論文主要架構如下：第二章是以相關文獻探討與回顧為主要內容，說明本研究所使用到的分析方法；第三章介紹本研究所使用到的數據資料及內容；第四章針對本研究的研究方法和步驟流程進行說明；第五章為實驗模擬；第六章為結論與未來研究。

第二章文獻回顧

本章節將分成三個小節，分別是刀具磨耗預測方法、數據生成、集成式學習，在 2.1 小節中將介紹過往學者在刀具磨耗特性的相關研究，以及學者所使用的方法之間的差異，更了解如何運用不同方法在機器檢測上，並且從中理解各個方法特色與優點，接著在 2.2 小節中將詳細介紹數據生成，過往學者使用哪些方法生成資料，並針對如何確保資料符合現實情況進行說明。而 2.3 小節中著重於介紹集成式學習，針對將目前學者常運用到的集成模型進行探討。

2.1 刀具磨耗預測方法

刀具對工廠來說是重要的工具，而刀具在加工過程中會出現磨損與斷掉情形發生，導致加工零件因此受損造成生產成本提高，因此過往學者針對此問題提出了許多改善方法，以下將詳細進行說明。

2.1.1 影響刀具磨耗因素

在有限的數據資源下，過往學者一開始會利用統計分析方法去得到研究所需要的資料，並透過建立合適的目標數學式與條件數學式，來找出影響刀具變異的因素，使刀具的加工品質損失最小。然而透過建立統計數學模型後的結果發現到，影響刀具壽命主要原因為切削速度、切削深度、切削寬度、振動、刀具材料與工件材質，舉例來說，Bhuiyan *et al.*[33]使用聲發射感測器(AE sensor)蒐集工具機切削過程所產生聲波信號去預測刀具磨耗，並分析觀察刀具的狀態，發現切削主軸加速度、切削深度與切削寬度對刀具磨損狀態影響很大，Dolinsek *et al.*[42]也運用相同感測器檢測到不同刀具的磨損狀態與工件材質是有關係的，Erturk *et al.*[43]提到加工參數(切削速度、切削時間、切削深度)與刀具磨耗呈線性增加關係，因此得知這些參數皆會影響刀具磨耗的程度，Bhuiyan *et al.*[32]學者運用機台轉速與機台電流之間的變化關係進行刀具磨耗預測，其中原理與主軸轉速有關，當刀具變鈍切割時轉速會變慢，機台為了提升轉速進而提高電流使轉速提高達到切割所需轉速。在加工過程中，刀具超過某個磨耗值時，對工件影響層面有所不同，而 Wang *et al.*[34]將正常刀具磨損的過程分為三個階段，分別為初始磨損階段(A)、正常磨損階段(B)、劇烈磨損階段(C)，如圖 2.1 所示，各階段說明如下。初始磨損階段：此階段磨損，由於刀具每一刀不一定等長加上新刀具比較銳利，所以這一階段磨耗比較快。正常

磨損階段：刀具經過初始磨損階段後，不等長刀刃已經磨平，承受壓力面積變大，壓力變小，使得磨耗速度明顯趨緩，刀具進入正常磨耗階段，磨耗狀況比較緩慢且穩定，沒有劇烈起伏。劇烈磨損階段：此時刀具已經變鈍，切削阻力增大，磨損率增加，摩擦力變大，切削力與切削溫度上升，磨損速度明顯增加很快，刀具處於隨時發生壞掉現象。在實際工廠加工中，工廠應在進入此階段磨耗之前更換刀具，來避免劇烈急升且不穩定的刀具磨耗影響到工廠加工品質。




圖 2.1 刀具磨損階段曲線[34]

而工廠普遍認為的刀具壽命為刀具開始進行切削直到刀具無法再進一步加工的使用時間，但刀具壽命會根據切削方式不同，導致刀具無法切割的原因也有所不同，因此如何定義刀具壽命成了至關重要的事情，為了能達到一致性與可比較性，ISO 8688-2[19]提供了替換刀具的標準為平均每刀磨耗超過 0.3mm，單一刀磨耗超過 0.5mm，透過此標準可以確定刀具是否可以繼續加工。

表 2.1 刀具磨耗統計分析之相關文獻整理

作者	方法
Bhuiyan <i>et al.</i> [33] Dolinsek <i>et al.</i> [42] Erturk <i>et al.</i> [43]	利用聲發射感測器(AE sensor)蒐集聲波信號 熱反應擴散技術
Bhuiyan <i>et al.</i> [32] Wang <i>et al.</i> [34]	使用機台電流與機台轉速之間的關係 堆疊式自動編碼器 (SAE) 模型、LSTM

2.1.2 機器學習

機器學習屬於一種演算法的設計，分為監督式學習與非監督式學習，常見的監督式機器學習方法有隨機森林(Random Forest)、決策樹(Decision Tree)、支援向量機(Support Vector Machine, SVM)等等；而常見的非監督式機器學習方法有分群演算法(K-means Clustering)和混合模型(Gaussian Mixture Model)等等，兩者差異為資

料是否被標記或是被定義。機器學習簡單而言，其實就是讓電腦透過資料去學習，並根據經驗改進，幫助人類有效率的找出最佳規則，而資料量越多，該模型準確度越高。在傳統的機器學習中常見的使用流程，首先從資料取出對分析有用的資訊(i.e.特徵值選取，降維方法)後，針對取出的特徵值放進不同模型進行建模，這樣的方法也常應用於工廠內的機器檢測或是刀具磨耗監控。針對機台檢測部分，舉例來說，Sun *et al.*[12]提出 KS-LLE 方法去分析變速箱測試台上所測得的數據，在機台訊號處理上有效的提取特徵與降維方法後，與傳統的流形學習(Manifold Learning，為機器學習的一種)相比後進行建模，該研究所提出的方法可以提升變速箱的故障檢測之有效性，進而降低計算成本。機台上的軸承是工廠常見的組件之一，其與其他機器的零件相比下更容易損壞，而 Jalali *et al.*[45]提出基於基因演算法(Genetic Algorithm)的特徵挑選方法結合機器學習支持向量機(SVM)，進行智慧檢測滾珠軸承的故障分類。另外，針對刀具磨耗監控的部分，Mohanraj *et al.*[47]則主要預測常見的加工機切削工具-銑刀，該研究使用蒐集到的震動數據，從該數據提取小波係數，並利用 SVM、KNN、多層感知器和決策樹等等的機器學習算法進行預測，其結果發現決策樹進行特徵挑選的方法結合支持向量機，對於監測銑刀狀態的準確率最高。Gomes *et al.*[29]也運用感測器蒐集振動數據，透過 RFE 方法(Recursive Feature Elimination，遞迴式特徵消除)進行特徵選取，再使用支持向量機模型進行更為精密的微型切削刀具磨耗預測。Corne *et al.*[39]則是利用機台主軸功率數據做分析，並透過類神經網路(ANN)來進行預測鑽孔過程的磨耗與破損。Hesser *et al.*[14]為了進行刀具狀態的分類，利用加速度數據進行分析，並透過類神經網路進行分類，以達到 CNC 刀具磨耗的監控。Li *et al.*[55]提出了一種新穎的信號檢測方法，來取代較為昂貴的感測器，該方法結合隨機森林(Random Forest)分類器與多元線性回歸(Multiple Linear Regression)，以檢測不同磨損時間的磨耗切削能力。從上述的研究可以得知，使用傳統的機器學習方法在工廠工具機上的檢測、監控、分析皆獲得不錯的結果，除了節省建立複雜的統計數學模型之外，對於工廠方也相對的獲得重大的進展，但機器學習的模型通常是較小的模型結構，在複雜非線性的刀具切割振動數據中，若要提升模型預測績效，則挑選特徵值這個部分成為模型好壞的關鍵。

表 2.2 刀具磨耗機器學習之相關文獻整理

作者	目標	方法
Sun <i>et al.</i> [12]	進行變速箱的故障檢測	KS-LLE 方法
Jalali <i>et al.</i> [45]	檢測滾珠軸承的故障	基因演算法、SVM
Mohanraj <i>et al.</i> [47]	監測銑刀狀態	決策樹、SVM、KNN、MLP
Gomes <i>et al.</i> [29]	刀具磨損監控	SVM
Corne <i>et al.</i> [39]	預測鑽孔過程	類神經網路(ANN)
Hesser <i>et al.</i> [14]	CNC 刀具磨耗的監控	類神經網路
Li <i>et al.</i> [55]	檢測不同磨損時間的切削能力	隨機森林、多元線性回歸

2.1.3 深度學習

近年來，深度學習模型已成為機器檢測熱門常使用的方法，這個方法有效克服機器學習需要深入探討重要特徵該怎麼取的困擾，深度學習簡單化了這個問題，如圖 2.2 所示，並且深度學習模型能夠自我學習，從資料當中找到連專家都看不出來的深度特徵值，這些深度特徵能夠提供給後面的類神經網路良好的特徵值進行預測因此提高了預測的準確度。



圖 2.2 機器學習與深度學習的差異

目前機器檢測也廣泛運用在深度學習方法上，例如，Zhao *et al.*[41]使用卷積雙向長短期記憶類神經網路來監控機台的健康，Cheng *et al.*[9]使用聲音訊號經由小波分解後透過深度卷積神經網路(Deep Convolutional Neural Network)去評估磨損狀態，Jia *et al.*[18]運用大量機台數據對旋轉工具機進行智慧故障檢測使用 Multilayer perceptron 模型進行檢測，Zhang *et al.*[13]通過振動信號數據經由小波轉換後運用卷積神經網路(Convolutional Neural Network)建立刀具磨損狀態的分類模型，Zhao *et al.*[40]使用雙向改良後的遞迴類神經網路(Gated Recurrent Unit)真對三個不同任務進行實驗分別為刀具磨損進行預測、齒輪故障與主軸故障檢測，驗證了該模型取深度特徵的有效性。從以上文獻來看，許多學者驗證了深度學習的方法都比傳統方

法都來的更好，機器學習本身在處理非線性問題與高維度問題的資料上較弱，相較之下深度學習模型不但可以在大量的特徵中提取出重要的特徵並在複雜非線性的數據中進行學習預測，深度學習能夠解決傳統機器學習無法解決的問題，並且消除要依賴專家人士提取特徵的方式，在適當的參數調整下達到更良好的績效。

表 2.3 刀具磨耗機器學習之相關文獻整理

作者	目標	方法
Zhao et al.[41]	監控機台的健康	卷積雙向長短期記憶類神經網路
Cheng et al.[9]	評估磨損狀態	小波分解、DCNN
Jia et al.[18]	故障檢測	Multilayer perceptron 模型
Zhang et al.[13]	刀具磨損監控	小波轉換、CNN
Zhao et al.[40]	預測刀具磨損、故障檢測	遞迴類神經網路

2.1.4 過往方法比較

針對上述過往研究可以發現，不論是一般的統計方法、機器學習或是深度學習，在研究上皆可以達到預測刀具磨耗、故障檢測、監控刀具磨耗等等目標，以下針對三大方法進行比較，這些方法中的統計方法大多重視分析前的數據資料蒐集，過去學者透過感測器去蒐集信號、聲波、振幅等等的相關數據，以利後續進行分析或是預測，若蒐集的數據量太少，則會影響分析結果的準確度。接著，機器學習模型利用較小的模型結構就可以在預測刀具磨耗得到不錯的結果，但該模型在處理非線性問題與高維度問題的資料上較弱，因此挑選特徵值成了模型好壞的關鍵。相較之下深度學習模型，不但可以在大量的特徵中提取出重要的特徵，甚至在複雜非線性的數據中，也能進行學習預測，達到更好的績效。

2.2 數據生成

過往在實務上分析可以分為事前規劃與事後分析，前者所使用的方法大部分為作業研究、演算法等等以建立數學式的方式進行；後者則是運用統計方法、機器學習、深度學習對數據進行分析，目前熱門常使用的方法是事後分析，而事後分析又可以分為小數據與大數據，其中差別在於資料量的多寡，小數據會運用統計分析與機器學習進行分析，大數據常用於深度學習，而大數據的優勢在於可以將所有可能會發生的狀況都有考量進來，使在訓練類神經網路可以有更好的準確性，就不會有出現考慮不周的情況發生，但想要有大量的數據進行分析，事前需要蒐集大量的資料並透過人力去將這些資料進行標記提供深度學習練習，舉例來說，在圍棋界很

有名的 AlphaGo 在訓練之前也是輸入了大量的棋譜讓模型進行學習，在實務上缺少足夠訓練資料是很常見的事情，對於深度學習是一大障礙，學者針對這樣的問題提出了需多方法例如：上採樣(資料增強、SMOTE、GAN 等)、下採樣，以下將分別進行介紹。

2.2.1 上採樣(Oversampling)

2.2.1.1 資料增強

學者提出使用資料增強的方法將原始資料隨機翻轉、水平位移、亮度調整等，增加擾動如圖 2.3，對於人來說屬於同一張圖片，但對於電腦來說相同矩陣上會有不同的數值變化，將其視為新生成出的樣本，使模型學習到更多信息，整個方法運用到上採樣的抽樣方法，透過資料的複製[11][31][28][22]，達到生成效果，來提昇辨識率。




圖 2.3 資料增強

2.2.1.2 SMOTE(Synthetic Minority Over-sampling Technique)

SMOTE 是一種解決資料不平衡的方法，在 2002 年由 Nitesh Chawla *et al.*[35] 提出，而在分類的問題中有些類別資料難以取得，使深度學習模型或機器學型在訓練過程中造成傾斜的狀況，為了能讓模型更好訓練，該方法會隨機選擇少數類別進行合成，在類別中找出 k 個鄰近點，然後透過數值相加平均來產生新的資料，如圖 2.4 所示，假設 k 為 3，找附近的 3 點為 A、B 與 C，進行數值相加取平均得出新的資料 D。




圖 2.4 smote 生成方法

而目前各領域也常使用 SOMTE 解決許多資料不平衡的問題，例如醫療領域的疾病診斷，Wei *et al.*[25]使用 SOMTE 來平衡藥物所帶來的副作用，因有些藥不常使用所以造成不平衡現象，Abdoh *et al.*[44]使用 SOMTE 增加患癌症人數資料，因多數的癌症資料集患病者人數遠少於沒有患病者人數，Ishaq *et al.*[3] 使用 SOMTE 方法生成資料，提高預測心臟病患者生存率；工業製造領域，Mathew *et al.* 使用加權 SOMTE 方法進行機台資料的增生，用於提昇機械故障診斷率[21]，Bustillo *et al.*使用 SOMTE 增加刀具切割資料，檢測刀具有無破損[1]等。

表 2.4 SOMTE 之相關文獻整理

作者	目標
Nitesh Chawla, <i>et al.</i> [35]	解決資料不平衡的方法
Wei <i>et al.</i> [25]	平衡藥物所帶來的副作用
Abdoh <i>et al.</i> [44]	平衡患者人數
Ishaq <i>et al.</i> [3]	提高預測心臟病患者生存率
Mathew <i>et al.</i> [21]	提昇機械故障診斷率
Bustillo <i>et al.</i> [1]	檢測刀具有無破損

2.2.1.3 生成對抗網路(Generative Adversarial Network)

生成對抗網路又稱為 GAN，是一種非監督式學習的方法，主要架構由兩個模型組合而成，分別為生成網路(Generator Network)與鑑別網路(Discriminator Network)。兩個模型以博弈的方式彼此競爭，生成網路輸入是隨機亂數，輸出的結果是與真實數據相仿的樣本分佈空間，而鑑別網路的輸入為生成網路所生成的仿真數據與真實數據進行識別資料的真假，後將識別結果回饋給鑑別網路與生成

網路，鑑別網路會根據回饋修正識別能力去識別出生成資料，而生成網路會根據回饋進行參數修正製造出更逼真的資料來去欺騙鑑別網路，透過不斷來回的訓練與調整直到鑑別網路無法再識別資料的真假時即可停止訓練，便可以得到能夠模擬真實數據分布的生成網路，網路架構如圖 2.5 所示。舉例來說，將鑑別網路當成一位警察，而生成網路當成印製假鈔的犯人，警察要做的事情是打擊犯罪，識別出鈔票的真假阻止犯人，將識別出鈔票真假的結果會回饋給犯人，犯人會依據警察給予的回饋印製更像的假鈔，直到警察無法識別出鈔票的真假，經由上述不斷的學習印製新的假鈔與辨識真假鈔的回饋使兩個模型不斷訓練，最後產生出連警察都無法正確識別的假鈔票。生成網路的訓練結果可以拿來與真實資料進行結合增加資料集，當資料集有不平衡或資料量較少的情況下，可以輸入少量的資料讓生成模型產生更多符合現實的資料，使資料集更加完善並且減少蒐集資料所要耗費的時間，因此有許多學者使用這樣的技術來進行資料的生成。




圖 2.5 生成對抗網路架構圖[56]

目前生成對抗網路應用在於生成虛擬的資料，常運用在影像與影音的生成、合成、辨識、修復等等，例如，Shrivastava *et al.*[6]運用生成虛擬照片進行訓練，解決需要人工標記的麻煩，Deng *et al.*[20]提出一種條件式生成對抗網路的表情識別系統，使機器做出反應，Jiang *et al.*[50]提出了用時序性的生成對抗網路生成資料進行機器的異常故障檢測，Vioal *et al.*[23]作者運用了多種取信號時頻的方式並透過

DCGAN 模型(Deep Convolutional Generative Adversarial Network)進行生成資料後，透過 CNN 做驗證平衡資料方法的有效性，最後使用生成後的資料與原始資料進行工具機的故障檢測，Shi *et al.*[54]提出了 WGAN 模型(Wrap Generative Adversarial Network)，可以生成虛擬不同漫畫風格紋理圖，同時可以調整臉部表情的誇張程度，Tan *et al.*[51]，利用生成對抗網路合成複雜性的藝術品，Hsu *et al.*[8]可以針對不同 GAN 所生成出來圖片進行辨識圖像真假，Miyato *et al.*[46]使用有條件式的 GAN 分別給予生成網路與鑑別網路進行訓練，使生成器依據條件生成目前圖像或是其他類別圖像，這樣的條件方式可以使不同資訊進行融合並可以考慮更多情形，Wu *et al.*[38]使用強化學習配合生成對抗網路，生成出近似於看圖說故事的回答，改善傳統生成方法。綜合上述，將生成資料加入到原來資料集中，能解決資料集不足夠的問題，降低蒐集料所需要耗費的成本，進一步的使分類模型或預測模型有更好的精準度。

表 2.5 生成對抗網路之相關文獻整理

作者	目標	方法
Shrivastava <i>et al.</i> [6]	生成虛擬照片進行訓練	GAN
Mao <i>et al.</i> [20]	生成物品與人臉資料	條件式 GAN
Jiang <i>et al.</i> [50]	異常故障檢測	時序性 GAN
Vioal <i>et al.</i> [23]	工具機的故障檢測	DCGAN
Shi <i>et al.</i> [54]	生成虛擬不同漫畫風格紋理圖	WGAN
Tan <i>et al.</i> [51]	合成複雜性的藝術品	GAN
Hsu <i>et al.</i> [8]	辨識圖像真假	GAN
Miyato <i>et al.</i> [46]	生成圖像	條件式 GAN
Wu <i>et al.</i> [38]	改善傳統生成資料方法	強化學習、GAN

2.2.2 下採樣(Downsampling)

在分類問題上常會出現類別分佈不均的情況，而學者提出了針對資料集進行再次採樣如圖 2.6 所示，在多類別中運用抽樣方法抽取資料，使多資料類別與少資料類別一樣多，在抽樣的過程可以執行多次，重組成不同的資料集，來進行模型訓練[5][31][7]，但這樣的方法會造成，分類結果受到抽樣結果好壞而定，影響很大，取樣取的好並不能表示所有真實情況，取樣取的不好對模型的訓練完全沒有幫助反而會有反效果，雖然此方法有機會能提昇分類結果，但會有考慮不周的地方。




圖 2.6 下採樣

2.3 集成式學習(Ensemble Learning)

所謂集成式學習的主要概念，是將不同的監督式學習模型結合成一個模型進行預測，然而集成式學習依照處理方式可以分為四種，(1)多數決(majority voting)、(2)裝袋法(Bagging)、(3)提昇法(Boosting)以及(4)堆疊法(Stacking)，以下將列點說明：

- 多數決(majority voting)：其處理方式為從大多數分類器所預測出來的結果，並將其結果進行結合。
- 裝袋法(Bagging)：為 Bootstrap aggregating 的縮寫，由 Breiman *et al.* [27]所提出，其處理方式主要是將訓練資料進行隨機抽樣的方式製造出不同的資料集進行預測，能提高不穩定模型的預測準確率。常見例子有隨機森林(Random Forest)。
- 提昇法(Boosting)：由 Freund *et al.*[53]所提出，該演算法被廣泛利用，其處理方式是先訓練一個模型，得到解答之後使用誤差進行學習，主要根據訓練資料的每一筆難易度給予該筆資料不同的權重，其中針對較難的資料除了透過加強該權重之外，還會再訓練其他新的回歸器與分類器，來提昇模型學習績效。常見的例子有 AdaBoost、Gradient Boosting、XGboost。
- 堆疊法(Stacking)：由 Wolpert *et al.* [15]最早提出概念，處理方式會先將訓練資料切成兩個部分，將第一層的模型輸出結果放到第二層網路進行預測，第二層模型會針對第一層所學習到的資訊再做一次訓練一個用在學習前的分類，再將兩種網路進行結合，此種方法一樣會提升模型學習的績效。

透過上述集成式學習的處理方式可以得知，主要將每個模型各自的弱點，使用

其他模型來補足缺陷，舉例來說，把模型看成專家，每位專家都有他的強項，在做預測時去蒐集多個專家的判斷，整合出一個任何專家都比不上的超強專家。目前許多學者使用集成式學習提昇模型績效，例如，Sun *et al.* [37]使用集成學習與半監督式模型進行結合運用在傳感器的預測與監控，其中較為特別的是，該研究使用未標記的數據集來訓練不同的子模型，以確保其多樣性，更可以有效地利用未標記的樣本並幫助增強模型性能。在醫療領域上，Xue *et al.* [17]結合遷移學習與集成學習，為了防止單個學習造成單一性和局限性分類的結果，該研究使用了四個卷積神經網絡 (CNN) 進行實驗，然後採用基於加權投票的集成式學習方法，通過多次比較實驗後，用來辨識癌細胞的好壞分類，Yang *et al.* [52]為了從輸入的圖像中去除測量噪聲，以獲得更好的信噪比，因此該研究透過使用集成學習降低圖片噪聲。在能源研究的部分，Kumari & Toshniwal[36] 為了提升預測太陽輻射度的效能，該研究利用集成式模型，透過結合梯度增強森林模型(Extreme Gradient Boosting Forest)和深層類神經網路(XGBF-DNN)，提昇其預測模型的穩定性與準確度。Pinto *et al* [48]則針對辦公大樓的用電量進行前一小時的預測，在研究中發現透過將多種不同模型的結果相結合後，反而更優於當前的機器學習模型，因此透過開發三種集成式學習模型，其中 Adaboost 模型在預測前半小時的績效在該研究中優於其他模型。

表 2.6 刀具磨耗機器學習之相關文獻整理

作者	目標	方法
Breiman <i>et al.</i> [27]	提高不穩定模型的預測準確率	裝袋法集成學習
Freund <i>et al.</i> [53]	提升模型績效	強化法集成學習
Wolpert <i>et al.</i> [15]		堆疊法集成學習
Sun <i>et al.</i> [37]	傳感器的預測與監控	集成學習、 半監督式模型
Xue <i>et al.</i> [17]	辨識癌細胞的好壞	集成學習、遷移學習
Yang <i>et al.</i> [52]	降低圖片噪聲	集成學習
Kumari & Toshniwal[36]	提升預測太陽輻射度的效能	集成學習
Pinto <i>et al</i> [48]	提升預測用電量的效能	集成學習

2.4 小結

綜合上述之文獻回顧，可歸納出以下結論：

- 1.目前針對刀具磨耗的過去研究在預測上皆有不錯的結果，不論是統計分析方法、機器學習或是深度學習都有優點，但過去學者在蒐集資料過程較為繁瑣與複雜，同時也會耗費相當多的時間在資料蒐集上，導致效率不佳。
- 2.針對數據生成的部分可以發現過往常見的 SOMTE 方法不會把來自其他類的相鄰例項考慮進來。導致類重疊的情況增加，若使用深度學習的生成對抗網路模型則可以解決此問題，因此將該模型做為後續生成數據的研究方法。
- 3.隨著預測模型越來越多，每個模型也許皆有各自的優勢，若將這些監督式學習的模型結合在一起，讓模型變得更強大，則能夠有效的提昇預測準確率。



第三章資料集

3.1 資料集介紹

本章節將介紹本論文所使用的資料集，為 PHM2010 競賽資料[57]，PHM 全名為 Prognostics and Health Management Society，是一個非營利性的組織，該協會致力於提昇工程科學的發展並且舉辦比賽提供資料給與分析，其中 PHM2010 的資料集被視作刀具磨耗基準資料集，資料集當中記錄了 CNC 機台切割時的數據，運用感測器進行蒐集數據以 50(k/Hz)速度進行蒐集，切割時所使用的刀具為 6(mm)球頭碳化鎢，所要切削的工件材質為不鏽鋼(HRC52)，而機台切割實驗參數的主軸轉速為 10400(RPM)、進給率為 1555(mm/min)、切削深度為 0.2(mm)。資料集中包含了六把刀具進行資料的蒐集，由於此資料集是用於比賽的資料集進行刀具磨耗的預測，比賽單位將 6 把刀具中挑選 3 把作為訓練集，提供每次刀具切削後的磨耗值與切削過程的振動數據，而其餘的 3 把刀作為測試集來驗證預測方法的有效性，沒有提供刀具切削後的磨耗值，因此本研究僅能使用訓練集三把刀具進行研究。

3.2 資料集觀察

實驗過程每一把刀具會進行三百一十五次切割，每一次的切割都會紀錄各個數值，資料表如表 3.1 所示，表中 7 個欄位分別為 x 軸的加速度、y 軸的加速度、z 軸的加速、x 軸振動、y 軸振動、z 軸振動與聲發射，由於切割時間有所不同每次切割所蒐集的筆數介於十萬至三十萬比不等如圖 3.1 所示。

表 3.1 PHM2010 資料欄位

	x 軸加速度	y 軸加速度	z 軸加速度	x 振動	y 振動	z 振動	聲發射
1	0.704	-0.387	-1.084	0.018	0.031	0.027	-0.004
2	0.772	-0.573	-1.153	-0.056	-0.057	-0.058	-0.004
3	0.828	-0.673	-1.242	0.037	0.019	0.031	-0.004
...	...	...	...	...	...	...	...
127399	0.207	0.483	0.292	0.111	0.114	0.125	-0.004




圖 3.1 PHM2010 資料視覺化結果

刀具切割次數都有上限，到達切割上限刀具是需要被更換，然而太早更換刀具就會造成浪費；太晚更換反而會毀損昂貴的零件。如圖 3.2 所示，圖中可以觀察出資料集所使用刀具的安全切割磨耗值落在 66 到 165 之間，因此本論文將資料依據磨耗值分成三種不同狀態分別為初期磨耗(0 至小於等於 66)、正常磨耗(大於 66 至小於等於 165)與劇烈磨耗(165 以上)，本研究將資料集依據每個特徵與類別畫出箱型圖，根據觀察聲發射(Acoustic Emission, AE)箱型圖(如圖 3.3 所示)發現，這個特徵的資料可以事先以數值進行簡易分類。除此之外，還觀察出劇烈磨耗階段(為綠色箱型圖)，圖中四分位距明顯高於初期磨耗階段(為藍色箱型圖)與正常磨耗階段(為橘色箱型圖)，原因是聲發射用途為檢測出刀具有無缺陷或損傷。而其餘特徵沒有觀察出明顯差異，如圖 3.4 所示。




圖 3.2 刀具狀態分界




圖 3.3 聲發射(Acoustic Emission,AE)箱型圖




圖 3.4 其餘六個特徵箱型圖

3.3 處理資料集所遇到的困難

在實際加工生產的情況中，工廠會要求現場人員使用安全切割磨耗區域進行工廠的加工，一把新的刀具開始做切削時會因為刀刃較尖，造成快速的磨損情形但這樣的情形不會維持太久就會進入安全磨耗，而劇烈磨耗狀態會因為工廠工人不想讓刀具損毀零件而提早更換刀具，導致資料不平衡的狀況發生如圖 3.5 所示，而資料不平衡會造成分類結果不佳的情況，其原因是相對於正常磨耗類別，初期磨耗與劇烈磨耗類別樣本數少，在資料傾斜分布不均的情況下，訓練時模型會偏向資料多的類別，最終訓練出來的模型會不好。




圖 3.5 刀具磨耗類別分佈

第四章研究方法

本論文提出利用生成對抗網路處理資料不平衡的問題應用在刀具磨耗的探討，將研究流程分為兩個階段進行，如圖 4.1 所示。階段一包含(1)將振動資料進行清洗，使用線性插值法進行缺失值填補，並將資料整理成時序矩陣格式當作生成對抗網路的輸入(2)建立與訓練生成對抗網路模型，來補足較少類別資料，以解決資料不平衡問題。階段二包含(1)利用時域與頻域提取重要特徵值，(2)建立與訓練卷積類神經網路進行刀具狀態分類，(3)將訓練好的模型，應用機器學習方法進行集成學習的分類，如類神經、決策樹、隨機森林，本研究的集成學習使用類神經模型來獲得最終分類的結果。以下詳細介紹流程。




圖 4.1 研究流程圖

4.1 資料清洗

4.1.1 線性補值

本研究所使用的振動數據是由 CNC 機台上加裝感測器蒐集而來的資料。而在機台運作中有可能會遇到，電壓不穩定、網路設備故障、或者本身感測器問題，造成蒐集到的資料有缺失值 Null 的情況，這樣的資料沒有辦法進行模型的訓練。根據過往研究，最常使用的方法是線性補值方法，將資料中的缺失值進行填補。線性補值方法公式如下：

$$x_n = x_{n-1} + n\Delta \quad (1)$$

$$\Delta = \frac{x_{t+1} - x_0}{t+1} \quad (2)$$

其中 t 為需要補值的範圍， n 表示第 n 筆需要填補的資料。

本論文會先將資料集中所有維度資料的缺失數值採用線性補值方法，將缺失值進行填補。

4.1.2 時序矩陣資料

過往的研究中，訓練生成對抗網路是以圖片的形式進行，本研究嘗試以時間序列資料進行訓練。為了能讓時序資料放進生成對抗網路進行訓練，本研究會將線性補值後的資料轉換成時序矩陣資料形式如圖 4.2 所示。




圖 4.2 序列轉換時序矩陣

4.1.3 利用生成對抗網路增生資料

將清洗過的資料轉換成時序矩陣後，本節將介紹生成對抗網路架構與訓練方式，生成對抗網路(GAN)包含兩個類神經網路，分別為嘗試著產生很像真實資料的生成網路(Generator Network)與嘗試著識別真資料與假資料的鑑別網路(Discriminator Network)。這種網路架構訓練方式特別之處是在於，透過兩模型以博弈的方式彼此競爭互相學習，達到以假亂真的目的。如果要生成刀具振動數據，生成網路會先以亂數做為輸入生成數據，接著將生成數據與原始振動數據當作鑑別網路的輸入，進行訓練。鑑別網路會判別圖片是由生成網路所製造出來的模擬刀具振動數據或是真實數據，並將判別後的資訊回饋給生成網路。生成網路會依據回饋，生成出更符合現實的刀具振動資料，讓鑑別網路繼續判別真假，不斷循環訓練，直到讓鑑別網路無法判斷真假為止，如圖 4.3 所示。




圖 4.3 生成對抗網路模型

本研究使用的生成網路模型包括 9 層，分別為：輸入層與四組上採樣和卷積層的組合，其架構如表 4.1 所示。以下詳細說明生成網路模型每一層的架構。

首先是輸入資料，假設亂數資料有 n 筆資料且特徵數量為 m 個，此輸入為 $n \times m$ 的亂數矩陣，數值屬於 0 到 1 的常態分佈亂數。

接著為輸入層的部分，輸入層主要是將輸入資料放進模型中，此層的輸入資料即為輸出結果，可以寫為以下公式：

$$O_i^{input} = x_i^{input} \quad (3)$$

其中 O 表示神經元的輸出， x 表示輸入資料， i 表示模型的第 i 個輸入。

再來是上採樣層的部分，模型中包含 4 個上採樣層：上採樣 U1、上採樣 U3、上採樣 U5 與上採樣 U7，其方法採用最近鄰插值，透過複製現有資料的方式來擴充特徵圖，使模型在訓練的過程中，能夠更好的學習到資料的特徵，假設輸入為 n ，採樣大小為 $size$ ，可以表示為：

$$O_i = x_{\left\lfloor i \times \frac{1}{size} \right\rfloor}, i \in [0, n \times size), i \in \mathbb{N} \quad (4)$$

其中 O_i 表示第 i 個神經元的輸出， x_i 表示第 i 個輸入。

接著是卷積層的部分，模型中包含 4 個一維的卷積層：卷積 C2、卷積 C4、卷積 C6 與卷積輸出。在這四層中的卷積神經元數量分別為 128、64、64、7。四層中的每個節點都有卷積核為 k ，每個卷積核的大小為 m ，可以表示為：

$$O_i = act(\sum_{k=0}^{k=m-1} x_{i+m-k} w_k + b_i) \quad (5)$$

其中 O_i 表示第 i 個神經元的輸出， x_i 表示第 i 個原始輸入， w 為濾波器， $act(\bullet)$ 為激活函數，前三個捲積層所使用的激活函數為 LeakyReLU， b_j 表示第 j 個神經元的偏壓值。激活函數 LeakyReLU function 說明：LeakyReLU 為非線性函數，其公式如下：

$$O_i = \max(0.1x_i, x_i) \quad (6)$$

其中， O 為輸出， x 為輸入， i 為第 i 個神經元。而最後一個卷積層所使用的激活函數為 tanh function，其公式如下：

$$O_i = \frac{e^{x_i} - e^{-x_i}}{e^{x_i} + e^{-x_i}} \quad (7)$$

其中， O 為輸出， x 為輸入， i 為第 i 個神經元。

表 4.1 生成網路架構

階層	類型	輸出大小	卷積核尺寸	步伐	激活函數
輸入	輸入	125×128	-	-	-
U1	上採樣	250×128	-	-	-
C2	卷積	125×64	3	2	LeakyReLU
U3	上採樣	250×64	-	-	-
C4	卷積	125×64	3	2	LeakyReLU
U5	上採樣	250×64	-	-	-
C6	卷積	125×64	3	2	LeakyReLU
U7	上採樣	250×64	-	-	-
輸出	卷積	250×7	-	-	tanh

本研究使用的鑑別網路，也採用一維的卷積類神經網路，包括 9 層，分別為：輸入層、四個卷積層、3 個批量標準化層(Batch Normalization layer)與輸出層，其中批量標準化層，有助於減緩梯度消失並且可以加速類神經的收斂，其公式如下：

$$O_i = \gamma \frac{x_i - \bar{x}}{\sqrt{Var(x_i)}} + \beta \quad (8)$$

其中 O 為輸出， x 為輸入， i 為第 i 個神經元， γ 與 β 為 scale 和 shift，是神經網路訓練的參數。

而卷積層與生成網路中的卷積層公式相同。模型的輸入為真實刀具振動數據

與生成網路模擬的刀具振動數據，輸出為兩者之間的相似程度，表 4.2 為本研究鑑別網路所使用的模型架構。

表 4.2 鑑別網路架構

階層	類型	輸出大小	卷積核尺寸	步伐	激活函數
輸入	輸入	250×7	-	-	-
C1	卷積	125×128	3	2	LeakyReLU
C2	卷積	63×128	3	2	LeakyReLU
BN3	批量標準化	63×128	-	-	-
C4	卷積	63×64	3	2	LeakyReLU
BN5	批量標準化	63×64	-	-	-
C6	卷積	63×64	3	1	LeakyReLU
BN7	批量標準化	63×64	-	-	-
輸出	全連接	1	-	-	-

模型建置完成後，根據反向傳播演算法進行權重的更新在訓練過程中生成網路追求 Generator Loss 越低越好，表示生成網路產出的資料越接近現實使鑑別網路分辨出數據真假。Generator Loss 公式如下：

$$GeneratorLoss = \frac{1}{N} \sum_{i=1}^N \log(1 - D(G(R^i))) \quad (9)$$

其中 R 為隨機亂數向量，D 為鑑別網路，G 為生成網路，N 為訓練資料。

而鑑別網路追求 Discriminator Loss 越低越好，表示鑑別網路有能力判別數據的真假。Discriminator Loss 公式如下：

$$Discriminator = -\frac{1}{N} \sum_{i=1}^N \log D(X^i) - \frac{1}{N} \sum_{i=1}^N \log(1 - D(\hat{X}^i)) \quad (10)$$

其中 X 為原始資料， $\hat{X}$ 為生成資料，D 為鑑別網路，N 為訓練資料。

由於本研究所使用振動資料數量較少，如果想要更多的數據，就必須花費更多的人力蒐集資料，為了解決資料少的情況，研究透過生成對抗網路進行資料的擴增，使資料更完整，以利於考慮工廠加工的不同情形，藉由生成網路產出符合工廠現實狀況的振動資料。

4.2 利用時域與頻域提取重要特徵值

資料經由生成對抗網路平衡後，進行提取刀具磨損變化的特徵，本小節會介紹三種研究中運用到的振動訊號提取特徵的方法，分別為時間序列特徵擷取，可以在

相同的時間間隔，分析刀具切割中的振幅變化；快速傅立葉轉換，觀察分析刀具切割中的振幅與頻率之間的關係；最後是連續小波轉換，能刀具切割的振幅在時間與頻率中的變動。

4.2.1 時序特徵提取

過去學者在取得時間序列重要特徵時，會使用固定大小的窗格以重疊的方式將時間序列以等長的方式切割，在將每個切割好的窗格中取不同特徵的統計量例如：最大值、最小值、平均值、總和、平均絕對偏差、均方根誤差與標準差。本研究會將振動數據特徵依據上述方法取 7 種時域中的統計特徵，來進行後續深度學習模型的訓練，以下分別介紹各個統計特徵公式， x 為矩陣視為一個特徵的窗格，而每一個窗格中有 n 個資料，表示為 $X = [x_1, x_2, x_3, \dots, x_n]$ ， t 為某一個時間點的窗格。

- (1) 最大值(Max)；每一個特徵窗格的最大值，公式如下：

$$\text{Max} = \max\{x(t)\} \quad (11)$$

- (2) 最小值(Min)；每一個特徵窗格的最小值，公式如下：

$$\text{Min} = \min\{x(t)\} \quad (12)$$

- (3) 平均值(Average)；每一個特徵窗格的平均值，公式如下：

$$\text{Average} = \text{average}\{x(t)\} \quad (13)$$

- (4) 總和(Sum)；每一個特徵窗格的數值加總，公式如下：

$$\text{Average} = \text{average}\{x(t)\} \quad (14)$$

- (5) 平均絕對偏差(MAD)： m 為 t 窗格內所有資料平均，每一個特徵窗格的離散程度，公式如下：

$$\text{MAD} = \frac{1}{|t|} \sum_{i=1}^{|t|} |x_i - m| \quad (15)$$

- (6) 均方根誤差(RMSE)；每一個特徵窗格的數值差異，公式如下：

$$\text{RMSE} = \sqrt{\frac{1}{|t|} \sum_{i=1}^{|t|} x_i^2} \quad (16)$$

- (7) 標準差(STD)：平均絕對偏差類似反映每一個特徵窗格的離散程度，公式如下：

$$\text{STD} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \quad (17)$$

4.2.2 快速傅立葉轉換

刀具振動數據是屬於連續的資料，過往學者也運用快速傅立葉轉換進行分析[2][49][30][26]。快速傅立葉轉換(FFT)，是離散傅立葉轉換的加快版本，其原理是任何連續的訊號，都可以用不同的正弦波的頻率來表示，可以將時域快速轉換成頻域，將訊號分解成不同振幅和頻率的正弦波，利用傅立葉轉換可以看出一個信號當中是由什麼樣的頻率所組合而成的，其公式如下：

$$x(e^{j\omega_k}) = \sum_{n=0}^{L-1} x[n]e^{j\omega_k n} \quad (18)$$

其中 $x(e^{j\omega_k})$ 為頻率的連續函數， ω_k 為特定頻率樣本等同於 $\frac{2\pi k}{N}$ ， L 為 $x[n]$ 的長度，這個公式主要分析訊號中包含了什麼成分，也就是各種頻率佔了總成分的多少，如 4.4 圖，在原本的振動圖上看不出甚麼特徵，但經由轉換後可以發現振動數據是由哪些頻率與振幅組合而成，將這些特徵突顯出來，使模型更容易學習頻域上的特徵。




圖 4.4 透過快速傅立葉轉換成頻域

4.2.3 連續小波轉換

將振動數據以連續小波轉換的方式將時域轉換成時頻域，而小波最早是由 Morlet 與 Grossman 提出，小波分析是以小波基底函數所有的特性組合，合成公式如下：

$$W(a,b) = \int_{-\infty}^{\infty} f(t)\psi_{a,b}(t)dt \quad (19)$$

其中 a 為延展參數， b 為平移參數， ψ 為母小波，而連續小波是數位訊號重要的方法，可以透過連續的函數處理連續時間的資料，進而獲取小波係數，以分析在不同

時間不同延展下的變化，連續小波轉換公式如下：

$$W_x(a, b) = \langle f(t), \psi_{a,b} \rangle = \frac{1}{\sqrt{a}} \int_R f(t) \psi \left(\frac{t-b}{a} \right) dt \quad (20)$$

其中 a 為延展參數， b 為平移參數， ψ 為母小波函數經過延展與位移所得出的基底函數。

反連續小波轉換公式：

$$f(t) = \frac{1}{C_\psi} \int_{-\infty}^{\infty} \int_0^{\infty} \frac{1}{a^2} W_x(a, b) \psi_{a,b}(t) da db \quad (21)$$

運用連續小波轉換後的資料轉換成時頻圖如圖 4.5 所示，可以看出每個時間有不同的頻率，突顯出時域上的特徵。




圖 4.5 透過連續小波轉換之時頻圖

4.3 卷積類神經網路

本小節將詳細介紹研究中所使用的卷積類神經網路，因為卷積類神經網路的特徵擷取方式，是使用過濾器從資料中提取局部特徵進行訓練，有利於更詳細的分析刀具振動數據。本研究的模型輸入為刀具振動數據經時域與頻域提取特徵後的資料，模型的輸出為刀具磨耗狀態，本研究使用的模型包括 11 層，分別為：輸入層、四組卷積層和最大池化層的組合與兩個完全連接的層，以下詳細說明卷積類神經模型每一層的架構。

首先輸入資料的部分，本研究將使用三種不同特徵擷取方法放入模型進行分類，假設資料有 n 筆資料且特徵數量為 m 個，此數據為 $n \times m$ 的矩陣，經由時域或頻域從中提取 h 個重要特徵值，因此輸入資料為 $n \times m \times h$ 。

接著為輸入層的部分，輸入層主要是將輸入資料放進模型中，此層的輸入資料即為輸出結果，可以寫為以下公式：

$$O_i^{input} = x_i^{input} \quad (22)$$

其中 O 表示神經元的輸出， x 表示輸入資料， i 表示模型的第 i 個輸入。

再來是卷積層的部分，其目的是透過濾波器在序列數據上滑動，有效的提取每個局部的特徵，假設刀具振動為 1×7 的矩陣，濾波器為 1×3 的矩陣，如圖 4.6 所示。




圖 4.6 矩陣資料圖

接著，濾波器矩陣會在刀具振動資料矩陣滑動，在每次滑動的過程中進行計算，將濾波器矩陣所覆蓋的刀具振動資料相乘累加，最終輸出一個 1×5 的特徵矩陣，如圖 4.7 所示。




圖 4.7 卷積過程圖

本研究的卷積模型中，包含 4 個卷積層：卷積 C1、卷積 C3、卷積 C5 與卷積 C7，這四層中的卷積神經元數量分別為 $2^{\lceil \log_2[m*2] + 1}$ 、 $2^{\lceil \log_2[m*2] + 2}$ 、 $2^{\lceil \log_2[m*2] + 3}$ 、 $2^{\lceil \log_2[m*2] + 3}$ ，每個節點都有卷積核為 k ，每個卷積核的大小為 m ，可以表示為：

$$O_i = \text{act}\left(\sum_{k=0}^{k=m-1} x_{i+m-k} w_k + b_i\right) \quad (23)$$

其中 O_i 表示第 i 個神經元的輸出， x_i 表示第 i 個原始輸入， w 為濾波器， $\text{act}(\bullet)$ 為激活函數，這裡所使用的激活函數為 Relu， b_i 表示第 i 個神經元的偏壓值。激活函

數 Relu function 詳細說明：Relu 為非線性函數，其公式如下：

$$O_i = \max(0, x_i) \quad (24)$$

其中， O 為輸出， x 為輸入， i 為第 i 個神經元。

接著是最大池化層的部分，假設輸入維度為 (L_i, D_i) ，並且該層的池化大小為 p ，步伐為 s 。該層的數學公式編寫如下：

$$L_y = \frac{L_i - p_l}{s} + 1 \quad (25)$$

$$D_y = D_i \quad (26)$$

最終輸出為 (L_y, D_y) 。假設以圖 4.7 的特徵矩陣為最大池化層的輸入，令池化大小 $p=3$ ，步伐為 $s=2$ ，其過程如圖 4.8 所示。



圖 4.8 最大池化過程圖

最後，由兩層全連接層：全連接 A 與全連接 B。在這兩層中的激活函數分別為 Relu 與 Softmax，這兩層目的是整合前一層神經元的輸出，並把分類結果輸出，而公式可寫為：

$$O_j = \text{act}(x_j \times w_{ij}) + b_j \quad (27)$$

其中 O_j 表示第 j 個神經元的輸出， $\text{act}(\bullet)$ 為激活函數，可為任何的激活函數， x_j 表示第 j 個神經元的輸入， w_{ij} 表示與前一層連接的權重值， b_j 表示第 j 個神經元的偏壓值。激活函數 softmax function 詳細說明：經過 softmax function 激活函數後，每個數值輸出介於 0 到 1 之間，所有輸出總合為 1，公式如下：

$$O_i = \frac{e^{z_i}}{\sum_{j=0}^c e^{z_j}} \quad (28)$$

其中， c 為類別總數， O 為輸出， z 為模型預測值， i 為第 i 個神經元。在建立完模型之後，根據反向傳播演算法進行權重的更新，反覆對模型進行訓練。表 4.3 為本研究所使用的卷積類神經架構。

表 4.3 卷積類神經架構

階層	類型	輸出大小	卷積核尺寸	步伐	激活函數
輸入	輸入	$m \times h$	-	-	-
C1	卷積	$h \times 2^{\log_2 \lceil m^*2 \rceil + 1}$	3	1	Relu
P2	最大池化	$(h/2) \times 2^{\log_2 \lceil m^*2 \rceil + 1}$	-	-	-
C3	卷積	$(h/2) \times 2^{\log_2 \lceil m^*2 \rceil + 2}$	3	1	Relu
P4	最大池化	$(h/4) \times 2^{\log_2 \lceil m^*2 \rceil + 2}$	-	-	-
C5	卷積	$(h/4) \times 2^{\log_2 \lceil m^*2 \rceil + 3}$	3	1	Relu
P6	最大池化	$(h/8) \times 2^{\log_2 \lceil m^*2 \rceil + 3}$	-	-	-
C7	卷積	$(h/8) \times 2^{\log_2 \lceil m^*2 \rceil + 3}$	3	1	Relu
P8	最大池化	$(h/16) \times 2^{\log_2 \lceil m^*2 \rceil + 3}$	-	-	-
F9	全連接	512	-	-	Relu
輸出	全連接	3	-	-	softmax

4.4 結合集成式學習提昇刀具磨耗分類準確性

前面 4.2 以及 4.3 小節介紹過本研究將會透過使用三種不同的特徵提取方法結合卷積類神經，進行刀具使用狀態的分類。此小節將介紹如何使用卷積類神經網路分類後的結果當作模型輸入，進行集成式學習提昇分類的準確率。在使用集成式學習之前，為了讓模型可以觀察到不同的特性，通常建議每個特徵都需保有獨立性，才能達到最好的效果。集成式學習最大的特色在於它能考慮多種特徵與更多元化的資訊，通常使用多個模型一起分類的結果會比單一模型分類的精準度還要好，其處理方法可分為四種(1)多數決(majority voting)、(2)裝袋法(Bagging)、(3)提升法(Boosting)以及(4)堆疊法(Stacking)，而本研究所使用的為堆疊法(Stacking)，其最大的優勢為它可以利用淺層類神經網路進行修正，讓準確率提昇，而其它的三種處理方式，通常都以投票、抽樣或是誤差修正，對於模型修正效果沒有比堆疊法好，基於此特性，本研究使用淺層類神經網路作為堆疊處理法的集成式學習模型，並將三種不同特徵提取方法的卷積神經網路模型結果放入集成式學習模型進行訓練，來修正其分類不正確的結果，進而達到更好的分類準確度，以下將針對模型架構詳細說明。

首先，輸入資料的部分，本研究將使用三種不同特徵擷取的模型進行集成式學習，舉例來說，假設有 h 種方法的模型做集成式學習，且每個模型進行刀具磨耗狀態分類結果共有 n 筆，因此輸入數據可以用 $h \times n$ 的矩陣表示之。

接著為輸入層的部分，輸入層主要是將輸入資料放進模型中，此層的輸入資料即為輸出結果，可以寫成公式如下：

$$O_i^{input} = x_i^{input} \quad (29)$$

其中 O 表示神經元的輸出， x 表示輸入資料， i 表示模型的第 i 個輸入。

再來是隱藏層的部分，隱藏層由多個連接層構成，其中全連接的層數會依據前一個神經元數量決定，假設前一個神經元輸出為 α ，全連接層共有 $\log_2 \alpha$ 層，且每層個神經元都會整合前一層神經元的輸出，且彼此之間為全連接的狀態，而公式如下：

$$O_j = (x_j \times w_{ij}) + b_j \quad (30)$$

其中 O_j 表示第 j 個神經元的輸出， x_j 表示第 j 個神經元的輸入， w_{ij} 表示與前一層連接的權重值， b_j 表示第 j 個神經元的偏壓值。

最後，是輸出層的部分，這層主要目的是將上一層所有神經元的輸出整合，並通過激活函數計算並輸出結果，公式可寫為：

$$O_j = act(x_j \times w_{ij}) + b_j \quad (31)$$

其中 O_j 表示表示第 j 個神經元的輸出， $act(\bullet)$ 為激活函數，可為任何的激活函數，此模型所使用的激活函數為 Softmax， x_j 表示第 j 個神經元的輸入， w_{ij} 表示與前一層連接的權重值， b_j 表示第 j 個神經元的偏壓值。

在建立完模型之後，根據反向傳播演算法進行權重的更新，反覆對模型進行訓練，最終可以得出提昇準確率的結果。

第五章實驗模擬

本研究使用真實的刀具磨耗資料來驗證論文中所提出方法的有效性。本章節分成四個部分，分別維資料前處理、平衡資料集與結果、提昇績效方法，以及質化與量化合理性說明。所有實驗皆用 Python 完成，並執行於 Intel Core i7-9700KF at 3.6GHz 的 CPU、16GB 的記憶體、搭配 Nvidia RTX 2080 ti 8GB 的 GPU 和 Windows 10 的作業系統完成。

5.1 資料前處理

在資料集觀察階段，可以得知振動數據具有資料連續性，並且資料之間的時間相等，屬於時間序列資料。但機台感測器在蒐集資料時會因為電壓不穩定、網路設備故障、或是本身感測器有問題，使原始振動數據資料集中具有缺失值，因此本研究利用線性插值法先將資料進行補值，如圖 5.1 所示，再依據刀具磨耗值，將振動數據分成三種不同狀態分別為初期磨耗(0 至小於等於 66)、正常磨耗(大於 66 至小於等於 165)與劇烈磨耗(165 以上)，將資料整理成生成對抗網路所需要的時序矩陣格式。




圖 5.1 線性插值方法結果

5.2 平衡資料集與結果

5.2.1 資料平衡結果

承 5.1 所述，刀具磨耗共分成三種狀態(1)初始磨耗、(2)正常磨耗和(3)劇烈磨耗。在 PHM2010 資料集中，我們觀察出資料不平衡的問題。於是本研究將 GAN 用於初始磨耗及劇烈磨耗階段的資料生成，而生成後可以使三階段的資料量一致，資料平衡之前後比較如圖 5.2 所示。




圖 5.2 生成資料前後比較圖

在 GAN 模型的訓練上，為了確保所產生的資料與原始分佈相似，本研究使用 Frechet Inception Distance score (FID score)來評估模型的相似程度與迭代次數。FID score 是計算真實圖像與生成圖像特徵向量之間的高斯分佈距離，數值越小表示生成圖像的高斯分布越接近真實圖像。圖 5.3 為訓練過程的 FID score，透過觀察可以發現第 800 次迭代時，該 FID score 的數值最小，代表該分布越接近真實情況。圖 5.4 為迭代次數比較圖，可以看出，訓練 100 次、2000 次、4000 次後，GAN 模型產生的模擬資料相較於圖 5.4 中上方原始資料極不相似，而訓練 800 次 GAN 模型產生的資料相似於原始資料，相似度極高，與 FID score 相互呼應，因此本研究最終選擇了 800 次迭代作為模型的訓練次數。




圖 5.3 訓練過程的 FID score




圖 5.4 迭代次數比較圖

5.2.2 混淆矩陣結果

完成資料平衡的階段後，本研究利用時域與頻域提取重要特徵值，放進卷積類神經進行模型訓練與分類，最終為連續小波轉換為最佳結果(accuracy=88%)。為了驗證本研究所使用 GAN 模型的有效性，本研究也採用了 Oversampling、Downsampling 與 SMOTE 三種方法進行資料平衡，並且對這些方法平衡後的資料進行時序特徵、傅立葉轉換與小波轉換三種特徵擷取做為比較。下表 5.1 為所有方法分類結果之混淆矩陣，其中 Total population 為總驗證資料數量；True Condition 為實際的類別；Predicted Outcome 為模型輸出類別。在原始數據的混淆矩陣中看出其模型分類結果皆以 1 類居多，在連續小波轉換後的資料最為明顯，而多種方法平衡資料後，經過 GAN 平衡後的方法，個類別分類正確率提昇，原本第 1 類分成第 0 類的數量變少許多，在連續小波轉換的結果中，模型分類結果的準確性有顯著的被提昇，因此可得知，本研究先透過特徵篩選方式後的資料，帶入 GAN 進行訓練可以顯著提昇分類的績效。

表 5.1 所有方法之混淆矩陣

原始數據(時序特徵提取)				
Total population(T=13586)		True Condition		
		0	1	2
Predicted Outcome	0	122	2	0
	1	354	9534	21
	2	0	961	2582

原始數據(快速傅立葉轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	1281	8373	265
	2	0	67	3476
原始數據(連續小波轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	0	124	0
Predicted Outcome	1	0	9654	265
	2	0	371	3172
Oversampling (時序特徵提取)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	1296	8616	7
	2	0	952	2591
Oversampling (快速傅立葉轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	675	9245	1
	2	0	1499	2044
Oversampling (連續小波轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	105	17	2
Predicted Outcome	1	252	9308	359
	2	12	240	3291
Downsampling (時序特徵提取)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	1128	8688	103
	2	0	659	2884
Downsampling (快速傅立葉轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	1194	8725	1
	2	0	678	2865

Downsampling (連續小波轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	56	68	0
Predicted Outcome	1	0	9597	322
	2	0	283	3260
SMOTE (時序特徵提取)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	1185	8723	11
	2	100	652	2491
SMOTE (快速傅立葉轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	1460	8457	2
	2	0	864	2679
SMOTE (連續小波轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	104	20	0
Predicted Outcome	1	529	9164	226
	2	0	221	3322
GAN (時序特徵提取)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	121	3	0
Predicted Outcome	1	134	9785	0
	2	0	1470	2073
GAN (快速傅立葉轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	124	0	0
Predicted Outcome	1	169	9750	0
	2	0	1753	1790
GAN (連續小波轉換)				
Total population(T=13586)		True Condition		
	0	1	2	
	0	80	44	0
Predicted Outcome	1	19	9803	97
	2	0	316	3227

5.2.3 敏感度分析(ROC 曲線與 mAP 曲線)

本研究使用 Receiver Operating Characteristic (ROC)[4] 與 mean Average Precision (mAP)來比較四種資料平衡方法的敏感度。ROC 是使用真陽性率(true positive rate)與偽陽性率(false-positive rate)評估模型的效能，而 ROC 圖中的對角線為隨機猜測(random guessing)，若曲線低於此對角線，表示模型的分類結果不如隨機猜測的結果。反之越高於對角線的曲線，模型的分類結果越好，公式如下：

$$\text{False positive rate} = \frac{TP}{TP + FN} \quad (32)$$

$$\text{True positive rate} = \frac{FP}{TN + FP} \quad (33)$$

其中， TP 為預測為真，實際也為真， FN 為預測為假，實際為真， FP 為預測為真，實際為假， TN 為預測為假，實際也為假。

綜合上述所說，曲線下的區域面積越大表示模型的分類效果越好。圖 5.5 為原始資料經由 GAN 平衡後提取時序特徵的 ROC 圖，可以看出刀具磨耗狀態分類結果的曲線下面積第 1、2 類為 79%；第 0 類高達了 98%，其平均綜合績效 Macro-averaging 與 Micro-averaging 也分別有 86%與 91%。




圖 5.5 原始資料經由 GAN 平衡後提取時序特徵的 ROC 圖

mAp 是用來評估模型是否能準確辨識陽性(positive)的資料，mAp 也會產生一條隨機猜測(random guessing)的對角線，若曲線下的區域面積越大，表示模型越佳，將資料判斷成為陽性的機率越低公式如下：

$$Recall = \frac{TP}{TP + FN} \quad (34)$$

$$Precision = \frac{TP}{TP + FP} \quad (35)$$

其中， TP 為預測為真，實際也為真， FN 為預測為假，實際為真， FP 為預測為真，實際為假。

如圖 5.6 所示，可以看出各個刀具磨耗狀態的分類皆高於隨機猜測，平均綜合績效 Micro-averaging 達到 82%。




圖 5.6 原始資料經由 GAN 平衡後提取時序特徵的 mAP 圖

表 5.2 與表 5.3 為本研究的實驗結果。其中，表 5.2 為所有方法的 ROC 曲線下面積的結果；表 5.3 為所有方法的 mAP 曲線下面積的結果。表 5.2 中可以看出本研究所使用的 GAN 生成方法搭配連續小波轉換，是所有方法中最好的，相較於其他資料平衡方法，該方法更能提昇分類結果，如圖 5.7 所示。結果顯示，資料未平衡與平衡後初期磨耗(Class 0，紅色線)的曲線下面積，從原來的 0.5 提昇至 0.82，有顯著的提昇。

表 5.2 所有方法 ROC 曲面下面積結果

	時序特徵提取	快速傅立葉轉換	連續小波轉換
原始資料	Class0:0.98	Class0:0.95	Class0:0.5
	Class1:0.85	Class1:0.91	Class1:0.92
	Class2:0.86	Class2:0.98	Class2:0.93
	Micro:0.93	Micro:0.91	Micro:0.96
	Macro:0.90	Macro:0.95	Macro:0.78
Oversampling	Class0:0.95	Class0:0.97	Class0:0.91
	Class1:0.80	Class1:0.76	Class1:0.93
	Class2:0.87	Class2:0.79	Class2:0.95
	Micro:0.88	Micro:0.88	Micro:0.95
	Macro:0.87	Macro:0.84	Macro:0.93
Downsampling	Class0:0.96	Class0:0.96	Class0:0.73
	Class1:0.85	Class1:0.85	Class1:0.94
	Class2:0.90	Class2:0.90	Class2:0.94
	Micro:0.90	Micro:0.90	Micro:0.96
	Macro:0.90	Macro:0.90	Macro:0.87
SMOTE	Class0:0.95	Class0:0.95	Class0:0.98
	Class1:0.81	Class1:0.81	Class1:0.79
	Class2:0.85	Class2:0.88	Class2:0.79
	Micro:0.88	Micro:0.97	Micro:0.91
	Macro:0.87	Macro:0.88	Macro:0.86
GAN	Class0:0.98	Class0:0.99	Class0:0.82
	Class1:0.79	Class1:0.75	Class1:0.95
	Class2:0.79	Class2:0.75	Class2:0.95
	Micro:0.91	Micro:0.89	Micro:0.97
	Macro:0.86	Macro:0.83	Macro:0.91




圖 5.7 未處理平衡資料與平衡後的 ROC 比較圖(上圖為未資料平衡下圖為資料平衡後)

接著，從表 5.3 中可以明顯的可以看出初期磨耗(Class 0)分類結果皆為 GAN 生成方法為最佳。圖 5.8 也可以觀察出，初期磨耗(Class 0，紅色線)與劇烈磨耗(Class 2，紫色線)，平衡資料後曲線下的區域面積與未平衡資料相比明顯增加，可提昇原始資料集中，少筆數資料的辨識率。

表 5.3 所有方法 mAP 曲面下面積結果

	時序特徵提取	快速傅立葉轉換	連續小波轉換
原始資料	Class0:0.25	Class0:0.09	Class0:0.01
	Class1:0.90	Class1:0.95	Class1:0.95
	Class2:0.79	Class2:0.92	Class2:0.85
	Micro:0.85	Micro:0.82	Micro:0.91

Oversampling	Class0:0.09	Class0:0.16	Class0:0.24
	Class1:0.88	Class1:0.85	Class1:0.96
	Class2:0.80	Class2:0.69	Class2:0.86
	Micro:0.75	Micro:0.76	Micro:0.90
Downsampling	Class0:0.10	Class0:0.09	Class0:0.46
	Class1:0.90	Class1:0.90	Class1:0.96
	Class2:0.83	Class2:0.86	Class2:0.86
	Micro:0.79	Micro:0.79	Micro:0.92
SMOTE	Class0:0.09	Class0:0.08	Class0:0.14
	Class1:0.88	Class1:0.88	Class1:0.96
	Class2:0.78	Class2:0.82	Class2:0.89
	Micro:0.75	Micro:0.74	Micro:0.88
GAN	Class0:0.46	Class0:0.42	Class0:0.52
	Class1:0.87	Class1:0.85	Class1:0.96
	Class2:0.69	Class2:0.63	Class2:0.91
	Micro:0.82	Micro:0.78	Micro:0.94




圖 5.8 未處理平衡資料與平衡後的 mAP 比較圖(上圖為未資料平衡下圖為資料平衡後)

5.2.4 小結

表 5.4 為生成對抗網路與其他三種方法生成的資料，經由 4.2 中提到的三種方法，進行特徵擷取後的分類準確率比較，並以原始資料作為對照組。我們首先看到 Oversampling、Downsampling 與 SMOTE 的部分，三種生成數據的方法針對三種特徵擷取方法的效果皆較差，尤其是快速傅立葉轉換的效果明顯差於時序特徵提取與連續小波轉換。由於本研究採用的快速傅立葉轉換後僅針對頻率與振幅進行，並未考慮時間，因此效果較其他兩者不佳。從表 5.4 中還可以看出，GAN 的生成資料經由連續小波轉換，準確度可提昇到 0.88，時序特徵提取(accuracy = 0.84)與快速傅立葉轉換(accuracy = 73%)，也優於其他資料生成方法。由此可證實，本研究所提出的 GAN 平衡資料方法，相較於其他資料平衡的方法，更能有效地提高刀具分類的準確度。

表 5.4 生成資料評估

	時序特徵提取	快速傅立葉轉換	連續小波轉換
原始資料	73%	68%	62%
Oversampling	63%	63%	77%
Downsampling	66%	66%	83%
SMOTE	63%	63%	72%
GAN	84%	73%	88%

5.3 提升績效方法

為了使準確率再提升，本研究使用了集成式學習，也就是將 3 個特徵提取的模型結合進行分類，來提高準確度。為了能有效的提昇模型準確率，因此採用了準確率較高的模型進行深度特徵提取，並將深度特徵輸入至類神經網路進行分類，得出最終結果比先前的所有模型都高。表 5.5 中，集成式學習的模型準確率達到 91%，比先前未使用集成方法提高了 3%的準確度。

表 5.5 集成學習評估

	precision	recall	F1-score
0 類	0.70	0.98	0.82
1 類	0.96	0.99	0.97
2 類	0.98	0.88	0.93
accuracy		0.91	

第六章結論與未來研究

過往工廠的刀具磨耗通常都是依據作業員個人經驗，去判斷刀具更換的時間點，以減少產品損壞。而近年來有刀具監測系統的出現，成為目前工廠重要的系統之一。一般而言，若要建立完善的刀具監測系統，是需要相當多的實驗來蒐集數據，另外大多過往學者的研究，也僅使用了單一模型進行分類，分類結果也有不錯的績效，如何突破目前績效也是目前學者所關注的，因此我們提出兩個概念去克服問題。第一個概念是透過生成對抗網路以少量的資料產出符合現實工廠加工情況，解決資料不平衡的問題，並將原始資料與生成資料當作本研究所建立深度模型之輸入；第二個概念是將三種不同方法提取資料特徵建立卷積類神經網路進行訓練後，利用集成式學習讓多個模型結合進行分類，提昇準確度。總體而言，生成對抗網路可以解決資料數據難以蒐集和資料不平衡的問題，再結集成式學習提昇刀具即時監控的準確度。最後，本研究在原始刀具磨耗資料的驗證下，證明方法的有效性，但如要實際應用在工廠中，可能需要加強工廠內的硬體設備去因應龐大模型的需求。

針對未來研究上，有以下建議可以供參考：

- (1)輕量化深度學習的模型：為了解決深度學習模型運算成本過高的問題，可以考慮先針對模型進行特徵擷取並降低維度，再丟入簡易類神經模型進行分類，除了能達到深度學習一樣的效果，更能降低運算成本。
- (2)刀具磨耗除了原始數據的磨耗值以外，還可以加入主軸轉速跟進給率等等會影響刀具磨耗的相關因素來生成更符合現實的模擬數據。
- (3)本研究提出的框架應用於其他議題上，解決更多問題以證實此框架的實用性。

參考文獻

- [1] A. Bustillo, and J. J. Rodríguez, "Online breakage detection of multitooth tools using classifier ensembles for imbalanced data," *International Journal of Systems Science*, vol. 45, no. 12, pp. 2590-2602, 2014.
- [2] A. Duerden, F.E. Marshall, N. Moon, C. Swanson, K. Donnell and G.S. Grubbs II , "A chirped pulse Fourier transform microwave spectrometer with multi-antenna detection," *Journal of Molecular Spectroscopy*, vol. 376, pp. 111396, 2021.
- [3] A. Ishaq, S. Sadiq, M. Umer, S. Ullah, S. Mirjalili, V. Rupapara, and M. Nappi, "Improving the prediction of heart failure patients' survival using SMOTE and effective data mining techniques," *IEEE Access*, vol. 9, pp. 39707-39716, 2021.
- [4] A. P. Bradley, "The use of the area under the ROC curve in the evaluation of machine learning algorithms," *Pattern recognition*, vol. 30, no. 7, pp. 1145-1159, 1997.
- [5] A. R. Hassan, and M. I. H. Bhuiyan, "Automated identification of sleep states from EEG signals by means of ensemble empirical mode decomposition and random under sampling boosting," *Computer methods and programs in biomedicine*, vol. 140, pp. 201-210, 2017.
- [6] A. Shrivastava, T. Pfister, O. Tuzel, J. Susskind, W. Wang, and R. Webb, "Learning from simulated and unsupervised images through adversarial training," *Proceeding on IEEE Conf. on computer vision and pattern recognition*, pp. 2107-2116, 2017.
- [7] B. Krawczyk, M. Galar, Ł. Jeleń, and F. Herrera, "Evolutionary undersampling boosting for imbalanced classification of breast cancer malignancy," *Applied Soft Computing*, vol. 38, pp. 714-726, 2016.
- [8] C. C. Hsu, C. Y. Lee, and Y. X. Zhuang, "Learning to detect fake face images in the wild," *Proceeding on International Symposium on Computer, Consumer and Control*, pp. 388-391, 2018.
- [9] C. Cheng, J. Li, Y. Liu, M. Nie, and W. Wang, "Deep convolutional neural network-based in-process tool condition monitoring in abrasive belt grinding," *Computers in Industry*, vol. 106, pp. 1-13, 2019.
- [10] C. Shi, G. Panoutsos, B. Luo, H. Liu, B. Li, and X. Lin, "Using multiple-feature-spaces-based deep learning for tool condition monitoring in ultraprecision manufacturing," *IEEE Transactions on Industrial Electronics*, vol. 66, Issue. 5, pp. 3794-3803, 2018.

- [11] C. Shorten, and T. M. Khoshgoftaar, "A survey on image data augmentation for deep learning," *Journal of Big Data*, vol. 6, no. 1, pp. 1-48, 2019.
- [12] C. Sun, P. Wang, R. Yan, R. X. Gao, and X. Chen, "Machine health monitoring based on locally linear embedding with kernel sparse representation for neighborhood optimization," *Mechanical Systems and Signal Processing*, vol. 114, pp. 25-34, 2019.
- [13] C. Zhang, X. Yao, J. Zhang, and E. Liu, "Tool wear monitoring based on deep learning," *Comput. Integr. Manuf. Syst*, vol. 23, no. 10, pp. 2146-2155, 2017.
- [14] D. F. Hesser, and B. Markert, "Tool wear monitoring of a retrofitted CNC milling machine using artificial neural networks," *Manufacturing letters*, vol. 19, pp. 1-4, 2019.
- [15] D. H. Wolpert, "Stacked generalization," *Neural networks*, vol. 5, no. 2, pp. 241-259, 1992.
- [16] D. Kong, Y. Chen, and N. Li, "Gaussian process regression for tool wear prediction," *Mechanical systems and signal processing*, vol. 104, pp. 556-574, 2018.
- [17] D. Xue, X. Zhou, C. Li, Y. Yao, M. Rahaman, J. Zhang, H. Chen, J. Zhang, S. Qi, and H. Sun, "An Application of Transfer Learning and Ensemble Learning Techniques for Cervical Histopathology Image Classification," *IEEE Access*, vol. 8, pp. 104603-104618, 2020.
- [18] F. Jia, Y. Lei, J. Lin, X. Zhou, and N. Lu, "Deep neural networks: A promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with massive data," *Mechanical Systems and Signal Processing*, vol. 72, pp. 303-315, 2016.
- [19] International Organization for Standardization (Geneva), ISO 3685: Tool-life Testing with Single-point Turning Tools. ISO, 1993.
- [20] J. Deng, G. Pang, Z. Zhang, Z. Pang, H. Yang, and G. Yang, "cGAN based facial expression recognition for human-robot interaction," *IEEE Access*, vol. 7, pp. 9848-9859, 2019.
- [21] J. Mathew, C. K. Pang, M. Luo, and W. H. Leong, "Classification of imbalanced data by oversampling in kernel space of support vector machines," *IEEE transactions on neural networks and learning systems*, vol. 29, no. 9, pp. 4065-4076, 2017.

- [22] J. Shijie, W. Ping, J. Peiyi, and H. Siping, "Research on data augmentation for image classification based on convolution neural networks," *Proceeding on IEEE Conf. on Chinese automation congress*, pp. 4165-4170, 2017.
- [23] J. Viola, Y. Q. Chen, and J. Wang, "FaultFace: Deep convolutional generative adversarial network (DCGAN) based ball-bearing failure detection method," *Information Sciences*, vol. 542, pp. 195-211, 2021.
- [24] J. Wang, J. Xie, R. Zhao, L. Zhang, and L. Duan, "Multisensory fusion based virtual tool wear sensing for ubiquitous manufacturing," *Robotics and computer-integrated manufacturing*, vol. 45, pp. 47-58, 2017.
- [25] J. Wei, Z. Lu, K. Qiu, P. Li, and H. Sun, "Predicting Drug Risk Level from Adverse Drug Reactions Using SMOTE and Machine Learning Approaches," *IEEE Access*, vol. 8, pp. 185761-185775, 2020.
- [26] K. Koga, "Signal processing approach to mesh refinement in simulations of axisymmetric droplet dynamics," *Journal of Computational and Applied Mathematics*, vol. 383, pp. 113131, 2021.
- [27] L. Breiman, "Bagging predictors," *Machine learning*, vol. 24, no. 2, pp. 123-140, 1996.
- [28] L. Perez, and J. Wang, "The effectiveness of data augmentation in image classification using deep learning," *arXiv preprint*, arXiv:1712.04621, 2017.
- [29] M. C. Gomes, L. C. Brito, M. B. da Silva, and M. A. V. Duarte, "Tool wear monitoring in micromilling using Support Vector Machine with vibration and sound sensors," *Precision Engineering*, vol. 67, pp. 137-151, 2021.
- [30] M. Jalayer, C. Orsenigo, and C. Vercellis, "Fault detection and diagnosis for rotating machinery: A model based on convolutional LSTM, Fast Fourier and continuous wavelet transforms," *Computers in Industry*, vol. 125, pp. 103378, 2021.
- [31] M. Koziarski, B. Kwolek, and B. Cyganek, "Convolutional neural network-based classification of histopathological images affected by data imbalance," *Proceeding on Video Analytics. Face and Facial Expression Recognition*, pp. 1-11, 2018.
- [32] M. S. H. Bhuiyan, I. A. Choudhury, and Y. Nukman, "An innovative approach to monitor the chip formation effect on tool state using acoustic emission in turning," *International Journal of Machine Tools and Manufacture*, vol. 58, pp. 19-28, 2012.

- [33] M. S. H. Bhuiyan, I. A. Choudhury, M. Dahari, and Y. Nukman, "Application of acoustic emission sensor to investigate the frequency of tool wear and plastic deformation in tool condition monitoring," *Measurement*, vol. 92, pp. 208-217, 2016.
- [34] M. Wang, J. Zhou, J. Gao, Z. Li, and E. Li, "Milling Tool Wear Prediction Method Based on Deep Learning Under Variable Working Conditions," *IEEE Access*, vol. 8, pp. 140726-140735, 2020.
- [35] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: synthetic minority over-sampling technique," *Journal of artificial intelligence research*, vol. 16, pp. 321-357, 2002.
- [36] P. Kumari, and D. Toshniwal, "Extreme gradient boosting and deep neural network based ensemble learning approach to forecast hourly solar irradiance," *Journal of Cleaner Production*, vol. 279, pp. 123285, 2021.
- [37] Q. Sun, and Z. Ge, "Deep learning for industrial KPI prediction: When ensemble learning meets semi-supervised data," *IEEE Transactions on Industrial Informatics*, vol. 17, no. 1, pp. 260-269, 2020.
- [38] Q. Wu, P. Wang, C. Shen, I. Reid, and A. Van Den Hengel, "Are you talking to me? reasoned visual dialog generation through adversarial learning," *Proceeding on IEEE Conf. on Computer Vision and Pattern Recognition*, pp. 6106-6115, 2018.
- [39] R. Corne, C. Nath, M. El. Mansori, and T. Kurfess, "Study of spindle power data with neural network for predicting real-time tool wear/breakage during inconel drilling," *Journal of Manufacturing Systems*, vol. 43, pp. 287-295, 2017.
- [40] R. Zhao, D. Wang, R. Yan, K. Mao, F. Shen, and J. Wang, "Machine health monitoring using local feature-based gated recurrent unit networks," *IEEE Transactions on Industrial Electronics*, vol. 65, no. 2, pp. 1539-1548, 2017.
- [41] R. Zhao, R. Yan, J. Wang, and K. Mao, "Learning to monitor machine health with convolutional bi-directional LSTM networks," *Sensors*, vol. 17, no. 2, pp. 273, 2017.
- [42] S. Dolinšek, and J. Kopač, "Acoustic emission signals for tool wear identification," *Wear*, vol. 225, pp. 295-303, 1999.
- [43] Ş. Ertürk, and O. Kayabaşı, "Investigation of the Cutting Performance of Cutting Tools Coated With the Thermo-Reactive Diffusion (TRD) Technique," *IEEE Access*, vol. 7, pp. 106824-106838, 2019.

- [44] S. F. Abdoh, M. A. Rizka, and F. A. Maghraby, "Cervical cancer diagnosis using random forest classifier with SMOTE and feature reduction techniques," *IEEE Access*, vol. 6, pp. 59475-59485, 2018.
- [45] S. K. Jalali, H. Ghandi, and M. Motamedi, "Intelligent condition monitoring of ball bearings faults by combination of genetic algorithm and support vector machines," *Journal of Nondestructive Evaluation*, vol. 39, no. 1, pp. 1-12, 2020.
- [46] T. Miyato, and M. Koyama, "cGANs with projection discriminator," *arXiv preprint*, arXiv:1802.05637, 2018.
- [47] T. Mohanraj, J. Yerchuru, H. Krishnan, R. S. Nithin Aravind, and R. Yameni, "Development of tool condition monitoring system in end milling process using wavelet features and Hoelder's exponent with machine learning algorithms," *Measurement*, vol. 173, pp. 108671, 2021.
- [48] T. Pinto, I. Praça, Z. Vale, and J. Silva, "Ensemble learning for electricity consumption forecasting in office buildings," *Neurocomputing*, vol. 423, pp. 747-755, 2021.
- [49] W Xu, K.J. Xu, X.L. Yu, Y. Huang, and W.K. Wu, "Signal processing method of bubble detection in sodium flow based on inverse Fourier transform to calculate energy ratio," *Nuclear Engineering and Technology*, 2021.
- [50] W. Jiang, Y. Hong, B. Zhou, X. He, and C. Cheng, "A GAN-based anomaly detection approach for imbalanced industrial time series," *IEEE Access*, vol. 7, pp. 143608-143619, 2019.
- [51] W. R. Tan, C. S. Chan, H. E. Aguirre, and K. Tanaka "ArtGAN: Artwork synthesis with conditional categorical GANs," *Proceeding on IEEE Conf. on Image Processing*, pp. 3760-3764, 2017.
- [52] X. Yang, Y. Xu, Y. Quan, and H. Ji, "Image denoising via sequential ensemble learning," *IEEE Transactions on Image Processing*, vol. 29, pp. 5038-5049, 2020.
- [53] Y. Freund, and R. E. Schapire, "Experiments with a new boosting algorithm," *In icml*, vol. 96, pp. 148-156, 1996.
- [54] Y. Shi, D. Deb, and A.K. Jain, "WarpGAN: Automatic caricature generation," *Proceeding on IEEE Conf. on Computer Vision and Pattern Recognition*, pp. 10762-10771, 2019.

- [55] Z. Li, R. Liu, and D. Wu., "Data-driven smart manufacturing: tool wear monitoring with audio signals and machine learning," *Journal of Manufacturing Processes*, vol. 48, pp. 66-76, 2019.
- [56] 賴屹民(譯)(民 109)。精通機器學習：使用 Scikit-Learn, keras 與 TensorFlow(原作者：Aurélien Géron)。台北市：碁峰資訊。(原著出版年：2019)
- [57] 2010 phm society conference data challenge:
<https://www.phmsociety.org/competition/phm/10>.

