

2020/02/25

國立雲林科技大學研究生學位論文電子檔上傳同意書

National Yunlin University of Science and Technology Agreement on Uploading E-file of the Thesis

工業工程與管理 研究所 工工 組研究生 王怡婷 (請簽章)

論文已完成口試委員修改建議，並經系所辦查對以下事項無誤，請同意論文上傳學校圖書館。

■查對事項：

☒ 中文論文名稱(研究生自填)：

基於卷積類神經網路之澳門公車軌跡辨識

☒ 英文論文名稱(研究生自填)：

Trajectory Recognition of Macao Bus Based on Convolutional Neural Networks

☒ 中文論文名稱與學位論文考試委員會審定書之名稱一致。

☒ 中、英文論文名稱與教務資訊系統/歷年成績之名稱一致。

☒ 中、英文論文名稱與學位論文 PDF 檔封面之名稱一致。

查對人(系所辦助理)： 組員陳應心 (請簽章)

謹陳

論文指導教授： 陳老中 (請簽章)

備註：

論文上傳前，請掃描成電子檔併於學位論文 PDF 檔第一頁(封面的前一頁)。
請勿裝訂於紙本學位論文內。

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

基於卷積類神經網路之澳門公車軌跡辨識

Trajectory Recognition of Macao Bus Based on

Convolutional Neural Networks

王怡婷

Yi-Ting Wang

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D.

中華民國 109 年 6 月

June 2020

國立雲林科技大學
碩士班學位論文考試委員會審定書

本論文係王怡婷君在本校 工業工程與管理系所提論文「基於卷積類神經網路之澳門公車軌跡辨識」合於碩士資格水準，業經本委員會評審認可，特此證明。

口試委員：

陳奕中

陳奕中

侯東旭

侯東旭

黃家耀

黃家耀

指導教授：

陳奕中

陳奕中

所 長：

駱昱

中 華 民 國 109 年 7 月 8 日

摘要

近年來隨著全球定位系統(GPS)技術的逐漸發展，人們要監控地球上各種物體的移動方式也越來越方便，而許多大眾交通工具的營運公司也跟上這股潮流，紛紛在自家的交通工具上架設 GPS 系統，並利用該系統回傳的交通工具點位進行各項與營運有關的分析，如到站時間預測、駕駛行為分析等，而澳門公車的營運公司也跟上這股潮流，在他們公司所擁有的公車上裝上 GPS 並收集資料。然而，該公司目前所收集到的 GPS 資料是與車子開關連動，因此只要公車一發動，該公車不論是否在營運其位置都會回傳到系統上。此外，因為該營運公司也未記錄公車的運行班表，所以 GPS 系統上所收集到的軌跡幾乎無法判別屬於哪條路線的哪個班次，更別說進行後續各項分析。本論文則提出了新的軌跡識別模型-金字塔卷積類神經網路來協助澳門公車的營運公司辨識每條軌跡屬於哪條路線的哪個班次。最終，本研究使用了整年份的澳門公車軌跡資料來證實本研究所提出之方法的有效性。

關鍵字: GPS 軌跡辨識、公車路線、卷積類神經網路、金字塔結構

ABSTRACT

Advances in the implementation of global-positioning-system (GPS) technology have made it increasingly convenient to monitor the movement of objects on the earth. GPSs installed in private vehicles are widely used to predict arrival times and assess driver behavior. The Macau transport authority has installed GPS systems on busses; however, the system is unable to determine whether vehicles are in operation. Furthermore, tracking data has not been integrated with bus schedules, such that the trajectories collected by the GPSs cannot be linked to specific bus routes or operators. This paper proposes a model-pyramid convolutional neural network for trajectory recognition to identify the route and shift to which trajectory data belongs. The efficacy of the proposed scheme was verified using real-world bus trajectory data for Macau from a one-year period.

Key words : GPS track recognition · Bus route · Convolutional neural network · Pyramid structure

目錄

摘要	i
ABSTRACT	ii
目錄	iii
表目錄	v
圖目錄	vii
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	2
1.3 研究範圍與限制	5
第二章 文獻探討	6
2.1 軌跡辨識	6
2.2 卷積類神經網路(Convolutional neural networks , CNNs)	8
2.3 金字塔結構	10
第三章 資料集	12
3.1 澳門公車的 GPS 軌跡資料之介紹	12
3.2 澳門公車站牌資料之介紹	15
第四章 研究方法	16
4.1 研究架構	16
4.2 產生 GPS 軌跡圖	17
4.3 方法一:一般卷積類神經網路	19

4.4 方法二:分群	21
4.5 方法三:金字塔卷積類神經網路	24
第五章 實驗模擬	26
5.1 單軌軌跡之方法一結果分析	27
5.2 單軌軌跡之方法二結果分析	30
5.3 單軌軌跡之方法三結果分析	33
5.4 單軌軌跡之總結結果分析	36
5.5 多軌軌跡之方法一結果分析	36
5.6 多軌軌跡之方法二結果分析	38
5.7 多軌軌跡之方法三結果分析	40
5.8 多軌軌跡之總結	42
第六章 結論與未來研究	43
參考文獻	44

表目錄

表 2.1 軌跡辨識相關文獻整理	7
表 2.2 卷積類神經相關文獻整理	9
表 2.3 金字塔結構相關文獻整理	11
表 3.1 澳門公車 GPS 軌跡資料範例	12
表 3.2 各公車編號之單軌跡圖	13
表 3.3 澳門公車站牌資料	15
表 4.1 GPS 軌跡資料比對示意圖	18
表 5.1 第 10 條路線之個別辨識結果	27
表 5.2 第 13 條路線之個別辨識結果	28
表 5.3 第 22 條軌跡路線之個別辨識結果	29
表 5.4 各軌之分辨率	29
表 5.5 各分群數量之分數	30
表 5.6 各分群之輪廓系數	30
表 5.7 單軌跡之分群總結果	33
表 5.8 第一階段之紅色部分分數計算	34
表 5.9 第二階段之紅色部分分數計算	35
表 5.10 單軌跡方法二綜合比較表	36
表 5.11 多軌跡識別之個別類別辨識率	37
表 5.12 方法二之各群分群分數	38
表 5.13 方法二之各群輪廓系數	38
表 5.14 多軌跡方法二之綜合比較表	40
表 5.15 多軌跡第一階段切割結果	41
表 5.16 第二階段切割結果	42

表 5. 17 各方法之結果比較	42
------------------------	----



圖目錄

圖 1. 1 澳門地區公車路線圖	2
圖 1. 2 軌跡切割示意圖[36]	4
圖 1. 3 階層式卷積類神經架構示意圖	4
圖 2. 1 卷積類神經網路架構圖[35]	9
圖 4. 1 研究流程圖	16
圖 4. 2 球面距離計算範例	17
圖 4. 3 多軌跡之輸入示意圖	19
圖 4. 4 卷積層運算示意圖	20
圖 4. 5 池化層計算方式示意圖	20
圖 4. 6 分群方法之流程圖	21
圖 4. 7 <i>HOG</i> 特徵圖示意圖	22
圖 4. 8 金字塔方法之流程圖	24
圖 5. 1 50 條公車路線圖	26
圖 5. 2 單軌跡之模型準確率	27
圖 5. 3 第 10 條路線之個別辨識結果	28
圖 5. 4 第 13 條路線之個別辨識結果	28
圖 5. 5 第 22 條軌跡路線之個別辨識結果	29
圖 5. 6 分群數量為 9 之散點圖	31
圖 5. 7 第一群模型績效	31
圖 5. 8 第二群模型績效	32
圖 5. 9 R17 之路線比較圖	32
圖 5. 10 第三群模型績效	32
圖 5. 11 第一階段切割圖	33

圖 5. 12 第一階段之切割結果.....	34
圖 5. 13 第二階切割圖	35
圖 5. 14 第二階段之切割結果	35
圖 5. 15 多軌跡之示意圖	37
圖 5. 16 分群數 2 v.s 分群數 8 之散點圖	38
圖 5. 17 多軌跡之分群第一群示意圖.....	39
圖 5. 18 多軌跡分群之第 1 群模型結果	39
圖 5. 19 多軌跡分群之第 2 群模型結果	39
圖 5. 20 多軌跡第一階段切割	40
圖 5. 21 多軌跡之第一階段切割結果	41
圖 5. 22 第二階段多軌跡切割	41
圖 5. 23 第二階段切割結果	42



第一章 緒論

1.1 研究背景與動機

近年來隨著定位技術和監視設備的飛速發展，各種大眾運輸工具上開始廣泛的配備全球定位系統(GPS)，由於 GPS 能提供許多大眾運輸工具詳細且高精度的時間和位置訊息，對於大眾運輸營運的公司來講特別重要，因為可以透過收集到的 GPS 軌跡數據進行各項之分析，包含到站資訊預測、駕駛行為模式分析、交通流量分析等等。而澳門公車營運業者也跟上了全球如此的步伐，開始將 GPS 傳感器裝置於公車上並收集大量的公車軌跡路線，其公車軌跡路線圖如圖 1.1 所示。

上述澳門公車的營運公司雖然想法不錯，但是在實際上時卻發現這些數據無法順利被分析，因為澳門公車傳感器與公車電源連動，只要公車一啟動其時間和位置就會被紀錄且回傳到系統裡面，再加上澳門公車當時並沒有記載每輛公車的班表，所以目前澳門公車無法得知收集來的公車軌跡是否屬於有營運的狀況，或者即使公車在營運的狀況下，也無法辨別這是屬於哪一條公車路徑。再者，GPS 傳感器會遇到許多 GPS 軌跡和真實移動路線不同的情形，這是因為 GPS 傳感器本身就有飄移的問題且澳門地區也常有辦活動或是修路的情形，所以澳門公車經常需要改道行駛造成真實量測到的軌跡和實際移動軌跡不同，因此澳門公車業者現在急需是辨識出所收集到的 GPS 訊號屬於哪一個班次的公車軌跡。

過往能有效的使用 GPS 軌跡數據進行軌跡辨識的學者，例如，Zhao *et.al*[1] 在 2020 年提出一個無監督式的兩階段方法，而該方法是為了利用 GPS 軌跡資料來推斷運輸危險物品的之多次出行目的為何，例如，裝載、卸載或停靠站點等，實驗結果之準確性表明，該方法可以有效的幫助分析和裝載狀態相關的車輛行程，也提供危險品運輸監管決策上的幫助，Yu *et.al*[2]利用智慧型手機上配備的 GPS




圖 1.1 澳門地區公車路線圖

功能來產生車隊的軌跡數據，並利用一種基於單元式的地圖匹配技術來生成時空速度矩陣，接著透過 Schattenp-norm 矩陣來跳脫數據上的限制，其使用來自中國成都的數據進行驗證，除了可以幫助監視和可視化交通路網中的流量狀態，也可以做為新的流量管理方式，Kohan *et.al*[3]為了發現和交通擁堵有關的交通流量模式，提出高交通流量模式的模型，並且從這模式中繪製嚴重交通堵塞時的替代路徑來作為訓練資料，經由實際數據進行驗證之後，其模型提供良好的績效且也提供交通擁堵時的替代方案，由於澳門常常有改道行駛的情況發生，因此上述之方法皆不適合用在澳門地區，李泊漾[36]的研究論文曾利用資料結構的 hash 方法來辨識澳門公車軌跡，然而成效並沒有很好。

1.2 研究目的

本論文預期採用人工智慧卷積類神經網路來解決上述問題，利用將經緯度點為位置放在地圖上來作為圖像資料，有這樣子的想法是因為卷積類神經網路在影像辨識上表現出眾，因此被眾多學者使用且作為影像辨識的重要工具，舉例來說，Verma *et.al*[4]在 2020 年提出一種能夠識別單肢或視多肢人類活動的卷積類神經網路，Tang *et.al*[5]利用一種基於三維卷積類神經網路以了解自動車輛識別觀察和

其 OD 呈現的交通模式之間的高相關性，為滿足交通流量的管理和控制的需求，需要準確的和時間相關之 OD 矩陣，其實驗結果顯示在大量的 OD 下，相對誤差穩定在百分之五左右，Han *et.al*[6]由於卷積類神經網路深度學習的技術可以從圖像中提取典型特徵和區分多層次特徵，因此將其用於複雜場景中遙感大數據的多目標識別，在其研究中證明了卷積類神經網路在遙感圖像數據目標識別中具有良好之應用前景，Zhu *et.al*[7]針對室內應用場景的特點，提出一種快速卷積類神經網路的圖像分割法，對室內圖像進行分割且透過層間融合的方式來減少室內場景圖像的數量，從結果可以看出其尺度融合技術可以有效的避免卷積類神經圖像特徵訊息的丟失且具有更快速的圖像預處理。綜合上述卷積類神經網路在圖像處理中的相關論文，我們發現若能將軌跡先轉換為圖像(如圖 1.2 所示)，再使用卷積類神經網路進行分析則應能獲得較傳統軌跡分析方法更好的結果。

然而我們發現單一卷積類神經網路能應用在許多領域上，但若運用在澳門公車的軌跡資料上單一卷積類神經網路難有好的效果，因為以下兩個原因(1)澳門的地小且人口分布不均，其公車路線大部分都集中在某部分區域，(2) 軌跡相似度高，澳門擁有許多公車業者，不同公車號碼但行駛相同路線所屬不同公車業者，而需分為不同類別，造成雖不同號碼但軌跡路線相似度高的問題。因此本研究額外提出了使用地圖切割的方式來改善上述的問題，包含(1)該如何切割，如果切割過多則為造成過度學習，若過少則有可能造成模型學習不到重要的特徵，(2)何時該停止，若無設定閾值停止切割有可能會造成模型績效不增反減的情況發生，因此本研究採用樹狀切割的方式。在該方法中，我們會計算單一軌跡特徵圖之 RGB 平均值取差異最大的部分做為切割方向以及利用 *K-means* 分群方法將所有軌跡進行相似度計算再切割，接著我們會將地圖切割成多個區塊再進行建模，然而我們也必須了解到單一卷積類神經網路對於軌跡易變性高且密度高的情況無法擁有良好的績效。



圖 1.2 軌跡切割示意圖[36]




圖 1.3 階層式卷積類神經架構示意圖

因此本研究利用階層式卷積類神經網路來提升準確度，再切割完軌跡圖之後再分別對每一個網格區塊進行建模，其示意圖如圖 1.3 所示，直至到達指定之閾值則停止切割，最後我們使用澳門公車軌跡資料進行驗證。

1.3 研究範圍與限制

本研究限制如下：

1. 公車上的傳感器並不會因為無載客的時候關閉，因此，本研究進行軌跡辨識時會參雜其他非正常行駛之公車路線。
2. 澳門地狹人稠且經常發生維修道路之行為，當有維修情況發生時就會造成某些公車路線須改道而行，因而形成與原本公車路線不一樣而造成模型無法輕易分辨。
3. 不同公司的公車所擁有的 GPS 軌跡資料相似度高，因此在分類模型上可能會造成誤判。



第二章 文獻探討

在本章節中共分成三個小節，分別為軌跡辨識、卷積類神經、金字塔結構，在 2.1 小節中會詳細介紹應用深度學習於軌跡辨識的相關研究及目標，藉此了解如何應用不同的深度學習方法於軌跡辨識中且了解其特色和優點，而不同的深度學習模型可以用於不同的資料、領域上、績效也因此會有所差異，接著在 2.2 小節將著重介紹如何建構卷積類神經以及概念和原理，並針對目前有應用到該模型的文獻深入研究探討，而在 2.3 小節中將介紹過往研究中不同的類神經金字塔結構，並且深度探討其不同模型的績效以及其應用。

2.1 軌跡辨識

由於人們的生活方式是透過從一個點到另一個點串聯形成軌跡來表示，現代社會中許多運輸業者如公車公司、物流公司、計程車公司等在其車輛上加裝全球定位系統(GPS)做為即時監控和調度使用並且收集大量的時空紀錄，透過分析這些紀錄來進行軌跡辨識且可以廣泛應用在其他領域，舉例來說 JIN *et al.*[8]在 2018 年分析大規模軌跡資料進而了解當地居民的生活型態且分析這些軌跡背後的隱藏行為模式達到區分該軌跡是屬於犯罪嫌疑人的還是普通居民，Xiao *et al.*[9]利用軌跡數據形成的旅行模式擷取一些關鍵的旅行特徵，包括旅行價格、旅行目的、和旅行方式，再利用機器學習以及其他分類方法找出行使模式有助於檢測不同種型態的行為模式，Yuan *et al.*[10]為了解決交通堵塞的問題，透過識別車輛軌跡估算從起點到道路行駛的時間以分析不同交通流量對目標道路擁堵的影響，Wei *et al.*[11]在 2019 年藉由觀察軌跡之間的相似程度來找尋交通事件的特徵，並加入時間序列的數據開發出一種能夠結合車輛運動學的新模型來判斷交通事件以提供相關的管理人員做決策，Zhang *et al.*[12]利用移動設備所生成的大量時空軌跡數據，透過多尺度深度學習模型分類運輸方式和速度，McLaughlin *et al.* [13]利用遞迴類神經網路在開放的環境中重疊攝影機影像且重新識別人的軌跡，

表 2.1 軌跡辨識相關文獻整理

作者	目標	方法
Jin <i>et al.</i> [8]	分類嫌疑犯及居民軌跡	TPM、MST-CNN
Xiao <i>et al.</i> [9]	分類旅行模式	SVM、MNL、BN、 ANN、GPC
Yuan <i>et al.</i> [10]	自動車輛識別起點軌跡	DNN
Wei <i>et al.</i> [11]	分類虛擬和真實軌跡	CNN
Zhang <i>et al.</i> [12]	分類車種軌跡	DenseNet
McLaughlin <i>et al.</i> [13]	重新識別人的軌跡	CNN、RNN
Li <i>et al.</i> [14]	選擇最適合移動廣告的候選 車輛	MLP-W、MLP-T
Zheng <i>et al.</i> [15]	分辨鐵路駕駛員的駕駛行為	DEC、AAEKC、 AAECC、SAECC
Arif <i>et al.</i> [16]	識別人類動作	CNN
Park <i>et al.</i> [17]	預測車輛軌跡	LSTM

Li *et al.*[14]開發深度學習模型根據每台移動廣告車輛的軌跡選擇最適合移動廣告的候選車輛，Zheng *et al.*[15]利用五種無監督式之深度學習模型結合 GPS 軌跡和檔位變化分辨鐵路駕駛員的駕駛行為，Arif *et al.*[16]，通過跟蹤人類運動像素內的點位生成有效軌跡，再利用卷積類神經網路萃取特徵並識別人類動作，Park *et al.*[17]開發了一種深度學習的方法並將其應用於學習和預測交通路網中車輛的運行模式，綜合上述例子，不論是在都會區或是城鄉郊區對於路況資訊需求日益漸增，國內交通運輸的相關單位開始利用資訊和通訊等科技，結合交通運輸之專業知識，然而傳統軌跡辨識方法仍是根據歷史資料統計計算每一條軌跡的相似度，再將相似度高的軌跡歸在同一類搭配專家經驗分析，但如此作法當數據量較大時就須對每一個 GPS 訊號進行運算，需耗費大量人力與時間，分析出的數據也可能因為人工處理而有錯誤，如此結果可能導致決策的錯誤或是誤判，在效益方面可能造成虧損而得不償失，然而由於人工智慧的興起，需多科學家開始將機器學習等方法應用於軌跡辨識，而機器學習在解決非線性問題且複雜度高的資料上較弱，

相較於機器學習類神經網路不但可以解決非線性的問題也沒有太多的限制，模型本身具有學習能力且在足夠的樣本及合適的參數設計下，模型即可有一定準確率的預測能力，本節提供了應用深度學習於軌跡識別的相關研究並整理如表 2.1 所示。

2.2 卷積類神經網路(Convolutional neural networks, CNNs)

所謂卷積類神經網路又名 CNN，是一種監督式學習的方法，在圖片的辨識上擁有相似於人類的辨識能力甚至更好，相較於一般的類神經網路(Deep neural networks, DNNs)辨識圖像，因其只能輸入平面的資料也就是一維資料的特性，而忽略資料本身的形狀間接造成喪失原本空間排列的重要資訊，然而由於卷積類神經多了卷積層和池化層兩層，讓卷積類神經不只是簡單的將資料進行運算還能保留空間上的資訊，更可以看到圖像的小細節且能避免參數大幅的增加。

目前關於卷積類神經網路的應用大多在影像辨識方面，常用於影像辨識、特徵選取、音訊分類、文本分類等等，少部分會用在時間序列的分析，例如，Priego-Torres *et al.*[18]在 2020 年的時候應用卷積類神經網路對惡性乳腺組織進行分割並判斷其是否為乳腺癌，Yao *et al.*[19]在 2020 年提出了一種基於卷積類神經網路的智能軸承故障診斷方法，除了判斷的速度增加以外更大幅提升的故障嚴重性識別的準確度，Fuqua *et al.*[20]開發了一種成本敏感的分類方案，透過卷積類神經網路在製造環境中辨識可分離或不可分離之故障模式，Khatami *et al.*[21]將卷積類神經網路合併正規化的新方法，集中訓練數據的規律性訊息以提高特徵的重要性且在醫學影像上證明其網路的有效性和準確性，Kujawa *et al.*[22]在 2020 年利用卷積類神經網路對汙泥和菜籽秸製成的堆肥早期成熟度進行分類的可能性，為堆肥的早期成熟度的評估提供一種簡化且具有成本效益的方法，Wang *et al.*[23]提出一種基於聚類的人臉識別卷積類神經網路，Zhou *et al.*[24]在 2020 年提出了一種基於卷積類神經網路和安全主題相關的微博客搜索模型，透過搜索特定安全




圖 2.1 卷積類神經網路架構圖[35]

表 2.2 卷積類神經相關文獻整理

作者	目標	方法
Priego-Torres <i>et al.</i> [18]	診斷是否為乳腺癌	DCNN
Yao <i>et al.</i> [19]	智能軸承故障診斷	SIRCNN
Fuqua <i>et al.</i> [20]	異常控制圖辨識	CSCNN
Khatami <i>et al.</i> [21]	醫學影像相關辨識	CNN
Kujawa <i>et al.</i> [22]	堆肥的早期成熟度分類	CNN
Wang <i>et al.</i> [23]	人臉識別	CNNs
Zhou <i>et al.</i> [24]	微博安全主題的分類	DCNN-CSTRS
Zhao <i>et al.</i> [25]	機台故障診斷	CNN
Chen <i>et al.</i> [26]	識別植物病害	VGGNet
Chen <i>et al.</i> [27]	社交媒體傳播研究	CNN

主題的內容的微博並針對其獲取之局部語意特徵進行分類。

Zhao *et al.*[25]開發深度殘差收縮卷積類神經網路以提高來自高噪聲真動的訊號特徵習能力，並且提供較高準確度之故障診斷。學 Chen *et al.*[26]在 2020 年運用卷積類神經網路自動識別植物病害，透過識別植物葉片的疾病並取得其相關特徵以利後續辨識，Chen *et al.*[27]開發基於深度學習的 3D 藝術設計模型的特徵提取方法，利用矩陣函數提取人們偏好的特徵，並在 3D 藝術創作進行社交媒體傳播研究，將科學和藝術創造相結合得到了驗證，綜合上述可以得知，現今卷積類神經網路已經被運用在各種領域且都有得到很好的績效，不僅可以處理圖像資料甚至到文本內容都可以處理且由於其模型本身特徵提取功能，因此也有許多人運

用在特徵處理上。

2.3 金字塔結構

金字塔結構現今最主要的用途為圖像切割和語意分割，是一種以多角度解析圖像的有效且概念相對簡單的結構，一般而言，當在分辨影像的類別時會直接觀察目標物之外觀且可能還會搭配其周圍的背景，若忽略這些特徵而直接做分辨可能就會造成準確度降低的情況發生，然而由於金字塔結構能夠有效利用圖像的上下文信息提高分割的性能進而得到更好的模型績效，例如，Tang *et al.*[28]在 2020 年的時後提出一種基於深度殘差之拉普拉斯金字塔網路辨去分辨地面真實高分辨率圖像，在此研究中利用了二階段訓練的策略，利用不同輸出組件間之上下文訊息並在數據集上進行大量的驗證且得到了不錯的績效，Chen *et al.*[29]透過具有上下文特徵之特徵融合模型的圖像分割方法進行分類，利用高斯核函數進行預處理形成一系列不同的小圖像進而形成金字塔圖像，再將其作為模型的輸入以提升模型準確度，Tuncer *et al.*[30]提出一種新穎的基於金字塔和多核的方法來提高分辨鹽和胡椒的準確率，為了深度提取特徵使用金字塔模型從每個集別提取特徵再進行降維，最後實驗結果證明該方法的成功，Wei *et al.*[31]提出了一種建築物自動提取框架，而該框架時基於卷積類神經網路的分割和將分割圖像轉換為結構化的多邊形正規化所組成，並且引入金字塔結構的多尺度來開發模型，在不同數據集上進行的實驗表明，在圖像分辨率低的情況下也有很好的表現，Guo *et al.*[32]利用多尺度特徵金字塔的 3D 卷積類神經網路分割鼻咽癌圖像，為了有效提高特徵的重用性以及避免梯度消失和爆炸，而將第一層卷積的原始特徵直接傳遞到每個採樣階段，最後的實驗結果也有效等於經驗豐富的醫生判斷，Zhang *et al.*[33]使用多層級細化機制來增強前饋類神經網路，先生成一個粗略的預測圖再以分層遞歸連接類神經網路組合特徵且搭配金字塔池化層用於聚合機於不同區域的全圖像上下文，相較於一般類神經具有良好的績效，Fu *et al.*[34]開發一種基於卷積類神經網

表 2.3 金字塔結構相關文獻整理

作者	目標	方法
Tang <i>et al.</i> [28]	分辨地面真實高分辨率圖像	DLP
Chen <i>et al.</i> [29]	特徵融合模型的圖像分割	CNN
Tuncer <i>et al.</i> [30]	基於金字塔和多核的方法	Multi kernel LBP;
Wei <i>et al.</i> [31]	建築物辨識	FCN
Guo <i>et al.</i> [32]	鼻咽癌圖像識別	SFP
Zhang <i>et al.</i> [33]	多層級細化機制來增強前饋類神經網路	CNN
Fu <i>et al.</i> [34]	自動學習火車滾動軸承的缺陷特徵	APP-UNet16

路可以自動學習火車滾動軸承的缺陷特徵，不需要像傳統方法一樣手動設計和提取特徵，透過空間金字塔直接對火車圖像進行分割，結果表明能夠識別油斑較小的缺陷區域，綜合上述可以得知，金字塔結構被廣泛運用在圖像上並且與卷積類神經網路節合，不但可以在圖像上取得更細緻的特徵，還可以大幅提升模型的績效。



第三章 資料集

在本章節將介紹本論文研究所使用之資料集，總共有兩種，分別為澳門公車 GPS 軌跡資料、澳門公車站牌資料。














3.1 澳門公車的 GPS 軌跡資料之介紹

本研究驗證所使用的 GPS 軌跡資料為澳門公車 2016 年 5 月 1 日至 5 月 9 日的軌跡資料，其欄位名稱包含 GPS 時間、公車路線號碼、站牌順序、經度、緯度，共 5 種資料。表 3.1 為澳門公車 GPS 軌跡資料的範例，其中 GPS 時間為紀錄回傳的時間，經度和緯度表示的為該公車當下的地理位置，公車路線號碼為該公車的代號，站牌順序為公車每一個站點位置的順序，其記錄方式為第一站和第二站之間的點位皆標示為 1，以此類推，接著根據每台公車所回傳的 GPS 軌跡數據繪製成軌跡圖，如表 3.2 所示，而澳門公車的 GPS 傳感器連接鑰匙，當插入鑰匙啟動公車之後便開始收集資料且每 10 秒回傳一筆到公司的伺服器，然後卻有可能因為以下限制而造成本研究資料處理上困難，(1)營運資料和非營運資料混雜，由於公車啟動便會收集資料，即便公車只是在回送或是從休息點移動到第一個站點位置也會被記錄下來與營運資料混雜在一起，(2)外部因素影響問題，澳門地狹人稠常常有道路整修的事件發生，因而造成公車無法按照原本的行駛路線行駛需改道而行。












表 3.1 澳門公車 GPS 軌跡資料範例

GPS 時間	公車路線號碼	站牌順序	經度	緯度
2016/05/01 08:33:10 PM	R1A	1	22.2152	113.5490
2016/05/01 08:33:20 PM	R1A	1	22.2150	113.5492
2016/05/01 08:33:30 PM	R1A	2	22.2145	113.5497

表 3.2 各公車編號之單軌跡圖

軌跡圖					
代號	R1	R1A(back)	R1A(go)	R2	R2A(back)
軌跡圖					
代號	R2A(go)	R3	R3A	R3X	R4
軌跡圖					
代號	R5	R5AX	R5X	R6A	R6B
軌跡圖					
代號	R7(back)	R7(go)	R7A(back)	R7A(go)	R8(back)
軌跡圖					
代號	R8(go)	R8A	R9	R9A	R10
軌跡圖					
代	R10A(back)	R10A(go)	R10B	R10X	R11

號					
---	--	--	--	--	--

軌跡圖					
代號	R12(back)	R12(go)	R15(back)	R15(go)	R16
軌跡圖					
代號	R17	R18(back)	R18(go)	R18A	R18B(back)
軌跡圖					
代號	R18B(go)	R19	R21(Back)	R21(go)	R22
軌跡圖					
代號	R23	R25(back)	R25(go)	R25AX	R25X

3.2 澳門公車站牌資料之介紹

本研究所使用之澳門公車站牌資料其欄位名稱包括所屬公司名稱、公車路線號碼、公車站牌名稱、站牌所在經度、站牌所在緯度、各站間距離，共 6 種資料，而站牌資料為本研究做為上述 GPS 軌跡分段的依據，其範例如表 3.3 所示。

表 3.3 澳門公車站牌資料

公司名稱	公車路線 號碼	公司站牌 名稱	經度	緯度	距離
新時代	3	外港碼頭	22.19809	113.55957	0
新時代	3	友誼馬路	22.19492	113.55482	985
新時代	3	旅遊 活動中心	22.19464	113.55302	488
新時代	3	外港碼頭	22.19809	113.55957	966



第四章 研究方法

4.1 研究架構

本章節將介紹本研究所提出之三種方法，而這三種方法的流程圖如下圖 4.1 所示，三種方法一開始都會透過軌跡資料與站牌資料產生 GPS 軌跡圖，接著再用不同的方法進行軌跡分析，一般的方法是直覺的方法採用一般的卷積類神經網路進行軌跡辨識。而分群的方法則是先取得邊緣檢測之 *HOG* 特徵，再使用分群演算法將這些特徵進行分群，最後每一群資料會使用一個卷積類神經網路進行辨識任務。在金字塔方法則是先 GPS 軌跡圖切割成多個區塊，再丟入本研究所設計的金字塔卷積類神經網路。值得注意的是，為了提高模型的績效，本研究在每次運行模型之後會先檢查是否有到達閾值，若有則輸出模型，若沒有則會重新對圖片進行切割，最後我們會比較三種方法，並且選擇準確度最高之模型作為本研究軌跡辨識之最終模型。




圖 4.1 研究流程圖

4.2 產生 GPS 軌跡圖

本節會介紹(1)如何產生 GPS 軌跡圖(2)為何產生單軌跡以及多軌跡。首先，在產生 GPS 軌跡圖的時候是直接將澳門公車公司給我們的 GPS 軌跡訊號以實心圓的方式直接點在地圖上面，並且將每個點串聯起來成為 GPS 軌跡圖，但是在生成 GPS 軌跡圖的時候會遇到兩種不合理的情況，包含(1)GPS 傳感器沒有回傳資料造成缺值，我們會利用站牌資料與處理過後的軌跡資料來填補缺失值，先將每段透過 Haversine 公式計算 GPS 軌跡之球面距離，其計算的方式為假設 A 點的 GPS 座標為 (x_1, y_1) ，B 點的 GPS 座標為 (x_2, y_2) ，如圖 4.2 所示，將兩個 GPS 座標帶入公式 4.1 計算出的距離通稱為 d ，即為球面距離，其中 r 為地球之半徑 6371 公里，經由上述 Haversine 公式計算出的球面距離，再帶入速度之計算公式 4.2， T 為時間每 10 秒收集一筆為單位($T=10$)， V 為平均速度， S 為距離，最後再依照每段所計算出的速度算出缺失值點位位置。(2)GPS 軌跡飄移，若 GPS 軌跡飄移的程度較小，則依然會將該筆資料視為 GPS 軌跡訊號，若 GPS 軌跡飄移超出整張地圖外面，則會將此資料視為雜訊刪除，由於這種情況一年只有發生 10 幾次，因此我們利用手動的方式刪除飄移點進行校正，最後畫出來的 GPS 軌跡圖如表 4.1 所示。





$$d = 2r \sqrt{\sin^2\left(\frac{x_2 - x_1}{2}\right) + \cos(x_1)\cos(x_2)\sin^2\left(\frac{y_2 - y_1}{2}\right)} \quad (4.1)$$

$$V = \frac{S}{T} \quad (4.2)$$



圖 4.2 球面距離計算範例

表 4.1 GPS 軌跡資料比對示意圖

		GPS 軌跡資料
R1 正確軌跡	R1 GPS 軌跡資料	
		雜訊
R1 正確軌跡	R1 GPS 軌跡資料	

在模型輸入和輸出方面可以分為單軌跡以及多軌跡，產生這兩種軌跡圖的原因是因為我們將路線的去程跟回程視為兩種不同的路線，如果司機在來回開完一輪之後有休息，則去程跟回程則各自獨立形成單軌跡，但若司機礙於時間的關係無法休息，只能開著車等就會造成去程跟回程的路線連在一起形成多軌跡，因此我們必須同時考慮單軌跡以及多軌跡的情況，在單軌跡的部分，本研究將上述處理過後軌跡數據分別按照每條公車軌跡繪製成軌跡圖作為單軌跡模型之輸入，再將每條公車路線按照順序標記為 0,1,2,3,4...等以此類推，GPS 軌跡圖經由模型訓練完之後則會輸出該軌跡是屬於類別幾的軌跡路線並將其轉換為相應的公車代號。在多軌跡的部分，本研究會隨機挑選起迄點相同的兩條軌跡將其繪製在同一張圖上作為多軌跡模型之輸入，接著，本研究採用二進位制標記，即當該軌跡圖上有屬於該公車之軌跡則標記為 1，若無則標記為 0，而在模型訓練完之後就會輸出由 0 和 1 所組成之陣列，再將輸出結果為 1 的轉換為原本的公車代號，單軌跡以及多軌跡之模型輸出和輸入如圖 4.3 所示，每張輸入的 GPS 軌跡圖之長和寬皆




圖 4.3 多軌跡之輸入示意圖

且軌跡線條寬度為 4cm 繪製在 100*100 的網格地圖上。

4.3 方法一:一般卷積類神經網路

在完成 GPS 軌跡圖的產生以後，我們接著在一般的方法中使用卷積類神經網路進行訓練，而這個方法是將產生的一堆 GPS 軌跡圖丟入到卷積層裡面，下面將會分別介紹卷積類神經網路之架構，包含卷積層、池化層以及全連接層。

卷積層為了取得軌跡圖之重要的空間特徵，本研究透過這一層的原理利用一個指定尺寸的窗格(kernel)，由上而下、由左而右取得軌跡圖像各個局部的特徵作為下一層輸入，舉個例子來說，假設我們有一張 GPS 軌跡圖將其轉換為像素圖(如圖 4.4 之最左邊的圖所示)且使用 3*3 的窗格取得圖片特徵，接著在每個相對位置上將兩個矩陣相乘並加總相乘結果，直到整張圖都完成，如圖 4.4 中，灰色框框的值為 $255*0+255*0+255*0+255*1+0*0+0*0+0*0+0*0+255*1=510$ ，以此類推，最後產生如圖 4.4 最右邊的圖。




圖 4.4 卷積層運算示意圖




圖 4.5 池化層計算方式示意圖

池化層主要的目標是在將輸入軌跡圖片的尺寸縮小並保留重要特徵，其好處有減少輸入資料的維度相對的計算成本和時間以及模型參數也相對降低，還有具有抗干擾的作用，當圖片的某部分像素有微小偏差的時候，對於這層的輸出結果影響不大，和卷積層相似池化層也同樣會使用 *kernel* 來取出各區域的值進行計算，由於本研究採用最大池化法，因此只針對其作法進行說明，如下圖 4.5 所示，假設有一個 2x2 的 *kernel*，灰色方框內的最大值為 510 所以其輸出即為 510，以此類推。

全連接層指的就是一般的類神經網路，經由卷積層和池化層之後，接著須將軌跡圖辨識出屬於哪一條軌跡路線就需要透過全連接層之功用，也就是將軌跡圖的空間特徵資訊丟到全連接層進行最後的分類，由於全連接層的每顆神經元和上

一層各個神經元連接在一起且每個連接都有獨立以及不相等的權重值，造成在進行全連接層的運算時消耗較多資源，舉個例子來說明，假設經過卷積層和池化層的輸出圖像尺寸為 50*50，到全連接層的時候將會有 50*50*50*50 個帶有不同權重的連接，經由這些權重計算後輸出結果。

4.4 方法二:分群

第二種方法的流程圖(如圖 4.6 所示)以下我們將依序分別介紹:




圖 4.6 分群方法之流程圖

輸入的部分和 4.2 章節相同這邊就不在多作說明，接著本研究採用方向梯度直方圖特徵檢測演算法(Histogram of Oriented Gradients, HOG)，其概念為當圖像某個像素和鄰近的像素值(Gradient)差異很大則會被標記為邊緣且凸顯出來，如圖 4.7 所示。

為了達成這個目的其主要有 5 個步驟，分別為顏色空間正規化、梯度計算、梯度方向直方圖、重疊塊直方圖正規化以及最後 HOG 特徵，以下將對這幾個步驟分別介紹:

顏色空間正規化這個步驟主要對影像進行正規化的處理，分成兩個部分處理，分別為影像灰階化以及 Gamma 校正，第一個步驟是將彩色的輸入資料轉成灰階影像，其公式如下 4.2 所示:

$$\text{Gray} = 0.3 \times R + 0.59 \times G + 0.11 \times B \quad (4.2)$$

接著，第二個步驟則是進行校正，透過進行 Gamma 校正，將輸入的影像資料整體的亮度提升或是降低，其公式如下 4.3 所示:

$$Y(x, y) = I(x, y)^\gamma \quad (4.3)$$




圖 4.7 HOG 特徵圖示意圖

梯度計算經由上個步驟將資料進行顏色和空間的正規化之後，則須分別求取從水平方向和垂直方向進行梯度以及方向的計算，水平的方向以 $[-1 \ 0 \ 1]$ 表示，垂直的方向以 $[-1 \ 0 \ 1]^T$ 表示，其公式如下 4.4 所示：

$$\begin{aligned}
 G_x(x, y) &= I(x + 1, y) - I(x - 1, y) \\
 G_y(x, y) &= I(x, y + 1) - I(x, y - 1) \\
 G(x, y) &= \sqrt{G_x(x, y)^2 + G_y(x, y)^2} \\
 \theta(x, y) &= \arctan\left(\frac{G_y(x, y)}{G_x(x, y)}\right)
 \end{aligned} \tag{4.4}$$

梯度方向直方圖這個步驟會將軌跡圖像資料分割成數個單元(cell)且相鄰近的單元之間不互相重疊，再各個單元統計梯度方向直方圖，並且將所有的梯度方向分成 9 維的特徵向量，作為圖的橫軸，而縱軸的部分則為所對應到的梯度值累加。

重疊梯度方向圖正規化軌跡圖像變化多端容易造成梯度值的變化範圍較廣，因此為了提高模型的績效需先將特徵進行正規化，其方法為將每一個單元放在一個區塊中(block)，再分別將每個區塊進行正規化，舉個例子來說，假設有一張軌跡圖尺寸為(500,500)，將其劃分成多個(4,4)的單元，因此分割之後可以得到(500/4,500/4)個單元且無重疊，接著將(2,2)個單元作為一個區塊，相鄰的區塊則是有重疊的可以藉由鄰近的像素資訊來提高準確率，最後對每個區塊進行正規化輸出的結果即為 HOG 特徵。

在提取完軌跡圖之特徵後，本研究將提取結果丟到所選的分群演算法之中，為了分出更好的結果，本研究採用 *Calinski-Harabaz Index* 作為分群指標，相較於輪廓系數運算速度相對較快，藉由計算資料和每個類別的中心點距離平方合來計算，其公式如下 4.5

$$S(k) = \frac{\text{tr}(B_k)}{\text{tr}(W_k)} \frac{m - k}{k - 1} \quad (4.5)$$

其中 B_k 是指各類別之間的協方差矩陣， W_k 為類別之間內部的協方差矩陣， m 為輸入的資料樣本數， k 為類別數，當 *Calinski-Harabaz Index* 的分數值越大，則代表聚類的效果越好，相反，當值越小的時候則代表資料相似分群不顯著，在分群的部分，假設我們根據上述指標將 GPS 軌跡圖分成 k 群($C_1, C_2, C_3, \dots, C_k$)，其目標維追求每一群最小化平方誤差 E ，其公式如 4.6 所示，其中 μ_i 為質心，表達公式如 4.7 所示，接著分別計算每一個輸入之 GPS 軌跡圖到各質心之距離，選擇距離最小的作為該 GPS 軌跡圖之族群，以此類推，最終輸出分群結果之後，再按照軌跡圖分群分數最好的群數分別對每一群建一個卷積類神經模型並進行分類，由於此卷積類神經模型的計算和前一個方法相同，這邊就不在贅述。

$$E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2 \quad (4.6)$$

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x \quad (4.7)$$

4.5 方法三:金字塔卷積類神經網路

第三種方法的流程圖(如圖 4.8 所示)以下我們將按照每個步驟分別介紹:




圖 4.8 金字塔方法之流程圖

軌跡特徵圖堆疊這個步驟我們利用一種最新的技術 *Grad-CAM*，其目標為可視化卷積類神經網路，使卷積類神經網路更加透明。我們將 GPS 軌跡圖輸入至卷積類神經網路之後，利用反向傳播的方式將卷積類神經網路的最後一層卷積層所產生之 GPS 軌跡圖之重要區域乘上全連接層中相對應的權重，並且產生帶有權重的 GPS 軌跡圖，公式如 4.8 所示，接著為了避免有些像素值大於 255 因此透過激活函數 *relu* 將 GPS 軌跡特徵圖進行正規化，最終產生出 GPS 軌跡圖之熱力圖，公式如 4.9 所示，而我們將所有軌跡之 GPS 軌跡圖之熱力圖堆疊在一起，並找出卷積類神經網路辨識這些軌跡最重要的地方。

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \quad (4.8)$$

$$L_{Grad-CAM}^c = ReLU\left(\sum_k \alpha_k^c A^k\right) \quad (4.9)$$

計算 rgb 平均值這個步驟將 GPS 軌跡圖轉換成 GPS 軌跡圖之熱力圖之後，紅色的部分為卷積類神經網路判斷為重要的地方，藍色則為類神經判斷為不重要的地方，為了找出 GPS 軌跡圖之重要的特徵，我們分別計算每個切割區塊之 rgb 平

均值。

確認切割方向此步驟為在計算完每個區塊之 rgb 平均值之後，由於要讓卷積類神經網路能夠根據最大化差異辨識，因此我們找出每個切割方法區塊間平均值差異最大的作為切割的方向，之後針對每一個切割區塊建立一個卷積類神經網路，在 4.3 章節時已介紹過卷積類神經網路的運作以及架構，這邊就不在多贅述。

是否有到達閾值這個步驟是將 GPS 軌跡圖切割得越多有可能會造成過度學習的情況發生，然而切割的過少也有可能因為卷積類神經模型無法學習到重要的 GPS 軌跡圖特徵造成模型績效下降，為了找出適當的切割次數，我們在每次模型執行完之後設立一個閾值，若此次模型績效較上次切割時模型績效好，則繼續切割，若此次模型績效較上一次切割時模型績效差，則停止切割。

Conv1D 此步驟的目標為串聯 GPS 軌跡圖各個區塊的模型輸出且產生最終的結果，我們將其堆疊在一起並且丟入到一維之卷積類神經網路模型中，讓模型能夠綜合，每個區塊之輸出得到的每條公車編號概率，輸出最終該張圖所擁有的軌跡編號。

第五章 實驗模擬

本章節採用真實的澳門公車軌跡資料來驗證本研究所提出之方法的可行性以及執行效率，此章的內容總共分成 2 大部分，每個部分在分成 4 個小部分，包含單軌軌跡之方法一結果分析、單軌軌跡之方法二結果分析、單軌軌跡之方法三結果分析、單軌軌跡之總結，多軌軌跡之方法一結果分析、多軌軌跡之方法二結果分析、多軌軌跡之方法三結果分析以及多軌軌跡之總結，由於硬體上的限制，本研究目前只採用澳門公車路線前 50 條作為驗證資料，如圖 5.1 所示，大部分的路線集中在澳門上半島，只有少部分會橫跨上下半島，所以可以討論我們的方法是否能對集中的路線進行辨識做討論，每條軌跡繪製成 500 張長寬為 500*500 之軌跡圖作為輸入資料，所有的軌跡圖皆採用灰階方式呈現，單軌跡之訓練集資料為 17,150 張，測試集資料為 7,350 張，多軌跡之訓練集資料為 29,733 張，測試集資料為 7,634 張，本研究之實驗皆是以程式語言 Python 完成，並且操作在 Intel Core I7-9700K at 3.60GHz 的 CPU、Nvidia GeForce RTX 2080ti 的 GPU、搭配 64GB 記憶體以及 Windows 10 的作業軟體來完成。




圖 5.1 50 條公車路線圖

5.1 單軌軌跡之方法一結果分析

本小節主要針對第一種方法之結果分析，包含單一卷積類神經之參數選擇以及模型績效探討，在模型架構的部分，主要使用三層卷積層、三層池化層以及一層隱藏層，其模型結果如圖 5.2 所示。





圖 5.2 單軌跡之模型準確率


從圖中可以看出在迭代次數為 1 的時候開始收斂，其最後模型準確率為 90.19%，本研究將其各軌跡之辨識績效列於表 5.4，從表中可以發現第 10 條、第 13 條軌跡以及第 22 條軌跡績效較差，本研究分別針對這幾條路線進行探討針對第 10 條(R5)的部分，個別之辨識結果如下表 5.1 所示，其模型易將第 10 條軌跡分辨為第 24 條軌跡(R10)，本研究將兩條軌跡路線分別進行比對，雖然這兩條公車之站點位置相較於前者重複度較低，但因為其所根據經緯度所繪製出來之軌跡圖形相似程度高，因而間接造成模型誤判。

表 5.1 第 10 條路線之個別辨識結果

實際值	10	10	10	10	10
預測值	10	24	24	10	24



R5




R10

圖 5.3 第 10 條路線之個別辨識結果


針對第 13 條軌跡(R6A)的部分，個別之辨識結果如下表 5.2 所示，可以從中看出模型易將此條軌跡路線分辨為第 3 條軌跡(R2)，經由觀察資料之後發現其站點位置相似度高只有少數幾站不同且出發點一致，但其所繪製之軌跡型相似度較低，因此在軌跡分辨之準確率又相較於第 10 條軌跡高。

表 5.2 第 13 條路線之個別辨識結果

實際值	13	13	13	13	13
預測值	13	13	13	10	10



R6A



R2

圖 5.4 第 13 條路線之個別辨識結果

針對第 22 條軌跡(R9)的部分，個別之辨識結果如下表 5.3 所示，可以從中看出模型易將此條軌跡路線分辨為第 23 條軌跡(R9A)，從兩者軌跡圖以及站點位置來看，其站點位置重複度高且擁有相同的出發點，在軌跡圖形的部分相較於第 13 條軌跡相似程度又較高，導致模型在此軌跡之辨識準確率較低。

表 5.3 第 22 條軌跡路線之個別辨識結果

實際值	22	22	22	22	22
預測值	22	23	22	23	23




圖 5.5 第 22 條軌跡路線之個別辨識結果

綜合上述結果單一卷積類神經模型在軌跡站點相似度高或軌跡圖形相似度高的時候較不好分辨且容易造成誤判的情況發生，因而導致模型績效不好準確率下降，然而在其他軌跡之辨識的部分單一卷積類神經模型則表現良好。

表 5.4 各軌之分辨率

軌跡編號	0	1	2	3	4	5	6	7	8	9
準確率	0.89	1	0.99	0.72	1	1	1	0.97	1	1
軌跡編號	10	11	12	13	14	15	16	17	18	19

準確率	0.56	1	1	0.62	1	1	1	1	1	1
軌跡編號	20	21	22	23	24	25	26	27	28	29
準確率	1	0.99	0.43	0.72	0.78	1	1	0.99	1	1
軌跡編號	30	31	32	33	34	35	36	37	38	39
準確率	1	0.99	1	1	0.85	0.96	1	1	0.96	1
軌跡編號	40	41	42	43	44	45	46	47	48	49
準確率	1	0.73	1	0.98	0.96	1	1	1	1	0.92

5.2 單軌軌跡之方法二結果分析

在第二個方法的中，本研究在透過梯度直方圖特徵檢測演算法採集每條路線軌跡圖之後特徵之後，再丟入不同分群數量的 Kmeans 聚類方法中按照相似度進行分群，並以 *Calinski-Harabaz Index* 計算分群分數，其各群數之分數以及輪廓系數如表 5.5 和表 5.6 所示，從表中可以發現雖然在計算 *Calinski-Harabaz Index* 分數時分群數量為 10 的時候分群效果最好，但計算輪廓系數時分群數量為 9 時效果較佳且將其畫成散點圖來看，如圖 5.6 所示，分群數量為 9 時各群之間已有明顯的分界線，因此本研究最終將 50 條軌跡分成 9 群，並取用前三群丟入一般卷積類神經模型，以下將針對三群分別進行探討。

表 5.5 各分群數量之分數

群數	2	3	4	5	6	7	8	9	10
分數	66.3	62.7	90.8	103.4	124.4	188.4	235.1	275.1	300.3

表 5.6 各分群之輪廓系數

群數	2	3	4	5	6	7	8	9	10
分數	0.64	0.49	0.53	0.55	0.59	0.6	0.61	0.59	0.57




圖 5.6 分群數量為 9 之散點圖

在第一群的部分，其共同的特點為其軌跡皆位於澳門之上半島且都會行經花地瑪堂區以及媽閣，例如，R1、R2、R5AX 等軌跡路線，本研究將其丟入一般卷積類神經網路模型，其結果如下圖 5.7 所示，從圖中可以發現其軌跡辨識績效都有明顯的效果，但第 1 個種類和第 9 個種類時效果較差分別為 R2 和 R18B，原因為這兩條軌跡路線其軌跡圖形相似度較高且辨識錯誤的幾張照片皆有發生訊號飄移的狀況進而造成雜訊而誤判。




圖 5.7 第一群模型績效

在第二群的部分其共通的特色為一樣皆在上半島偏下方且行經永寧廣場，該群總軌跡數共 12 條，本研究將其模型辨識結果呈現在下方如圖 5.8 所示，而在這一群中各軌跡之辨識績效相當顯著，只有在第 9 種軌跡(R17)時有些微辨識錯誤，然而其原因為部分軌跡圖有因為改路或換到進而造成模型難以識別的情況發生，如圖 5.9 所示。




圖 5.8 第二群模型績效




圖 5.9 R17 之路線比較圖

在第三群的部分其特點為皆行經外港碼頭和媽閣，而此群總軌跡數為 4 條，模型之辨識結果如圖 5.10 所示，其四條之辨識效果皆為顯著，其中第 1 種類(R10A BACK)和第 2 種類(R10A GO)之分群效果有些微誤差的情況，由於其兩條軌跡一條為去程一條為回程，因此在辨識上較困難。




圖 5.10 第三群模型績效

表 5.7 單軌跡之分群總結果

群數	總題數	答錯題數	準確率
第一群	7350	306	95.83%
第二群	7350	15	99.78
第三群	7350	110	98.50
總計	14700	431	97.0%

綜合上述結果可以得知，依照相似度進行分群的方式，將相似度高的歸類為一群其模型更能學習到更重要空間特徵，而且在分群建模的情況下，每一群所訓練模型皆有良好的績效，其最後結果如表 5.7 所示。

5.3 單軌軌跡之方法三結果分析

在方法三的部分首先利用訓練完之單一卷積類神經模型取得每一條軌跡之重要特徵，並將其 50 條軌跡堆積，如圖 5.11 所示，紅色的部分為模型較注重的地方而藍色的部分為模型會忽略的部分，接著為了找出切割的方向，分別計算每個切法之紅色部分的平均再進行比較，如表 5.8 所示，此方法所使用之模型架構皆由三層卷積層、三層池化層以及兩層全連接層所組成。




圖 5.11 第一階段切割圖

表 5.8 第一階段之紅色部分分數計算

上	167.94	左	178.45
下	210.39	右	199.99
差異	42.45	差異	21.43

將圖片分割成上下部分差異最大，因此在第一步驟切割的時候先採用橫向切割，再分別對上下兩部分進行建模，其結果如下圖 5.12 所示，從圖中可以發現在第一步分割圖片時其二維卷積模型即有不錯的模型跡效，而將其二維結果經由一維卷積模型訓練之後最終第一階段切割之準確率為 87.1%。




圖 5.12 第一階段之切割結果

接著在進行第二階段的部分，由於上半部之軌跡較密集，因此針對上半部的部分在進行切割，同樣分別計算切割區塊之紅色平均像素值之差異，如圖 5.13 以及表 5.9 所示：




圖 5.13 第二階切割圖

表 5.9 第二階段之紅色部分分數計算

左上	74.47	上上	84.82
右上	93.47	下上	83.12
差異	19	差異	1.7

從上表得知將圖片左右對半切之差異較大，因此在第二次切割的時候一樣選擇將圖片切成左右兩邊，再分成三個部分分別建構二為卷積類神經模型，之後一樣將結果丟入到一維卷積類神經模型進行分類，其最終結果如下圖 5.14 所示，從圖中可以發現這階段的整體模型績效已經超越一般卷積類神經模型。




圖 5.14 第二階段之切割結果

由於繼續切割下去其模型績效有下降的趨勢，因此在第三階段則停止切割，綜合上述結果可以得知本研究所提出之方法在每一次切割的時候都能夠學習到每一個圖片區塊之更重要的空間特徵且在一定數量的圖片區塊都能獲得良好的績效。

5.4 單軌軌跡之總結結果分析

將三種方法進行比較首先針對第一種方法，因為單一卷積類神經模型必須大範圍的觀察整張軌跡圖且當遇到軌跡圖形狀較相似的時候，模型較不容易獲取到較細微之特徵間接造成模型判斷錯誤，再來，第二種方法由於已經先經過聚類階段，將相似的軌跡匯集在一起分別進行建模，在這樣的作法下，每一群的模型所需要分類的目標物相對較少且能觀察到的特徵相對較細緻，因此在單軌跡分類的部分績效最佳，最後，本研究所提出之金字塔卷積類神經，雖然績效相較於第二種方法些微低下，但是由於本研究提出之方法是一次直接將 50 條軌跡進行分類且在模型架構上每一個區塊皆為平行處理，相對地所需要的運算時間也較少，在單軌跡分類這方面也有不錯的績效，其各方法比較如表 5.10 所示。

表 5.10 單軌跡方法二綜合比較表

方法	方法一	方法二	方法三
準確率	83.1%	97.0%	88.1%

5.5 多軌軌跡之方法一結果分析

第一種方法使用單一卷積類神經網路進行多軌跡辨識所使用之模型架構，包含三層卷積層、三層池化層以及兩層全連接層，然而從結果來看在多條軌跡辨識之下反而無法擁有良好的績效，將其個別之辨識績效呈現於下表 5.11，從表中可以得知，在單一軌跡辨識下辨識率都有在一定的水準，但在多軌跡識別之辨識率卻相當低，那是因為大部分屬於辨識率較低甚至無法分辨的多軌跡之軌跡圖片是




圖 5.15 多軌跡之示意圖

表 5.11 多軌跡識別之個別類別辨識率

軌跡編號	0	1	2	3	4	5	6	7	8	9
準確率	0.0	0.0	0.0	0.0	0.63	1.0	0.99	0.0	0.14	0.97
軌跡編號	10	11	12	13	14	15	16	17	18	19
準確率	0.0	0.0	0.0	0.0	0.0	0.4	0.95	1.0	0.98	0.42
軌跡編號	20	21	22	23	24	25	26	27	28	29
準確率	0.04	0.0	0.98	0.99	0.62	0.96	1.0	1.0	0.91	1.0
軌跡編號	30	31	32	33	34	35	36	37	38	39
準確率	0.0	1.0	0.0	0.90	1.0	0.9	1.0	0.99	0.0	0.63
軌跡編號	40	41	42	43	44	45	46	47	48	49
準確率	1.0	1.0	0.63	0.27	0.75	0.96	0.0	1.0	1.0	1.0

採用將起迄點一樣的路線隨機挑選合併在一起，因此軌跡多數有重疊的部分，如圖 5.15 所示，在第一種方法中模型需從整張圖片獲取重要之空間特徵可能會忽略掉較細微的部分，因而造成在多軌跡識別任務中無法順利辨識。

5.6 多軌軌跡之方法二結果分析

在第二種方法之多軌跡識別的部分，首先一樣先計算每一種類別的分群分數以及輪廓系數，如下表 5.12 和表 5.13 所示，從表中可以得知，*Calinski-Harabaz Index* 所計算出來的分數在群數為 8 時最高，在計算輪廓系數時群數為 2 時分數較好，但本研究將群數群數 8 和群數 2 分別繪製成散點圖，如圖 5.16 所示，從圖中可以發現，在群數為 2 時會有單獨一種類別為一群無法進行分類，因此本研究採用群數為 8 作為最後分群總數，並取前 2 群時分別進行建模且分別分析其績效。

表 5.12 方法二之各群分群分數

群數	2	3	4	5	6	7	8	9	10
分數	88	246	440	583	710	782	905	879	867

表 5.13 方法二之各群輪廓系數

群數	2	3	4	5	6	7	8	9	10
分數	0.87	0.64	0.66	0.55	0.55	0.49	0.67	0.50	0.50




圖 5.16 分群數 2 v.s 分群數 8 之散點圖

在第一群的部分，主要共同特色為皆有一條或是兩條之軌跡橫跨上下半島，如圖 5.17 所示，其丟入單一卷積類神經模型之結果如下圖 5.18 所示，從圖中可以發現，其多軌跡之識別任務上績效較單軌跡識別低，但是在績效辨識還是有維持在 80%以上。




圖 5.17 多軌跡之分群第一群示意圖




圖 5.18 多軌跡分群之第 1 群模型結果

在第二群的部分其共通的特色為大部分軌跡都位於上半島，經由單一卷積類神經模型辨識之後，其結果如下圖 5.19 所示，從圖中可以發現，在第二群辨識的效果比第一群準確率來的較低，那是因為其在第二群中所需分類的類別較多，軌跡重疊的狀況也多，所以績效相對較差。




圖 5.19 多軌跡分群之第 2 群模型結果

綜合上述可以得知，第二種方法運用在多軌跡之辨識上其效果雖然沒有比單軌跡辨識來的好，但準確率還是有維持 80%以上，然而藉由分群之後減少了每群模型所需要辨識的類別數量，因此相較於第一種方法其模型績效較好，綜合結果比較表如表 5.14 所示。

表 5.14 多軌跡方法二之綜合比較表

群數	總題數	答錯答題數	準確率
第一群	7634	1376	81.96
第二群	7634	1987	73.97%
總計	15268	3363	77.97%

5.7 多軌跡之方法三結果分析

在第三種方法之多軌跡識別部分，本研究一樣按照單一卷積類神經所產生之每個類別多軌跡之特徵軌跡圖，並將其疊加在一起且分別計算每個區塊紅色部分加總平均來決定切割方向，第一階段切割結果如下圖 5.20 和表 5.15 所示，因此第一階段切割即為上下切割，其結果如下圖 5.21 所示，從圖中可以看到，本研究所提出之方法在第一階段切割時即有良好的績效且相較於前兩者之方法效果最佳。




圖 5.20 多軌跡第一階段切割

表 5.15 多軌跡第一階段切割結果

上	201.46	左	211.15
下	234.15	右	224.45
差異	32.69	差異	13.3




圖 5.21 多軌跡之第一階段切割結果

接著進行第二階段的切割，由於上半部分是屬於軌跡較密集的地方，因此接續第一階段切割結果著重針對上半部繼續切割，其結果如下圖 5.22 和表 5.16 所示，根據結果第二階段一樣採取左右對半切割，其結果如圖 5.23 所示，從圖中可以得知再進行第二階段切割的時候，模型績效有些微上升，然而由於上升幅度不大，因此本研究就不進行在更進一步切割。




圖 5.22 第二階段多軌跡切割

表 5.16 第二階段切割結果

左上	95.51	上上	103.16
右上	105.94	下上	98.3
差異	10.43	差異	4.86




圖 5.23 第二階段切割結果

5.8 多軌軌跡之總結

在多軌跡識別任務中，第一種方法之模型由於是整張圖片作為輸入且多軌跡圖片大部分軌跡皆有重疊的情況，因此在識別上較不易取得較細微之特徵，整體而言為三種方法之最差，第二種方法之模型在分群的時候，先將有橫跨上下澳門半島的為一群，另一群則聚集在上半島，其兩群之績效相較於單軌跡之識別任務較低，但因為縮小分群的種類，因此績效又比第一種方法來的好，在第三種本研究所提出之金字塔卷積類神經模型，經由切割之後，讓每一個區塊的模型都能學習到該區塊之重要空間特徵，再透過一維卷積類神經模型綜合各個區塊的特徵進行最終的分類，其在第一階段切割即超越前兩種方法之準確，到第二階段切割時，雖然準確率只有些微上升，但本研究所提出之方法之績效仍然為三種最佳。

表 5.17 各方法之結果比較

方法	方法一	方法二	方法三
準確率	69.1%	77.97%	90.0%

第六章 結論與未來研究

針對本研究所使用之澳門公車軌跡資料，其由於資料品質本身就不好，參雜過多的雜訊以及各軌跡相似度高造成一般卷積類神經模型難以辨識，本研究使用三種方法(一般卷積類神經網路、分群、金字塔卷積類神經網路)進行比較且設計了一系列實驗來做為實驗模擬，在實驗結果中可以分成兩個部分進行講解。

在單軌跡辨識任務中，本研究所提出之方法其效能較優於其他兩種方法，雖然在第二種方法中準確率表現比較好，但是由於其為分別針對每群進行建模所需分類之類別數較少且所花時間較長，然而本研究所提出之方法採用一次全部類別進行分類且在進行切割之後所需模型參數量較少計算速度相對較快，從此可以得出，本研究所提出之方法有效性和效能方面更勝於其他兩者。

在多軌跡辨識任務中，由於軌跡相似度高部分軌跡會有重疊的現象發生，間接造成第一種方法無法順利的學習到重要特徵，其績效為三種方法最差，在第二種方法因為先進行分群的動作，大幅的縮小每個模型所需分類的類別數且也較能觀察到細微的特徵，在本研究所提出之方法在第一次切割的時候，其模型績效已經超越另外兩種方法，也就代表能學習到更多重要的空間特徵，雖然在第二次切割時只有小幅的成長，但已足以驗證本研究所提出之方法的可行性。

最後，在未來研究中可以再利用不同種類的運具軌跡進行相同實驗的辨識或是將其運用在不同領域之中，進一步透過軌跡分析發現和解決現存的問題，此技術不僅可以用在運具軌跡之中，也可以使用在人流的活動，相信都能獲得不錯的成效。

參考文獻

- [1]. Zhao, H., Qian, D., Lv, Y., Zhang, B., & Liang, R. (2020). Development of a global positioning system data-based trip-purpose inference method for hazardous materials transportation management. *Journal of Intelligent Transportation Systems*, 24(1), 24-39.
- [2]. Yu, J., Stettler, M. E., Angeloudis, P., Hu, S., & Chen, X. M. (2020). Urban network-wide traffic speed estimation with massive ride-sourcing GPS traces. *Transportation Research Part C: Emerging Technologies*, 112, 136-152.
- [3]. Kohan, M., & Ale, J. M. (2020). Discovering traffic congestion through traffic flow patterns generated by moving object trajectories. *Computers, Environment and Urban Systems*, 80, 101426.
- [4]. Verma, K. K., Singh, B. M., Mandoria, H. L., & Chauhan, P. (2020). Two-Stage Human Activity Recognition Using 2D-ConvNet. *International Journal of Interactive Multimedia & Artificial Intelligence*, 6(2).
- [5]. Tang, K., Cao, Y., Chen, C., Yao, J., Tan, C., & Sun, J. (2020). Dynamic origin-destination flow estimation using automatic vehicle identification data: A 3D convolutional neural network approach. *Computer-Aided Civil and Infrastructure Engineering*.
- [6]. Han, X., Jiang, T., Zhao, Z., & Lei, Z. (2020). Research on remote sensing image target recognition based on deep convolution neural network. *International Journal of Pattern Recognition and Artificial Intelligence*, 34(05), 2054015.
- [7]. Zhu, Z., Li, D., Hu, Y., Li, J., Liu, D., & Li, J. (2020). Indoor scene segmentation algorithm based on full convolutional neural network. *NEURAL COMPUTING & APPLICATIONS*.

- [8]. Jin, C. H., Chen, D. K., Zhu, F. W., & Wu, M. H. (2019). Detecting Suspects by Large-Scale Trajectory Patterns in the City. *Mobile Information Systems*, 2019.
- [9]. Xiao, Guangnian; JUAN, Zhicai; Zhang, Chunqin. Travel mode detection based on GPS track data and Bayesian networks. *Computers, Environment and Urban Systems*, 2015, 54: 14-22.
- [10]. Yuan, J., Yu, C., Wang, L., & Ma, W. (2019). Driver Back-Tracing Based on Automated Vehicle Identification Data. *Transportation Research Record: Journal of the Transportation Research Board*, 2673(6), 84-93.
- [11]. Wei, Yanning; LI, Keping; Tang, Keshuang. Trajectory-based identification of critical instantaneous decision events at mixed-flow signalized intersections. *Accident Analysis & Prevention*, 2019, 123: 324-335.
- [12]. Zhang, R., Xie, P., Wang, C., Liu, G., & Wan, S. (2019). Classifying transportation mode and speed from trajectory data via deep multi-scale learning. *Computer Networks*, 162, 106861..
- [13]. McLaughlin, Niall; Martinez Del Rincon, Jesus; Miller, Paul. Recurrent convolutional network for video-based person re-identification. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016. p. 1325-1334.
- [14]. LI, Xin, Deep trajectory: a deep learning approach for mobile advertising in vehicular networks. *Neural Computing and Applications*, 2019, 31.7: 2813-2825.
- [15]. Zheng, Han; CUI, Zanyang; Zhang, Xingchen. Identifying modes of driving railway trains from gps trajectory data: An ensemble classifier-based approach. *ISPRS International Journal of Geo-Information*, 2018, 7.8: 308.
- [16]. Arif, S., Wang, J., Hussain, F., & Fei, Z. (2019). Trajectory-Based 3D Convolutional Descriptors for Human Action Recognition. *Journal of Information*

Science & Engineering, 35(4).

- [17]. Park, S. H., Kim, B., Kang, C. M., Chung, C. C., & Choi, J. W. (2018, June). Sequence-to-sequence prediction of vehicle trajectory via LSTM encoder-decoder architecture. In 2018 IEEE Intelligent Vehicles Symposium (IV) (pp. 1672-1678). IEEE.
- [18]. Priego-Torres, B. M., Sanchez-Morillo, D., Fernandez-Granero, M. A., & Garcia-Rojo, M. (2020). Automatic segmentation of whole-slide H&E stained breast histopathology images using a deep convolutional neural network architecture. *Expert Systems with Applications*, 113387.
- [19]. Yao, D., Liu, H., Yang, J., & Li, X. (2020). A Lightweight Neural Network with Strong Robustness for Bearing Fault Diagnosis. *Measurement*, 107756.
- [20]. Fuqua, D., & Razzaghi, T. (2020). A cost-sensitive convolution neural network learning for control chart pattern recognition. *Expert Systems with Applications*, 150, 113275.
- [21]. Khatami, A., Nazari, A., Khosravi, A., Lim, C. P., & Nahavandi, S. (2020). A weight perturbation-based regularisation technique for convolutional neural networks and the application in medical imaging. *Expert Systems with Applications*, 149, 113196.
- [22]. Kujawa, S., Mazurkiewicz, J., & Czekala, W. (2020). Using convolutional neural networks to classify the maturity of compost based on sewage sludge and rapeseed straw. *Journal of Cleaner Production*, 120814.
- [23]. Wang, M., & Deng, W. (2020). Deep face recognition with clustering based domain adaptation. *Neurocomputing*.
- [24]. Zhou, N., Du, J., Xue, Z., Liang, M., Yao, X., & Cui, W. (2019). Security topics related microblogs search based on deep convolutional neural

networks. *Neurocomputing*.

- [25]. Zhao, M., Zhong, S., Fu, X., Tang, B., & Pecht, M. (2019). Deep residual shrinkage networks for fault diagnosis. *IEEE Transactions on Industrial Informatics*, 16(7), 4681-4690.
- [26]. Chen, J., Chen, J., Zhang, D., Sun, Y., & Nanekaran, Y. A. (2020). Using deep transfer learning for image-based plant disease identification. *Computers and Electronics in Agriculture*, 173, 105393.
- [27]. Chen, K., & Huang, X. (2019). Feature extraction method of 3D art creation based on deep learning. *Soft Computing*, 1-13.
- [28]. Tang, Y., Gong, W., Chen, X., & Li, W. (2019). Deep Inception-Residual Laplacian Pyramid Networks for Accurate Single-Image Super-Resolution. *IEEE Transactions on Neural Networks and Learning Systems*, 31(5), 1514-1528.
- [29]. Chen, Y., Tao, J., Liu, L., Xiong, J., Xia, R., Xie, J., ... & Yang, K. (2020). Research of improving semantic image segmentation based on a feature fusion model. *JOURNAL OF AMBIENT INTELLIGENCE AND HUMANIZED COMPUTING*.
- [30]. Tuncer, T., & Dogan, S. (2020). Pyramid and multi kernel based local binary pattern for texture recognition. *Journal of Ambient Intelligence and Humanized Computing*, 11(3), 1241-1252.
- [31]. Wei, S., Ji, S., & Lu, M. (2019). Toward automatic building footprint delineation from aerial images using cnn and regularization. *IEEE Transactions on Geoscience and Remote Sensing*, 58(3), 2178-2189.
- [32]. Guo, F., Shi, C., Li, X., Wu, X., Zhou, J., & Lv, J. (2020). Image segmentation of nasopharyngeal carcinoma using 3D CNN with long-range skip connection and multi-scale feature pyramid. *Soft Computing*, 1-10.

- [33].Zhang, L., Wu, J., Wang, T., Borji, A., Wei, G., & Lu, H. (2020). A Multistage Refinement Network for Salient Object Detection. *IEEE Transactions on Image Processing*, 29, 3534-3545.
- [34].Fu, X., Li, K., Liu, J., Li, K., Zeng, Z., & Chen, C. (2020). A two-stage attention aware method for train bearing shed oil inspection based on convolutional neural networks. *Neurocomputing*, 380, 212-224.
- [35].LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324.

中文文獻

- [36].李泊樣 (2019)。基於公車 GPS 軌跡資料之公車駕駛行為分析 ——以澳門公車為例。國立雲林科技大學工業工程與管理系碩士論文，雲林縣。

