

國立雲林科技大學工業工程與管理系

工業工程組

碩士論文

MS in Industrial Engineering and Management
Department of Industrial Engineering and Management
National Yunlin University of Science & Technology
Master Thesis

基於類神經網路之區域 PM2.5 預測
Regional PM2.5 Prediction Based on Neural Network

李東錡

Dong-Chi Li

指導教授：陳奕中 博士

Advisor : Yi-Chung Chen, Ph.D.

中華民國 108 年 6 月

June 2019

國立雲林科技大學
研究所碩士班學位論文考試委員會審定書

本論文係李東錡君在本校 工業工程與管理系提論文「基於類神經網路之區域PM2.5預測」合於碩士資格水準，業經本委員會評審認可，特此證明。

口試委員：

陳奕中

陳奕中

傅家啟

傅家啟

劉傳銘

劉傳銘

陳思翰

陳思翰

陳以錚

陳以錚

指導教授：

陳奕中

陳奕中

所 長：

陳奕中

中 華 民 國 108 年 7 月 18 日

摘要

近年來，空氣品質預測相關研究急遽上升，然而，大多數研究無法從資料中篩選出合適的特徵，進而導致研究受到限制。在許多情況中，模型篩選出來的特徵並不足以解釋大氣科學現象。另一方面，若要求模型預測準確則需要耗費大量計算成本。在本論文中，提出兩種方法克服上述問題。首先，使用小波模型來擴張原始資料訊號特徵，增加模型對資料的時間分辨率，其次，結合 RBF 函數於遞迴類神經網路，以便於從小波模型生成的特徵值中挑選最適合的特徵進行空氣品質預測，實驗結果證明了該方案在建立具有突出預測性能的模型方面的有效性。

關鍵詞：空氣品質預測、深度學習、小波模型、時空資料庫分析



Abstract

There has been a recent surge in the research on predicting air quality; however, much of this work has been hampered by an inability to select appropriate features for analysis. In many cases, the selected features cannot be interpreted or trained based on the tenets of atmospheric science theory. In other cases, ensuring the accuracy of the model comes at a high computational cost. In this paper, we propose two methods by which to overcome the above-mentioned problems. First, we propose increasing the resolution of the model and employing a wavelet model to expand the dimensions of the signal features in the original data. We also propose combining the RBF function with a recurrent neural network to facilitate the selection of suitable features from those generated using the wavelet model for the prediction of air quality prediction. Experimental results demonstrate the efficacy of the proposed scheme in establishing a model with outstanding predictive performance.

Keywords : Air Quality Prediction, Deep Learning, Wavelet Model, Spatio-Temporal Databases Analysis

誌謝

時光匆匆，兩年碩士生涯瞬時而過，首先要感謝在大學時期開啟我對數據分析興趣的鍾震耀老師及陳思翰老師，謝謝你們在課堂中深入淺出的教學，課堂後提供我實習機會及許多學習教材，為我在數據科學領域基礎上扎根，深深影響我在研究所的求學過程。

接下來感謝在研究所中影響我最多的陳奕中老師，很幸運可以成為老師第一批雲科碩士學生，在對研究未來都還懵懂無知時，願意傾心傾力對我們教育，尤其在碩士一年級剛入學時，實驗室內沒有一位同學會寫程式的情況下，老師願意請助教來為我們額外上程式課程，幫助我們更快進入研究軌道，每一次的 meeting 老師對於我們論文報告方式、數學理論解釋及方法應用上要求，都讓我們有深刻的體悟，也影響我做研究的態度。

以及感謝雷組強老師，在論文上給予許多良好建言，讓我得以用更全面的思考方式來完成論文，每次的討論過程總能激發出新的想法，使的論文更完整。

另外，感謝實驗室各位的幫忙，首先是駿宏學長，在假日休假時願意來到雲科教我們寫程式，並帶領著我和泊樣在工研院 AIDEA 競賽中取得佳績，這是我頭一次參加程式競賽，透過這一次的競賽開啟我對研究的熱忱，也讓我學著獨立思考解開研究上的困難。接著是承儒、勝敏、志豪學長、winky 當我在研究上遇到困難時總能給我很好的建議及協助，還有碩士一起打拼的夥伴映均、泊樣、欣霖、昱瑋、士哲，從碩一開始我們一起接受奕中老師的訓練，求學過程中遇到許多困難也共同突破，以及非常可靠的學弟妹怡婷及毅傑，在我需要你們的時候總是挺身而出。

最後感謝我的家人，感謝你們支持我繼續念碩士，因為有你們的支持與關懷，讓我可以無後顧之憂，全新全意的完成我的學業，由衷的感謝你們。

最後僅將這篇論文獻給最關心我的家人及朋友們。

目錄

摘要.....	i
Abstract	ii
誌謝.....	iii
目錄.....	iv
表目錄.....	vi
圖目錄.....	vii
第一章 緒論	1
1.1 研究背景及動機	1
1.2 研究目的	6
第二章 文獻探討.....	10
2.1 懸浮微粒危害	10
2.2 影響懸浮微粒 PM2.5 濃度因素	10
2.3 小波分析.....	11
2.4 空品預測方法	13
第三章 研究方法.....	17
3.1 研究架構.....	17
3.2 資料清洗.....	18
3.3 利用小波模型擷取特徵值	18
3.4 使用 RBF 函數結合 Deep RNN 建模	20
3.5 使用 RBF 函數結合 LSTM 建模	22
3.6 利用 RBF 函數取出深度學習模型所找出的特徵值	23
3.7 使用天際線查詢從所有結果中挑選最佳的特徵值	25
第四章 實驗模擬.....	28
4.1 資料集與實驗參數介紹.....	28
4.2 小波模型之最佳參數選擇與有效性驗證	30

4.3	深度學習模型之最佳參數選擇	32
4.4	本論文方法取出之特徵值有效性驗證.....	33
4.5	本論文所選取特徵值之合理性說明.....	34
第五章	結論與未來研究	36
參考文獻		37



表目錄

表 1 PM _{2.5} 來源.....	11
表 2 過往空品預測常用方法比較.....	16
表 3 各輪特徵挑選結果示意表	25
表 4 空品影響因子.....	28
表 5 小波分解層數於基礎模型績效比較	30
表 6 使用原始資料因子作為特徵值直接放入不同模型訓練與預測之結果	31
表 7 使用 2 層小波模型結果為特徵值並放入不同模型訓練與預測之結果	31
表 8 RBF-DRNN 搭配不同閾值的預測結果	32
表 9 RBF-LSTM 搭配不同閾值的預測結果.....	32
表 10 過往方法預測之效能	32
表 11 使用 RBF-DRNN 所選取之特徵值，結合過往常用方法來進行預測之效能	33
表 12 使用 RBF-LSTM 所選取之特徵值，結合過往常用方法來進行預測之效能	33
表 13 本論文方法最常被挑選到的 53 種特徵值。	34

圖目錄

圖 1 行政院環保署 3 日預報	3
圖 2 空品數值訊號拆解範例	7
圖 3 Recurrent-based Deep Learning Model 架構圖	8
圖 4 Recurrent-based Deep Learning Model 輕量化架構圖	8
圖 5 研究流程圖	17
圖 6 小波分解	19
圖 7 RBF-DRNN	21
圖 8 監測站空間關係圖	29



第一章 緒論

1.1 研究背景及動機

近年來，在環保團體、醫界聯盟所組成的公民團體不斷揭露空污的危害與嚴重性下，空氣汙染議題引起各方各界開始關注。起初於 2010 年 6 月舉行之彰化國光石化健康風險專家會議中，中興大學環工系莊秉潔教授提出「國光石化營運造成 PM2.5 與健康及能見度影響」。該研究模擬出國光石化營運時 PM2.5 污染物的影響範圍及對生態環境和人體健康所造成的危害(莊秉潔，2010)。因「反國光石化運動」提高了民眾對空污風險的意識，帶起了政府及民間團體，紛紛投入 PM2.5 對健康風險影響的議題。然而促使 PM2.5 產生的事件有工廠製程中的煙霧排放、廢棄物燃燒、車輛行徑產生的砂石礫、移動污染源等等生活事件，綜合所有因素都影響 PM2.5 的含量，只是受影響的地區及範圍、程度高低各有所不同，因此找出空氣汙染時空間彼此關係便是一大課題。

早於 2005 年民眾對於空汙風險意識尚未成熟時，環保署便設置標準空氣品質監測站，但當時並無訂出實際的管制標準，且標準空氣品質監測站造價昂貴設置數量亦有限，直至 2018 年環保署開始與各縣市環保局合作大量佈設微行空氣感測器於重點監測區域，不同於市售空氣盒子，微型空氣感測器設備附掛於路燈桿 3 至 5 公尺空氣流通處、環境取樣較具代表性、有精準比對校正並定期維護、可降低誤判，主要囊括工業區、社區、交通密集區，藉此提升空品數據的時空解析度，形成一個高密度空品監測網絡，以彌補標準監測站點所沒有監測的範圍；另外民眾也因為受到空氣汙染影響行程安排，2009 年環保署開始提供空氣品質 3 日(72 小時)預報作業，內容包括 PM10、臭氧 PSI 及 PM2.5 24 小時、臭氧 8 小時預警值，以利民眾行程安排的便捷度；而民間團體方面在中研院研究團隊、LASS 社群(Location Aware Sensing System)集結群眾智慧的技術提出了空氣盒子計劃，協助民眾可以即時性的了解自身周遭的空氣品質，但由於空氣盒子受擺放位置(室內、室

外)、是否對設備定期進行維護、校正...等，都會影響其空氣數值，故僅能大略提供民眾參考，無法代表實質空氣指標。在於上述內容中，可發現國內對空污即時監測系統雖然著墨甚多，但這些系統及方法大多利用過去及現在的資料，對於預測未來的相關應用仍少。歸納其主要原因可分為二項說明，其一是因為空氣品質良窳受到許多因素影響，很難同時獲得各方數據來模擬所有因素，且空氣污染分散在不同地點，其擴散方式各有不同，對於監測站點之間所蒐集到的數據也受到所在地理位置、氣候變化或人為因素影響，使得空氣品質預測變的複雜，舉例來說，台中地區空氣污染源主要來自工業製造(中龍鋼鐵、中部科學工業園區)、發電廠(臺中火力電廠)及移動源(汽車、柴油車、機車)這些空氣污染源都可能會造成空氣品質在同一天有巨大的浮動變化，這讓預測變得困難；其二雖然國內環保署有提供 3 日預報作業(如圖 1)，但這些預報內容空品區範圍過大，以中部地區來說，中部包含(台中、彰化、南投)，但其實這三個區域的地形、氣候、人口組成差異許多，僅依大區域空品區做預報，對於民眾想知道自身周遭空氣品質或是特定時間的空氣品質每日預報能提供的資訊有限，故必須改善現有的預報資訊，以提供民眾更貼近生活的資訊。

在過往空氣品質預測的方法大致可分為兩種，包含了以大氣科學為主的方法，以及以統計方法結合機器學習理論為主的方法。在大氣科學部分，學者們得先收集研究地區的所以空品可能影響因子，接著將這些因子輸入大氣模型中，探討其中的物理與化學反應後，再進行建模與預測。如 Saide *et al.* [1]收集了智利首都 Santiago 所有可能影響空品的因子，接著將這些因子輸入名為 WRF-Chem 的化學傳輸模型來預測該地區的 PM10、PM2.5 數值並成功達到應有的預測效果。然而這類方法不僅需要大量的專業知識，在資料收集與建立模型上也需要耗費大量的時間與成本，在長時間的預測上效果也可能較差。因此，部分學者開始使用統計方法結合機器學習理論來進行空品預測。例如，Wang *et al.* [2]選取了多個空氣污染特徵值及氣象特徵值歷史資料輸入支持向量機迴歸模型(Support Vector Regression,

SVR)與整合移動平均自回歸模型(Autoregressive Integrated Moving Average model, ARIMA)的混和

空品區	AQI 指標	指標 污染物	AQI 指標	指標 污染物	AQI 指標	指標 污染物
北部	50		75	細懸浮微粒 (75)	60	細懸浮微粒 (60)
竹苗	50		55	細懸浮微粒 (55)	50	
中部	90	細懸浮微粒 (90)	90	細懸浮微粒 (90)	75	細懸浮微粒 (75)
雲嘉南	100	細懸浮微粒 (100)	100	懸浮微粒 (100)	85	懸浮微粒 (85)
高屏	150	細懸浮微粒 (150)	90	細懸浮微粒 (90)	75	細懸浮微粒 (75)
宜蘭	50		60	細懸浮微粒 (60)	35	
花東	35		50		35	
馬祖	100	細懸浮微粒 (100)				
金門	100	細懸浮微粒 (100)				
澎湖	90	細懸浮微粒 (90)				
分類	良好	普通	對敏感族群不健康		對所有族群不健康	
指標 等級	0~50	51~100	101~150		151~200	
					201~300	
					301~500	

圖 1 行政院環保署 3 日預報

模型預測中國深圳 PM2.5 濃度。Kumar and Ridder [3]則是先利用快速傅里葉轉換 (Fast Fourier Transform, FFT)，從空品歷史資料集中取出有可能影響空氣品質的特徵值後，再將這些特徵值輸入 ARIMA 的時間序列預測模型來預測空品。Feng *et al.* [4]利用地理軌跡模型與小波分析(Wavelet analysis)理論，從他們所收集的歷史空品資料集萃取出合適的特徵值，最後再將這些特徵值輸入多層感知機(Multilayer Perceptron, MLP)進行空氣的預測。Cai *et al.* [5]在進行空品預測前，先收集了研究地區的氣候特徵值、汙染特徵值，並將額外的特徵值如太陽輻射量、幹道方向、交通運輸工具數量，一同輸入前饋式類神經網路來預測城市幹道的 PM2.5 數值。Biancofiore *et al.* [6]使用三年的 PM2.5、PM10，並從所有氣象資料中取出溫度、壓力、濕度、風速和風向等五個特徵值，最終將這些資料與特徵值輸入遞迴類神經模型來對義大利中部城市進行空品預測。整體而言，上述方法都能成功的完成空品的預測。以方法論來說，這類方法因為不需要大量的大氣專業知識，所以分析門檻較低。然而效能卻受限於學者們從歷史資料所萃取出的特徵值是否適當。即便學者們選了合適的空品預測模型，若輸入不適當的特徵值資料集來做訓練，其模型效果依然會非常差。

有鑑於上述統計分析方法與機器學習理論遇到的缺點，從 2018 年來有許多學

者開始轉向使用深度學習模型來進行空品預測。因為深度學習模型能夠在使用者僅輸入大量原始資料或特徵值的狀況下，自行從這些輸入資料中組合出另一組適合建模的特徵值，並使用這些新特徵值來建模，因此提高模型的建模準確率。舉例來說，Freeman *et al.* [7]收集了 Kuwait 地區的空品歷史時間序列資料集，從中選取了 5 到 25 個特徵值，將這些特徵值輸入長短期記憶類神經網路(Long Short Term Memory Network, LSTM)進行建模與預測，並證實了這樣的方法預測效果比傳統 ARIMA 為佳。Zhou *et al.* [8]設計了一個名為 DM-LSTM 的模型，能夠用於預測長時間的空品數值，並驗證了該模型在台灣台北地區能表現的較其他模型好。Wang and Song [9]則設計了一個新的 LSTM 模型來讓使用者同時將空品預測目標城市以及其鄰近城市的歷史數據一同輸入並建模。亦即，該方法模型能同時考慮空品歷史資料集中的時間與空間因子。而實驗模擬也證明了這樣的方法預測準確率相較於線性迴歸、迴歸樹、深層類神經網路等傳統方法高。整體而言，深度學習模型的使用的確為空品預測領域帶來新的改變，並大幅提昇了空品預測的準確度。然而必須了解深度學習模型在改善空品預測準確度的同時也帶來了另一項挑戰-高成本的模型運算效能。大部分的深度學習模型都必須透過雲端計算主機或是具有 GPU 的高階電腦才能完成訓練與使用，而這些設備都所費不貲。也許學者們在僅訓練單一地區空品預測模型所造成的成本尚可接受，但若政府要對針對某個大地區，或是整個國家進行空品預測模型建模時，這個成本便會高到無法負荷。

從 2018 年開始，由於深度學習模型的高運行成本，所以許多學者開始討論如何在不降低太多分析準確度的狀況下降低深度學習模型的運行成本。目前方法大致上分為兩個方向，包含了(1)刪減深度學習模型中無用的架構以降低運行成本，以及(2)從深度學習模型中擷取對分析有用的特徵值後，再用新的特徵值去訓練低成本的機器學習模型並降低後續的運行成本。針對第一個方向來說，Han *et al.* [10]提出了藉由刪除深度學習模型中數值較小的類神經權重值來加快深度學習模型運行速度的方法。近年來，則有 Li *et al.* [11]提出了藉由刪去深度學習模型中總和權

重值較小的 Complete filters layer 來減少深度學習模型的層數，並因此提昇深度學習模型運行速度的方法。上述兩個方法雖然宣稱有效，但這類方法能刪去的類神經架構數量不多，所以能改善的速度有限。接著在第二個方向中，學者們主張若能將合適的特徵值輸入傳統的機器學習模型，則傳統機器學習模型應能獲得跟深度學習模型一樣好的效能。例如 Sani *et al.* [12]直接取出深度學習最後一個池化層與全連階層間的數值作為深度學習挑選出來對模型最有幫助的特徵值，再將這些特徵值輸入低成本的 KNN 方法來進行動作辨識，並驗證了這樣方法確實能以較低成本達到與深度學習模型差不多的動作辨識率。Mohammad *et al.* [13]則是設計了新的公式來計算每個特徵值在深度學習模型中的重要程度，選取其中最重要者，再把這些重要的特徵值重新輸入深度模型中訓練，最終獲得了低成本，且與深度學習模型效能差不多又優於傳統分析方式的辨識率。然而發現這類挑選特徵值的做法對空品預測來說是不適當的，因為在大氣科學領域中空品預測非常重視被選取出特徵值的合理解釋，在預測模型建立的同時還需要解釋為何使用這些特徵值於目標模型上。但過往從深度學習模型找出特徵值的方法不是過於簡略無法說服讀者，就是取出的特徵值過於複雜以致於難以解釋。因此本論文提出一些新方法來克服上述的缺點。

整合上述過往學者們對空品預測的研究後，可得知要進行高精準度與低成本的空品預測，必須進行以下兩個步驟，(1)先從空品的歷史時空資料集中盡可能萃取出所有可能對空品預測有幫助的特徵值。(2)將這些特徵值輸入深度學習模型中，並藉由深度學習模型從前一步所萃取的特徵值中找出對提昇模型預測精準度最有用的數個特徵值。之後再利用這些特徵值重新建構新的預測模型。而在本論文中，針對這兩個步驟分別提出了解決方式。包含了(1)使用小波模型來從空品歷史時空資料集萃取出所有可能對空品預測有幫助的特徵值，以及(2)設計一個新的深度學習模型來協助選取合適建模的特徵值，並因此減少深度學習模型的大小。

1.2 研究目的

針對上述問題本論文一開始會先使用小波模型針對空品的歷史時空資料集取出所有可能對空品預測有幫助的特徵值。而小波模型是一種能把長時間的時間序列，藉由頻率拆解成多組變化週期不同的時間序列，並已被大量運用於氣候變異等存在多重時間尺度週期性變異的資料分析上。假設空品預測的目標區域是(a)中的 A，且 A 區域周圍有 BC 兩個區域，則本論文會收集 ABC 三個區域的所有可能會影響空污數值的歷史因子資料，如 PM2.5、NO₂，及降雨量等，接著將這些資料利用小波模型分解成多個特徵值。

本論文則是希望使用小波模型將不同區域不同因子的長短期時間序列變化拆開，並期望能探討這些長短期時間序列變化對目標區域的空污數值影響。假設(b)是 A 區域的 PM2.5 數值，(c)與(d)是 B 區域與 C 區域各自 PM2.5 時間序列經小波拆解後的結果。經比較(b)到(d)後，可以看到僅有 B 區域的 a5 長期變化會影響 A 區域的 PM2.5 數值長期變化數值。至於 C 區域，可發現其 d4 的高頻波，明顯對於 A 區的短期變化具有影響。若將上述兩者整合起來，可說 A 區 PM2.5 數值長期會受到 B 區域 a5 特徵值影響，而短期會受 C 區域 d4 特徵值影響。理論上，若只輸入這兩個特徵值進入後續模型中，則理論應能以最低成本達到最精準的預測結果。本論文接著會使用徑向基函數(Radial basis function, RBF)函數結合一個具遞迴層的深度模型(Recurrent-based Deep Learning Model, RDLM)來選取合適用來建模的特徵值並同時進行深度學習模型縮小的步驟，其中這個 RDLM 可為一般的遞迴深度類神經網路(Deep Recurrent Neural Networks, DRNN)的網路，或是著名的長短型記憶模型(LSTM)。本論文會同時將 RBF 函數結合這兩個模型，並討論其效能的差異。主要想法來自於 LSTM 模型與 DRNN 模型雖然都由深度的遞迴層與全連接層所組成，但 LSTM 又多了遺忘功能，會適時的遺忘過去訓練好的參數，以提升模型對時間序列的預測能力，所以 LSTM 普遍效能較 DRNN 為佳。然而本論文是使

用深度學習模型來擷取最佳的模型特徵值，無法確定 LSTM 的遺忘功能是否會造成特徵值選取上的問題。因此，一併將不具有遺忘功能的 DRNN 一起實作，並進行比較。本論文所設計的模型如圖 3 所示。在該圖中，可以看到 RBF 函數主要是連接




圖 2 空品數值訊號拆解範例

輸入層與後續的 DRNN 或是 LSTM，且每個輸入層神經元會連接到 n 個 RBF 函數。藉由這些 RBF 函數，每個模型輸入(亦即本論文從原始資料萃取出來的特徵值)會被轉換成 n 個新的特徵值，而這些被轉換後的特徵值會被輸入到後續的 DRNN 或是 LSTM 中建模。若模型在訓練中一同調整 RBF 函數參數，則對模型訓練後的 RBF 函數轉換後所得到的新特徵值應該會是 DRNN 或是 LSTM 所找出對建模最適合的特徵值。接著檢驗每個特徵值在模型使用時對 DRNN 或是 LSTM 的貢獻度，

則可以找出對 DRNN 或是 LSTM 最合適的特徵值，並反推找到最適合建模的模型輸入。最終再一次將這些挑選出的模型輸入再次輸入類似圖 3 架構的模型，並產生如圖 4 的模型，預期新的模型因為模型輸入較少，所以整體網路大小將會縮小。且因為僅有對建模精準度有幫助的模型輸入被留下，而其他模型輸入被刪去，




圖 3 Recurrent-based Deep Learning Model 架構圖




圖 4 Recurrent-based Deep Learning Model 輕量化架構圖

所以新的模型其預測效果應該與前一輪相去不遠，甚至有可能更好。整體而言，相較於過往從深度學習模型中挑選出合適特徵值的研究，本論文所設計的模型能從深度學習模型中輕易的挑選出易於解釋的特徵值(i.e., 所設計模型的模型輸入)。

同時本論文所提出的方法也能達到降低深度學習模型運行成本且不會降低模型的預測精準度的目的。

在完成上述兩步驟的設計後，將使用真實的空品時空資料集來驗證所提方法的有效性。本論文所使用的真實資料集是台灣中部地區 9 個空品觀測站於 2015 年 1 月 1 日 0 時至 2018 年 7 月 25 日 23 時所收集的資料，其中該資料集中共包含了四個氣象因子氣溫、風速、濕度、風向及八種空氣汙染因子 O₃、PM_{2.5}、PM₁₀、CO、NO、SO₂、NO₂、NO_x 的監測結果。



第二章 文獻探討

本章節將列舉出與本論文相關的幾個重要研究，除了過往文獻探討懸浮微粒危害、模型創建外，將著重關注於過往空品預測的常見研究方向，包含了大氣科學方法、統計分析結合機器學習的方法、淺層類神經網路的方法，以及深度學習的方法。最後比較這些方法在空品預測上的成效。

2.1 懸浮微粒危害

在過去幾年中，許多學者研究懸浮粒子(Particulate Matter ,PM) 對人類健康、環境生態系統污染的影響。在人類健康方面 Brown *et al.*[14]在研究指出懸浮微粒顆粒大小會直接影響人體健康問題，顆粒越小，其穿透力沉積在呼吸道上就越深；Valavanidis *et al.*[15]研究也指出小於 $1\mu\text{m}$ 的顆粒通常表現得與氣體分子相似，因此空氣污染物會滲透到肺泡，並且進一步轉移到細胞組織或循環系統中，影響人類身體健康。根據 2013 年國際癌症研究機構 (International Agency for Research on Cancer, IARC) 報告指出室外空氣污染是造成癌症的重要因素，並將其歸類在 IARC 的第一級致癌物中。2014 年 WHO 指出室內與室外空氣污染會對呼吸道造成危害，包含急性呼吸道感染和慢性阻塞性肺病，且與心血管疾病及癌症亦具有強烈相關性。而環境生態系統污染方面，Zhou *et al.*[16]研究指出 PM_{2.5} 濃度增長對於農作物(小麥、玉米、水稻)產量具有顯著影響。由上述可知已有許多研究證實空汙對於人體具有顯著的傷害無法忽視。

2.2 影響懸浮微粒 PM_{2.5} 濃度因素

懸浮微粒 PM_{2.5} 對人類及環境生態已造成相當大的威脅，在預測前應瞭解影響 PM_{2.5} 濃度因素，PM_{2.5} 來源可分為原生性及衍生性，皆可能由自然界或人為產生。經由環保署提供相關污染因子，詳如表 1，而相關學者研究如下：

表 1PM2.5 來源

依來源區分	自然界產出	火山爆發、地殼岩石等
	人類行為產出	石化燃料及工業排放、移動源廢氣等燃燒行為
依性質區分	原生性 PM2.5	直接從自然與人為活動所排放，在大氣環境中未經化學反應的微粒一如天然的海鹽飛沫、營建工地粉塵、車行揚塵及工廠直接排放
	衍生性 PM2.5	自然與人為活動排放到大氣環境中的化學物質經過太陽光照或其他化學反應後生成一如燃煤、燃油及燃氣電廠、煉鋼廠、石化相關產業工廠、機動車輛、船舶、建物塗料、農業施肥、禽畜排泄及生活污水等

資料來源:行政院環保署

Hatzopoulou *et al.*[17]則說交通運輸工具是造成 PM2.5 的主要來源之一，主要因素源自於輪胎磨損產生廢棄顆粒，以及先前就已經沉積於路面上的懸浮粒子，經由交通工具將再次吹起，造成 PM2.5 重新懸浮於空氣中。Marlier *et al.*[18]提到農村活動(焚燒稻草)、森林火災(火耕)，也是形成 PM2.5 的主要原因，產生的 PM2.5 佔據全球城市總平均 18%。接著，Wan *et al.*[19]研究指出由於烹飪會產生有機及無機揮發物，所排放最大平均 PM2.5 濃度約為廚房未烹飪的 4 倍。Freeman *et al.*[7]則說空氣品質是連續多變量時間序列，隨著時間推移空氣品質存在周期性，當前空氣汙染物值濃度與先前空氣汙染物值濃度在某種程度上具有相關。Siwek and Osowski Wang and Song [9, 20]則提到除了要掌握本地及附近地區的空气汙染排放量之外，還必須考量地形、氣候相互作用下對於空氣品質所造成的化學、物理影響。

2.3 小波分析

小波最早由 Morlet 和 Grossman 提出，主要分為連續小波及離散小波。兩者主要區別在於，連續轉換在所有可能的縮放和平移上操作，而離散轉換採用所有縮

放和平移值的特定子集，可有效應用於訊號及噪音的分離，提高時域及頻域主要在於分析長期資料數據，從中解析非線性之訊號變動週期，此方法最主要的特點在於能夠顯示非平穩的信號的時頻結構特徵，適合運用於氣候變異等存在多重時間尺度週期性變異。而小波分析以基底函數所具有之特性合成，基底函數分別為小波函數(Wavelet Function)及尺度函數(Scaling Function)，藉由小波函數表現細節變化，尺度函數表現大致變化。

小波函數 $\Psi(t)$ 可用下列數學式表示：

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) \quad (1)$$

其中 a 為尺度參數， b 為平移參數， ψ 為母小波，而小波轉換數學式可表示為：

$$W(a,b) = \int_{-\infty}^{\infty} f(t) \psi_{a,b}(t) dt \quad (2)$$

連續小波是處理數位訊號重要方法，透過處理連續時間的函數，獲取小波係數，可以清楚分析出不同時間尺度的變化，以下為其數學式：

$$W_x(a,b) = \langle f(t), \psi_{a,b} \rangle = \frac{1}{\sqrt{a}} \int_R f(t) \psi * \left(\frac{t-b}{a}\right) dt \quad (3)$$

其中 a 為尺度參數， b 為平移參數； $\frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right)$ 為母小波函數經尺度和位移所得到的基底函數； $\psi *$ 為 $\psi(t)$ 的共扼函數。

其逆轉換為：

$$f(t) = \frac{1}{C_\psi} \int_{-\infty}^{\infty} \int_0^{\infty} \frac{1}{a^2} W_x(a,b) \psi_{a,b}(t) da db \quad (4)$$

其中 $C_\psi = \int_R \frac{|\hat{\psi}(\omega)|^2}{|\omega|} d\omega$ ， $\hat{\psi}$ 為傅立葉轉換值

除了連續小波外，離散小波則是另一種知名的小波模型變形，其目標是為降低連續小波運算的複雜度，而將連續小波轉換公式的尺度參數 a 與平移參數 b 離散化，其作法必須先取得 $f(t)$ 與 a, b 做內積所得到的係數， $a = a_0^m, b = nb_0 a_0^m$ ，其中 m, n 為整數，可獲得小波原型函數：

$$\psi_{a,b}(t) = \psi_{a_0^m, nb_0 a_0^m} = a_0^{-\frac{m}{2}} \psi(a_0^{-m} t - nb_0) \quad (5)$$

而離散小波轉換可表示為：

$$f(t) = \sum_m \sum_n x_{m,n} \psi_{m,n}(t) \quad (6)$$

其中 $x_{m,n}$ 為小波係數：

$$x_{m,n} = \langle f(t), \psi_{m,n}(t) \rangle = \frac{1}{a_0^{\frac{m}{2}}} \int f(t) \psi(a_0^{-m} t - nb_0) dt \quad (7)$$

2.4 空品預測方法

目前常用於空氣汙染預測方法是大氣科學方法和統計預測方法。機理分析方法須詳盡記錄研究地區所有影響因子清單，並以此作為模型輸入，同時要求研究人員對於各因子的轉換機制須有深入瞭解，以便選取適當的物理、化學模型進行計算預測；統計預測方法雖然不需要像機理分析深入探究內部物理化學反應，但需要蒐集各種大氣條件下大量歷史量測數據，主要分析方法可分為線性和非線性回歸模型，其中空氣預測模型大多使用非線性模型主要分析工具，原因為已經有多位學者研究指出懸浮微粒為非線性變化，故線性模型不適用於懸浮微粒時間序列預測。

大氣科學方法：在進行這類方法，學者們必須先了解空污傳播的各項專業知

識，並依據這些專業知識收集目標研究地區中會影響空污數值的因子歷史資料。接著，學者們還必須將這些資料整理後輸入複雜的物理或是化學傳輸模型中，進行高成本的運算後才能獲得成果。然而影響空品的因子太多以致於不可能全盤考慮，所以這類依據大氣科學方法所作出的預測效果有時會不太準確。舉例來說，Konovalov *et al.* [21] 曾使用大氣科學模型預測某地四季 PM10 的濃度，但其研究結果顯示其預測準確率會低於使用統計迴歸分析來預測的結果。Saide *et al.* [1] 使用化學傳輸模型(WRF / Chem)預測城市地區 PM10、PM2.5 的濃度，藉此瞭解該地區工廠廢氣排放是否超過當地法定標準，並提供政府預報作業，研究中詳細分析 PM10、PM2.5 的成因和變化趨勢，其中包含污染物的水平擴散、垂直擴散時空分布。雖然這樣的方法可以瞭解空氣汙染排放前後相對應關係，然而這樣方法對於地區整體時間序列預測誤差較大，較不適用於空品預測問題上。

統計分析結合機器學習的方法:此方法在預測時並不需要像大氣科學方法了解許多專業知識，因此近年來成為學者們最常用來進行空品預測的工具之一。一般來說，這類方法大多使用非線性模型完成，因為空污數值的變化已被多位學者證實為非線性變化，故線性模型並不適用於本議題上。舉例來說，Nieto *et al.* [22] 使用了西班牙北部城市七年 PM10 歷史數據，從中挑選了多個特徵值並將他們分別輸入支持向量機迴歸(SVR)、多層感知器(MLP)、多變量移動平均自迴歸模型(VARMA)和整合移動平均自迴歸模型(ARIMA)等四種模型進行預測績效比較，並發現 SVR 在中期預測(1 個月)及長期預測(半年)都有較好的預測能力。接著 Wang *et al.* [2] 挑選了多種空氣汙染特徵值及氣象特徵值歷史資料，並將這些特徵值輸入支持向量機迴歸模型(SVR)與整合移動平均自迴歸模型(ARIMA)的整合模型中，成功完成了中國深圳 PM2.5 濃度的預測。Singh *et al.* [23] 則是利用了多種 Tree-related 機器學習演算法 Single Decision Tree (SDT), Decision Tree Forest (DTF), and Decision Treeboost (DTB)來分析印度 Lucknow 城市空污的來源並進行空品預測。而該研究實驗結果則驗證了這些 Tree-related 的機器學習演算法會比使用傳統

Support Vector Machines (SVM)方法好。上述的統計分析及機器學習方法都宣稱能成功的對空品問題進行預測，然而這類方法最大的問題是挑選到合適預測空品的特徵值，預測才能達到預期結果。倘若輸入不合適預測空品的特徵值於同樣的模型，其預測效果通常也不佳。

淺層類神經網路的方法:淺層類神經網路自從被開發出來以後，一直都是受學者們重用的模型之一。因為該模型具有自適應的特色，只要使用者給予合適的輸入與輸出數值，類神經網路便會透過訓練演算法自適應的找出合適的模型來將輸入對應成輸出。這樣的特性也讓類神經網路常被用於複雜且難以解釋的問題，如空品預測上。例如：Park *et al.* [24] 為了預測韓國首爾地鐵站內未來一小時的 PM10 濃度，將地鐵站外前一小時 PM10 濃度、地鐵運行數量，以及風速等特徵值輸入類神經網路中，並獲得 74% 的預測準確率。Cai *et al.* [5] 將氣候歷史資料、空污歷史資料、太陽輻射量、幹道方向，以及交通工具數量作為前饋式類神經網路的輸入，並因此預測城市幹道的 PM2.5 數值。而其研究成果也顯示這樣方式預測出來的成果較迴歸方式為準。近年則有 Biancofiore *et al.* [6] 從三年的氣象歷史資料與空污歷史資料中取出多個特徵值，並輸入遞迴類神經網路中來預測義大利中部城市的 PM2.5 與 PM10 數值。其結果也證實這樣的方式較多元線性迴歸模型(MLR)以及非遞迴類神經模型進為佳。從上述的研究可以看出類神經網路確實能帶給空品預測問題更佳的預測準確率。但與前述統計分析和機器學習方法相同，仍會遇到在輸入不適當特徵值時空品預測效能不佳的問題。

深度學習的方法:深度學習模型是淺層類神經網路的延伸，自該模型問世後即受到學者們的矚目，並被應用於多個領域中。而在空品預測的領域中，從 2018 年開始也有許多研究開始應用深度學習模型於空品預測問題上，也獲得到不錯的成效。例如 Freeman *et al.* [7] 直接應用長短期記憶類神經網路(LSTM)與 Kuwait 地區的空品歷史時間序列來進行當地的空品預測，證實這樣的方式較傳統的 ARIMA 好。Zhou *et al.* [8] 與 Wang and Song [9] 則基於深度學習模型的概念分別設計了新的深

度學習模型同時考慮空品歷史資料集的時間與空間因子並進行建模。該研究實驗模擬也證實了深度學習模型在空品預測的問題上確實比傳統方式更為準確。

表 2 過往空品預測常用方法比較

模型需求	大氣科學方法	統計分析 機器學習	淺層 類神經網路	深度學習
空品專業知識	V	X	X	X
歷史數據	X	V	V	V
預測精準率	低	中	中	高
特徵擷取重要因子的解釋能力	高	中	中	低

然而，雖然深度學習模型在空品預測的準確度上能達到不錯的成效，但是相對的也耗費了大量的訓練與使用成本，讓處理空品預測的問題變得即為昂貴。再者，因為深度學習網路較傳統分析方法，如統計分析、機器學習，以及淺層類神經網路更為複雜，所以在空品預測模型的解釋上也變得更為困難。

過往空品預測方法的比較:表 2 為使用比較過往空品預測常用的四大方向。首先，大氣科學方法因為需要有空品專業知識為基礎才能進行分析，但其他方法並不需要，所以學者們要藉由大氣科學方法來進行分析的門檻會較其他三個方法高。但也就是因為大氣科學方法是基於專業知識而設計的，所以依此方法在進行空品預測時不需要任何歷史數據，且對模型中重要因子的解釋能力也會較高。至於剩下的三個方法，都是屬於資料科學的一部分，故在使用這些方法進行分析時都需要大量的歷史數據為基礎才能進行。然而，有這些歷史數據為依據，也讓這三個方法的預測精準率較高，尤以深度學習最高，因為其具有三者之中最複雜的模型。但相對的，深度學習模型最為複雜，所以對該模型內重要因子的解釋也最為困難。

第三章 研究方法

3.1 研究架構

本論文所提出方法的流程圖如圖 5 所示，分為 Offline 與 Online 兩個部分處理。首先 Offline 部分從資料輸入開始分成四個階段處理，包含了第一階段的資料清洗、第二階段的利用小波模型擷取特徵值、第三階段的使用 RBF 函數結合 Deep RNN 建模或是使用 RBF 函數結合 LSTM 模型建模，以及第四階段的利用 RBF 函數取出深度學習模型所找出的特徵值。特別的，因為無法確保單一輪處理所選取出的特徵值是最佳解，所以在 Offline 的部份中會重複第二階段到第四階段數輪。最終，在獲得多輪的結果後，使用天際線查詢從所有輪的結果中挑選最佳的特徵值。而被挑選的特徵值將作為 Online 部分模型的輸入，並用於實際問題上。現介紹流程圖內各主要部分如下，其中第三階段的模型因為包含 RBF 結合 DRNN 與 RBF 結合 LSTM 兩種，故分成兩節進行討論。




圖 5 研究流程圖

3.2 資料清洗

一般來說，會影響空品數值的各項因子，如天氣因子的溫度、濕度，以及各項污染物數值 PM10、PM2.5 等，都是由感測器收集而來。但感測器在使用上都會遇到維護停機、電源故障、網路設備不穩，甚至是感測器本身故障的問題，所以會造成收集到的資料出現遺漏值、超過於正常數值範圍、數值為 0，Null 或是具有負數紀錄。由於這樣有問題的資料是不能用於資料分析與建模的，所以本論文在進行後續步驟之前會先清洗收集到的資料。並參考過往研究 Freeman *et al.* [7] 使用的線性插值法來補齊這些遺漏或是資料有異常的數值。而插值方式分為兩種，主要依據遺漏或是異常數值的時間範圍來決定的。若範圍小於 24 小時，則使用遺漏或是異常範圍前後的數值來進行插值(Eq. (1))，因為這樣補起來的數值最能與當天前後的情形對應。

$$x_n = x_{n-1} + n\Delta \quad (1)$$

$$\Delta = \frac{x_{g+1} - x_0}{g + 1} \quad (2)$$

其中 g 代表需要補值的範圍大小，而 n 代表要補值的第 n 筆資料。接著，若需要補值的範圍超過 24 小時，則使用補值前 24 小時數值與後 24 小時數值的平均進行補值。

$$x(t) = \frac{x_{t+24} - x_{t-24}}{2} \quad (3)$$

會有這樣的作法是因為要補值的範圍太大，很難從資料還原復當天情況，只能使用前一天同時段與後一天同時段來模擬當天同時段的可能空品狀況。

3.3 利用小波模型擷取特徵值

完成空氣汙染因子與氣候因子觀測資料補值程序後，接著利用小波模型來對資料頻域取特徵值。使用小波模型原因是空氣汙染已被證實會被環境影響，並讓各種污染物質濃度在短時間產生高度變化。在這種狀況下，以頻域為基礎的特徵

值取法會比傳統的時域取法更能夠取出合適探討空污數值變化的特徵值。




圖 6 小波分解

一般來說，小波分析是以基底函數所具有之特性合成，而基底函數分別為小波函數(Wavelet Function)及尺度函數(Scaling Function)，其中小波函數是用來表示時間序列中的細節變化，尺度函數則是用來表現時間序列的大致變化。藉由上述小波模型的定義，本論文將使用的小波模型概念以圖 4 的方式呈現。在該圖中 $x[n]$ 是本論文所收集來的各空氣污染因子、氣象因子數據。 $g[n]$ 為低通濾波器，可以將輸入訊號的高頻部份濾掉而輸出低頻部份。 $h[n]$ 為高通濾波器，與低通濾波器相反，這個濾波器會濾掉低頻部份而輸出高頻部份。最後 Q 為降取樣濾波器，用於輸出 $x[n]$ 經過這層小波模型取特徵值後的結果。另外在圖 6 中，可看到小波模型是個階層式的架構，原始資料在輸入小波模型後，會先經過第一輪的處理，產生低頻訊號與高頻訊號各一，其中低頻訊號即是小波分析定義的尺度函數，而高頻訊號則是小波函數。本論文會把這個小波函數留下當成第一輪的特徵值，至於尺度函數則會被放入第二輪中再次進行處理。接著每一輪的處理同樣會產生小波函數與尺度函數的訊號各一。同樣會把其中的小波函數當成該輪的特徵值，而尺度函數就會被當成下一輪的輸入。最終，這樣的過程將持續到使用者設定的輪數為止。此外本論文參考過往研究的建議 Feng *et al.* [4]，使用小波分層級數經驗法來進行小波分層設定，該經驗法告訴使用者，若一輪的輸出結果符合 Eq. (4)，則可停止。

$$\frac{std(A_f)}{std(s)} < 0.1 \quad (4)$$

其中 $std(\bullet)$ 代表標準差函數， A_J 代表第 J 層低頻訊號， s 代表原始訊號。

本論文所使用的解小波模型方法是過往研究常用的離散小波方法。該方法定義小波函數 $\psi(t)$ 可以以 Eq. (5) 呈現。

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) \quad (5)$$

其中 a 為尺度參數， b 為平移參數， ψ 為母小波，而小波轉換數學式可表示為

$$W(a,b) = \int_{-\infty}^{\infty} f(t) \psi_{a,b}(t) dt \quad (6)$$

然而，若要以連續函數的概念來解 Eq. (5) 可能會過於複雜，所以連續小波方法會以 $a = a_0^m, b = nb_0 a_0^m$ 的方式將 a 與 b 離散化，其中 m, n 為整數來簡化求解的過程。而在把 a 與 b 離散化後，即可獲得新的小波函數

$$f(t) = \sum_m \sum_n x_{m,n} \psi_{m,n}(t) \quad (7)$$

其中 $x_{m,n}$ 為小波係數

$$x_{m,n} = \langle f(t), \psi_{m,n}(t) \rangle = \frac{1}{a_0^{\frac{m}{2}}} \int f(t) \psi(a_0^{-m}t - n_0^b) dt \quad (8)$$

在上述的過程中，學者一般會認為高頻訊號具有較高的時間分辨率，能描述時間序列的突然變化，而低頻訊號具有較高的頻率分辨率並能描述污染物濃度的長期變化，這也是本論文進行後續分析的基礎。

3.4 使用 RBF 函數結合 Deep RNN 建模

在使用小波模型擷取空品特徵值後，接著會將這些特徵值輸入本論文所設計的深度學習模型中，亦即使用 RBF 函數結合深度迴歸類神經模型(RBF-DRNN)，以及使用 RBF 函數結合長短期記憶模型(RBF-LSTM)。為了說明方便，本節會先介紹 RBF-DRNN，下一節才對 RBF-LSTM 進行介紹。




圖 7 RBF-DRNN

本論文所介紹的 RBF-DRNN 模型如圖 5 所示，包含了輸入層、RBF 層、Recurrent 層，以及多層全連接層。首先，輸入層並不做任何運算，僅是把所找到的特徵值傳入模型中。假設針對目標空品預測區域，總共使用了周圍 n 個區域的 m 種資料，且每種資料都用小波模型取 k 個特徵值，則模型預計會有 $n \cdot m \cdot k$ 個輸入。

接著，RBF 層的功能是把模型的每個輸入轉換成 q 個新特徵值，則本層會有 $n \cdot m \cdot k \cdot q$ 個神經元，每個神經元內包含一個 RBF 函數，並可被寫為

$$O_{ij} = \exp \left[\frac{-(Output_{Input_layer} - m_{ij})^2}{\sigma_{ij}^2} \right] \quad (9)$$

其中 i 與 j 分別表示模型的第 i 個輸入以及其第 j 個 RBF 函數，而 m_{ij} 和 σ_{ij} 則是這個神經元中 RBF 函數的平均值及標準差。

遞迴層會接受來自 RBF 層的數值，並探討前一個時間點遞迴層的輸出對現在時間點遞迴層輸出的影響。此層的神經元個數則以前一層神經元數目 α 為基準，共有 $2^{\lfloor \log_2 \alpha \rfloor}$ 個，且每個神經元彼此間為全連接的狀況，而公式可寫為：

$$U^t = I^t \times w_i^t + bias_i \quad (10)$$

$$S^t = h_i^t \times kw_i^t \quad (11)$$

$$h_i^t = O_i^{t-1} \quad (12)$$

$$O_i^t = act(U^t + S^t) \quad (13)$$

其中 U^t 代表的是第 t 時間點的輸入項方程式。為當前輸入 I^t 乘上對應的權重值 w^t 並加上對應偏壓值 $bias_i$ ，而 S^t 則為前一個時間點的輸出(即 $h_i^t = O_i^{t-1}$)乘上其對應的遞迴權重值 kw_i^t 。最終將這兩項加總並輸入激活函數中則可獲得當前時間點的輸出 O_i^t 。

RBF-DRNN 的最後為多層的全連接層，其中層數是依據前一層神經元的數量而定的。假設前一層共有 α 個神經元，共會有 $\log_8 \alpha$ 層。在這層中，每個神經元都會整合來自前一層所有神經元的輸出，並將整合結果經過激活函數計算後輸出，而每一層第 i 個神經元的公式則可寫為

$$o_j = act(i_j \times w_{ij}) + b_j \quad (14)$$

其中 i_j 代表前一層神經元的輸出， act 可為任意的激活函數， w_{ij} 為前一層輸出對應的權重值， b_j 則是對應第 j 個神經元的偏壓值。

3.5 使用 RBF 函數結合 LSTM 建模

本節主要依循前一節的概念介紹所設計的 RBF-LSTM 模型，如圖 8 所示。基本上 RBF-LSTM 的模型架構與 RBF-DRNN 類似，前面皆由輸入層與 RBF 層構成，後面也同樣由全連接層構成。唯一不同處是遞迴層部分。因此以下僅就 RBF-LSTM 的遞迴層介紹，其他層的介紹則可參照前一節的說明。

在遞迴層部分，假設前一層具有 α 個神經元，則遞迴層將會有共有 $2^{\lfloor \log_2 \alpha \rfloor}$ 個神經元，且每個神經元彼此間為全連接的狀況，至於激活函數則使用各種常用的激活




圖 8 RBF-LSTM

函數，如 Sigmoid、ReLU、Tanh 等。然而相較於一般的遞迴層，此處的遞迴層額外考慮了輸入閘、忘記閘、記憶細胞向量、輸出閘、隱藏狀態向量等五個元素，分別為 i_t 、 f_t 、 c_t 、 o_t 、 h_t 並依序寫成如下的公式。

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci} \circ c_{t-1} + b_i) \quad (15)$$

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf} \circ c_{t-1} + b_f) \quad (16)$$

$$c_t = f_t \circ c_{t-1} + i_t \circ \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (17)$$

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co} \circ c_t + b_o) \quad (18)$$

$$h_t = o_t \circ \tanh(c_t) \quad (19)$$

其中上述式子中的 W_{xi} 、 W_{hi} 、 W_{ci} 、 W_{xf} 、 W_{hf} 、 W_{cf} 、 W_{xc} 、 W_{hc} 、 W_{xo} 、 W_{ho} 、 W_{co} 、 b_i 、 b_f 、 b_c 、 b_o 皆為權重值，會由類神經網路訓練後求得最佳解。

3.6 利用 RBF 函數取出深度學習模型所找出的特徵值

這個小節描述如何從訓練好的 RBF-DRNN 或是 RBF-LSTM 中取得對建模有用的特徵值。




圖 9 RBF 訓練過程示意圖

以下先描述使用 RBF 函數選取特徵值的概念，接著介紹數學作法。以下舉圖 9 為例說明 RBF 函數為何可以從深度學習模型中挑選適合建模的特徵值 (i.e., RBF-DRNN 或是 RBF-LSTM 的輸入)。為了簡化說明，在圖 9 模型中僅使用三個輸入，每個輸入會跟隨三個 RBF 函數，且假設整個模型已訓練完成。此外，圖 9 中內的數值則分別代表模型在 $t-2$, $t-1$, 以及 t 時候的數值。首先，觀察模型第一個輸入圖 9(a) 以及其經由 RBF 轉換後的三個特徵值。在三個轉換後的特徵值中，可以看到其數值都接近 0。換言之在任何時間點，這三個轉換後的特徵值輸入後續 DRNN 或是 LSTM 的數值都為 0，這並不會對 DRNN 或是 LSTM 的輸出造成任何影響。本論文認為這些轉換後的特徵值及他們所屬的輸入對建模並沒有幫助故予以刪除。接著觀察第二個輸入圖 9(b) 以及其轉換後的特徵值，在三個轉換後的特徵值中有兩個在不同時間點都有劇烈的變化，而一個數值都接近 0。在這個狀況下，這兩個劇烈變化的特徵值可能會對後續 DRNN 或是 LSTM 的輸出產生影響。因此，本論文認為透過這兩個特徵值可了解到模型第二個輸入對於建模可能是有幫助的因子。最終觀察第三個輸入圖 9(c) 以及其轉換後的特徵值，發現三者數值皆固定在 1、0.8，以及 0.3。乍看之下這些特徵值可能是會對後續 DRNN 或是 LSTM 的輸出造成影響。但在任意一種遞迴式類神經網路中，只要輸入在不同時間皆保持相同權

重的情況下，則這個輸入幾乎不會對網路輸出造成影響。換言之，第三個輸入轉換後的特徵值也不會對後續 DRNN 或是 LSTM 的輸出產生影響，所以模型的第三

個輸入對本論文來說也是對建模沒有幫助的因子。

表 3 各輪特徵挑選結果示意表

	第一輪	第二輪	第三輪	第四輪	第五輪	第六輪
特徵數量	300	280	170	110	100	80
模擬誤差	0.07	0.06	0.04	0.03	0.04	0.08

根據上述的概念，可發現一個輸入經過 RBF 函數轉換後的特徵值是否有劇烈變化會是一個判斷指標。因此，本論文以標準差為依據進行特徵值的選取。首先，先設定兩個閾值 δ 與 ε ，其中 δ 是標準差的門檻，若某個經由 RBF 函數轉換後特徵值的標準差大於 δ ，則認定這個轉換後的特徵值對後續模型的輸出有影響，反之則不影響。接著 ε 則是一個輸入是否被選取的門檻值。假設模型中每個輸入會跟隨 n 個 RBF 函數，且這些 RBF 所轉出特徵值的標準差有 m 個超過 δ ，則會檢驗 m/n 的數值是否大於 ε 。若大於，則代表這個輸入對於建模有幫助，反之，則沒有幫助而應該刪去。

一旦完成了上述挑選特徵值步驟後，即完成圖 5 研究流程圖中第二階段到第四階段一輪的步驟，亦即從第二階段所用的特徵值中找到對建模最有用的數個特徵值。然而，這樣一輪步驟所選取出來的特徵值不一定會是最佳解，所以會重複進行第二階段到第四階段多輪特徵挑選，不斷刪去對建模較無作用的特徵值，僅留下對建模最有用的特徵值。

最終在圖 5 研究流程圖中第二階段到第四階段多輪特徵挑選後，預期會得到如表 3 的結果，而每一輪的結果包含了擷取出來的特徵值編號、擷取出來的特徵值數量(意義等同於建置深度學習網路的成本)、利用本輪所擷取特徵值進行模擬後的誤差(意義等同於深度學習網路的效能)。

3.7 使用天際線查詢從所有結果中挑選最佳的特徵值

在利用上小節的方法獲得如表 3 的多輪特徵挑選結果後，本小節接著討論如何從多輪特徵挑選結果中找到最佳輪數選取結果。本論文會使用著名的天際線查詢來完成此部份的選擇，由於本節欲完成一個多條件選擇的議題，而天際線查詢

則是用來解決多條件選擇議題中最常被使用的方法。以下先解釋何謂多條件的選擇議題，接著介紹天際線查詢的定義，最後介紹本論文實現天際線查詢的作法。

多條件選擇，顧名思義是每個候選者都會擁有多個被考慮的條件，使用者必須同等的考慮這些條件，並依據這些條件挑選最適合自己者。舉例來說，表 3 中的每一輪結果為一個候選者，而這些候選者都有兩個條件，擷取出來的特徵值數量及誤差，這即是一個標準的多條件選擇問題。

天際線查詢在過去幾年來，都是協助使用者進行多條件選擇的主要方法之一，因為他能夠協助使用者選擇每個條件都較佳的候選者。其選取方法是透過「支配」的概念來達成，其中所謂的支配是指一個物件 A，在所有維度的表現都比另外一個物件 B 好或是相當，則稱 A 物件支配 B 物件。舉例來說，本論文目的找出最少輸入特徵數量達到預測誤差最小者，表 3 第二輪的結果特徵值數量 280、進行模擬後的誤差 0.06 都比第一輪的結果特徵值數量 300、進行模擬後的誤差 0.07 好，則稱第二輪的結果支配第一輪的結果。而天際線查詢則是協助本論文從所有資料中找出不被任何其他物件支配的物件。舉例來說，表 3 中的第一輪至第三輪結果都會被第四輪的結果支配，至於第四輪、第五輪結果與第六輪結果部分擷取出的特徵值數量較少，部分則是誤差較低，所以皆不能互相支配。最終在上述案例中，挑選第四輪、第五輪與第六輪結果為表 3 中的天際線結果，亦即本論文所謂的最佳特徵值選取方法。

為了避免產生多條天際線及增加天際線查詢效率，本論文採用 σ -Neighborhood 天際線查詢演算法，這種改良版的天際線查詢方法可以找出最合適的天際線及降低所需查詢資料點數量，加快查詢時間。舉例來說，以表 3 各輪特徵數量及模擬誤差結果，如果依照傳統天際線查詢演算法進行計算，第四輪、第五輪及第六輪應作為天際線。但以實際面來看，本論文追求(1)縮小模型所需的特徵數量及(2)良好的模擬誤差。而第六輪的查詢結果並非本論文所需的天際線，僅有第四輪同時滿足 2 種條件，該輪擁有最小預測誤差及縮小模型所需的特徵數量，

雖然特徵數量不是最少的一輪，但誤差在可容許的範圍內，故該輪將支配其他所有輪成為唯一條天際線，而這個方法核心加速查詢設計如下。

在進行該查詢演算法前必須先設定權重 w 及距離 σ 決定容許的誤差範圍，以本論文為例，模型所需的特徵數量不需要是最低，但不能超過容許範圍，設定完權重 w 及距離 σ 後，接下來進行以下步驟，首先把每一輪的結果，依據各輪所有維度數值乘上所對應的權重 w 進行加總由小到大排序，接著會從總和較小者 p ，依序讓該輪與其他輪總和較大者 q 做比較。在比較的過程中，有可能獲得以下兩種結果。(1)若 p 支配 q ，則 q 不可能成為天際線查詢的結果，所以該輪會直接從等待檢查的列表中刪除。(2)若 p 不能支配 q ，則 q 尚有機會成為天際線查詢的結果，所以該輪會被保留下來以待後續檢查。整個演算法將持續到沒有任何物件需要被檢查為止，最後，計算每條非天際線資料點與天際線資料點的距離是否小於 σ 。若小於 σ ，即為答案，否則不是答案。



第四章 實驗模擬

本章使用了真實空品資料集來驗證所提出方法的有效性與執行的效率。這章的內容預計分成四個部分，包含了資料集與實驗參數介紹、小波模型之最佳參數選擇與有效性驗證、本論文所提出模型之有效性驗證，以及本論文所選取特徵值之合理性說明。所有實驗是以 Python 完成，並操作在 Intel Core I7-8700K at 3.70GHz 的 CPU、Nvidia GTX 1080ti 11GB 的 GPU、搭配 DDR4 64GB 記憶體以及 Windows 10 的作業軟體來完成。

4.1 資料集與實驗參數介紹

本論文蒐集 2015 年 1 月 1 日 0 時至 2018 年 7 月 25 日 23 時台灣苗栗、台中、彰化、南投、馬祖等九個環保署空氣監測站之數值，其中這些地區的空氣監測站位置如圖 8 所示。對於每個站點抓取其每小時的空氣污染因子資料與每小時的氣候因子資料來做為空品的歷史資料集，並從中擷取各式特徵值，所有收集到的因子則列於表 4 上。而在本論文中目標空品預測對象則是位於所有收集到監測站中，位居中央的台中大里監測站。本論文預期使用其他監測站的所有空氣污染與氣象因子，以及台中大里監測站除去 PM2.5 的所有空氣污染與氣象因子作為依據來預測台中大里監測站的 PM2.5 數值。預測方式則是以所有輸入因子前 12 小時的數值來預測後 1 小時台中大里監測站的 PM2.5 數值。本論文所提出模型之各項參數設定則列於表 4 中，其中粗體的數字為預設值。首先在小波模型之拆解層數部分，會測試拆解成 2、4、6、8、10 層時，何者對空品資料取特徵值之結果為佳。接著在 RBF-DRNN 與 RBF-LSTM 的模型輸入部分，一開始總共會有 9 個監測站×12 種空氣與污染因子×小波模型所拆解出的 n 個特徵值。接著，針對每個模在 RBF 層型輸入，

表 4 空品影響因子

氣象因子	氣溫、風速、濕度、風向
空氣污染因子	O3, PM2.5, PM10, CO, NO, SO2, NO2, NOX




圖 8 監測站空間關係圖

使用 3 個神經元來做新特徵值的轉換，所以 RBF 層共有 $9 \times 12 \times 3 \times n = 324n$ 個神經元。特別的，在下一節的實驗會證實小波模型拆解成兩層時會有最佳解，並會把 n 預設為 2，所以本論文預設 RBF 層共有 $324 \times 2 = 648$ 個神經元。後續的遞迴層與全連接層神經元個數設為 24, 24, 12, 1。至於從深度學習模型中選取特徵值所需的標準差門檻值 δ ，本研究使用 0.1、0.15、0.2、0.25、0.3 來進行實驗。最終，針對一個輸入是否被選取的門檻值 ε ，因為針對每個輸入僅使用 3 個 RBF 函數，故將其設定為 $2/3$ ，亦即要有超過半數 RBF 函數認為這個輸入因子對建模是有益的入才會被本方法所取出。

最後為了驗證本論文方法的有效性，使用了兩種常見的深度學習預測模型效能評估方式，包含了平均絕對誤差(Mean Absolute Error, MAE)、均方根誤差(Root Mean Squared Error, RMSE)，然而不採用平均絕對百分比誤差(Mean Absolute Percentage Error, MAPE)作為模型績效驗證指標是由於 PM2.5 數值於部分時間段出現 ND 值，代表未檢出(i.e.,表示數據低於偵測極限 2 微克/立方公尺。)，在這種

表 5 小波分解層數於基礎模型績效比較

小波模型	Train RMSE	Test RMSE	Train MAE	Test MAE
NO	6.25	5.38	4.91	4.12
Level 2	4.63	4.52	3.61	3.30
Level 4	5.42	5.37	4.29	4.01
Level 6	6.87	7.32	5.32	5.44
Level 8	8.28	9.08	6.45	6.98
Level 10	8.12	9.89	6.33	7.81

情形下將數值替代為 0，則根據 Eq. (22) 公式分母為 0 會造成該方法無法被使用，然而如果將其替代為極小值，也容易造成評估指標失真，故選擇 MAE 及 RMSE 作為深度學習預測模型效能評估方式，其三者評估方式公式如下所示，其中 N 為資料總筆數、 d 為模型預測值、 y 為真實值、 i 為第幾筆資料。

$$MAE = \frac{1}{N} \left(\sum_{i=1}^N |d_i - y_i| \right) \quad (20)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (d_i - y_i)^2} \quad (21)$$

$$MAPE = \frac{1}{N} \sum_{i=1}^N \frac{|d_i - y_i|}{y_i} \times 100\% \quad (22)$$

4.2 小波模型之最佳參數選擇與有效性驗證

本小節主要進行與小波模型有關的驗證，包含了小波模型最佳參數的選擇以及有效性的驗證。首先在小波模型最佳參數選擇部分，共測試了使用 2、4、6、8、10 層小波模型來取特徵值，以及直接使用原始資料當特徵值(未使用小波模型)，並將這些特徵值直接輸入 RBF-DRNN 時的效果，其結果則如表 5 所示。

而在表 5 中，可以看到當使用兩層的小波模型來取特徵值會有最佳的模型結果。接著當使用越多層的小波模型來取特徵值，則模型效能會逐漸上升。至於不使用小波模型的狀況下，其模型效能則落在小波模型取 4 層到 6 層間。而因為本

表 6 使用原始資料因子作為特徵值直接放入不同模型訓練與預測之結果

Method	Train RMSE	Test RMSE	Train MAE	Test MAE
Decision Tree	6.37	6.84	4.87	5.04
MLP	6.86	5.95	5.42	4.51
Random Forest	5.80	5.88	4.50	4.49
RNN	6.25	5.38	4.91	4.12
SVR	8.58	7.28	6.34	5.77
LSTM	5.98	5.83	4.38	4.57

表 7 使用 2 層小波模型結果為特徵值並放入不同模型訓練與預測之結果

Method	Train RMSE	Test RMSE	Train MAE	Test MAE
Decision Tree	5.05	5.04	3.90	3.71
MLP	6.86	5.95	5.42	4.51
Random Forest	4.63	4.52	3.61	3.30
RNN	5.32	4.44	4.50	3.40
SVR	9.01	7.51	6.67	5.95
LSTM	4.91	4.41	3.81	3.40

文所使用的模型是以前 12 小時資料來預測未來 1 小時 PM2.5 數值。在小波模型拆解中，小波拆解層數越小代表物質越短時間的變化，反之則代表物質長時間的變化。因此，對於時間長度為三年的目標資料集，拆解完的第一層與第二層大致上都是表示 12 小時內的短期變化，若只輸入這兩層取出的特徵值，則可以提供模型最恰當的資訊而得到較佳的預測結果。而第三層以後的特徵值，因為代表的是長時間的變化，若將這些特徵值輸入模型中，這些特徵值不僅對模型沒有幫助還有可能誤導模型的預測並因此降低預測的準確率。因此依據表 5 的結果，在之後的模型會以 2 層的小波模型為主來取特徵值並訓練後續的模型。

在確認小波模型取的最佳層數後，接著討論將這樣的特徵值輸入其他的模型中，是否同樣能提昇其他模型的效率，其中選定的模型包含了過往常用於空品預測的模型，如 Decision Tree、MLP、Random Forest、RNN、SVR，以及僅有 LSTM 模型的狀況，每個模型都同樣是以過去 12 小時的資料預測未來 1 小時的 PM2.5 數值。這部份驗證結果如表 6 與表 7 所示，其中表 6 直接使用原始資料作為特徵值進模型訓練預測的結果，表 7 則是使用小波模型將資料拆解成 2 層取出特徵值進入模型的訓練預測結果。在比較兩張表格後，可以明顯發現除了 SVR 以外，所有模型在使用 2 層小波模型所取出特徵值為輸入進行訓練與預測時所獲得的成果都

較直接使用原始資料為佳。而這也代表了本論文提到使用小波模型來取特徵值的

表 8RBF-DRNN 搭配不同閾值的預測結果

STD 閾值	Train RMSE	Test RMSE	Train MAE	Test MAE	最終特徵值量
0.1	5.35	5.22	3.51	3.54	216
0.15	5.52	5.27	3.52	3.56	146
0.2	5.55	4.95	3.54	3.55	132
0.25	5.28	5.50	3.52	3.57	216
0.3	5.31	5.49	3.50	3.55	216

表 9RBF-LSTM 搭配不同閾值的預測結果

STD 閾值	Train RMSE	Test RMSE	Train MAE	Test MAE	最終特徵值量
0.1	4.77	5.29	3.49	3.55	175
0.15	5.02	4.73	3.52	3.53	146
0.2	5.00	5.07	3.52	3.56	216
0.25	4.79	5.33	3.50	3.56	216
0.3	5.08	5.50	3.49	3.54	216

表 10 過往方法預測之效能

方法	Train RMSE	Test RMSE	Train MAE	Test MAE
Decision Tree	6.64	5.62	5.04	4.28
Random Forest	6.00	5.67	4.44	4.43

方法確實有效。至於 SVR 方法，因為操作原理是將原始資料透過核函數映設到高維後再進行資料分析，但這部份的作法與小波模型的作法(以某種意義上也是把資料提升到高維)重疊。所以將資料先用小波模型轉換成高維，再進入 SVR 再把高維資料轉成更高維，造成後續分析效果不佳。

4.3 深度學習模型之最佳參數選擇

本小節主要討論本論文深度學習模型的最佳參數選擇，包含了(1)RBF-DRNN 與 RBF-LSTM 的效能比較，以及(2)RBF 特徵值選取閾值的設定，兩者討論如下，共測試 10 組實驗，包含了 RBF-DRNN 搭配閾值 0.1、0.15、0.2、0.25、0.3，以及 RBF-LSTM 搭配閾值 0.1、0.15、0.2、0.25、0.3，其結果則分別列於表 8 與表 9 中。

首先在 RBF-DRNN 與 RBF-LSTM 的效能比較上，從表 8 與表 9 中發現 RBF-DRNN 與 RBF-LSTM 的效能其實相去不遠，在不同參數的組合上互有領先，但領先範圍都在誤差範圍內。換言之，若要在真實問題上使用本論文模型，則兩者所能提供的效能都差不多。然而，若是考慮到運算成本，RBF-DRNN 的運算成本應該會比 RBF-LSTM 少，故建議在真實問題上僅使用 RBF-DRNN 即可。

表 11 使用 RBF-DRNN 所選取之特徵值，結合過往常用方法來進行預測之效能

方法	Train RMSE	Test RMSE	Train MAE	Test MAE
Random Forest	4.71	4.66	3.54	3.55
Decision Tree	5.02	5.03	3.77	3.79
MLP	5.89	5.13	4.53	3.96
LSTM	4.56	4.32	3.41	3.33
RNN	4.81	4.51	3.51	3.51

表 12 使用 RBF-LSTM 所選取之特徵值，結合過往常用方法來進行預測之效能

方法	Train RMSE	Test RMSE	Train MAE	Test MAE
Random Forest	4.63	4.66	3.49	3.55
Decision Tree	5.01	5.00	3.77	3.79
MLP	5.28	4.65	3.92	3.61
LSTM	4.43	4.51	3.31	3.52
RNN	4.81	4.51	3.51	3.51

至於閾值的設定，從表 8 與表 9 中可以看到不同閾值所產生出來的效果其實相去不遠，都在誤差範圍內。然而，若考慮到不同閾值所取出的特徵值數量，發現當閾值等於 0.15 時，兩個模型都會取出較少的特徵值，亦即在閾值等於 0.15 時，本論文方法所建立起的網路運算成本最小，故挑選 0.15 為後續實驗模擬所用的閾值。

4.4 本論文方法取出之特徵值有效性驗證

本論文提出了一個使用深度學習模型取出對空品預測來說較適合特徵值的方法。本節則嘗試說明取出的特徵值真的對空品預測有幫助。為了驗證這點，本論文的方法與過往方法做比較，其中過往方法包含了(1)使用 Decision Tree 從原始資料中取出特徵值，並使用 Decision Tree 來進行預測，以及(2)使用 Random Forest 從原始資料中取出特徵值，並使用 Random Forest 來進行預測。至於本論文先使用 2 層的小波模型結合 RBF-DRNN 與 RBF-LSTM 選取特徵值，並將這些特徵值分別輸入過往常用的各種方法，如 Random Forest、Decision Tree、MLP、LSTM、RNN 進行訓練與預測，其結果則列於表 10 到表 12 中。而在表 10 到表 12 中，可明顯發現本論文方法應用在過往常見的預測方法上效能都會比過往僅使用 Random Forest 或 Decision Tree 挑選特徵值來預測的準確，而這也證實了本論文方法的有效性。

表 13 本論文方法最常被挑選到的 53 種特徵值。

地區	特徵挑選結果					
大里	amb_temp_a2	amb_temp_d1	CO_d1	NO2_a2	NO2_d1	NO_d1
	NOX_d1	O3_d1	PM10_a2	PM10_d1	PM2.5_a2	PM2.5_d1
	rh_a2	rh_d1	Wind_dir_a2	Wind_dir_d1	Wind_speed_d1	
西屯	CO_d1	NO2_d1	NO_d1	NOX_d1	O3_a2	O3_d1
	PM10_d1	PM2.5_d1	rh_a2	rh_d1	Wind_dir_a2	Wind_dir_d1
	Wind_speed_d1					
沙鹿	amb_temp_a2	amb_temp_d1	NO2_d1	NOX_d1	O3_d1	PM10_a2
	PM10_d1	PM2.5_d1	rh_a2	rh_d1	SO2	
忠明	O3_d1					
豐原	O3_d1	Wind_dir_a2	Wind_dir_d1			
線西	amb_temp_a2	O3_a2	PM2.5_d1			
埔里	o3_a2	pm10_d1				
馬祖	PM2.5_d1					

4.5 本論文所選取特徵值之合理性說明

在使用上述小節證實本論文方法效能的確優於其他方法後，接著驗證小波模型結合深度學習方法所取出之特徵值確實符合大氣科學的常理，表 13 為本論文方法最常被挑選出與台灣台中大里監測站 PM2.5 數值最相關的 53 種特徵值。在該表中若以空間來看，可以看到 53 種特徵值中最常出現的監測站分別為大里、西屯與沙鹿。其次常出現的監測站則為豐原與線西。以常理判斷，大里最多物質被判斷為重要特徵是可被預期的結果，因為以自身過去數據判斷自身未來狀況通常會是最準確的預測。西屯與沙鹿，這兩個觀測站在空間上都位於大里觀測站的西北方，而在台灣地區 PM2.5 數值主要來自冬季隨東北季風從大陸地區吹來的污染物質，故若有污染物質飄來，則位於西北方的觀測站會較先遇到，便有警示效果。此觀點也同樣可解釋為何線西特徵值也會經常被取出，原因為線西與大里同樣位於大甲溪的河谷，若有污染物質從西方沿河谷傳來，則必然會先經過線西再抵達大里。至於豐原，雖然不位於大里觀測站的西北方，但也被挑選出來。這是因為豐原是台灣中部工廠最聚集的區域之一，這些工廠產生很多污染物質，若風向正確，仍會飄到隔壁的大里。而這點也能從豐原被挑選到的特徵值證實，因為豐原被挑選到的特徵值與其他觀測站不同，幾乎沒有污染物質，主要是風向。同時也代表著

若風向正確，豐原空品優劣的確會影響到大里地區空品。整體而言，可以從表 13 中驗證所提出方法的正確性。



第五章 結論與未來研究

短時間內數值高度變化一直是預測 PM2.5 難以掌握的關鍵，對於這部分所產生的問題，本論文使用小波分解將影響 PM2.5 因子進行訊號拆解，增加模型對資料的解析能力，同時結合遞迴式深度類神經網路進行時間序列預測，與普遍模型最大的不同，本論文加入 RBF 函數於遞迴式深度類神經網路輸進行特徵挑選，並設計一系列實驗(有無進行小波分解、遞迴深度類神經網路選擇、小波分解層數及特徵閾值條件)證實本論文方法的有效性，另外使用常見時間序列模型評估方法 RMSE、MAE 找出模型最佳參數設定，最後使用天際線查詢演算法找尋最佳訓練輪數及其所挑選出的重要特徵。

在實驗結果中，本論文證實提出的方法效能的確優於其他方法，能在不失去誤差的前提下，減少模型訓練所需特徵數量，將能改善深度學習耗時、耗能的詬病，且所設計的模型挑選出的特徵值也符合大氣上的常理，實質的幫助研究人員辨別重要影響因子。

在未來研究中，可以再針對其他監測站進行相同實驗，找出監測站彼此之間的影響，進一步推論影響各地區空品的因素，這不僅是準確預測空品，更是為了找出問題。最後此技術除了運用於空氣預測領域，也能嘗試應用於其他時序型研究的特徵擷取，相信都可以有相當不錯的表現。

參考文獻

中文文獻

- [1] 環保署/國科會空汙防治科研合作計畫(2013)。細懸浮微粒(PM2.5)時空分布特性之研究。
- [2] <https://taqm.epa.gov.tw/taqm/tw/b0203.aspx>(行政院環保署空氣品質監測網)
- [3] 莊秉潔(2010)，國光石化營運造成 PM2.5 與健康及能見度影響。

英文文獻

- [1] P. E. Saide, G. R. Carmichael, S. N. Spak, L. Gallardo, A. E. Osses, M. A. Mena-Carrasco, and M. Pagowski, "Forecasting urban PM10 and PM2.5 pollution episodes in very stable nocturnal conditions and complex terrain using WRF-Chem CO tracer model," *Atmospheric Environment*, vol. 45, no. 16, pp. 2769-2780, 2011.
- [2] P. Wang, H. Zhang, Z. Qin, and G. Zhang, "A novel hybrid-Garch model based on ARIMA and SVM for PM2.5 concentrations forecasting," *Atmospheric Pollution Research*, vol. 8, no. 5, pp. 850-860, 2017.
- [3] U. Kumar, and K. De Ridder, "GARCH modelling in association with FFT-ARIMA to forecast ozone episodes," *Atmospheric Environment*, vol. 44, no. 34, pp. 4252-4265, 2010.
- [4] X. Feng, Q. Li, Y. J. Zhu, J. X. Hou, L. Y. Jin, and J. J. Wang, "Artificial neural networks forecasting of PM2.5 pollution using air mass trajectory based geographic model and wavelet transformation," *Atmospheric Environment*, vol. 107, pp. 118-128, Apr, 2015.
- [5] M. Cai, Y. Yin, and M. Xie, "Prediction of hourly air pollutant concentrations near urban arterials using artificial neural network approach," *Transportation Research Part D: Transport and Environment*, vol. 14, no. 1, pp. 32-41, 2009.

- [6] F. Biancofiore, M. Busilacchio, M. Verdecchia, B. Tomassetti, E. Aruffo, S. Bianco, S. Di Tommaso, C. Colangeli, G. Rosatelli, and P. Di Carlo, "Recursive neural network model for analysis and forecast of PM10 and PM2.5," *Atmospheric Pollution Research*, vol. 8, no. 4, pp. 652-659, 2017.
- [7] B. S. Freeman, G. Taylor, B. Gharabaghi, and J. Thé, "Forecasting air quality time series using deep learning," *Journal of the Air & Waste Management Association*, vol. 68, no. 8, pp. 866-886, 2018.
- [8] Y. Zhou, F.-J. Chang, L.-C. Chang, I. F. Kao, and Y.-S. Wang, "Explore a deep learning multi-output neural network for regional multi-step-ahead air quality forecasts," *Journal of Cleaner Production*, vol. 209, pp. 134-145, 2019.
- [9] J. Wang, and G. Song, "A Deep Spatial-Temporal Ensemble Model for Air Quality Prediction," *Neurocomputing*, vol. 314, pp. 198-206, 2018.
- [10] S. Han, H. Mao, and W. J. J. a. p. a. Dally, "Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding," *International Conference on Learning Representations*, 2016
- [11] H. Li, J. Wang, R. Li, and H. Lu, "Novel analysis–forecast system based on multi-objective optimization for air quality index," *Journal of Cleaner Production*, vol. 208, pp. 1365-1383, 2019.
- [12] S. Sani, N. Wiratunga, S. Massie, "Learning deep features for knn based human activity recognition," *Proceedings of the International Conference on Case-Based Reasoning Workshops*, pp. 95-103, 2017.
- [13] Mohammad, Y., Matsumoto, K., & Hoashi, K. "Deep feature learning and selection for activity recognition," *Proceedings of the 33rd Annual ACM Symposium on Applied Computing. ACM*, 2018.

- [14] J. Brown, T. Gordon, O. Price, and B. Asgharian, "Thoracic and respirable particle definitions for human health risk assessment," *Particle and fibre toxicology*, vol. 10, no. 1, 2013.
- [15] A. Valavanidis, K. Fiotakis, and T. Vlachogianni, "Airborne Particulate Matter and Human Health: Toxicological Assessment and Importance of Size and Composition of Particles for Oxidative Damage and Carcinogenic Mechanisms," *Journal of Environmental Science and Health, Part C*, vol. 26, no. 4, pp. 339-362, 2008.
- [16] L. Zhou, X. Chen, and X. Tian, "The impact of fine particulate matter (PM_{2.5}) on China's agricultural production from 2001 to 2010," *Journal of Cleaner Production*, vol. 178, pp. 133-141, 2018.
- [17] M. Hatzopoulou, S. Weichenthal, H. Dugum, G. Pickett, L. Miranda-Moreno, R. Kulka, R. Andersen, and M. Goldberg, "The impact of traffic volume, composition, and road geometry on personal air pollution exposures among cyclists in Montreal, Canada," *Journal of Exposure Science And Environmental Epidemiology*, vol. 23, pp. 46, 2012.
- [18] M. E. Marlier, R. S. DeFries, A. Voulgarakis, P. L. Kinney, J. T. Randerson, D. T. Shindell, Y. Chen, and G. Faluvegi, "El Niño and health risks from landscape fire emissions in southeast Asia," *Nature Climate Change*, vol. 3, pp. 131, 2012.
- [19] M.-P. Wan, C.-L. Wu, G.-N. Sze To, T.-C. Chan, and C. Y. H. Chao, "Ultrafine particles, and PM_{2.5} generated from cooking in homes," *Atmospheric Environment*, vol. 45, no. 34, pp. 6141-6148, 2011.
- [20] K. Siwek, and S. Osowski, "Improving the accuracy of prediction of PM₁₀ pollution by the wavelet transformation and an ensemble of neural predictors," *Engineering Applications of Artificial Intelligence*, vol. 25, no. 6, pp. 1246-1258, 2012.

- [21]I. B. Konovalov, M. Beekmann, F. Meleux, A. Dutot, and G. Foret, “Combining deterministic and statistical approaches for PM10 forecasting in Europe,” *Atmospheric Environment*, vol. 43, no. 40, pp. 6425-6434, 2009.
- [22]P. J. García Nieto, F. Sánchez Lasheras, E. García-Gonzalo, and F. J. de Cos Juez, “PM10 concentration forecasting in the metropolitan area of Oviedo (Northern Spain) using models based on SVM, MLP, VARMA and ARIMA: A case study,” *Science of The Total Environment*, vol. 621, pp. 753-761, 2018.
- [23]K. P. Singh, S. Gupta, and P. Rai, “Identifying pollution sources and predicting urban air quality using ensemble learning methods,” *Atmospheric Environment*, vol. 80, pp. 426-437, 2013.
- [24]S. Park, M. Kim, M. Kim, H.-G. Namgung, K.-T. Kim, K. H. Cho, and S.-B. Kwon, “Predicting PM10 concentration in Seoul metropolitan subway stations using artificial neural network (ANN),” *Journal of Hazardous Materials*, vol. 341, pp. 75-82, 2018.

