

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

利用 RBF-DNN 配合醫院病患人流資料探究

流行病之院內感染熱區

Using RBF-DNN with Hospital Patient Flow Data to  
Explore the Epidemic of Nosocomial Infection Hotspots

施長宏

Chang-Hung Shih

指導教授：蘇純繒 博士

Advisor: Chun-Zeng Su, Ph.D.

共同指導教授：陳奕中 博士

Co-Advisor: Yi-Chung Chen, Ph.D.

中華民國 112 年 6 月

June 2023

## 摘要

自 2019 年年底爆發新冠肺炎疫情開始，民眾的生活開始受到嚴重影響。不僅進出各室內場所需要進行實名管制，還要在接觸到確診者後被隔離 14 天，並造成生活上的各種不便。而這的規定對醫療人員來說更是惡夢般的存在，因為醫院身為面對疾病的第一線，必然有高機率會接觸到新冠肺炎的患者，讓醫療人員被隔離的機率遠高於一般民眾。有鑑於此，本論文提出利用徑向基函數深度學習模型這個可解釋化 AI 來探討以下兩件事，包含(1)當有患者進入醫院後，醫院各區域可能會接觸到確診者的人數、以及(2)醫院中可能會接觸到確診者的熱區。最終，本論文的實驗結果則證實了我們所提出方法的有效性。此外藉由我們的討論結果，我們預期未來能協助醫院進行兩個改善項目，包含(1)未來在任何確診者進入醫院後，準確匡列可能的接觸者，而非全院的人都匡列及隔離，以及(2)讓醫院在未來能針對院內可能接觸到確診者的熱區進行空間調整，像是改變診間位置等，以期讓院內人員與民眾接觸到確診者的機率最小化。

**關鍵字：**傳染預測、院內感染、RBF-DNN、Arena 系統模擬

## ABSTRACT

The effects of the new crown pneumonia outbreak at the end of 2019 have been severe. Control of the epidemic requires registration to enter and exit various indoor places, as well as 14-day quarantines following contact with a confirmed case. This regulation is particularly inconvenient for medical staff, who, as the front line in disease treatment and prevention, have a high probability of exposure. This paper thus proposes using the radial basis function deep learning model, an interpretable AI, to determine the following: (1) the number of people who may be exposed to confirmed cases in each area of the hospital each time a patient enters the hospital and (2) hot areas in the hospital where contact with confirmed cases is likely. Experimental results confirm the effectiveness of the proposed method. Future directions for research include (1) creating an accurate list of contacts for confirmed cases rather than a general list of all the people in the hospital and isolation and (2) allowing the hospital to make space adjustments for hot areas, such as changing the location of clinics, to minimize the chances of hospital personnel and the public coming into contact with confirmed cases..

**Keywords:** Infection prediction, hospital infection, RBF-DNN, Arena system simulation

## 目錄

|                                    |     |
|------------------------------------|-----|
| 摘要 .....                           | I   |
| ABSTRACT .....                     | II  |
| 目錄 .....                           | III |
| 表目錄 .....                          | V   |
| 圖目錄 .....                          | VII |
| 第一章 緒論 .....                       | 1   |
| 1.1 研究背景與動機 .....                  | 1   |
| 1.2 研究目的 .....                     | 3   |
| 1.3 研究範圍及限制 .....                  | 4   |
| 1.4 研究流程 .....                     | 5   |
| 第二章 文獻回顧 .....                     | 7   |
| 2.1 流行病感染傳播預測 .....                | 7   |
| 2.1.1 流行病模型 .....                  | 7   |
| 2.1.2 機器學習方法 .....                 | 8   |
| 2.1.3 深度學習方法 .....                 | 9   |
| 2.2 特徵提取 .....                     | 9   |
| 2.3 系統模擬 .....                     | 10  |
| 2.4 合成資料 .....                     | 11  |
| 第三章 資料集 .....                      | 12  |
| 3.1 病患就診資料集介紹 .....                | 12  |
| 3.2 臺大醫院雲林分院一樓平面圖 .....            | 12  |
| 第四章 研究方法 .....                     | 14  |
| 4.1 資料清洗 .....                     | 15  |
| 4.2 建立 ARENA 模擬 .....              | 17  |
| 4.2.1 醫院模組設計 .....                 | 18  |
| 4.2.2 模組參數定義 .....                 | 19  |
| 4.2.3 確診者行動資料集前處理 .....            | 22  |
| 4.3 尋找感染關鍵網格 .....                 | 22  |
| 4.3.1 建立與訓練 RBF-DNN .....          | 23  |
| 4.3.2 利用 RBF-DNN 取出關鍵高風險感染網格 ..... | 25  |
| 4.4 評估 RBF-DNN 模型之指標 .....         | 27  |
| 4.5 簡易 AI 模型 .....                 | 28  |
| 第五章 實驗模擬 .....                     | 29  |
| 5.1 資料集前處理及實驗參數介紹 .....            | 29  |
| 5.2 ARENA 模擬與密切接觸者匡列紀錄 .....       | 30  |

|                                   |    |
|-----------------------------------|----|
| 5.2.1 普通病患人數分布函數及診間服務時間分布函數 ..... | 30 |
| 5.2.2 模型建立 .....                  | 37 |
| 5.3 RBF 模型參數選擇及實驗、績效評估 .....      | 46 |
| 5.4 RBF 網格拆解及機器學習模型績效評估 .....     | 49 |
| 第六章 結論與未來研究 .....                 | 52 |
| 參考文獻 .....                        | 53 |



## 表目錄

|                                           |    |
|-------------------------------------------|----|
| 表 1 病患就診時序資料 .....                        | 12 |
| 表 2 病患就診時序資料 .....                        | 15 |
| 表 3 本研究主要使用到的 Arena 基本流程模組定義 .....        | 18 |
| 表 4 院內每小時的網格人數示意圖 .....                   | 22 |
| 表 5 確診者經過的網格示意圖 .....                     | 22 |
| 表 6 Input Analyzer 生成各診間的人數到達間隔時間分布 ..... | 31 |
| 表 7 Input Analyzer 生成各診間的病患人數分布 .....     | 33 |
| 表 8 Input Analyzer 生成各診間的候診看診時間分布 .....   | 35 |
| 表 9 Create 模組參數設定-一般看診病患 .....            | 37 |
| 表 10 Create 模組參數設定-確診病患 .....             | 38 |
| 表 11 Assign 模組參數設定 .....                  | 39 |
| 表 12 Process 模組參數設定 .....                 | 40 |
| 表 13 相同候診區 Decide 參數設計 .....              | 41 |
| 表 14 是否為密切接觸者須進行匡列 Decide 模組設計 .....      | 42 |
| 表 15 需要匡列人數 Record 參數設計 .....             | 43 |
| 表 16 確診者進入人數 Record 參數設計 .....            | 44 |
| 表 17 確診進入人數為 Max1 的匡列結果 .....             | 45 |
| 表 18 確診進入人數為 MAX1 的確診者進入數模擬結果 .....       | 45 |
| 表 19 RBF-DNN 訓練資料集-以 MAX1 為例 .....        | 46 |
| 表 20 3RBF-DNN 無重要特徵篩選績效 .....             | 47 |
| 表 21 3RBF-DNN 重要特徵篩選績效 .....              | 48 |
| 表 22 4RBF-DNN 無重要特徵篩選績效 .....             | 48 |
| 表 23 4RBF-DNN 重要特徵篩選績效 .....              | 48 |

|                                   |    |
|-----------------------------------|----|
| 表 24 4RBF-DNN 搭配不同閥值結果-MAX1 ..... | 49 |
| 表 25 RBF 關鍵網格輸出 .....             | 49 |
| 表 26 隨機森林績效表 .....                | 50 |



## 圖目錄

|                                               |    |
|-----------------------------------------------|----|
| 圖 1 院內感染示意圖 .....                             | 1  |
| 圖 2 常用防疫措施：實名制登陸、社交距離 APP .....               | 2  |
| 圖 3 研究架構圖 .....                               | 6  |
| 圖 4 臺大醫院雲林分院一樓平面示意圖(翻攝於院內告示牌).....            | 13 |
| 圖 5 門診區網格編碼示意圖 .....                          | 13 |
| 圖 6 研究方法流程圖 .....                             | 14 |
| 圖 7 病患看診軌跡重建示意圖 .....                         | 16 |
| 圖 8 台大斗六院區網格示意圖 .....                         | 17 |
| 圖 9 病患時序網格示意圖 .....                           | 17 |
| 圖 10 一般病患進院看診流程 .....                         | 18 |
| 圖 11 台大斗六院區掛號處等候區示意圖 .....                    | 19 |
| 圖 12 台大斗六院區骨科、牙科、外科診間候診區示意圖 .....             | 20 |
| 圖 13 Arena 模擬軟體建構院內模型(以掛號處為例).....            | 20 |
| 圖 14 Arena 模擬軟體建構院內模型(以骨科、牙科、外科為例).....       | 20 |
| 圖 15 RBF-DNN 研究方法流程圖 .....                    | 22 |
| 圖 16 資料攤平過程 .....                             | 23 |
| 圖 17 RBF-DNN 模型架構圖 .....                      | 25 |
| 圖 18 使用 RBF 來找出重要欄位的案例，(a)案例 1，(b)案例 2。 ..... | 27 |
| 圖 19 Input Analyzer 院內各診間的病患進入時間間隔分布長條圖 ..... | 32 |
| 圖 20 Input Analyzer 院內各診間的病患人數分布長條圖 .....     | 34 |
| 圖 21 Input Analyzer 院內各診間的候診看診時間分布長條圖 .....   | 36 |
| 圖 22 MAX1(a)資料分布、(b)訓練結果 .....                | 46 |
| 圖 23 分段正規化後的模擬資料分布示意圖 .....                   | 47 |



|                                        |    |
|----------------------------------------|----|
| 圖 24 隨機森林測試圖(a)7:3、(b)8:2、(c)9:1 ..... | 51 |
|----------------------------------------|----|



## 第一章 緒論

### 1.1 研究背景與動機

「避免群聚感染」、「防止並減少防疫破口」都是近年來各大新聞媒體刊登的標題。為了減少感染源，除了打疫苗以外，避免過多的人在同一個空間接觸也是一種有效的防疫方式。然而因為科技的便利性，如：遠距上班、線上課程、網路購物、外送平台，所以絕大部分的業務都是能在家完成，但當中仍容易造成群聚感染的地方就是醫院，疫情初期，還沒有「不舒服先快篩」的醫療資訊，也未有該部分的醫療資訊，許多病患並不知道自己已經確診，仍舊會到醫院看病，無形中形成另一條新的傳播鏈。如圖 1，假如今天這位病患在不知道自己已經確診的情況下，前往醫院定期回診，從該位病患進入醫院掛號後，進入診間，到最後前往藥局領藥離開，當中可能會跟許多不同病患間有間接接觸，而導致其他病患或是醫護人員因此感染新冠肺炎或被隔離 14 天。




圖 1 院內感染示意圖

過去在疫情控管上，使用的方法大致分為三種分別是(1)QRcode 實名制、(2)社交距離 APP 如圖 2(a)、(b)，來注意是否有和確診者有過密切接觸的訊息，進而進行通報檢查，而當有確診者出現時，通常是採取(3)全部框列的方式，與確診者出現在同一區域的民眾，皆會收到通知，在疫情初期都需要至醫院進行病毒篩檢，來確

保自己是否需要進行隔離。這些方式或許在某種程度上能夠抑制傳染，但也存在著不少問題，例如：(一)在大型設施通常，如：醫院，只會在大門口處設有實名制掃碼，在進入醫院後，即使有相關就診資料也很難，甚至無法得知病患的移動資訊；(二)因為 APP 並不是全民強制安裝且不能保證用戶習慣的一致性，就防疫層面的效果並不是那麼全面，仍會有漏網之魚，而間接變成防疫漏洞；(三)利用全部框列的方式，行政上雖然簡單，但後續對於醫療資源的消耗巨大，可能病患 A 今天去看骨科，而確診者是去看耳鼻喉科，但卻因為和確診者是同一天就診經過相同的路線而被匡列，不僅需要耗費民眾的時間，醫院也需要對於這些並非潛在危險群的民眾動員人力資源，而且反倒有可能有民眾因為被框列到醫院做檢查而使其再次暴露在可能染疫的風險當中。



圖 2 常用防疫措施：實名制登陸、社交距離 APP

既然如此，對於院內傳播感染預測的研究就十分重要了，一方面是因為醫療資源的稀缺性，一方面則是盡力避免民眾有再次暴露在疫情高風險區的可能性。近年政府與學者也意識防疫方式的問題，並開始對其投入研究，方學者[15]於 2006 年通過空間蒙特卡羅模型分析在香港醫院內的控制措施效果，以此降低院內感染的可能性，Tanade[40]於 2019 年開發了一個基於 Hasenöhl 的 SEIHRFD 模型的分區模型，減少 EVD 在院內隔離區的感染率，Patel *et al.*[31]於 2021 年提出針對 COVID-19 傳播的數學模型 SEIHRD 對於進出隔離室的醫護人員進行感染傳播預測，Rathnayaka *et al.*[34]在 2020 年利用接觸者追蹤系統(BLE)紀錄醫護人員進出院

內隔離室的時間等交互信息，協助院方制定感染預防政策，Abbas *et al.*[2]於 2021 年結合流行病學和遺傳數據配合 SIR 模型進行院內爆發的重建，藉此找出院內感染傳播鏈，Pei *et al.*[32]於 2021 年提出利用動態規畫的方式來找出醫療資源的最佳化使用，幫助流行病爆發期間的醫療資源分配。

綜合過往研究，發現雖然有關於院內感染傳播預測的研究，但是研究區域及對象都著重在已經確診且待在隔離區的病患和負責值班的醫護人員，在重建傳播鏈或是感染預測相對比較單一，對於在疫情初期，因為被匡列而為了確認自己是否確診而突然湧入的大批人潮，是目前研究的模型無法預估的情況，而對於醫院而言，相較於已經確定的確診的病患，那些因為被匡列而湧入醫院進行篩檢或是那些根本不確定自己是否已經確診的病患，將裡面真正的潛在危險群篩選出來，才是現今的首要目標，相較於只有隔離室，一般的門診區聚集了更多不同病症的患者且相對而言路徑也較不單一，加上因為我們並不知道誰是確診者誰不是確診者，而目前並無將普通診區的傳染預測與院內人流結合的相關研究，所以，本研究希望在此提出一個新的概念預測院內診區的之傳染區域並進行分析，詳細作法將在下一節進行說明。

## 1.2 研究目的

有鑑於上述方法在防疫上的不便與缺陷，以及現在在該領域並無對於普通診區的感染傳播預測研究，針對上述問題，本研究將在此提出一個全新的概念來找出最有可能發生病患聚集的診區，並將其提供給醫院制定政策來降低該區域的病患數量如:更換門診位置、採用分流看診的方式，以此降低院內發生感染的機率。

本研究提出兩個方法來達成上述目標，包含(1)使用 Radial basis function (RBF) 結合深度學習模型進行建模，為我們找出在醫院中染疫風險較高的診間，以及(2)使用 Arena 軟體模擬醫院有確診者進入時的傳播情形，藉此方式建立有感染傳播的資料集。首先我們會提出第一個方法，是因為 RBF 函數已被證實若被加在類神

經網路之前，則可被用來解釋類神經網路的哪些輸入是對輸出有重要影響的。像是近期曾有學者利用 RBF 來對關鍵因子進行不同主題的探討，如找尋 PM2.5 預測[6]、台北捷運運量預測[8]，甚至是刀具磨耗預測[9]的關鍵因子等。而本論文即打算透過 RBF 函數這樣的特性，以醫院內所有空間的人流數量當做出網路輸入，而可能接觸到確診者的人數當做輸出，最終找出醫院哪些空間是接觸到確診者的熱區。接著我們會提出第二個方法，是因為並不是每天都會有確診者出現在醫院造成院內有傳播的現象發生，舉例說明:2020/01/01 早上 10:00 發現皮膚科有確診者出現，造成一傳播鏈，而接下來幾天乃至幾個禮拜，或許因為都沒有相似情況發生，導致訓練資料不足，因此我們在訓練上述網路前必然得先進行資料擴增。但我們也必須了解到我們要擴增的資料是具有隨機特性的人類的移動軌跡而非一般的數值資料，因此並非使用傳統方法，如 Synthetic Minority Over-sampling Technique (SMOTE)等可以擴增的。因此本研究提出使用 Arena 軟體模擬醫院有確診者進入時的傳播情形，藉此方式建立有感染傳播的資料集。特別的，我們選用 Arena 是因為他能產生具隨機性的資料、模擬物件在場所之間移動的狀況，以及記錄上述過程的能力，而這些功能恰符合本論文所需。最終在我們將上述兩個演算法合併後，我們預期能達成本論文的目標並對醫院在傳染病的管控上產生巨大的貢獻。

### 1.3 研究範圍及限制

因本研究是與台大醫院雲林分院斗六院區(以下簡稱台大斗六院區)合作進行，研究範圍訂為台大斗六院區的門診區，研究的時間範圍為 2021 年全年，並有以下限制：

(1)為了維護病患隱私問題及受限於資料集，我們無法知道個別病患在隨著時間變化下的移動行為跟時間，此處將假設為各科門診的最短移動距離且不額外考慮病患中途去超商購物或去廁所的狀況。

(2)受限於資料集，無法得知病患是否為確診者，後續確診者資料將利用模擬



的方式進行訓練資料集的建構。

(3)考慮到病患是在不確定確診情況下至醫院就醫，將研究區域指定在人流量較大的一樓門診區，將針對一樓門診區進行本次研究探討。

(4)醫院的門診有分為候診區共用以及有單獨候診區的診間，考慮到地緣關係，在此會將模型進行分開模擬，將有相同候診區的診間進行同步模擬。

## 1.4 研究流程

本研究的架構流程圖如圖 3 所示，共包含六個階段，以下將進行說明：

### 1. 確認研究方向並定義問題

說明現在的防疫方式存在的問題，並針對過往傳染預防研究進行討論，發現並不能有效在疫情初期進行遏止，在此提出一種結合醫院人流在確診發生時可以精確匡列人數的方法架構，針對合作醫院進行預測。

### 2. 相關文獻回顧

回顧過往對於院內感染預測、院內人流分析的相關文獻，以及本研究會使用到的深度學習模型和資料生成方式研究的文獻，進行整理及總結。

### 3. 資料蒐集、前處理

本研究使用的是台大斗六院區提供之病患就診資料，時間為 2021 全年，在取得資料集後，進行資料觀察，對於有問題資料進行處理。

### 4. 建立研究方法

利用模擬軟體模擬醫院有確診者進入時的感染情況，待新的訓練資料集建立完成後，整理成適合輸入至模型的資料格式，建立深度學習模型進行特徵篩選。

### 5. 模型結果輸出

輸出深度學習模型抓取到的重要特徵，並對模型進行績效評估。

### 6. 結論與討論

根據研究目的定義，觀察輸出結果並做結論，接著對於未來可進行的研究方向

進行討論。




圖 3 研究架構圖

## 第二章 文獻回顧

在本章節中將會針對與本研究相關的過往研究進行回顧，將分為以下小節進行介紹:(1)流行病感染傳播、(2)特徵提取、(3)系統模擬、(4)合成資料。

### 2.1 流行病感染傳播預測

自從 2019 年，新冠肺炎開始肆虐全球，隨著有關 COVID-19 的公共數據越來越多，越來越多研究開始從不同方面了解和預防 COVID-19 的傳播[3][4]。其中，一個重要的研究方向是對 COVID-19 傳播進行建模和預測，例如預測感染爆發的規模。這樣的結果可以幫助政府機構更好地了解該疾病的總體影響，也有助於決策者在大流行病的應對策略制定，例如:分配醫療資源。現今通常在感染傳播預測方面通常分為三種方法:(1)流行病模型、(2)機器學習模型、(3)深度學習模型，下面將會分為三個小節對於相關研究進行回顧。

#### 2.1.1 流行病模型

在大流行病盛行時，流行病模型是一種被廣泛使用來進行傳染預測的方法，例如:由 Kermack 和 McKendrick[25]在 1927 年提出的易感-感染-抗性模型，由 Hethcote[18]在 2000 年提出的易感-暴露-感染-移除模型，這些模型因對於傳播動態的預測準確度高[53]，所以常被用來做為流行病的傳播預測，Jonathan *et al.*[35]在疫情爆發初期，使用 SIR 模型結合傳播模型對於中國其他城市感染人數及規模進行預測，發現與中國境外發現的報告病例相當。Kuzdeuov *et al.*[26]提出一個開源隨機流行病模擬器，將國家建模為網路，節點則為行政區域並在各節點分別使用 SEIR 模型，以此模擬在人口流動的情況下的感染情形，並用以模擬政策執行的效果，表明不同地區應使使用不同政策來減少感染發生。Cooper *et al.*[12]在藉由增強基礎的 SIR 模型來提高不同國家在傳染預測的精準度。

上述大多數研究都考慮了經典的流行病模型，例如易感-感染-抗性模型和 易感-暴露-感染-移除模型模型，並根據公開報告的數據進行分析。然而，由於檢測能



力和無症狀患者等原因，很多傳染性病例未經過檢測，甚至可能檢測不足，因此公開報告的病例數(包括確診病例和康復病例)往往遠少於實際數字。導致易感-感染-抗性模型和易感-暴露-感染-移除模型等經典流行病模型無法準確表徵 COVID-19 的流行病演變。此外，也因為數據不足的關係，大多數研究都是以國家為預測單位 [53]。

### 2.1.2 機器學習方法

機器學習是透過演算法將資料進行分類或是進行預測模型訓練，需要以定義特徵的過程進行資料的標記，收集到的數據才足以提供機器學習可以理解的標籤進行訓練，最後根據所學特徵分類資料。例如: Rustam *et al.* [37] 比較四種機器學習方法: 指數平滑法、支援向量機、線性回歸、套索算法，對於 COVID-19 進行短期預測，發現根據當前情況的模型預測是正確的，這可能有助於了解即將發生的情況，而指數平滑法則是在預測新確診病例、死亡率和康復率方面表現最好。Cheng *et al.* [9] 對於三種機器學習模型: (1) 整合自回歸綜合移動平均、(2) 支援向量機、(3) 整合自回歸綜合移動平均-支援向量機進行傳染預測比較，根據平均絕對百分比誤差 (Mean Absolute Percentage Error, MAPE) 比較模型的預測性能，發現與傳統的機器學習模型整合自回歸綜合移動平均和支援向量機相比，組合模型能夠實現更準確可靠的 COVID-19 趨勢預測。Ribeiro *et al.* [36] 比較自回歸綜合移動平均、立體回歸、隨機森林、嶺回歸、支援向量回歸和堆疊-集成學習提前一天、三天和六天預測巴西 10 個日發病率較高的州的 COVID-19 累計確診病例，採用改進百分比指數、平均絕對誤差和對稱平均絕對百分比誤差標準來評估比較方法的性能，推斷支援向量機和堆疊集成學習模型是預測大多數採用狀態的 COVID-19 病例的合適工具。

從上述的研究我們可以看出機器學習方法確實能帶良好的預測準確率，但因為機器學習算法需要通過了解標記的數據來進行學習，在資料面上需要透過人工

對資料進行特徵工程將其轉換成可理解之數據標籤，調整資料結構使算法輸出成期望輸出，而在方法面上要找尋合適的分群演算法以解決特定問題，由於模型算法的局限性，它們在特定情況下的性能會有所降低。

### 2.1.3 深度學習方法

深度學習可用於爆發預測、傳播跟踪和識別、COVID-19 診斷、生物醫學和藥物治療、信息流行病學和信息監控[33]，先前絕大部分使用深度學習在 COVID-19 的研究都是診斷及檢測[5][20][29]，對於感染預測的研究相對較少，有研究指出深度學習中的多層感知器(MLP)有助於流行病模型 SIR 進行參數估計[16][39]。Abbasimehr *et al.*[1]設計了一種多頭注意力機制和統計特徵(ATT-FE)的混合方法以及卷積神經網絡和統計特徵(CNN-FE)的組合方法，並將它們應用於確診病例數最多的 10 個國家的 COVID-19 數據。實驗結果表明，混合模型在性能指標方面優於傳統模型。實驗還證明了混合 ATT-FE 方法優於長短期記憶模型。Istaitieh *et al.*[21]在研究中使用 3 種評估方式比較了 4 種不同的機器學習及深度學習模型在確診預測上，深度學習模型在三個誤差度量方面大大優於自回歸綜合移動平均模型。然而，與自回歸綜合移動平均相比，一維類神經網路以小幅度優於其他兩個深度學習模型，其次是人工神經網路和長短期記憶模型以非常好的結果排名第三。

## 2.2 特徵提取

特徵提取(Feature extraction)是指因為機器學習無法識別的原始資料而將資料轉化為演算法可識別特徵的過程。比如說，圖片本身無法被機器學習直接使用，但是如果將圖片中的點轉化成矩陣的形式，那麼機器學習演算法就能使用了。在醫學方面，王學者[54]用 AI 特徵提取協助牙科掃描資料與 CT 資料之定位與融合，取代傳統手動標記特徵的方式，不但省時也能減少手動標記所花費的人力。而在傳統機具的研究上，謝學者[56]藉由不同夾持狀態所產生的振動訊號，建立了可用於數控車床或傳統機床的振動分析和健康診斷方法，利用主成分分析方法對於 37 個特

徵進行評估，證實使用主成分分析法(Principal Component Analysis, PCA)方法建立主成份分佈圖確定夾持狀態下的振動值變化，並基於振動變化機制建立健康狀態反饋數據集是可行的。也有應用在水文研究的案例，葉學者[55]分別以原始變數和核主成分分析(Kernel Principal Component Analysis, Kernel PCA)所得之核主成分作為深度神經網路降尺度模式之學習資料，利用歷史情境階段性優化深度神經網路模式參數以建立降尺度模式推估案例區域之月降雨量，並使用多變量線性回歸作為基準模式比較其效能。由上述文獻可以得出若找出合適的特徵工程方法，對模型的預測準確度確實都能提升。

## 2.3 系統模擬

在研究中常見的模擬軟體大致可以分為二種：(1)模擬器(Arena、Promodel...)，像是 Wirabhuana *et al.*[47]利用 Arena 對於卡車裝配線中的焊接及金屬表面處理部門進行模擬改善當前流程降低製造時間、(2)Excel 軟體，Xianxia 和 Chuanqing[48]在 2011 年利用 EXCEL 軟體模擬車間流水線用以檢驗該流水線生產效率和之後產線擴編後的生產效率及可能產生的問題，而本研究主要使用 Arena 模擬器進行開發，過往也有許多不同領域的研究都是使用 Arena 進行開發，在庫存物流研究上，Ma *et al.* [27]針對生命周期較短的電子產品庫存進行模擬，在模擬上加入淘汰率跟降價率加上經濟訂單量的概念，利用 Arena 模擬制定了存儲策略跟生產計劃，Vamanan *et al.*[43]提出結合可優化問題的 CPLEX 與 Arena 進行模擬，從進貨、包裝、入庫到出貨等各項作業，解決供應鏈問題，使產品滿足最大的需求。因為實驗過於複雜或有收集資料不方便的問題，也有學者利用 Arena 模擬大型基礎設施的運作來找出潛在問題，如：2005 年 Valentin *et al.*[42]使用場景導航器工具結合 Arena 對於摩洛哥的工業港口丹吉爾港進行模擬，建構出接近現況的仿真模型，進行不同情況的管理實驗。過往也有針對醫院流程或是床位管理等問題進行研究，基於醫療資源的稀缺性加上少數資源有使用的急迫性，像是加護病房的儀器相較一般病房

較為精密且稀少，因此床位不多，因此 Azcarate *et al.*[6]提出一種新的模擬框架,進行更加真實的數學建模，達到加護病房中最佳的床位管理規劃。

綜合上述文獻可以知道系統模擬在研究上的泛用性且績效表現良好，也證實了本研究所提出的方法的有效性。

## 2.4 合成資料

近年，隨著大數據分析被引進醫療領域後，常因為資料量收集困難、隱私問題[11]或是因為疫情突然爆發沒有足夠的資料[44]，而導致訓練時有困難，許多學者變開始使用所謂的「合成資料」來進行研究。El Emam *et al.*[14]使用順序分類和回歸樹的作法，生成確診者資料進行安大略省死亡率的預測。Wang *et al.*[45] 提出 T-SIRGAN 模型，先利用易感-暴露-移除模型生成模擬數據，再丟入生成對抗網路進行數據擴充，再輸入 Transformers 預測新冠趨勢，並利用真實世界的數據來證明此方法的有效性。Waheed *et al.*[44]開發名為 CovidGAN(Covid-Generative Adversarial Network) 的模型來生成合成胸部 X 光 (Chest X-ray) 圖像的方法。此外，我們證明了可以利用 CovidGAN 生成的合成圖像來增強 CNN 檢測 COVID-19 的性能。單獨使用 CNN 進行分類的準確率為 85%。通過添加 CovidGAN 生成的合成圖像，準確率提高到 95%。Singh *et al.*[38]已傳統易感-暴露-感染-移除模型為基礎，開發有 10 個隔間的流行病模型:易感(S)，暴露(E)，隔離(Q)，測試(T)，未測試(UT)，感染症狀( $I_s$ )，感染未經檢測的症狀( $I_{us}$ )，無症狀感染者( $I_{as}$ )、分離(J)和回收(R)，使用來自印度的 COVID-19 真實數據集和合成數據集驗證了理論模型。

### 第三章 資料集

本章節將介紹資料來源，可分為兩種，分別是病患就診資料集、臺大醫院雲林分院一樓平面圖。

#### 3.1 病患就診資料集介紹

本研究預期使用 2021 全年度的台大斗六院區病患靠卡時間資料來進行分析，資料格式範例則如表 1 所示。當中分別有科別、就診日期、掛號時間、第一次結帳時間、第一次看診完成時間、處方時間及給藥時間。當中因為有提前掛號的情況或是可能持有慢性處方簽進院只是為了領藥而沒有掛號行為導致缺值，可能會導致模型在訓練上出現偏誤，此部分將會在下個章節的資料前處理進行處理。

有關這個資料集本研究有兩點需要說明。第一個是資料本身並沒有任何病患個人資訊，因此並不牽涉到任何人體實驗與倫理問題。第二個是病患在不同地點的行走路徑我們僅以最短路徑為考量，並不額外考慮病患中途去超商購物或去廁所的狀況。

表 1 病患就診時序資料

| 流水號 | 科別   | 就診日      | 掛號時間           | 初次結帳時間         | 看診完成時間         | 處方時間            | 給藥時間            |
|-----|------|----------|----------------|----------------|----------------|-----------------|-----------------|
| 1   | ENT  | 2021/1/1 | 2021/1/1 07:30 | 2021/1/1/10:06 | 2021/1/1 08:52 | 2021/1/1/ 09:12 | 2021/1/1/ 09:35 |
| 2   | ENT  | 2021/1/1 | 2021/1/1 06:30 | 2021/1/1/10:12 | 2021/1/1 09:28 | 2021/1/1/ 09:58 | 2021/1/1/ 11:03 |
| :   | :    | :        | :              | :              | :              | :               | :               |
| n   | DENT | 2021/1/4 | 2021/1/4 06:30 | 2021/1/4/11:51 | 2021/1/4 08:56 | 2021/1/4/ 09:56 | 2021/1/4/ 10:35 |

#### 3.2 臺大醫院雲林分院一樓平面圖

本研究預計台大斗六院區提供的院內配置資料來進行 Arena 建模，資料樣式範例如圖 4 所示，本研究會先將診間與其候診區位置進行切割並將有資料的診間標示，如圖 5 所示，藍色部分為診間，綠色部分為候診區，如此當病患進入醫院看診時，便能以此就診紀錄找出病患的院內活動，並以此進行紀錄。






圖 4 臺大醫院雲林分院一樓平面示意圖(翻攝於院內告示牌)




圖 5 門診區網格編碼示意圖

## 第四章 研究方法

本章節將介紹本研究所提出之研究方法，應用於在院內疫情爆發時應該去匡列的潛在危險群，流程圖如下圖 6 所示，分為離線訓練(Offline processing)與在線運作(Online processing)兩個部分。




圖 6 研究方法流程圖

Offline processing 為模型訓練過程，主要分為四階段，(1)資料前處理階段，將院內就診時序資料進行清洗；(2)利用醫院配置資料進行 Arena 建模，紀錄確診者在院內的活動，讓其能與就診時序資料進行整合；(3)利用整合資料進行 Radial basis function-Deep Neural Networks(RBF-DNN)的建立與訓練，並在模型訓練後，透過拆解 RBF-DNN 找出院內感染關鍵網格；(4)針對模型進行績效評估(5)針對關鍵網格輸出結果配合病患就診資料、門診配置資料、確診者模擬資料收集機器學習模型的訓練資料集，建立與訓練一個機器學習模型並檢視績效。Online Processing 則是利用訓練好的機器學習模型使用新的病患就診時序資料及確診者的時序資料進行需要匡列的門診、人數的預測。



## 4.1 資料清洗

在此階段，會先將屬於一樓的門診科別篩選出來，如：屬於牙科的 DENT、耳鼻喉科的 ENT 等，那這邊本研究會將病患分成幾種模式進行前處理：(1)當天掛號當天看診當天領藥、(2)提前掛號當天看診當天領藥、(3)提前掛號當天看診非當天領藥、(4)只有領藥，其餘的數值例如：領藥時間較診完成時間提前得或是其他醫院的資料等將會予以刪除，這樣的目的是為了能夠方便去統計不同時間進入不同區域的病患的人數計算，而藉由這樣的時間資料我們則可重建出每位病患在醫院內移動的軌跡。舉例來說，流水號 1 號病患的在從入口進入醫院後，會先在 6 點 40 分到掛號處掛號，接著他在 7 點 30 分時到診間報到，並分別在 8 點 52 分、9 點 12 分，以及 9 點 35 分完成看診、處方，以及領藥，所以我們可繪出他在台大斗六院區的軌跡如圖 7 所示。

表 2 病患就診時序資料

| 流水號 | 科別   | 就診日      | 掛號時間           | 初次結帳時間         | 看診完成時間         | 處方時間            | 給藥時間            |
|-----|------|----------|----------------|----------------|----------------|-----------------|-----------------|
| 1   | ENT  | 2021/1/1 | 2021/1/1 07:30 | 2021/1/1/10:06 | 2021/1/1 08:52 | 2021/1/1/ 09:12 | 2021/1/1/ 09:35 |
| 2   | ENT  | 2021/1/1 | 2021/1/1 06:30 | 2021/1/1/10:12 | 2021/1/1 09:28 | 2021/1/1/ 09:58 | 2021/1/1/ 11:03 |
| :   | :    | :        | :              | :              | :              | :               | :               |
| n   | DENT | 2021/1/4 | 2021/1/4 06:30 | 2021/1/4/11:51 | 2021/1/4 08:56 | 2021/1/4/ 09:56 | 2021/1/4/ 10:35 |




圖 7 病患看診軌跡重建示意圖

在完成所有病患在台大斗六院區移動軌跡的重建後，我們接著會將這些移動軌跡統計成適合輸入 RBF-DNN 的資料格式。首先，我們會先把台大斗六院區的平面圖切割成網格狀，如圖 4-3 所示。接著我們會統計每小時或是整天經過各網格的病患數量，最終將統計後的結果整理成圖 8 的時序網格資料，當中虛線表示雖然是相同候診區但該區域用來計算牙科的病患，實線則為因地圖緣故，雖然看起來很近實則為不同區域。至於 RBF-DNN，由於其輸入資料格式是  $n$  維的向量，其中  $n$  等於台大斗六院區的網格數量，因此我們會直接將圖 9 的時序網格資料編號後整理成一個向量，並等待後續輸入 RBF-DNN 中。




圖 8 台大六院區網格式意圖




圖 9 病患時序網格式意圖

## 4.2 建立 Arena 模擬

本節將進行 Arena 模擬的建立。Arena 是一套可以針對流程或系統進行診斷與改善的工具，使用者可以應用該模擬器建立一個代表真實系統的模擬，經過模擬過程，最終可以得到其經由使用者所設計的模擬得出的量化結果。本研究希望透過系統模擬的方式，找出確診者從進入醫院看診到領藥離開可能待的時長較長的網格，並予以紀錄，目前在患者進入醫院看診的流程基本如圖 10 所示。

此小節將分為三部份介紹，分別是(1)醫院模組設計、(2)模組參數設定、(3)確診者行動資料集前處理。




圖 10 一般病患進院看診流程

#### 4.2.1 醫院模組設計

本研究利用 Arena 16.01 版本的模擬軟體建立模擬模式。以下將說明建立的模式中,主要使用到的模組(Module)、資源及變數等定義,首先介紹模組的部份,如下表 3。

表 3 本研究主要使用到的 Arena 基本流程模組定義

| 模組名稱    | 定義                       |
|---------|--------------------------|
| Create  | 產生隨機確診人數、看診人數            |
| Assign  | 設定記錄區列人數參數、在診區候診看診時間參數設計 |
| Process | 病患的占用、延遲和釋放過程            |
| Decide  | 判斷病患是否進入網格，決定執行的下一步驟     |
| Record  | 指定變數紀錄                   |
| Dispose | 離開醫院                     |

本研究在建立模擬的架構前,有些變數需要利用實際資料進行統計分析後，找出現有數列適當的分布函數,並使用在模擬架構上。為了找出多久來一次需求的時間分布，與每次需求來的數量分布，因此將歷史預約看診統計過後，代入 Arena 內建的 Input Analyzer，Input Analyzer 屬於統計檢定軟體的功能，對歷史的就診資料進行機率分佈，進而得出需求函數與時間函數的 Fit 函數值，利用機率分佈的函數來接近實際流程的結果。



#### 4.2.2 模組參數定義

Arena 模擬模組設定流程模組(Flow Modules)，本研究因為院內將模型分為兩種型態，分別是像如圖 11 所示，候診區與其他診間候診區而言相對獨立而自行獨立設計和不同診區但擁有同一候診區圖 12 所示，因應不同診區的情形本研究設計出如下圖 13 及圖 14 的模擬模型，各個模塊將會在後續小節一一介紹。




圖 11 台大斗六院區掛號處等候區示意圖



圖 12 台大斗六院區骨科、牙科、外科診間候診區示意圖




圖 13Arena 模擬軟體建構院內模型(以掛號處為例)




圖 14 Arena 模擬軟體建構院內模型(以骨科、牙科、外科為例)



#### 流程模組(Flow Modules):

- Create 模組為實體 Entities 的起點，此處以上圖 13 的模型進行說明，本研究將模組分別命名為 patient1 和 covid1 分別表示為普通病患及確診病患，Entities Type 名稱為 p1 及 c1 為 patient1 和 covid1 的個體類型名稱，而模組中需要設定的 Time Between Arrivals，主要是定義實體跟實體彼此間到達的時間間隔，單位設定為 Hours，本研究將利用 Arena 軟體中的 Input Analyzer 得出到達診間時間間隔分布公式作為設定，而每次的到達量也是根據 Input Analyzer 所計算出的人數分布作為設定。
- Assign 模組在模型中擔任著後續在 Process 及 Decide 部分的變數定義，像是 Process 中的 Delay Type，再利用 Input Analyzer 推算出來後，在此部分定義變數名稱，在 Process 則只需要輸入變數即可，而在 Decide 的判斷是部分所用參數也是在此先定義好後，在進入模組時直接輸入變數即可。
- Process 模組為病患進入候診區到看診的流程處理，以上圖 12 來做說明，模組名稱為 Register，意思代表著掛號的處理，其中 Logic-Action 設定為資源使用方式，本研究是以使用資源之後歸還設定，因此設為 Seize Delay Release，接著設定處理人員名稱為 register1，每次院內人員能處理的病患為 1 位，所以在 Unit to Seize/Release 的部分設為 1，而在 Delay Type 的部分為病患在診區的服務時間機率分配，本研究使用清洗後的資料集中的看診完成時間扣除掛號完成時間來進行各科門診的數據前處理，在將整理好的樹鋸樹入近 Input Analyzer 後，得到各科門診的時間處理函式。
- Decide 模組在本研究有兩種型態，此處以上圖 13 進行說明，當診區因為科別不同但是擁有同樣的候診區時，會在第一個 Decide 先判斷患者等等要進入的診區，因為可能有兩到三個診區使用相同的候診區，在 Type 上會選擇使用 2 way By Condition 或是 N way By Condition 進行病患的判斷，而在第二個 Decide 則是會對於病患是否需要進行匡列進行判斷，判斷的規則是當患者進入診區到離開時是否有確診者進入診區且時長超過 15 分鐘，判斷公式如下：

$$ORTH.TotalTimePerEntity > 0.25 \& \& NumberInORTH > 0 \quad (1)$$

Arena 內建數學式的 *Process.TotaltimePerEntity*，是用來判斷每個進入診區的人總時長是否超過 15 分鐘，後面的 *NumberInORTH* 則是在判斷是否有確診者的進入，當兩者條件達成時才會進入 Record 模組進行記錄。

- Record 模組，主要紀錄在 Decide 模組判定需要匡列的人數，會在此模組進行累加，紀錄的則是當下在診區等待的人數。
- Dispose 模組，模組名稱為 Finish\_Process，當中的 Process 為科別的代稱，指

系統中病患完成在這個科別的看診流程。

### 4.2.3 確診者行動資料集前處理

將上一小節輸出的結果分別整理成模型會用到的數據集，分別是該小時的各網格人數、確診者經過的網格如下表 4、表 5 所示。表 4 中的 0 表示沒有經過，1 則是有經過。

表 4 院內每小時的網格人數示意圖

| 時間               | 網格 1 | 網格 2 | 網格 3 | ... | 網格 16 |
|------------------|------|------|------|-----|-------|
| 2021/01/01/06:40 | 12   | 0    | 13   | ... | 3     |
| 2021/01/01/7:40  | 27   | 14   | 19   | ... | 10    |
| :                | :    | :    | :    | :   | :     |
| 2021/01/01/19:40 | 7    | 8    | 15   | ... | 16    |

表 5 確診者經過的網格示意圖

| 時間               | 網格 1 | 網格 2 | 網格 3 | ... | 網格 16 |
|------------------|------|------|------|-----|-------|
| 2021/01/01/06:40 | 1    | 1    | 0    | ... | 0     |
| 2021/01/01/07:40 | 1    | 0    | 1    | ... | 0     |
| :                | :    | :    | :    | :   | :     |
| 2021/01/01/19:40 | 1    | 0    | 1    | ... | 1     |

### 4.3 尋找感染關鍵網格

本計劃使用 RBF-DNN 來找尋台大斗六院區院內關鍵高風險感染網格的作法流程圖如圖 15 所示，共包含了兩個階段，(1)建立與訓練 RBF-DNN，以及(2)從訓練後 RBF-DNN 的 RBF 層參數找出關鍵高風險感染網格。兩部分內容則介紹如下




圖 15 RBF-DNN 研究方法流程圖

### 4.3.1 建立與訓練 RBF-DNN

RBF-DNN 的內部架構如圖 17 所示，包含(1)一層輸入層，(2)一層攤平層，(3)一層 RBF 層、(4)多層全連接層，及(5)一層輸出層。

(1)輸入層:輸入層未執行任何動作，只負責將輸入數值帶入 RBF-DNN 中。至於此層的神經元數量則是依據我們將台大斗六院區的平面圖拆成幾個網格而定。

(2)資料攤平層:在攤平層中，為了將原來的網格資料變成可以輸入進去 1D-RBF 中，將資料維度轉換成常度為  $q \times 1$  的一為資料，轉換過程如圖 16 所示。




圖 16 資料攤平過程

(3)RBF 層:在 RBF 層中，每個輸入層神經元的輸出將使用  $q$  個 RBF 來描述他們與輸出的關係，其中  $q$  建議由使用者依每個輸入欄位的資料分布狀況決定，若資料分布較為分散，則建議將  $q$  設定的較大，反之則可設定的較小。至於每個神經元都會包含一個 RBF，並可寫為

$$O_{ij} = \exp[-(O_{inputi} - m_{ij})^2 / \sigma_{ij}^2] \quad (2)$$

其中  $O_{ij}$  代表 RBF 層中相對應第  $i$  個輸入層神經元的第  $j$  個 ( $j \leq q$ ) RBF 神經元的輸出， $O_{inputi}$  代表第  $i$  個輸入層神經元的輸出， $m_{ij}$  和  $\sigma_{ij}$  則是這個 RBF 神經元的平均值及標準差。

(4)全連接層:接著介紹 RBF-DNN 之多層全連接層細節。這個全連接層共需使用幾層，又每層需要多少神經元，會依 RBF 層的神經元數量決定。全連接層的第一層會先對 RBF 層的結果進行降維的動作。假設 RBF 層共有  $r$  個神經元，則第一個全連接層使用的神經元數量會是  $2^{(\text{floor}(\log_2 r) - 2)}$  個，其中  $\text{floor}(\cdot)$  代表無條件捨去函數。

而藉由如此的設置，我們預期可快速去除RBF層升維時產生的無意義維度，並有效提升模型的預測準確率。至於第二層以後的全連接層，我們則會參照大部分論文的作法以每次降低2倍或4倍直到最後一層全連接層的神經元數量到達2或是4為止。每個全連接層神經元的公式則可寫為

$$O_j = \tanh(w_{ij}I_i) + b \quad (3)$$

其中 $O_j$ 代表本層第 $j$ 個節點的輸出， $\tanh(\bullet)$ 為Tangent sigmoid函數， $I_i$ 代表前一層第 $i$ 個節點的輸出數值， $w_{ij}$ 為前一層第 $i$ 個節點與本層第 $j$ 個節點間的權重， $b_j$ 則是本層第 $j$ 個節點的偏壓值。

(5)輸出層:最終模型所預測的確診人數會由輸出層輸出。這層僅使用一個神經元，且其與最後的全連接層神經元為全連接關係，而該神經元的數學公式則可寫為

$$Output = linear(w'_i I_i) \quad (4)$$

其中 $Output$ 表示RBF-DNN的輸出， $linear(\bullet)$ 代表線性函數， $I_i$ 代表前一層第 $i$ 個節點的輸出數值， $w'_i$ 為前一層第 $i$ 個神經元與輸出神經元間的權重。

本計畫所設計 RBF-DNN 的 DNN 架構其他 DNN 有個不同點。其全連接層的激活函數皆為 Tangent sigmoid function，而非目前常見的 Relu 或 Leaky Relu 函數。輸出層的激活函數則為線性函數，而非其他函數。會有這樣的設計，是因為本論文分析結果成立的前提是建立在「不管 RBF-DNN 面對的資料集為何，其都得在接受輸入後輸出逼近理想輸出值的結果」，否則後續的分析就會變得無效了。又過往 Cybenko [13]已證實若一個函數的結果為無限多個 Tangent sigmoid 函數的線性組合結果，則該函數必然能逼近任何問題的輸出數值。而對本論文所設計的 RBF-DNN 架構來說，其恰會符合如此的特性，因為最後一層全連接層的輸出為 Tangent sigmoid 函數的輸出，而輸出層能對這些 Tangent sigmoid 函數進行線性組合，因此可逼近任何的函數。




圖 17 RBF-DNN 模型架構圖

#### 4.3.2 利用 RBF-DNN 取出關鍵高風險感染網絡

此小節描述如何從訓練好的 RBF-DNN 中判定台大斗六院區中的網絡哪些是關鍵高風險感染網絡。以下先介紹分析的原理，接著介紹如何依據這個原理來進行分析。在原理部分，過往學者若將 RBF 函數加在類神經網路前，如 Radial Basis Function Neural Network[19][49]、Fuzzy Neural Network[23][46]，或 RBF-LSTM[7][8][10]等，大多是希望透過 RBF 標記出輸入欄位中對建模有幫助的資料點分布位置，並強化這些資料點數值對後續網路的影響力。反之若遇到輸入欄位有對建模沒有幫助的資料點，則 RBF 會弱化這些數值對後續網路的影響力。假設一個輸入欄位其數值大於 0.5 時會對建模有幫助，且數值越大幫助越大，則一旦這個輸入欄位被輸入首層為 RBF 的類神經網路後，則該 fields 相對應三個 RBF 在訓練後的分布位置可能如圖 18(a)所示，平均值在 0.3 的 RBF 會是一個扁平的形狀，並讓每個數值小於 0.5 的輸入數值在經過這個 RBF 後都被轉換為接近 0 的數字。而平均值在 0.9 的 RBF 則會是鐘形的，並可讓每個數值大於 0.5 的輸入數值在經過



這個 RBF 後，具有數值越大則轉換後數值越大的特性。至於平均值在 0.6 附近的 RBF 因為其他兩個 RBF 就足以表示這個輸入對模型的影響力了，所以他變成一個完全扁平的狀況，讓輸入數值不管為何皆會輸出為 0。接著假設有另一個輸入欄位不管其輸入數值為何都對建模來說是沒有幫助的，則其相對應兩個 RBF 的訓練結果可能如圖 18(b)所示，明顯不管哪種形狀的 RBF 都會讓輸入數值在轉換後皆為接近 0 的數值。基於上述原理，過往有學者[7][10]提出若能分析某個輸入欄位所有數值輸入 RBF 後輸出結果的變化程度，則應能了解該輸入欄位是否包含對建模有幫助的資料。若有幫助，則其 RBF 的輸出結果變化程度可能會非常大。反之則可能接近 0。

我們依據上述理論開發的分析演算法共有三個步驟，包含(1)產生並訓練  $\alpha$  個具有不同初始權重值的 RBF-DNN，(2)計算每個輸入欄位在這  $\alpha$  個 RBF-DNN 中的個別分數，(3)利用手肘法與統計方法挑選第二步驟中分數較高的幾個欄位作為關鍵網絡。

分析演算法會從訓練  $\alpha$  個初始權重值不同的 RBF-DNN 開始，是因為類神經網路每次訓練出參數的結果都會因初始值不同而有所不同。換言之本論文所在意的 RBF 層各項參數也會應初始值不同而有所改變，因此為了避免這個狀況，我們必須先訓練出多個 RBF-DNN，之後再統計這些模型的結果，如此才能避免因初始值不同而造成分析上的誤差。我們建議  $\alpha$  必須設為 30 以上的數值，如此後續分析結果在統計上才會有意義。

第二步驟是分別計算每個欄位在  $\alpha$  個 RBF-DNN 的各自分數。假設每個 RBF-DNN 都會用  $q$  個 RBF 層神經元來描述一個輸入欄位，且我們今天要計算第  $i$  個輸入欄位( $1 \leq i \leq 24$ )在第  $j$  個 RBF-DNN( $1 \leq j \leq \alpha$ )的分數， $Score_{ij}$ 則我們會先計算這個輸入欄位所有數值在輸入第  $k$  個 RBF 層神經元( $1 \leq k \leq q$ )運算後，其輸出數值的標準差  $\sigma_{ijk}$ ，並獲得  $Score_{ij} = \sigma_{ij1} + \sigma_{ij2} + \dots + \sigma_{ijq}$ 。而在這個步驟完成後，針對第  $i$  個輸入欄位我們可獲得  $\alpha$  個分數  $\{Score_{i1}, Score_{i2}, \dots, Score_{i\alpha}\}$ 。本步驟會加總所有

RBF 神經元輸出數值的標準差來作為一個欄位的分數，是因為在 RBF-DNN 中，每個輸入欄位一進模型就會被擴張成  $q$  個新維度，而每個新維度的資料都各自會對後續建模用的模型產生影響力，故這  $q$  個維度的數值應該被總和起來看，才能視為一個輸入欄位對建模部分模型的影响力。

在獲得第二步驟的結果後，第三步驟會先對所有欄位的  $\alpha$  個分數由大到小進行排序，接著利用手肘法選取最具代表性的前  $\tau$  個分數。其中所謂的手肘法是指當分數由大排到小後，挑選其中第一個轉折點之前的資料來做為代表性資料，而這樣的作法已被大量應用在機器學習領域中，如  $k$ -means 之  $k$  值決定等。而在挑選完最具代表性的前  $\tau$  個分數後，第三步驟會統計這  $\tau$  個分數是對應到哪些輸入欄位，並選取其中出現次數最高的幾個輸入欄位作為關鍵高風險感染網格。




圖 18 使用 RBF 來找出重要欄位的案例，(a)案例 1，(b)案例 2。

#### 4.4 評估 RBF-DNN 模型之指標

本研究使用 RBF-DNN 模型的目的是要找出院內感染風險的關鍵網格，於是使用 MAE 作為評估指標，數值越小表示模型的預測與實際值越接近，模型的性能越好。可用來模型預測值與實際觀測值之間的平均絕對差異。藉以評估模型在預測目標值的準確度，其公式如式(13)，其中  $y_i$  為實際值， $\hat{y}_i$  則為預測值。

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4)$$

## 4.5 簡易 AI 模型

本節將會把輸出之關鍵網格及門診配置資料及病患就診資料及確診者模擬資料輸入簡易的 AI 模型進行驗證。此處大部分傳統機器學習模型所提到的迴歸模型，如 Support vector regression、K-nearest neighbors 或 Random Forest 都會是可用的選擇。而在模型的績效表現上會以較能看出匡列人數誤差的 MAE 及經常被用來觀察模型績效的 RMSE 進行評估。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5)$$



## 第五章 實驗模擬

本章使用了台大斗六院區的病患就診資料集來驗證所提出方法的有效性。本章節分成幾個部分，包含資料集前處理、Arena 模擬與密切接觸者匡列紀錄、RBFDDNN 參數設定及實驗、RBF 網格拆解及機器學習模型績效評估。

### 5.1 資料集前處理及實驗參數介紹

本論文收集 2021 年 1 月 1 日 0 時至 2021 年 12 月 31 日 23 時於台大斗六院區之病患健保卡靠卡資料，在本節中，將會把靠卡資料整理成數個數據集供模擬模型中的不同參數使用。會使用到的資料可以分為 3 種：(1)模擬使用的人數分布數據集、(2)病患進入時間間隔的數據集、(3)不同診區看診候診時間分布的數據集。

在人數分布數據集中，本研究將先統計了院內不同門診在各小時的紀錄，統計使用到的欄位看診完成的時間，倘若遇到同個小時完成掛號及看診，便會在掛號處及門診區各進行加一，然而由於靠卡資料顯示的是完成的時間，若是遇到整點或是整點出頭的患者會將其歸類進上一小時的資料中，掛號及領藥的計算則是看欄位中掛號完成的時間以及領藥完成的時間去進行計算。

在病患進入時間間隔的數據集中，會將掛號完成時間先依照門診做區分，將不同門診完成掛號時間進行扣除，得到的數據集為每個掛完該科別的病患會進入該診間的時間間隔；而掛號處則不需要進行門診分類，而是直接進行相扣，領藥部分則會先將給藥時間依序相扣。

而在不同診區看診候診時間分布的數據集上，本研究先將不同門診的第一次看診完成時間扣除掛號時間，領藥處的計算則是利用給藥時間扣除處方時間進行計算。

上述的數據集都將會在下一小節中，在各個參數設定前進入 Input Analyzer 中取得各自的最佳分布函數，再進行模擬。

## 5.2 Arena 模擬與密切接觸者匡列紀錄

### 5.2.1 普通病患人數分布函數及診間服務時間分布函數

在模擬時，為了讓模型能盡量地貼近現實，有些變數需要使用實際的資料進行統計分析，得到適當的分布函數，來用於模擬架構上。以下為利用過去台大斗六院區病患就診資料帶入 Arena 內建的 Input Analyzer，所得出需求函數與時間函數的 Fit 函數值，利用得出的機率分佈函數來接近實際流程的結果。以表 6 的掛號處為例，本研究將院內掛號台人數到達間隔時間的數據集，經過 Input Analyzer 的 Fit 過程後所得出的時間分布為  $-0.5 + \text{LOGN}(1.41, 1.44)$ ，該時間分布為 Arena 軟體建議多久產生一次病患進入的函數式值，而圖 19 則是院內各區域的間隔時間分布長條圖，可以使模擬所產生的每日病患進院相似於真實資料。大多呈現的函數分布分為以下幾種：

- BETA 分布(Beta distribution): Beta 分佈是少數取值在一有限區間的常見分佈，它可以用於描述在  $[0, 1]$  區間內的隨機事件的概率分佈。
- LOGN 分布(logarithmic normal distribution): LOGN 分佈是一種連續概率分布，它的隨機變量是自然對數尺度上的正態分布，通常用於描述正的連續隨機變量並呈現右偏或正偏的分佈形狀。
- GAMM 分布(Gamma distribution): GAMM 分布是一種連續概率分布，它的隨機變量是非負實數。它在統計學和應用數學中常用於描述持續時間、事件發生次數和機會發生時間等。
- WEIB 分布(Weibull distribution): WEIB 分布是一個具有兩個參數的曲線家族。可以用於描述人數進入 (arrival) 的情況。在這種情況下，Weibull 分布可以描述特定事件 (例如人數進入某個地點或事件發生) 的時間間隔，可以根據事件發生的時間間隔分佈來推斷或預測人數進入的模式。
- ERLA 分布(Erlang distribution): Erlang 分布是一種連續概率分布，常用於描述



連續事件之間的時間間隔。在人數進入的情況下，Erlang 分布可以用於描述連續時間間隔內發生的人數數量。

- EXPO 分布(Exponential distribution): 是一種連續機率分布。指數分布可以用來表示獨立隨機事件發生的時間間隔。

表 6Input Analyzer 生成各診間的人數到達間隔時間分布

| 院內區域     | 時間分布                                  |
|----------|---------------------------------------|
| 掛號台      | $-0.5 + \text{LOGN}(1.41, 1.44)$      |
| 社會及家庭醫學科 | $-0.5 + \text{GAMM}(3.28, 1.46)$      |
| 婦產科      | $-0.5 + \text{WEIB}(7.81, 1.48)$      |
| 小兒科      | $-0.5 + \text{WEIB}(8.73, 1.56)$      |
| 耳鼻喉科     | $-0.5 + \text{GAMM}(2.81, 2.41)$      |
| 內科       | $-0.5 + \text{GAMM}(0.736, 2.16)$     |
| 領藥處      | $-0.5 + \text{ERLA}(0.605, 2)$        |
| 泌尿科      | $-0.5 + \text{LOGN}(5.88, 4.72)$      |
| 皮膚科      | $-0.5 + \text{GAMM}(2.34, 3.08)$      |
| 眼科       | $-0.5 + \text{LOGN}(5.13, 4.01)$      |
| 復健科      | $-0.5 + \text{GAMM}(2.52, 2.97)$      |
| 骨科       | $-0.5 + \text{LOGN}(4.34, 4.08)$      |
| 外科       | $-0.5 + 20 * \text{BETA}(1.15, 1.39)$ |
| 牙科       | $-0.5 + \text{LOGN}(4.06, 4.33)$      |
| 神經科      | $-0.5 + \text{GAMM}(2.78, 1.81)$      |
| 精神科      | $-0.5 + \text{LOGN}(4.53, 4.55)$      |




圖 19 Input Analyzer 院內各診間的病患進入時間間隔分布長條圖

同樣，將院方提供的資料集中，在時間分布下，每次產生多少人數的數據集，依次輸入 Input Analyzer 的 Fit 過程後，主要由 BETA 分布(Beta distribution)、GAMM 分布(Gamma distribution)和 LOGN(logarithmic normal distribution)分布為主得到的人數分布結果如表 7 所示，人數分布則如圖 20 所示。

表 7 Input Analyzer 生成各診間的病患人數分布

| 院內區域     | 時間分布                                      |
|----------|-------------------------------------------|
| 掛號台      | $-0.001 + 245 * \text{BETA}(0.255, 1.27)$ |
| 社會及家庭醫學科 | $-0.5 + 69 * \text{BETA}(0.304, 2.83)$    |
| 婦產科      | $-0.5 + 27 * \text{BETA}(0.49, 2.88)$     |
| 小兒科      | $-0.5 + 46 * \text{BETA}(0.443, 7.48)$    |
| 耳鼻喉科     | $-0.5 + 31 * \text{BETA}(0.539, 2.91)$    |
| 內科       | $-0.001 + 190 * \text{BETA}(0.237, 1.38)$ |
| 領藥處      | $-0.001 + \text{GAMM}(280, 0.23)$         |
| 泌尿科      | $-0.5 + 33 * \text{BETA}(0.461, 2.76)$    |
| 皮膚科      | $-0.5 + \text{LOGN}(2.88, 6.54)$          |
| 眼科       | $-0.5 + 22 * \text{BETA}(0.462, 2.82)$    |
| 復健科      | $-0.5 + 26 * \text{BETA}(0.365, 2.55)$    |
| 骨科       | $-0.5 + 74 * \text{BETA}(0.309, 3.3)$     |
| 外科       | $-0.5 + 15 * \text{BETA}(0.528, 3.25)$    |
| 牙科       | $-0.5 + 80 * \text{BETA}(0.439, 3.52)$    |
| 神經科      | $-0.5 + 71 * \text{BETA}(0.445, 5.19)$    |
| 精神科      | $-0.5 + 79 * \text{BETA}(0.314, 2.52)$    |




圖 20 Input Analyzer 院內各診間的病患人數分布長條圖

而在各診區的看診及候診時間的時間分布，本研究使用資料集中的完成看診時間扣除現場掛號的時間後的數據集，將其輸入進 Input Analyzer 中，主要由 WEIB 分布 (Weibull distribution)、GAMM 分布 (Gamma distribution) 和 EXPO 分布 (Exponential distribution) 為主，而因為人不可能有小數點，本研究在函數中加入 ANINT 函式，使進入的病患皆為整數個數，得到的人數分布結果如表 8 所示，人數分布則如圖 21 所示。

表 8 Input Analyzer 生成各診間的候診看診時間分布

| 院內區域     | 時間分布                               |
|----------|------------------------------------|
| 掛號台      | $-0.001 + \text{WEIB}(89, 0.854)$  |
| 社會及家庭醫學科 | $-0.001 + \text{GAMM}(169, 0.798)$ |
| 婦產科      | $0.999 + \text{GAMM}(169, 1.05)$   |
| 小兒科      | $-0.001 + \text{EXPO}(185)$        |
| 耳鼻喉科     | $-0.001 + \text{GAMM}(159, 1.03)$  |
| 內科       | $-0.001 + \text{WEIB}(109, 0.862)$ |
| 領藥處      | $-0.001 + \text{WEIB}(119, 1.04)$  |
| 泌尿科      | $-0.001 + \text{WEIB}(125, 1.02)$  |
| 皮膚科      | $-0.001 + \text{GAMM}(160, 0.993)$ |
| 眼科       | $-0.001 + \text{WEIB}(108, 0.813)$ |
| 復健科      | $-0.001 + \text{GAMM}(120, 1.29)$  |
| 骨科       | $-0.001 + \text{GAMM}(157, 1.08)$  |
| 外科       | $-0.001 + \text{EXPO}(134)$        |
| 牙科       | $-0.001 + \text{GAMM}(146, 1.38)$  |
| 神經科      | $-0.001 + \text{WEIB}(89, 0.852)$  |
| 精神科      | $-0.001 + \text{WEIB}(107, 0.891)$ |






圖 21 Input Analyzer 院內各診間的候診看診時間分布長條圖

### 5.2.2 模型建立

在經過分析病患就診資料後，本研究接下來將利用 Arena 來模擬當有確診者進入時需要進行匡列的情形，並計算需要匡列的人數，在建立模擬模型後，再決定模擬時長，以下分別列出參數設定：

#### 1. Create 模組：

主要生成各診間進入看診的病患和確診者，此模組中需要設定的參數有 Time Between Arrival 和 Entities per Arrival，前者是定義病患和病患之間到達的時間間隔有多少，後者則決定到達人數，本研究在上一小節已經利用 Input Analyzer 找出兩個參數的函數公式，單位為 Hours，而因為人不可能有小數點，本研究在函數中加入 ANINT 函式，使進入的病患皆為整數個數，設定如下表 9 所示。

表 9 Create 模組參數設定-一般看診病患

| Name     | Entity Type | Time Between Arrival                  | Entities per Arrival                                    | Max Arrival |
|----------|-------------|---------------------------------------|---------------------------------------------------------|-------------|
| Register | P0          | $-0.5 + \text{LOGN}(1.41, 1.44)$      | $\text{ANINT}(-0.001 + 245 * \text{BETA}(0.255, 1.27))$ | infinite    |
| FM       | P1          | $-0.5 + \text{GAMM}(3.28, 1.46)$      | $\text{ANINT}(-0.5 + 69 * \text{BETA}(0.304, 2.83))$    | infinite    |
| OBGY     | P2          | $-0.5 + \text{WEIB}(7.81, 1.48)$      | $\text{ANINT}(-0.5 + 27 * \text{BETA}(0.49, 2.88))$     | infinite    |
| PED      | P3          | $-0.5 + \text{WEIB}(8.73, 1.56)$      | $\text{ANINT}(-0.5 + 46 * \text{BETA}(0.443, 7.48))$    | infinite    |
| ENT      | P4          | $-0.5 + \text{GAMM}(2.81, 2.41)$      | $\text{ANINT}(-0.5 + 31 * \text{BETA}(0.539, 2.91))$    | infinite    |
| MED      | P5          | $-0.5 + \text{GAMM}(0.736, 2.16)$     | $\text{ANINT}(-0.001 + 190 * \text{BETA}(0.237, 1.38))$ | infinite    |
| Pharmacy | P6          | $-0.5 + \text{ERLA}(0.605, 2)$        | $\text{ANINT}(-0.001 + \text{GAMM}(280, 0.23))$         | infinite    |
| URO      | P7          | $-0.5 + \text{LOGN}(5.88, 4.72)$      | $\text{ANINT}(-0.5 + 33 * \text{BETA}(0.461, 2.76))$    | infinite    |
| DERM     | P8          | $-0.5 + \text{GAMM}(2.34, 3.08)$      | $\text{ANINT}(-0.5 + \text{LOGN}(2.88, 6.54))$          | infinite    |
| OPH      | P9          | $-0.5 + \text{LOGN}(5.13, 4.01)$      | $\text{ANINT}(-0.5 + 22 * \text{BETA}(0.462, 2.82))$    | infinite    |
| PMR      | P10         | $-0.5 + \text{GAMM}(2.52, 2.97)$      | $\text{ANINT}(-0.5 + 26 * \text{BETA}(0.365, 2.55))$    | infinite    |
| ORTH     | P11         | $-0.5 + \text{LOGN}(4.34, 4.08)$      | $\text{ANINT}(-0.5 + 74 * \text{BETA}(0.309, 3.3))$     | infinite    |
| SURG     | P12         | $-0.5 + 20 * \text{BETA}(1.15, 1.39)$ | $\text{ANINT}(-0.5 + 15 * \text{BETA}(0.528, 3.25))$    | infinite    |
| DENT     | P13         | $-0.5 + \text{LOGN}(4.06, 4.33)$      | $\text{ANINT}(-0.5 + 80 * \text{BETA}(0.439, 3.52))$    | infinite    |
| NEUR     | P14         | $-0.5 + \text{GAMM}(2.78, 1.81)$      | $\text{ANINT}(-0.5 + 71 * \text{BETA}(0.445, 5.19))$    | infinite    |
| PSYC     | P15         | $-0.5 + \text{LOGN}(4.53, 4.55)$      | $\text{ANINT}(-0.5 + 79 * \text{BETA}(0.314, 2.52))$    | infinite    |

然而因為今天要模擬的是當確診病患進入診間看診導致院內感染的情形，本研究設立另一個確診者進入的 Create 模組，而今天因不確定會有多少的確診者同時進入診間，再模擬時將會實驗已進入人數 1 至 5 個進行實驗，並代入後續中的 RBF 來探討績效較好的模組，此處在 Time Between Arrival 的部分參數設計與一般看診病患相同，原因是撇除為確診者條件，該病患也是要進入該診間看診的一位病患。設計如表 10 所示。

表 10 Create 模組參數設定-確診病患

| Name     | Entity Type | Time Between Arrival                  | Entities per Arrival | Max Arrival |
|----------|-------------|---------------------------------------|----------------------|-------------|
| Register | C0          | $-0.5 + \text{LOGN}(1.41, 1.44)$      | 1                    | *1-5        |
| FM       | C1          | $-0.5 + \text{GAMM}(3.28, 1.46)$      | 1                    | *1-5        |
| OBGY     | C2          | $-0.5 + \text{WEIB}(7.81, 1.48)$      | 1                    | *1-5        |
| PED      | C3          | $-0.5 + \text{WEIB}(8.73, 1.56)$      | 1                    | *1-5        |
| ENT      | C4          | $-0.5 + \text{GAMM}(2.81, 2.41)$      | 1                    | *1-5        |
| MED      | C5          | $-0.5 + \text{GAMM}(0.736, 2.16)$     | 1                    | *1-5        |
| Pharmacy | C6          | $-0.5 + \text{ERLA}(0.605, 2)$        | 1                    | *1-5        |
| URO      | C7          | $-0.5 + \text{LOGN}(5.88, 4.72)$      | 1                    | *1-5        |
| DERM     | C8          | $-0.5 + \text{GAMM}(2.34, 3.08)$      | 1                    | *1-5        |
| OPH      | C9          | $-0.5 + \text{LOGN}(5.13, 4.01)$      | 1                    | *1-5        |
| PMR      | C10         | $-0.5 + \text{GAMM}(2.52, 2.97)$      | 1                    | *1-5        |
| ORTH     | C11         | $-0.5 + \text{LOGN}(4.34, 4.08)$      | 1                    | *1-5        |
| SURG     | C12         | $-0.5 + 20 * \text{BETA}(1.15, 1.39)$ | 1                    | *1-5        |
| DENT     | C13         | $-0.5 + \text{LOGN}(4.06, 4.33)$      | 1                    | *1-5        |
| NEUR     | C14         | $-0.5 + \text{GAMM}(2.78, 1.81)$      | 1                    | *1-5        |
| PSYC     | C15         | $-0.5 + \text{LOGN}(4.53, 4.55)$      | 1                    | *1-5        |

註: \*此處 1-5 表示診間最大進入確診人數 1 人至 5 人，會分成 5 組進行實驗

## 2. Assign 模組:

用以設定後面 Process 和 Decide 的參數，在此進行設定的參數有兩個，診間看診及候診時間的 ProcessTime 及確認確診者進入的 NumberInProcess，如下表 11 所示。

表 11 Assign 模組參數設定

| Name        | Type      | Attribute Name | New Value                 |
|-------------|-----------|----------------|---------------------------|
| Assign_A    | Attribute | NumInA         | EntitiesWIP(C0)           |
|             |           | Regist_time    | -0.001 + WEIB(89, 0.854)  |
| Assign_B    | Attribute | NumInB         | EntitiesWIP(C1)           |
|             |           | FM_time        | -0.001 + GAMM(169, 0.798) |
| Assign_CtoE | Attribute | NumInC         | EntitiesWIP(C2)           |
|             |           | OBGY_time      | 0.999 + GAMM(169, 1.05)   |
|             |           | NumInD         | EntitiesWIP(C3)           |
|             |           | PED_time       | -0.001 + EXPO(185)        |
|             |           | NumInE         | EntitiesWIP(C4)           |
|             |           | ENT_time       | -0.001 + GAMM(159, 1.03)  |
| Assign_F    | Attribute | NumInF         | EntitiesWIP(C5)           |
|             |           | MED_time       | -0.001 + WEIB(109, 0.862) |
| Assign_G    | Attribute | NumInG         | EntitiesWIP(C6)           |
|             |           | Pharmacy_time  | -0.001 + WEIB(119, 1.04)  |
| Assign_HtoK | Attribute | NumInH         | EntitiesWIP(C7)           |
|             |           | URO_time       | -0.001 + WEIB(125, 1.02)  |
|             |           | NumInI         | EntitiesWIP(C8)           |
|             |           | DERM_time      | -0.001 + GAMM(160, 0.993) |
|             |           | NumInJ         | EntitiesWIP(C9)           |
|             |           | OPH_time       | -0.001 + WEIB(108, 0.813) |
|             |           | NumInK         | EntitiesWIP(C10)          |
|             |           | PMR_time       | -0.001 + GAMM(120, 1.29)  |
| Assign_LtoN | Attribute | NumInL         | EntitiesWIP(C11)          |
|             |           | ORTH_time      | -0.001 + GAMM(157, 1.08)  |
|             |           | NumInM         | EntitiesWIP(C12)          |
|             |           | SURG_time      | -0.001 + EXPO(134)        |
|             |           | NumInN         | EntitiesWIP(C13)          |
|             |           | DENT_time      | -0.001 + GAMM(146, 1.38)  |
| Assign_OtoP | Attribute | NumInO         | EntitiesWIP(C14)          |
|             |           | NEUR_time      | -0.001 + WEIB(89, 0.852)  |
|             |           | NumInP         | EntitiesWIP(C15)          |
|             |           | PSYC_time      | -0.001 + WEIB(107, 0.891) |

在上表 13 中，因為本研究會將擁有相同候診區的門診一起進行模擬，所以將 Assign 設計在一起，當中的 A-P 分別代表不同診間和區域，A:掛號台、B:家醫科、C:婦產科、D:小兒科、E:耳鼻喉科、F:內科、G:領藥處、H:泌尿科、I:皮膚科、J:眼科、K:復健科、L 骨科、M:外科、N:牙科、O:神經科、P:精神科。

### 3. Process 模組：

該模組為流程處理過程，用於設定資源占用、延遲及釋放，此部分在上一小節已經利用 Input Analyzer 來找出不同門診間的處理函數了，此部分函數也已在上一部份 Assign 完成設定，此處只需輸入參數即可完成對於流程時間的設定，如下表 12 所示。

表 12 Process 模組參數設定

| Name     | Action              | Delay Type | Unit    | Expression    |
|----------|---------------------|------------|---------|---------------|
| Register | Seize Delay Release | Expression | Minutes | Regist_time   |
| FM       | Seize Delay Release | Expression | Minutes | FM_time       |
| OBGY     | Seize Delay Release | Expression | Minutes | OBGY_time     |
| PED      | Seize Delay Release | Expression | Minutes | PED_time      |
| ENT      | Seize Delay Release | Expression | Minutes | ENT_time      |
| MED      | Seize Delay Release | Expression | Minutes | MED_time      |
| Pharmacy | Seize Delay Release | Expression | Minutes | Pharmacy_time |
| URO      | Seize Delay Release | Expression | Minutes | URO_time      |
| DERM     | Seize Delay Release | Expression | Minutes | DERM_time     |
| OPH      | Seize Delay Release | Expression | Minutes | OPH_time      |
| PMR      | Seize Delay Release | Expression | Minutes | PMR_time      |
| ORTH     | Seize Delay Release | Expression | Minutes | ORTH_time     |
| SURG     | Seize Delay Release | Expression | Minutes | SURG_time     |
| DENT     | Seize Delay Release | Expression | Minutes | DENT_time     |
| NEUR     | Seize Delay Release | Expression | Minutes | NEUR_time     |
| PSYC     | Seize Delay Release | Expression | Minutes | PSYC_time     |

#### 4.Decide 模組:

此模組在本研究的模型中有兩種 1.是在有相同候診區時用來判斷病患會繼續哪一個診間進行就診。2.則是是用來判斷是否有需要匡列的必要，設定條件為當確診者進入候診區後若時間超過 15 分鐘，則會判斷為 True，表示為密切接觸者並進到 Record 進行紀錄，設定如下表 13、14 所示。

表 13 相同候診區 Decide 參數設計

| Name       | Type               | Conditions      |
|------------|--------------------|-----------------|
| DecideCtoE | N-way By Condition | Entity Type,P2  |
|            |                    | Entity Type,C2  |
|            |                    | Entity Type,P3  |
|            |                    | Entity Type,C3  |
| DecideHtoK | N-way By Condition | Entity Type,P7  |
|            |                    | Entity Type,C7  |
|            |                    | Entity Type,P8  |
|            |                    | Entity Type,C8  |
|            |                    | Entity Type,P9  |
|            |                    | Entity Type,C9  |
| DecideLtoN | N-way By Condition | Entity Type,P11 |
|            |                    | Entity Type,C11 |
|            |                    | Entity Type,P12 |
|            |                    | Entity Type,C12 |
| DecideOtoP | N-way By Condition | Entity Type,P14 |
|            |                    | Entity Type,C14 |



表 14 是否為密切接觸者須進行匡列 Decide 模組設計

| Name    | Type               | Value                                      |
|---------|--------------------|--------------------------------------------|
| DecideA | 2-way By Condition | Register.TotalTimePerEntity>0.25&&NumInA>0 |
| DecideB | 2-way By Condition | FM.TotalTimePerEntity>0.25&&NumInB>0       |
| DecideC | 2-way By Condition | OBGY.TotalTimePerEntity>0.25&&NumInC>0     |
| DecideD | 2-way By Condition | PED.TotalTimePerEntity>0.25&&NumInD>0      |
| DecideE | 2-way By Condition | ENT.TotalTimePerEntity>0.25&&NumInE>0      |
| DecideF | 2-way By Condition | MED.TotalTimePerEntity>0.25&&NumInF>0      |
| DecideG | 2-way By Condition | Pharmacy.TotalTimePerEntity>0.25&&NumInG>0 |
| DecideH | 2-way By Condition | URO.TotalTimePerEntity>0.25&&NumInH>0      |
| DecideI | 2-way By Condition | DERM.TotalTimePerEntity>0.25&&NumInI>0     |
| DecideJ | 2-way By Condition | OPH.TotalTimePerEntity>0.25&&NumInJ>0      |
| DecideK | 2-way By Condition | PMR.TotalTimePerEntity>0.25&&NumInK>0      |
| DecideL | 2-way By Condition | ORTH.TotalTimePerEntity>0.25&&NumInH>0     |
| DecideM | 2-way By Condition | SURG.TotalTimePerEntity>0.25&&NumInI>0     |
| DecideN | 2-way By Condition | DENT.TotalTimePerEntity>0.25&&NumInJ>0     |
| DecideO | 2-way By Condition | NEUR.TotalTimePerEntity>0.25&&NumInH>0     |
| DecideP | 2-way By Condition | PSYC.TotalTimePerEntity>0.25&&NumInI>0     |

#### 5.Record 模組:

負責記錄於第二個 Decide 中判斷為 True 的結果，此處將分成兩個部分進行收集 1.是用來進行當確診者進入候診區超過 15 分鐘時的密切接觸者計數器，2.則是用來收集確診者進入的時間及人數，參數設計如下表 15、表 16 所示。

表 15 需要匡列人數 Record 參數設計

| Name    | Type  | Value              | CounterName |
|---------|-------|--------------------|-------------|
| RecordA | Count | NQ(Register.Queue) | Counter1    |
| RecordB | Count | NQ(FM.Queue)       | Counter2    |
| RecordC | Count | NQ(OBGY.Queue)     | Counter3    |
| RecordD | Count | NQ(PED.Queue)      | Counter4    |
| RecordE | Count | NQ(ENT.Queue)      | Counter5    |
| RecordF | Count | NQ(MED.Queue)      | Counter6    |
| RecordG | Count | NQ(Pharmacy.Queue) | Counter7    |
| RecordH | Count | NQ(URO.Queue)      | Counter8    |
| RecordI | Count | NQ(DERM.Queue)     | Counter9    |
| RecordJ | Count | NQ(OPH.Queue)      | Counter10   |
| RecordK | Count | NQ(PMR.Queue)      | Counter11   |
| RecordL | Count | NQ(ORTH.Queue)     | Counter12   |
| RecordM | Count | NQ(SURG.Queue)     | Counter13   |
| RecordN | Count | NQ(DENT.Queue)     | Counter14   |
| RecordO | Count | NQ(NEUR.Queue)     | Counter15   |
| RecordP | Count | NQ(PSYC.Queue)     | Counter16   |

表 16 確診者進入人數 Record 參數設計

| Name    | Type  | Value  | CounterName |
|---------|-------|--------|-------------|
| RecordA | Count | NumInA | Counter1    |
| RecordB | Count | NumInB | Counter2    |
| RecordC | Count | NumInC | Counter3    |
| RecordD | Count | NumInD | Counter4    |
| RecordE | Count | NumInE | Counter5    |
| RecordF | Count | NumInF | Counter6    |
| RecordG | Count | NumInG | Counter7    |
| RecordH | Count | NumInH | Counter8    |
| RecordI | Count | NumInI | Counter9    |
| RecordJ | Count | NumInJ | Counter10   |
| RecordK | Count | NumInK | Counter11   |
| RecordL | Count | NumInL | Counter12   |
| RecordM | Count | NumInM | Counter13   |
| RecordN | Count | NumInN | Counter14   |
| RecordO | Count | NumInO | Counter15   |
| RecordP | Count | NumInP | Counter16   |

完成上述的模型及參數建構設定後，便要開始進行模擬，收集確診者匡列的資料集來進行 RBF 的訓練，在 Run Step 的部分以每天 18 小時，模擬時長和資料集提供的相同為 271 天，總計為 4878 小時的模擬，當中也會模擬表 12 中提到的不同確診進入人數。下表 17 及表 18 為模擬匡列人數及確診人數的結果。

表 17 確診進入人數為 Max1 的匡列結果

| 科別<br>時間 | A | B  | C   | D  | E  | F   | G   | H   | I  | J  | K   | L   | M  | N  | O   | P   |
|----------|---|----|-----|----|----|-----|-----|-----|----|----|-----|-----|----|----|-----|-----|
| 1        | 0 | 0  | 21  | 39 | 20 | 0   | 0   | 23  | 0  | 16 | 0   | 0   | 0  | 16 | 66  | 0   |
| 2        | 0 | 15 | 0   | 24 | 15 | 0   | 35  | 0   | 48 | 57 | 34  | 0   | 0  | 26 | 0   | 0   |
| 3        | 0 | 0  | 10  | 17 | 72 | 0   | 0   | 0   | 0  | 48 | 0   | 0   | 0  | 0  | 0   | 0   |
| 4        | 0 | 55 | 18  | 37 | 41 | 38  | 0   | 4   | 15 | 42 | 12  | 17  | 66 | 82 | 85  | 72  |
| :        | : | :  | :   | :  | :  | :   | :   | :   | :  | :  | :   | :   | :  | :  | :   | :   |
| 268      | 0 | 90 | 45  | 18 | 42 | 113 | 57  | 154 | 5  | 68 | 5   | 111 | 96 | 27 | 86  | 122 |
| 269      | 0 | 76 | 52  | 42 | 41 | 94  | 267 | 146 | 24 | 0  | 31  | 89  | 77 | 44 | 126 | 22  |
| 270      | 0 | 19 | 156 | 25 | 22 | 29  | 0   | 160 | 22 | 64 | 126 | 57  | 36 | 51 | 134 | 0   |
| 271      | 0 | 84 | 9   | 32 | 3  | 122 | 248 | 35  | 2  | 0  | 6   | 6   | 28 | 37 | 39  | 33  |

表 18 確診進入人數為 MAX1 的確診者進入數模擬結果

| 科別<br>時間 | A | B | C | D | E | F  | G | H  | I | J | K | L | M  | N | O  | P  |
|----------|---|---|---|---|---|----|---|----|---|---|---|---|----|---|----|----|
| 1        | 0 | 0 | 0 | 1 | 0 | 0  | 0 | 3  | 0 | 2 | 0 | 0 | 0  | 1 | 3  | 0  |
| 2        | 0 | 0 | 1 | 0 | 1 | 0  | 1 | 0  | 1 | 1 | 2 | 0 | 0  | 1 | 0  | 0  |
| 3        | 0 | 0 | 0 | 0 | 0 | 0  | 0 | 0  | 0 | 9 | 0 | 0 | 0  | 0 | 0  | 0  |
| 4        | 0 | 1 | 1 | 1 | 1 | 1  | 0 | 1  | 1 | 1 | 2 | 1 | 10 | 1 | 1  | 1  |
| :        | : | : | : | : | : | :  | : | :  | : | : | : | : | :  | : | :  | :  |
| 268      | 0 | 1 | 1 | 1 | 1 | 2  | 2 | 10 | 1 | 4 | 1 | 3 | 5  | 0 | 11 | 10 |
| 269      | 0 | 1 | 1 | 1 | 1 | 10 | 5 | 1  | 1 | 0 | 3 | 1 | 8  | 1 | 1  | 2  |
| 270      | 0 | 8 | 3 | 1 | 4 | 2  | 0 | 6  | 1 | 3 | 3 | 3 | 1  | 1 | 7  | 5  |
| 271      | 0 | 0 | 1 | 1 | 1 | 2  | 2 | 1  | 1 | 0 | 3 | 1 | 8  | 1 | 1  | 1  |

在得到匡列數據後，將會將其整合成接下來 RBF-DNN 所需要的訓練的資料集，此部分的做法是將每一天的確診者網格資料及病患就診資料進行攤平成為一個 2\*16\*18 欄 271 列的人流網格，16\*18 欄表示的是 16 個門診一天工作 18 的小時加上記錄確診者的所以乘 2，而 271 列則是模擬天數。如下表 19 所示。

表 19 RBF-DNN 訓練資料集-以 MAX1 為例

|   |    |    |     |     |     |     |     |     |     |     |     |
|---|----|----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| 0 | 1  | 2  | ... | 101 | 102 | ... | 385 | 386 | ... | 575 | 576 |
| 0 | 2  | 23 | ... | 20  | 47  | ... | 92  | 12  | ... | 71  | 55  |
| 0 | 11 | 7  | ... | 14  | 62  | ... | 61  | 43  | ... | 156 | 34  |
| 0 | 3  | 9  | ... | 27  | 19  | ... | 54  | 71  | ... | 14  | 77  |
| : | :  | :  | ... | :   | :   | ... | :   | :   | ... | :   | :   |
| 0 | 17 | 51 | ... | 2   | 33  | ... | 125 | 28  | ... | 0   | 0   |

### 5.3 RBF 模型參數選擇及實驗、績效評估

本小節主要討論本研究提出的模型之最佳參數選擇，當中包含(1)模擬資料前處理及(2) RBF 特徵值選取閾值的設定，兩者討論如下。

在收集完模擬結果後，發現模擬資料在匡列確診人數上會有資料不平衡的問題，如圖 22(A)所示。而當中絕大部分是 0，造成模型學習效果不佳，如圖 22(B)所示，模型能夠抓取趨勢卻無法學到峰值，即使如此特徵也可能會因此抓到過多 0，在此本研究採用分段正規化的方式使資料分布狀況較均勻。




圖 22 MAX1(a)資料分布、(b)訓練結果




圖 23 分段正規化後的模擬資料分布示意圖

在經過分段正規化後，資料分布情形如上圖 23 所示，可以看出資料在分布上呈現較為平衡的狀態，後續也將用此種方法對其他訓練資料集進行平衡。

接下來進入 RBF-DNN 部分的實驗，此部分會分為幾個步驟進行: (1)先進行 3 個及 4 個 RBF 的輸入實驗，挑出績效最好的一組、(2)對該組進行閾值的實驗，分別有 0.075、0.05、0.1、0.15、0.2 五種閾值，觀察各個閾值的績效、(3)拆解績效最佳的組合找出院內感染的關鍵網格。

首先，進行 3 個及 4 個 RBF 的輸入，這部分會進行兩組分別是輸入全部特徵以及只輸入模型找到的重要特徵後，每組會進行五次取平均，比較哪一組表現最佳，結果如下表 20-23 所示。

表 20 3RBF-DNN 無重要特徵篩選績效

| 資料集  | RMSE   | MAE    |
|------|--------|--------|
| Max1 | 135.25 | 59.35  |
| Max2 | 124.38 | 87.6   |
| Max3 | 144.41 | 100.46 |
| Max4 | 139.33 | 102.17 |
| Max5 | 198.57 | 170.39 |



表 21 3RBF-DNN 重要特徵篩選績效

| 資料集  | RMSE   | MAE    | 最終特徵值量  |
|------|--------|--------|---------|
| Max1 | 163.99 | 100.42 | 224/576 |
| Max2 | 297.14 | 265.36 | 223/576 |
| Max3 | 219.85 | 223.21 | 229/576 |
| Max4 | 273.26 | 224.53 | 227/576 |
| Max5 | 311.03 | 208.53 | 219     |

表 22 4RBF-DNN 無重要特徵篩選績效

| 資料集  | RMSE   | MAE    |
|------|--------|--------|
| Max1 | 86.6   | 43.6   |
| Max2 | 154.49 | 100.89 |
| Max3 | 192.6  | 115.57 |
| Max4 | 195.63 | 134.14 |
| Max5 | 235.16 | 155.96 |

表 23 4RBF-DNN 重要特徵篩選績效

| 資料集  | RMSE   | MAE    | 最終特徵值量  |
|------|--------|--------|---------|
| Max1 | 78.2   | 47.28  | 227/576 |
| Max2 | 276.93 | 199.96 | 223/576 |
| Max3 | 278.37 | 214.78 | 222/576 |
| Max4 | 268.22 | 222.21 | 226/576 |
| Max5 | 279.06 | 231.10 | 226/576 |

從結果可以發現，MAE 數量會隨著進入人數上限提升而增加，可能是因為說，因為確診人數增加所導致需要匡列的人變多，因而在誤差上也跟著增加，在比較完結果之後，本研究決定對於相對來說績效較好的 RBF4 的 Max1 進行閾值的實驗，觀看績效之後進行網格的拆解。閾值結果如下表 24 所示。

表 24 4RBF-DNN 搭配不同閾值結果-MAX1

| STD 閾值 | TESTMAE | 最終特徵量   |
|--------|---------|---------|
| 0.075  | 79.64   | 170/576 |
| 0.05   | 68.17   | 161/576 |
| 0.1    | 60.78   | 159/576 |
| 0.15   | 54.57   | 145/576 |
| 0.2    | 79.32   | 120/576 |

在經過閾值之後可以發現當閾值為 0.15 時，出來的表現最佳，那後續也將對此閾值出來的特徵參數量進行拆解並將特徵輸入進去機器學習模型中進行績效評估。

#### 5.4 RBF 網格拆解及機器學習模型績效評估

本節將對於在上一小節中 STD 閾值 0.15 的 Max1 進行網格拆解，找尋其重要特徵網格在將其代入進機器學習模型中進行學習並評估其績效。拆解後網格如下表 26 所示

表 25 RBF 關鍵網格輸出


|     |     |     |     |     |     |     |     |     |     |     |     |     |     |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| 1   | 2   | 3   | 4   | 5   | 6   | 7   | ... | 140 | 141 | 142 | 143 | 144 | 145 |
| 100 | 101 | 102 | 103 | 104 | 105 | 288 | ... | 540 | 542 | 543 | 544 | 559 | 560 |

因本研究使用的攤平方式是每個門診同一小時進行攤平，所以當我們拆解網格去看計算後發現，100 表示的是院內營業後約莫第七小時的耳鼻喉門診的確診者網格，101 則是同小時的內科門診確診者網格，102 則是同小時的領藥處確診者網格等等，在我們拆解網格時，發現到相同候診區其實網格被選為重要特徵的機率較高，表示具有相同候診區的門診，可能為感染熱區的機率較高。


接著本研究，將會使用拆出的重要特徵網格輸入進隨機森林的模型中進行訓練並評估其績效，訓練的績效表及測試的圖如下表 26 及下圖 24 所示所示。

表 26 隨機森林績效表


| 訓練測試比例集次數  | TrainRMSE | TrainMAE | TestRMSE | TestMAE |
|------------|-----------|----------|----------|---------|
| 7:3 500 次  | 67.21     | 29.92    | 114.95   | 71.93   |
| 7:3 1000 次 | 68.74     | 31.27    | 94.45    | 45.93   |
| 8:2 500 次  | 63.26     | 30.35    | 28.56    | 19.63   |
| 8:2 1000 次 | 62.22     | 28.67    | 55.40    | 38.44   |
| 9:1 500 次  | 68.32     | 29.59    | 130.39   | 59.55   |
| 9:1 1000 次 | 65.41     | 30.09    | 128.8    | 50.43   |




(a) 500 次




(a) 1000 次




(b) 500 次



(b) 1000 次



(c) 500 次



(c) 1000 次

圖 24 隨機森林測試圖(a)7:3、(b)8:2、(c)9:1

從上圖可以看出模型在預測上已經能很好的跟上趨勢了，雖然有部分預測值會有多匡列的情形，但是這種情形在匡列上是可以被接受的，而在部分時候會有少匡列的情形，在此部分將會對於輸出值在加上一個常數，來使其能夠超過不足的值，本研究所顧慮的點及目標是可以多匡列一些但是不要過頭，但是要降低有少匡列而導致疫情爆發的情況發生。

## 第六章 結論與未來研究

自 2019 年疫情爆發以來，圍堵疫情避免爆發，一直是相關單位的首要目標，因為台灣人的稍有不舒服就前往醫院的就醫習慣，雖然讓人們能在確診的當下馬上進行處置，但只要院內疫情爆發就會發生全體匡列的情形，導致醫護人員壓力過大及醫療資源緊繃，在保護病患隱私的前提下，本研究提出利用模擬確診者進入的方式，進行匡列人數資料的生成，並將其輸入進機器學習模型中，使其能夠快速地生成結果去應變突然爆發時所要匡列的人員數量，本論文在此加入 RBF 函數進行特徵挑選，在訓練完成後進行網格的拆解，希望能讓院方更了解院內可能的感染熱區為何能夠在未來對於疫情規範的政策有所幫助，而在實驗中，隨機森林的結果也證實了本研究所提出的方法有效性。

在未來研究中，可以針對不同門診的位置進行移動的研究，來找出院內感染熱區發生機率最低的布置方法。



## 參考文獻

- [1] Abbasimehr, H., Paki, R., & Bahrini, A. (2021). Improving the performance of deep learning models using statistical features: The case study of COVID - 19 forecasting. *Mathematical Methods in the Applied Sciences*.
- [2] Abbas, M., Nunes, T. R., Cori, A., Cordey, S., Laubscher, F., Baggio, S., ... & Harbarth, S. (2021). Explosive nosocomial outbreak of SARS-CoV-2 in a rehabilitation clinic: the limits of genomics for outbreak reconstruction. *Journal of Hospital Infection*, 117, 124-134.
- [3] Altieri, N., Barter, R. L., Duncan, J., Dwivedi, R., Kumbier, K., Li, X., ... & Yu, B. (2020). Curating a COVID-19 data repository and forecasting county-level death counts in the United States. *arXiv preprint arXiv:2005.07882*.
- [4] Bertozzi, A. L., Franco, E., Mohler, G., Short, M. B., & Sledge, D. (2020). The challenges of modeling and forecasting the spread of COVID-19. *Proceedings of the National Academy of Sciences*, 117(29), 16732-16738.
- [5] Bhowal, P., Sen, S., Yoon, J. H., Geem, Z. W., & Sarkar, R. (2021). Choquet integral and coalition game-based ensemble of deep learning models for covid-19 screening from chest x-ray images. *IEEE Journal of Biomedical and Health Informatics*, 25(12), 4328-4339.
- [6] C. Azcarate, L. Esparza, and F. Mallor,(2020) “The problem of the last bed : Contextualization and a new simulation framework for analyzing physician decisions,” *Omega*, vol. 96
- [7] Chen, Y. C., & Li, D. C. (2021). Selection of key features for PM2. 5 prediction using a wavelet model and RBF-LSTM. *Applied Intelligence*, 51(4), 2534-2555.
- [8] Chen, Y. C., Liu, S. C., Chen, B. X., Loh, C. H., & Ying, J. J. C. (2020). Ensembling-



- mRBF-LSTM framework for prediction of abnormal traffic flows. In 2020 International Conference on Pervasive Artificial Intelligence (ICPAI) (pp. 206-213). IEEE.
- [9] Cheng, Y., Bai, Y., Xu, T., & Hu, H. (2022). Global COVID-19 development trend forecast based on machine learning. In 2022 International Conference on Big Data, Information and Computer Network (BDICN) (pp. 128-131). IEEE.
- [10] Chiu, S. M., Chen, Y. C., Kuo, C. J., Hung, L. C., Hung, M. H., Chen, C. C., & Lee, C. (2022). Development of Lightweight RBF-DRNN and Automated Framework for CNC Tool-Wear Prediction. *IEEE Transactions on Instrumentation and Measurement*, 71, 1-11.
- [11] Choi, E., Biswal, S., Malin, B., Duke, J., Stewart, W. F., & Sun, J. (2017). Generating multi-label discrete patient records using generative adversarial networks. In *Machine learning for healthcare conference* (pp. 286-305). PMLR.
- [12] Cooper, I., Mondal, A., & Antonopoulos, C. G. (2020). A SIR model assumption for the spread of COVID-19 in different communities. *Chaos, Solitons & Fractals*, 139, 110057.
- [13] Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of control, signals and systems*, 2(4), 303-314.
- [14] El Emam, K., Mosquera, L., Jonker, E., & Sood, H. (2021). Evaluating the utility of synthetic COVID-19 case data. *JAMIA open*, 4(1), ooab012.
- [15] Fang, H., Chen, J., & Hu, J. (2006). Modelling the SARS epidemic by a lattice-based Monte-Carlo simulation. In 2005 IEEE Engineering in Medicine and Biology 27th Annual Conference (pp. 7470-7473). IEEE.
- [16] Farooq, J., & Bazaz, M. A. (2021). A deep learning algorithm for modeling and forecasting of COVID-19 in five worst affected states of India. *Alexandria*

Engineering Journal, 60(1), 587-596.

- [17] Gao, Y., Cai, G. Y., Fang, W., Li, H. Y., Wang, S. Y., Chen, L., ... & Gao, Q. L. (2020). Machine learning based early warning system enables accurate mortality risk prediction for COVID-19. *Nature communications*, 11(1), 1-10.
- [18] Hethcote, H. W. (2000). The mathematics of infectious diseases. *SIAM review*, 42(4), 599-653.
- [19] Huang, G. B., Saratchandran, P., & Sundararajan, N. (2005). A generalized growing and pruning RBF (GGAP-RBF) neural network for function approximation. *IEEE transactions on neural networks*, 16(1), 57-67.
- [20] Huang, X. (2021). COVID-19 Image Diagnosis on CT Images Using Deep Learning. In 2021 2nd International Conference on Artificial Intelligence and Computer Engineering (ICAICE) (pp. 77-80). IEEE.
- [21] Istaiteh, O., Owais, T., Al-Madi, N., & Abu-Soud, S. (2020, October). Machine learning approaches for covid-19 forecasting. In 2020 International Conference on Intelligent Data Science Technologies and Applications (IDSTA) (pp. 50-57). IEEE.
- [22] Kamalov, F., Rajab, K., Cherukuri, A., Elnagar, A., & Safaraliev, M. (2022). Deep Learning for Covid-19 Forecasting: state-of-the-art review. *Neurocomputing*.
- [23] Kasabov, N. K. (1996). Learning fuzzy rules and approximate reasoning in fuzzy neural networks and hybrid systems. *Fuzzy sets and Systems*, 82(2), 135-149.
- [24] Kaur, D., Sobiesk, M., Patil, S., Liu, J., Bhagat, P., Gupta, A., & Markuzon, N. (2021). Application of Bayesian networks to generate synthetic health data. *Journal of the American Medical Informatics Association*, 28(4), 801-811.
- [25] Kermack, W. O., & McKendrick, A. G. (1927). A contribution to the mathematical theory of epidemics. *Proceedings of the royal society of london. Series A, Containing papers of a mathematical and physical character*, 115(772), 700-721.

- [26] Kuzdeuov, A., Baimukashev, D., Karabay, A., Ibragimov, B., Mirzakhmetov, A., Nurpeiissov, M., ... & Varol, H. A. (2020). A network-based stochastic epidemic simulator: Controlling covid-19 with region-specific policies. *IEEE journal of biomedical and health informatics*, 24(10), 2743-2754.
- [27] M. Vamanan, Q. Wang, R. Batta, and R. J. Szczerba, "Integration of COTS software
- [28] Myall, A., Price, J. R., Peach, R. L., Abbas, M., Mookerjee, S., Zhu, N., ... & Barahona, M. (2022). Prediction of hospital-onset COVID-19 infections using dynamic networks of patient contact: an international retrospective cohort study. *The Lancet Digital Health*, 4(8), e573-e583.
- [29] Nefoussi, S., Amamra, A., & Amarouche, I. A. (2021, February). A Comparative Study of Deep Learning Networks for COVID-19 Recognition in Chest X-ray Images. In 2020 2nd International Workshop on Human-Centric Smart Environments for Health and Well-being (IHSH) (pp. 237-241). IEEE.
- [30] Park, N., Mohammadi, M., Gorde, K., Jajodia, S., Park, H., & Kim, Y. (2018). Data synthesis based on generative adversarial networks. *arXiv preprint arXiv:1806.03384*.
- [31] Patel, A., Bhowmik, T., Gupta, S., & Mukhopadhyay, D. (2021). Mathematical Model for Controlling the Spreading of COVID-19 in the Context of Hospital Environment. In 2021 6th International Conference for Convergence in Technology (I2CT) (pp. 1-5). IEEE.
- [32] Pei, Z., Yuan, Y., Yu, T., & Li, N. (2021). Dynamic Allocation of Medical Resources During the Outbreak of Epidemics. *IEEE Transactions on Automation Science and Engineering*, 19(2), 663-676.
- [33] Pham, Q. V., Nguyen, D. C., Huynh-The, T., Hwang, W. J., & Pathirana, P. N. (2020). Artificial intelligence (AI) and big data for coronavirus (COVID-19) pandemic: a

- survey on the state-of-the-arts. IEEE access, 8, 130820.
- [34] Rathnayaka, A., Al Mamun, M. A., Wu, F., Curtis, S. J., Stewardson, A. J., & Yuce, M. R. (2020). Protecting health care workers from infectious diseases using physical proximity networks (PPN). In 2020 Ieee Sensors (pp. 1-4). IEEE.
- [35] Read, J. M., Bridgen, J. R., Cummings, D. A., Ho, A., & Jewell, C. P. (2020). Novel coronavirus 2019-nCoV: early estimation of epidemiological parameters and epidemic predictions. medrxiv.
- [36] Ribeiro, M. H. D. M., da Silva, R. G., Mariani, V. C., & dos Santos Coelho, L. (2020). Short-term forecasting COVID-19 cumulative confirmed cases: Perspectives for Brazil. *Chaos, Solitons & Fractals*, 135, 109853.
- [37] Rustam, F., Reshi, A. A., Mehmood, A., Ullah, S., On, B. W., Aslam, W., & Choi, G. S. (2020). COVID-19 future forecasting using supervised machine learning models. IEEE access, 8, 101489-101499.
- [38] Singh, A., & Arquam, M. (2022). Epidemiological modeling for COVID-19 spread in India with the effect of testing. *Physica A: Statistical Mechanics and its Applications*, 592, 126774.
- [39] Sujath, R. A. A., Chatterjee, J. M., & Hassanien, A. E. (2020). A machine learning forecasting model for COVID-19 pandemic in India. *Stochastic Environmental Research and Risk Assessment*, 34(7), 959-972.
- [40] Tanade, C., Pate, N., Paljug, E., Hoffman, R. A., & Wang, M. D. (2019). Hybrid modeling of ebola propagation. In 2019 IEEE 19th International Conference on Bioinformatics and Bioengineering (BIBE) (pp. 204-210). IEEE.
- [41] Tucker, A., Wang, Z., Rotalinti, Y., & Myles, P. (2020). Generating high-fidelity synthetic patient data for assessing machine learning healthcare software. *NPJ digital medicine*, 3(1), 1-13.

- [42] Valentin, E. C., Steijaert, S., Bijlsma, R. A., & Silva, P. (2005). Approach for modelling of large maritime infrastructure systems. In Proceedings of the Winter Simulation Conference, (pp. 9-pp). IEEE.
- [43] Vamanan, M., Wang, Q., Batta, R., & Szczerba, R. J. (2004). Integration of COTS software products ARENA & CPLEX for an inventory/logistics problem. *Computers & Operations Research*, 31(4), 533-547.
- [44] Waheed, A., Goyal, M., Gupta, D., Khanna, A., Al-Turjman, F., & Pinheiro, P. R. (2020). Covidgan: data augmentation using auxiliary classifier gan for improved covid-19 detection. *Ieee Access*, 8, 91916-91923.
- [45] Wang, H., Tao, G., Ma, J., Jia, S., Chi, L., Yang, H., ... & Tao, J. (2022). Predicting the Epidemics Trend of COVID-19 Using Epidemiological-Based Generative Adversarial Networks. *IEEE Journal of Selected Topics in Signal Processing*, 16 (2), 276-288.
- [46] Wang, Y., & Luo, C. (2021). An intelligent quantitative trading system based on intuitionistic-GRU fuzzy neural networks. *Applied Soft Computing*, 108, 107471.
- [47] Wirabhuana, A., Haron, H., & Imtiyan, M. R. (2008). Simulation and re-engineering of truck assembly line. In 2008 Second Asia International Conference on Modelling & Simulation (AMS) (pp. 783-787). IEEE.
- [48] Xianxia, Q., & Chuanqing, T. (2011). Excel-Based Simulation on Problems of Two-Stage Assembly Line Queuing. In 2011 International Conference on Business Computing and Global Informatization (pp. 492-496). IEEE.
- [49] Yang, L. (2021). Risk prediction algorithm of social security fund operation based on RBF neural network. *International Journal of Antennas and Propagation*, 2021.
- [50] Yu, Y., & Ma, X. (2012). Study on inventory control of perishable electronic product including reverse logistics. In Proceedings of 2012 IEEE International Conference

- on Service Operations and Logistics, and Informatics (pp. 445-450). IEEE.
- [51] Zhang, J., Cormode, G., Procopiuc, C. M., Srivastava, D., & Xiao, X. (2017). Privbayes: Private data release via bayesian networks. *ACM Transactions on Database Systems (TODS)*, 42(4), 1-41.
- [52] Zhang, Z., Yan, C., Mesa, D. A., Sun, J., & Malin, B. A. (2020). Ensuring electronic medical record simulation through better training, modeling, and evaluation. *Journal of the American Medical Informatics Association*, 27(1), 99-108.
- [53] Zou, D., Wang, L., Xu, P., Chen, J., Zhang, W., & Gu, Q. (2020). Epidemic model guided machine learning for COVID-19 forecasts in the United States. *Medrxiv*.
- [54] 王柏元(2022)。使用 AI 特徵提取協助牙科掃描資料與 CT 資料之定位與融合。〔碩士論文。國立中正大學〕臺灣博碩士論文知識加值系統。  
<https://hdl.handle.net/11296/99y635>。
- [55] 葉威里(2020)。深度學習神經網路推估氣候變遷降雨量之研究。〔碩士論文。中原大學〕臺灣博碩士論文知識加值系統。  
<https://hdl.handle.net/11296/86vp2u>。
- [56] 謝忠諺(2022)。運用振動訊號與主成份分析法於車床夾持異常偵測之研究。〔碩士論文。國立虎尾科技大學〕臺灣博碩士論文知識加值系統。  
<https://hdl.handle.net/11296/fwn82m>。