

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management
National Yunlin University of Science & Technology
Master Thesis

利用 RBF-UNet 以提昇刀具磨耗預測之準確率

Improve the Accuracy of Tool Wearing Prediction
by using the RBF-Unet

楊添翼

Tain-Yi Yang

指導教授：陳維婷 博士

陳奕中 博士

Advisor : Wei-Ting Chen, Ph.D

Yi-Chung Chen, Ph.D.

中華民國 112 年 6 月

June 2023

摘要

近年來隨著工業 4.0 概念的逐漸普及，台灣地區的 CNC 廠商開始吹起一股使用 CNC 機台運作時的震動訊號來進行刀具壽命預測的風潮。各廠商除了積極向外購買最新的機台外，也積極扶植台灣本地團隊進行相關研究，也因此在學界形成一個龐大的市場。而就台灣學界在此領域的發展狀況來說，目前學者們皆以了解(1)知道如何對感測器收集到的震動訊號做前處理，以及(2)知道使用深度學習模型能替震動訊號與刀具壽命預測間進行建模能獲得較佳的預測結果。然而，在我們實地與台灣的中小企業主接觸後，我們發現學界這樣的模式其實是不受產業界青睞的，因為上述第二個項目，使用深度學習來建模，因為需要大量的建立與運行成本(包含時間與金錢都是)，對中小企業主來說是難以達成的。因此有鑑於目前中小企業主所遇到的困難，本研究預計開發新的框架來建立低成本但預測效果與深度學習模型差不多的刀具預測模型。

本研究提出的框架包含三個階段，(1)收集 CNC 機臺在切削過程中感測器所收集到的資料轉換成時頻圖。(2)接著開發 RBF-UNet Model 來找出對刀具壽命預測最關鍵的資料特徵在哪裡。(3)從原始資料中再次擷取這些關鍵特徵資料，並輸入各種簡易的低成本 AI 模型中建模。我們預期能以較低的成本建立高精準度的刀具磨耗預測系統，並因此協助台灣中小企業主克服深度學習模型的高建立與運算成本、進一步提昇刀具壽命預測的能力，並進一步提昇相關產業的競爭力。

關鍵字：刀具磨耗、降低運行成本、RBF、UNet、深度學習

Abstract

In recent years, with the gradual popularization of the concept of Industry 4.0, CNC manufacturers in Taiwan have begun to use the vibration signal to predict the tool life while the CNC machine is operating. In addition to actively purchasing the latest machines, various manufacturers are also actively supporting local teams in Taiwan to conduct related research, thus forming a huge market in the academia. As far as the development status of Taiwan's academia in this field is concerned, the current scholars all known (1) know how to pre-process the vibration signals collected by the sensor, and (2) know that using deep learning models with the vibration signals and tool life prediction can get better prediction results. However, after contact with small and medium-sized business owners in Taiwan, we found that such a model in academia is actually not favored by the industry, because the above-mentioned second project uses deep learning to model, because it requires a lot of establishment and operation. The cost (including time and money) is difficult for small and medium-sized business owners. Therefore, in view of the current difficulties encountered by small and medium-sized owners, this study is expected to develop a new framework to establish a low-cost tool prediction model with a predictive effect similar to that of a deep learning model.

The framework proposed in this study consists of three stages, (1) collect the data which collected by the sensor during the cutting process of the CNC machine and converting it into a time-frequency diagram. (2) Then develop RBF-UNet Model to find out where are the most critical data features for tool life prediction. (3) Extract these key feature data from the original data again, and as input to various simple and low-cost AI models for modeling. We expect to be able to establish a high-precision tool wear prediction system at a lower cost, and thus assist small and medium-sized enterprises in Taiwan to overcome the high establishment and computing costs of deep learning models, further improve the ability of tool life prediction, and further enhance the related industries. Competitiveness.

Keywords : Tool-wear 、 Reduce operating costs 、 RBF 、 UNet 、 Deep-learning

目錄

摘要.....	I
ABSTRACT.....	II
目錄.....	III
表目錄.....	V
圖目錄.....	VI
第 1 章 緒論.....	1
1.1 研究背景與動機.....	1
1.2 研究目的.....	6
1.3 研究流程.....	7
第 2 章 文獻回顧.....	9
2.1 刀具磨耗預測方法.....	9
2.1.1 刀具磨耗特性介紹.....	9
2.1.2 使用機器學習解決刀具磨耗預測的問題.....	10
2.1.3 使用深度學習解決刀具磨耗預測的問題.....	10
2.2 RBF 的應用.....	11
2.3 UNET.....	12
2.4 小結.....	13
第 3 章 資料集.....	14
3.1 PHM 2010 競賽資料.....	14
第 4 章 研究方法.....	16
4.1 資料預處理.....	16
4.1.1 資料清洗.....	16
4.1.2 時頻圖轉換.....	17
4.2 RBF-UNET MODEL.....	17
4.2.1 UNet.....	18
4.2.2 RBF.....	19
4.2.3 隱藏層.....	21
4.2.4 從 RBF-UNet Model 取出重要特徵.....	21
4.2.5 複合式 RBF-UNet Model.....	22
4.3 績效評估.....	22
第 5 章 實驗模擬.....	25
5.1 震動資料切割.....	25
5.2 時頻圖轉換.....	26
5.3 RBF-UNET MODEL.....	27
5.3.1 模型架構.....	27
5.3.2 原始尺寸 2700 x 900.....	28
5.3.3 切割圖片 64 x 900.....	30

5.3.4 切割圖片 300 x 900	31
5.3.5 小結	34
5.3.6 複合式 RBF-UNET MODEL	34
5.4 RBF LAYER 拆解	38
5.5 輕量化模型	45
5.6 ONLINE	52
第 6 章 結論與未來展望	53
參考文獻	54



表目錄

表 1 過往使用機器學習進行刀具磨耗預測相關研究	10
表 2 過往使用深度學習進行刀具磨耗預測相關研究	11
表 3 PHM2010 競賽資料集欄位	14
表 4 混淆矩陣	23
表 5 UNET 參數	28
表 6 全連接層各層參數	28
表 7 原始尺寸訓練、測試集的影像數量	29
表 8 原始圖片(2700x900)績效	29
表 9 切割圖片 64 X 900 訓練、測試集的影像數量	30
表 10 切割圖片(64x900)績效	30
表 11 切割圖片(300 X 900)之實驗 1 訓練、測試集的影像數量	32
表 12 切割圖片之實驗 1(300 X 900)績效	32
表 13 切割圖片(300x900)之實驗 2 訓練、測試集的影像數量	33
表 14 切割圖片(300 X 900)之實驗 2 績效	33
表 15 所有實驗之績效比較	34
表 16 RBF-UNET MODEL_INITIAL 時頻圖數量	35
表 17 RBF-UNET MODEL_NORMAL 時頻圖數量	35
表 18 RBF-UNET MODEL_SEVERE 時頻圖數量	36
表 19 三類磨耗之績效	36
表 20 複合式 RBF-UNET MODEL 績效	37
表 21 特徵數量	46
表 22 複合式 RBF-UNET-RANDOMFOREST 訓練、測試集的影像數量	46
表 23 1024 之績效	46
表 24 各 λ 值之績效比較	48
表 25 RBF-UNET-RANDOMFOREST 特徵數量	48
表 26 N_RBF-UNET-RANDOMFOREST 各 λ 值之績效比較	49
表 27 U_RBF-UNET-RANDOMFOREST 各 λ 值之績效比較	50

圖目錄

圖 1 刀具磨耗示意圖，以 PHM2010 資料集為例[1]	2
圖 2 頻域示意圖	3
圖 3 ADAPTIVE FEATURE LEARNING 示意圖	6
圖 4 過往三個降低成本的方法	7
圖 5 研究流程圖	8
圖 6 刀具磨損階段曲線 [16]	9
圖 7 RBF 示意圖	11
圖 8 ANN-RBF NEURAL NETWORK	11
圖 9 UNET 結構	13
圖 10 PHM2010 資料視覺化結果	15
圖 11 研究方法架構圖	16
圖 12 透過連續小波轉換之時頻圖	17
圖 13 RBF-UNET 架構	18
圖 14 UNET 架構	19
圖 15 RBF 架構示意圖	20
圖 16 RBF 示意圖	21
圖 17 RBF 運作原理[31]	21
圖 18 複合式 RBF-UNET MODEL	22
圖 19 輕量化模型架構	23
圖 20 複合式輕量化 RBF-UNET 架構	24
圖 21 混合式輕量化 RBF-UNET 架構	24
圖 22 各磨耗類別數量比例	26
圖 23 刀具磨耗三階段之時頻圖	27
圖 24 RBF-UNET MODEL 架構	28
圖 25 UNET 架構	28
圖 26 原始圖片 (2700x900)	29
圖 27 原始圖片 (2700x900) 混淆矩陣	30
圖 28 切割圖片 (64x900)	31
圖 29 切割圖片 (64x900) 混淆矩陣	31
圖 30 切割圖片 (300 x 900) 之實驗 1 混淆矩陣	32
圖 31 切割圖片 (300x900)	33
圖 32 切割圖片 (300 x 900) 實驗 2 混淆矩陣 2	34
圖 33 RBF-UNET MODEL_INITIAL 混淆矩陣	36
圖 34 RBF-UNET MODEL_NORMAL 混淆矩陣	36
圖 35 RBF-UNET MODEL_SEVERE 混淆矩陣	37
圖 36 複合式 RBF-UNET MODEL	37
圖 37 複合式 RBF-UNET MODEL 混淆矩陣	38
圖 38 $\alpha=0.1$ 重要特徵	39
圖 39 $\alpha=0.6$ 重要特徵	40
圖 40 $\alpha=0.7$ 重要特徵	41
圖 41 $\alpha=0.8$ 重要特徵	42
圖 42 $\alpha=0.9$ 重要特徵	43

圖 43 RBF-UNET MODEL_INITIAL 之 GRAD-CAM 結果.....	44
圖 44 RBF-UNET MODEL_SEVERE 之 GRAD-CAM 結果	44
圖 45 RBF-UNET-RANDOMFORES 模型架構.....	45
圖 46 複合式 RBF-UNET-RANDOMFOREST.....	45
圖 47 1024 網格特徵之混淆矩陣	47
圖 48 各 λ 之混淆矩陣.....	47
圖 49 混合式 RBF-UNET-RANDOMFOREST 模型架構.....	49
圖 50 交集聯集之混淆矩陣	51
圖 51 輕量化模型運行時間	52



第1章 緒論

1.1 研究背景與動機

近年來隨著工業 4.0 的浪潮興起，世界各大機械製造商無不積極導入物聯網與大數據分析技術來開發各項機械的輔助系統，希冀能完善這些機械的運轉效率或可靠度，並進一步提昇這些設備的賣價與銷量。而臺灣的機械製造商也不落人後，在此領域投入大量資金與研發人力，期待能透過臺灣深厚的資通訊技術能力設計出領先全球的機械輔助系統，並進一步提升臺製機械設備的全球市佔率。而在這股浪潮中，最常被提及的機械輔助系統即是附屬於 CNC 機臺的「刀具磨耗預測系統」，所謂的刀具磨耗預測系統是指廠商在 CNC 設備中加入各種感測器來接受刀具切削產品時所產生的各種切削訊號，例如使用三軸加速器來接收刀具切削時的震動訊號，又或是使用麥克風來接收刀具切削時所產生的聲音等。接著廠商會設計合適的人工智慧模型來從這些切削訊號判別目前刀具的磨耗狀況是屬於初始磨耗、穩定磨耗，還是崩潰磨耗[1]，如圖 1 為

如此的刀具磨耗預測系統一般能帶給工廠大幅降低人力成本，降低刀具的使用成本，與提升產品良率三大好處。首先在人力成本的部分，在傳統沒有如此系統的時候，刀具的更換時間點通常得由資深專業員工依據他們的經驗決定，因此每間工廠不得不依據其 CNC 機臺的數量多寡來增聘多位員工來確保刀具能準時被替換掉，但有在此系統後，工廠可將刀具的更換時間交給電腦決定，並減少聘用的員工數量。接著在刀具使用成本的部分，在傳統沒有如此系統的時候，刀具會因為工作流程或作業較為保守的員工而在仍可使用的時候就被替換掉，又以一件 CNC 加工為主的企業，其每天要替換的刀具數量是非常龐大的，若是長期發生刀具被提早更換的狀況，額外產生的刀具使用成本是很驚人的。但是若有本系統準確判斷應該換刀的時間點，則此問題將能有效的被解決。最終在產品良率的部分，由於早期刀具的更換時間點是需要人力判斷的，但有時員工一忙就會錯過換刀的最佳時機，並讓刀具進入崩潰磨耗的階段。此時刀具可能會產生缺角或裂解的情況，造成產品的損傷，並造成生產良率的降低與產生重新製作的額外成本。而若一臺 CNC 機臺能與本系統連動，則 CNC 機臺就可以在刀具進入崩潰磨耗前及時停止，則可以避免上述的問題發生。綜合上述觀點來看，一個刀具磨耗預測系統能有效降低工廠的各項成本，因此近期全世界附有刀具磨耗預測系統的 CNC 機臺銷量開始大幅提升甚至超越傳統沒有次系統輔助的 CNC 機臺。所以如何快速地替 CNC 機臺開發先進的刀具磨耗預測系統也成為臺灣機械製造商目前最迫

切的問題，因為唯有快速與先進才能讓臺灣機械製造商在這股工業 4.0 的浪潮下順利存活甚至大幅搶攻市佔率。




圖 1 刀具磨耗示意圖，以 PHM2010 資料集為例[1]

早期學者們大多是會基於機器學習演算法下去設計 CNC 刀具磨耗預測系統 [3][4][5]。一開始學者們會從各種感測器收集而來的資料中挑選適合做預測的幾個欄位，例如先把震動時間序列轉到頻域上，並取個頻段中的最大震幅來當作預測欄位，如圖 2 所示。接著學者們會透過一些降維演算法來從前述幾個預測用的欄位選取出貨整合出一些關鍵特徵值。最終學者們會把這些關鍵特徵值輸入各種機器學習模型中建模。例如 Chen *et al.* [46] 與 Kong *et al.* [17] 皆是使用迴歸模型來監測刀具的模耗狀況。Zhu and Liu [48] 與 Yu *et al.* [49] 則是基於馬可夫模型的原理設計了能預測刀具模耗狀況的模型。而除了上述的方法論外，淺層類神經網路也常被學者們用於刀具模耗預測的問題上，並被大量學者證實了該方法的有效性 [50][51]。整體而言，上述的各式機器學習方法目前已被廣泛應用到實際工廠中，一方面是因為該方法具有一定的準確度，另一方面也是因為機器學習方法通常具有運算成本低的優點，可直接在運算功能不強但低花費的工業用電腦上執行，因此深受業界喜愛。然而隨著 CNC 機檯上加裝的感測器越來越多，且了解到在近期許多研究證明深度學習模型的建模準確率較傳統機器學習模型高後，業界開始出現於刀具模耗預測系統中使用深度學習模型來取代傳統機器學習模型的需求。

使用深度學習模型來實現刀具磨耗預測系統一開始的流程與傳統的機器學習的做法相同，都是先從感測器收集到的資料中挑選數個預測用的欄位開始。但深度學習作法與機器學習做法最大的不同是在於深度學習不會再透過降為演算法來從欄位中取得隊預測來說的關鍵特徵值，而是會直接將收集到的欄位輸入至深度模型中，並讓深度學習模型在訓練時讓模型的前幾層神經元先找到適合預測的關鍵特徵值，其後才會讓

模型後面幾層神經元針對這些關鍵特徵值來建模，一個簡單的說明範例則如圖 3 所示。




圖 2 頻域示意圖

特別的，上述做法學者們通常稱之為深度學習模型的 Adaptive feature learning 特性 [2][3]，並認為是深度學習模型準確率會較傳統機器學習模型更好的關鍵。因為過往方法雖然能利用降維演算法找到對目標預測問題來說的關鍵特徵值，但這些特徵值卻不一定適合後續用來建模的傳統機械模型。相較之下，深度學習模型在訓練時因為能同時完成選取關鍵特徵值與建模兩個動作，所以建出來的模型必然能與被選取出的關鍵特徵值相契合，也因此提升了建模的準確率 [25][52]。而業就因為深度學習有如此的特性，近期吸引了許多學者投入相關研究，期能找出最適合用於刀具模耗預測議題的深度學習模型。例如 Kurek *et al.* [52] 使用了 Convolutional neural network 來分析鑽頭的磨損狀況。Zhang *et al.* [25] 使用了 Long short-term memory model 來預測刀具的模耗狀況。整體而言，上述研究都證實了不管是使用哪種深度學習模型，其預測準確度通常會比傳統機器學習方法來的精準，因此理應能激起產業界基於深度學習模型來實現刀具模耗預測系統的想法。但我們發現大部份的工廠短期內並沒有如此計畫，因為以下兩大問題。

(1) 深度學習模型的運算成本高，若每臺 CNC 都必須使用一個深度學習模型來進行磨耗預測的運算，則工廠將無法負擔如此高的運算成本：眾所皆知，深度學習模型雖然能帶來比其他機械學習模型更高的建模精準度，但其也帶來龐大的運算量這個副作用，在這個情況下，若工廠想要透過深度學習模型來替一個 CNC 機臺做即時的模耗預測，則工廠就必須在這個 CNC 機臺周邊安裝高成本的可運行 GPU 電腦，又或者是建置與租借昂貴的高階雲端計算服務才能達成。又我們必須了解到一個稍具規模工廠所擁有的 CNC 機臺數量不會僅有數臺，通常會有數十到數百臺。在這情況下，不管工廠是要替每臺 CNC 架設一臺專屬的具 GPU 電腦，還是要建置或租借雲端平臺，這些

額外的設備建置費用將會是非常驚人而難以負擔的。

因此從 2018 年開始，學者們陸續提出各種方案來開發建模精準度接近深度學習模型，現介紹如下。過往第一種方法是針對目標的深度學習模型設計一個專屬的硬體來運行這些模型[53][54]，如圖 4(a)所示。這類作法雖然確實可以大幅降低模型的運算成本，但本方法的運用彈性過低且需要花費額外的硬體設計與製作成本，明顯與目前刀具模耗預測問題所需的高彈性應用模型與低成本相抵觸，因此不適用於本研究。過往第二種作法是先訓練一個深度學習模型，接著刪減這個模型中對輸出最沒有貢獻的權重、神經元或層。最終於線上使用這個刪減後的深度學習模型來進行預測[5][6]，如圖 4(b)所示。這類作法的先驅是 Han *et al.* [4]，他們提出使用 L1/L2-norm regularizations 來找出深度學習模型中對輸出數值影響不大的權重值，並驗證這些權重值若能從深度學習模型中被刪除，則該深度學習模型的運算成本不僅能有效降低，且其效能也不會受到太大的影響。接著，Scardapane *et al.*[5]和 Wen *et al.*[6]則使用 Lasso penalties 來達到同樣的目標。不過上述作法在現實中並不實用[7][8][9]，因為一個訓練後的深度學習模型若刪除部分權重值，則該模型的權重矩陣會變成稀疏矩陣，但目前硬體仍只會把稀疏矩陣視為一般矩陣運算，因此權重值刪除前後的運算成本幾乎不變。近年有其他學者提出直接刪除已訓練之深度學習模型一整層神經元的想法。如 Li *et al.*[10]提出先計算 Filters 層的絕對權重總和，再將權重和較小之層刪除。Molchanov *et al.*[11]提出用泰勒展開式估計 Filters 層對 Loss 函數的影響來評估該 Filters 層是否該刪減。Luo *et al.*[12]則是導入貪婪演算法的概念，從影響 Loss 函數最大的 Filter 層開始挑選，直到挑選數量符合使用者設定的條件為止。整體而言，上述幾種作法都成功驗證他們方法的可行性，然而我們必須了解到一個深度學習模型即便刪去部分層，其本質仍是一個深度學習模型，雖然建模準確度可以被維持，但其與原本深度學習模型相同，都需要大量的運算成本，因此這類作法對降低模型運算成本幫助是有限的，可能不適用於本論文。

至於過往最後一種實現高精準度輕量化 AI 模型的方式是依據深度學習模型的 Adaptive learning 特性所設計的，其運作概念則如圖 4(c)所示。如前所述，所謂的 Adaptive learning 能在深度學習模型訓練時，透過網路前半部的參數找出最適用於網路後半部建模的因子[13][14]。因此近期有學者提出若能從網路中有效提出這些因子，再把這些因子放入其他低成本的傳統 AI 模型，則這些 AI 模型也應能達到與深度學習模型類似的建模準確率，但建模成本確能大幅降低。如 Sani *et al.* [13]直接將深度學習模

型最後一個池化層的輸出視為關鍵因子，將這些因子輸入 K-Nearest Neighbor 建模，並成功建立起低成本的動作辨識模型。Mohammad *et al.* [14]設計一連串的數學公式來拆解深度學習模型內的參數以獲得關鍵因子，並證實使用這些關鍵因子來建立的低成本 AI 模型，其在動作辨識上的表現能獲得與深度學習類似的準確度。Chen *et al.* [56]與 Chiu *et al.* [57]則是在替地圖網格數值建模的議題中，先使用 Grad-Cam 套件來獲得卷積類神經網路在所有輸入網格中所認定的關鍵網格，接著他們證實即便這些關鍵網格是與相對低成本的 AI 模型搭配，其建模準確率也與原本的卷積類神經網路差異不遠。近年則有 Chen and Lee [31]與 Chiu *et al.* [58]開發 RBF-based 深度學習模型，並宣稱他們能透過這些外加的 RBF 快速找出深度學習模型在所有輸入中所找到的關鍵輸入為何，並驗證這些關鍵輸入即便搭配較低成本的 AI 模型也能達到與深度學習模型類似的建模準確度。整體而言，這類作法相較於前兩種作法能夠以更低的運算成本達到與深度學習模型類似的建模精準度，因此本論文將基於本作法的概念來進行後續模型與演算法的開發。

(2)過往的刀具磨耗預測研究中，無法同時考慮資料中時域與頻域的特性：雖然有學者將震動資料轉換成時序資料並使用了 Long short-term memory model 來預測刀具的模耗狀況，這種做法能有效表示時域上的特性，但卻對取出頻域上的特性幫助不大。也有學者把震動時間序列轉到頻域上，並利用各種機械模型做預測，這種作法則是能表示頻域特性，但卻對取出時域特性幫助不大。也因此本研究提出使用時頻圖做刀具磨耗預測的研究，並因此同時考慮時域與頻域的資料。

在過往研究中深度學習模型在處理圖片資料時大多偏好使用以 CNN 為基底的模型，然而這類模型的建模效能將受限於 CNN 卷積核的大小。若卷積核設的太小，則模型難以考量矩陣中的大範圍特徵。反之，若卷積核設的太大，則模型會忽視矩陣中的小範圍特徵。而這點對一般的圖像辨識議題來說問題並不大，因為使用者可透過事先觀察來了解目標圖像資料集大部分的物體大小，並設置合適的卷積核大小。但對本計畫案討論的刀具磨耗時頻圖來說，因為我們無法事先解讀時頻圖中的關鍵特徵位置與大小為何，所以我們很難事先找出合適的卷積核大小，大多僅能靠試誤法來找到最佳解，所以我們提出新的方法來解決這個問題。




圖 3 Adaptive feature learning 示意圖

1.2 研究目的

綜合上述，本研究基於兩個概念提出 RBF-UNet Model 來解決以上的困難，(1)概念一，此概念框架是以圖 3(c)的設計理念來建立目標的刀具磨耗預系統，解決其深度學習運算成本過高的問題，亦即先訓練一個深度學習模型、拆解這個模型來取出其所找到的關鍵建模用特徵值。最終將這些特徵值輸入至低成本 AI 模型建模。然而本研究將透過已被證實可以有效降低深度學模型成本的 RBF 來進行網路的拆解，並搭配(2)概念二，引進了可同時考慮多種特徵範圍的 UNet[15]，來協助解決時頻圖因為卷積層的大小而找不到關鍵特徵值的問題，最終期待能透過概念一與概念二提出的 RBF 與 UNet 的結合在先行深度學習模型僅訓練一次的狀況下，快速找出目標刀具磨耗預測問題的最適特徵範圍，並以此取出最適合用來建立後續低成本 AI 模型的時頻圖關鍵輸入網格




圖 4(a)




圖 4(b)




圖 4(c)

圖 4 過往三個降低成本的方法

1.3 研究流程

本研究之流程圖如圖 5 所示，各階段說明如下：

1. 確認研究問題

根據過往刀具磨耗預測研究議題，之研究議題，針對各研究 所提出預測方法之缺點，提出一種能低成本高精度的 AI 預測模型。

2. 相關文獻回顧

對於刀具磨耗預測之相關研究進行方法回顧，並針對不同預測模型研究進行介紹，如長短期記憶類神經網路。

3. 資料收集與整理

PHM2010 競賽資料集中的三把完整的感測器訊號及刀具磨耗，以及 PMC 資料集中四把完整的感測器訊號及刀具磨耗。

4. 觀察資料

將資料視覺化，了解感測器資料的分布狀況，並依照分布狀況對資料做後續的處理，對於本研究而言，視覺化觀察資料後便能得知是否存在異常值與缺失值。

5. 結合 RBF 與 UNet 開發全新模型

建構一個可以考慮時頻域的模型協助開發低成本 AI 預測模型

6. 模擬測試

將實際資料輸入至本研究開發之刀具磨耗預測模型中進行預測，並透過模擬驗證之推估模型準確度及預測效率進行參數之調整與修正。

7. 結論

根據模擬測試後的模型之預測結果驗證本研究開發之預測模型是否降低建模成本及預測是否準確，並依照研究結果提出結論與未來相關研究建議。




圖 5 研究流程圖

第2章 文獻回顧

2.1 刀具磨耗預測方法

2.1.1 刀具磨耗特性介紹

眾所皆知，影響 CNC 刀具磨耗的原因有很多，不同的刀具材質，不同的工件材質或是 CNC 機器上設定的各種不同的主軸轉速、進給率、切削深度等的參數皆會影響到刀具的磨耗，而這些影響條件跟刀具磨耗有著一定的關係，如 Bhuiyan *et al.*[16]與 Dolinsek *et al.*[17]分別都證實了這件事情，二者都是利用聲發射感測器收集到的 CNC 機臺加工時所產生的聲音的數據，前者提出影響刀具磨耗的原因是主軸轉速，後者則是認為工件的才是影像刀具磨耗的主因。然而刀具的磨耗也不是從開封到淘汰都是一樣的，所有東西的產生一定都要經過只屬於他的過程方能產生，而每樣新的東西開始使用時，都會有一段的磨合期，當然在 CNC 刀具的部分也不例外，而在這部分我們稱這個磨合期為初始磨耗(Rapid initial wear)，這是因為每把剛拆封的刀具的每個刀刃不一定是等長的，而最先與工件接觸的便是那最長的一刀，因為是只有一刀接觸工件，使其磨耗速度較快，一段時間後，較長的那刀變得與其他刀一樣長時，其受壓面積也隨之變大，此時的刀具磨損狀況較為穩定，其磨損速度也趨於穩定，此階段的磨耗稱之為正常磨耗(Uniform wear)，此階段可以穩定的切削且其加工的效率最高，刀具隨著切削工件的時間越長，其銳利度也會慢慢降低，刀具變鈍，其切削時的摩擦力與溫度都會增加，很快的就會失去切削能力，此階段稱為崩潰磨耗(Failure)，在此階段刀具容易出現缺角或裂解的情況，而在此階段所加工的工件其精度不佳且工件容易受損。所以我們必須在刀具進入這個階段之前就要將刀具更換掉。




圖 6 刀具磨損階段曲線 [16]

2.1.2 使用機器學習解決刀具磨耗預測的問題

機器學習 Machine Learning 是 AI 人工智慧的一個分支，以演算法訓練、學習、改進運用大量數據資料或過往的經驗，以達到最佳化的效能，做出更好的分類、判斷和分析，而這樣的方法已經普遍應用在工廠中。如 Benkedjouh *et al.*[18]就同時架設多個感測器在機臺上收集資料。但是隨著科技的進步，感測器更加的發達，又因如果同時架設多個感測器在機臺上，其收集到的資料量會極為龐大，為了使資料量降低，需要透過特徵提取或是降維來達成，為了找出對預測最有幫助的資料，Jalali *et al.* [19] 證實他們利用基因演算法進行取特徵值與降維成功找出對預測有幫助的資料並搭配 SVM 來監測銑刀狀態，Gomes *et al.*[20]也一樣使用 SVM 來進行銑刀的磨耗，或是像 Mohanraj *et al.* [21] 藉由取出的小波係數等資料利用決策樹找出對預測有幫助的資料。機械學習的運作流程則是要先找出對資料有意義的資訊，然而為了取特徵值或降維，必須設計一套演算法或是方法，但是要設計出演算法或是方法談何容易。重要資料取出之後就要建模，然而目前已經有學者成功利用類經網路模型進行積排監測，如 Hesser *et al.*[22]應用類神經網路進行 CNC 刀具磨耗的監控刀具 Corne *et al.*[23] 使用 ANN 預測鑽孔過程。

表 1 過往使用機器學習進行刀具磨耗預測相關研究

年分	學者	方法
2020	Mohanraj <i>et al.</i> [21]	使用決策樹與 SVM 進行監測銑刀狀態
2017	Corne <i>et al.</i> [23]	使用 ANN 預測鑽孔過程
2020	Gomes <i>et al.</i> [20]	使用感測器蒐集振動數據，並用 SVM 進行銑刀的刀具磨損監控
2019	Hesser <i>et al.</i> [22]	應用 ANN(類神經網路)進行刀具磨耗的監控。

2.1.3 使用深度學習解決刀具磨耗預測的問題

依據上一部分所寫的，機器學習模型遇到龐大的資料集時，想要降低資料量需要透過人工或是利用那些取特徵值或是降維的方法，這個步驟耗時又耗神，且取出的特徵值不一定會符合後續的建模，所以學者們為了不想在這個步驟多花費時間，而深度學習模型剛好的特性就是能夠進行 Adaptive feature learning，可以自行找出最合適建模的特徵值，所以學者們發展出利用深度學習模型來預測刀具磨耗。如 Jia *et al.* [24]證實了深度學習的 Adaptive feature learning 能協助深度學習模型預測更加準確，Zhang *et al.* [25] 嘗試用 Long short-term memory model 來進行刀具磨耗預測，Sun *et al.*[26] 則是利用 Auto-encoder 進行刀具磨耗預測。Zhao *et al.*[27] 應用雙向改良後的遞迴類神經網路

(Gated Recurrent Unit Networks)進行機器健康監視。上述的文獻中都不僅解決了機器學習取特徵值的困難且期都有不錯的績效，但我們必須要瞭解到這些方法雖然執行成本很高，所以電腦效能就要更高，甚至是要使用到 GPU，但是 GPU 的價格是超出大部分中小企業所能負荷的範圍，所以中小企業中的接受度不高。

表 2 過往使用深度學習進行刀具磨耗預測相關研究

年分	學者	方法
2016	Jia <i>et al.</i> [24]	旋轉工具機故障檢測使用 MLP 進行檢測。
2017	Zhao <i>et al.</i> [27]	應用 Gated Recurrent Unit Networks 進行機器健康監視。
2017	Zhao <i>et al.</i> [24]	應用卷積雙向長短期記憶模型進行機器健康監視。
2019	Cheng <i>et al.</i> [25]	應用卷積類神經網路進行皮帶模削機的切削監控。

2.2 RBF 的應用

Radial Basis Function (RBF)過去最常被用來當作機器學習中 Support Vector Machine (SVM)算法的核函數 [28][29][30]，而其常見的函數有線性的多項式函數，也有非線性的高斯徑向基函數等等。RBF 的作用在於將輸入特徵來逼近某一個給定的函數。如圖 7 中，輸入特徵 x 會經某個 RBF 核函數 $y = f(x)$ 轉換後，RBF 中的高斯徑向基函數會用來擬和輸入特徵的分布，這種擬和特徵的能力在處理許多非線性特徵關係上有著很好的優勢，有學者透過 RBF 在機器學習的運用上取得良好的預測性能。而隨著近幾年深度學習的發展，有學者開始將 RBF 加入到 Artificial Neural Network (ANN)的神經元當中。




圖 7 RBF 示意圖




圖 8 ANN-RBF Neural Network

例如 Yilmaz *et al.* [31] 比較兩種人工神經網路 ANN-RBF 和 ANN-MLP 預測土壤膨脹百分比的性能，這兩種網路都是由輸入層、隱藏層與輸出層構成，其中 ANN-RBF 在隱藏層中加入高斯徑向基函數，如圖 9 所表示。由他們的實驗結果可得知，透過 RBF 中的高斯徑向函數轉換可以減少神經網路中反向傳播進行搜索空間的維度，ANN-RBF 因為其良好的非線性的轉換能力使的收斂的速度比 ANN-MLP 來的更快。而 Zeng *et al.* 提出一種基於 RBF 神經網路的模型，用來預測短期的太陽能功率。他們發現 RBF 神經網路能夠有效捕捉太陽輻射數據的非線性和時變的特性，因此該模型能取得更低的預測誤差。Wu *et al.* [32] 透過將 Particle Swarm Optimization(PSO)與 Genetic Algorithm(GA)的概念融入 RBF 神經網路中，用來預測降雨機率。他們用融合最佳演算法的方式為 RBF 神經網路的參數做調整，使模型具有更有效的預測能力以及避免模型提早收斂在局部最優點。Chen *et al.* [33] 提出 RBF-LSTM 模型來預測空氣中 PM2.5 濃度的數值。他們利用分析 RBF 中的徑向基函數的輸出，以提取深度學習模型識別重要的關鍵特徵。透過這些關鍵特徵的建模預測來提升模型的準確度並且降低訓練成本。

2.3 UNet

本研究對 UNet 的相關研究進行調查，首先 UNet 最早是由 Ronneberger *et al.* [41] 所提出，他們用根據 Fully Convolution Network(FCN)的概念發明了 UNet 來對細胞膜影像進行辨識和分割。其結構如圖 9 所示為一個 U 形狀的 Convolutional encoder-decoder 對稱網路結構，前半段的 encoder 輸入圖像的特徵提取器，後半段的 decoder 會讀取特徵進行最終的輸出，並且兩者之間會使用 skip connections 傳遞重要特徵訊息。此結構的效果在當時被證實擁有非常傑出的表現。

因此開始有許多學者研究基於 UNet 的改良模型或是將 UNet 應用在醫學領域 [35][36][37] 和其他領域 [38][39][40] 等等。例如 Oktay *et al.* [41] 提出 Attention UNet 來進行 Pancreas 的分割任務，他們提出一種 attention gate 使模型能夠自動學習關注不同形狀




圖 9 UNet 結構

和大小的目標醫療影像。Stoller *et al.* [42] 提出 Wave-UNet 來進行端到端的 audio source separation。他們證實了這種 UNet-like 的結構提取的 feature maps 能夠有效地使模型分辨不同時間尺度的特徵。最近有學者考慮建模成本的問題，如 Zhang *et al.* [43] 提出一種用於環境微生物(EM)圖像分割的低成本 UNet(LCU-UNet)，因此也改善了 UNet 相對較高的內存成本問題。另外 Yu *et al.* [44] 提出了 Spatio-Temporal UNet(ST-UNet)來預測 spatio-temporal graph，他們的實驗結果證實了此模型可以有效地從時空圖中探索局部和全局的空間特性。最近，Zhou *et al.* [45] 在 ST-UNet 架構上加入注意力機制對車站級別人流時空圖做預測。他們利用模型中內部分層的時空注意力機制來有效克服應人群流量而產生的複雜時空相關性。

2.4 小結

上述回顧了 RBF 函數與 UNet 的相關研究，我們從中了解到 RBF 對於預測問題的相關研究，從他們的研究可得知，RBF 擁有對於非線性擬和傑出的能力，並且可以加快模型收斂的速度，降低建模所花費的成本。也可以了解到 UNet 在各領域有著傑出的表現，所以本研究也將結合他的結構來協助本研究的模型開發。

第3章 資料集

本研究將使用 PHM2010 競賽資料與 PMC 機臺收集的數據兩個資料集，下面將分別介紹這兩個資料集。

3.1 PHM 2010 競賽資料

這小結將介紹 PHM 2010 競賽資料，所謂的 PHM 指的是名為 Prognostics and Health Management Society 的非營利組織，該組織藉由提供資料集舉辦競賽來提升工程科學的發展，而本研究所使用的 PHM2010 資料集更被視為 Benchmark Dataset，該資料當中紀錄了 CNC 機臺用 6mm 碳化鎢球刀切削不鏽鋼切削一硬度為 HRC52 的工件過程產生的數據，將機臺的主軸轉速設定為 10400 RPM、進給率為 1555 mm/min、切削深度為 0.2 mm 做為當時的實驗參數，整個資料集包含了六把刀的切削在切削時所產生的感測數據，而因這個資料集當時為競賽資料集，所以該組織將資料集一分為二，一半有著完整的感測數據集與刀具的磨耗值做為訓練集，而另一半則是測試集，為該組織驗證參賽團隊方法的有效性故沒有提供刀具磨耗的數值，因此，本研究僅能使用其中有完整數據的三把刀來進行研究。

該資料集總共包含了七個欄位，其中，三個欄位為 x 軸、y 軸、z 軸三軸的加速度，三個欄位為 x 軸、y 軸、z 軸三軸的震動資料，最後一欄為聲波資料，如表 3 所示，該資料集每把刀會進行三百一十五次的切削，由於每次的切削的時間不一樣長，所以造成該資料的比數介於十萬至三十萬不等。

表 3 PHM2010 競賽資料集欄位

	x 軸加速度	y 軸加速度	z 軸加速度	x 軸震動	y 軸震動	z 軸震動	AE 聲波
1	0.606	1.100	-0.144	-0.017	-0.024	-0.042	-0.004
2	0.516	1.071	-0.188	0.243	0.249	0.241	-0.005
3	0.433	1.060	-0.218	-0.062	-0.061	-0.042	-0.005
...	...	...	...	...	...	...	...
219122	-0.010	1.685	3.952	0.101	0.089	0.112	-0.004




圖 10 PHM2010 資料視覺化結果



第4章 研究方法

本研究提出之方法將刀具磨耗預測分為兩部分，分別為 Offline 訓練與 Online 運作兩部分，研究方法架構圖如圖 14 所示。在 Offline 訓練中又分為兩個部分，第一部分是為了使後續模型的運算量降低，於是開發了一個名為 RBF-UNet Model 來找出對於刀具磨耗重要的特徵值。第二部分則是使用第一階段所訓練好的 RBF-UNet Model 從資料中找出符合的特徵值，進而利用低成本的 AI 模型進行刀具磨耗預測，因此本研究將著重於開發 RBF-UNet Model 的開發，盡可能地找出真正影響刀具磨耗的因素。在 Online 運作的部分，當 CNC 機臺的震動資訊輸入時，運用本研究所開發的低成本 AI 模型進行磨耗預測。




圖 11 研究方法架構圖

4.1 資料預處理

本小節將針對感測器的資料進行資料前處理，分別為第一步資料清洗以及第二步時頻圖轉換，下面會依序說明。

4.1.1 資料清洗

凡是經過感測器所收集的資料，都會因為電壓不穩定、網路設備故障、或者本身感測器問題等各種原因而造成資料的缺失，然而使用有缺失值的資料進行模型的預測，會造成模型的不準確，所以必須將其缺失值使用各種補值方法進行補植。而本研究所

使用的資料集是透過加裝在 CNC 機臺上的感測器所收集到的數據，所以該資料集也不例外的有缺失值的產生，本研究將使用過往研究中最常被使用的線性插值法來將資料集中有缺失值與異常值的地方進行補值。

$$x_n = x_{n-1} + n\Delta \quad (1)$$

$$\Delta = \frac{x_{t+1} - x_0}{t+1} \quad (2)$$

4.1.2 時頻圖轉換

Morlet 與 Grossman[2]所提出連續小波轉換是常被用來將資料從時域轉換成時頻域資料的方法，本研究也將裡用此方法來將震動資料轉換成時頻域資料，供後續模型做使用，公式如下：

$$W(a,b) = \int_{-\infty}^{\infty} f(t)\psi_{a,b}(t)dt \quad (3)$$

數位訊號常使用透過連續的函數處理連續時間的資料，藉由母小波(ψ)，以及母小波函數經過延展與位移所得出的延展係數(α)、平移參數(b)兩個基底函數所組成的連續小波轉換公式，公式如下，可以獲取到可以用來分析在不同時間不同延展下的變化的小波係數。圖 17 的時頻圖為運用連續小波轉換後的資料所轉換。

$$W_x(a,b) = \langle f(t), \psi_{a,b} \rangle = \frac{1}{\sqrt{a}} \int_R f(t) \psi \times \left(\frac{t-b}{a}\right) dt \quad (4)$$

$$f(t) = \frac{1}{C_\psi} \int_{-\infty}^{\infty} \int_0^{\infty} \frac{1}{a^2} W_x(a,b) \psi_{a,b}(t) da db \quad (5)$$




圖 12 透過連續小波轉換之時頻圖

4.2 RBF-UNet Model

本小節將介紹本研究所開發的 RBF-UNet Model，架構如圖 18 所示，其中包含了 UNet 層、一個攤平層、RBF 層以及多個隱藏層，多個隱藏層構成一個完整的 DNN 的低成本 AI 模型，下面會分成(1) UNet、(2) RBF 函數兩部分進行說明。




圖 13 RBF-UNet 架構

4.2.1 UNet

首先是將時頻圖輸入至 UNet 中找出影響刀具磨耗預測的候選特徵，UNet 由 Ronneberger 等人 [34] 所提出，其架構圖顯示在圖 17 中。UNet 主要是以其網路形狀類似英文字母 U 而聞名，該網路全部由卷積層所構成，因此也可稱為所謂的 Fully Convolutional Network(FCN)[55]。它由左側的收縮路徑和右側的擴展路徑所組成每一個卷積層都搭載 3×3 的卷積核和 ReLU 激活函數。在收縮路徑中的 down sampling 由 2×2 的最大池化層負責處理其會將特徵圖的長寬縮減並且將通道特徵數量加倍；而在擴展路徑中則會用 2×2 的 up sampling 將特徵圖的通道數量減半並且會將在縮減路徑中對稱的特徵複製過來一併進行卷積來將特徵圖的大小還原。在最後一層會使用 1×1 的卷積層來進行最終的輸出。雖然該網路原先被設計用來做影像分割的任務，然而本研究發現此網路架構也適合用來解決時頻圖的特徵尋找的問題，因為其架構中，隨著卷積層層數的增加，就可以得到由小到大不同範圍的特徵，可以讓我們完整的考慮到時頻圖中所有大小的特徵值。




圖 14 UNet 架構

4.2.2 RBF

接下來是 RBF 層的部分，在進入 RBF 層之前，本研究先將時頻圖經過上一小節提到的 UNet 找出了不同大小的候選特徵，藉由一個攤平層將所有特徵攤平，接下來我本研究將藉由 RBF 函數來找出其關鍵的特徵，本研究將會將 UNet 所找出的特徵值進行攤平的動作。攤平後的特徵數以 m 來表示，而每個特徵將會搭配 q 個 RBF 神經元，這意味著 RBF 層中將會有 $m \times q$ 個 RBF 神經，每個 RBF 神經元的功能為透過高斯函數的計算，公式如下，公式中 i 與 j 分別表示模型內第 i 個輸入及第 j 個 RBF 函數，而 σ_{ij} 和 m_{ij} 則代表此神經元中 RBF 函數的標準差及平均值。

$$O_{ij} = \exp \left[\frac{-\left(Output_{input_layer} - m_{ij} \right)^2}{\sigma_{ij}^2} \right] \quad (6)$$




圖 15 RBF 架構示意圖

接下來介紹 RBF 運作原理，如圖 21 所示，假設候選特徵_1 與候選特徵_2 各有 3 個 RBF，代表圖 21 中每個輸入面的三個 RBF 神經元。來自候選特徵_1 的 RBF 和來自候選特徵_2 的 RBF，可以描述座標軸上的範圍，如圖 22(a)中的虛線圓圈。圖 22(b)顯示了訓練後的狀況。該圖清楚表明訓練後所有 RBF 的位置和大小與訓練前不同徑向基函數經過訓練後也能更準確地描述三類數據（黑色、灰色和白色）的範圍。在這種情況下，圖 21 中網絡的後續層再根據 RBF 描述的結果進行後續計算，從而可以更準確地確定每類數據對應的結果。我們擴展這個概念來確定刀具磨耗預測問題的關鍵特徵。最初，我們使用 UNet 找出時頻圖所有的特徵，將得到的輸入到 RBF-UNet Model 中，訓練模型以實現高精度的刀具磨耗預測。訓練後，RBF 層應標記對圖 21 有用的數據點的分佈。




圖 16 RBF 示意圖




圖 17 RBF 運作原理[31]

4.2.3 隱藏層

RBF-UNet Model 最後一部分是包含多個全連接層。這些層中的每個神經元整合前一層所有神經元的輸出，並將整合結果輸出到後續層，第 i 層神經元 j 的公式如下所示，其中 o_i 表示上一層所有神經的輸出量， w_{xj} 表示一個神經元之間連接的權重值， b_j 是該神經元的配置。

$$o_j = o_i \times w_{xj} + b_j \quad (7)$$

4.2.4 從 RBF-UNet Model 取出重要特徵

如上面所述，在 RBF-UNet Model 訓練的同時，可以通過 RBF 層來標註輸入的候選特徵的關鍵數據的分布，接下來確定為了選出對候選特徵關鍵的特徵值，假設每個大小的卷積層攤平後有 q 個 RBF，其中有 k 個確定包含對預測有用的數據，將門檻設

定為 β ，如果 k/q 大於 β 則代表此大小的卷積層對於 DNN 預測很有用，因此被選為重要特徵，反之，則大小的卷積層對預測沒有用，不會被選出來。

4.2.5 複合式 RBF-UNet Model

本研究擔心一個 RBF-UNet Model 要分辨三種類別的磨耗對模型來說會負荷太重，所以本研究基於 RBF-UNet Model 的基礎開發了複合式 RBF-UNet Model，架構如圖 18 所示，本研究將三個磨耗類別各自建立一個 RBF-UNet Model，讓模型只判斷是否為初始磨耗的 RBF-UNet Model_Initial、判斷是否為正常磨耗的 RBF-UNet Model_Normal 與判斷是否劇烈磨耗的 RBF-UNet Model_Severe，最後再將這三個模型的輸出結果進行合併得到最終的結果。




圖 18 複合式 RBF-UNet Model

4.3 績效評估

因本研究目的是為了改善過去刀具磨耗預測系統運算成本高之成本過高的問題，所以將本研究所建立的 RBF-UNet Model，與過去的方法做比較是否較低，為了驗證本研究提出的方法對於刀具磨耗預測的有效性，本研究將利用混淆矩陣做為評估指標，如表 4 所示，透過計算模型預測結果的準確率(Accuracy)、精確度(Precision)、召回率(Recall)與 F1-score 作為模型評估的指標，其計算方式如下。

表 4 混淆矩陣

實際\預測	Positive	Negative
Positive	True Positive(TP)	False Positive(FP)
Negative	False Negative(FN)	True Negative(TN)

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (8)$$

$$Recall = \frac{TP}{TP + FN} \quad (9)$$

$$Precision = \frac{TP}{TP + FP} \quad (10)$$

$$F1-score = \frac{2 \times Recall \times Precision}{Recall + Precision} \quad (11)$$

4.4 輕量化 RBF-UNet

因為本研究提出的 RBF-UNet Model 的模型運行時間與成本較高，本研究想將 RBF-UNet Model 進行輕量化，本研究計畫將後面多個全連階層由傳統機器學習、淺層類神經等成本較低的模型替換，如圖 41 所示，本研究將從 RBF Layer 拆解得出的重要特徵投入低成本模型進行判斷，進而讓模型整體的運算成本降低，且還可以得到與原始模型差異不大的準確率。




圖 19 輕量化模型架構

4.4.1 複合式輕量化 RBF-UNet

本研究基於複合式 RBF-UNet Model 進行輕量化，設計出複合式輕量化 RBF-UNet，這個部分是分別將 RBF-UNet Model_Initial、RBF-UNet Model_Normal 與 RBF-UNet Model_Severe 這三個模型依照輕量化 RBF-UNet 架構進行輕量化，如圖?所示，使每個

模型達到輕量化的效果，使每個模型運行的時間縮小，進而使總運行時間變少，加快預測速度。




圖 20 複合式輕量化 RBF-UNet 架構

4.4.2 混合式輕量化 RBF-UNet

本研究繼續基於輕量化 RBF-UNet 設計混合式輕量化 RBF-UNet，本研究將 RBF-UNet Model_Initial、RBF-UNet Model_Normal 與 RBF-UNet Model_Severe 這三個模型所輸出的重要特徵分別進行交集或聯集設計兩格混合式輕量化 RBF-UNet，架構如圖所示，首先是 U_RBF-UNet 是將三個模型重要特徵做做聯集，把三個模型覺得重要的特徵都輸入到低成本 AI 模型中進行預測，接下來是 n_RBF-UNet 是將三個模型重要特徵做交集，找到對於三個模型都重要的重要特徵，以降低投入低成本 AI 模型的特徵數量。




圖 21 混合式輕量化 RBF-UNet 架構

第5章 實驗模擬

本研究使用 PHM 2010 競賽資料的 CNC 震動資訊透過連續小波轉換成時頻圖作為本研究之研究框架的輸入資料集，刀具磨耗值經過分類最為輸出，此框架包含訓練三個部分，第一部分是訓練 RBF-UNet Model 將刀具磨耗進行分類，第二部分是拆解 RBF-UNet Model 來找出在時頻圖中影響刀具磨耗的重要特徵，第三部分則是透過輸入重要特徵來訓練低成本 AI 模型，最終以量化方式來驗證各模型績效，以下分為六個部分進行介紹，(1)震動資料資料切割，(2)時頻圖轉換，(3) RBF-UNet Model 訓練，(4)拆解 RBF 分析重要特徵，(5) 輕量化模型訓練，(6)Online，本研究的所有實驗皆是以 Python 程式語言進行實作，並且操作在 Intel(R) Core(TM) i9-9940X CPU @ 3.30GHz 的 CPU、兩顆 Nvidia TITAN RTX 24GB 的 GPU、搭配約 128GB 記憶體，並使用 Windows 10 的作業軟體來完成。

5.1 震動資料切割

PHM 資料集中，本研究將空值利用線性插值補值之後，得到一個完整的 PHM 資料集後，資料集中包含了 c1、c4、c6 三把刀具的震動與刀具磨耗資訊，本研究將 c1、c4 兩筆資料當作模型的訓練資料集，c6 則是模型的測試資料集。但是每一次加工所產生的振動訊號長度落在 12 萬到 30 萬不等，本研究希望每一筆訊號的長度皆一致，且讓資料的損失的情況降到最低，所以本研究針對每一筆原始的震動訊號進行切割，本研究以長度 5000 對原始資料進行切割，以達到每一筆訊號長度是一致的。針對刀具磨耗，本研究利用其磨耗的數值大小將其分成初始磨耗、正常磨耗、劇烈磨耗三種磨耗種類，當磨耗小於 66 即為初始磨耗，也就是新的刀具每一刀刀鋒進行磨合的階段，介於 66 至 165 之間的本研究將其定義為正常磨耗，大於 165 則是劇烈磨耗，即是刀具必須淘汰的情況，但是從圖 22 可以看出其三個類別的數量及其不平衡，所以本研究在投入模型之前都會先進行資料平衡，本研究將以三種磨耗類型中數量最少的類型作為平衡的標準，將其他類型的張數隨機抽樣使其數量達到平衡。






圖 22 各磨耗類別數量比例

5.2 時頻圖轉換

從上一節本研究得到一筆資料長度一致的震動訊號資料，本研究將透過連續小波的方式將每一筆的震動訊號資料轉換成繪製時頻圖的資料，本研究在利用這些資料花初時頻圖，本研究所生成的時頻圖的原始大小為 2700x900，如圖 23 所示。






圖 23(c)劇烈磨耗

圖 23 刀具磨耗三階段之時頻圖

5.3 RBF-UNet Model

本研究將繪製成時頻圖的震動訊號資料輸入至自行開發的 RBF-UNet Model 來進行刀具磨耗的分類，但是本研究在實驗過程中發現輸入 RBF-UNet Model 的時頻圖的尺寸會影響到該模型分類的準確率，因此本節透過將一張時頻圖切割成不同大小範圍的時頻圖來進行多次實驗，然後將每個實驗所得到的績效結果進行比較後，最後得到最適合該模型之較佳的圖片大小，下面將會詳細介紹本研究所設計三種圖片尺寸的實驗，本研究將訓練出來的模型透過混淆矩陣、Accuracy 等指標來判定模型的績效，本節將會分為模型架構、三種不同大小範圍的時頻圖及三模型這幾個部分進行介紹。

5.3.1 模型架構

首先是模型架構，RBF-UNet Model 是由一個 UNet 架構、RBF Layer 及多個全連接層三個部分所組合而成，如圖 24 所示，本研究會將時頻圖投入 UNet 進行不同大小的特徵提取，本研究會將 UNet 所有的層進行攤平及合併輸入至 RBF Layer 中，在 RBF Layer 中本研究給攤平的每一個特徵 3 個 RBF 神經元，來計算該特徵的重要度，最後我們將這些資訊透過多個全連接層學習最後輸出刀具磨耗的類別。

接下來介紹 UNet 的部分，如圖 25，本研究所建立的 RBF-UNet Model 裡所使用的 UNet 總共有 5 大層，模型中所使用到的 Max Pooling 的尺寸大小都是 2x2、Convolution 的尺寸大小也都是 3x3、Up-Convolution 尺寸大小全部為 3x3，以及模型中所使用到的激活函數都為 ReLU，參數如表 5 所示。

接下來是多個全連接層的部分，在 RBF-UNet Model 中，本研究加入了 9 層全連接層，在前 8 層的全連接層，其各層的神經元數量由 512 個持續降低至 4 個，這 8 所使用的激活函數全部都為 ReLU，最後在輸出層將神經元數量設定為 3，符合刀具磨耗的

類別數量，其激活函數為 softmax，各層的參數如表 6 所示。




圖 24 RBF-UNet Model 架構




圖 25 UNet 架構

表 5 UNet 參數

類型	尺寸	激活函數
Max pooling	2	ReLU
Up-convolution	2	ReLU
Convolution	3	ReLU

表 6 全連接層各層參數

層	神經元數量	激活函數
FullConnected Layer 1	512	ReLU
FullConnected Layer 2	256	ReLU
FullConnected Layer 3	128	ReLU
FullConnected Layer 4	64	ReLU
FullConnected Layer 5	32	ReLU
FullConnected Layer 6	16	ReLU
FullConnected Layer 7	8	ReLU
FullConnected Layer 8	4	ReLU
Output Layer	3	Softmax

5.3.2 原始尺寸 2700 x 900

首先本研究不對圖片進行任何切割處理，本研究將原始 900x2700 的圖片壓縮至 64x64 投入模型進行訓練，如圖 26 所示，本次實驗的混淆矩陣如圖 27 所示，其模型績

效如表 8。

從結果來看，分類的結果都非常差，而且所有的圖片都被分類到正常磨耗(1)，本研究推斷是因為在原始尺寸中，尺寸太大，而本研究將圖片壓縮到 64*64 大小時，使圖片損失太多資訊，且本研究發現在正常磨耗中時間點接近初始磨耗或是劇烈磨耗時的時頻圖會與他們很相似，綜合上述，導致模型無法準確的學習到每一類的重要資訊。

表 7 原始尺寸訓練、測試集の影像數量

資料集\類別	類別 0	類別 1	類別 2
訓練	4240	4216	4219
測試	1796	1820	1817

表 8 原始圖片(2700x900)績效

指標	分數
Accuracy	0.33499
Precision	0.33499
Recall	0.33499
F1_score	0.33499




圖 26(a)




圖 26(b)

圖 26 原始圖片(2700x900)




圖 27 原始圖片(2700x900)混淆矩陣

5.3.3 切割圖片 64 x 900

根據上一小節所得到的結論，本研究將圖片進行切割，圖片的高度保持原始尺寸，本研究將長度切割剩下 64 並做 Time shift，並且也將圖片壓縮至 64x64，如圖 28 所示，本次實驗的混淆矩陣如圖 29 所示，其模型績效如表 10 所示。

從結果來看，所有的圖片也都被分配到同一類，跟上面部一樣的是被分配到劇烈磨耗，雖然本研究已經將圖片大小降低了，也讓切割完的尺寸與壓縮後的尺寸差一沒有那麼大，但是依然無法讓模型的績效有所提升，本研究推斷是因為 64 的寬度太小，一張圖片裡的內容所包含的內容過少，而造成每一類的時頻圖特徵分散在多張圖片，導致模型無法學習到每一類所包含的重要資訊。

表 9 切割圖片 64 x 900 訓練、測試集의影像數量

資料集\類別	類別 0	類別 1	類別 2
訓練	5626	5548	5626
測試	2374	2452	2374

表 10 切割圖片(64x900)績效

指標	分數
Accuracy	0.32972
Precision	0.32972
Recall	0.32972

F1_score 0.32972




圖 28(a)




圖 28(b)




圖 28(c)

圖 28 切割圖片(64x900)




圖 29 切割圖片(64x900)混淆矩陣

5.3.4 切割圖片 300 x 900

由上一小節得出的結論，本研究將其切割的寬度增加到 300，使圖片尺寸為 300x900，並做 Time shift，且也將圖片壓縮至 64x64，如圖 30 所示，本次實驗的混淆矩陣如圖 29 所示，其模型績效如表 10 所示。

從結果來看，其績效都比前面兩小節實驗的績效明顯的有所提高，由圖 31 的混淆矩陣，發現在這次實驗中，初始磨耗可以被模型被準確的分類，但是可以看出在這個尺寸大小下，正常磨耗與劇烈磨耗這兩類，模型依然是無法判別得很清楚，綜合上述，模型還是無法準確的將 3 個刀具磨耗類別。

但是因為該尺寸大小對模型績效有所提升，所以本研究針對這一個尺寸大小多做一實驗，本研究將上一輪實驗的模型學習錯誤的資料，投入至訓練資料集，讓模型多學習該類型圖片的特徵，從圖 32、表 14，其結果卻比原先的模型績效還差。

表 11 切割圖片(300 x 900)之實驗 1 訓練、測試集的影像數量

資料集\類別	類別 0	類別 1	類別 2
訓練	12060	11968	7972
測試	2940	3032	2028

表 12 切割圖片之實驗 1(300 x 900)績效

指標	分數
Accuracy	0.55825
Precision	0.55825
Recall	0.55825
F1_score	0.55825




圖 30 切割圖片(300 x 900)之實驗 1 混淆矩陣




圖 31(a)




圖 31(b)




圖 31(c)

圖 31 切割圖片(300x900)

表 13 切割圖片(300x900)之實驗 2 訓練、測試集的影像數量

資料集\類別	類別 0	類別 1	類別 2
訓練	12082	24792	17386
測試	2940	3032	2028

表 14 切割圖片(300 x 900) 之實驗 2 績效

指標	分數
Accuracy	0.45599
Precision	0.45599
Recall	0.45599
F1_score	0.45599




圖 32 切割圖片(300 x 900)實驗 2 混淆矩陣 2

5.3.5 小結

根據 5.3.1 到 5.3.4 小節，本實驗使用了 3 種圖片尺寸進行實驗模擬，最終本實驗找到 300x900 是相對比較合適的尺寸，在這一個尺寸中，一張圖片所包含的資訊不會過多也不會過少，剛好適合 RBF-UNet Model 學習，表 15 為各尺寸的績效比較。

表 15 所有實驗之績效比較

時頻圖尺寸\評估指標	Accuracy	Precision	Recall	F1_score
原始尺寸(2700x900)	0.33498	0.33498	0.33498	0.33498
切割尺寸 1 (64x900)	0.32972	0.32972	0.32972	0.32972
切割尺寸 2 (300x900)	0.55825	0.55825	0.55825	0.55825
切割尺寸 2 (300x900)2	0.45599	0.45599	0.45599	0.45599

5.3.6 複合式 RBF-UNet Model

基於上面幾個實驗的結果，本研究發現要讓 RBF-UNet Model 準確的分類出初始磨耗、正常磨耗、劇烈磨耗三個類別是具有挑戰性的，所以本研究基於複合式 RBF-UNet Model 的概念將三個磨耗類別個別建立 RBF-UNet Model，讓模型只判斷是否為初始磨耗的 RBF-UNet Model_Initial、判斷是否為正常磨耗的 RBF-UNet Model_Normal 與判斷是否劇烈磨耗的 RBF-UNet Model_Severe，在本節所有實驗的圖片尺寸則會遵循上面幾個實驗所得出的結果，將時頻圖切割成 300*900 的大小，並壓縮至 64x64 投入 RBF-UNet Model 進行訓練。

根據圖 33、圖 34、圖 35 及表 19 顯示，本研究得出在初始磨耗與劇烈磨耗這兩個

類別的 RBF-UNet Model_Initial 與 RBF-UNet Model_Severe 表現得很好，唯獨在正常磨耗的類別，其準確率還是很低，本研究去探討其內會造成正常磨耗的 RBF-UNet Model_Normal 績效差背後的原因，最後，本研究發現因為在正常磨耗的時頻圖中，時間點靠近初始磨耗的時頻圖會與時初始磨耗的時頻圖分辨不出來，反之若是靠近劇烈磨耗則會有與劇烈磨耗相似的時頻圖出現在正常磨耗中。

既然 RBF-UNet Model_Normal 在正常磨耗的類別表現不優，本實驗提出將捨去判斷是否為正常磨耗這一個模型，本研究將初始磨耗的 RBF-UNet Model_Initial 與劇烈磨耗的 RBF-UNet Model_Severe 結合，進而產生一個複合式 RBF-UNet Model，如圖 36 所示，也就是讓 RBF-UNet Model_Initial 與 RBF-UNet Model_Severe 這兩個 RBF-UNet Model 分別去判斷同一筆資料集，若是 RBF-UNet Model_Initial 判斷資料是初始磨耗，則該資料就為初始磨耗；若是 RBF-UNet Model_Severe 判斷資料是劇烈磨耗，則該資料就為劇烈磨耗；最後若該資料經 RBF-UNet Model_Initial 與 RBF-UNet Model_Severe 兩個模型皆被判斷為非初始與非劇烈，則該筆資料就為正常磨耗。

因為上面初始磨耗與劇烈磨耗分別訓練出來的模型有著不錯的績效，所以當那兩個模型都判斷出該張時頻圖都不是屬於自計的類別時，則就可以準確的判斷該張圖片就是正常磨耗，本研究發現用該複合式 RBF-UNet Model 就可以得到不錯結果，其績效如圖 37 與表 20 所示，所以本研究將以這一個方法接續下去進行拆解 RBF 拆解的實驗、與輕量化模型的建置。

表 16 RBF-UNet Model_Initial 時頻圖數量

資料集\類別	初始磨耗	非初始磨耗
訓練	12060	12000
測試	2940	2940

表 17 RBF-UNet Model_Normal 時頻圖數量

資料集\類別	正常磨耗	非正常磨耗
訓練	11968	11900
測試	3032	3000

表 18 RBF-UNet Model_Severe 時頻圖數量

資料集\類別	劇烈磨耗	非劇烈磨耗
訓練	7972	7900
測試	2028	2000

表 19 三類磨耗之績效

模型\評估指標	Accuracy	Precision	Recall	F1_score
RBF-UNet Model_Initial	0.992517	0.99555	0.989455	0.99249
RBF-UNet Model_Normal	0.502653	0.502653	1.0	0.66902
RBF-UNet Model_Severe	0.980387	0.973748	0.987672	0.980660




圖 33 RBF-UNet Model_Initial 混淆矩陣




圖 34 RBF-UNet Model_Normal 混淆矩陣




圖 35 RBF-UNet Model_Severe 混淆矩陣




圖 36 複合式 RBF-UNet Model

表 20 複合式 RBF-UNet Model 績效

指標	分數
Accuracy	0.967875
Precision	0.967875
Recall	0.967875
F1_score	0.967875




圖 37 複合式 RBF-UNet Model 混淆矩陣

5.4 RBF Layer 拆解

5.4.1 每一個大小的卷積層之重要度計算

這一個小節介紹如何將 RBF-UNet Model 內的 RBF Layer 拆解出來進行計算 UNet Layer 中每一個大小的卷積層的重要度，本實驗將設計一個閾值 α 來判斷該特徵是否重要，若該特徵的 RBF 成績大於 α ，則本實驗將他視為重要特徵，反之，若該特徵的 RBF 成績小於 α ，本研究就將他視為不重要特徵，本研究將統計該大小的卷積層所擁有的重要特徵的數量，將該值除以該大小的卷積層特徵總數，計算出該大小的卷積層的重要度 β ，如式 13 所示，本研究將設計 5 個 α 進行實驗來找出重要度最高的卷積層大小。

$$RBF \geq \alpha \rightarrow \text{重要特徵} \quad (12)$$

$$\text{重要度}(\beta) = \frac{\text{各大小卷積層之重要特徵數量}}{\text{各大小卷積層之特徵數量}} \quad (13)$$

本研究想探討在不同磨耗階段的 RBF-UNet Model 中，所得到重要的卷積層大小是否會不一樣，所以本研究將上一節所訓練的 RBF-UNet Model_Initial 與 RBF-UNet Model_Severe 兩個 RBF-UNet Model 分別進行拆解計算，本研究設計了 5 個實驗，在各個實驗中其 α 都會不同，本研究想要藉由本實驗來看出在不同的 α 情況下，各層的重要度是否會有變化，以及在 RBF-UNet Model_Initial 與 RBF-UNet Model_Severe 這兩個 Model 之間是否會有不一樣的結果

在本實驗裡，本研究投入 2000 張圖片去計算，計算出每一個大小的卷積層對於各張圖片之重要度，再將卷積後的結果進行分析，如圖 38 到圖 42 所示，首先看到 α 為 0.1 的情況，如圖 38 所示，本研究發現不管是 RBF-UNet Model_Initial 還是 RBF-UNet

Model_Severe，隨著尺寸不斷地放大，各大小的卷積層之重要度也隨之持續上升，本研究推斷是因為隨著尺寸放大，其時頻圖的小細節也隨之被放大，使模型可以更好學習到該圖片中的特色，導致那些特徵在計算 RBF 值時的分數也會比較高，就會有比較多的特徵值超過 α ，然而最後就產生卷積層大小為 1024 時，所計算出來的重要度是最高的。將 α 設定為其他值時也產生了相同的情況，如圖 39 至圖 42 所示。所以本研究在這邊就定義大小為 1024 的卷積層是 RBF-UNet Model 中最重要的一個尺寸。




圖 38(a) RBF-UNet Model_Initial




圖 38(b) RBF-UNet Model_Severe

圖 38 $\alpha=0.1$ 重要特徵

各卷積層大小之重要度




圖 39(a) RBF-UNet Model_Initial

各卷積層大小之重要度




圖 39(b) RBF-UNet Model_Severe

圖 39 $\alpha=0.6$ 重要特徵

各卷積層大小之重要度




圖 40(a) RBF-UNet Model_Initial

各卷積層大小之重要度




圖 40(b) RBF-UNet Model_Severe

圖 40 $\alpha=0.7$ 重要特徵




圖 41(a) RBF-UNet Model_Initial




圖 41(b) RBF-UNet Model_Severe

圖 41 $\alpha=0.8$ 重要特徵




圖 42(a) RBF-UNet Model_Initial




圖 42(b) RBF-UNet Model_Severe

圖 42 $\alpha=0.9$ 重要特徵

5.4.1 RBF Layer 合理性驗證

為了驗證本實驗所拆解出來的 RBF Layer 所得到的結果是合理的，本研究在 UNet Layer 加上 Grad-CAM，Grad-CAM 可以視覺化最後一層卷積層在特徵網格圖上所重點關注的區域，所以本研究將 Grad-CAM 加到每一個大小卷積層之最後的一個 Layer，去觀察其所關注到的區域，根據圖 43 至圖 44，本研究觀察到隨著卷積層的大小的提高，模型所學習到的區域會越完整，尤其在 1024 這一個大小所關注的大小，由此可知本研究利用 RBF 抓取重要大小的卷積層是合理的，所以後續本研究也會利用此結果來建立輕量化模型。




圖 43 RBF-UNet Model_Initial 之 Grad-CAM 結果




圖 44 RBF-UNet Model_Severe 之 Grad-CAM 結果

5.5 輕量化模型

本研究利用輕量化 RBF-UNet 的該念進行本小節的實驗，本研究將使用隨機森林 (RandomForest) 作為輕量化 RBF-UNet 的低成本 AI 模型進行建模，如圖 45 所示，設計出 RBF-UNet-RandomForest 進行實驗，下面分為兩個部分進行實驗，包括(1)複合式 RBF-UNet-RandomForest 及(2)混合式 RBF-UNet-RandomForest。




圖 45 RBF-UNet-RandomFores 模型架構

5.5.1 複合式 RBF-UNet-RandomForest

本研究將透過隨機森林來建立該輕量化模型，此小節本研究將會針對 RBF-UNet Model_Initial 與 RBF-UNet Model_Severe 兩個模型分別建立一個 RandomForest 輕量化模型，模型架構如圖 46 所示，在此小節本研究將會透過調整投入的 RBF 數量設計多個實驗，去找出多少數量的特徵對於 RandomForest 可以達到較好的績效。本小節所建立的隨機森林模型訓練集與測試及皆為 1000 張時頻圖。




圖 46 複合式 RBF-UNet-RandomForest

本研究首先取出上一節所得出的重要度最高的卷積層(大小為 1024)的所有特徵輸入至 RandomForest 進行建模，總共輸入 49152 個特徵。從圖 47、圖 48 與表 23 可以看出 RandomForest 可以有效的利用本研究所輸入的特徵去分辨出刀具磨耗的三個種類。

接下來本研究又將針對 RBF-UNet Model 裡的 RBF 數值進行排序，本研究將設定 6 組參數 λ ， λ 為抓取前幾名的比例，本研究將這一個參數乘上總特徵數得到不同數量的特徵輸入至 RandomForest 進行建模，各試驗輸入的數量如表 21 所示，從這些實驗中，本研究發現當 λ 等於 0.1、0.05、0.04、0.03、0.02 時，複合式 RBF-UNet-RandomForest

模型的績效與輕量化前準確率差異不大，依然可以準確地分辨出各種類型的磨耗，但是當 λ 為 0.01 時，其模型的績效就下降下來了，模型無法準確地分辨出各種類型的磨耗，本研究推斷是因為當 λ 等於 0.01 時，輸入至 RandomForest 的特徵數量過少，所以模型無法學習到各種特徵，導致模型的績效不佳。

表 21 特徵數量

λ 值	特徵數量
1024 網格	49152
0.1	76185
0.05	38092
0.04	30474
0.03	22855
0.02	15237
0.01	7618

表 22 複合式 RBF-UNet-RandomForest 訓練、測試集的影像數量

資料集\類別	類別 0	類別 1	類別 2
訓練 1	504	496	
訓練 2	478		522
測試	372	360	268

表 23 1024 之績效

指標	分數
Accuracy	0.965
Precision	0.965
Recall	0.965
F1_score	0.965




圖 47 1024 網格特徵之混淆矩陣




圖 48 各 λ 之混淆矩陣

表 24 各 λ 值之績效比較

λ 值\評估指標	Accuracy	Precision	Recall	F1_score
0.1	0.952	0.952	0.952	0.952
0.05	0.953	0.953	0.953	0.953
0.04	0.959	0.959	0.959	0.959
0.03	0.952	0.952	0.952	0.952
0.02	0.614	0.614	0.614	0.614
0.01	0.245	0.245	0.245	0.245

5.5.3 RBF-UNet-RandomForest

本研究根據上一小節所得到的結論，本研究想再將兩個 RandomForest 的模型縮減成一個，使其整體的模型運算成本可以再次降低，本研究在這邊一樣設計 6 組參數 λ 從 RBF-UNet Model_Initial 與 RBF-UNet Model Severe 這兩個模型中取出不同數量的特徵，並將這兩組特徵進行合併，本研究也利用連集與交集兩種合併方法來建立 U_RBF-UNet-RandomForest 與 n_RBF-UNet-RandomForest 模型，模型架構如圖 49 所示，投入 RandomForest 的特徵數量如表 25 所示。

表 25 RBF-UNet-RandomForest 特徵數量

λ 值	U_RBF-UNet-RandomForest	n_RBF-UNet-RandomForest
0.1	282400	18000
0.05	144100	6000
0.04	116400	4000
0.03	88786	2000
0.02	60240	550
0.01	30240	15




圖 49 混合式 RBF-UNet-RandomForest 模型架構

在這些實驗組合中，本研究在將兩組特徵依照交集的發是進行合併進行 n_RBF-UNet-RandomForest 的建模，績效如表 26 所示，本實驗發現當 λ 等於 0.02 時，該模型績效就不佳，本研究根據投入的特徵數量可以發現比起複合式 RBF-UNet-RandomForest 投入的特徵數量是更加的少，模型無法完整的學習到每種情況的特徵，導致模型的準確率下降。


而若將兩組特徵依照聯集的發是進行合併所建立的 U_RBF-UNet-RandomForest，因為該方法投入的特徵相對來說會比較多，所以可以讓模型完整學習到該學習的資料，所以該模型的績效較佳的，績效如表 27 所示，包括在複合式 RBF-UNet-RandomForest 表現得並不理想的 λ (0.01)，在利用聯集後所產生的特徵進行建模的 U_RBF-UNet-RandomForest 中，雖然準確率是與其他 λ 所得到的準確率無法相比，但是卻遠遠優於其他模型在 λ 等於 0.01 時的準確率，甚至優於當 n_RBF-UNet-RandomForest 中， λ 等於 0.02 時所得到的績效。

表 26 n_RBF-UNet-RandomForest 各 λ 值之績效比較

λ 值\評估指標	Accuracy	Precision	Recall	F1_score
0.1	0.959	0.959	0.959	0.959
0.05	0.949	0.949	0.949	0.949
0.04	0.947	0.947	0.947	0.9469
0.03	0.937	0.937	0.937	0.937
0.02	0.427	0.427	0.427	0.427
0.01	0.355	0.355	0.355	0.355

表 27 U_RBF-UNet-RandomForest 各 λ 值之績效比較

λ 值\評估指標	Accuracy	Precision	Recall	F1_score
0.1	0.945	0.945	0.945	0.945
0.05	0.949	0.949	0.949	0.949
0.04	0.942	0.942	0.942	0.942
0.03	0.959	0.959	0.959	0.959
0.02	0.96	0.96	0.96	0.96
0.01	0.891	0.891	0.891	0.891






圖 50 交集聯集之混淆矩陣

5.6 Online

在這邊本研究將訓練好的模型，移植到配備較低的電腦上面去執行，該電腦配備為 Intel(R) Core(TM) i7-9700KF CPU @ 3.60GHz 的 CPU、一顆 Nvidia GeForce RTX 2080 Ti 11GB 的 GPU、搭配約 16GB 記憶體，並使用 Windows 10 的作業軟體，從圖 51 可以看到本研究開發之輕量化模型移植到配備比較低的電腦時，他的運行時間是與本研究用來訓練模型所使用的電腦是很接近的，由此可知本研究所開發之輕量化模型是有效的。




圖 51 輕量化模型運行時間

第6章 結論與未來展望

本研究透過自行開發 RBF-UNet Model 的模型可以準確地找出真正影響刀具磨耗的特徵，並成功利用低成本的 AI 模型準確地判斷出刀具的磨耗的類型並降低刀具磨耗預測系統的運算成本，使 CNC 工廠不必花費大量的資金更換設備便可以擁有刀具磨耗預測系統，幫助工廠節省人力成本，且盡可能地協助工廠將刀具的壽命使用到極限，以利降低刀具的使用成本，並減少工件的損傷，增加公司的收益。

針對未來研究，本研究目前是將 RBF-UNet Model 後面的全連接層利用低成本的 AI 模型替換，但是這個方法對於降低模型運行成本是有限的，本研究提出幾點延伸討論，(1)針對 UNet Layer 去除重要度不高的層，以達成真正意義上的降低模型運行成本。(2)將輕量化過後的 RBF-UNet Model 鑲嵌到小型感測器中並安裝在機臺上面即時去判斷該機臺目前刀具的磨耗情形，以達到最即時的回饋，降低刀具的使用成本。



參考文獻

- [1] Y. C. Chen, S. M. Chiu, L. C. J. Kuo, L. C. Hung, M. H. Hung, and C. C. Chen, "Using Fuzzified Deep Recurrent Neural Networks to Retrieve Deep Features to Enhance the Accuracy of Tool Wear Prediction," Proceeding on IEEE International Conference on Automation Science and Engineering (CASE), 2019
- [2] Gouarir, A., Martínez-Arellano, G., Terrazas, G., Benardos, P., & Ratchev, S. J. P. C. (2018). In-process tool wear prediction system based on machine learning techniques and force analysis. *Procedia CIRP*, 77, 501-504.
- [3] Sun, C., Ma, M., Zhao, Z., Tian, S., Yan, R., & Chen, X. (2018). Deep transfer learning based on sparse autoencoder for remaining useful life prediction of tool in manufacturing. *IEEE transactions on industrial informatics*, 15(4), 2416-2425.
- [4] Han S, Pool J, Tran J, Dally W (2015) Learning both weights and connections for efficient neural network. *Adv Neural Inf Proces Syst*:1135–1143
- [5] Scardapane S, Comminiello D, Hussain A, Uncini A (2017) Group sparse regularization for deep neural networks. *Neurocomputing* 241:81–89
- [6] Wen W, Wu C, Wang Y, Chen Y, Li H (2016) Learning structured sparsity in deep neural networks. *Adv Neural Inf Proces Syst*:2074–2082
- [7] Han S, Liu X, Mao H, Pu J, Pedram A, Horowitz MA, Dally WJ (2016) EIE: efficient inference engine on compressed deep neural network. *Proceeding on ACM/IEEE Int Symp on Computer Architecture* 44:243–254
- [8] Parashar A, Rhu M, Mukkara A, Puglielli A, Venkatesan R, Khailany B, Emer J, Keckler SW, Dally WJ (2017) Scnn: An accelerator for compressed-sparse convolutional neural networks. *Proceeding on Annual Int. Symp. on Computer Architecture*, pp. 27–40
- [9] Zhang S, Du Z, Zhang L, Lan H, Liu S, Li L, Guo Q, Chen T, Chen Y (2016) Cambricon-x: an accelerator for sparse neural networks. *Proceeding on Annual IEEE/ACM Int Symp on Microarchitecture*:1–12
- [10] Li H, Kadav A, Durdanovic I, Samet H, Graf HP (2017) Pruning filters for efficient convnets. *Proceeding on Int. Conf. on Learning Representations*
- [11] Molchanov P, Tyree S, Karras T, Aila T, Kautz J (2017) Pruning convolutional neural networks for resource efficient transfer learning. *Proceeding on Int. Conf. on Learning Representations*
- [12] Luo J, Wu J, Lin W (2017) ThiNet: a filter level pruning method for deep neural network compression. *Proceeding on IEEE Int Conf on Computer Vision*:5068–5076

- [13] Sani S, Wiratunga N, Massie S (2017) Learning deep features for knn based human activity recognition. *Proceeding on Int Conf on Case-Based Reasoning Workshops*:95–103
- [14] Mohammad YFO, Matsumoto K, Hoashi K (2018) Deep feature learning and selection for activity recognition. *Proceeding on Annual ACM Symposium on Applied Computing*:930–939
- [15] Stoller, D., Ewert, S., & Dixon, S. (2018). Wave-u-net: A multi-scale neural network for end-to-end audio source separation. *arXiv preprint arXiv:1806.03185*.
- [16] Bhuiyan, M. S. H., Choudhury, I. A., Dahari, M., Nukman, Y., & Dawal, S. Z. (2016). Application of acoustic emission sensor to investigate the frequency of tool wear and plastic deformation in tool condition monitoring. *Measurement*, 92, 208-217.
- [17] Dolinšek, S., & Kopač, J. (1999). Acoustic emission signals for tool wear identification. *Wear*, 225, 295-303.
- [18] Benkedjouh, T., Medjaher, K., Zerhouni, N., & Rechak, S. (2015). Health assessment and life prediction of cutting tools based on support vector regression. *Journal of intelligent manufacturing*, 26, 213-223.
- [19] Jalali, S. K., Ghandi, H., & Motamedi, M. (2020). Intelligent condition monitoring of ball bearings faults by combination of genetic algorithm and support vector machines. *Journal of Nondestructive Evaluation*, 39, 1-12.
- [20] Gomes, M. C., Brito, L. C., da Silva, M. B., & Duarte, M. A. V. (2021). Tool wear monitoring in micromilling using support vector machine with vibration and sound sensors. *Precision Engineering*, 67, 137-151.
- [21] Mohanraj, T., Yerschuru, J., Krishnan, H., Aravind, R. N., & Yameni, R. (2021). Development of tool condition monitoring system in end milling process using wavelet features and Hoelder's exponent with machine learning algorithms. *Measurement*, 173, 108671.
- [22] Hesser, D. F., & Markert, B. (2019). Tool wear monitoring of a retrofitted CNC milling machine using artificial neural networks. *Manufacturing letters*, 19, 1-4.
- [23] Corne, R., Nath, C., El Mansori, M., & Kurfess, T. (2017). Study of spindle power data with neural network for predicting real-time tool wear/breakage during inconel drilling. *Journal of Manufacturing Systems*, 43, 287-295.
- [24] F. Jia, Y. Lei, J. Lin, X. Zhou, and N. Lu, (2016) "Deep neural networks: A promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with

massive data," *Mechanical Systems and Signal Processing*, vol. 72, 303-315.

- [25] Zhang, J., Wang, P., Yan, R., & Gao, R. X. (2018). Deep learning for improved system remaining life prediction. *Procedia Cirp*, 72, 1033-1038.
- [26] Sun, C., Wang, P., Yan, R., Gao, R. X., & Chen, X. (2019). Machine health monitoring based on locally linear embedding with kernel sparse representation for neighborhood optimization. *Mechanical Systems and Signal Processing*, 114, 25-34.
- [27] Zhao, R., Wang, D., Yan, R., Mao, K., Shen, F., & Wang, J. (2017). Machine health monitoring using local feature-based gated recurrent unit networks. *IEEE Transactions on Industrial Electronics*, 65(2), 1539-1548.
- [28] Chen, D. (2017). Research on traffic flow prediction in the big data environment based on the improved RBF neural network. *IEEE Transactions on Industrial Informatics*, 13(4), 2000-2008.
- [29] Gopi, A. P., Jyothi, R. N. S., Narayana, V. L., & Sandeep, K. S. (2023). Classification of tweets data based on polarity using improved RBF kernel of SVM. *International Journal of Information Technology*, 15(2), 965-980.
- [30] Han, S., Qubo, C., & Meng, H. (2012, June). Parameter selection in SVM with RBF kernel function. In *World Automation Congress 2012* (pp. 1-4). IEEE.
- [31] Yilmaz, I., & Kaynar, O. (2011). Multiple regression, ANN (RBF, MLP) and ANFIS models for prediction of swell potential of clayey soils. *Expert systems with applications*, 38(5), 5958-5966.
- [32] Wu, J., Long, J., & Liu, M. (2015). Evolving RBF neural networks for rainfall prediction using hybrid particle swarm optimization and genetic algorithm. *Neurocomputing*, 148, 136-142.
- [33] Chen, Y. C., & Li, D. C. (2021). Selection of key features for PM_{2.5} prediction using a wavelet model and RBF-LSTM. *Applied Intelligence*, 51, 2534-2555.
- [34] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention—MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III* 18 (pp. 234-241). Springer International Publishing.
- [35] Du, G., Cao, X., Liang, J., Chen, X., & Zhan, Y. (2020). Medical image segmentation based on u-net: A review. *Journal of Imaging Science & Technology*, 64(2).
- [36] Lin, A., Chen, B., Xu, J., Zhang, Z., Lu, G., & Zhang, D. (2022). Ds-transunet: Dual

- swin transformer u-net for medical image segmentation. *IEEE Transactions on Instrumentation and Measurement*, 71, 1-15.
- [37] Pun, N. S., & Agarwal, S. (2022). Modality specific U-Net variants for biomedical image segmentation: a survey. *Artificial Intelligence Review*, 55(7), 5845-5889.
- [38] Jiang, Z., Tahmasebi, P., & Mao, Z. (2021). Deep residual U-net convolution neural networks with autoregressive strategy for fluid flow predictions in large-scale geosystems. *Advances in Water Resources*, 150, 103878.
- [39] Shen, Z., Xu, Y., Ni, B., Wang, M., Hu, J., & Yang, X. (2018). Crowd counting via adversarial cross-scale consistency pursuit. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 5245-5254).
- [40] Valloli, V. K., & Mehta, K. (2019). W-net: Reinforced u-net for density map estimation. *arXiv preprint arXiv:1903.11249*.
- [41] Oktay, O., Schlemper, J., Folgoc, L. L., Lee, M., Heinrich, M., Misawa, K., ... & Rueckert, D. (2018). Attention u-net: Learning where to look for the pancreas. *arXiv preprint arXiv:1804.03999*.
- [42] Stoller, D., Ewert, S., & Dixon, S. (2018). Wave-u-net: A multi-scale neural network for end-to-end audio source separation. *arXiv preprint arXiv:1806.03185*.
- [43] Zhang, J., Li, C., Kosov, S., Grzegorzec, M., Shirahama, K., Jiang, T., ... & Li, H. (2021). LCU-Net: A novel low-cost U-Net for environmental microorganism image segmentation. *Pattern Recognition*, 115, 107885.
- [44] Yu, B., Yin, H., & Zhu, Z. (2019). ST-UNet: A spatio-temporal U-network for graph-structured time series modeling. *arXiv preprint arXiv:1903.05631*.
- [45] Zhou, Y., Li, J., Chen, H., Wu, Y., Wu, J., & Chen, L. (2021). A spatiotemporal hierarchical attention mechanism-based model for multi-step station-level crowd flow prediction. *Information Sciences*, 544, 308-324.
- [46] Chen, B., Chen, X., Li, B., He, Z., Cao, H., & Cai, G. (2011). Reliability estimation for cutting tools based on logistic regression model using vibration signals. *Mechanical Systems and Signal Processing*, 25(7), 2526-2537.
- [47] Kong, D., Chen, Y., & Li, N. (2018). Gaussian process regression for tool wear prediction. *Mechanical systems and signal processing*, 104, 556-574.
- [48] Yu, J., Liang, S., Tang, D., & Liu, H. (2017). A weighted hidden Markov model approach for continuous-state tool wear monitoring and tool life prediction. *The International Journal of Advanced Manufacturing Technology*, 91, 201-211.

- [49] Zhu, K., & Liu, T. (2017). Online tool wear monitoring via hidden semi-Markov model with dependent durations. *IEEE Transactions on Industrial Informatics*, 14(1), 69-78.
- [50] Hesser, D. F., & Markert, B. (2019). Tool wear monitoring of a retrofitted CNC milling machine using artificial neural networks. *Manufacturing letters*, 19, 1-4.
- [51] Martins, C. H., Aguiar, P. R., Frech, A., & Bianchi, E. C. (2013). Tool condition monitoring of single-point dresser using acoustic emission and neural networks models. *IEEE Transactions on Instrumentation and Measurement*, 63(3), 667-679.
- [52] Kurek, J., Wieczorek, G., Kruk, B. S. M., Jegorowa, A., & Osowski, S. (2017, September). Transfer learning in recognition of drill wear using convolutional neural network. In *2017 18th International Conference on Computational Problems of Electrical Engineering (CPEE)* (pp. 1-4). IEEE.
- [53] Chen, F., Song, L., & Chen, Y. (2018, January). ReGAN: A pipelined ReRAM-based accelerator for generative adversarial networks. In *2018 23rd Asia and South Pacific Design Automation Conference (ASP-DAC)* (pp. 178-183). IEEE.
- [54] Song, L., Qian, X., Li, H., & Chen, Y. (2017, February). Pipelayer: A pipelined reram-based accelerator for deep learning. In *2017 IEEE international symposium on high performance computer architecture (HPCA)* (pp. 541-552). IEEE.
- [55] Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 3431-3440).
- [56] Chen, Y. C., Chang, T. Y., Chow, H. Y., Li, S. L., & Ou, C. Y. (2022). Using convolutional neural networks to build a lightweight flood height prediction model with grad-cam for the selection of key grid cells in radar echo maps. *Water*, 14(2), 155.
- [57] Chiu, S. M., Liou, Y. S., Chen, Y. C., Lee, C., Shang, R. K., & Chang, T. Y. (2023). Identifying key grid cells for crowd flow predictions based on CNN-based models with the Grad-CAM kit. *Applied Intelligence*, 53(11), 13323-13351.
- [58] Chiu, S. M., Chen, Y. C., Kuo, C. J., Hung, L. C., Hung, M. H., Chen, C. C., & Lee, C. (2022). Development of lightweight RBF-DRNN and automated framework for CNC tool-wear prediction. *IEEE Transactions on Instrumentation and Measurement*, 71, 1-11.
- [59] Y.C. Chen, 雲林科技大學工業工程與管理系大數據分析導論課程講義第 6 章