

國立雲林科技大學研究生學位論文電子檔上傳同意書

National Yunlin University of Science and Technology Agreement on Uploading E-file of the Thesis

工業工程與管理系研究所 _____ 組

學號 M10921003 研究生 李香蘭 (請簽章)

論文已完成口試委員修改建議，並經系所辦查對以下事項無誤，請同意論文上傳學校圖書館。

■ 查對事項：

☒ 中文論文題目(研究生請於下方自填中文論文題目，請以電腦繕打，勿手寫。)：

應用補償式遷移學習模型於區域人流之強健性預測

☒ 英文論文題目(研究生請於下方自填英文論文題目，請以電腦繕打，勿手寫。)：

Robust Regional Crowd Flow Prediction Based on Compensatory Transfer Learning Models

☒ 中文論文題目與學位論文考試委員會審定書之題目一致。

☒ 中、英文論文題目與單一/教務資訊系統/歷年成績之題目一致。

☒ 中、英文論文題目與學位論文 PDF 檔封面之題目一致。

查對人(系所辦承辦人員)： 組員林雅婷 (請簽章)

謹陳

論文指導教授： 陳堯中 (請簽章)

使用說明：

1. 同意書送系所承辦人員查對時，請研究生提供「審定書」及「論文封面」檔案。
2. 學位論文電子檔上傳前，請將簽核完成之同意書掃描成電子檔併於學位論文 PDF 檔第一頁(封面的前一頁)。
3. 正本請自行留存，請勿裝訂於紙本學位論文內。

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

應用補償式遷移學習模型於區域人流之強健性預測

Robust Regional Crowd Flow Prediction Based on
Compensatory Transfer Learning Models

李香蘭

Siang-Lan Li

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D.

中華民國 111 年 6 月

June 2022

國立雲林科技大學
碩士班學位論文考試委員會審定書
National Yunlin University of Science and Technology
Thesis Oral Defense Approval Form

本論文係 李香蘭 君在本校 工業工程與管理系碩士班 所提論文
應用補償式遷移學習模型於區域人流之強健性預測 碩士資格水
準，業經本委員會評審認可，特此證明。

The student LI, SIANG-LAN enrolled in the Master's program in
Department of Industrial Engineering and Management has
satisfactorily passed the oral defense of the thesis Robust Regional
Crowd Flow Prediction Based on Compensatory Transfer Learning
Models.

口 試 委 員 :
Oral defense
committee members

陳奕中

陳奕中

呂學毅

蔡明翰

王聖鐸

指 導 教 授 :
Advisor(s)

陳奕中

陳奕中

所 長 :
Dean of Graduate
Institute

傅家啓

中 華 民 國 111 年 7 月 14 日

摘要

近期越來越多人逐漸開始重視預測都市人流量，人流預測與生活中的大小事都息息相關，不管是城市中的商業決策、公共衛生管理、交通管制，亦或是救災，如果能精準預測未來人流量，對這些議題都有很大的幫助。而過往針對都市人流預測之研究，大多使用三種方法來研究，分別為(1)統計方法、(2)機器學習方法、以及(3)深度學習方法，而在這三種方法中，又以深度學習模型訓練出來的績效結果為最好的，但使用深度學習模型於人流問題有兩大困難點需要克服，(1)模型訓練時間成本過長，以及(2)預測需具有強健性。因此針對過往人流預測之研究的缺點，本研究提出以補償式遷移學習模型預測區域人流量。此模型包含基礎模型卷積神經網路-長短期記憶模型(Convolutional Neural Network-Long Short-Term Memory, CNN-LSTM)預測人流量、使用梯度加權類激活映射(Gradient-weighted Class Activation Mapping, Grad-CAM)挑出影響預測的關鍵空間特徵、徑向基底函數網路-長短期記憶模型(Radial Basis Function - Long Short-Term Memory, RBF-LSTM)挑出關鍵時間點特徵、遷移學習理論之外掛模型(AddNN)預測人流誤差量，並且將多個外掛模型以集成學習之概念使預測達到強健性，最後統合基礎模型(BaseNN)與集成外掛模型(AddNNs)之結果獲得最終人流量預測，期望透過基礎模型的預測區域人流量與外掛模型預測基礎模型之誤差來使預測區域人流量達到更準確的數值，並加快整體模型預測效率，讓模型可以上線用於實際情況。

關鍵字：區域人流預測、卷積神經網路、長短期記憶模型、徑向基底函數網路、外掛模型、遷移學習、集成學習

ABSTRACT

Recently, more and more scholars have gradually paid attention to urban crowd prediction. There is a deep connection between crowd prediction and our daily life, whether business decisions, public health management, traffic control, or disaster relief in the city. Crowd flow prediction would be very helpful if we can predict it accurately. Current research on urban crowd prediction is focused on three methods, (1) statistical methods, (2) machine learning methods, and (3) deep learning methods. Among these three methods, the training performance of deep learning model is the best. However, deep learning model has two difficulties to overcome while using it on the prediction, (1) the time costs on training the model is too high, and (2) the prediction needs to be robust. Because of the shortcomings to the recent research on the crowd flow prediction, this research purpose a compensatory transfer learning model for crowd flow prediction. This model includes the base model convolutional neural network-long short-term memory (CNN-LSTM) to predict the crowd flow, using gradient-weighted class activation mapping (Grad-CAM) selects key temporal features, the plug-in model(AddNN) based on transfer learning predicts errors of the crowd flow and uses AddNNs with ensemble learning to get a robust crowd flow prediction. Finally, we combined the results of the basic model (BaseNN) and the add-on model (AddNN) with the concept of ensemble learning. We expected the regional crowd prediction can have a precise prediction through the base model and the plug-in model, and increase predict efficiency of the model and make it usable in our real life.

Keywords: Crowd Flow Forecasting, CNN, LSTM, Plug-in Module, Transfer Learning, Ensemble Learning

誌謝

時光飛逝，轉眼間兩年的研究所生涯即將邁入尾聲，驀然回首總有釋懷的感覺，心中滿滿不捨，感謝這段期間遇到許多熱心幫助、關懷的師長、學長姐以及同學們，此篇論文的完成承蒙許多人的支持以及鼓勵，讓我在曾經想要放棄之時卻又見到一絲曙光。

首先感謝我的指導教授—陳奕中老師，在大一那年有幸遇到老師擔任導師，教導許多有關資料科學及專業基礎的課程，在升上碩士班後加入您的實驗室進行研究。在學期間時常鼓勵我們參與研討會、比賽以及各種不同類型的專案累積自己的經驗及知識，也會在忙碌中不厭其煩地給予我們許多指導及建議，讓我在研究這條路上學習到很多。老師精心指導和無私的關懷，讓我受益匪淺。在此向我的恩師表示深深的感謝和崇高的敬意。

感謝非常照顧我們的富正大哥，志豪學長、東錡學長、映均學姐、靜瑜學姐、柏翔學長，提供我們許多資源且對於報告上給予很多建議及提醒，時時和我們分享學術上的知識，也會關心我們的生活狀況、分享趣事，和你們一起討論研究內容的時候總是學到很多自己未發現到的盲點及缺陷，感謝有你們讓我的研究可以更加完整。

感謝這兩年來和我一起努力的好戰友—佑蓉、佳昇以及重佑，不論是在課業、專案、論文提報到最後的口試，亦或是在生活上都給予我許多的幫忙及建議，也帶給我許多的歡笑，因為有你們讓我的研究所生活多采多姿。謝謝承安、維展、庭宇、恩杰、冠蓉、沂芸、湘庭、敏秀，在我面對電腦螢幕出現滿滿的錯誤感到無奈時，突來的一句招呼或關心總是讓我覺得很暖，是你們把我從獨自一人的小圈圈一把拉起，一起面對困難與共享各種歡樂的時光。也謝謝實驗室其他學長姐、學弟妹的指導與幫助，讓我不是獨自一個人面對枯燥無味的研究，共同完成各種大大小小的競賽及專案。另外，感謝在遊戲中遇到的一群好友們，在我忙碌的這段時間即使沒

有上線一起遊玩，還是會時不時關心我最近的狀況、陪我聊天放鬆，在我受挫時會跟我分享最近的趣事，給予我許多鼓勵。

最後特別感謝我最親愛的家人們，在我忙碌的碩士期間依舊時常關心我的身體，叮嚀我研究之餘不忘要注意心理狀態，在我身後默默的支持我、鼓勵我，讓我可以放心地去學習並完成碩士學位，朝我的目標前進，正因為有他們的支持，我才有動力繼續撐下去。

最後，謹此向所有幫助過我的人致上最大的謝意，並將這份成果獻給你們。



目錄

摘要	i
ABSTRACT	ii
誌謝	iii
目錄	v
表目錄	viii
圖目錄	ix
第一章 緒論	1
1.1 研究動機與目的	1
1.2 研究範圍	4
1.3 研究限制	4
1.4 研究流程	4
第二章 文獻回顧	7
2.1 複雜時間序列預測方法	7
2.1.1 統計模型	7
2.1.2 機器學習-SVR	7
2.1.3 機器學習-KNN algorithm	8
2.1.4 深度學習-LSTM	8
2.2 遷移學習	10
2.3 集成學習	11
2.4 文獻回顧小結	12
第三章 資料集介紹	13
3.1 目標資料集	13
3.2 輔助資料集	14

第四章	研究方法	15
4.1	建立基礎模型	16
4.1.1	資料前處理	16
4.1.2	訓練 CNN-LSTM 模型預測人流量	18
4.2	建立外掛模型	22
4.2.1	Grad-CAM 擷取影響人流量誤差的重要特徵	22
4.2.2	建立 RBF-LSTM 模型挑選重要時間特徵	24
4.2.3	外掛模型架構	26
4.2.4	使用遷移學習訓練外掛模型預測誤差	26
4.2.5	建立集成學習模型	27
4.3	模型實際運行	28
4.4	模型之績效評估	28
第五章	實驗模擬	29
5.1	資料集介紹	29
5.2	基礎模型與 Grad-CAM 挑選關鍵空間特徵	30
5.2.1	基礎模型(CNN-LSTM)	30
5.2.2	Grad-CAM 挑選空間特徵	31
5.3	RBF-LSTM 模型挑選關鍵時間特徵	33
5.3.1	西門商圈	33
5.3.2	信義商圈	35
5.3.3	東區商圈	37
5.3.4	南西商圈	39
5.3.5	新板特區商圈	40
5.4	遷移外掛模型訓練速度與績效	42
5.5	整體模型預測績效	43

5.6	預測強健性績效評估	46
第六章	結論與未來研究建議	49
參考文獻		50



表目錄

表 5.1 各商圈平均誤差人數	31
表 5.2 不同輸入對西門商圈預測人流量誤差的結果	33
表 5.3 西門商圈外掛模型輸入組合預測結果	35
表 5.4 不同輸入對信義商圈預測人流量誤差的結果	35
表 5.5 信義商圈外掛模型輸入組合預測結果	37
表 5.6 不同輸入對東區商圈預測人流量誤差的結果	37
表 5.7 東區商圈外掛模型輸入組合預測結果	38
表 5.8 不同輸入對南西商圈預測人流量誤差的結果	39
表 5.9 南西商圈外掛模型輸入組合預測結果	40
表 5.10 不同輸入對新板特區商圈預測人流量誤差的結果	40
表 5.11 新板特區商圈外掛模型輸入組合預測結果	42
表 5.12 各商圈訓練外掛模型訓練時間及預測結果	43
表 5.13 西門商圈集成模型結果與其他模型結果比較	44
表 5.14 信義商圈集成模型結果與其他模型結果比較	44
表 5.15 東區商圈集成模型結果與其他模型結果比較	44
表 5.16 南西商圈集成模型結果與其他模型結果比較	45
表 5.17 新板特區商圈集成模型結果與其他模型結果比較	45

圖目錄

圖 1.1 研究流程圖	6
圖 2.1 RNN 模型網路架構示意圖[14]	9
圖 2.2 LSTM 模型網路架構示意圖[14]	9
圖 2.3 集成學習範例	11
圖 3.1 人流資料範圍	13
圖 3.2 Google Trends 搜尋趨勢示意圖	14
圖 4.1 研究方法架構圖	16
圖 4.2 目標資料區間示意圖範例	18
圖 4.3 CNN-LSTM 模型架構示意圖	18
圖 4.4 卷積層運算示意圖[21]	19
圖 4.5 Dropout 示意圖	21
圖 4.6 Grad-CAM 的視覺化熱區圖	22
圖 4.7 使用 Grad-CAM 於圖像辨識示意圖[32]	23
圖 4.8 CNN-LSTM 標記網格並使用 Grad-CAM 識別示意圖	23
圖 4.9 RBF 層輸出計算平均值及標準差	25
圖 4.10 外掛模型架構圖	25
圖 4.11 集成學習模型	27
圖 4.12 最終模型結果	28
圖 5.1 西門商圈預測與實際人數比較	30
圖 5.2 信義商圈預測與實際人數比較	30
圖 5.3 東區商圈預測與實際人數比較	30
圖 5.4 南西商圈預測與實際人數比較	30
圖 5.5 新板特區商圈預測與實際人數比較	31

圖 5.6 西門商圈 Grad-CAM 熱區圖	32
圖 5.7 信義商圈 Grad-CAM 熱區圖	32
圖 5.8 東區商圈 Grad-CAM 熱區圖	32
圖 5.9 南西商圈 Grad-CAM 熱區圖	32
圖 5.10 新板特區商圈 Grad-CAM 熱區圖	33
圖 5.11 西門商圈 RBF 輸出標準化排序結果	34
圖 5.12 西門商圈 RBF 特徵值與人流量關係圖	34
圖 5.13 信義商圈 RBF 輸出標準化排序結果	36
圖 5.14 信義商圈 RBF 特徵值與人流量關係圖	36
圖 5.15 東區商圈 RBF 輸出標準化排序結果	37
圖 5.16 東區商圈 RBF 特徵值與人流量關係圖	38
圖 5.17 南西商圈 RBF 輸出標準化排序結果	39
圖 5.18 南西商圈 RBF 特徵值與人流量關係圖	39
圖 5.19 新板特區商圈 RBF 輸出標準化排序結果	41
圖 5.20 新板特區商圈 RBF 特徵值與人流量關係圖	41
圖 5.21 西門商圈強健性比較圖	46
圖 5.22 信義商圈強健性比較圖	47
圖 5.23 東區商圈強健性比較圖	47
圖 5.24 南西商圈強健性比較圖	48
圖 5.25 新板特區商圈強健性比較圖	48

第一章 緒論

1.1 研究動機與目的

近年來，越來越多人開始重視預測都市人流量，透過預測都市各地區的人流狀況，可以得知未來每天不同時間各地點的人流分布，經過統計後就可以得知人口量。而人流預測與生活中的大小事都息息相關，不管是城市中的商業決策、公共衛生管理、交通管制，亦或是救災，如果能精準預測未來人流量，對這些議題都有很大的幫助。在商業方面，商家若透過預測都市中的人流集中地點及時間，即可在哪些地區決定可以增設新店面以獲得更多的營收，也可以配合人潮集中的時間調整銷售策略，讓營收最大化。在公共衛生管理方面，在像流行性感冒或新型冠狀病毒等會透過民眾飛沫傳播的傳染病之高峰期間，如果能透過預測人流量提前得知未來會發生群聚的地點，即可提供給相關單位事先加強防疫宣導並考慮派遣人力到場維持防疫措施，避免造成防疫上的破口。在交通管制方面，若交通管理單位從預測都市交通熱區的人流量得知未來在哪些地區發生大量群聚情形，一方面可以加派人力到場維持秩序，避免因人潮眾多而發生推擠或踩踏事件，另一方面可預估人數是否超過該地區的交通負荷，若超過則可以事先增加大眾運輸工具的班次數量或是派遣接駁車等策略，以公共運輸替代個人騎車或開車的方式紓解大量人群的問題。在救災方面，若能透過預測未來各地區人群分布狀況，即可在災害發生前預先佈置救援人力，避免發生災害來臨時因人力不足而錯失救援的時機。

這裡以商業為例，A 先生是一名攤販業主，每天都會推著攤車到逢甲夜市擺攤販售小吃，對 A 先生而言來逢甲夜市觀光旅遊的每個人都有機會成為他的顧客。而在逢甲商圈擺攤初期容易因無法仔細估算大概會有多少人來逛夜市，可能會有備料過多而食物沒賣出去的情形或太多人來購買而備料不足的情況發生，前者會讓業者增加額外成本，後者會使業者減少獲利的機會。因此對於 A 先生而言，若是能精準估算商圈的人數，就可以省下浪費的成本也能獲得更多的利潤。對此電信

公司提供預測地區人流量的服務，店家需要向電信公司申請想預測人流量的區域，電信公司將會把該地區的人流量預測結果提供給店家。對於電信公司提供的此項服務當然會吸引眾多店家來申請，預測人流量對於商家開店來說是一件很重要的事，把握人潮即把握商機，若是能對於店面附近的人流量做預測，就可以做為商店營業決策的評估指標。

對此項具有商業價值的應用而言，相當考驗預測的準確度，電信業者推出這項服務會需要克服下列兩大困難點。(1)模型訓練時間成本問題，前面有提到因考量到商業價值的應用，故不能讓模型訓練時間太長，以免拖延到商店決定相關的事項。(2)預測結果不具有強健性，強健性是指進行預測時，避免被少數樣本影響整體預測結果，以餐廳為例，在製作餐點前會向上游業者購買食材，店家會先預測接下來可能會賣出多少份餐點來決定要向業者購買多少食材，若店家預測的準確度高，就不會剩下過多的食材浪費，反之若店家預測出現失誤，導致食材剩下一堆無法賣掉，就會影響到店家的營收。而商店也是同樣道理，若人流預測出現一次極大的誤差，就會對商店收益帶來很大的影響，進而會影響到其他店家無法相信電信公司提出的服務是準確的。

過往針對人流預測的方法可分成統計方法、機器學習方法以及深度學習方法來進行預測。在統計方法中，Zhang 等人[48]於 2011 年利用季節性自迴歸移動平均模型於預測都市高速公路短期的交通流量；Kumar 等人[20]於 2015 年利用季節性自迴歸移動平均模型以有限的交通資料預測短期交通流量；Clark 等人[6]於 2003 年利用 k -近鄰演算法預測都市中高速公路車流量。使用統計方法來預測人流量，因模型太過簡單，如果店家想預測的地點很多且人口流動量大，輸入的資料變得很複雜，導致模型無法好好訓練到整個資料特徵，整體預測績效會大大降低。在機器學習方法中，Li 等人[22]於 2021 年利用高斯過程迴歸模型預測交通流量；Yuan 等人[43]於 2021 年利用物理正則化高斯過程模型預測高速公路流量。使用機器學習來預測人流量，雖然模型複雜度相較於統計模型還要高，但因訓練過程需要以人工的

方式挑選特徵值，且人工挑選特徵值的好壞會嚴重影響模型預測的準確度，導致使用機器學習模型來預測人流量也不是一個很好的方法。在深度學習方法中，Lv 等人[26]於 2014 年利用堆疊自編碼器模型預測高速公路流量；Fu 等人[10]於 2016 年利用長短期記憶模型與門控遞迴單元預測短期交通流量；Zhang 等人[45]於 2016 年利用 DeepST 模型預測都市區域人流量；Zhang 等人[46]於 2018 年利用 ST-ResNet 模型預測都市區域人流量。使用深度學習模型來預測人流量的準確度相對於傳統統計模型與機器學習模型預測的準確度還要高，所以現今預測人流量之研究大多使用深度學習模型來進行訓練，能使預測出來的結果更符合實際狀況，但使用深度學習模型來預測最大的缺點在於需要耗費相當多的設備資源訓練模型，這會導致深度學習模型受限於設備程度無法普遍使用在各個地方，並且使用深度學習模型做訓練所需要使用的時間相較於其他兩種方法而言較多，訓練的時間成本高就會影響將結果提供給店家的時間，進而影響店家是否繼續使用此項服務的意願。前述所提到的各種預測人流量的研究，都僅使用一個模型來預測人流量，但使用單一模型來預測容易因輸入的數值有誤而對模型預測造成誤差，目前也尚未有相關研究提出具有強健性人流預測。

綜合上述提到兩個人流預測研究中會遇到的問題，本研究提出五個概念來解決，(1)以深度學習模型卷積神經網路-長短期記憶模型(Convolutional Neural Network-Long Short-Term Memory, CNN-LSTM)作為基礎模型訓練人流量達到較高精準度的預測結果，(2)使用梯度加權類激活映射(Gradient-weighted Class Activation Mapping, Grad-CAM)解釋最後一層 CNN 的梯度資訊，並以熱區圖呈現影響預測的關鍵空間因子，(3)使用網路聲量資料配合徑向基底函數網路-長短期記憶模型(Radial Basis Function - Long Short-Term Memory, RBF-LSTM)訓練人流誤差量並拆解 RBF 找出影響誤差產生的關鍵時間因子，(4)使用遷移學習的方法訓練多個預測誤差之外掛模型解決訓練時間成本過長的問題，(5)使用集成學習整合多個外掛模型預測結果解決預測結果需具有強健性的問題。透過上述提出之五個概念，即可讓

人流量預測降低時間成本且使預測結果更加精準。

1.2 研究範圍

針對人流量預測問題，為了使研究結果更符合實際情況，本研究將範圍限制在雙北市之商業區，包含信義商圈、西門商圈、東區商圈、新板特區商圈以及南西商圈，並將這些商圈的中心區域做為研究地點，因為這些地區的人流量多，並且經常會舉辦各種活動導致人流量變化大，因此本研究將針對雙北市商業區之商圈中心區域人流量進行預測。

1.3 研究限制

礙於收集資料過程中的多個限制，人流資料集的時間範圍只有 2018 年的資料並且只使用其中一家電信商所提供的資料，人流的定義為人群的流動，在本篇研究中將人流定義為人群分布，在原始資料裡的人流量是以網格化的方式在地圖上顯示，即為隨著時間而在網格中變化的人群流動數量，而無法知道單一人口隨著時間變化的活動行為。

影響人流量產生變動有許多因素，如天氣、地理位置、節日、大型活動…等，本研究僅以大眾搜尋關鍵字詞之網路聲量作為研究中的影響人流量誤差的元素。

1.4 研究流程

本研究之流程如圖 1.1 所示，分成七個階段，各階段說明如下：

1. 定義研究問題

根據過往人流量預測之研究議題，針對研究中所提出預測方法之缺點，提出一種能應用於小區域人群流量的預測方法。並透過遷移學習與集成學習的設計概念，使其可以降低預測的時間成本且能在預測上保持一定的穩定性，不受到異常數值而影響預測結果。

2. 相關文獻回顧

對於人流量預測之相關研究進行文獻回顧，針對不同預測模型研究進行探討，並在此階段說明本研究所使用到的深度學習預測模型。

3. 收集研究資料

本研究所收集之目標資料集為臺北市、新北市的人群流量資料，內容為電信業者所提供之 2018 年每小時行動數據資料。輔助資料集使用 Google 搜尋趨勢資料。

4. 資料整理

對於 2018 年之目標資料集以及各研究地區之網路聲量資料進行格式清洗。

5. 建立研究方法

本研究以大數據分析之流程訂定研究方法，首先將目標資料集與輔助資料集進行資料前處理，對資料視覺化，了解各時間點人流分佈狀況，配合地圖資料找出雙北市的商業區範圍，加以挑出符合本研究所要預測的人流量多且變動大之商業地區。將目標資料集輸入至基礎模型進行預測，再將輔助資料集做為外掛模型的輸入、基礎模型的誤差做為輸出訓練外掛模型，最後以集成學習的方式整合基礎模型與外掛模型得到最終的預測結果。

6. 模擬測試

將真實資料輸入至本研究開發之人群流量預測模型中進行預測，並透過模擬驗證推估模型準確度及預測的效率進行參數調整與修正。

7. 結論

根據模擬測試後的模型之預測結果驗證本研究開發之預測模型、外掛模型是否達到降低模型訓練時間及預測是否準確，並依照研究結果提出結論與未來相關之研究建議。




圖 1.1 研究流程圖

第二章 文獻回顧

本章節將列舉人流預測的相關研究，而人流預測大多數屬於複雜的時間序列預測問題，在文獻回顧的部分首先介紹過往用於處理時間序列預測問題的模型，其熱門方法包含統計模型、機器學習模型及深度學習模型。而過往文獻中尚未找到有學者將遷移學習與集成學習應用於人流預測上，故本章節會另外介紹遷移學習與集成學習之相關研究，最後進行文獻回顧小結。

2.1 複雜時間序列預測方法

2.1.1 統計模型

ARIMA(Autoregressive Integrated Moving Average model)又稱為整合移動平均自迴歸模型[17][18][34][44]，是一種常見的時間序列預測統計模型，由自迴歸模型(Autoregressive model, AR)以及移動平均模型(Moving Average model, MA)組成，常應用於時間序列資料的預測上，除了規律性的時間序列資料，ARIMA 也可應用在不平穩的時間序列資料。因為 ARIMA 不僅結合自迴歸模型與移動平均模型，還包含使時間序列平穩化的差分過程。若發現待預測之時間數列不滿足平穩的條件，即個體值出現明顯持續上升或下降的趨勢，會再對原始時間序列進行差分平穩化處理，使個體值圍繞時間序列之平均值上下波動。此方法是以過去一段時間內曾發生過的事情來推估當下即將發生的事情，ARIMA 模型建立在歷史資料的基礎上，所以收集的歷史資料越多，可以使模型預測越準確；Van 等人[37]於 1996 年使用 ARIMA 與混合分類器的方法預測高速公路短期流量；Zhang 等人[48]於 2011 年應用 ARIMA 與季節性結合的 SARIMA 來預測高速公路上短期的交通流量；Chen 等人[4]於 2019 年使用 ARIMA 與廣義自迴歸條件異方差模型等混和模型進行預測特殊事件期間的短期交通客流量。

2.1.2 機器學習-SVR

SVR(Support Vector Regression)又稱為支持向量迴歸模型[7][13][19]，為支援向

量機(Support Vector Machine, SVM)的分支,差別在於SVR預測出的數值為連續值,而SVM則是用來預測分類。SVR的原理是透過找到一個超平面,使得資料點的距離與超平面的距離和為最小,也就是使預測誤差降到最低,傳統迴歸方法認為預測值要與真實值一樣才是預測正確,而SVR會設定閾值 α ,若誤差在 $\pm\alpha$ 內都認為是預測正確。Su等人[35]於2007年利用增量支持向量迴歸模型(ISVR)預測短期交通流量;Li等人[23]於2013年利用支持向量迴歸與高斯損失函數(Gauss-SVR)預測都市交通流量;Hong等人[16]於2011年利用季節性SVR與混沌模擬退火演算法(SSVRCSA)來預測台灣北部交通流量;Hong等人[15]於2011年使用SVR與蟻群演算法(SVRACO)來預測短期交通流量。

2.1.3 機器學習-KNN algorithm

KNN演算法(k -Nearest Neighbors algorithm)又稱為 k -近鄰演算法[1][27][47],與其他預測模型最大的不同點在於常見的預測模型在訓練過程中會以損失函數來做為模型訓練的學習目標,而KNN在訓練過程中會在資料中找尋與目標最近的 k 個資料點,將 k 個資料點的數值平均後即為預測出的目標值,而 k 值的設定通常以交叉驗證來決定 k 值的大小。Cheng等人[5]於2018年利用自適應時空 k -近鄰演算法模型(adaptive-STKNN)來預測高速公路短期流量;Xia等人[39]於2016年使用時空權重 k -近鄰演算法模型(STW-KNN)來預測短期交通流量;Wang等人[38]於2015年利用支援向量機(SVM)與 k -近鄰演算法模型(KNN)來預測短期高速公路出口流量;Yu等人[42]於2012年使用 k -近鄰演算法模型(KNN)來預測短期交通流量。

2.1.4 深度學習-LSTM

LSTM(Long Short-Term Memory)又稱作長短期記憶類神經網路[11][12][33][36][40],其神經網路架構由循環類神經網路(Recurrent Neural Network, RNN)變化而來,兩種類神經網路都是用於訓練時間序列的資料,RNN在長期記憶時會容易出現梯度消失(Vanishing gradient)或梯度爆炸(Exploding gradient)問題,以致於模型無法訓練出好的績效。




圖 2.1 RNN 模型網路架構示意圖[14]




圖 2.2 LSTM 模型網路架構示意圖[14]

圖 2.1 為 RNN 模型網路架構示意圖，從圖 2.1 可以發現，RNN 模型透過前一個輸出傳入下一個單元傳送訊息，此方法可以用來記憶前一個單元的資料，但是 RNN 對於長期的預測較不準確。圖 2.2 為 LSTM 模型網路架構示意圖，LSTM 在神經元加上三種閘門(Gate)，分別為輸入閘(Input Gate)、遺忘閘(Forget Gate)以及輸出閘(Output Gate)，透過控制遺忘閘來決定前次記憶是否影響此次的輸出結果，即可對長期預測有良好的效果。在過去研究中 LSTM 模型大多用來處理複雜的時間序列資料。例如 Narmadha 等人[29]於 2021 年使用 CNN 和長短期記憶網路(LSTM)來預測短期交通流量；Bogaerts 等人[3]於 2020 年使用 CNN 和 LSTM 預測交通流量，發現不論是短期或長期都可以使用此模型來進行預測並且得到準確的數值；Zou 等人[50]於 2018 年應用 LSTM 於城市等級的交通流量預測；Li 等人[24]於 2018 年運用 LSTM 於預測旅遊流量，其最終結果顯示 LSTM 優於 ARIMA；Liu 等人[25]

於 2020 年使用 LSTM 預測廣州地鐵交通客流量。

近年來也有許多混合深度學習模型之研究進行人群流量預測，透過結合模型間不同特性，同時考慮時空特徵，例如，Narmadha 等人[29]於 2021 年使用卷積類神經網絡(CNN)和長短期記憶網路(LSTM)的架構，同時獲取時間及空間上的特徵來預測短期交通流量；Bogaerts 等人[3]於 2020 年使用卷積類神經網絡(CNN)和長短期記憶網路(LSTM)來預測交通流量，並將結果與過往僅使用單一模型來比較，發現其準確度也較之前的方法優異。

2.2 遷移學習

遷移學習(Transfer Learning)屬於機器學習的一種研究方法，研究起源於一個觀察，學者發現人類可以將以前的學到的知識應用於解決新的問題上，達到更快的解決問題或取得更好的效果。所以遷移學習的概念是從以前的任務當中去學習知識(Knowledge)或經驗，並應用於新的任務上，其目的在於從一個或多個源任務(Source tasks)中抽取知識、經驗，然後應用於一個目標領域(Target domain)，因目標領域和源領域(Source domain)的資料是類似的，所以可以透過遷移學習將已經學到的模型參數(模型學到的知識)，分享給新模型來加快並優化新模型的學習效率。使用遷移學習的優點有三個，(1)站在巨人的肩膀上，前人花費大量時間訓練出來的模型會比從零開始自己短時間內建構出的模型還要好，透過遷移學習就可以減少自己花費大量時間訓練模型，後續再依自己的資料進一步訓練模型準確度即可。(2)可以降低訓練成本，如果是使用導出特徵向量的方法進行遷移學習，後期再訓練的成本非常低，沒有使用高階的電腦也可以輕鬆訓練。(3)適用於小數據資料集，對於資料集過少的情況，重新訓練一個具有幾千萬參數的大型深度學習網路是不可能的，即使真的可以訓練出來，也有極大的可能會造成模型過擬合(Overfitting)的情況發生，若是使用遷移學習就可以提取已訓練好之大量特徵來進行再訓練。在過往研究中，Zoetmulder 等人[49]於 2021 年利用遷移學習來訓練醫學影像分割的任務並得到良好的績效；Menegola 等人[28]於 2017 年使用訓練糖尿病導致視網膜病變之模型運

用遷移學習的方式解決皮膚病變中的黑色素瘤分類問題。

2.3 集成學習

集成學習(Ensemble Learning) 是機器學習中的一種提升模型績效的方法，其概念在於多個學習加總的效果，會比單個學習的效果更好，也就是類似「三個臭皮匠勝過一個




圖 2.3 集成學習範例

諸葛亮」，圖 2.3(a)(b)為集成學習範例，設計師對於新服裝有 A、B、C 三種構想方案，對此他想詢問其他人的意見當作決定的參考，從圖 2.3(a)可知道單僅詢問一人時，雖然可以得到一個結果，但設計師同時會產生疑慮，只詢問一個人的意見可能會依個人喜好造成想法偏頗，不是一個最好的方案。而圖 2.3(b)詢問了多個人意見，透過每個人所選擇的答案及想法，似乎能更客觀地決定了要如何抉擇。相較於只詢問一個人，詢問多個人可以達到一個更穩定的答案，可以讓結果導向更好的決定，而這就是集成學習的核心。Sang 等人[31]於 2018 年使用集成學習在文字分類的研究；Binson 等人[2]於 2021 年使用集成學習透過電子鼻檢測慢性阻塞性肺病及肺癌；Yang 等人[41]於 2021 年使用集成學習與遷移學習方法的深度學習模型識別風力發電機的葉片損壞。

2.4 文獻回顧小結

本研究將時間序列預測方法分別以統計模型、機器學習模型、深度學習模型進行介紹，可發現基於深度學習模型預測出的結果優於其他兩種方法，而深度學習方法中，許多研究以證明卷積類神經網路(CNN)有強大的特徵擷取能力，可用來擷取資料中的空間特徵，而長短期記憶類神經網路(LSTM)優於循環類神經網路(RNN)的記憶能力，可用來擷取時間上的特徵並加以訓練。雖然使用深度學習網路模型可以得到良好的預測績效，但因其網路架構龐大，需要花費大量的設備成本與時間成本，故本研究藉由過往研究中遷移學習與集成學習的概念，將人流預測模型能以其概念建立，減少大量之建模時間成本與增加預測精準度。



第三章 資料集介紹

本章節介紹本實驗中所使用的不同類型時間序列資料集，分成兩個類型。第一個類型為目標資料集，以人流群量預測為目標的人流資料。第二個類型為輔助預測人流量的輔助資料集，以 Google 瀏覽器搜尋關鍵字統計的 Google 搜尋趨勢資料，此資料集作為網路聲量大小的判斷依據，以下分兩節進行資料介紹。

3.1 目標資料集

本研究使用某電信業者所提供之行動數據人流資料，資料涵蓋區域為臺北市、新北市、基隆縣、桃園市、宜蘭縣等地區，如圖 3.1 所示，而本研究選用 2018 年的人流資料作為目標資料集來進行後續模擬。

資料範圍從 2018 年 01 月 01 日至 2018 年 12 月 31 日，而為了保護行動裝置使用者之個資安全，資料集是以每 500 公尺 $\times$ 500 公尺範圍的網格大小計算所涵蓋之人群流量，但因產學合作案簽署保密協議，故無法在此提供更多資料的細節。




圖 3.1 人流資料範圍

3.2 輔助資料集

此資料來源是 Google 開發的一款 Google 搜尋趨勢(Google Trends)服務，輸入搜尋關鍵字並且自訂時間範圍，可得到過去民眾使用 Google Chrome 網頁瀏覽器搜尋關鍵字的趨勢資料，如圖 3.2 為搜尋關鍵字「西門町」在 2018 年的搜尋趨勢。表 3.2 為從 2018 年 01 月 01 日至 2018 年 12 月 31 日每小時搜尋可能會造成人流量起伏等關鍵字，例如西門町、新北市歡樂耶誕城、東區地下街...等。




圖 3.2 Google Trends 搜尋趨勢示意圖

表 3.1 Google 搜尋趨勢資料

日期	時間	關鍵字	關鍵字搜尋趨勢數值
2018-01-01	0 時	西門町	23
2018-01-01	0 時	東區	12
2018-01-01	0 時	東區地下街	18
...		...	...
2018-12-31	23 時	台北 101	96

第四章 研究方法

本研究提出之方法將預測人群流量分為兩部分，分別為 Offline 訓練與 Online 運作兩部分，研究方法架構圖如圖 4.1 所示。在 Offline 訓練中分成兩個階段進行，第一階段為建立基礎模型，首先將目標資料先進行資料前處理，包含數值預處理和數值正規化兩個部分，利用卷積神經網路-長短期記憶模型(Convolutional Neural Network-Long Short-Term Memory, CNN-LSTM)預測人流量，再透過梯度加權類激活映射(Gradient-weighted Class Activation Mapping, Grad-CAM)觀察對於預測人流量來說重要的空間特徵為何，探討影響預測的地區。第二階段要建立外掛模型預測人流誤差值，前一階段建立的模型尚存在些許誤差，在此階段，我們會先用 Grad-CAM 分析基礎的 CNN-LSTM 模型以獲得目標區域人流數量預測的關鍵空間因子。接著我們會用 CNN-LSTM 模型所產生的誤差做為輸出，訓練徑向基底函數網路-長短期記憶模型(Radial Basis Function - Long Short-Term Memory, RBF-LSTM)來預測基礎模型的人流量誤差，訓練完後透過拆解 RBF 層的輸出，挑選出對於預測誤差來說重要的關鍵字詞及時間點。挑選完關鍵特徵，將特徵值進行排列組合產生多組輸入，先訓練出第一個深度學習模型(Deep Neural Network, DNN)外掛模型後使用遷移學習的方式依序訓練其他組外掛模型，產生多個外掛模型，外掛模型的用途在於預測基礎模型的誤差，運用集成學習的方式整合模型預測出人流量誤差量。在 Online 運作部分，將 Offline 階段建立的基礎模型以及集成外掛模型將目標資料與輔助資料一起輸入至已訓練好的模型裡，得到欲預測之網格人流量。




圖 4.1 研究方法架構圖

4.1 建立基礎模型

4.1.1 資料前處理

在將資料輸入至模型訓練前，要先確認資料型態是否統一，是否有出現異常或缺漏值，避免因資料出現小瑕疵而導致模型預測不準確，以下將分為兩個部份來依序介紹。

首先是數值預處理，透過資料視覺化觀察後發現目標資料集在 2018 年的資料裡面有出現缺漏值，而缺漏值大多是因為資料收集過程中因儀器的故障、維修或網路不穩定造成資料缺失。為了使資料保持連續性，本研究使用線性插值法來進行資

料補值，插值分為兩種方式，依遺漏或異常數值的持續時間來決定。若持續時間小於 24 小時，則我們會使用該時段前後的數值來進行插值，因為這樣補起來的數值最能與當天的情形對應。假設 $y(\cdot)$ 是目標的時間序列， h 代表遺失範圍前最後一筆正常資料的時間， g 代表資料遺失的時間長短， n 代表要補值的第 n 筆資料預測，其中 $g-1 \geq n \geq 1$ ，則第一種補值公式可表示如式(1)，若需要補值的範圍超過 24 小時，則我們會使用補值前 24 小時的人流資料與後 24 小時的人流資料的平均進行補值，其補值公式則如式(2)，其中 t 代表要補值的數值。過往研究中有學者是使用平均值補值的方法，此方法雖然可以讓數值補上且數值合理，但假如缺漏的時間點舉辦活動或有大量人群移動，可能會導致補值不夠精準使預測結果不好，所以本研究採用線性差值法來進行補值，讓資料在時間的連續性上可以維持。

$$y(h+n) = y(h) + \frac{n}{g+1}(y(h+g+1) - y(h)) \quad (1)$$

$$y(t) = \frac{y(t+24) + y(t-24)}{2} \quad (2)$$

經過資料清洗後，輸入模型前要確認資料是否需要數值正規化，若資料區間太廣，輸入模型訓練前沒有經過正規化的步驟，會導致模型預測結果偏向資料比重較多的區間。以下圖 4.2 目標資料區間示意圖為例，可以發現大多數網格的數值都落在 4000 人以下，4000 人以上的數量鮮少，如果沒有進行正規化就輸入至模型訓練，會導致模型輸出的結果絕大部分都落在 4000 人以下的數值，即使有數值超過 4000 人以上，也會很接近 4000 人，而人流預測差距 1000 人以上就會對其應用造成很大的影響，為避免這種情況發生，本研究使用最小值最大值正規化(Min-Max Normalization)來處理，最小值最大值正規化的公式如式(3)，透過正規化後的數值會將資料區間縮小，但不會影響原資料的分布情況，輸出資料後再經由反正規化還原成原來的數值大小。使用正規化時要注意，若資料集發生新增或刪減資料時，需要重新再執行正規化，因前次的正規化的資料筆數發生變動，連帶影響整體數值的分布，所以需要重新執行一次才能讓資料進行反正規化後還原成原本的數值。




圖 4.2 目標資料區間示意圖範例

$$x' = \frac{x - \min}{\max - \min} \quad (3)$$

4.1.2 訓練 CNN-LSTM 模型預測人流量

在本節中，我們將介紹用於區域人群流量預測的基礎模型 CNN-LSTM 的架構及如何訓練。

該模型的輸入輸出為預處理時產生的輸入 $\mathbf{I}$ 和輸出 $\mathbf{O}$ 。 i_r 為輸入 $\mathbf{I}$ 中第 r 筆資料， i_r 包含 $t_{input} \times m \times n$ 個數值 (t_{input} 表示前 t_{input} 個時間序列， $m \times n$ 表示每個時間點的網格數)。 $\mathbf{O}$ 為輸入資料經過訓練後預測出的目標人流量。使用 CNN-LSTM 模型時，輸入輸出分別為 i_r 和 o_r 。




圖 4.3 CNN-LSTM 模型架構示意圖

圖 4.3 為 CNN-LSTM 模型的架構示意圖。除了輸入層和輸出層，模型還有兩個子部分。第一個部分是為了提取不同時間段中有用的空間資訊。包含兩個卷積層

(Convolution layer)和一個最大池化層(Subsampling/Pooling layer)。第二個部分從前一個部分提取對人流預測有用的時間資訊，並將資訊輸出到輸出層以產生預測結果。該部分包括五個 LSTM 層(LSTM layer)、三個 Dropout 層(Dropout layer)和一個輸出層。下列將詳細解釋 CNN-LSTM 模型中每一層的訓練過程以及該層在人流量預測中的作用。

(1)輸入層：輸入層的主要功能和目的是向模型輸入資料。該層節點 i 的數學公式如式(4)。

$$O_i = I_i \quad (4)$$

(2)卷積層：本研究所提出的模型包含兩個卷積層。第一個卷積層的輸入包含按時間拆解的輸入資料，即為各個 t_{input} 時間段的 $m \times n$ 矩陣數值。其設計目標是利用這兩個卷積層從各個時間段中提取空間和時間信息，幫助模型實現更好的預測精準度。假設每層有 k 個卷積核(kernel)，每個卷積核的大小為 $s \times s$ 。對於時間段 t 內位置 (x,y) 處的神經元 i ，輸出可以表示為式(5)。其中 $O^i(t,x,y)$ 是時間段 t 層中位置 (x,y) 處神經元 i 的輸出值， b_i 和 k_i 是相應的偏移項和卷積核，卷積層運算如圖 4.4 所示，卷積層從輸入資料中提出特徵，透過卷積核在資料上平滑移動由各個網格相乘後再相加算出數值，直到所有網格都走完。而卷積核的數值為預訓練的權




圖 4.4 卷積層運算示意圖[21]

重，初始值由常態分佈隨機產生，卷積核的數量即為控制學習的參數量，沒有數值越大或越小即代表此次的訓練結果會很好或很糟，依照資料的特性而有不同的卷積核數量。 I 表示該層輸入， $act(\bullet)$ 是激活函數，本研究中使用 Relu 函數作為激活函數。

$$O_{(t,x,y)}^i = act(\sum_{j=1}^s \sum_{l=1}^s k_{t,x+j-1,y+l-1}^i I_{(t,x,y+l-1)} + b_t^i) \quad (5)$$

(3)最大池化層：最大池化層在兩層卷積層後，主要目的為減小模型的大小並突顯空間特徵訊息的重要性。假設前一層的輸入維度是 (L_i, W_i, D_i) ，而這一層的kernel 和步伐分別是 (p, p) 和 s 。該層的運算公式如式(6)至式(8)， (L_o, W_o, D_o) 為最大池化層輸出的維度。

$$L_o = \left\lfloor \frac{L_i - p}{s} + 1 \right\rfloor \quad (6)$$

$$W_o = \left\lfloor \frac{W_i - p}{s} + 1 \right\rfloor \quad (7)$$

$$D_o = D_i \quad (8)$$

(4)攤平及串聯層：該層將模型前半部分排序及得到的各個時間維度的空間特徵資訊進行攤平和串聯，以方便模型後半部分的操作。上一層總共 t 個時間段的輸入維度為 (L_i, W_i, D_i) ，該層的攤平後輸出維度為 D_o ，其中 $D_o = L_i \times W_i \times D_i$ 。這一層串聯了 t 個時間段的數據，最終輸出的維度為 (t, D_o) 。

(5)LSTM 層：透過模型前半部分得到更高維度的空間特徵，在這一層訓練各種時間特徵的影響。模型的後半部分共有五個 LSTM 層。第一層對模型前半部分輸出的時間序列特徵進行初步排序，第二層提取高維度的資訊。第三層降低維度以更好地收斂預測目標值所需的時間特徵資訊。在模型中，前四個 LSTM 層的輸出皆為下一層 LSTM 的輸入，只有在最後的 LSTM 層，才使用最後一個時間點的 LSTM 神經元輸出作為整個 LSTM 模型的輸出。這樣做的目的是為了方便獲取最終的時間特徵資訊，以便輸出層可以更好地對其進行模擬。每層分為 t 個時間點。

每個神經元包含五個部分：輸入閘 i_t 、遺忘閘 f_t 、記憶單元 c_t 、輸出閘 o_t 和隱藏狀態 h_t 。閘的激活函數為 Sigmoid 函數，為了更好地控制輸出範圍，我們對循環過程的激活函數使用了 Relu 函數。這一層神經元的公式如式(9)至式(13)。




圖 4.5 Dropout 示意圖

$$i_t = \sigma(W_{xi} * x_t + W_{hi} * h_{t-1} + W_{ci} \circ c_{t-1} + b_i) \quad (9)$$

$$f_t = \sigma(W_{xf} * x_t + W_{hf} * h_{t-1} + W_{cf} \circ c_{t-1} + b_f) \quad (10)$$

$$c_t = f_t \circ c_{t-1} + i_t \circ Relu(W_{xc} * x_t + W_{hc} * h_{t-1} + b_c) \quad (11)$$

$$o_t = \sigma(W_{xo} * x_t + W_{ho} * h_{t-1} + W_{co} \circ c_t + b_o) \quad (12)$$

$$h_t = o_t \circ Relu(c_t) \quad (13)$$

(6) Dropout 層：Dropout 是一種對抗過度擬合的正則化方法，為了避免出現模型過度擬合的情況，本研究在前三個 LSTM 層的每一層之後各添加了一個 Dropout 層。這一層的概念是存在停止工作的概率 p ，如圖 4.5 為例，每一層以 0.3 的機率丟棄神經元，在訓練時每一次的迭代(epoch)以一定的機率丟棄隱藏層神經元，而被丟棄的神經元不會傳遞訊息，使模型訓練過程中不會過度依賴某些區域的特徵，增強了模型的泛化能力

(7)輸出層：最後，模型使用一個全連接層(Fully-connected layer)對提取的特徵

進行建模，公式如式(14)，其中 o_j 是節點的輸出， $\sigma(\bullet)$ 是 Sigmoid 函數， w_{ij} 和 b_j 是相對應的權重和偏移項。

$$o_j = \sigma(w_{ij}i_i) + b_j \quad (14)$$




圖 4.6 Grad-CAM 的視覺化熱區圖

4.2 建立外掛模型

4.2.1 Grad-CAM 擷取影響人流量誤差的重要特徵

本章節將會介紹如何對 CNN-LSTM 模型進行 Grad-CAM 算法的計算。Grad-CAM(Gradient-weighted Class Activation Mapping)[32]在 2016 年被發表出來，該方法透過反向傳播(Backpropagation, BP)來計算 CAM(Class Activation Mapping)的特徵權重，其算法取代了 GAP(Global Average Pooling)，因此無須更改模型架構和重新訓練。

藉由 Grad-CAM，可以視覺化最後一層卷積層在特徵網格圖上所重點關注的區域，如圖 4.6 所示，該熱區圖說明了卷積層的特徵圖之中，左下角和右邊的紅色的特徵區域在此預測有更重要的權重。過往 Grad-CAM 常被使用在圖像識別上，而輸入影像中每張待識別的對象位置皆不相同，如圖 4.7，所以會造成 Grad-CAM 視覺化後產生的熱區圖長得不一樣。而本研究所輸入之資料為區域網格人群流量資料，預測地區周圍的網格座標不會變動，預測所使用的網格範圍都相同，能使最後產生之熱區圖顯示熱點及非熱點不會因每個時間的資料而變動。




圖 4.7 使用 Grad-CAM 於圖像辨識示意圖[32]




圖 4.8 CNN-LSTM 標記網格並使用 Grad-CAM 識別示意圖

圖 4.8 為總共 t_{input} 個時間段的人流量資料被輸入到卷積層。Grad-CAM 利用進入 CNN 最後一個卷積層的特徵圖 F (Feature map)，對每個神經元的分佈重要性做進行排名。對於每個 F ，都有 t_{input} 個特徵圖。它們的長度和寬度分別是 m_f 和 n_f ，它們的通道尺寸是 s_c 。在預測過程中，將資訊輸入到 CNN-LSTM 模型中，隨後輸出的是預測結果 $\hat{o}$ 。對於時間段 t 內通道 c 的特徵圖 f^c ，我們可以透過式(15)計算各自的重要性權重 w_c^t 。前項計算 GAP，後項 $\partial \hat{o} / \partial f^c$ 表示通過反向傳播的梯度計算。

$$w_c^t = \frac{1}{m_f \times n_f} \sum_{m_f} \sum_{n_f} \frac{\partial \hat{o}}{\partial f_c^t} \quad (15)$$

接著結合所有特徵圖的重要性，並使用式(16)得到 CNN-LSTM 模型的特徵權重矩陣 $\mathbf{W}$ ，其中前項是所有時間點的平均，後項計算各個時間點的權重和對應的特徵圖權重組合。Grad-CAM 值是使用 Relu 函數計算而來。使用式(16)可以將 $\mathbf{W}$ 中的值由大到小排序，以獲得 CNN-LSTM 模型中的重要特徵及其順序。

$$\mathbf{W} = \frac{1}{t_{input}} \sum_t Relu(\sum_c^{s_c} w_c^t f_c^t) \quad (16)$$

4.2.2 建立 RBF-LSTM 模型挑選重要時間特徵

上一節完成基礎模型(BaseNN)的訓練與建置以及使用 Grad-CAM 觀察關鍵特徵網格後，在本節中將會介紹如何使用輔助資料來訓練 RBF-LSTM 預測人流量誤差並找出關鍵時間點資料。

每個地區所使用到的輔助資料會以預測的地區為中心周圍 1500 公尺範圍內的景點名稱或常搜尋字詞做為輸入，然而因為每個人對於出遊或行程規劃的事前準備時間不同，大多數人的生活習慣又以一週為一個循環，故本研究針對這點，將前一天至前七天的每個小時輔助資料作為 RBF-LSTM 模型的輸入，而輸出為前述之 CNN-LSTM 模型得出的誤差(Base_Error)，用以預測基礎模型的誤差值。

而使用 RBF 的目的在於幫我們找出不同關鍵詞中影響預測誤差的重要時間段，為使解說容易，下面輸入將以三個 Google Trends 抓取出的關鍵詞，輸入大小為前一天至前三天的 24 小時資料為例，此處 RBF 設定為產生 3 個新的特徵值(q)。

(1)經過前述 RBF-LSTM 模型訓練多次後，選擇模型中預測結果最好的超參數來做測試。(2)將測試資料輸入至挑選出的 RBF-LSTM 模型中，並提取 RBF 層的輸出結果。(3)而在 RBF 層篩選特徵部分，每個 RBF 會產生 3 筆新的特徵值，透過計算三個 RBF 的平均值與標準差，就可以知道每個時間中每個關鍵字對預測誤差的重要程度，如圖 4.9 所示，而標準差越大代表資料訓練過程持續調整權重大小，其

重要程度也越大，最後使用手肘法來挑選要選擇哪些特徵值作為外掛模型來訓練。手肘法是在訓練分群被提出的概念，透過 SSE(Sum of the Squared Errors，誤差平方和)作為指標，決定最終結果要被分成幾群，而本研究借鑒此概念，將三組 RBF 的特徵值標準化後，將數值由大而小排序，找出資料的轉折點在哪裡，決定要選取多少特徵時間點作為外掛模型訓練。




圖 4.9 RBF 層輸出計算平均值及標準差




圖 4.10 外掛模型架構圖

4.2.3 外掛模型架構

上一節完成 RBF-LSTM 模型訓練並挑選出關鍵字詞及時間點影響預測誤差後，本節接著介紹外掛模型(AddNN)的模型架構。

本研究在外掛模型上使用簡單的深度學習網路(DNN)來進行訓練，原因有兩個，(1)由於每個商圈挑選出來的關鍵字詞及時間點都不同，挑選出的資料間失去時間關聯性，使用基礎 DNN 就可以訓練，(2)為了減少訓練的時間成本，越複雜的模型可以學習到資料更多的特徵，可以使預測更精準，當資料複雜度不高時，使用簡單的模型即可達到高精準度的預測結果。模型架構如圖 4.10 所示，輸入的特徵量為 n ，經由四層全連接層的運算後得到預測出的人流誤差值。

4.2.4 使用遷移學習訓練外掛模型預測誤差

經過拆解 RBF 層挑選出影響預測的關鍵特徵後，將特徵值進行排列組合產生多組輸入，先訓練出第一個 DNN 外掛模型後使用遷移學習的方式依序訓練其他組外掛模型，產生多個外掛模型，外掛模型的用途在於預測基礎模型的誤差。

外掛模型的輸入為前一節挑選出的多個特徵值，將這些特徵值進行排列組合產生多組不同的輸入，而使用排列組合是為了使輸入的數值產生更多的變化。舉例來說，原本有 5 個特徵，全部輸入到同一個模型訓練，如果其中一個特徵相對其他特徵來說對預測結果較沒有幫助，可能會導致模型因為學習該特徵而產生更多訓練誤差，若使用排列組合的方式每次挑選其中幾個當輸入訓練模型，就可以產生不同輸入的訓練結果，進而把影響預測的特徵去除，找到只需要較少特徵的模型比所有特徵放入訓練還更好的結果。本研究以數學中常使用的組合(Combination，如 C_2^5)方法來產生多種特徵輸入，選取其中一組輸入先訓練出第一個 DNN 外掛模型(AddNN_1)，剩下的外掛模型(AddNN_2、AddNN_3...)架構與 AddNN_1 的模型架構一樣，差別在於第一個外掛模型是從頭開始訓練，而剩下的外掛模型，因為訓練目標及模型輸入類似，在這裡為了節省後續外掛模型訓練的速度，使用遷移學習的

方式遷移第一個外掛模型的第一層模型參數，僅訓練後面幾層的參數值，透過此方法去減少模型訓練時間同時達到類似的預測水準。

藉由可能會影響人流變動的關鍵字詞來預測基礎模型(BaseNN)的人流量誤差(Base_Error)，訓練出多個外掛模型(AddNN)，目的是用來輔助 BaseNN 的預測，使預測結果能更精確。

4.2.5 建立集成學習模型

外掛模型的預測目標為人流誤差值，然而人流量容易因為大型活動或特殊節日導致該地點出現劇烈的人流變化量，過高或過低的人數會使模型在預測時出現模型未訓練到的數值而使誤差變大，所以本研究為避免預測結果受到輸入數值異常影響預測結果，使用集成學習的方式來產生具有強健性的預測結果。

透過前一節訓練出多個外掛模型來預測人流誤差值，從所有外掛模型中挑出三個預測績效最好的模型進行集成學習如圖 4.11 所示，最後將三個外掛模型的結果再接上一顆類神經訓練，得到最後的人流誤差值結果。




圖 4.11 集成學習模型




圖 4.12 最終模型結果

4.3 模型實際運行

從前面幾節中可獲得一個基礎模型(BaseNN)預測人流量以及一個集成外掛模型預測人流誤差值，將基礎模型的人流量結集成外掛模型的人流誤差值即可得到最終的預測人流量結果，如圖 4.12 所示，將想預測的地區周圍人流量與網路聲量資料輸入模型，即可得到人流預測值。

4.4 模型之績效評估

本研究目的為改善過往研究所遇到的兩個問題，(1)時間成本過高以及(2)預測必須考慮強健性，因此本研究將透過下列四項指標與過去方法做比較，以(1)模型所需參數量、(2)模型訓練時間等兩項指標來進行時間及訓練成本的績效評估，以(3)各種模型誤差之平均值、(4)模型輸入出現錯誤值等兩項指標來驗證本研究所提出之模型預測有良好的準確度及具有強健性。誤差以平均絕對誤差(Mean Absolute Error, MAE)作為計算方式，公式如式(17)，與所有模型誤差做平均值之比較。

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (17)$$

第五章 實驗模擬

本研究使用某電信公司提供行動數據人流資料作為目標資料集，Google Trends 所搜集的網路聲量資料作為輔助資料集，以卷積神經網路-長短期記憶模型 (Convolutional Neural Network-Long Short-Term Memory, CNN-LSTM) 訓練預測人流量之基礎模型，配合梯度加權類激活映射 (Gradient-weighted Class Activation Mapping, Grad-CAM) 挑選空間特徵及徑向基底函數網路-長短期記憶模型 (Radial Basis Function - Long Short-Term Memory, RBF-LSTM) 挑選時間特徵，再使用遷移學習及集成學習訓練外掛模型預測人流誤差值，結合基礎模型及外掛模型結果獲得最後的預測結果，最終以量化及質化方式來驗證本研究所提出的方法之有效性。以下將分成五個部分來介紹，(1) 資料集介紹，(2) 基礎模型與 RBF-LSTM 模型挑選關鍵時間特徵，(3) 遷移式外掛模型 (4) 集成學習模型 (5) 挑選特徵之質化分析。本研究之實驗是使用 python 程式語言實作，並在 Intel i7-12700 處理器、DDR4 64GB 記憶體及 Windows 11 的作業系統上完成。

5.1 資料集介紹

本研究之目標資料集為某電信業者所提供之行動數據人流資料，資料區間為 2018 年 1 月 1 日至 2018 年 12 月 31 日，每個資料點為 500*500 公尺的網格。輔助資料集為 Google Trends 所搜集之網路聲量資料。

研究地點選擇新北市、台北市中五個大型商圈作為研究地點，分別為西門商圈、信義商圈、東區商圈、新板特區商圈以及南西商圈，雙北市裡有各種規模的商圈，而這五個商圈是較為著名且消費者最常造訪的商圈，故本研究選擇這五個地點作為研究目標。

5.2 基礎模型與 Grad-CAM 挑選關鍵空間特徵

5.2.1 基礎模型(CNN-LSTM)

本研究選擇新北市、台北市 5 個大型商圈作為研究地點，分別為西門商圈、信義商圈、東區商圈、新板特區商圈以及南西商圈。基礎模型(CNN-LSTM)訓練部分，使用前 3 小時($T \sim T-2$)人流量，周圍半徑 1500 公尺的網格座標作為輸入，預測下一個小時($T+1$)中心座標的地區人數。圖 5.1 至圖 5.5 為各個商圈的基礎模型預測值與實際值比較圖，表 5.1 為各商圈平均誤差人數。




圖 5.1 西門商圈預測與實際人數比較




圖 5.2 信義商圈預測與實際人數比較




圖 5.3 東區商圈預測與實際人數比較




圖 5.4 南西商圈預測與實際人數比較




圖 5.5 新板特區商圈預測與實際人數比較

表 5.1 各商圈平均誤差人數

	西門商圈	信義商圈	東區商圈	南西商圈	新板特區商圈
MAE	196	582	222	247	687

由表 5.1 可得知在沒有其他資料輔助預測的情況下，五個商圈的人流誤差值從 196 人至 687 人不等，每個商圈的預測結果不盡相同，且有的商圈可能因為人流變化劇烈而使模型無法好好預測出準確的結果。

5.2.2 Grad-CAM 挑選空間特徵

訓練完基礎模型後，透過 Grad-CAM 套件拆解 CNN 模型最後一層的特徵網格，透過熱區圖呈現出來。在熱區圖中，顏色越接近橘、紅色代表該區塊對於預測結果越重要；反之，顏色越接近藍色代表該區塊對於預測結果越不重要。圖 5.6 至圖 5.10 為將 Grad-CAM 繪製出的熱區圖重疊到地圖上的結果，從圖片上可看到根據每個商圈地理位置不同，影響該地區的環境因子也不一樣。

西門商圈觀察到的關注點在萬華、三重地區，萬華地區是著名觀光客旅遊會前往的地方，有許多著名的景點，而三重地區關注的範圍含有一些大型建築，如醫院、學校、運動中心等。信義商圈關注的地區有兩個，一個位置在商圈中心左方，其範圍內涵蓋醫院、國父紀念館、中山公園等人群聚集地。一個在右下角的山區，附近有象山、虎山、拇指山等登山景點，也會有許多人為了拍攝遠方的城市而特地前往。

東區商圈關注的地區在商圈右半邊，由地圖上觀察可發現該地區有許多餐廳、服飾店以及購物中心，都是人群會移動且聚集的地點。南西商圈關注的地區在商圈的右半部，該地區涵蓋了學校、小型商圈、餐飲場所等地點。新板特區商圈關注的地區在商圈中心偏下方的位置，包含板橋車站、百貨公司、府中商圈等板橋地區人群聚集處。

從 Grad-CAM 的熱區圖顯示可觀察出影響各商圈人流預測的地區，可看出大多商圈的人流預測和周圍的人流聚集點(如小型商圈、餐飲場所、景點…等)有關。




圖 5.6 西門商圈 Grad-CAM 熱區圖

圖 5.7 信義商圈 Grad-CAM 熱區圖




圖 5.8 東區商圈 Grad-CAM 熱區圖

圖 5.9 南西商圈 Grad-CAM 熱區圖




圖 5.10 新板特區商圈 Grad-CAM 熱區圖

5.3 RBF-LSTM 模型挑選關鍵時間特徵

我們將基礎模型預測出的人數與實際人數相減獲得誤差(Error)，再將輔助資料中與預測地區有關的關鍵字詞作為輸入 RBF-LSTM 模型訓練誤差，輸入的時間區段分別為前一天($T \sim T-23$)、前一至二天($T \sim T-47$)、前一至三天($T \sim T-71$)...、前一至七天($T-167$)，輸出為基礎模型所產生的誤差(Error)。下面將針對不同商圈各別探討 RBF-LSTM 模型的訓練人流誤差結果及挑選出的時間特徵點。

5.3.1 西門商圈

表 5.2 為不同輸入對西門商圈預測人流量誤差的結果，透過模擬後發現輸入前三天的輔助資料所預測出的誤差值能讓預測人流量的結果維持最好的績效，故後續將以前一至三天($T \sim T-71$)作為模型輸入。

表 5.2 不同輸入對西門商圈預測人流量誤差的結果

	前一天	前一至 二天	前一至 三天	前一至 四天	前一至 五天	前一至 六天	前一至 七天
MAE	201	159	126	130	134	133	129

訓練完 RBF-LSTM 模型後，取出 RBF 層的輸出再進行標準化，最終將標準化結果由大到小進行排序如圖 5.11 所示，可看到圖中在第八個特徵點出現轉折，依照手肘法的概念，取前八個特徵時間點作為後續的外掛模型輸入。




圖 5.11 西門商圈 RBF 輸出標準化排序結果

對挑選出來的八個特徵時間點取其中一個特徵值的數值與實際人流變化做比較，挑選 T-3 關鍵字為西門町的特徵，意指當關鍵字在前 3 小時搜尋量提升後，3 小時後的人流量會上升，圖 5.12 為 2018 年 1 月 14 日的人流資料與聲量資料，可以看到下午 2 點在聲量資料出現高點，而三小時後西門商圈就發生人流量變多的情況，這可以驗證挑出來的特徵值確實會影響到人流預測。

挑選出八個特徵時間點後，利用排列組合方式得到不同特徵點組合，為避免挑選的特徵點數量會影響到預測結果，本研究模擬多種組合結果來決定該商圈預測誤差要使用多少個特徵點以得到最佳預測結果。




圖 5.12 西門商圈 RBF 特徵值與人流量關係圖

表 5.3 西門商圈外掛模型輸入組合預測結果

	模型人數	誤差改善幅度	訓練時間(s)	模型總參數量
base_model	196	X	205	226,833
base_model + C_1^8	182	7.1%	275	226,865
base_model + C_2^8	165	15.8%	288	226,927
base_model + C_3^8	136	30.6%	306	227,082
base_model + C_4^8	135	31.1%	368	227,718
base_model + C_5^8	130	33.7%	412	228,692

表 5.3 為西門商圈外掛模型輸入組合預測結果，從表中可知道最佳結果為 C_5^8 的模型，結合基礎模型後的誤差人數為 130 人，而 C_3^8 的模型績效為 136 人，與最佳結果差距 6 人，但其模型減少了訓練的參數量也減少近 34% 的訓練時間，在考慮模擬的時間成本及運算成本後，本研究選用 C_3^8 的模型輸入作為西門商圈後續外掛模型的輸入特徵量。

5.3.2 信義商圈

表 5.4 為不同輸入對信義商圈預測人流量誤差的結果，透過模擬後發現輸入前四天的輔助資料所預測出的誤差值能讓預測人流量的結果維持最好的績效，故後續將以前一至四天(T~T-95)作為模型輸入。

表 5.4 不同輸入對信義商圈預測人流量誤差的結果

	前一天	前一至 二天	前一至 三天	前一至 四天	前一至 五天	前一至 六天	前一至 七天
MAE	426	430	412	405	409	424	417

訓練完 RBF-LSTM 模型後，取出 RBF 層的輸出再進行標準化，最終將標準化結果由大到小進行排序如圖 5.13 所示，可看到圖中在第七個特徵點出現轉折，依照手肘法的概念，取前七個特徵時間點作為後續的外掛模型輸入。




圖 5.13 信義商圈 RBF 輸出標準化排序結果




圖 5.14 信義商圈 RBF 特徵值與人流量關係圖

針對挑出來的其中一個特徵的數值與實際人流變化做比較，這裡挑選 T-6 關鍵字為微風廣場，圖 5.14 為 2018 年 2 月 2 日的人流資料與聲量資料，下午 1 點聲量資料出現高數值，晚上 7 點在信義商圈就出現大群人潮，可推測此特徵和人潮變化有關。

表 5.5 為信義商圈外掛模型輸入組合預測結果，從表中可知道最佳結果為 C_5^7 的模型，結合基礎模型後的誤差人數為 414 人，而 C_4^7 的模型績效為 405 人，與最佳結果差距 9 人，但其模型減少了訓練的參數量也減少 19% 的訓練時間，在考慮模擬的時間成本及運算成本後，本研究選用 C_4^7 的模型輸入作為信義商圈後續外掛模型的輸入特徵量。

表 5.5 信義商圈外掛模型輸入組合預測結果

	誤差人數	誤差改善幅度	訓練時間(s)	模型總參數量
base_model	582	X	205	226,833
base_model + C_1^7	476	18.2%	270	226,881
base_model + C_2^7	430	26.1%	298	227,034
base_model + C_3^7	421	27.7%	325	227,310
base_model + C_4^7	405	30.4%	349	227,899
base_model + C_5^7	414	28.9%	428	228,730

5.3.3 東區商圈

表 5.6 為不同輸入對東區商圈預測人流量誤差的結果，透過模擬後發現輸入前三天的輔助資料所預測出的誤差值能讓預測人流量的結果維持最好的績效，故後續將以前一至三天(T~T-71)作為模型輸入。

表 5.6 不同輸入對東區商圈預測人流量誤差的結果

	前一天	前一至 二天	前一至 三天	前一至 四天	前一至 五天	前一至 六天	前一至 七天
MAE	151	145	140	148	146	148	150




圖 5.15 東區商圈 RBF 輸出標準化排序結果




圖 5.16 東區商圈 RBF 特徵值與人流量關係圖

取出 RBF 層的輸出再進行標準化，最終將標準化結果由大到小進行排序如圖 5.15 所示，可看到圖中在第五個特徵點出現轉折，依照手肘法的概念，取前五個特徵時間點作為後續的外掛模型輸入。

這裡挑選 T-2 關鍵字為國父紀念館與實際人流變化做比較，圖 5.16 為 2018 年 4 月 29 日的人流資料與聲量資料，在下午 2 點時聲量資料出現高數值，下午 4 點在東區商圈就出現一些人潮，可推測此特徵和東區商圈的人流變化有關。

挑選出五個特徵時間點後，利用排列組合方式得到不同特徵點組合。表 5.7 為東區商圈外掛模型輸入組合預測結果，從表中可知道最佳結果為 C_3^5 的模型，模型績效為 156 人，因此選用 C_3^5 的模型輸入作為西門商圈後續外掛模型的輸入特徵量。

表 5.7 東區商圈外掛模型輸入組合預測結果

	模型人數	誤差改善幅度	訓練時間(s)	模型總參數量
base_model	222	X	210	226,833
base_model + C_1^5	182	18.0%	268	226,864
base_model + C_2^5	168	24.3%	283	226,937
base_model + C_3^5	156	29.7%	303	227,029
base_model + C_4^5	158	28.8%	342	227,465

5.3.4 南西商圈

表 5.8 為不同輸入對南西商圈預測人流量誤差的結果，透過模擬後發現輸入前三天的輔助資料所預測出的誤差值能讓預測人流量的結果維持最好的績效，故後續將以前一至三天(T~T-71)作為模型輸入。

表 5.8 不同輸入對南西商圈預測人流量誤差的結果

	前一天	前一至 二天	前一至 三天	前一至 四天	前一至 五天	前一至 六天	前一至 七天
MAE	199	186	167	170	172	169	170

訓練完 RBF-LSTM 模型後，取出 RBF 層的輸出再進行標準化，最終將標準化結果由大到小進行排序如圖 5.17 所示，可看到圖中在第六個特徵點出現轉折，依照手肘法的概念，取前六個特徵時間點作為後續的外掛模型輸入。




圖 5.17 南西商圈 RBF 輸出標準化排序結果




圖 5.18 南西商圈 RBF 特徵值與人流量關係圖

這裡選擇 T-4 關鍵字為台北地下街與實際人流變化做比較，圖 5.18 為 2018 年 8 月 18 日的人流資料與聲量資料，可以看到中午 12 點聲量資料突然衝高，下午 4

點的南西商圈人數隨之增加，由此我們可以推測此特徵和南西商圈的人流變化量有關。

挑選出六個特徵時間點後，利用排列組合方式得到不同特徵點組合。表 5.9 為南西商圈外掛模型輸入組合預測結果，從表中可知道最佳結果為 C_3^6 的模型，結合基礎模型後的誤差人數為 176 人，故選用 C_3^6 的模型輸入作為南西商圈後續外掛模型的輸入特徵量。

表 5.9 南西商圈外掛模型輸入組合預測結果

	模型人數	誤差改善幅度	訓練時間(s)	模型總參數量
base_model	247	X	205	226,833
base_model + C_1^6	189	23.5%	264	226,714
base_model + C_2^6	181	26.7%	281	226,886
base_model + C_3^6	176	28.7%	308	227,102
base_model + C_4^6	179	27.5%	337	227,368
base_model + C_5^6	178	27.9%	379	227,940

5.3.5 新板特區商圈

表 5.10 為不同輸入對新板特區商圈預測人流量誤差的結果，透過模擬後發現輸入前四天的輔助資料所預測出的誤差值能讓預測人流量的結果維持最好的績效，故後續將以前一至四天(T~T-95)作為模型輸入。

表 5.10 不同輸入對新板特區商圈預測人流量誤差的結果

	前一天	前一至 二天	前一至 三天	前一至 四天	前一至 五天	前一至 六天	前一至 七天
MAE	514	491	475	468	476	472	470

取出 RBF 層的輸出再進行標準化，最終將標準化結果由大到小進行排序如圖 5.19 所示，可看到圖中在第六個特徵點出現轉折，依照手肘法的概念，取前六個特徵時間點作為後續的外掛模型輸入。




圖 5.19 新板特區商圈 RBF 輸出標準化排序結果




圖 5.20 新板特區商圈 RBF 特徵值與人流量關係圖

這裡挑選 T-2 關鍵字為環球購物中心與實際人流變化做比較，圖 5.20 為 2018 年 10 月 13 日的人流資料與聲量資料，可以看到在早上 9 點出現搜尋熱潮，在早上 11 點就看到大批人潮出現在新版特區商圈，從這邊就可以推測此特徵和該商圈有關。

挑選出六個特徵時間點後，利用排列組合方式得到不同特徵點組合。表 5.11 為新板特區商圈外掛模型輸入組合預測結果，從表中可知道最佳結果為 C_5^6 的模型，結合基礎模型後的誤差人數為 487 人，而 C_4^6 的模型績效為 492 人，與最佳結果差距 5 人，模型減少了訓練的參數量也減少 11% 的訓練時間，在考慮模擬的時間及運算成本後，選擇 C_4^6 的模型輸入作為新板特區商圈後續外掛模型的輸入特徵量。

表 5.11 新板特區商圈外掛模型輸入組合預測結果

	模型人數	誤差改善幅度	訓練時間(s)	模型總參數量
base_model	687	X	205	226,833
base_model + C_1^6	548	20.2%	281	226,912
base_model + C_2^6	530	22.9%	306	227,285
base_model + C_3^6	511	25.6%	342	227,414
base_model + C_4^6	492	28.4%	378	227,969
base_model + C_5^6	487	29.1%	421	228,371

5.4 遷移外掛模型訓練速度與績效

透過前一階段挑選出的要放入的特徵值數量及組合後，此章節將挑選出的特徵時間點先取其中一種組合訓練出第一個外掛模型(AddNN_1)，接著以同架構的模型，遷移第一層的參數再訓練後面幾層模型，完成訓練所有的外掛模型。表 5.12 為各商圈訓練外掛是否使用遷移學習的訓練時間及預測結果，可看到使用遷移學習訓練出的模型，訓練時間平均減少 21.6%，且訓練出來的預測結果與從新訓練的模型績效差不多，由此可知本研究提出的遷移外掛模型可以減少模型訓練時間，且達到類似的訓練結果。

表 5.12 各商圈訓練外掛模型訓練時間及預測結果

模擬地區		模型訓練時間(s)	模型預測誤差(人)
西門商圈	無使用遷移學習	121	140
	使用遷移學習	89	145
信義商圈	無使用遷移學習	127	398
	使用遷移學習	96	407
東區商圈	無使用遷移學習	118	148
	使用遷移學習	92	160
南西商圈	無使用遷移學習	135	164
	使用遷移學習	102	181
新板特區商圈	無使用遷移學習	176	473
	使用遷移學習	153	492

5.5 整體模型預測績效

將前一階段所訓練出的所有外掛模型，以訓練出來誤差結果最低的前三名模型放入集成外掛模型，並將三個模型結果使用淺層類神經接起來輸出最後的預測誤差值，最終將基礎模型預測結果與集成外掛模型的誤差人流量結果相加即可獲得最終的預測結果，

各商圈的最終模型預測結果與其他模型比較如下表 5.13 至表 5.17 所示，從結果可發現在每個商圈的預測結果中將基礎模型結合 RBF-LSTM 模型的預測結果是最好的，訓練花費的時間也比基礎模型結合集成外掛模型來得少。

表 5.13 西門商圈集成模型結果與其他模型結果比較

	基礎模型	基礎模型+RBF 模型	基礎模型+集成外掛模型
模型誤差(人)	196	126	140
誤差改善幅度	X	35.7%	28.6%
訓練時間(秒)	205	407	584
模型總參數量	226,833	309,102	227,586

表 5.14 信義商圈集成模型結果與其他模型結果比較

	基礎模型	基礎模型+RBF 模型	基礎模型+集成外掛模型
模型誤差(人)	582	387	423
誤差改善幅度	X	33.5%	27.3%
訓練時間(秒)	205	387	423
模型總參數量	226,833	316,484	227,754

表 5.15 東區商圈集成模型結果與其他模型結果比較

	基礎模型	基礎模型+RBF 模型	基礎模型+集成外掛模型
模型誤差(人)	222	140	160
誤差改善幅度	X	36.9%	27.9%
訓練時間(秒)	205	389	536
模型總參數量	226,833	309,460	227,679

表 5.16 南西商圈集成模型結果與其他模型結果比較

	基礎模型	基礎模型+RBF 模型	基礎模型+集成外掛模型
模型誤差(人)	196	126	140
誤差改善幅度	X	35.7%	28.6%
訓練時間(秒)	205	407	584
模型總參數量	226,833	309,102	227,586

表 5.17 新板特區商圈集成模型結果與其他模型結果比較

	基礎模型	基礎模型+RBF 模型	基礎模型+集成外掛模型
模型誤差(人)	687	468	503
誤差改善幅度	X	31.9%	26.8%
訓練時間(秒)	205	436	551
模型總參數量	226,833	315,256	227,697

5.6 預測強健性績效評估

使用集成模型的關鍵點在於避免當數值出現錯誤值，也可以讓預測結果不能差距太多，因此本研究將 RBF-LSTM 模型與集成外掛模型各對其中一至兩個特徵產生錯誤值，為避免錯誤值太多失去預測的意義，本研究認為商圈會在週末(禮拜六、日)的數值產生較劇烈的變化，故選擇在這兩天的資料產生錯誤值，其預測結果如下圖 5.21 至圖 5.25 所示。從每個商圈的比較可看出，當出現錯誤值時使用集成外掛模型預測出的數值比使用 RBF 模型預測出來的結果產生較低的誤差，其原因可能有兩個，(1)RBF 模型因為還有包含 LSTM 模型訓練，訓練時容易因為時序資料影響，導致時間越後面的資料因前面資料預測不準確而產生更大的誤差，(2)集成外掛模型因為有多個模型共同訓練，當其中一個模型的輸入發生錯誤時，其他模型的輸出可以將該模型產生的誤差降低，避免因單一模型的預測失誤導致誤差過大，也驗證了本研究使用集成外掛模型使預測結果具有強健性。




圖 5.21 西門商圈強健性比較圖




圖 5.22 信義商圈強健性比較圖




圖 5.23 東區商圈強健性比較圖




圖 5.24 南西商圈強健性比較圖




圖 5.25 新板特區商圈強健性比較圖

第六章 結論與未來研究建議

人流預測對於現在生活來講是密不可分的事情，尤其對於店家在做商業決策時，若能精準掌握該地區人流量的變化，就可以節省許多事前的備貨時間與減少時效性商品未販售所損失的成本。綜觀過往都市人流預測之研究，有兩大困難點需要克服，(1)模型訓練時間成本過長，以及(2)預測需具有強健性。因此本研究針對上述之兩大困難點提出五大概念，(1)以 CNN-LSTM 基礎模型訓練人流量，(2)使用 Grad-CAM 解釋最後一層 CNN 的梯度資訊，並以熱區圖呈現影響預測的關鍵空間因子(3)使用 RBF-LSTM 模型訓練並拆解關鍵時間特徵，(4)使用遷移學習的方法訓練多個預測誤差之外掛模型解決訓練時間成本過長的問題，(5)使用集成學習整合多個外掛模型預測結果解決預測結果需具有強健性的問題。在實驗模擬中，本研究經過一連串的實驗預測人流量，並使用 Grad-CAM 觀察出影響預測人流量的空間特徵因子，再透過訓練及拆解 RBF-LSTM 模型確實能找出網路聲量中影響人流誤差的關鍵因子，使用手肘法將影響力較大的關鍵因子挑出後，利用遷移學習的技術訓練多個預測人流誤差量的外掛模型，以及使用集成學習來統合多個外掛模型的預測結果。從上述實驗中我們得到以下兩個結論，(1)使用輔助資料與 RBF-LSTM 模型確實可以減少人流預測的誤差，但容易因單個模型輸入錯誤值而導致模型預測結果不準。(2)使用集成外掛模型預測雖無法達到 RBF-LSTM 模型同等的預測績效，但在資料發生錯誤時，可以減少因錯誤值而產生的誤差。

針對未來研究，我們提出兩點延伸探討與建議，(1)目前所使用的人流資料單一網格範圍太大，對於提供給商家來做使用的成效有限，未來若有機會可以拿到單一範圍更小的人流資料產生的結果可以提供更多價值。(2)未來可加入不同社群平台(如 Facebook、Instagram)所發布的貼文或打卡定位等影響人流量預測的資料，探討這些資料對人流量變化的影響。

參考文獻

- [1] Ban, T., Zhang, R., Pang, S., Sarrafzadeh, A., & Inoue, D. (2013, November). Referential knn regression for financial time series forecasting. In *International Conference on Neural Information Processing* (pp. 601-608). Springer, Berlin, Heidelberg.
- [2] Binson, V. A., Subramoniam, M., & Mathew, L. (2021). Detection of COPD and Lung Cancer with electronic nose using ensemble learning methods. *Clinica Chimica Acta*, 523, 231-238.
- [3] Bogaerts, T., Masegosa, A. D., Angarita-Zapata, J. S., Onieva, E., & Hellinckx, P. (2020). A graph CNN-LSTM neural network for short and long-term traffic forecasting based on trajectory data. *Transportation Research Part C: Emerging Technologies*, 112, 62-77.
- [4] Chen, E., Ye, Z., Wang, C., & Xu, M. (2019). Subway passenger flow prediction for special events using smart card data. *IEEE Transactions on Intelligent Transportation Systems*, 21(3), 1109-1120.
- [5] Cheng, S., Lu, F., Peng, P., & Wu, S. (2018). Short-term traffic forecasting: an adaptive ST-KNN model that considers spatial heterogeneity. *Computers, Environment and Urban Systems*, 71, 186-198.
- [6] Clark, S. (2003). Traffic prediction using multivariate nonparametric regression. *Journal of transportation engineering*, 129(2), 161-168.
- [7] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20(3), 273-297.
- [8] Dietterich, T. G. (2002). Ensemble learning. *The handbook of brain theory and neural networks*, 2(1), 110-125.

- [9] Dong, X., Yu, Z., Cao, W., Shi, Y., & Ma, Q. (2020). A survey on ensemble learning. *Frontiers of Computer Science*, 14(2), 241-258.
- [10] Fu, R., Zhang, Z., & Li, L. (2016, November). Using LSTM and GRU neural network methods for traffic flow prediction. In *2016 31st Youth Academic Annual Conference of Chinese Association of Automation (YAC)* (pp. 324-328). IEEE.
- [11] Gers, F. A., Schraudolph, N. N., & Schmidhuber, J. (2002). Learning precise timing with LSTM recurrent networks. *Journal of machine learning research*, 3(Aug), 115-143.
- [12] Greff, K., Srivastava, R. K., Koutník, J., Steunebrink, B. R., & Schmidhuber, J. (2016). LSTM: A search space odyssey. *IEEE transactions on neural networks and learning systems*, 28(10), 2222-2232.
- [13] Hao, P. Y. (2009). Interval regression analysis using support vector networks. *Fuzzy sets and systems*, 160(17), 2466-2485.
- [14] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8), 1735-1780.
- [15] Hong, W. C., Dong, Y., Zheng, F., & Lai, C. Y. (2011). Forecasting urban traffic flow by SVR with continuous ACO. *Applied Mathematical Modelling*, 35(3), 1282-1291.
- [16] Hong, W. C., Dong, Y., Zheng, F., & Wei, S. Y. (2011). Hybrid evolutionary algorithms in a SVR traffic flow forecasting model. *Applied Mathematics and Computation*, 217(15), 6733-6747.
- [17] Kalpakis, K., Gada, D., & Puttagunta, V. (2001, November). Distance measures for effective clustering of ARIMA time-series. In *Proceedings 2001 IEEE international conference on data mining* (pp. 273-280). IEEE.
- [18] Kinney Jr, W. R. (1978). ARIMA and regression in analytical review: An empirical test. *Accounting Review*, 48-60.

- [19] Ko, C. N., & Lee, C. M. (2013). Short-term load forecasting using SVR (support vector regression)-based radial basis function neural network with dual extended Kalman filter. *Energy*, 49, 413-422.
- [20] Kumar, S. V., & Vanajakshi, L. (2015). Short-term traffic flow prediction using seasonal ARIMA model with limited input data. *European Transport Research Review*, 7(3), 1-9.
- [21] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324.
- [22] Li, J., Boonaert, J., Doniec, A., & Lozenguez, G. (2021). Multi-models machine learning methods for traffic flow estimation from Floating Car Data. *Transportation Research Part C: Emerging Technologies*, 132, 103389.
- [23] Li, M. W., Hong, W. C., & Kang, H. G. (2013). Urban traffic flow forecasting using Gauss-SVR with cat mapping, cloud model and PSO hybrid algorithm. *Neurocomputing*, 99, 230-240.
- [24] Li, Y., & Cao, H. (2018). Prediction for tourism flow based on LSTM neural network. *Procedia Computer Science*, 129, 277-283.
- [25] Liu, L., Zhen, J., Li, G., Zhan, G., He, Z., Du, B., & Lin, L. (2020). Dynamic Spatial-Temporal Representation Learning for Traffic Flow Prediction. *IEEE Transactions on Intelligent Transportation Systems*.
- [26] Lv, Y., Duan, Y., Kang, W., Li, Z., & Wang, F. Y. (2014). Traffic flow prediction with big data: a deep learning approach. *IEEE Transactions on Intelligent Transportation Systems*, 16(2), 865-873.
- [27] Martínez, F., Frías, M. P., Pérez-Godoy, M. D., & Rivera, A. J. (2018). Dealing with seasonality by narrowing the training set in time series forecasting with kNN. *Expert systems with applications*, 103, 38-48.

- [28] Menegola, A., Fornaciali, M., Pires, R., Bittencourt, F. V., Avila, S., & Valle, E. (2017, April). Knowledge transfer for melanoma screening with deep learning. In *2017 IEEE 14th International Symposium on Biomedical Imaging (ISBI 2017)* (pp. 297-300). IEEE.
- [29] Narmadha, S., & Vijayakumar, V. (2021). Spatio-Temporal vehicle traffic flow prediction using multivariate CNN and LSTM model. *Materials Today: Proceedings*.
- [30] Polikar, R. (2012). Ensemble learning. In *Ensemble machine learning* (pp. 1-34). Springer, Boston, MA.
- [31] Sang, D. V., Cuong, D. M., & Cuong, L. T. B. (2018, December). An Effective Ensemble Deep Learning Framework for Malware Detection. In *Proceedings of the Ninth International Symposium on Information and Communication Technology* (pp. 192-199).
- [32] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE international conference on computer vision* (pp. 618-626).
- [33] Sherstinsky, A. (2020). Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network. *Physica D: Nonlinear Phenomena*, 404, 132306.
- [34] Siami-Namini, S., Tavakoli, N., & Namin, A. S. (2018, December). A comparison of ARIMA and LSTM in forecasting time series. In *2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA)* (pp. 1394-1401). IEEE.
- [35] Su, H., Zhang, L., & Yu, S. (2007, August). Short-term traffic flow prediction based on incremental support vector regression. In *Third International Conference on Natural Computation (ICNC 2007)* (Vol. 1, pp. 640-645). IEEE.

- [36] Sundermeyer, M., Schlüter, R., & Ney, H. (2012). LSTM neural networks for language modeling. In *Thirteenth annual conference of the international speech communication association*.
- [37] Van Der Voort, M., Dougherty, M., & Watson, S. (1996). Combining Kohonen maps with ARIMA time series models to forecast traffic flow. *Transportation Research Part C: Emerging Technologies*, 4(5), 307-318.
- [38] Wang, X., An, K., Tang, L., & Chen, X. (2015). Short term prediction of freeway exiting volume based on SVM and KNN. *International Journal of Transportation Science and Technology*, 4(3), 337-352.
- [39] Xia, D., Wang, B., Li, H., Li, Y., & Zhang, Z. (2016). A distributed spatial-temporal weighted model on MapReduce for short-term traffic flow forecasting. *Neurocomputing*, 179, 246-263.
- [40] Xingjian, S. H. I., Chen, Z., Wang, H., Yeung, D. Y., Wong, W. K., & Woo, W. C. (2015). Convolutional LSTM network: A machine learning approach for precipitation nowcasting. In *Advances in neural information processing systems* (pp. 802-810).
- [41] Yang, X., Zhang, Y., Lv, W., & Wang, D. (2021). Image recognition of wind turbine blade damage based on a deep learning model with transfer learning and an ensemble learning classifier. *Renewable Energy*, 163, 386-397.
- [42] Yu, B., Wu, S. H., Wang, M. H., & Zhao, Z. H. (2012). K-nearest neighbor model of short-term traffic flow forecast. *Jiaotong Yunshu Gongcheng Xuebao*, 12(2), 105-111.
- [43] Yuan, Y., Zhang, Z., Yang, X. T., & Zhe, S. (2021). Macroscopic traffic flow modeling with physics regularized Gaussian process: A new insight into machine learning applications in transportation. *Transportation Research Part B*:

Methodological, 146, 88-110.

- [44] Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159-175.
- [45] Zhang, J., Zheng, Y., Qi, D., Li, R., & Yi, X. (2016, October). DNN-based prediction model for spatio-temporal data. In *Proceedings of the 24th ACM SIGSPATIAL international conference on advances in geographic information systems* (pp. 1-4).
- [46] Zhang, J., Zheng, Y., Qi, D., Li, R., Yi, X., & Li, T. (2018). Predicting citywide crowd flows using deep spatio-temporal residual networks. *Artificial Intelligence*, 259, 147-166.
- [47] Zhang, M. L., & Zhou, Z. H. (2007). ML-KNN: A lazy learning approach to multi-label learning. *Pattern recognition*, 40(7), 2038-2048.
- [48] Zhang, N., Zhang, Y., & Lu, H. (2011). Seasonal autoregressive integrated moving average and support vector machine models: prediction of short-term traffic flow on freeways. *Transportation Research Record*, 2215(1), 85-92.
- [49] Zoetmulder, R., Gavves, E., Caan, M., & Marquering, H. (2021). Domain and Task Specific Transfer Learning For Medical Segmentation Tasks. *Computer Methods and Programs in Biomedicine*, 106539.
- [50] Zou, Z., Gao, P., & Yao, C. (2018, June). City-Level Traffic Flow Prediction via LSTM Networks. In *Proceedings of the 2nd International Conference on Advances in Image Processing* (pp. 149-153).