

國立雲林科技大學工業工程與管理系

碩士論文

Department of Industrial Engineering and Management

National Yunlin University of Science & Technology

Master Thesis

基於 R-tree 與 SPACE-MDL-LSTM 提升大區域人流預
測之效率

Improve the Predicted Efficiency of Crowd Flow
in Large Areas Based on the
R-tree and the SPACE-MDL-LSTM

鄭力誠

Li-Cheng Zheng

指導教授：陳奕中 博士

Advisor: Yi-Chung Chen, Ph.D.

中華民國 110 年 6 月

June 2021

摘要


全城市的人流預測議題近年越來越受學者們重視，因為全城市的人流預測可以為政府提前對人流的變化做出各項反應，進而提升城市的服務品質。綜觀過往全城市人流預測之研究，大多為兩種方式執行，(1)過往對於大區域之人流預測時，因大區域中包含太多種不同的區域類型，若只使用單一模型預測會因區域間太多不同影響之因素導致模型預測準確度不高，甚至模型無法進行有效地預測。(2)將預測模型從大區域細分成小區域，再以小區域各自建立，目的使整體模型準確度較高，但也因各個模型內含大量參數導致整體大區域模型體積龐大造成運行時間長，造成現實中整體上線預測非常困難。因此針對過往人流大範圍預測之研究對於小區域建模成本過高之缺點，本研究提出以資料結構 R-tree 之概念建立適用於人流預測之深度學習模型，此模型稱為 Space-MDL-LSTM。Space-MDL-LSTM 包含基礎模型 LSTM、基於 MDL 理論之外掛模組，透過外掛模組減少基礎模型的數量，使其實際上線預測時能提升效率。最終本研究使用台灣臺北市、新北市、桃園市、基隆市等地區的真实人流數據資料進行驗證本研究提出之方法的效率及有效性，在預測精準度與建立時間雖與過去方法相比較差約 30%，但也因基礎模型與節點數量的降低，更新花費時間不論是日、週、月的更新頻率皆優於過去方法將近 90%，也透過質化分析節點內的網格屬性具有高度相似，網格屬性相似就可代表人流趨勢相似，驗證了使用同個基礎模型與外掛模組的合理性。

關鍵字：人流預測、全城市、R-tree、LSTM、MDL、外掛模組

Abstract

City-wide crowd prediction is crucial to the formulation of effective responses to changes in crowd flow. Existing crowd prediction models are prone to inaccuracy when dealing with complex situations involving commercial areas, residential areas, and traffic hotspots. Other schemes that divide the study area into sectors tend to be cumbersome (due to a large number of parameters) and prone to excessive run times. In the current study, we developed a deep learning model based on the R-tree data structure to facilitate crowd flow prediction in large areas. This proposed Space-MDL-LSTM system uses an LSTM module with gride-based plug-in modules to create an indexing structure aimed at accelerating search functions for online prediction. Real-world flow data was used to verify the efficiency and effectiveness of the proposed method.

Keywords: Crowd Flow Forecasting, Citywide, R-tree, LSTM, MDL, Plug-in Module



誌謝

本論文得以順利完成，首先感謝指導教授陳奕中老師、國家災害防救科技中心災防資訊組組長張子瑩與博士後研究員尚榮康在研究方向與專業知識的指導與建議，使本論文更加完整及嚴謹。再來感謝雲科大工商暨交通數據實驗室博士後研究員王富正、博士班志豪、東錡、映均學長姊在論文撰寫過程中給予寫作上的建議與鼓勵。

再來感謝我的家人給我一路上的支持，讓我能無後顧之憂地完成碩士學業，也感謝我學士與碩士期間的好夥伴詠緹，不管在專案上或是課堂上給我最強大的支援與支持，給予我持續進步的動力。

最後謹以此向所有幫助、關心我的人致上最大的謝意。



目錄

摘要	i
Abstract.....	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
第一章 緒論	1
1.1 研究動機與目的	1
1.2 研究範圍與流程	5
第二章 文獻回顧	8
2.1 時間序列預測方法	8
2.1.1 統計模型	8
2.1.2 機器學習	9
2.1.3 淺層類神經網路	9
2.1.4 深度學習	10
2.2 資料索引管理方法	11
2.2.1 R-tree	11
2.2.2 M-tree	12
2.2.3 G-tree	13
第三章 研究方法	15
3.1 計算各網格全年標準差	15
3.2 利用 R-tree 索引架構建立 Space-MDL-LSTM	16
3.2.1 建立基礎模型與外掛模組	18
3.2.2 節點分割演算法	20
3.3 方法之績效評估	21
第四章 實驗模擬	22
4.1 資料集介紹	22
4.2 Space-MDL-LSTM 之參數設定	24
4.3 實驗結果分析	26
第五章 結論與未來研究	37

參考文獻	38
------------	----



表目錄

表 1 2019 年行動數據人流資料集	24
表 2 各網格全年標準差表	24
表 3 不同節點最大容量績效比較表	26
表 4 不同標準閥值績效比較表	26
表 5 Space-MDL-LSTM 與個別建立績效比較表	28
表 6 Space-MDL-LSTM 網格節點對照表	29



圖目錄

圖 1 人流資料示意圖	2
圖 2 2019 年 12 月 25 日 20 時雙北地區人流分布圖	2
圖 3 2019 年 1 月 1 日 00 時雙北地區人流分布圖	2
圖 4 同群建立基礎模型	5
圖 5 基礎模型結合外掛模組	5
圖 6 研究流程圖	7
圖 7 淺層類神經網路示意圖	9
圖 8 遞迴類神經網路示意圖	10
圖 9 R-tree 結果示意圖	11
圖 10 R-tree 索引架構示意圖	12
圖 11 M-tree 結果示意圖	13
圖 12 M-tree 索引架構示意圖	13
圖 13 G-tree 結果示意圖	14
圖 14 G-tree 索引架構示意圖	14
圖 15 研究方法架構圖	15
圖 16 R-tree 索引架構建立 Space-MDL-LSTM 流程圖	17
圖 17 基礎模型與外掛模組架構	20
圖 18 人流資料集範圍	23
圖 19 臺北車站網格之人流序列圖	23
圖 20 華中橋堤外網格之人流序列圖	23
圖 21 三種方法誤差比較直方與累加機率圖	28
圖 22 Space-MDL-LSTM 結果示意圖	29
圖 23 Space-MDL-LSTM 各節點網格數量統計圖	30

圖 24 Space-MDL-LSTM 節點編號 1 示意圖	30
圖 25 Space-MDL-LSTM 節點編號 1 投點示意圖	31
圖 26 節點編號 1 內網格時間序列	31
圖 27 Space-MDL-LSTM 節點編號 2 示意圖	32
圖 28 Space-MDL-LSTM 節點編號 2 投點示意圖	33
圖 29 節點編號 2 內各節點內網格時間序列	33
圖 30 Space-MDL-LSTM 節點編號 3 示意圖	34
圖 31 Space-MDL-LSTM 節點編號 3 投點示意圖	34
圖 32 節點編號 3 內網格時間序列	35
圖 33 Space-MDL-LSTM 節點編號 16 投點示意圖	35
圖 34 節點編號 16 內網格時間序列	36



第一章 緒論

1.1 研究動機與目的

近年來，人流資料的預測日趨重要，因為若能透過預測人流資料，能得知在未來每天不同時刻所在的真實位置，經統計後就得知各地點之人群數量，如圖 1 所示。對於城市的商業決策、交通管理、公共安全，甚至是傳染病的防治等許多方面都有著極大的幫助，舉例說明，在交通管理方面，若交通管理單位透過預測城市中交通熱點的人流資料提前得知未來某時間點的潛在乘客數是否超過負荷，若超過則可提前加開班次或規劃接駁車等策略紓解大量乘客之問題[4][12][17][24]，甚至於能提前安排相關人員之人力配置，如圖 2 所示，可發現雙北市在 2019 年 12 月 25 日 20 時在紅圈處有大量人流之情況，因當時時間點在板橋市政府廣場有耶誕城的活動，因此對於交通管理單位、公車業者應對於板橋市政府附近交通進行管制或增加捷運與公車班次。在傳染病防治方面，在像是新型冠狀病毒此類會透過民眾口沫傳染的傳染病之高峰期，若能提前預測出哪些地點的人流狀況會使民眾大量聚集至使防疫出現漏洞[29]。如圖 3 所示，可發現雙北地區在 2019 年 1 月 1 日 00 時在紅圈處有人群大量聚集的現象，即可供相關單位先提前進行防疫上的防護措施，如人數上的管制、強制戴口罩等。在商業決策方面，對於連鎖企業在規劃展店時，若能提前得知各展店候選點之服務範圍內實際潛在的客群數，則可選擇最高效益之位置進行展店，甚至能提前安排各家分店之商品的進貨量[3]。透過上述例子可明顯得知，人流資料的預測對於許多的領域可創造出的價值十分可觀。



圖 1 人流資料示意圖




圖 2 2019 年 12 月 25 日 20 時雙北地區人流分布圖




圖 3 2019 年 1 月 1 日 00 時雙北地區人流分布圖

過往人流預測的方法大致可分為統計模型、機器學習、深度學習等方法進行預測，在統計模型中，Williams 等人[32]於 1998 年利用季節性自迴歸綜合移動平均模型與指數平滑模型於預測城市高速公路交通流量，Zhang 等人[35]於 2011 年利用季節性自迴歸綜合移動平均模型於預測短期高速公路上的交通流量，Hoang 等人[10]於 2016 年將人流分為季節、趨勢及殘差後透過高斯馬可夫隨機模型預測城市中的交通流量。在機器學習方法中，Su 等人[25]於 2007 年利用增量支持向量迴歸模型(ISVR)預測短期交通流量，Lippi 等人[15]於 2013 年透過結合季節性自迴歸綜合移動平均模型與 Kalman 濾波器建立支持向量迴歸模型用於預測短期的交通流量，Chan 等人[5]於 2012 年利用貝葉斯迴歸模型預測人群流量。在深度學習方法中，Zhang 等人[34]於 2016 年建立 DeepST 模型，其中使用卷積層獲取人流資料之時間週期與季節趨勢用於預測人群流量，Zhang 等人[33]於 2018 年使用時空結合的 ST-ResNet 模型用於預測城市各區域的人群流量，Tian 等人[28]於 2018 年使用長短期記憶類神經網路用於填補交通流量缺失值並預測。

透過上述研究可得知，預測人流相關研究中，深度學習模型與傳統統計模型與機器學習模型相比預測準確度較高，於是現今許多研究透過深度學習模型預測人群流量，使預測能更符合實際狀況。然而，本研究發現雖然深度學習模型預測準確度高，但是在現實應用中實用性並不高，以下分為兩部分說明。(1)在針對大區域之人流預測時，因大區域中包含太多種不同的區域類型，如商業區、住宅區、交通熱點等，若只使用單一模型預測會因區域間太多不同影響之因素導致模型預測準確度不高，甚至模型無法進行有效地預測。(2)預測模型將大區域細分成小區域，再以小區域各自建立，目的使整體模型準確度較高，但也因各個模型內含大量參數導致整體大區域模型體積龐大造成運行時間長，造成現實中整體上線預測非常困難。舉例說明，假設臺北市共有 1000 個區域需要預測，若只以臺北市整個大區域建立模型，則會因臺北市包含太多種不同的區域，如商圈、學區、交通熱點等類型進而使模型預測準確度不高，甚至模型無法進行有效地預測，但若針對 1000 個區域各自

分別建立模型，則一共需要建立 1000 個深度學習模型，造成整體模型儲存空間龐大、訓練時間過長、預測效率不理想等因素等，整體建模成本相當高。若防疫相關單位需要實際應用 1000 個模型預測未來下一小時之人流做人群大量聚集的預警，一旦這 1000 個區域的模型使整體預測時間超過一小時，則無法及時得知最新人流情況，對於相關管理單位做決策的幫助也就有限，所以一些新的方法應該被提出用以改善上述缺點。

綜合上述過往人流預測研究之問題，本研究提出三大概念，(1)針對過往研究對於小區域建模成本過高之缺點，本研究提出基於時間與空間特徵進行分群，使同一群之區域中的網格以一基礎模型進行預測，減少大量建模成本。如圖 4 所示，針對紅色網格群建立基礎模型 BasicModel_A、黃色網格群建立基礎模型 BasicModel_B，後續依此類推。(2)因本研究會以一群多網格的方式建立模型，於是針對過往研究對於大區域預測只使用單一基礎模型預測太多不相似網格會有不準確之缺點，本研究提出基於 MDL 理論以外掛模組的方式補償各小區域與基礎模型之間的差異，使不建立額外龐大的基礎模型前提下，使預測精準度提高。如圖 5 所示，針對紅色網格群中上方的深藍色區域以基礎模型 BasicModel_A 建立外掛模組 Plusmodel_A1、紅色網格群中下方的深藍色區域以基礎模型 BasicModel_A 建立外掛模組 Plusmodel_A2、黃色網格群中的深藍色區域以基礎模型 BasicModel_B 建立外掛模組 Plusmodel_B1，後續依此類推，若網格與訓練基礎模型網格類似，則不需要額外建立外掛模組，直接使用基礎模型預測即可。上述兩大概念所建立之模型能以各群之基礎模型結合各區域之外掛模組的方式提升模型預測準確度，解決透過大區域建立模型造成精準度不佳的問題。(3)上述概念會建立多個基礎模型與外掛模組必須要管理使其能夠快速找尋合適之基礎模型與外掛模組。因此本研究提出以資料結構 R-tree 的概念建立適用於人流預測之深度學習模型，此模型稱為 Space-MDL-LSTM，Space-MDL-LSTM 包含基礎模型、外掛模組，並且對於基礎模型與外掛模組之結果建立索引架構，透過減少基礎模型數量，使其實際上線預測時

能提升效率，而本研究也會以基礎模型數量與模型建立、更新時間定義為方法的建模成本，其中更新時間包含不同頻率如日、週、月。




圖 4 同群建立基礎模型




圖 5 基礎模型結合外掛模組

1.2 研究範圍與流程

本研究針對臺北市、新北市、基隆市、桃園區與宜蘭縣之人群流量預測進行探討，使用了電信業者提供之行動數據資料進行模擬驗證，其資料內容為 2019 年 01 月 01 日 00:00:00 至 2019 年 12 月 31 日 23:00:00 每小時之人流資料，因涉及保密協定，資料集部分僅公開部份資訊。本研究之流程如圖 6 所示，各階段說明如下：

1. 確認研究問題

根據過往人流預測之研究議題，針對各研究所提出預測方法之缺點，提出一種能應用於大區域人群流量的預測方法。並透過外掛模組與索引架構的設計，使其能有效地建立及索引所需之基礎模型與外掛模組預測。

2. 相關文獻回顧

對於人群流量預測之相關研究進行方法回顧，並針對不同預測模型研究進行介紹，如整合移動平均自迴歸模型、遞迴式類神經網路、長短期記憶類神經網路。

3. 資料收集與整理

電信業者所提供之北北基桃宜地區的行動數據人流資料，資料範圍為 2019 年 01 月 01 日 0 時至 2019 年 12 月 31 日 23 時，以每小時為一單位的人群流量資料。

4. 觀察資料

對於資料進行視覺化，為瞭解各時間點人流分佈狀況，並依分佈狀況對於資料做後續處理。對於本研究而言，視覺化觀察資料後便能得知各區域各時段民眾的人流狀況。

5. 結合資料結構索引開發預測模型與外掛模組

建構一個結合空間與時間的模型以預測人群流量，以資料結構建立基礎模型與建立外掛模組。

6. 模擬測試

將實際資料輸入至本研究開發之人群流量預測模型中進行預測，並透過模擬驗證之推估模型準確度及效率進行參數之調整與修正。

7. 結論

根據模擬測試後的模型之預測結果驗證本研究開發之預測模型、外掛模組及索引架構是否降低建模成本及預測是否準確，並依照研究結果提出結論與未來相關研究建議。




圖 6 研究流程圖

第二章 文獻回顧

本章節將介紹人流預測相關研究及資料索引管理之熱門方法，人流預測絕大多數皆屬於複雜的時間序列問題，於是文獻回顧的部分會於 2.1 節介紹過往專門處理時間序列預測問題的模型，熱門方法包含統計模型、淺層類神經網路、機器學習及深度學習模型，如整合移動平均自迴歸模型、遞迴類神經網路、長短期記憶類神經網路等多種方法。本研究將藉由過去資料索引管理之方法概念，將人流預測模型能以其概念建立，減少大量之建模成本。於 2.2 節介紹過往應用於時間、空間資料索引管理之熱門方法 R-tree、M-tree 及 G-tree。

2.1 時間序列預測方法

2.1.1 統計模型

整合移動平均自迴歸模型(Autoregressive Integrated Moving Average model, ARIMA)是常見的時間序列預測統計模型之一，最常應用在非平穩的時間序列上，主要是因為 ARIMA 不僅結合自迴歸模型及移動平均模型，在進行差分將時間序列平穩化，ARIMA 包含了三個重要的參數 p, d, q ，其中 p 為自迴歸項，模型會根據過去的 p 的歷史數值之迴歸作為當前時間點數值、 d 為時間序列平穩化的差分次數，以時間點 t 的數值減去時間點 $t-1$ 的數值，即稱為 1 階差分，以此類推， q 為移動平均項數，模型會根據過去的 q 項時間點數值平均誤差來預測當前時間點數值。Van 等人[30]於 1996 年使用 ARIMA 與初始分類器混合的方法預測短期流量。Williams 等人[32]於 1998 年預測城市高速公路單個區間之交通流量。Zhang 等人[35]於 2011 年應用 ARIMA 與季節性結合的 SARIMA 來預測高速公路上短期的交通流量。Chen 等人[6]於 2019 年使用 ARIMA 與四種不同的廣義自迴歸條件異方差模型等混和模型進行預測特殊事件期間的短期交通客流量。Jamil 等人[12]於 2017 年使用 ARIMA 模型預測計程車之乘客熱點區域。

2.1.2 機器學習

機器學習方法從輸入資料中學習到資料中的特性，並透過這些特性對預測未來資料，其原理由大量之統計理論綜合而成，能以模型本身之預測經驗改進內部參數，使預測結果能更加符合輸入資料，在許多流量預測之研究以機器學習模型預測也驗證方法之有效性。Su 等人[25]於 2007 年利用增量支持向量迴歸模型(ISVR)預測短期交通流量，Lippi 等人[15]於 2013 年透過結合季節性自迴歸綜合移動平均模型與 Kalman 濾波器建立支持向量迴歸模型用於預測短期的交通流量，Chan 等人[5]於 2012 年利用貝葉斯迴歸模型預測人群流量。Sun 等人[27]於 2015 年應用小波分析於 SVM 模型預測 SVM 北京地鐵之短期客流量預測。

2.1.3 淺層類神經網路

近年來類神經網路(Neural Network, NN)已被廣泛且成功的用於時間序列的預測，類神經網路主要概念是透過神經元彼此間的連接及傳遞訊息，主要透過輸入值後，經由激活函數的運算後將值輸出，神經網路可分為輸入層、隱藏層及輸出層，如圖 7 所示。只需將合適的輸入與輸出給予模型，模型就能不斷透過輸入資料的訓練學習，以調整輸入層、隱藏層及輸出層內的各個參數，便能達成預測的目標。Panigrahi 等人[19]於 2017 年使用非線性指數平滑技術開發 ANN 模型預測時間序列流量數據。




圖 7 淺層類神經網路示意圖

而為了提升類神經網路於時間序列問題的預測能力，就有學者將基礎的類神

經網路改良，提出具有考量到過去資料的類神經網路，稱為遞迴類神經網路 (Recurrent neural network, RNN)。RNN 相較於基礎類神經網路多了在自身的網路中循環傳遞，使其可以描述短時間的動態行為，如圖 8。Zhene 等人[36]於 2018 年使用 RNN 結合 CNN 應用於城市中的交通客流預測。Hu 等人[11]於 2020 年使用 RNN 進行快速公共交通運輸系統人群擁擠情況的預測。




圖 8 遞迴類神經網路示意圖

2.1.4 深度學習

長短期記憶類神經網路(Long Short-Term Memory, LSTM)是近來熱門用於人群流量預測的深度學習模型，由 Gers 等人[8]於 2000 年所提出，模型架構主要根據 RNN 改良，LSTM 相較於 RNN 多了記憶性，改善了 RNN 在長期記憶上的缺點。其主要概念為控制輸入閘、遺忘閘、輸出閘來決定輸入是否影響記憶或記憶是否影響輸出，過去研究多數用來處理複雜的時間序列資料。例如 Zou 等人[38]於 2018 年應用 LSTM 於城市等級的交通流量預測。Li 等人[14]於 2018 年運用 LSTM 於預測旅遊流量，其最終結果顯示 LSTM 優於 ARIMA。Liu 等人[18]於 2018 年使用 LSTM 預測廣州地鐵交通客流量預測。鄭宇哲[39]於 2020 年透過餘弦相似度計算網格間的相關性，透過 DBSCAN 空間分群演算法將網格分群後建立 LSTM 模型，並且再透過外掛模組補償的方式補償基礎模型預測各區域間的不足。

近年來也有許多混合深度學習模型之研究進行人群流量預測，透過結合模型間不同特性，同時考慮時空特徵，例如，Jin 等人[13]於 2018 年結合了卷積類神經網路(CNN)和長短期記憶類神經網路(LSTM)的網路架構，以同時獲取時空特徵預

測城市中的交通流量。Liu 等人[16]於 2020 年提出了結合卷積類神經網絡和長短期記憶類神經網絡的模型 SPN，用於學習時空中的重要特徵，其準確度也較之前的方法優異。Sun 等人[26]於 2020 年使用時空卷積網路預測不規則區域的全城市市人群流量。Zhou 等人[37]於 2019 年使用 ST-Unet 進行大型級別站點之人群流量預測，透過集成來自鄰近站點的人群流量特徵分群來學習站點間的空間依賴性，透過對人群流動的時間特徵，將時間段和趨勢進行建模來學習時間依賴性。

2.2 資料索引管理方法

2.2.1 R-tree

R-tree 是常見被使用於空間資料儲存的樹狀資料結構，概念由 Guttman 於 1984 年提出[9]，主要是將具有相同相似特徵之資料放在同一節點之中，為求每個節點裡資料彼此相似加快搜尋速度，節點期望最小面積，故節點稱為 MBR(Minimum bounding rectangle)，示意圖如圖 9 所示。圖 9 中每個藍色點代表一筆資料，而每個矩形都代表一個節點。架構圖如圖 10 所示，每個節點都是資料點的結合，越往上層結合的節點就越多，所以當使用 R-tree 索引架構搜尋資料點時，只需要搜尋與節點有關的資料點即可，不必將所有節點搜尋過一次即可獲得答案，效率也就會明顯提升。




圖 9 R-tree 結果示意圖




圖 10 R-tree 索引架構示意圖

R-tree 之建立方法流程中，若欲插入的資料點為 x ，則會先透過比較插入哪個節點後的面積，依照 MBR 之概念，R-tree 會選擇插入後面積最小的節點做插入。若資料點 x 插入節點 N 擁有最小之面積且節點 N 有足夠的空間，則資料點 x 會直接插入 N 中，若沒有足夠的空間，則會分割節點 N ，透過節點 N 中兩距離最遠之資料點分割為節點 N_1 與節點 N_2 ，並重新調整原本在節點 N 的資料點，使各資料點皆在最佳的節點中。Beckmann 等人[2]於 2009 年應用 R-tree 建立真實多維數據之索引架構，結果顯示將有相關之資料點放入同個節點中可增加搜尋效率。Arge 等人[1]於 2008 年基於 R-tree 之概念建立索引架構，實施高效率之搜尋方法。

2.2.2 M-tree

M-tree 也是常見被使用於空間資料儲存的樹狀資料結構，概念由 Paolo Ciaccia 等人於 1997 年提出[20]，目的與 R-tree 一樣，將具有相同相似特徵之資料放在同一節點之中，但 M-tree 是以歐式距離(Euclidean distance)來決定每個資料點該放入哪個節點中，歐式距離公式如式(1)。

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (1)$$

相較於 R-tree，M-tree 使用圓心與半徑定義出節點之範圍，來判斷每個資料點該放入哪個節點中，可以針對多維特徵計算歐式距離後建立。示意圖與索引架構如圖 11、12 所示。Skopal 等人[22] [23]於 2003 及 2009 年應用 M-tree 建立了動態索引架構，加快了索引架構和搜索處理之速度。




圖 11 M-tree 結果示意圖




圖 12 M-tree 索引架構示意圖

2.2.3 G-tree

G-tree 主要是以資料內容之分佈建立的樹狀資料結構，概念由 Chen 等人[7]於 2013 年提出，目的與 R-tree、M-tree 一樣，將具有相同相似特徵之資料放在同一節點之中，但 G-tree 是以高斯函數(Gaussian function)為基礎計算之機率 P_q ，如式(2)。

$$P_q = \frac{1}{2\pi\sigma_x\sigma_y} \left(e^{-\left(\frac{\sigma_y^2(q_x - \mu_x)^2 + \sigma_x^2(q_y - \mu_y)^2}{2\sigma_x^2\sigma_y^2}\right)} \right) \quad (2)$$

之後 G-tree 會透過 P_q 與閾值來決定每個資料點該放入哪個節點中，並非如 R-tree 使用節點面積最小或如 M-tree 以距離最小來判斷每個資料點該放入哪個節點中，G-tree 示意圖如圖 13 所示。此設計也形成了 G-tree 的特色，G-tree 中同一節點之資料點，其中資料點之各特徵的數值都與節點中心的數值相當靠近，換言之，G-tree 內同一節點之資料點皆是高度相關的，建立完成之 G-tree 索引架構圖如圖 14 所示。Chen 等人[7]於 2013 年透過建立 G-tree 克服了過去方法在天際線中的問

題，並且透過實驗模擬則證實了在天際線問題中使用 G-tree 的有效性。




圖 13 G-tree 結果示意圖




圖 14 G-tree 索引架構示意圖

第三章 研究方法

本研究提出之方法將預測人群流量分為兩部分，分別為 Offline 訓練與 Online 運作兩部分，研究方法架構圖如圖 15 所示。在 Offline 訓練中分為三階段，第一階段計算各網格全年標準差作為後續演算法挑選網格之依據；第二階段利用 R-tree 索引架構建立 Space-MDL-LSTM，針對網格建立基礎模型與外掛模組；第三階段進行方法的績效評估。因此本研究會著重於第二階段之訓練，找出良好之結果、基礎模型與外掛模組之結合。最後 R-tree 索引架構能依網格特徵索引該選用的基礎模型與外掛模組，因應各區域之特徵變化做出預測。在 Online 運作部分，當人流資料輸入時，依其網格特徵透過 R-tree 選用基礎模型與外掛模組，並將兩者結合後預測未來人流。




圖 15 研究方法架構圖

3.1 計算各網格全年標準差

為了使模型先以較難預測之網格開始分節點，期望建模難度由難至易開始建立預測模型，使模型能被最合適之網格使用。本研究以網格全年的人流標準差作為判斷網格預測的難度，網格全年標準差越大代表其時間序列的起伏變動越大，也就越需要提早以該網格為單位建模，標準差公式如式(3)。後續將以標準差為依據由標準差大至小依序為各網格建模。

$$std = \sqrt{\frac{\sum_{i=1}^N (X_i - \mu)^2}{N}} \quad (3)$$

3.2 利用 R-tree 索引架構建立 Space-MDL-LSTM

經過前述步驟計算各網格全年標準差後，本研究第三步驟以 2.2.1 節所提出之 R-tree 索引架構建立 Space-MDL-LSTM，流程圖如圖 16 所示。以下為 R-tree 索引架構概念建立 Space-MDL-LSTM 之步驟。

Step1: 選取全年標準差最大且尚未分入節點之網格使用各節點基礎模型建立外掛模組並比較誤差，可得知以哪個節點之基礎模型所建立的外掛模組可得最小的誤差，在此定義該選取網格為網格 x 、得最小誤差之該節點為節點 N 、最小誤差為 e_{min} ，若 R-tree 索引架構中尚無分節點則以網格 x 為一節點，透過網格 x 建立該節點之基礎模型。建立基礎模型與外掛模組方法於 3.2.1 節介紹。

Step2: 若節點 N 之誤差 e_{min} 小於標準閾值 σ ，則網格 x 加入節點 N ，否則以網格 x 為一節點，透過網格 x 建立該節點之基礎模型，標準閾值 σ 可依照使用者所設定，本研究會以實驗模擬決定最合適之數值。

Step3: 若網格 x 加入節點 N 後大於節點最大容量，則需要透過節點分割演算法將節點 N 分割，網格 x 在 Space-MDL-LSTM 中的基礎模型將使用節點 N 之基礎模型，而外掛模組使用在 Step1 中建立之外掛模組，完成建立 Space-MDL-LSTM。節點分割演算法於 3.2.2 節介紹，節點最大容量可依照使用者所設定，本研究會以實驗模擬決定最合適之數值。

Step4: 重複 Step 1 至 Step 3，直到所有劇烈變動網格皆已分節點並建立 Space-MDL-LSTM。

本研究建立 Space-MDL-LSTM 的概念為樹狀結構是將相似的資料點放入同個節點中，而本研究依據 R-tree 的 MBR 的概念，不斷將網格與現有節點計算相似程度，再透過標準閾值的判斷是否加入相似後加入節點。




圖 16 R-tree 索引架構建立 Space-MDL-LSTM 流程圖

以本研究案例針對 Space-MDL-LSTM 流程進行舉例說明，假設 Space-MDL-LSTM 中標準閾值為 400、節點容量上限為 10。此時尚未有網格分入節點，則選取全年標準差最大的網格為中心經緯度座標 121.515_25.045 之網格，建立節點 1 並以此網格建立節點 1 之基礎模型。之後進行後續步驟，挑選目前全年標準差最大且尚未分入節點之網格為中心經緯度座標 121.490_25.060 的網格，使用節點 1 之基礎模型建立外掛模組並比較誤差，建立後誤差小於標準閾值 400，則加入節點 1，此時節點 1 內網格數量為 2，並無大於最大容量，進行後續步驟，挑選目前全年標準差最大且尚未分入節點之網格為中心經緯度座標 121.565_25.035 的網格，使用節點 1 之基礎模型建立外掛模組並比較誤差，若建立後誤差大於標準閾值 400，則建立節點 2 並以此網格建立節點 2 之基礎模型，若過程中有節點大於容量上限 10，

則需進行 3.2.2 節的節點分割演算法，此流程直到所有網格皆以建立 Space-MDL-LSTM 且加入節點後則結束。

3.2.1 建立基礎模型與外掛模組

本研究以網格之時間序列訓練基礎模型 LSTM，LSTM 能透過訓練資料的過程中，學習到該網格的長期特徵變化，為了提升模型的收斂速度及精準度，本研究會先將網格進行數據正規化，將時間序列的數值範圍等比例縮放到-1 至 1 之間後再輸入模型。

基礎模型 LSTM 運作主要透過輸入閘、遺忘閘、輸出閘三個開關控制資料是否儲存記憶單元或是否考慮記憶單元內的資料，之後再搭配激活函數即可預測未來的時間序列，可再依輸入資料的特性，選用不同激活函數，如較常應用的 ReLu、Sigmoid、Tanh 等，而本研究以非線性函數 Tanh 做為模型激活函數。LSTM 模型中輸入閘、遺忘閘、輸出閘、記憶單元、激活函數之功能如下[8]：

(i).輸入閘(Input Gate)：輸入閘可決定當前輸入是否要輸入模型中，數學式如式(4)。

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci} \circ c_{t-1} + b_i) \quad (4)$$

(ii).遺忘閘(Forget Gate)：遺忘閘可決定上一時間 cell 的狀態的多少比例可以影響當前 cell，若是遺忘閘輸出為 0，則代表上一時間點 cell 的狀態就無法對當前 cell 造成影響，數學式如式(5)。

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf} \circ c_{t-1} + b_f) \quad (5)$$

(iii).記憶單元(Memory Cell)：記憶單元將來自過去的訊息儲存在單元中，主要會透過輸入閘、遺忘閘、輸出閘控制是否儲存、遺忘及輸出。數學式如(6)。

$$c_t = f_t \circ c_{t-1} + i_t \circ \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (6)$$

(iv).輸出閘(Output Gate)：輸出閘決定了記憶單元的值是否輸出，如果輸出閘為關閉狀態，則無論記憶單元裡的值為多少，輸出都為 0。數學式如式(7)。

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co} \circ c_t + b_o) \quad (7)$$

(v).隱藏狀態(Hidden State)：隱藏狀態為當前 cell 的最終結果。數學式如式(8)。

$$h_t = o_t \circ \tanh(c_t) \quad (8)$$

(vi).激活函數(Activation Functions)：數學式如式(9)。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (9)$$

其中 W_{xi} 、 W_{hi} 、 W_{ci} 、 W_{xf} 、 W_{hf} 、 W_{cf} 、 W_{xc} 、 W_{hc} 、 W_{xo} 、 W_{ho} 、 W_{hc} 會隨著模型不斷訓練將以上權重調整至最佳解， b_i 、 b_f 、 b_c 、 b_o 為修正模型訓練結果及加快訓練速度之參數。

透過網格之時間序列建立基礎模型 LSTM 後，對於使用基礎模型預測不同網格的人群流量可能無法掌握不同網格更細部之時間特徵及短期趨勢，使基礎模型無法應變造成預測準確度不高，因此本研究基於 Wang 等人[31]於 2010 年以 Minimum Description Length(MDL)理論建立 HRNN 之基礎，目的透過相較於基礎模型規模較小之外掛模組提高整體建模效率以提升精準度。

MDL 理論最早由 Rissanen 提出[21]，這個想法是基於數據壓縮的概念，使用少於數據中符號數量的符號來精確地描述數據。MDL 理論可以用於構建預測模型之結構，已成功用於計算神經網路中神經元的最小數量，該神經網路使用最少數量的神經元就可以很好地仿效非線性系統之功能，鄭宇哲[39]於 2020 年透過此概念建立外掛模組，有效的補償網格與基礎模型 LSTM 間的差異。因此在本研究中以 MDL 理論建構外掛模組，以最少數量之模型補償網格與群中基礎模型之差異。

本研究外掛模組之概念為藉由建立額外的 LSTM 層與 Dense 層進行時間特徵補償，增加基礎模型的權重參數，目的為透過建立外掛模組，避免為了要提升預測人群流量之準確度，而建立過多的基礎模型及過度訓練且訓練效果不佳之問題。基礎模型與外掛模組架構圖如圖 17 所示，外掛模組共有兩層，其步驟為先將網格資料輸入至基礎模型進行預測，針對基礎模型拆解後提取出各層的輸出，乘上權重值

後作為外掛模組的各層輸入值。舉例說明，網格資料輸入至基礎模型中的 LSTM_1 層，產生之輸出值會乘上權重 PlusWeight_1 輸入至 LSTM_PLUS 中，而基礎模型中 LSTM_2 層之輸出值乘上權重 PlusWeight_2 與前述之 LSTM_PLUS 輸入至 Dense_PLUS 層中，最後再將基礎模型中 Dense 之輸出與外掛模組中 Dense_PLUS 之輸出結合後輸出，即為外掛模組之輸出值。




圖 17 基礎模型與外掛模組架構

外掛模組的參數會以隨機產生多個外掛模組的方式，經由與基礎模型結合後以誤差評估預測績效挑選最合適的外掛模組，若外掛模組相較於基礎模型有提升預測之準確度則保留；若沒有則替換外掛模組，直到找到能使預測績效最高且提升之外掛模組，假設本研究產生 1000 個外掛模組，將各外掛模組與基礎模型結合並比較績效，若外掛模型有提升預測準確度則保留該外掛模組；若沒有則代表此網格不適合此基礎模型，最後找到預測該網格績效最好且與基礎模型比較後有所提升之外掛模組，儲存外掛模組之模型架構與各層權重值，作為該網格之預測使用。

3.2.2 節點分割演算法

根據 3.2 節 Step3 中，若網格 x 加入節點 N 後大於節點最大容量，必須將節點 N 做分割，本研究提出之分割演算法步驟如下。

Step1:將節點 N 中預測誤差最大之網格 x_{max} 建立新的一節點 N_{max} ，並以網格 x_{max} 建立屬於該節點之外掛模組。

Step2:將節點 N 原網格各使用節點 N_{max} 之基礎模型與外掛模組建立各網格專屬外掛模組並比較誤差，以誤差是否小於 3.2 節中提及之標準閾值 σ 來判斷是否加入節點 N_{max} 。若誤差小於標準閾值 σ ，則加入節點 N_{max} ，誤差大於標準閾值 σ 之網格則留在原節點，即完成節點分割演算法。

針對節點分割演算法，以本研究案例舉例說明，假設 Space-MDL-LSTM 中標準閾值為 400、節點最大容量為 10，若此時節點 5 目前包含了 11 個網格，則節點 5 必須進行分割，首先透過步驟一挑選出節點 5 中標準差最大的網格為中心經緯度座標 121.455_25.000 之網格，並以此網格建立新節點 5_1，並且以中心經緯度座標 121.455_25.000 的網格建立與節點 5 基礎模型的外掛模組為節點 5_1 之外掛模組。步驟 2 是將節點 5 中其餘 10 個網格分別與節點 5_1 建立各網格專屬外掛模組並比較誤差，若誤差有小於標準閾值 400，則加入節點 5_1，若無則繼續留在節點 5，假設透過節點分割演算法，將節點 5 分割獨立出節點 5_1，其包含的網格數分別為 7、4，完成節點分割，進行 Space-MDL-LSTM 的後續步驟。

3.3 方法之績效評估

因本研究目的為改善過去研究之方法大範圍以小區域訓練預測模型而造成建模成本過高之缺點，將本研究建立之 Space-MDL-LSTM 與 R-tree 索引架構以四項指標與過去方法做比較，以(1)建立之模型數量、(2)建立之節點數量、(3)模型總建立時間、(4)模型更新時間這四項指標量驗證本研究提出之方法能降低建立模型之數量，提升模型建立與更新效率，減少模型之建置成本，(5)以模型誤差驗證本研究提出之方法對於人流之預測的有效性，誤差以 RMSE 作為計算方式，公式如式(10)，與過去方法之所有模型誤差做平均值與標準差之比較。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (10)$$

第四章 實驗模擬

本研究使用電信業者提供之行動數據人流資料來模擬驗證所提出之方法有效性與執行效率。本章節將分成三個部分，包含(1)資料集介紹、(2)Space-MDL-LSTM之參數設定、(3)實驗結果分析。本研究資料處理與實驗都是以 Python 撰寫，並執行於 Intel i5-8400 2.80GHz 的 CPU、Nvidia GTX 1080ti 的 GPU、搭配 48GB 記憶體以及 Windows 10 的作業軟體來完成。

4.1 資料集介紹

本研究使用某電信業者所提供之行動數據人流資料，因涉及保密協定，資料集部分僅公開部份資訊，其資料涵蓋區域為北北基桃宜地區，如圖 18 所示。其資料範圍為 2019 年 01 月 01 日至 2019 年 12 月 31 日，電信業者為維護使用者的個資安全，以每 500 公尺 x 500 公尺範圍的網格計算所涵蓋之人群流量，以經緯度紀錄網格中心點。2019 年資料集共 2924 個欄位，包含時間欄位與 2923 個網格，共 8760 個小時，資料集範例如表 1 所示。透過計算全年標準差之後，將標準差最大與最小之網格進行資料觀察，如表 2，在資料集中標準差最大的網格為臺北車站網格，人流序列圖如圖 19，透過圖 19 可見其網格人數變化非常大；而資料集中標準差最小的網格為華中橋堤外網格，人流序列圖如圖 20，由圖 20 發現雖然華中橋堤外網格較臺北車站網格來說較無明顯趨勢，因網格內較無明顯人數聚集地標使網格人數較易波動。而臺北車站網格較華中橋堤外網格有預測價值，因此本研究以標準差由大至小建立模型。




圖 18 人流資料集範圍




圖 19 臺北車站網格之人流序列圖




圖 20 華中橋堤外網格之人流序列圖

表 1 2019 年行動數據人流資料集

Time	121.510_24.775	121.430_24.845	121.445_24.845	121.550_24.845
2019/01/01- 00:00	34	15	715	89
...	...	...	...	...
2019/12/31- 22:00	45	34	987	124
2019/12/31- 23:00	43	22	812	107

表 2 各網格全年標準差表

網格	標準差	網格內地標
121.515_25.045	5258.382	臺北車站
121.565_25.035	4529.177	臺北 101
121.565_25.040	4195.094	捷運市政府
...	...	
121.260_25.110	87.823	蘆竹工業區
121.495_25.010	84.504	華中橋堤外

4.2 Space-MDL-LSTM 之參數設定

本研究提出之 Space-MDL-LSTM 方法需要決定標準閾值 σ 與節點最大容量，因此本節透過實驗的方式比較績效結果後選擇較佳之數值，參數設定實驗會以標準差最大的前 300 個網格作為實驗模擬對象，參數設定實驗分為兩階段，第一階段以標準閾值 $\sigma = 400$ 為基準，觀察不同的節點最大容量對於績效的影響，選擇績

效最好之節點最大容量。第二階段以第一階段選擇的節點最大容量為基準，觀察不同的標準閾值對於績效的影響，並選擇績效最好之標準閾值 σ 。績效中整體的預測準確度會以誤差 RMSE 比較，方法的架構大小以基礎模型數量與節點數量比較，而實驗中的基礎模型架構為過去三小時輸入至模型預測未來一小時，資料集會以訓練 70%、測試 15%與驗證 15%的比例做驗證。

第一階段之不同節點最大容量實驗共測試了五種數量，依序為 5、7、10、12、15，其績效比較表如表 3。透過表 3 可以發現節點最大容量越高，則誤差 RMSE 會越高、節點數量越少，反之節點最大容量如果越低，則誤差 RMSE 會越低、節點數量越多。其原因為若 Space-MDL-LSTM 中節點最大容量越高，則每個節點容納的網格越多，網格也會因此與較多網格共用節點內的外掛模組，誤差相對就會越高；而節點最大容量越低，雖然網格可以被分配到較適合之節點，但節點數量也會相對增加。而節點最大容量對於基礎模型數量並較無明顯差異。經過表 3 比較後發現，節點最大容量為 10 時，其節點數量有明顯的轉折點，而 RMSE 相對於其他數量也落於中間數值，因此透過第一階段參數設定實驗將 Space-MDL-LSTM 中節點最大容量設為 10 供後續實驗使用。

第二階段共測試五種不同標準閾值數量，依序為 300、400、500、600、700，績效比較表如表 4，透過表 4 發現標準閾值越高，誤差會越高，基礎模型與節點數量會越少，反之標準閾值越低，誤差會越低，基礎模型數量越多。其原因為若 Space-MDL-LSTM 中標準閾值越高，每個節點可接受的網格類型越多，雖基礎模型與節點數量較少，但也因為節點內的網格加入較不合適的節點，導致整體的預測精準度較低，反之標準閾值越低，節點對於網格的接受度就越低，雖預測精準度較高，但也導致許多網格需要額外建立基礎模型。而標準閾值對於節點數量較無明顯差異。經過表 4 比較後發現，標準閾值為 400 時，其基礎數量有明顯的轉折點，而 RMSE 相對於其他數量也落於中間數值，因此透過第二階段參數設定實驗將 Space-MDL-LSTM 中標準閾值設為 400 供後續實驗使用。

表 3 不同節點最大容量績效比較表

標準閥值	節點最大容量	RMSE	基礎模型數量	節點數量
400	5	228.00	31	119
	7	247.97	27	96
	10	244.78	29	65
	12	251.62	26	61
	15	252.72	28	54

表 4 不同標準閥值績效比較表

標準閥值	節點最大容量	RMSE	基礎模型數量	節點數量
300	10	217.58	51	81
400		244.78	29	65
500		290.13	22	80
600		309.54	18	71
700		323.23	14	57

4.3 實驗結果分析

本節會以上述實驗所設置之標準閥值為 400、節點最大容量為 10 的 Space-MDL-LSTM 與未使用 Space-MDL-LSTM 的個別建立方法作為對照組比較績效並做量化與質化的驗證，在量化驗證的部分，目的為驗證本研究提出之方法的有效性，除了驗證其預測精準度與基礎模型與節點數量，還有比較花費時間來驗證是否有提高效率，花費時間共可分為四種，建立、更新頻率為日、週、月的更新時間。在質化驗證的部分會去探討在每個節點內的網格是否有相關，目的為驗證本研究提出之方法的合理性。

在量化驗證的部分，首先透過 RMSE 來比較方法間的誤差，實驗組為本研究

提出之 Space-MDL-LSTM，對照組有兩種，(1)將每個節點內的網格只使用基礎模型預測，不使用外掛模組進行補償，目的為驗證加入外掛模組後是否能有效降低誤差。(2)將每個網格個別建立基礎模型，目的為驗證本研究提出之方法的有效性。可透過圖 21 觀察三種方法的誤差比較直方圖與累加機率圖，透過直方圖與累加機率圖能觀察不同方法的誤差分布，其中綠色為對照組中只使用基礎模型預測不使用外掛模組的方法一、藍色為對照組中每個網格個別建立基礎模型的方法二、橘色為本研究提出之 Space-MDL-LSTM，x 軸為誤差 RMSE，直方圖的 y 軸為數量，累加機率圖的 y 軸為機率。由圖 21 可以發現在誤差 RMSE 範圍 0 到 100 的只有 Space-MDL-LSTM 與對照組方法二，代表 Space-MDL-LSTM 在最小誤差上優於對照組方法一；橘色線雖然在 RMSE 低於 300 時較綠色線差，但隨著 RMSE 超過 300 後越大，效果越明顯的優於方法一，尤其在誤差 RMSE 範圍 400 到 500 間 Space-MDL-LSTM 明顯低於對照組方法一。因此透過此圖可以得證，與節點內網格只使用基礎模型預測的對照組方法一相比，Space-MDL-LSTM 的 RMSE 平均數值、最小數值都明顯較優，也證明了本研究使用外掛模組有效補償了使用基礎模型預測的不足，可以消除掉較大的誤差，讓每一個網格預測都差不多。而後續透過預測績效進一步比較 Space-MDL-LSTM 與個別建立方法的建模成本差異。績效比較表如表 5 所示。由表 5 得知 Space-MDL-LSTM 與個別建立基礎模型績效並進行比較後，可發現本研究提出之 Space-MDL-LSTM 在誤差與建立花費時間上高於個別建立基礎模型方法 29.8%、135%，其結果可解釋為因網格是使用外掛模組來補償與基礎模型的預測的不足，相對於個別建立基礎模型，外掛模組能補償的能力有限，因此誤差會較高，雖然 RMSE 看起來誤差百分比差非常多，但實際 RMSE 差距約 60，其實以人流變化來看，誤差並不算大。但也因為需要去建立各個網格的外掛模組，需要以隨機產生多個外掛模組選擇績效最好的方式產生，相對於基礎模型的建立花費時間較高，但也因基礎模型數量節省了 90.3% 的數量，在更新上的優勢較為明顯，對於更新頻率從日到月來說，本研究提出之方法更新花費時間約節省了 90%，

其影響的是日後模型上線時，能即時更新模型，原本需要更新 300 個基礎模型，現在只需要更新 29 個模型，更新時間大幅下降 90%。且本研究目前實驗模擬僅以 300 個網格做測試，若以真實資料為例，資料範圍內網格數量達到 2923 格，則需 2923 個基礎模型，若使用本研究提出之 Space-MDL-LSTM 方法，在誤差相差 29.8%的前提下，大幅提高模型更新的效率近 90.3%。




圖 21 三種方法誤差比較直方與累加機率圖

表 5 Space-MDL-LSTM 與個別建立績效比較表

項目	Space-MDL-LSTM	個別建立	差距
RMSE	244.78	188.62	+29.8%
基礎模型數量	29	300	-90.3%
節點數量	65	300	-78.3%
建立花費時間(s)	9707	4122	+135%
日更新花費時間(s)	138	1426	-90.3%
週更新花費時間(s)	141	1457	-90.3%
月更新花費時間(s)	150	1584	-90.5%

在質化驗證的部分，因 Space-MDL-LSTM 是將具有相關的網格組成同節點並且共用基礎模型，因此質化驗證將本研究針對 Space-MDL-LSTM 的結果進行探討網格間是否有相關，表 6 為 Space-MDL-LSTM 網格節點對照表，可以透過表 6 得知網格之間是否使用同個基礎模型與外掛模組進行預測，進而得知網格之間的相關；圖 22 可看到 Space-MDL-LSTM 的結果將網格投點至地圖上視覺化，其顏色相近代表其節點相近，經由圖 23 可得知 Space-MDL-LSTM 各節點網格數量，後續將舉四個節點作為例子探討節點內的網格，驗證 Space-MDL-LSTM 的合理性。

表 6 Space-MDL-LSTM 網格節點對照表

網格	節點
121.515_25.045	1
121.490_25.060	2
121.565_25.035	2_1
...	...
121.455_25.000	16_3_1_1




圖 22 Space-MDL-LSTM 結果示意圖




圖 23 Space-MDL-LSTM 各節點網絡數量統計圖

在 Space-MDL-LSTM 結果中，由圖 24、25 可發現節點編號 1 內只有一個網絡，此網絡位於臺北市中心—臺北車站。臺北車站網絡在資料集中屬標準差最大之網絡，可見其網絡的變化幅度相當大，本研究探討發現臺北車站網絡中含有多種屬性的地標，像是(1)交通要點型的台鐵、高鐵、捷運、公車站(2)商業區型的微風臺北車站、新光三越站前店、臺北地下街(3)文教業型的補習業者(4)小吃美食商圈等等，此種具有多屬性的地標人流組成相當複雜，對於導致人流趨勢也較起伏不定，相較於其他網絡大不相同，因此其餘網絡無一與臺北車站網絡類似網絡內包含這麼多種屬性，驗證了節點編號 1 內只有臺北車站網絡的合理性。




圖 24 Space-MDL-LSTM 節點編號 1 示意圖




圖 25 Space-MDL-LSTM 節點編號 1 投點示意圖




圖 26 節點編號 1 內網格時間序列

在 Space-MDL-LSTM 結果中，由圖 27、28 可發現節點編號 2 內共有 18 個網格，可發現在節點編號 2 內又額外分成四個節點 2_1、2_2、2_3、2_4，透過地圖視覺化統整結果發現，在節點 2 中的 9 個網格，可以統整發現其屬性皆偏向於住宅區，住宅區最著代表性的不乏就是三峽的北大特區、萬華青年公園住宅區及萬隆住宅區；而在節點 2_1 中，因節點 2 的基礎模型是由臺北 101 網格所訓練建立，因此可以得知他的標準差相較於其他節點編號 2 內的網格大，因此在第一次節點切割時，獨立成節點 2_1，也因臺北 101 網格同時結合了商圈、世貿、臺北市政府、

住宅，也是屬於並無其餘網格與其相似的多屬性網格；在節點 2_2 中，相似點都是住宅區，但是在這三個網格中，大龍峒網格包含了臺北市著名的保安宮、大直北安網格包含了大直高中與北安國中、南樹林網格包含了南樹林車站周圍，與節點 2 單純的住宅區相比，節點 2_2 中多了其他屬性，像是活動時間範圍為白天的保安宮、學校與台鐵定義為通勤車站的南樹林車站，因此可以統整節點 2_2 內的網格為具有活動時間範圍為白天的地標與住宅區網格；節點 2_3 較易發現其包含的網格為活動時間範圍為晚上的夜市、商圈等；而在節點 2_4 中為偏向辦公屬性的信義敦化網格。統整以上對於節點編號 2 的分析，可以發現在節點編號 2 在基礎模型訓練網格為臺北 101 中包含了活動時間範圍為通勤、商業、辦公、住宅等屬性，節點內其餘網格也都具備此類屬性，也透過圖 29 可以發現，x 軸為以每小時為單位的時間，y 軸為人流量，每個節點內的網格人流序列明顯有相同之處，如圖 29(c)，節點 2_2 內的人流序列趨勢也很明顯的相似，圖 29(f)也將在節點編號 2 內的所有網格人流序列一起觀察，可以發現使用變化趨勢有類似之處，證明了節點編號 2 內網格使用同個基礎模型預測的合理性。




圖 27 Space-MDL-LSTM 節點編號 2 示意圖




圖 28 Space-MDL-LSTM 節點編號 2 投點示意圖




圖 29 節點編號 2 內各節點內網絡時間序列

在 Space-MDL-LSTM 結果中，由圖 30、31 可發現節點編號 3 內共有 2 個網格，包含了師大附中與中央健保署網格及臺北市政府與捷運市政府網格，透過地圖視覺化發現這兩個網格在白天較有相同之趨勢，像是市政府與師大附中與中央健保署相同，而師大附中旁又包含了捷運大安站，與捷運市政府站雷同，但臺北市政府與捷運市政府網格相較於師大附中與中央健保署網格多了統一時代廣場與新光三越信義新天地，且為台節點編號 3 之訓練網格，因此師大附中與中央健保署有額外建立外掛模組來補償與節點編號 3 基礎模型的不足，可以透過圖 32 發現這兩的網格在變化趨勢上有很明顯的相似之處。




圖 30 Space-MDL-LSTM 節點編號 3 示意圖




圖 31 Space-MDL-LSTM 節點編號 3 投點示意圖




圖 32 節點編號 3 內網格時間序列




圖 33 Space-MDL-LSTM 節點編號 16 投點示意圖

而其中網格數量最多的為節點編號 16，透過圖 23 加總後可發現節點內網格數量達 124 個網格，節點編號 16 共可分為 20 個節點，透過將網格進行地圖視覺化後發現如圖 33，節點編號 16 的網格橫跨了臺北市、新北市、桃園市與基隆市。網格間的最大共同點在於其網格內都包含學校，其學校規模包含大學、高中、國中、小學，大學包含像是台灣大學、臺北科技大學、中央大學、輔仁大學等，高中則是包含松山高中、中山女高、板橋高中等，可以分析歸納出節點編號 16 內網格數量這麼多是因為這些網格都大致上包含了學校或與學校人流趨勢相近的地標，主要

也因學校有固定的上下學時間、學校只有平日會有學生，因此假日人流會明顯與平日區別，而基礎模型會以學校人流趨勢去學習，後續網格只要是符合學校趨勢的則都會加入節點編號 16，可以透過圖 34 發現，雖節點內網格數量較多，但不難發現同屬於節點編號 16 內的網格變化趨勢具有共同規律。

經過上述的量化與質化驗證可以得證，Space-MDL-LSTM 於預測精準度與建立時間雖與過去方法相比較差，但也因基礎模型與節點數量的降低，更新花費時間不論是日、週、月的更新頻率皆優於過去方法將近 90%，也透過分析節點內的網格屬性具有高度相似，網格屬性相似就可代表人流趨勢相似，驗證了使用同個基礎模型與外掛模組的合理性。




圖 34 節點編號 16 內網格時間序列

第五章 結論與未來研究

全城市的人流預測議題近年越來越受學者們重視，因為全城市的人流預測可以為政府提前對人流的變化做出各項反應，進而提升城市的服務品質。綜觀過往全城市人流預測之研究，大多為兩種方式執行，(1)過往對於大區域之人流預測時，因大區域中包含太多種不同的區域類型，如商業區、住宅區、交通熱點等，若只使用單一模型預測會因區域間太多不同影響之因素導致模型預測準確度不高，甚至模型無法進行有效地預測。(2)將預測模型從大區域細分成小區域，再以小區域各自建立，目的使整體模型準確度較高，但也因各個模型內含大量參數導致整體大區域模型體積龐大造成運行時間長，造成現實中整體上線預測非常困難。因此針對過往人流大範圍預測之研究對於小區域建模成本過高之缺點，本研究透過 R-tree 索引架構建置應用於人群流量預測的 Space-MDL-LSTM 模型。Space-MDL-LSTM 包含基礎模型 LSTM、基於 MDL 理論之外掛模組，並且對於基礎模型與外掛模組之結果建立索引架構，期望透過預測模型間的誤差來判斷網格間的相似性，模型能夠進行長期及短期的人群流量預測，並加快整體模型預測與更新效率。

在實驗結果中，透果量化與質化驗證了 Space-MDL-LSTM 於預測精準度與建立時間雖與過去方法相比較差，但也因基礎模型與節點數量的降低，更新花費時間不論是日、週、月的更新頻率皆優於過去方法將近 90%，也透過分析節點內的網格屬性具有高度相似，網格屬性相似就可代表人流趨勢相似，驗證了使用同個基礎模型與外掛模組的合理性。

在日後研究中，因城市人群流量與許多其他因素相關，像是交通流量、天氣等，增加額外的資料集能幫助模型更好的提取特徵，若資料輸入越多，本研究之方法的效果就會更明顯，也能使降低誤差，縮小與個別建立基礎模型誤差上的差距，在外掛模組建立的部分，可以透過演算法建立的方式取代隨機產生，能使整體績效更高，也能試著透過合併節點，調整各節點的基礎模型，能避免結果落入區域最佳解。

參考文獻

- [1] Arge, L., Berg, M. D., Haverkort, H., & Yi, K. (2008). The priority R-tree: A practically efficient and worst-case optimal R-tree. *ACM Transactions on Algorithms*, 4(1), 1-30.
- [2] Beckmann, N., & Seeger, B. (2009). A revised r*-tree in comparison with related index structures. In *Proceedings of the 2009 ACM SIGMOD International Conference on Management of data* (pp. 799-812).
- [3] Bilal, M., Marjani, M., Hashem, I. A. T., Gani, A., Liaqat, M., & Ko, K. (2019). Profiling and predicting the cumulative helpfulness (Quality) of crowd-sourced reviews. *Information*, 10(10), 295.
- [4] Ceapa, I., Smith, C., & Capra, L. (2012). Avoiding the crowds: understanding tube station congestion patterns from trip data. In *Proceedings of the ACM SIGKDD international workshop on urban computing* (pp. 134-141).
- [5] Chan, A. B., & Vasconcelos, N. (2011). Counting people with low-level features and Bayesian regression. *IEEE Transactions on Image Processing*, 21(4), 2160-2177.
- [6] Chen, E., Ye, Z., Wang, C., & Xu, M. (2019). Subway passenger flow prediction for special events using smart card data. *IEEE Transactions on Intelligent Transportation Systems*, 21(3), 1109-1120.
- [7] Chen, Y. C., & Lee, C. (2013). G-Tree: A Novel Index Structure for Subspace Skyline Query. *International Journal of e-Education, e-Business, e-Management and e-Learning*, 3(6), 483.
- [8] Gers, F. A., Schmidhuber, J., & Cummins, F. (1999). Learning to forget: Continual prediction with LSTM.
- [9] Guttman, A. (1984). R-trees: A dynamic index structure for spatial searching.

- In *Proceedings of the 1984 ACM SIGMOD international conference on Management of data* (pp. 47-57).
- [10] Hoang, M. X., Zheng, Y., & Singh, A. K. (2016). FCCF: forecasting citywide crowd flows based on big data. In *Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems* (pp. 1-10).
- [11] Hu, R., Chiu, Y. C., & Hsieh, C. W. (2020). Crowding prediction on mass rapid transit systems using a weighted bidirectional recurrent neural network. *IET Intelligent Transport Systems*, 14(3), 196-203.
- [12] Jamil, M. S., & Akbar, S. (2017). Taxi passenger hotspot prediction using automatic ARIMA model. In *2017 3rd International Conference on Science in Information Technology (ICSITech)* (pp. 23-28). IEEE.
- [13] Jin, W., Lin, Y., Wu, Z., & Wan, H. (2018). Spatio-temporal recurrent convolutional networks for citywide short-term crowd flows prediction. In *Proceedings of the 2nd International Conference on Compute and Data Analysis* (pp. 28-35).
- [14] Li, Y., & Cao, H. (2018). Prediction for tourism flow based on LSTM neural network. *Procedia Computer Science*, 129, 277-283.
- [15] Lippi, M., Bertini, M., & Frasconi, P. (2013). Short-term traffic flow forecasting: An experimental comparison of time-series analysis and supervised learning. *IEEE Transactions on Intelligent Transportation Systems*, 14(2), 871-882.
- [16] Liu, L., Zhen, J., Li, G., Zhan, G., He, Z., Du, B., & Lin, L. (2020). Dynamic Spatial-Temporal Representation Learning for Traffic Flow Prediction. *IEEE Transactions on Intelligent Transportation Systems*.
- [17] Liu, P., Zhang, Y., Kong, D., & Yin, B. (2019). Improved Spatio-Temporal Residual Networks for Bus Traffic Flow Prediction. *Applied Sciences*, 9(4), 615.
- [18] Liu, Y., Qin, Y., Guo, J., Cai, C., Wang, Y., & Jia, L. (2018). Short-term forecasting

- of rail transit passenger flow based on long short-term memory neural network. In *2018 International Conference on Intelligent Rail Transportation (ICIRT)* (pp. 1-5). IEEE.
- [19] Panigrahi, S., & Behera, H. S. (2017). A hybrid ETS–ANN model for time series forecasting. *Engineering Applications of Artificial Intelligence*, 66, 49-59.
- [20] PaoloCiaccia, M. P. (1997). M-tree: An efficient access method for similarity search in metric spaces. In *Proceedings of the 23rd VLDB Conference, Athenes, Greece* (pp. 357-368).
- [21] Rissanen, J. (1978). Modeling by shortest data description. *Automatica*, 14(5), 465-471.
- [22] Skopal, T., & Lokoč, J. (2009). New dynamic construction techniques for M-tree. *Journal of Discrete Algorithms*, 7(1), 62-77.
- [23] Skopal, T., Pokorný, J., Krátký, M., & Snášel, V. (2003). Revisiting M-tree building principles. In *East European Conference on Advances in Databases and Information Systems* (pp. 148-162). Springer, Berlin, Heidelberg.
- [24] Stenneth, L., Wolfson, O., Yu, P. S., & Xu, B. (2011). Transportation mode detection using mobile phones and GIS information. In *Proceedings of the 19th ACM SIGSPATIAL international conference on advances in geographic information systems* (pp. 54-63).
- [25] Su, H., Zhang, L., & Yu, S. (2007). Short-term traffic flow prediction based on incremental support vector regression. In *Third International Conference on Natural Computation (ICNC 2007)* (Vol. 1, pp. 640-645). IEEE.
- [26] Sun, J., Zhang, J., Li, Q., Yi, X., Liang, Y., & Zheng, Y. (2020). Predicting citywide crowd flows in irregular regions using multi-view graph convolutional networks. *IEEE Transactions on Knowledge and Data Engineering*.

- [27] Sun, Y., Leng, B., & Guan, W. (2015). A novel wavelet-SVM short-time passenger flow prediction in Beijing subway system. *Neurocomputing*, 166, 109-121.
- [28] Tian, Y., Zhang, K., Li, J., Lin, X., & Yang, B. (2018). LSTM-based traffic flow prediction with missing data. *Neurocomputing*, 318, 297-305.
- [29] Turiel, J., & Aste, T. (2020). Wisdom of the crowds in forecasting COVID-19 spreading severity. *arXiv preprint arXiv:2004.04125*.
- [30] Van Der Voort, M., Dougherty, M., & Watson, S. (1996). Combining Kohonen maps with ARIMA time series models to forecast traffic flow. *Transportation Research Part C: Emerging Technologies*, 4(5), 307-318.
- [31] Wang, J. S., & Hsu, Y. L. (2010). An MDL-based Hammerstein recurrent neural network for control applications. *Neurocomputing*, 74(1-3), 315-327.
- [32] Williams, B. M., Durvasula, P. K., & Brown, D. E. (1998). Urban freeway traffic flow prediction: application of seasonal autoregressive integrated moving average and exponential smoothing models. *Transportation Research Record*, 1644(1), 132-141.
- [33] Zhang, J., Zheng, Y., Qi, D., Li, R., Yi, X., & Li, T. (2018). Predicting citywide crowd flows using deep spatio-temporal residual networks. *Artificial Intelligence*, 259, 147-166.
- [34] Zhang, J., Zheng, Y., Qi, D., Li, R., & Yi, X. (2016). DNN-based prediction model for spatio-temporal data. In *Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems* (pp. 1-4).
- [35] Zhang, N., Zhang, Y., & Lu, H. (2011). Seasonal autoregressive integrated moving average and support vector machine models: prediction of short-term traffic flow on freeways. *Transportation Research Record*, 2215(1), 85-92.
- [36] Zhene, Z., Hao, P., Lin, L., Guixi, X., Du, B., Bhuiyan, M. Z. A., ... & Li, D. (2018).

Deep convolutional mesh RNN for urban traffic passenger flows prediction. In *2018 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation* (pp. 1305-1310). IEEE.

[37] Zhou, Y., Chen, H., Li, J., Wu, Y., Wu, J., & Chen, L. (2019). Large-Scale Station-Level Crowd Flow Forecast with ST-Unet. *ISPRS International Journal of Geo-Information*, 8(3), 140.

[38] Zou, Z., Gao, P., & Yao, C. (2018). City-Level Traffic Flow Prediction via LSTM Networks. In *Proceedings of the 2nd International Conference on Advances in Image Processing* (pp. 149-153)

[39] 鄭宇哲(2020)。應用輕量化外掛式深度學習模型於空間型態時間序列之預測。國立雲林科技大學工業工程與管理系碩士論文，雲林縣。

